Mathematik von Grund auf — Band 2

Die Kunst der linearen Struktur

Eine vollständige Einführung in die Lineare Algebra



Von den ersten Gleichungssystemen bis zur Singulärwertzerlegung
Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Stand der Forschung: August 2026

Mathematik von Grund auf — Band 2
Die Kunst der linearen Struktur · Lineare Algebra

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Simulationen, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/mathematik-von-grund-auf`
Dauerhaft archiviert bei Zenodo: `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Mathematik von Grund auf, Band 2: Die Kunst der linearen Struktur*. Fassung 1.0.1. `https://doi.org/10.5281/zenodo.23698547`

Satz: LaTeX mit Palatino. Fassung 1.0.1, Oktober 2026. 167 Seiten.

Vorwort: Warum ausgerechnet „linear“?

Es gibt einen Witz unter Mathematikern: Die Mathematik zerfällt in zwei Teile – die lineare Algebra und den Rest, und der Rest wird gelöst, indem man ihn linearisiert.

Wie die meisten guten Witze ist er im Kern wahr. Die Differentialrechnung ist der Versuch, eine krumme Funktion in jedem Punkt durch eine *lineare* Abbildung zu ersetzen. Die Quantenmechanik ist buchstäblich lineare Algebra in unendlichdimensionalen Räumen. Ein neuronales Netz besteht aus Matrixmultiplikationen, unterbrochen von kleinen nichtlinearen Zwischenschritten. Die Suchmaschine, mit der Sie Dinge finden, berechnet einen Eigenvektor.

Der Grund ist einfach: *Lineare Probleme kann man lösen.* Vollständig, algorithmisch, in endlich vielen Schritten. Für kaum eine andere Klasse mathematischer Probleme gilt das. Deshalb ist die lineare Algebra nicht ein Gebiet unter vielen, sondern das Werkzeug, mit dem man alle anderen bearbeitet.

> **Was dieses Buch will**
>
> Sie sollen am Ende nicht nur rechnen können, sondern *sehen*. Sie sollen wissen, warum die Matrixmultiplikation so absurd definiert ist, wie sie definiert ist – und dann verstehen, dass sie die einzig mögliche Definition war. Sie sollen bei einer Determinante nicht an eine Rechenvorschrift denken, sondern an ein orientiertes Volumen. Und Sie sollen bei den Wörtern „Eigenwert“ und „Singulärwertzerlegung“ nicht zusammenzucken, sondern ein Bild vor Augen haben.

Die drei Regeln, wie in Band 1

Erstens: Es gibt kein „man sieht leicht“. Wo ein Beweis eine Idee benutzt, die vom Himmel zu fallen scheint, steht dabei, woher sie kommt. Der Steinitzsche Austauschsatz zum Beispiel wirkt wie ein technisches Hilfsmittel – bis man versteht, dass die *gesamte* Dimensionstheorie an ihm hängt und dass sein Beweis nichts anderes ist als sorgfältiges Buchführen.

Zweitens: Motivation vor Definition. Niemand hat je die Vektorraumaxiome aufgeschrieben, weil sie hübsch aussahen. Sie sind die Destillation dessen, was Gleichungssysteme, Funktionenräume, Polynome und Pfeile in der Ebene gemeinsam haben. Ich zeige erst das Gemeinsame, dann die Axiome.

Drittens: Aufgaben mit vollständigen Lösungen. Jede Aufgabe ist durchgerechnet – nicht als Ergebniskontrolle, sondern als Vorführung. Rechnen Sie zuerst selbst.

> **Eine besondere Warnung für dieses Gebiet**
>
> Lineare Algebra hat eine Eigenschaft, die sie von der Zahlentheorie unterscheidet: Man kann sie *scheinbar* verstehen, ohne sie zu verstehen.
> Es ist möglich, den Gauß-Algorithmus fehlerfrei auszuführen, Determinanten zu berechnen, Eigenvektoren zu bestimmen – und trotzdem keine Ahnung zu haben, was dabei geschieht. Die Rechnungen sind mechanisch genug, dass sie das Verständnis ersetzen können.
> Deshalb enthält dieses Buch überall dort, wo eine Rechenvorschrift eingeführt wird, einen Abschnitt „Was hier eigentlich passiert“. Überspringen Sie diese Abschnitte nicht. Sie sind der Grund, warum das Buch existiert.

Zum Aufbau

- **Teil I** (Kap. 1–3) beginnt beim Konkreten: lineare Gleichungssysteme, der Gauß-Algorithmus, Matrizen. Alles ist hier Rechnung – aber jede Rechnung wird begründet.
- **Teil II** (Kap. 4–6) abstrahiert: Vektorräume, lineare Unabhängigkeit, Basis, Dimension. Hier findet der eigentliche Sprung statt, und er ist der schwierigste im ganzen Buch.
- **Teil III** (Kap. 7–9) behandelt lineare Abbildungen, Darstellungsmatrizen, Basiswechsel und den Dimensionssatz – das Herzstück der Theorie.
- **Teil IV** (Kap. 10–11) entwickelt die Determinante aus dem Volumenbegriff und beweist die Leibniz-Formel, die Laplace-Entwicklung und die Cramersche Regel vollständig.
- **Teil V** (Kap. 12–14) ist der Eigenwerttheorie gewidmet: charakteristisches Polynom, Diagonalisierbarkeit, Cayley–Hamilton, Jordansche Normalform – diese vollständig, mit Konstruktionsverfahren.
- **Teil VI** (Kap. 15–18) bringt Geometrie ins Spiel: Skalarprodukte, Gram–Schmidt, kleinste Quadrate, Spektralsatz, quadratische Formen und die Singulärwertzerlegung.
- **Teil VII** (Kap. 19–21) behandelt Numerik, Anwendungen und den aktuellen Forschungsstand – einschließlich der Entwicklung beim Matrixmultiplikationsexponenten, die noch im August 2026 einen neuen Rekord hervorgebracht hat.

Im Anhang finden Sie eine Formelsammlung, eine Zeitleiste, ein Glossar und ein kommentiertes Literaturverzeichnis mit vollständigen Angaben. Verweise der Form [17] beziehen sich darauf.

Ein Gebiet, das rückwärts entstand

Die lineare Algebra ist historisch *umgekehrt* zu ihrer heutigen Darstellung gewachsen.
Zuerst kamen die Gleichungssysteme – die chinesischen *Neun Kapitel* lösen um 200 v. Chr. ein 3×3-System mit dem Verfahren, das wir heute Gauß-Algorithmus nennen. Dann kamen die Determinanten (Seki 1683, Leibniz 1693). Dann, erst um 1850, die Matrizen als eigenständige Objekte (Cayley, Sylvester). Und ganz zuletzt, um 1888, der abstrakte Vektorraumbegriff (Peano), der heute am Anfang jeder Vorlesung steht.
Das ist typisch: Das Allgemeine wird zuletzt gefunden, weil man erst genug Spezialfälle braucht, um zu erkennen, was sie gemeinsam haben. Dieses Buch geht deshalb historisch vor – vom Konkreten zum Abstrakten. Das ist langsamer, aber es ist der Weg, auf dem Verständnis entsteht.

Die Mathematik ist die Kunst, verschiedenen Dingen denselben Namen zu geben.
— Henri Poincaré, 1908

Contents

Vorwort **iii**

I Das Konkrete: Gleichungen und Matrizen **1**

1 Lineare Gleichungssysteme **3**
1.1 Wo alles anfängt . . . 3
1.2 Die drei Möglichkeiten – geometrisch . . . 4
1.3 Der Gauß-Algorithmus . . . 5
1.4 Der allgemeine Fall: freie Variablen . . . 8
1.5 Wann ist ein System lösbar? . . . 10
1.6 Aufwand: Warum der Algorithmus praktikabel ist . . . 12

2 Matrizen **15**
2.1 Von der Tabelle zum Objekt . . . 15
2.2 Die Matrixmultiplikation – und warum sie so aussieht . . . 15
2.3 Die Transponierte . . . 18
2.4 Die Inverse . . . 19
2.5 Blockmatrizen und die LR-Zerlegung . . . 23

II Der abstrakte Sprung **25**

3 Vektorräume **27**
3.1 Der schwierigste Schritt des Buches . . . 27
3.2 Körper – der Vorrat an Skalaren . . . 27
3.3 Die Vektorraumaxiome . . . 28
3.4 Beispiele – vom Vertrauten zum Ungewohnten . . . 30
3.5 Untervektorräume . . . 31
3.6 Linearkombinationen und Erzeugendensysteme . . . 33

4 Basis und Dimension **37**
4.1 Lineare Unabhängigkeit . . . 37
4.2 Basis . . . 39
4.3 Der Steinitzsche Austauschsatz . . . 40
4.4 Basisergänzung und Konsequenzen . . . 42
4.5 Zeilenrang gleich Spaltenrang . . . 45

III Lineare Abbildungen **47**

5 Lineare Abbildungen **49**
5.1 Der eigentliche Gegenstand 49
5.2 Der Fortsetzungssatz 50
5.3 Kern und Bild 51
5.4 Der Dimensionssatz 51
5.5 Darstellungsmatrizen 54
5.6 Basiswechsel 56
5.7 Isomorphismen 58

IV Determinanten **61**

6 Die Determinante **63**
6.1 Die Frage nach dem Volumen 63
6.2 Permutationen 64
6.3 Die Leibniz-Formel 65
6.4 Eigenschaften und Berechnung 67
6.5 Laplace-Entwicklung und Cramersche Regel 70
6.6 Geometrische Deutung 72

V Eigenwerte **75**

7 Eigenwerte und Eigenvektoren **77**
7.1 Die Leitfrage 77
7.2 Das charakteristische Polynom 77
7.3 Diagonalisierbarkeit 80
7.4 Anwendung: Potenzen und Rekursionen 83
7.5 Der Satz von Cayley–Hamilton 85

8 Die Jordansche Normalform **89**
8.1 Was tun, wenn Diagonalisieren scheitert? 89
8.2 Hauptvektoren 90
8.3 Anwendung: Lineare Differentialgleichungssysteme 92
8.4 Anwendung: Markow-Ketten und PageRank 95

VI Geometrie: Skalarprodukte **99**

9 Skalarprodukte und Orthogonalität **101**
9.1 Was in einem Vektorraum fehlt 101
9.2 Die Cauchy–Schwarz-Ungleichung 102
9.3 Orthonormalbasen und Gram–Schmidt 103

9.4 Orthogonale Projektion und kleinste Quadrate . . . 106

10 Der Spektralsatz 111
10.1 Die Adjungierte . . . 111
10.2 Der Spektralsatz . . . 112
10.3 Quadratische Formen . . . 115

11 Die Singulärwertzerlegung 119
11.1 Die Verallgemeinerung, die alles umfasst . . . 119
11.2 Niedrigrangapproximation . . . 122
11.3 Die Pseudoinverse . . . 123
11.4 Hauptkomponentenanalyse . . . 124

VII Numerik und aktueller Stand 127

12 Numerische lineare Algebra 129
12.1 Warum exakte Mathematik nicht genügt . . . 129
12.2 Kondition . . . 130
12.3 QR-Zerlegung mit Householder-Reflexionen . . . 131
12.4 Cholesky-Zerlegung . . . 132
12.5 Iterative Verfahren . . . 134
12.6 Eigenwertberechnung . . . 135

13 Der aktuelle Forschungsstand 137
13.1 Wie schnell kann man Matrizen multiplizieren? . . . 137
13.2 Maschinelles Lernen entdeckt Algorithmen . . . 139
13.3 Randomisierte numerische lineare Algebra . . . 140
13.4 Lineare Algebra im maschinellen Lernen . . . 142
13.5 Gitter und Post-Quanten-Kryptographie . . . 142
13.6 Quantenalgorithmen . . . 143
13.7 Ein Ausblick für den Leser . . . 144

VIIIAnhänge 145

A Formelsammlung 147

B Zeitleiste 151

C Glossar 153

D Kommentierte Literatur 155

Part I

Das Konkrete: Gleichungen und Matrizen

1 Lineare Gleichungssysteme

1.1 Wo alles anfängt

Die Neun Kapitel, um 200 v. Chr.

Im chinesischen *Jiuzhang Suanshu* („Neun Kapitel der Rechenkunst“) steht im achten Kapitel, das *Fangcheng* – „rechteckige Anordnung“ – heißt, die folgende Aufgabe: *Drei Garben guten Getreides, zwei Garben mittleren und eine Garbe schlechten ergeben 39 Dou. Zwei Garben guten, drei mittleren und eine schlechte ergeben 34 Dou. Eine Garbe guten, zwei mittlere und drei schlechte ergeben 26 Dou. Wie viel Dou ergibt je eine Garbe?*
In moderner Notation:

$$\begin{aligned} 3x &+ 2y &+ z &= 39 \\ 2x &+ 3y &+ z &= 34 \\ x &+ 2y &+ 3z &= 26 \end{aligned}$$

Das Bemerkenswerte ist die Lösungsmethode. Der Text weist an, die Koeffizienten in einem Rechteck auf dem Rechenbrett anzuordnen – spaltenweise – und dann durch Subtraktion von Vielfachen einer Spalte von einer anderen systematisch Nullen zu erzeugen.
Das ist der Gauß-Algorithmus. Er ist zweitausend Jahre älter als Gauß.

Definition 1.1 (Lineares Gleichungssystem)**.** Ein **lineares Gleichungssystem** (LGS) mit m Gleichungen und n Unbekannten über $\mathbb{R}$ ist ein System der Form

$$\begin{aligned} a_{11}x_1 &+ a_{12}x_2 &+ \cdots &+ a_{1n}x_n &= b_1 \\ a_{21}x_1 &+ a_{22}x_2 &+ \cdots &+ a_{2n}x_n &= b_2 \\ \vdots & & & \vdots & \vdots \\ a_{m1}x_1 &+ a_{m2}x_2 &+ \cdots &+ a_{mn}x_n &= b_m \end{aligned}$$

mit gegebenen Zahlen a_{ij} (den **Koeffizienten**) und b_i (der **rechten Seite**). Gilt $b_1 = \cdots = b_m = 0$, so heißt das System **homogen**, sonst **inhomogen**.

Was „linear“ genau bedeutet

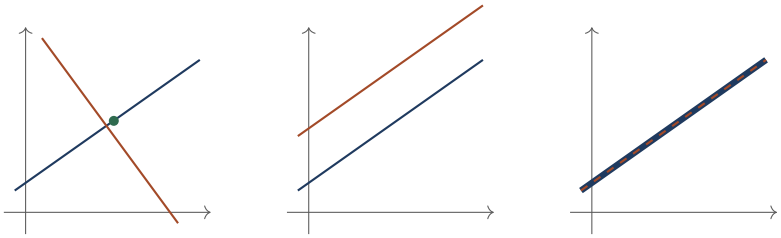
Die Unbekannten kommen nur in der ersten Potenz vor und werden nicht miteinander multipliziert. Verboten sind also:

$$x^2, \qquad xy, \qquad \sin x, \qquad \frac{1}{x}, \qquad \sqrt{x}.$$

Erlaubt sind ausschließlich Ausdrücke der Form $a \cdot x$ mit einer festen Zahl a, und Summen davon.
Der tiefere Grund für diese Einschränkung wird erst in Kapitel 5 sichtbar: Genau diese Bedingung sorgt dafür, dass die Lösungsmenge eine *geometrische* Struktur hat – sie ist ein verschobener Untervektorraum. Nichtlineare Systeme haben Lösungsmengen von beliebiger Wildheit.

1.2 Die drei Möglichkeiten – geometrisch

Bevor wir rechnen, sollten wir wissen, was uns erwarten kann. Betrachten wir zwei Gleichungen mit zwei Unbekannten. Jede Gleichung $ax + by = c$ beschreibt in der Ebene eine *Gerade*. Gesucht sind die Punkte, die auf beiden Geraden liegen.



genau eine Lösung | keine Lösung | unendlich viele

Die Trichotomie

Ein lineares Gleichungssystem über $\mathbb{R}$ hat entweder

- **keine** Lösung,
- **genau eine** Lösung, oder
- **unendlich viele** Lösungen.

Es gibt *nie* genau zwei, drei oder siebzehn Lösungen.

Beweis. Angenommen, es gibt zwei verschiedene Lösungen $\mathbf{u} \neq \mathbf{v}$. Wir zeigen, dass es dann unendlich viele gibt.

Sei $t \in \mathbb{R}$ beliebig und betrachte

$$\mathbf{w} := \mathbf{u} + t(\mathbf{v} - \mathbf{u}).$$

In Komponenten: $w_j = u_j + t(v_j - u_j)$. Setzen wir das in die i-te Gleichung ein:

$$\sum_{j=1}^{n} a_{ij} w_j = \sum_j a_{ij}\big(u_j + t(v_j - u_j)\big) = \underbrace{\sum_j a_{ij} u_j}_{=b_i} + t\Big(\underbrace{\sum_j a_{ij} v_j}_{=b_i} - \underbrace{\sum_j a_{ij} u_j}_{=b_i}\Big).$$

Der Klammerausdruck ist $b_i - b_i = 0$. Also

$$\sum_j a_{ij} w_j = b_i + t \cdot 0 = b_i.$$

Das gilt für jede Gleichung i, also ist $\mathbf{w}$ eine Lösung – und zwar für *jedes* $t \in \mathbb{R}$. Da $\mathbf{u} \neq \mathbf{v}$, liefern verschiedene t verschiedene $\mathbf{w}$. Es gibt also unendlich viele Lösungen. ■

Was der Beweis eigentlich zeigt

Die Lösungsmenge enthält mit je zwei Punkten auch die *ganze Gerade* durch diese Punkte. Solche Mengen heißen **affine Unterräume**: Punkte, Geraden, Ebenen, Hyperebenen – niemals Kurven, niemals isolierte Punktpaare.
Das ist die geometrische Essenz von „linear“, und wir werden sie in Kapitel 5 präzise formulieren: Die Lösungsmenge eines LGS ist entweder leer oder von der Form $\mathbf{u} + U$ mit einem Untervektorraum U.
Über anderen Körpern gilt die Trichotomie in dieser Form übrigens nicht. Über $\mathbb{F}_2 = \{0, 1\}$ hat $x + y = 1$ genau zwei Lösungen. Der Beweis oben benutzt stillschweigend, dass es unendlich viele Skalare t gibt.

1.3 Der Gauß-Algorithmus

Die Idee

Wir dürfen ein Gleichungssystem umformen, ohne die Lösungsmenge zu ändern. Erlaubt sind drei Operationen.

Definition 1.2 (Elementare Zeilenumformungen). (Z1) Vertauschen zweier Gleichungen.

(Z2) Multiplizieren einer Gleichung mit einer Zahl $\lambda \neq 0$.

(Z3) Addieren des λ-fachen einer Gleichung zu einer *anderen* Gleichung.

Satz 1.3. *Elementare Zeilenumformungen ändern die Lösungsmenge nicht.*

Beweis. Wir müssen für jede Operation zeigen, dass sich die Lösungsmenge weder vergrößert noch verkleinert. Der Schlüssel: Jede Operation ist *umkehrbar* durch eine Operation desselben Typs.

(Z1). Die Reihenfolge der Gleichungen spielt für die Frage, ob ein Tupel alle erfüllt, offensichtlich keine Rolle. Umkehrung: nochmals vertauschen.

(Z2). Erfüllt $\mathbf{x}$ die Gleichung $\sum_j a_{ij}x_j = b_i$, so auch $\sum_j (\lambda a_{ij})x_j = \lambda b_i$ (beide Seiten mit λ multiplizieren). Umgekehrt: Erfüllt $\mathbf{x}$ die neue Gleichung, so kann man wegen $\lambda \neq 0$ mit λ^{-1} zurückmultiplizieren.

Hier ist die Bedingung $\lambda \neq 0$ entscheidend. Multipliziert man mit 0, so wird aus $x = 5$ die Gleichung $0 = 0$ – und die ist von jedem x erfüllt. Die Lösungsmenge würde größer.

(Z3). Sei $\mathbf{x}$ eine Lösung des alten Systems. Dann gelten

$$\sum_j a_{ij}x_j = b_i \quad \text{und} \quad \sum_j a_{kj}x_j = b_k.$$

Addiert man das λ-fache der zweiten zur ersten:

$$\sum_j (a_{ij} + \lambda a_{kj})x_j = b_i + \lambda b_k.$$

Das ist genau die neue i-te Gleichung, und $\mathbf{x}$ erfüllt sie. Alle anderen Gleichungen sind unverändert.

Umgekehrt: Erfüllt $\mathbf{x}$ das neue System, so addiere man das $(-\lambda)$-fache der k-ten Gleichung – die ja unverändert geblieben ist – zur neuen i-ten und erhält die alte i-te zurück.

Warum „zu einer anderen“? Addierte man das λ-fache einer Gleichung zu sich selbst, so entstünde $(1+\lambda)\cdot(\text{Gleichung})$, und für $\lambda = -1$ wäre das $0 = 0$ – Informationsverlust. ■

Die Zeilenstufenform

Das Ziel der Umformungen ist eine Gestalt, aus der man die Lösung ablesen kann.

Definition 1.4 (Zeilenstufenform). Eine Matrix ist in **Zeilenstufenform** (ZSF), wenn

(i) alle Nullzeilen unten stehen, und

(ii) in jeder Nichtnullzeile das erste von null verschiedene Element (das **Pivot**) echt weiter rechts steht als das Pivot der Zeile darüber.

Sie ist in **reduzierter** Zeilenstufenform (RZSF), wenn zusätzlich

(iii) jedes Pivot gleich 1 ist, und

(iv) über jedem Pivot nur Nullen stehen.

$$\underbrace{\begin{pmatrix} \boxed{2} & 3 & -1 & 4 \\ 0 & \boxed{5} & 2 & 1 \\ 0 & 0 & 0 & \boxed{3} \\ 0 & 0 & 0 & 0 \end{pmatrix}}_{\text{Zeilenstufenform}} \qquad \underbrace{\begin{pmatrix} \boxed{1} & 0 & 7 & 0 \\ 0 & \boxed{1} & 2 & 0 \\ 0 & 0 & 0 & \boxed{1} \\ 0 & 0 & 0 & 0 \end{pmatrix}}_{\text{reduzierte Zeilenstufenform}}$$

Aufgabe 1.1. Lösen Sie das System aus den *Neun Kapiteln*:

$$3x + 2y + z = 39, \qquad 2x + 3y + z = 34, \qquad x + 2y + 3z = 26.$$

Lösung Schritt für Schritt.

Schritt 0 – Erweiterte Koeffizientenmatrix aufschreiben. Wir notieren nur noch die Zahlen; der senkrechte Strich trennt die rechte Seite ab.

$$\left(\begin{array}{ccc|c} 3 & 2 & 1 & 39 \\ 2 & 3 & 1 & 34 \\ 1 & 2 & 3 & 26 \end{array}\right)$$

Schritt 1 – Bequemes Pivot herstellen. Die dritte Zeile beginnt mit einer 1. Wir tauschen sie nach oben (Z1) – das erspart uns Brüche.

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 26 \\ 2 & 3 & 1 & 34 \\ 3 & 2 & 1 & 39 \end{array}\right)$$

Schritt 2 – Erste Spalte ausräumen. Wir subtrahieren das 2-fache der ersten Zeile von der zweiten und das 3-fache von der dritten (Z3).
Zeile 2 neu: $(2,3,1 \mid 34) - 2\cdot(1,2,3 \mid 26) = (0,\, 3-4,\, 1-6 \mid 34-52) = (0,-1,-5 \mid -18)$.
Zeile 3 neu: $(3,2,1 \mid 39) - 3\cdot(1,2,3 \mid 26) = (0,\, 2-6,\, 1-9 \mid 39-78) = (0,-4,-8 \mid -39)$.

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 26 \\ 0 & -1 & -5 & -18 \\ 0 & -4 & -8 & -39 \end{array}\right)$$

Schritt 3 – Zweite Zeile normieren. Multiplikation mit -1 (Z2):

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 26 \\ 0 & 1 & 5 & 18 \\ 0 & -4 & -8 & -39 \end{array}\right)$$

Schritt 4 – Zweite Spalte ausräumen. Wir addieren das 4-fache der zweiten Zeile zur dritten:
$(0,-4,-8 \mid -39) + 4\cdot(0,1,5 \mid 18) = (0,\, 0,\, -8+20 \mid -39+72) = (0,0,12 \mid 33)$.

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 26 \\ 0 & 1 & 5 & 18 \\ 0 & 0 & 12 & 33 \end{array}\right)$$

Das ist Zeilenstufenform. Der **Vorwärtsschritt** ist beendet.
Schritt 5 – Rückwärtseinsetzen. Die letzte Zeile bedeutet

$$12z = 33 \quad\Longrightarrow\quad z = \frac{33}{12} = \frac{11}{4}.$$

Die zweite Zeile bedeutet $y + 5z = 18$, also

$$y = 18 - 5\cdot\frac{11}{4} = \frac{72}{4} - \frac{55}{4} = \frac{17}{4}.$$

Die erste Zeile bedeutet $x + 2y + 3z = 26$, also

$$x = 26 - 2\cdot\frac{17}{4} - 3\cdot\frac{11}{4} = \frac{104}{4} - \frac{34}{4} - \frac{33}{4} = \frac{37}{4}.$$

Ergebnis:

$$x = \frac{37}{4} = 9{,}25, \qquad y = \frac{17}{4} = 4{,}25, \qquad z = \frac{11}{4} = 2{,}75.$$

Schritt 6 – Probe. Wir setzen in die *ursprüngliche* erste Gleichung ein (nie in die umgeformte – dort könnte sich ein Fehler versteckt haben):

$$3\cdot\tfrac{37}{4} + 2\cdot\tfrac{17}{4} + \tfrac{11}{4} = \tfrac{111+34+11}{4} = \tfrac{156}{4} = 39.\checkmark$$

Zweite Gleichung:

$$2 \cdot \tfrac{37}{4} + 3 \cdot \tfrac{17}{4} + \tfrac{11}{4} = \tfrac{74+51+11}{4} = \tfrac{136}{4} = 34. \checkmark$$

Dritte:

$$\tfrac{37}{4} + 2 \cdot \tfrac{17}{4} + 3 \cdot \tfrac{11}{4} = \tfrac{37+34+33}{4} = \tfrac{104}{4} = 26. \checkmark$$

Historische Anmerkung. Der chinesische Originaltext gibt genau diese Werte an – als $9\frac{1}{4}$, $4\frac{1}{4}$ und $2\frac{3}{4}$ Dou.

1.4 Der allgemeine Fall: freie Variablen

Nicht jedes System hat eine eindeutige Lösung. Sehen wir uns an, was dann passiert.

Aufgabe 1.2. Bestimmen Sie die Lösungsmenge von

$$\begin{aligned} x_1 &+ 2x_2 &+ x_3 &+ x_4 &&= 3 \\ 2x_1 &+ 4x_2 &+ x_3 &- x_4 &&= 4 \\ 3x_1 &+ 6x_2 &+ 2x_3 &+ 0 \cdot x_4 &&= 7 \end{aligned}$$

Lösung Schritt für Schritt.

Schritt 1 – Matrix aufstellen.

$$\left(\begin{array}{cccc|c} 1 & 2 & 1 & 1 & 3 \\ 2 & 4 & 1 & -1 & 4 \\ 3 & 6 & 2 & 0 & 7 \end{array}\right)$$

Schritt 2 – Erste Spalte ausräumen.
$Z_2 - 2Z_1$: $(0,\, 0,\, 1-2,\, -1-2 \mid 4-6) = (0, 0, -1, -3 \mid -2)$.
$Z_3 - 3Z_1$: $(0,\, 0,\, 2-3,\, 0-3 \mid 7-9) = (0, 0, -1, -3 \mid -2)$.

$$\left(\begin{array}{cccc|c} 1 & 2 & 1 & 1 & 3 \\ 0 & 0 & -1 & -3 & -2 \\ 0 & 0 & -1 & -3 & -2 \end{array}\right)$$

Beobachtung. Die zweite Spalte enthält unterhalb der ersten Zeile nur Nullen. Das Pivot der zweiten Zeile rutscht also in die *dritte* Spalte. Genau das erlaubt die Definition der Zeilenstufenform.

Schritt 3 – Weiter ausräumen. $Z_3 - Z_2$ liefert eine Nullzeile:

$$\left(\begin{array}{cccc|c} 1 & 2 & 1 & 1 & 3 \\ 0 & 0 & -1 & -3 & -2 \\ 0 & 0 & 0 & 0 & 0 \end{array}\right)$$

Schritt 4 – In reduzierte Form bringen. Zeile 2 mit -1 multiplizieren, dann von Zeile 1 subtrahieren:

$Z_2 \cdot (-1)$: $(0, 0, 1, 3 \mid 2)$.
$Z_1 - Z_2$: $(1,\ 2,\ 1-1,\ 1-3 \mid 3-2) = (1, 2, 0, -2 \mid 1)$.

$$\left(\begin{array}{cccc|c} 1 & 2 & 0 & -2 & 1 \\ 0 & 0 & 1 & 3 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{array}\right)$$

Schritt 5 – Pivot- und freie Variablen identifizieren.
Pivots stehen in Spalte 1 und Spalte 3. Also:

- **Pivotvariablen** (gebunden): x_1, x_3.
- **Freie Variablen**: x_2, x_4.

Was das bedeutet: Die freien Variablen dürfen wir *beliebig* wählen; die Pivotvariablen sind dadurch eindeutig festgelegt.
Schritt 6 – Nach den Pivotvariablen auflösen.
Zeile 1: $x_1 + 2x_2 - 2x_4 = 1 \Longrightarrow x_1 = 1 - 2x_2 + 2x_4$.
Zeile 2: $x_3 + 3x_4 = 2 \Longrightarrow x_3 = 2 - 3x_4$.
Schritt 7 – Parameter einführen. Setze $x_2 =: s$ und $x_4 =: t$ mit $s, t \in \mathbb{R}$ frei. Dann

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 1 - 2s + 2t \\ s \\ 2 - 3t \\ t \end{pmatrix} = \underbrace{\begin{pmatrix} 1 \\ 0 \\ 2 \\ 0 \end{pmatrix}}_{\text{spezielle Lösung}} + s \underbrace{\begin{pmatrix} -2 \\ 1 \\ 0 \\ 0 \end{pmatrix}}_{=:\mathbf{v}_1} + t \underbrace{\begin{pmatrix} 2 \\ 0 \\ -3 \\ 1 \end{pmatrix}}_{=:\mathbf{v}_2}.$$

Schritt 8 – Probe. Wir setzen $s = t = 0$, also $\mathbf{x} = (1, 0, 2, 0)$, in die ursprüngliche zweite Gleichung ein:

$$2 \cdot 1 + 4 \cdot 0 + 1 \cdot 2 - 1 \cdot 0 = 4. \checkmark$$

Und wir prüfen, dass $\mathbf{v}_1$ das *homogene* System löst (rechte Seite null), erste Gleichung:

$$1 \cdot (-2) + 2 \cdot 1 + 1 \cdot 0 + 1 \cdot 0 = 0. \checkmark$$

Zweite Gleichung: $2(-2) + 4(1) + 1(0) - 1(0) = 0$. ✓
Die Lösungsmenge ist eine zweidimensionale Ebene im vierdimensionalen Raum, verschoben um den Punkt $(1, 0, 2, 0)$.

Die Struktur jeder Lösungsmenge

Was wir eben gesehen haben, ist kein Zufall, sondern ein Satz:

$$\boxed{\text{Lösungsmenge} = \text{spezielle Lösung} + \text{Lösungen des homogenen Systems}}$$

Symbolisch: $L = \mathbf{x}_0 + L_{\text{hom}}$.

Beweis: Ist $\mathbf{x}$ irgendeine Lösung und $\mathbf{x}_0$ eine feste, so löst die Differenz $\mathbf{x} - \mathbf{x}_0$ das homogene System, denn

$$\sum_j a_{ij}(x_j - x_{0j}) = b_i - b_i = 0.$$

Umgekehrt ist $\mathbf{x}_0 + \mathbf{h}$ für jede homogene Lösung $\mathbf{h}$ wieder eine Lösung.
Diese Struktur – *spezielle Lösung plus homogener Anteil* – taucht in der gesamten Mathematik wieder auf: bei linearen Differentialgleichungen, bei Rekursionen, in der Funktionalanalysis. Sie ist *die* Konsequenz von Linearität.

1.5 Wann ist ein System lösbar?

Definition 1.5 (Rang). Der **Rang** einer Matrix A, geschrieben Rang A, ist die Anzahl der Nichtnullzeilen in einer Zeilenstufenform von A.

Ist das wohldefiniert?

Die Definition wirft sofort eine Frage auf: Verschiedene Wege durch den Gauß-Algorithmus können zu verschiedenen Zeilenstufenformen führen. Ist die Anzahl der Nichtnullzeilen wirklich immer gleich?
Ja – aber das ist ein *Satz*, kein Definitionsbestandteil, und wir können ihn erst in Kapitel 4 beweisen, wenn wir den Dimensionsbegriff haben. (Die reduzierte Zeilenstufenform ist sogar eindeutig; auch das beweisen wir dort.)
Bis dahin merken wir uns: Der Rang misst, wie viele der Gleichungen *wirklich neue Information* tragen. Im Beispiel oben hatten wir drei Gleichungen, aber Rang 2 – die dritte war eine Folge der ersten beiden.

Satz 1.6 (Lösbarkeitskriterium). *Sei A die Koeffizientenmatrix und $(A \mid \mathbf{b})$ die erweiterte Matrix eines LGS mit n Unbekannten. Dann gilt:*

(a) Das System ist lösbar $\iff$ Rang $A =$ Rang$(A \mid \mathbf{b})$.

(b) Im lösbaren Fall ist die Lösungsmenge ein affiner Unterraum der Dimension $n -$ Rang A.

(c) Die Lösung ist eindeutig $\iff$ Rang $A = n$.

Beweis. **(a).** Wir bringen $(A \mid \mathbf{b})$ auf Zeilenstufenform.

Fall Rang $A <$ Rang$(A \mid \mathbf{b})$*:* Das bedeutet, dass $(A \mid \mathbf{b})$ eine Nichtnullzeile mehr hat als A. Diese zusätzliche Zeile kann nur so aussehen, dass links vom Strich alles null ist und rechts ein Wert $c \neq 0$ steht:

$$(0\,0\,\cdots\,0 \mid c), \qquad c \neq 0.$$

Als Gleichung gelesen: $0 \cdot x_1 + \cdots + 0 \cdot x_n = c$, also $0 = c$. Das ist für kein $\mathbf{x}$ erfüllbar. Das System ist unlösbar.

Fall Rang $A =$ Rang$(A \mid \mathbf{b}) =: r$*:* Dann tritt keine solche Zeile auf. Die r Pivots stehen in r Spalten links vom Strich. Wir wählen die $n - r$ freien Variablen beliebig und lösen

von unten nach oben nach den Pivotvariablen auf – jede Pivotgleichung enthält genau eine noch unbestimmte Variable, ist also eindeutig auflösbar. Eine Lösung existiert.

(b). Nach dem eben beschriebenen Verfahren wird die Lösung durch die $n - r$ frei wählbaren Parameter beschrieben, und verschiedene Parameterwerte liefern verschiedene Lösungen (sie unterscheiden sich ja bereits in den freien Koordinaten). Die Lösungsmenge hat also $n - r$ Freiheitsgrade.

(c). Eindeutigkeit bedeutet: keine freien Variablen, also $n - r = 0$. ■

Aufgabe 1.3. Für welche $\lambda \in \mathbb{R}$ ist das System lösbar, und wie viele Lösungen gibt es?

$$\begin{aligned} x &+ y &+ \lambda z &= 1 \\ x &+ \lambda y &+ z &= 1 \\ \lambda x &+ y &+ z &= 1 \end{aligned}$$

Lösung Schritt für Schritt.

Schritt 1 – Umformen.

$$\left(\begin{array}{ccc|c} 1 & 1 & \lambda & 1 \\ 1 & \lambda & 1 & 1 \\ \lambda & 1 & 1 & 1 \end{array}\right) \xrightarrow[Z_3 - \lambda Z_1]{Z_2 - Z_1} \left(\begin{array}{ccc|c} 1 & 1 & \lambda & 1 \\ 0 & \lambda - 1 & 1 - \lambda & 0 \\ 0 & 1 - \lambda & 1 - \lambda^2 & 1 - \lambda \end{array}\right)$$

Nachrechnen der dritten Zeile: $(\lambda, 1, 1 \mid 1) - \lambda(1, 1, \lambda \mid 1) = (0,\, 1 - \lambda,\, 1 - \lambda^2 \mid 1 - \lambda)$. ✓

Schritt 2 – Fallunterscheidung erzwingen. Wir addieren Z_2 zu Z_3 (beachte $\lambda - 1 = -(1 - \lambda)$):

$$Z_3 + Z_2 = \big(0,\ 0,\ (1 - \lambda^2) + (1 - \lambda) \,\big|\, 1 - \lambda\big).$$

Wir vereinfachen den Eintrag:

$$(1 - \lambda^2) + (1 - \lambda) = 2 - \lambda - \lambda^2 = -(\lambda^2 + \lambda - 2) = -(\lambda + 2)(\lambda - 1).$$

Also

$$\left(\begin{array}{ccc|c} 1 & 1 & \lambda & 1 \\ 0 & \lambda - 1 & 1 - \lambda & 0 \\ 0 & 0 & -(\lambda + 2)(\lambda - 1) & 1 - \lambda \end{array}\right)$$

Schritt 3 – Fall $\lambda = 1$. Dann werden Zeile 2 und Zeile 3 komplett null:

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{array}\right)$$

$\operatorname{Rang} A = \operatorname{Rang}(A \mid \mathbf{b}) = 1$, also lösbar. Freiheitsgrade: $3 - 1 = 2$. Die Lösungsmenge ist die Ebene $x + y + z = 1$.

Schritt 4 – Fall $\lambda = -2$. Dann ist $-(\lambda + 2)(\lambda - 1) = 0$, aber die rechte Seite ist $1 - \lambda = 3 \neq 0$. Die dritte Zeile lautet

$$(0\,0\,0 \mid 3),$$

also $0 = 3$. **Unlösbar.**
Schritt 5 – Fall $\lambda \notin \{1, -2\}$. Dann sind $\lambda - 1 \neq 0$ und $-(\lambda+2)(\lambda-1) \neq 0$, alle drei Pivots existieren. Rang $A = 3 = n$: **genau eine Lösung**.
Wir berechnen sie. Aus Zeile 3:

$$z = \frac{1-\lambda}{-(\lambda+2)(\lambda-1)} = \frac{-(\lambda-1)}{-(\lambda+2)(\lambda-1)} = \frac{1}{\lambda+2}.$$

Aus Zeile 2: $(\lambda-1)y + (1-\lambda)z = 0$, also $(\lambda-1)(y-z) = 0$, und da $\lambda \neq 1$: $y = z = \frac{1}{\lambda+2}$.
Aus Zeile 1: $x = 1 - y - \lambda z = 1 - \frac{1}{\lambda+2} - \frac{\lambda}{\lambda+2} = \frac{(\lambda+2)-1-\lambda}{\lambda+2} = \frac{1}{\lambda+2}$.
Also $x = y = z = \frac{1}{\lambda+2}$.
Probe in Gleichung 1: $\frac{1}{\lambda+2} + \frac{1}{\lambda+2} + \frac{\lambda}{\lambda+2} = \frac{2+\lambda}{\lambda+2} = 1$. ✓
Zusammenfassung:

λ	Lösungsmenge
$\lambda = 1$	Ebene $x + y + z = 1$ (zwei Freiheitsgrade)
$\lambda = -2$	leer
sonst	genau ein Punkt $\left(\frac{1}{\lambda+2}, \frac{1}{\lambda+2}, \frac{1}{\lambda+2}\right)$

Was hier eigentlich passiert. Die Symmetrie des Systems (jede Gleichung entsteht aus jeder anderen durch zyklisches Vertauschen) legt nahe, dass eine symmetrische Lösung $x = y = z$ existieren sollte. Einsetzen liefert $(2+\lambda)x = 1$ – und genau bei $\lambda = -2$ bricht das zusammen. Bei $\lambda = 1$ dagegen fallen alle drei Gleichungen zusammen.

1.6 Aufwand: Warum der Algorithmus praktikabel ist

Satz 1.7. *Der Gauß-Algorithmus benötigt für ein $n \times n$-System etwa $\frac{2}{3}n^3$ arithmetische Operationen.*

Beweis. Im k-ten Eliminationsschritt ($k = 1, \ldots, n-1$) müssen $n-k$ Zeilen bearbeitet werden. Für jede dieser Zeilen berechnet man einen Faktor (1 Division) und modifiziert $n-k$ Einträge links vom Strich sowie einen rechts – das sind je etwa $n-k$ Multiplikationen und ebenso viele Subtraktionen.

Also insgesamt etwa

$$\sum_{k=1}^{n-1} (n-k) \cdot 2(n-k) = 2 \sum_{j=1}^{n-1} j^2 = 2 \cdot \frac{(n-1)n(2n-1)}{6} \approx \frac{2n^3}{3}$$

Operationen für den Vorwärtsschritt. Das Rückwärtseinsetzen kostet nur $O(n^2)$ und fällt nicht ins Gewicht. ∎

Der Vergleich, der alles klarmacht

Die *Cramersche Regel* (Kapitel 6) löst dasselbe Problem mit Determinanten. Berechnet man diese naiv über die Leibniz-Formel, so kostet das $(n+1)!$ Operationen.

n	Gauß ($\approx \frac{2}{3}n^3$)	Cramer naiv ($(n+1)!$)
5	83	720
10	667	$4 \cdot 10^7$
20	5 333	$5{,}1 \cdot 10^{19}$
30	18 000	$8{,}2 \cdot 10^{33}$

Bei $n = 30$ bräuchte ein Rechner mit 10^{12} Operationen pro Sekunde für Cramer etwa $2{,}6 \cdot 10^{14}$ Jahre – das Zwanzigtausendfache des Alters des Universums. Der Gauß-Algorithmus ist in 18 Mikrosekunden fertig.

Die Lehre: Eine geschlossene Formel ist nicht automatisch ein brauchbares Verfahren. Die Cramersche Regel ist theoretisch wertvoll – sie zeigt, dass die Lösung *rational* von den Koeffizienten abhängt –, aber als Rechenvorschrift ist sie unbrauchbar.

2 Matrizen

2.1 Von der Tabelle zum Objekt

Bisher war die Matrix nur eine Schreibhilfe – eine Tabelle, um sich das Hinschreiben der Unbekannten zu sparen. ARTHUR CAYLEY machte 1858 in seiner *Memoir on the Theory of Matrices*[6] daraus ein eigenständiges mathematisches Objekt, mit dem man rechnen kann.

Definition 2.1. Eine $m \times n$**-Matrix** über $\mathbb{R}$ ist ein rechteckiges Schema

$$A = (a_{ij})_{\substack{1 \le i \le m \\ 1 \le j \le n}} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}.$$

Die Menge aller solchen Matrizen wird mit $\mathbb{R}^{m \times n}$ bezeichnet. **Merkregel: Zeile zuerst, Spalte zweitens** – a_{ij} steht in Zeile i, Spalte j.

Definition 2.2 (Addition und Skalarmultiplikation)**.** Für $A, B \in \mathbb{R}^{m \times n}$ und $\lambda \in \mathbb{R}$:

$$(A + B)_{ij} := a_{ij} + b_{ij}, \qquad (\lambda A)_{ij} := \lambda a_{ij}.$$

Diese Definitionen sind unspektakulär – man rechnet einfach eintragsweise. Die interessante Definition ist die nächste.

2.2 Die Matrixmultiplikation – und warum sie so aussieht

Definition 2.3. Für $A \in \mathbb{R}^{m \times n}$ und $B \in \mathbb{R}^{n \times p}$ ist das Produkt $AB \in \mathbb{R}^{m \times p}$ definiert durch

$$(AB)_{ik} := \sum_{j=1}^{n} a_{ij}\, b_{jk}.$$

> **Die berechtigte Frage**
>
> Warum um alles in der Welt *so*? Warum nicht einfach $(AB)_{ij} = a_{ij} b_{ij}$, so wie bei der Addition?
> Diese eintragsweise Multiplikation existiert tatsächlich; sie heißt **Hadamard-Produkt** und wird gelegentlich benutzt. Aber sie ist mathematisch uninteressant, weil sie nichts mit dem zu tun hat, wofür Matrizen erfunden wurden.

Der Grund: Matrizen beschreiben Substitutionen

Betrachten wir zwei aufeinanderfolgende lineare Substitutionen. Erst ersetzen wir y durch z:

$$y_1 = b_{11}z_1 + b_{12}z_2, \qquad y_2 = b_{21}z_1 + b_{22}z_2.$$

Dann ersetzen wir x durch y:

$$x_1 = a_{11}y_1 + a_{12}y_2, \qquad x_2 = a_{21}y_1 + a_{22}y_2.$$

Was ergibt sich, wenn wir x direkt durch z ausdrücken? Einsetzen:

$$\begin{aligned} x_1 &= a_{11}(b_{11}z_1 + b_{12}z_2) + a_{12}(b_{21}z_1 + b_{22}z_2) \\ &= (a_{11}b_{11} + a_{12}b_{21})\,z_1 + (a_{11}b_{12} + a_{12}b_{22})\,z_2. \end{aligned}$$

Der Koeffizient von z_1 in der Gleichung für x_1 ist also

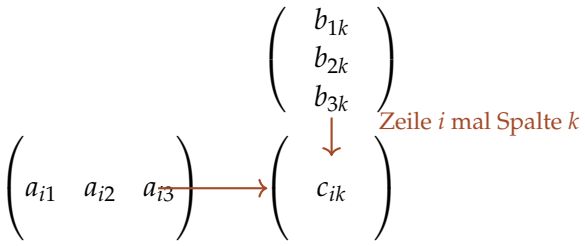
$$a_{11}b_{11} + a_{12}b_{21} = \sum_j a_{1j}b_{j1}.$$

Das ist genau die Definition der Matrixmultiplikation.
Die Matrixmultiplikation ist also nicht willkürlich, sondern *erzwungen*: Sie ist die einzige Definition, für die gilt

$$\text{Matrix von } (f \circ g) = (\text{Matrix von } f) \cdot (\text{Matrix von } g).$$

Alles Weitere – Assoziativität, Nichtkommutativität, das Verhalten der Einheitsmatrix – folgt aus dieser einen Tatsache.

Das Rechenschema



Die Merkregel

Der Eintrag an Position (i, k) des Produkts entsteht aus der *i-ten Zeile* von A und der *k-ten Spalte* von B: Man legt sie übereinander, multipliziert paarweise und summiert.
Die Größen müssen passen: A ist $m \times \boxed{n}$, B ist $\boxed{n} \times p$. Die inneren Zahlen müssen übereinstimmen; die äußeren geben das Format des Ergebnisses: $m \times p$.

Aufgabe 2.1. Berechnen Sie AB und BA für

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \qquad B = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Lösung Schritt für Schritt.

AB **– Eintrag für Eintrag.**
Position $(1,1)$: Zeile 1 von A ist $(1,2)$, Spalte 1 von B ist $\binom{0}{1}$.

$$1 \cdot 0 + 2 \cdot 1 = 2.$$

Position $(1,2)$: Zeile 1 von A, Spalte 2 von B ist $\binom{1}{0}$.

$$1 \cdot 1 + 2 \cdot 0 = 1.$$

Position $(2,1)$: Zeile 2 ist $(3,4)$, Spalte 1 ist $\binom{0}{1}$.

$$3 \cdot 0 + 4 \cdot 1 = 4.$$

Position $(2,2)$:

$$3 \cdot 1 + 4 \cdot 0 = 3.$$

Also

$$AB = \begin{pmatrix} 2 & 1 \\ 4 & 3 \end{pmatrix}.$$

BA **– dasselbe in anderer Reihenfolge.**
$(1,1)$: Zeile 1 von B ist $(0,1)$, Spalte 1 von A ist $\binom{1}{3}$: $0 \cdot 1 + 1 \cdot 3 = 3$.
$(1,2)$: $(0,1)$ mal $\binom{2}{4}$: $0 \cdot 2 + 1 \cdot 4 = 4$.
$(2,1)$: $(1,0)$ mal $\binom{1}{3}$: $1 \cdot 1 + 0 \cdot 3 = 1$.
$(2,2)$: $(1,0)$ mal $\binom{2}{4}$: $1 \cdot 2 + 0 \cdot 4 = 2$.

$$BA = \begin{pmatrix} 3 & 4 \\ 1 & 2 \end{pmatrix}.$$

Ergebnis: $AB \neq BA$**.**
Was hier geometrisch passiert. Die Matrix B vertauscht die beiden Koordinaten. Multipliziert man B von rechts an A, so werden die *Spalten* von A vertauscht; multipliziert man von links, die *Zeilen*. Das sind offensichtlich verschiedene Operationen.
Allgemeine Merkregel:

$$\text{Links multiplizieren} \;\to\; \text{operiert auf Zeilen},$$

$$\text{rechts multiplizieren} \;\to\; \text{operiert auf Spalten}.$$

Satz 2.4 (Rechenregeln). *Sofern die Formate passen, gilt:*

(a) $(AB)C = A(BC)$ *(Assoziativität)*

(b) $A(B+C) = AB + AC$ *und* $(A+B)C = AC + BC$ *(Distributivität)*

(c) $\lambda(AB) = (\lambda A)B = A(\lambda B)$

(d) $I_m A = A = A I_n$ *mit der Einheitsmatrix* $I_n = (\delta_{ij})$

Dagegen gilt nicht*:* $AB = BA$*; und aus* $AB = 0$ *folgt* nicht $A = 0$ *oder* $B = 0$*.*

Beweis der Assoziativität. Das ist die einzige nichttriviale Regel. Sei $A \in \mathbb{R}^{m\times n}$, $B \in \mathbb{R}^{n\times p}$, $C \in \mathbb{R}^{p\times q}$.

Wir berechnen den Eintrag an Position (i,l) von $(AB)C$:

$$\big((AB)C\big)_{il} = \sum_{k=1}^{p} (AB)_{ik}\, c_{kl} = \sum_{k=1}^{p} \left(\sum_{j=1}^{n} a_{ij} b_{jk} \right) c_{kl}.$$

Jetzt ziehen wir c_{kl} in die innere Summe (Distributivgesetz in $\mathbb{R}$) und vertauschen die Summationsreihenfolge – das ist erlaubt, weil es sich um endliche Summen handelt:

$$= \sum_{k=1}^{p} \sum_{j=1}^{n} a_{ij} b_{jk} c_{kl} = \sum_{j=1}^{n} \sum_{k=1}^{p} a_{ij} b_{jk} c_{kl}.$$

Nun ziehen wir a_{ij} aus der inneren Summe:

$$= \sum_{j=1}^{n} a_{ij} \left(\sum_{k=1}^{p} b_{jk} c_{kl} \right) = \sum_{j=1}^{n} a_{ij} (BC)_{jl} = \big(A(BC)\big)_{il}.$$

Beide Seiten haben also an jeder Position denselben Eintrag. ∎

Nullteiler

$$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

Beide Faktoren sind ungleich null, das Produkt ist null. Die Matrizen bilden also *keinen* nullteilerfreien Ring.
Praktische Konsequenz: Aus $AB = AC$ darf man *nicht* auf $B = C$ schließen. Kürzen ist nur erlaubt, wenn A invertierbar ist.

2.3 Die Transponierte

Definition 2.5. Die **Transponierte** $A^{\mathsf{T}} \in \mathbb{R}^{n\times m}$ von $A \in \mathbb{R}^{m\times n}$ ist definiert durch $(A^{\mathsf{T}})_{ij} := a_{ji}$ – man spiegelt an der Hauptdiagonalen.

Satz 2.6. $(A^{\mathsf{T}})^{\mathsf{T}} = A$, $(A+B)^{\mathsf{T}} = A^{\mathsf{T}} + B^{\mathsf{T}}$, *und*

$$(AB)^{\mathsf{T}} = B^{\mathsf{T}} A^{\mathsf{T}}.$$

Beweis. Die letzte Formel ist die überraschende – die Reihenfolge kehrt sich um. Nachrechnen:

$$\big((AB)^{\mathsf{T}}\big)_{ij} = (AB)_{ji} = \sum_k a_{jk} b_{ki}.$$

Andererseits

$$(B^{\mathsf{T}} A^{\mathsf{T}})_{ij} = \sum_k (B^{\mathsf{T}})_{ik} (A^{\mathsf{T}})_{kj} = \sum_k b_{ki} a_{jk}.$$

Die beiden Summen sind identisch (in $\mathbb{R}$ ist die Multiplikation kommutativ, die Summanden sind also gleich).

Warum die Umkehrung nötig ist: Aus Formatgründen. Ist A vom Typ $m \times n$ und B vom Typ $n \times p$, so ist A^{T} vom Typ $n \times m$ und B^{T} vom Typ $p \times n$. Das Produkt $A^{\mathsf{T}} B^{\mathsf{T}}$ wäre gar nicht definiert (außer zufällig); nur $B^{\mathsf{T}} A^{\mathsf{T}}$ passt: $(p \times n)(n \times m) = p \times m$. ✓ ■

2.4 Die Inverse

Definition 2.7. Eine quadratische Matrix $A \in \mathbb{R}^{n \times n}$ heißt **invertierbar** (oder **regulär**), wenn es $B \in \mathbb{R}^{n \times n}$ gibt mit

$$AB = BA = I_n.$$

Man schreibt $B = A^{-1}$.

Satz 2.8 (Eindeutigkeit der Inversen)**.** *Die Inverse ist, falls sie existiert, eindeutig bestimmt.*

Beweis. Seien B und C beides Inverse. Dann

$$B = BI = B(AC) = (BA)C = IC = C,$$

wobei nacheinander die Definition der Einheitsmatrix, $AC = I$, die Assoziativität, $BA = I$ und wieder die Einheitsmatrix benutzt wurden. ■

Satz 2.9 (Formel für 2×2)**.** *Für* $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ *mit* $ad - bc \neq 0$ *gilt*

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Ist $ad - bc = 0$*, so ist* A *nicht invertierbar.*

Beweis. Verifikation:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = \begin{pmatrix} ad - bc & -ab + ba \\ cd - dc & -cb + da \end{pmatrix} = \begin{pmatrix} ad - bc & 0 \\ 0 & ad - bc \end{pmatrix} = (ad - bc) I.$$

Division durch $ad - bc$ liefert die Behauptung. Die andere Reihenfolge rechnet man genauso nach.

Der Fall $ad - bc = 0$. Angenommen, A wäre invertierbar. Die obige Rechnung zeigt

$$A \cdot \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = 0.$$

Multiplizieren wir von links mit A^{-1}:

$$\begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = 0,$$

also $a = b = c = d = 0$, also $A = 0$. Aber die Nullmatrix ist nicht invertierbar (es gilt $0 \cdot B = 0 \neq I$). Widerspruch. ■

Inverse berechnen: das Gauß–Jordan-Verfahren

Das Verfahren

Man schreibt $(A \mid I)$ nebeneinander und formt mit Zeilenumformungen so lange um, bis links die Einheitsmatrix steht. Dann steht rechts A^{-1}:

$$(A \mid I) \longrightarrow (I \mid A^{-1}).$$

Lässt sich links keine Einheitsmatrix erzeugen (tritt eine Nullzeile auf), so ist A nicht invertierbar.

Warum das funktioniert

Jede elementare Zeilenumformung entspricht der Multiplikation von *links* mit einer **Elementarmatrix**. Zum Beispiel entspricht „addiere das λ-fache von Zeile 2 zu Zeile 1“ der Matrix

$$E = \begin{pmatrix} 1 & \lambda \\ 0 & 1 \end{pmatrix}, \qquad \text{denn} \qquad E \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} = \begin{pmatrix} z_1 + \lambda z_2 \\ z_2 \end{pmatrix}.$$

Der ganze Algorithmus ist also eine Folge von Linksmultiplikationen:

$$E_k \cdots E_2 E_1 A = I.$$

Setzt man $P := E_k \cdots E_1$, so ist $PA = I$, also $P = A^{-1}$. Und dasselbe P wirkt auf die rechte Hälfte:

$$E_k \cdots E_1 I = PI = P = A^{-1}.$$

Das ist der ganze Trick: Die rechte Hälfte protokolliert, welche Umformungen man gemacht hat.

Aufgabe 2.2. Bestimmen Sie die Inverse von

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 0 & 0 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 0 – Aufstellen.

$$\left(\begin{array}{ccc|ccc} 2 & 1 & 1 & 1 & 0 & 0 \\ 1 & 3 & 2 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 \end{array}\right)$$

Schritt 1 – Bequemes Pivot nach oben. Zeilen 1 und 3 tauschen:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 3 & 2 & 0 & 1 & 0 \\ 2 & 1 & 1 & 1 & 0 & 0 \end{array}\right)$$

Schritt 2 – Erste Spalte ausräumen.
$Z_2 - Z_1$: links $(0,3,2)$, rechts $(0-0,\ 1-0,\ 0-1) = (0,1,-1)$.
$Z_3 - 2Z_1$: links $(0,1,1)$, rechts $(1,0,0-2) = (1,0,-2)$.

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 3 & 2 & 0 & 1 & -1 \\ 0 & 1 & 1 & 1 & 0 & -2 \end{array}\right)$$

Schritt 3 – Zeilen 2 und 3 tauschen (um wieder ein Pivot 1 zu bekommen):

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 & -2 \\ 0 & 3 & 2 & 0 & 1 & -1 \end{array}\right)$$

Schritt 4 – Zweite Spalte ausräumen.
$Z_3 - 3Z_2$: links $(0,\ 0,\ 2-3) = (0,0,-1)$; rechts $(0-3,\ 1-0,\ -1+6) = (-3,1,5)$.

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 & -2 \\ 0 & 0 & -1 & -3 & 1 & 5 \end{array}\right)$$

Schritt 5 – Dritte Zeile normieren $(\cdot(-1))$:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 & 0 & -2 \\ 0 & 0 & 1 & 3 & -1 & -5 \end{array}\right)$$

Schritt 6 – Nach oben ausräumen. $Z_2 - Z_3$:

links $(0,1,0)$; rechts $(1-3,\ 0+1,\ -2+5) = (-2,1,3)$.

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & -2 & 1 & 3 \\ 0 & 0 & 1 & 3 & -1 & -5 \end{array}\right)$$

Links steht die Einheitsmatrix. Fertig.
Ergebnis:

$$A^{-1} = \begin{pmatrix} 0 & 0 & 1 \\ -2 & 1 & 3 \\ 3 & -1 & -5 \end{pmatrix}.$$

Schritt 7 – Probe. Wir rechnen AA^{-1} nach, wenigstens die erste Zeile.
Zeile 1 von A ist $(2,1,1)$.
Spalte 1 von A^{-1} ist $(0,-2,3)$: $2\cdot 0 + 1\cdot(-2) + 1\cdot 3 = 1$. ✓
Spalte 2 ist $(0,1,-1)$: $2\cdot 0 + 1\cdot 1 + 1\cdot(-1) = 0$. ✓
Spalte 3 ist $(1,3,-5)$: $2\cdot 1 + 1\cdot 3 + 1\cdot(-5) = 0$. ✓
Und Zeile 3 von A ist $(1,0,0)$; mal Spalte 3: $1\cdot 1 + 0 + 0 = 1$. ✓

Satz 2.10 (Charakterisierung der Invertierbarkeit). *Für $A \in \mathbb{R}^{n\times n}$ sind äquivalent:*

(i) *A ist invertierbar.*
(ii) $\operatorname{Rang} A = n$.
(iii) *Das System $A\mathbf{x} = \mathbf{0}$ hat nur die Lösung $\mathbf{x} = \mathbf{0}$.*
(iv) *Für jedes $\mathbf{b}$ hat $A\mathbf{x} = \mathbf{b}$ genau eine Lösung.*
(v) *Die reduzierte Zeilenstufenform von A ist I_n.*
(vi) $\det A \neq 0$ *(siehe Kapitel 6).*

Beweis der Kette (i) $\Longrightarrow$ (iv) $\Longrightarrow$ (iii) $\Longrightarrow$ (ii) $\Longrightarrow$ (v) $\Longrightarrow$ (i). **(i) $\Longrightarrow$ (iv).** Ist A invertierbar, so ist $\mathbf{x} := A^{-1}\mathbf{b}$ eine Lösung, denn $A(A^{-1}\mathbf{b}) = (AA^{-1})\mathbf{b} = \mathbf{b}$. Sie ist eindeutig: Aus $A\mathbf{x} = A\mathbf{y}$ folgt durch Linksmultiplikation mit A^{-1} sofort $\mathbf{x} = \mathbf{y}$.

(iv) $\Longrightarrow$ (iii). Spezialfall $\mathbf{b} = \mathbf{0}$; die Lösung $\mathbf{x} = \mathbf{0}$ existiert immer und ist nach Voraussetzung die einzige.

(iii) $\Longrightarrow$ (ii). Nach Satz 1.6(b) hat die Lösungsmenge des homogenen Systems die Dimension $n - \operatorname{Rang} A$. Ist sie nur der Nullpunkt, so ist diese Dimension 0, also $\operatorname{Rang} A = n$.

(ii) $\Longrightarrow$ (v). Bei Rang n hat die Zeilenstufenform n Pivots in n Spalten – also in jeder Spalte genau eines, und sie stehen zwangsläufig auf der Diagonalen. Normiert man sie auf 1 und räumt nach oben aus, erhält man I_n.

(v) $\Longrightarrow$ (i). Nach der Überlegung zum Gauß–Jordan-Verfahren gibt es Elementarmatrizen mit $E_k \cdots E_1 A = I$. Also ist $P := E_k \cdots E_1$ eine Linksinverse. Elementarmatrizen sind offensichtlich invertierbar (jede Umformung ist umkehrbar), also ist P als Produkt invertierbarer Matrizen invertierbar, und aus $PA = I$ folgt $A = P^{-1}$, also ist A invertierbar mit $A^{-1} = P$. ∎

Satz 2.11. *Sind A, B invertierbar, so auch AB, und*

$$(AB)^{-1} = B^{-1}A^{-1}.$$

Beweis.

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = AA^{-1} = I,$$

und analog von der anderen Seite. ∎

Die Socken-und-Schuhe-Regel

Erst Socken, dann Schuhe – zum Ausziehen erst Schuhe, dann Socken. Die Umkehrung einer Verkettung kehrt die Reihenfolge um. Dasselbe Muster wie beim Transponieren.

2.5 Blockmatrizen und die LR-Zerlegung

Rechnen mit Blöcken

Zerlegt man Matrizen in Blöcke passender Größe, so gelten dieselben Multiplikationsregeln:

$$\begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix} = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix},$$

sofern alle auftretenden Produkte definiert sind. **Achtung:** Die Reihenfolge innerhalb der Blockprodukte darf nicht vertauscht werden.
Dieses Prinzip ist die Grundlage aller schnellen Matrixalgorithmen – insbesondere des Strassen-Verfahrens (Kapitel 13).

Satz 2.12 (LR-Zerlegung). *Lässt sich $A \in \mathbb{R}^{n\times n}$ ohne Zeilenvertauschungen auf Zeilenstufenform bringen, so gibt es eine untere Dreiecksmatrix L mit Einsen auf der Diagonalen und eine obere Dreiecksmatrix R mit*

$$A = LR.$$

Mit Zeilenvertauschungen gilt allgemein $PA = LR$ mit einer Permutationsmatrix P.

Aufgabe 2.3. Bestimmen Sie die LR-Zerlegung von $A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$.

Lösung Schritt für Schritt.

Idee. Wir führen die Gauß-Elimination durch und *merken uns die Faktoren*, mit denen wir eliminiert haben. Diese Faktoren bilden L.
Schritt 1 – Erste Spalte.
$Z_2 - 2Z_1$ (Faktor $\ell_{21} = 2$): $(0,\, 3-2,\, 3-2) = (0, 1, 1)$.

$Z_3 - 4Z_1$ (Faktor $\ell_{31} = 4$): $(0,\, 7-4,\, 9-4) = (0,3,5)$.

$$\begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 3 & 5 \end{pmatrix}$$

Schritt 2 – Zweite Spalte.
$Z_3 - 3Z_2$ (Faktor $\ell_{32} = 3$): $(0,\, 0,\, 5-3) = (0,0,2)$.

$$R = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}$$

Schritt 3 – L aufstellen. Die Faktoren kommen an die entsprechenden Positionen:

$$L = \begin{pmatrix} 1 & 0 & 0 \\ \ell_{21} & 1 & 0 \\ \ell_{31} & \ell_{32} & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}.$$

Schritt 4 – Probe: LR ausrechnen.
Zeile 1 von L ist $(1,0,0)$: liefert genau Zeile 1 von R, also $(2,1,1)$. ✓
Zeile 2 ist $(2,1,0)$:

$$2\cdot(2,1,1) + 1\cdot(0,1,1) + 0 = (4,\, 2+1,\, 2+1) = (4,3,3). \checkmark$$

Zeile 3 ist $(4,3,1)$:

$$4\cdot(2,1,1) + 3\cdot(0,1,1) + 1\cdot(0,0,2) = (8,\, 4+3,\, 4+3+2) = (8,7,9). \checkmark$$

Wozu das gut ist. Will man $A\mathbf{x} = \mathbf{b}$ für *viele* verschiedene $\mathbf{b}$ lösen, so zerlegt man einmal ($\frac{2}{3}n^3$ Operationen) und löst dann jedes Mal nur noch zwei Dreieckssysteme:

$$L\mathbf{y} = \mathbf{b} \quad \text{(Vorwärtseinsetzen)}, \qquad R\mathbf{x} = \mathbf{y} \quad \text{(Rückwärtseinsetzen)},$$

mit je $O(n^2)$ Operationen. Bei 1000 rechten Seiten spart man den Faktor 1000 auf dem teuren Teil.

Part II

Der abstrakte Sprung

3 Vektorräume

3.1 Der schwierigste Schritt des Buches

Bis hierher war alles konkret: Zahlen in Tabellen, Rechenregeln, Algorithmen. Jetzt kommt der Schritt, an dem die meisten Anfänger straucheln – und er ist nicht schwierig, weil er kompliziert wäre, sondern weil er *eine andere Art des Denkens* verlangt.

Die Idee ist folgende. Wir haben inzwischen mehrere Dinge gesehen, mit denen man auf dieselbe Weise rechnet:

Objekte	**Addition**	**Skalarmultiplikation**
Pfeile in der Ebene	Aneinandersetzen	Strecken/Stauchen
Zahlentupel $(x_1, \dots, x_n)$	komponentenweise	komponentenweise
Matrizen $\mathbb{R}^{m\times n}$	eintragsweise	eintragsweise
Polynome $a_0 + a_1 x + \dots$	koeffizientenweise	koeffizientenweise
Funktionen $f : \mathbb{R} \to \mathbb{R}$	$(f+g)(x) = f(x) + g(x)$	$(\lambda f)(x) = \lambda f(x)$
Lösungen eines homogenen LGS	wie Tupel	wie Tupel

In allen sechs Fällen gelten dieselben Rechenregeln. Das ist keine Zufälligkeit – es ist ein Hinweis darauf, dass es eine gemeinsame Struktur gibt.

> **Die zentrale Bewegung der modernen Mathematik**
>
> Man schreibt die gemeinsamen Regeln als *Axiome* auf und beweist Sätze allein daraus. Jeder bewiesene Satz gilt dann automatisch für alle sechs Beispiele – und für alle, die noch gefunden werden.
> Das ist keine Liebhaberei der Abstraktion. Es ist Ökonomie: Man beweist einmal statt sechsmal. Und es ist Erkenntnis: Man sieht, *welche* Eigenschaften für ein Resultat wirklich gebraucht werden.

3.2 Körper – der Vorrat an Skalaren

Bevor wir Vektorräume definieren, müssen wir sagen, womit wir skalieren dürfen.

Definition 3.1 (Körper). Ein **Körper** ist eine Menge $\mathbb{K}$ mit zwei Verknüpfungen $+$ und $\cdot$, sodass gilt:

(K1) $(\mathbb{K}, +)$ ist eine abelsche Gruppe: Assoziativität, Kommutativität, neutrales Element 0, zu jedem a ein Negatives $-a$.

(K2) $(\mathbb{K} \setminus \{0\}, \cdot)$ ist eine abelsche Gruppe: Assoziativität, Kommutativität, neutrales Element $1 \neq 0$, zu jedem $a \neq 0$ ein Inverses a^{-1}.

(K3) Distributivgesetz: $a(b+c) = ab + ac$.

Beispiel 3.2. $\mathbb{Q}$, $\mathbb{R}$, $\mathbb{C}$ sind Körper. $\mathbb{Z}$ ist *keiner* – es fehlen die multiplikativen Inversen ($2^{-1} = \frac{1}{2} \notin \mathbb{Z}$).

Für eine Primzahl p ist $\mathbb{F}_p = \mathbb{Z}/p\mathbb{Z}$ ein Körper (das haben wir in Band 1 bewiesen). Etwa $\mathbb{F}_2 = \{0, 1\}$ mit $1 + 1 = 0$.

Warum das wichtig ist – ein konkretes Beispiel

In $\mathbb{F}_2$ gilt $1 + 1 = 0$, also $2 = 0$. Formeln, die durch 2 dividieren, brechen zusammen. Zum Beispiel ist die Zerlegung einer Matrix in symmetrischen und antisymmetrischen Anteil

$$A = \underbrace{\tfrac{1}{2}(A + A^{\mathsf{T}})}_{\text{symmetrisch}} + \underbrace{\tfrac{1}{2}(A - A^{\mathsf{T}})}_{\text{antisymmetrisch}}$$

über $\mathbb{F}_2$ sinnlos.
Deshalb steht in guten Lehrbüchern bei manchen Sätzen die Voraussetzung „$\operatorname{char}\mathbb{K} \neq 2$“. Wir arbeiten in diesem Buch überwiegend mit $\mathbb{K} = \mathbb{R}$ und weisen auf Stellen hin, wo der Körper eine Rolle spielt.

3.3 Die Vektorraumaxiome

Definition 3.3 (Vektorraum). Ein **$\mathbb{K}$-Vektorraum** ist eine Menge V zusammen mit

- einer Addition $+ : V \times V \to V$,
- einer Skalarmultiplikation $\cdot : \mathbb{K} \times V \to V$,

sodass für alle $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ und $\lambda, \mu \in \mathbb{K}$ gilt:

(V1) $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$ (Assoziativität)
(V2) $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$ (Kommutativität)
(V3) Es gibt $\mathbf{0} \in V$ mit $\mathbf{v} + \mathbf{0} = \mathbf{v}$ für alle $\mathbf{v}$ (Nullvektor)
(V4) Zu jedem $\mathbf{v}$ gibt es $-\mathbf{v}$ mit $\mathbf{v} + (-\mathbf{v}) = \mathbf{0}$ (Negatives)
(V5) $\lambda(\mathbf{u} + \mathbf{v}) = \lambda\mathbf{u} + \lambda\mathbf{v}$
(V6) $(\lambda + \mu)\mathbf{v} = \lambda\mathbf{v} + \mu\mathbf{v}$
(V7) $(\lambda\mu)\mathbf{v} = \lambda(\mu\mathbf{v})$
(V8) $1 \cdot \mathbf{v} = \mathbf{v}$

Zwei Feinheiten, die man leicht übersieht

(a) Es gibt zwei verschiedene Pluszeichen. In (V6) steht links $\lambda + \mu$ – das ist Addition *in* $\mathbb{K}$. Rechts steht $\lambda\mathbf{v} + \mu\mathbf{v}$ – das ist Addition *in* V. Dass man dasselbe Symbol benutzt, ist bequem und gefährlich.
(b) Warum braucht man (V8)? Es sieht überflüssig aus. Es ist es nicht. Betrachten Sie $V = \mathbb{R}$ mit gewöhnlicher Addition, aber der Skalarmultiplikation $\lambda \odot v := 0$ für alle λ, v. Dann gelten (V1)–(V7), aber (V8) versagt: $1 \odot v = 0 \neq v$. Ohne (V8) hätte man also degenerierte Strukturen, in denen die Skalarmultiplikation nichts tut.

Satz 3.4 (Erste Folgerungen)**.** *In jedem Vektorraum gilt:*

(a) *Der Nullvektor ist eindeutig.*
(b) $0 \cdot \mathbf{v} = \mathbf{0}$ *für alle* $\mathbf{v} \in V$.
(c) $\lambda \cdot \mathbf{0} = \mathbf{0}$ *für alle* $\lambda \in \mathbb{K}$.
(d) $(-1)\mathbf{v} = -\mathbf{v}$.
(e) *Aus* $\lambda\mathbf{v} = \mathbf{0}$ *folgt* $\lambda = 0$ *oder* $\mathbf{v} = \mathbf{0}$.

Beweis. Diese Aussagen wirken selbstverständlich. Sie sind es nicht – sie *folgen* aus den Axiomen, und das muss man zeigen. Beachten Sie, wie wenig dabei benutzt wird.

(a) Seien $\mathbf{0}$ und $\mathbf{0}'$ beides neutrale Elemente. Dann

$$\mathbf{0} = \mathbf{0} + \mathbf{0}' = \mathbf{0}' + \mathbf{0} = \mathbf{0}',$$

wobei zuerst die Neutralität von $\mathbf{0}'$, dann (V2), dann die Neutralität von $\mathbf{0}$ benutzt wurde.

(b) Hier ist der Trick, den man kennen muss. Wir schreiben $0 = 0 + 0$ in $\mathbb{K}$ und benutzen (V6):

$$0 \cdot \mathbf{v} = (0+0) \cdot \mathbf{v} = 0 \cdot \mathbf{v} + 0 \cdot \mathbf{v}.$$

Nun addieren wir auf beiden Seiten $-(0 \cdot \mathbf{v})$, das nach (V4) existiert:

$$0 \cdot \mathbf{v} + \big(-(0 \cdot \mathbf{v})\big) = \big(0 \cdot \mathbf{v} + 0 \cdot \mathbf{v}\big) + \big(-(0 \cdot \mathbf{v})\big).$$

Links steht $\mathbf{0}$. Rechts klammern wir nach (V1) um:

$$\mathbf{0} = 0 \cdot \mathbf{v} + \underbrace{\big(0 \cdot \mathbf{v} - 0 \cdot \mathbf{v}\big)}_{=\mathbf{0}} = 0 \cdot \mathbf{v} + \mathbf{0} = 0 \cdot \mathbf{v}.$$

(c) Analog mit $\mathbf{0} = \mathbf{0} + \mathbf{0}$ und (V5).

(d) Wir zeigen, dass $(-1)\mathbf{v}$ die definierende Eigenschaft des Negativen hat:

$$\mathbf{v} + (-1)\mathbf{v} \overset{\text{(V8)}}{=} 1 \cdot \mathbf{v} + (-1)\mathbf{v} \overset{\text{(V6)}}{=} (1 + (-1))\mathbf{v} = 0 \cdot \mathbf{v} \overset{\text{(b)}}{=} \mathbf{0}.$$

Da das Negative eindeutig ist (analog zu (a)), folgt $(-1)\mathbf{v} = -\mathbf{v}$.

(e) Sei $\lambda\mathbf{v} = \mathbf{0}$ und $\lambda \neq 0$. Da $\mathbb{K}$ ein Körper ist, existiert λ^{-1}. Dann

$$\mathbf{v} \overset{\text{(V8)}}{=} 1 \cdot \mathbf{v} = (\lambda^{-1}\lambda)\mathbf{v} \overset{\text{(V7)}}{=} \lambda^{-1}(\lambda\mathbf{v}) = \lambda^{-1}\mathbf{0} \overset{\text{(c)}}{=} \mathbf{0}.$$

■

Was diese Beweise lehren

Punkt (e) benutzt *wesentlich*, dass $\mathbb{K}$ ein Körper ist. Über einem Ring wie $\mathbb{Z}/6\mathbb{Z}$ gilt die Aussage nicht: dort ist $2 \cdot 3 = 0$ mit beiden Faktoren ungleich null. Strukturen über Ringen heißen **Moduln**, und ein großer Teil der Theorie bricht dort zusammen – insbesondere existieren nicht immer Basen.
Das ist der Grund, warum die lineare Algebra so gut funktioniert: Die Körperaxiome sind genau stark genug.

3.4 Beispiele – vom Vertrauten zum Ungewohnten

Beispiel 3.5 (Der Standardraum). $\mathbb{K}^n := \{(x_1, \ldots, x_n) : x_i \in \mathbb{K}\}$ mit komponentenweisen Operationen. Für $\mathbb{K} = \mathbb{R}$, $n = 2$ oder 3 ist das die Ebene bzw. der Anschauungsraum.

Beispiel 3.6 (Polynome). $\mathbb{K}[x]$, die Menge aller Polynome mit Koeffizienten in $\mathbb{K}$. Addition und Skalarmultiplikation koeffizientenweise. Dieser Raum ist *unendlichdimensional* – die Monome $1, x, x^2, x^3, \ldots$ sind alle voneinander unabhängig.

Der Unterraum $\mathbb{K}[x]_{\leq n}$ der Polynome vom Grad höchstens n hat dagegen die Dimension $n + 1$.

Beispiel 3.7 (Funktionenräume). $\mathrm{Abb}(M, \mathbb{R}) := \{f : M \to \mathbb{R}\}$ für eine beliebige Menge M, mit punktweisen Operationen. Enthält als Unterräume: die stetigen Funktionen, die differenzierbaren, die integrierbaren.

Dies ist der Raum, in dem die gesamte Analysis stattfindet. Der Ableitungsoperator $D : f \mapsto f'$ ist eine lineare Abbildung, denn $(f+g)' = f' + g'$ und $(\lambda f)' = \lambda f'$. Die gesamte Theorie linearer Differentialgleichungen ist lineare Algebra in solchen Räumen.

Beispiel 3.8 (Ein überraschender Fall). Sei $V := \mathbb{R}_{>0}$, die Menge der *positiven* reellen Zahlen. Wir definieren

$$\mathbf{u} \oplus \mathbf{v} := u \cdot v \qquad \text{(gewöhnliche Multiplikation!)},$$
$$\lambda \odot \mathbf{v} := v^\lambda.$$

Behauptung: Das ist ein $\mathbb{R}$-Vektorraum.

Nachprüfen: (V1) ist die Assoziativität der Multiplikation. (V2) die Kommutativität. Der Nullvektor ist die Zahl 1, denn $v \cdot 1 = v$. Das Negative von v ist $\frac{1}{v}$, denn $v \cdot \frac{1}{v} = 1 = \mathbf{0}$.
(V5): $\lambda \odot (u \oplus v) = (uv)^\lambda = u^\lambda v^\lambda = (\lambda \odot u) \oplus (\lambda \odot v)$. ✓
(V6): $(\lambda + \mu) \odot v = v^{\lambda+\mu} = v^\lambda v^\mu = (\lambda \odot v) \oplus (\mu \odot v)$. ✓
(V7): $(\lambda\mu) \odot v = v^{\lambda\mu} = (v^\mu)^\lambda = \lambda \odot (\mu \odot v)$. ✓
(V8): $1 \odot v = v^1 = v$. ✓

Was hier passiert. Der Logarithmus ist ein Isomorphismus $V \to \mathbb{R}$: Er verwandelt Multiplikation in Addition und Potenzieren in Multiplikation. Dieser Raum ist also „im Wesentlichen" $\mathbb{R}^1$, nur in anderer Verkleidung.

Genau deshalb rechnet man in der Statistik oft mit Log-Werten: Man macht aus einem multiplikativen Problem ein additives, also ein lineares.

3.5 Untervektorräume

Definition 3.9. Eine Teilmenge $U \subseteq V$ heißt **Untervektorraum** (UVR), wenn

(U1) $\mathbf{0} \in U$ (insbesondere $U \neq \emptyset$)
(U2) $\mathbf{u}, \mathbf{v} \in U \Longrightarrow \mathbf{u} + \mathbf{v} \in U$ (abgeschlossen unter Addition)
(U3) $\lambda \in \mathbb{K},\ \mathbf{u} \in U \Longrightarrow \lambda \mathbf{u} \in U$ (abgeschlossen unter Skalarmultiplikation)

Warum drei Bedingungen reichen

Man müsste eigentlich alle acht Vektorraumaxiome nachprüfen. Das ist unnötig: Axiome wie Assoziativität und Kommutativität sind *Gleichungen*, die für alle Elemente von V gelten – also erst recht für die Elemente von U. Sie werden *vererbt*.
Was *nicht* automatisch vererbt wird, ist die Existenz von Elementen: Man muss sicherstellen, dass Summen und Vielfache den Bereich nicht verlassen und dass $\mathbf{0}$ dabei ist. Genau das leisten (U1)–(U3).
Das Negative folgt übrigens aus (U3): $-\mathbf{u} = (-1)\mathbf{u} \in U$.
Warum (U1) und nicht nur $U \neq \emptyset$? Beides ist äquivalent, wenn (U3) gilt: Ist $\mathbf{u} \in U$, so $0 \cdot \mathbf{u} = \mathbf{0} \in U$. Man fordert (U1) trotzdem explizit, weil es der schnellste Test ist: *Enthält die Menge die Null?* Wenn nein, ist man sofort fertig.

Aufgabe 3.1. Welche der folgenden Mengen sind Untervektorräume von $\mathbb{R}^3$?

(a) $U_1 = \{(x,y,z) : x + 2y - z = 0\}$ (b) $U_2 = \{(x,y,z) : x + 2y - z = 1\}$
(c) $U_3 = \{(x,y,z) : x^2 = y^2\}$ (d) $U_4 = \{(x,y,z) : x \geq 0\}$
(e) $U_5 = \{(t,2t,-t) : t \in \mathbb{R}\}$ (f) $U_6 = \{(x,y,z) : xyz = 0\}$

Lösung Schritt für Schritt.

(a) U_1 – ja.
(U1): $(0,0,0)$ erfüllt $0 + 0 - 0 = 0$. ✓
(U2): Seien $\mathbf{u} = (u_1,u_2,u_3)$ und $\mathbf{v} = (v_1,v_2,v_3)$ in U_1, also

$$u_1 + 2u_2 - u_3 = 0, \qquad v_1 + 2v_2 - v_3 = 0.$$

Für die Summe:

$$(u_1+v_1) + 2(u_2+v_2) - (u_3+v_3) = \underbrace{(u_1 + 2u_2 - u_3)}_{=0} + \underbrace{(v_1 + 2v_2 - v_3)}_{=0} = 0. \checkmark$$

(U3): $\lambda u_1 + 2\lambda u_2 - \lambda u_3 = \lambda(u_1 + 2u_2 - u_3) = \lambda \cdot 0 = 0$. ✓
U_1 ist eine Ebene durch den Ursprung.

(b) U_2 – nein.
(U1) versagt sofort: $(0,0,0)$ liefert $0 \neq 1$. Der Nullvektor fehlt.

U_2 ist eine Ebene, die *nicht* durch den Ursprung geht – ein affiner Unterraum, kein Untervektorraum. Sie ist die Lösungsmenge eines *inhomogenen* Systems.

(c) U_3 – nein.
(U1) gilt: $0^2 = 0^2$. ✓ (U3) gilt: aus $x^2 = y^2$ folgt $(\lambda x)^2 = \lambda^2 x^2 = \lambda^2 y^2 = (\lambda y)^2$. ✓
Aber (U2) versagt. Gegenbeispiel:

$$\mathbf{u} = (1,1,0) \in U_3 \quad (1 = 1), \qquad \mathbf{v} = (1,-1,0) \in U_3 \quad (1 = 1).$$

Summe: $\mathbf{u} + \mathbf{v} = (2,0,0)$. Prüfung: $2^2 = 4 \neq 0 = 0^2$. **Nicht in U_3.**
Geometrisch: U_3 besteht aus den beiden Ebenen $x = y$ und $x = -y$. Die Vereinigung zweier Unterräume ist fast nie ein Unterraum.

(d) U_4 – nein.
(U1) und (U2) gelten. Aber (U3) versagt für negative Skalare: $(1,0,0) \in U_4$, aber $(-1) \cdot (1,0,0) = (-1,0,0) \notin U_4$.
Merke: Ein Untervektorraum ist stets symmetrisch zum Ursprung. Halbräume, Kegel und Quadranten sind niemals Untervektorräume.

(e) U_5 – ja.
(U1): $t = 0$ liefert $(0,0,0)$. ✓
(U2): $(t, 2t, -t) + (s, 2s, -s) = (t+s,\, 2(t+s),\, -(t+s))$ – das ist wieder von der Form mit Parameter $t + s$. ✓
(U3): $\lambda(t, 2t, -t) = (\lambda t, 2\lambda t, -\lambda t)$. ✓
U_5 ist eine Gerade durch den Ursprung.

(f) U_6 – nein.
(U1) und (U3) gelten. (U2) versagt:

$$(1,1,0) \in U_6 \text{ (da } 1 \cdot 1 \cdot 0 = 0), \qquad (0,0,1) \in U_6.$$

Summe: $(1,1,1)$, und $1 \cdot 1 \cdot 1 = 1 \neq 0$. **Nicht in U_6.**
Geometrisch: U_6 ist die Vereinigung der drei Koordinatenebenen – wieder eine Vereinigung, wieder kein Unterraum.

Satz 3.10. *Der Durchschnitt beliebig vieler Untervektorräume ist ein Untervektorraum. Die* Vereinigung *zweier Untervektorräume U, W ist genau dann einer, wenn $U \subseteq W$ oder $W \subseteq U$.*

Beweis. **Durchschnitt.** Sei $(U_i)_{i \in I}$ eine Familie von UVR und $D = \bigcap_i U_i$.
(U1): $\mathbf{0} \in U_i$ für jedes i, also $\mathbf{0} \in D$.
(U2): Sind $\mathbf{u}, \mathbf{v} \in D$, so liegen beide in jedem U_i; da jedes U_i abgeschlossen ist, liegt $\mathbf{u} + \mathbf{v}$ in jedem U_i, also in D.
(U3): analog.
Vereinigung. Ist etwa $U \subseteq W$, so $U \cup W = W$ – ein UVR.
Umgekehrt sei $U \cup W$ ein UVR und weder $U \subseteq W$ noch $W \subseteq U$. Dann gibt es $\mathbf{u} \in U \setminus W$ und $\mathbf{w} \in W \setminus U$. Da $U \cup W$ abgeschlossen ist, liegt $\mathbf{u} + \mathbf{w}$ in $U \cup W$, also in U oder in W.

Fall $\mathbf{u}+\mathbf{w}\in U$*:* Dann ist $\mathbf{w}=(\mathbf{u}+\mathbf{w})-\mathbf{u}$ Differenz zweier Elemente von U, also $\mathbf{w}\in U$ – Widerspruch.
Fall $\mathbf{u}+\mathbf{w}\in W$*:* Dann ist $\mathbf{u}=(\mathbf{u}+\mathbf{w})-\mathbf{w}\in W$ – Widerspruch. ∎

Definition 3.11 (Summe von Unterräumen)**.** Für Untervektorräume $U,W\subseteq V$ sei

$$U+W:=\{\,\mathbf{u}+\mathbf{w}:\mathbf{u}\in U,\ \mathbf{w}\in W\,\}.$$

Gilt zusätzlich $U\cap W=\{\mathbf{0}\}$, so heißt die Summe **direkt**, geschrieben $U\oplus W$.

Satz 3.12. *$U+W$ ist der kleinste Untervektorraum, der U und W enthält. Bei direkter Summe ist die Darstellung* $\mathbf{v}=\mathbf{u}+\mathbf{w}$ eindeutig.

Beweis. Dass $U+W$ ein UVR ist, rechnet man direkt nach: $(\mathbf{u}_1+\mathbf{w}_1)+(\mathbf{u}_2+\mathbf{w}_2)=(\mathbf{u}_1+\mathbf{u}_2)+(\mathbf{w}_1+\mathbf{w}_2)$ – man nutzt Kommutativität zum Umsortieren.
Jeder UVR, der U und W enthält, muss alle Summen $\mathbf{u}+\mathbf{w}$ enthalten, also $U+W$ umfassen. Somit ist $U+W$ der kleinste.
Eindeutigkeit bei direkter Summe. Seien

$$\mathbf{u}_1+\mathbf{w}_1=\mathbf{u}_2+\mathbf{w}_2.$$

Umstellen: $\mathbf{u}_1-\mathbf{u}_2=\mathbf{w}_2-\mathbf{w}_1$. Die linke Seite liegt in U, die rechte in W. Also liegt dieser Vektor in $U\cap W=\{\mathbf{0}\}$, ist also null. Somit $\mathbf{u}_1=\mathbf{u}_2$ und $\mathbf{w}_1=\mathbf{w}_2$. ∎

Beispiel 3.13. $\mathbb{R}^2=\{(x,0)\}\oplus\{(0,y)\}$: Jeder Vektor zerlegt sich eindeutig in horizontalen und vertikalen Anteil.
Dagegen ist $\mathbb{R}^2=\{(x,0)\}+\{(y,y)\}$ ebenfalls eine direkte Summe (der Durchschnitt ist nur die Null), obwohl die Räume nicht senkrecht aufeinander stehen. **Direktheit ist ein algebraischer, kein geometrischer Begriff** – Orthogonalität kommt erst in Kapitel 9 ins Spiel.

3.6 Linearkombinationen und Erzeugendensysteme

Definition 3.14. Seien $\mathbf{v}_1,\dots,\mathbf{v}_k\in V$. Ein Vektor der Form

$$\lambda_1\mathbf{v}_1+\lambda_2\mathbf{v}_2+\cdots+\lambda_k\mathbf{v}_k,\qquad \lambda_i\in\mathbb{K},$$

heißt **Linearkombination** der $\mathbf{v}_i$. Die Menge aller Linearkombinationen heißt **lineare Hülle** oder **Spann**:

$$\operatorname{span}(\mathbf{v}_1,\dots,\mathbf{v}_k):=\left\{\sum_{i=1}^{k}\lambda_i\mathbf{v}_i:\lambda_i\in\mathbb{K}\right\}.$$

Satz 3.15. $\operatorname{span}(\mathbf{v}_1,\dots,\mathbf{v}_k)$ *ist der kleinste Untervektorraum, der alle* $\mathbf{v}_i$ *enthält.*

Beweis. **UVR-Eigenschaft.** $\mathbf{0} = 0\mathbf{v}_1 + \cdots + 0\mathbf{v}_k$ liegt darin. Summen und Vielfache von Linearkombinationen sind wieder Linearkombinationen:

$$\sum \lambda_i \mathbf{v}_i + \sum \mu_i \mathbf{v}_i = \sum (\lambda_i + \mu_i)\mathbf{v}_i, \qquad \mu \sum \lambda_i \mathbf{v}_i = \sum (\mu\lambda_i)\mathbf{v}_i.$$

(Hier gehen (V5)–(V7) ein.)

Minimalität. Ein UVR, der alle $\mathbf{v}_i$ enthält, enthält wegen (U3) alle $\lambda_i \mathbf{v}_i$ und wegen (U2) alle Summen davon. ■

Definition 3.16. $\{\mathbf{v}_1, \ldots, \mathbf{v}_k\}$ heißt **Erzeugendensystem** von V, wenn $\operatorname{span}(\mathbf{v}_1, \ldots, \mathbf{v}_k) = V$.

Aufgabe 3.2. Liegt $\mathbf{b} = (1, 4, 7)$ im Spann von $\mathbf{v}_1 = (1, 2, 3)$, $\mathbf{v}_2 = (0, 1, 2)$?

Lösung Schritt für Schritt.

Schritt 1 – Frage übersetzen. Gesucht sind λ_1, λ_2 mit

$$\lambda_1 \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} + \lambda_2 \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \\ 7 \end{pmatrix}.$$

Komponentenweise gelesen ist das ein lineares Gleichungssystem:

$$\lambda_1 = 1, \qquad 2\lambda_1 + \lambda_2 = 4, \qquad 3\lambda_1 + 2\lambda_2 = 7.$$

Schritt 2 – Lösen. Aus der ersten Gleichung: $\lambda_1 = 1$. Einsetzen in die zweite: $2 + \lambda_2 = 4$, also $\lambda_2 = 2$.
Schritt 3 – Dritte Gleichung prüfen (das ist die Konsistenzbedingung!):

$$3 \cdot 1 + 2 \cdot 2 = 3 + 4 = 7. \checkmark$$

Ergebnis: Ja, $\mathbf{b} = 1 \cdot \mathbf{v}_1 + 2 \cdot \mathbf{v}_2$.
Die allgemeine Einsicht. Die Frage „Liegt $\mathbf{b}$ im Spann der Spalten von A?“ ist wörtlich dieselbe wie „Ist $A\mathbf{x} = \mathbf{b}$ lösbar?“. Der Spann der Spalten heißt deshalb **Spaltenraum** von A, und Satz 1.6 sagt genau: Das System ist lösbar genau dann, wenn $\mathbf{b}$ im Spaltenraum liegt.
Damit haben wir zwei völlig verschiedene Sprachen für dasselbe Phänomen – die algorithmische (Rang, Zeilenstufenform) und die geometrische (Spann, Unterraum). Beide zu beherrschen ist der Kern des Verstehens in diesem Gebiet.

Aufgabe 3.3. Zeigen Sie, dass $\{1, x, x^2\}$ und $\{1, 1 + x, 1 + x + x^2\}$ beide den Raum $\mathbb{R}[x]_{\leq 2}$ erzeugen.

Lösung Schritt für Schritt.

Erste Menge. Jedes Polynom vom Grad ≤ 2 hat die Form $a + bx + cx^2$, ist also per Definition Linearkombination von $1, x, x^2$. ✓

Zweite Menge. Zu zeigen: Jedes $a + bx + cx^2$ lässt sich als

$$\lambda_1 \cdot 1 + \lambda_2(1 + x) + \lambda_3(1 + x + x^2)$$

schreiben. Wir multiplizieren aus und sortieren nach Potenzen:

$$= (\lambda_1 + \lambda_2 + \lambda_3) + (\lambda_2 + \lambda_3)x + \lambda_3 x^2.$$

Koeffizientenvergleich liefert das System

$$\lambda_1 + \lambda_2 + \lambda_3 = a, \qquad \lambda_2 + \lambda_3 = b, \qquad \lambda_3 = c.$$

Das lässt sich von unten nach oben auflösen:

$$\lambda_3 = c, \qquad \lambda_2 = b - c, \qquad \lambda_1 = a - (b - c) - c = a - b.$$

Also: $a + bx + cx^2 = (a - b) \cdot 1 + (b - c)(1 + x) + c(1 + x + x^2)$.
Probe mit $a = 3, b = 5, c = 2$, also dem Polynom $3 + 5x + 2x^2$:

$$(3-5) \cdot 1 + (5-2)(1+x) + 2(1+x+x^2) = -2+3+3x+2+2x+2x^2 = 3+5x+2x^2$$

Beobachtung. Das System hatte Dreiecksgestalt und war deshalb eindeutig lösbar. Das ist kein Zufall: Beide Mengen sind *Basen* – und genau das ist das Thema des nächsten Kapitels.

4 Basis und Dimension

4.1 Lineare Unabhängigkeit

Im letzten Kapitel haben wir gesehen: Ein Erzeugendensystem beschreibt den ganzen Raum. Aber es kann Überflüssiges enthalten. Die Menge $\{(1,0),(0,1),(1,1)\}$ erzeugt $\mathbb{R}^2$ – der dritte Vektor ist aber entbehrlich, denn $(1,1) = (1,0) + (0,1)$.

Wir brauchen einen Begriff für „kein Vektor ist überflüssig“.

Definition 4.1 (Lineare Unabhängigkeit). Vektoren $\mathbf{v}_1, \dots, \mathbf{v}_k \in V$ heißen **linear unabhängig**, wenn aus

$$\lambda_1 \mathbf{v}_1 + \lambda_2 \mathbf{v}_2 + \cdots + \lambda_k \mathbf{v}_k = \mathbf{0}$$

stets $\lambda_1 = \lambda_2 = \cdots = \lambda_k = 0$ folgt.

Andernfalls heißen sie **linear abhängig**.

> **Was die Definition wirklich sagt**
>
> Die Gleichung $\sum \lambda_i \mathbf{v}_i = \mathbf{0}$ hat *immer* die Lösung $\lambda_1 = \cdots = \lambda_k = 0$ – die sogenannte **triviale** Darstellung des Nullvektors. Die Frage ist, ob es noch eine *andere* gibt.
>
> - **Unabhängig** = nur die triviale Darstellung.
> - **Abhängig** = es gibt eine nichttriviale, also mit mindestens einem $\lambda_i \neq 0$.
>
> **Der häufigste Anfängerfehler** ist, die Definition als „kein Vektor ist Vielfaches eines anderen“ zu lesen. Das ist zu schwach. Die drei Vektoren
>
> $$(1,0,0), \quad (0,1,0), \quad (1,1,0)$$
>
> sind paarweise keine Vielfachen voneinander – und trotzdem abhängig, denn $(1,0,0) + (0,1,0) - (1,1,0) = \mathbf{0}$.

Satz 4.2 (Äquivalente Formulierung). *$\mathbf{v}_1, \dots, \mathbf{v}_k$ sind genau dann linear abhängig, wenn sich einer von ihnen als Linearkombination der übrigen schreiben lässt.*

Beweis. „⇒“: Es gebe eine nichttriviale Darstellung $\sum \lambda_i \mathbf{v}_i = \mathbf{0}$, etwa mit $\lambda_j \neq 0$. Wir isolieren $\mathbf{v}_j$:

$$\lambda_j \mathbf{v}_j = -\sum_{i \neq j} \lambda_i \mathbf{v}_i.$$

Da $\lambda_j \neq 0$, dürfen wir durch λ_j dividieren (hier geht ein, dass $\mathbb{K}$ ein Körper ist!):

$$\mathbf{v}_j = -\sum_{i \neq j} \frac{\lambda_i}{\lambda_j} \mathbf{v}_i.$$

„⇐“: Sei $\mathbf{v}_j = \sum_{i \neq j} \mu_i \mathbf{v}_i$. Umstellen liefert

$$\sum_{i \neq j} \mu_i \mathbf{v}_i + (-1)\mathbf{v}_j = \mathbf{0},$$

und der Koeffizient von $\mathbf{v}_j$ ist $-1 \neq 0$. Das ist eine nichttriviale Darstellung. ■

Sonderfälle, die man kennen muss

- Ein einzelner Vektor $\mathbf{v}$ ist genau dann unabhängig, wenn $\mathbf{v} \neq \mathbf{0}$. (Denn $1 \cdot \mathbf{0} = \mathbf{0}$ ist nichttrivial.)
- Enthält eine Menge den Nullvektor, so ist sie *immer* abhängig.
- Die leere Menge ist per Konvention linear unabhängig – die Bedingung ist leer erfüllt.
- Zwei Vektoren sind genau dann abhängig, wenn einer ein Vielfaches des anderen ist.

Aufgabe 4.1. Prüfen Sie, ob die Vektoren

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 5 \\ 7 \end{pmatrix}, \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

linear unabhängig sind.

Lösung Schritt für Schritt.

Schritt 1 – Ansatz. Wir setzen an

$$\lambda_1 \mathbf{v}_1 + \lambda_2 \mathbf{v}_2 + \lambda_3 \mathbf{v}_3 = \mathbf{0}$$

und schreiben das komponentenweise:

$$\begin{array}{rcrcrcl} \lambda_1 & + & 2\lambda_2 & & & = & 0 \\ 2\lambda_1 & + & 5\lambda_2 & + & \lambda_3 & = & 0 \\ 3\lambda_1 & + & 7\lambda_2 & + & \lambda_3 & = & 0 \end{array}$$

Schritt 2 – Gauß. Die Koeffizientenmatrix hat die Vektoren als *Spalten*:

$$\begin{pmatrix} 1 & 2 & 0 \\ 2 & 5 & 1 \\ 3 & 7 & 1 \end{pmatrix} \xrightarrow[Z_3 - 3Z_1]{Z_2 - 2Z_1} \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix} \xrightarrow{Z_3 - Z_2} \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

Nachrechnen: $Z_2 - 2Z_1 = (0, 5-4, 1-0) = (0,1,1)$; $Z_3 - 3Z_1 = (0, 7-6, 1-0) = (0,1,1)$. ✓

Schritt 3 – Auswerten. Der Rang ist 2, es gibt drei Unbekannte – also eine freie Variable. Das homogene System hat nichttriviale Lösungen. **Die Vektoren sind linear abhängig.**

Schritt 4 – Die Abhängigkeit explizit finden. Setze $\lambda_3 =: t$. Aus Zeile 2: $\lambda_2 + t = 0$, also $\lambda_2 = -t$. Aus Zeile 1: $\lambda_1 + 2(-t) = 0$, also $\lambda_1 = 2t$.
Mit $t = 1$:

$$2\mathbf{v}_1 - \mathbf{v}_2 + \mathbf{v}_3 = \mathbf{0}.$$

Probe:

$$2\begin{pmatrix}1\\2\\3\end{pmatrix} - \begin{pmatrix}2\\5\\7\end{pmatrix} + \begin{pmatrix}0\\1\\1\end{pmatrix} = \begin{pmatrix}2-2+0\\4-5+1\\6-7+1\end{pmatrix} = \begin{pmatrix}0\\0\\0\end{pmatrix}. \checkmark$$

Umgeformt: $\mathbf{v}_2 = 2\mathbf{v}_1 + \mathbf{v}_3$ – der zweite Vektor ist überflüssig.

Das Kochrezept

Um k Vektoren aus $\mathbb{K}^n$ auf Unabhängigkeit zu prüfen:

1. Schreibe sie als Spalten einer Matrix A.
2. Bringe A auf Zeilenstufenform.
3. Unabhängig $\iff$ Rang $A = k \iff$ jede Spalte enthält ein Pivot.

Sofortige Konsequenz: Mehr als n Vektoren im $\mathbb{K}^n$ sind immer abhängig, denn der Rang kann höchstens n sein (es gibt nur n Zeilen).

4.2 Basis

Definition 4.3. Eine Familie $B = (\mathbf{b}_1, \ldots, \mathbf{b}_n)$ heißt **Basis** von V, wenn sie

(i) ein Erzeugendensystem von V ist und
(ii) linear unabhängig ist.

Satz 4.4 (Die Kernaussage über Basen). *$B = (\mathbf{b}_1, \ldots, \mathbf{b}_n)$ ist genau dann eine Basis von V, wenn sich* jeder *Vektor $\mathbf{v} \in V$ auf* genau eine *Weise als*

$$\mathbf{v} = \lambda_1\mathbf{b}_1 + \cdots + \lambda_n\mathbf{b}_n$$

schreiben lässt.

Beweis. „⇒“: Die Existenz der Darstellung ist die Erzeugendeneigenschaft. Zur Eindeutigkeit: Seien

$$\sum \lambda_i\mathbf{b}_i = \mathbf{v} = \sum \mu_i\mathbf{b}_i.$$

Subtraktion liefert

$$\sum(\lambda_i - \mu_i)\mathbf{b}_i = \mathbf{0}.$$

Aus der linearen Unabhängigkeit folgt $\lambda_i - \mu_i = 0$ für alle i, also $\lambda_i = \mu_i$.

„⇐“: Existenz für alle $\mathbf{v}$ ist die Erzeugendeneigenschaft. Für die Unabhängigkeit betrachte $\mathbf{v} = \mathbf{0}$: Dieser hat einerseits die Darstellung mit allen $\lambda_i = 0$. Nach Voraussetzung ist die Darstellung eindeutig, also ist das die einzige. ■

Warum das der wichtigste Satz des Kapitels ist

Eine Basis erlaubt es, *jeden* Vektor durch ein Zahlentupel zu ersetzen – eindeutig und rückgängig machbar. Das Tupel $(\lambda_1, \dots, \lambda_n)$ heißt **Koordinatenvektor** von $\mathbf{v}$ bezüglich B, geschrieben $\mathbf{v}_B$.
Damit wird jeder n-dimensionale Vektorraum zu $\mathbb{K}^n$. Polynome, Matrizen, Funktionen – alles wird zu Zahlentupeln, sobald man eine Basis gewählt hat. Das ist der Grund, warum die lineare Algebra so universell anwendbar ist.
Und der Preis: Die Koordinaten hängen von der Basis ab. Derselbe Vektor hat in verschiedenen Basen verschiedene Koordinaten. Der Umgang mit diesem Wechsel ist Thema von Kapitel 5.

Beispiel 4.5 (Wichtige Basen).
- $\mathbb{K}^n$: die **Standardbasis** $\mathbf{e}_1 = (1, 0, \dots, 0)$, $\mathbf{e}_2 = (0, 1, 0, \dots, 0)$, $\dots$, $\mathbf{e}_n$.
- $\mathbb{K}[x]_{\leq n}$: die Monombasis $1, x, x^2, \dots, x^n$. Dimension $n + 1$.
- $\mathbb{K}^{m \times n}$: die Matrizen E_{ij} mit einer 1 an Position (i, j) und sonst Nullen. Dimension mn.
- $\mathbb{C}$ als $\mathbb{R}$-Vektorraum: $\{1, i\}$. Dimension 2. Als $\mathbb{C}$-Vektorraum: $\{1\}$, Dimension 1.

Der letzte Punkt zeigt: Die Dimension hängt vom Grundkörper ab.

4.3 Der Steinitzsche Austauschsatz

Jetzt kommt das technische Herzstück. Alles, was folgt – die Wohldefiniertheit der Dimension, die Basisergänzung, der Rangsatz – hängt an diesem einen Lemma.

Lemma 4.6 (Austauschlemma). *Sei $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ eine Basis von V und*

$$\mathbf{w} = \sum_{i=1}^{n} \lambda_i \mathbf{b}_i$$

ein Vektor mit $\lambda_j \neq 0$ für ein bestimmtes j. Dann ist auch

$$B' = (\mathbf{b}_1, \dots, \mathbf{b}_{j-1}, \mathbf{w}, \mathbf{b}_{j+1}, \dots, \mathbf{b}_n)$$

eine Basis von V.

Beweis. **Teil 1: B' erzeugt V.** Da $\lambda_j \neq 0$, können wir nach $\mathbf{b}_j$ auflösen:

$$\mathbf{b}_j = \frac{1}{\lambda_j} \left(\mathbf{w} - \sum_{i \neq j} \lambda_i \mathbf{b}_i \right). \tag{$*$}$$

Sei nun $\mathbf{v} \in V$ beliebig. Da B eine Basis ist, gilt $\mathbf{v} = \sum_i \mu_i \mathbf{b}_i$. Ersetzen wir darin $\mathbf{b}_j$ durch $(*)$, so erhalten wir eine Darstellung von $\mathbf{v}$ durch $\mathbf{w}$ und die $\mathbf{b}_i$ mit $i \neq j$ – also durch die Vektoren aus B'.

Teil 2: B' ist unabhängig. Sei

$$\mu\mathbf{w} + \sum_{i\neq j} \mu_i \mathbf{b}_i = \mathbf{0}.$$

Wir setzen die Darstellung von $\mathbf{w}$ ein:

$$\mu \sum_{i=1}^{n} \lambda_i \mathbf{b}_i + \sum_{i\neq j} \mu_i \mathbf{b}_i = \mathbf{0}.$$

Nun sortieren wir nach den Basisvektoren. Der Koeffizient von $\mathbf{b}_j$ ist $\mu\lambda_j$ (der zweite Summand enthält $\mathbf{b}_j$ nicht); der Koeffizient von $\mathbf{b}_i$ für $i \neq j$ ist $\mu\lambda_i + \mu_i$:

$$(\mu\lambda_j)\,\mathbf{b}_j + \sum_{i\neq j} (\mu\lambda_i + \mu_i)\,\mathbf{b}_i = \mathbf{0}.$$

Da B unabhängig ist, verschwinden alle Koeffizienten. Insbesondere

$$\mu\lambda_j = 0.$$

Wegen $\lambda_j \neq 0$ folgt $\mu = 0$. Setzt man das in die übrigen Gleichungen ein, so bleibt $0 \cdot \lambda_i + \mu_i = 0$, also $\mu_i = 0$ für alle $i \neq j$.

Alle Koeffizienten sind null – B' ist unabhängig. ■

Satz 4.7 (Steinitzscher Austauschsatz). *Sei $B = (\mathbf{b}_1, \ldots, \mathbf{b}_n)$ eine Basis von V und $(\mathbf{w}_1, \ldots, \mathbf{w}_r)$ linear unabhängig. Dann gilt $r \leq n$, und man kann r der Basisvektoren so durch die $\mathbf{w}_i$ ersetzen, dass wieder eine Basis entsteht.*

Beweis. Induktion über r.

Anfang $r = 0$**.** Nichts zu tun.

Schritt. Die Behauptung gelte für $r-1$. Nach Umnummerierung dürfen wir annehmen, dass

$$B_{r-1} = (\mathbf{w}_1, \ldots, \mathbf{w}_{r-1},\ \mathbf{b}_r, \ldots, \mathbf{b}_n)$$

eine Basis ist (und $r - 1 \leq n$).

Wir stellen $\mathbf{w}_r$ in dieser Basis dar:

$$\mathbf{w}_r = \sum_{i=1}^{r-1} \alpha_i \mathbf{w}_i + \sum_{j=r}^{n} \beta_j \mathbf{b}_j. \qquad (**)$$

Behauptung: Nicht alle β_j sind null. Wären sie es, so wäre $\mathbf{w}_r$ eine Linearkombination von $\mathbf{w}_1, \ldots, \mathbf{w}_{r-1}$ – im Widerspruch zur linearen Unabhängigkeit der $\mathbf{w}_i$ (Satz 4.2).

Insbesondere folgt daraus $r - 1 < n$, also $r \leq n$: Wäre nämlich $r - 1 = n$, so gäbe es in $(**)$ gar keine β_j mehr, und wir hätten einen Widerspruch.

Sei also $\beta_{j_0} \neq 0$ für ein $j_0 \geq r$. Nach dem Austauschlemma dürfen wir in B_{r-1} den Vektor $\mathbf{b}_{j_0}$ durch $\mathbf{w}_r$ ersetzen und erhalten wieder eine Basis. Nach Umnummerierung ist das

$$B_r = (\mathbf{w}_1, \ldots, \mathbf{w}_r,\ \mathbf{b}_{r+1}, \ldots, \mathbf{b}_n).$$ ■

Korollar 4.8 (Wohldefiniertheit der Dimension)**.** *Je zwei Basen eines Vektorraums haben gleich viele Elemente.*

Beweis. Seien B mit n und C mit m Elementen zwei Basen.
C ist unabhängig, B ist Basis: Nach Steinitz folgt $m \leq n$.
B ist unabhängig, C ist Basis: Nach Steinitz folgt $n \leq m$.
Also $n = m$. ■

Definition 4.9. Die gemeinsame Elementanzahl aller Basen heißt **Dimension** von V, geschrieben $\dim V$. Existiert keine endliche Basis, so setzt man $\dim V = \infty$.

> **Warum dieses Korollar so wichtig ist**
>
> Ohne es wäre der Begriff „Dimension“ sinnlos. Man könnte nicht von „dem“ dreidimensionalen Raum sprechen, weil verschiedene Basen verschiedene Zahlen liefern könnten.
> Dass das nicht passiert, ist keine Selbstverständlichkeit – es ist der Inhalt des Austauschsatzes. ERNST STEINITZ publizierte ihn 1913 im Rahmen seiner Arbeiten zur Körpertheorie; HERMANN GRASSMANN hatte den Kern bereits 1844 in seiner *Ausdehnungslehre*[14], einem Werk, das seiner Zeit so weit voraus war, dass es praktisch niemand las.

4.4 Basisergänzung und Konsequenzen

Satz 4.10 (Basisergänzungssatz)**.** *Sei V endlichdimensional und $(\mathbf{w}_1, \dots, \mathbf{w}_r)$ linear unabhängig. Dann lässt sich diese Familie zu einer Basis von V ergänzen.*

Beweis. Sei $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ eine Basis. Nach Steinitz ist

$$(\mathbf{w}_1, \dots, \mathbf{w}_r,\ \mathbf{b}_{r+1}, \dots, \mathbf{b}_n)$$

(nach geeigneter Umnummerierung) eine Basis. Die hinzugefügten Vektoren sind $\mathbf{b}_{r+1}, \dots, \mathbf{b}_n$. ■

Satz 4.11 (Auswahlsatz)**.** *Aus jedem endlichen Erzeugendensystem lässt sich eine Basis auswählen.*

Beweis. Sei $(\mathbf{v}_1, \dots, \mathbf{v}_k)$ ein Erzeugendensystem. Ist es unabhängig, sind wir fertig. Andernfalls gibt es nach Satz 4.2 ein $\mathbf{v}_j$, das Linearkombination der übrigen ist. Dann erzeugen die übrigen bereits alles: Jede Linearkombination, in der $\mathbf{v}_j$ vorkommt, kann man umschreiben.

Man streicht $\mathbf{v}_j$ und wiederholt. Da die Anzahl in jedem Schritt echt sinkt, endet das Verfahren nach endlich vielen Schritten – bei einer unabhängigen Familie, die immer noch erzeugt, also einer Basis. ■

Satz 4.12 (Dimensionskriterien)**.** *Sei* $\dim V = n$ *und* $(\mathbf{v}_1, \dots, \mathbf{v}_n)$ *eine Familie mit* genau n *Vektoren. Dann sind äquivalent:*

(i) Die Familie ist eine Basis.

(ii) Sie ist linear unabhängig.

(iii) Sie ist ein Erzeugendensystem.

Beweis. **(ii) $\Longrightarrow$ (i).** Nach dem Basisergänzungssatz lässt sich die unabhängige Familie zu einer Basis ergänzen. Diese hat n Elemente (Korollar 4.8). Da wir schon n haben, wird nichts ergänzt – die Familie ist selbst schon Basis.

(iii) $\Longrightarrow$ (i). Nach dem Auswahlsatz enthält das Erzeugendensystem eine Basis; diese hat n Elemente. Da das System selbst nur n Elemente hat, wird nichts gestrichen.

(i) $\Longrightarrow$ (ii), (iii). Per Definition. ■

> **Warum das praktisch enorm hilft**
>
> Normalerweise muss man für eine Basis *zwei* Dinge prüfen. Kennt man die Dimension und hat genau so viele Vektoren, genügt *eine* Prüfung – und man nimmt natürlich die einfachere. Lineare Unabhängigkeit ist meist leichter zu zeigen als die Erzeugendeneigenschaft.

Satz 4.13 (Dimensionsformel für Unterräume). *Für Untervektorräume U, W eines endlichdimensionalen Raums gilt*

$$\dim(U+W) + \dim(U \cap W) = \dim U + \dim W.$$

Beweis. Sei $(\mathbf{d}_1, \ldots, \mathbf{d}_k)$ eine Basis von $U \cap W$, also $k = \dim(U \cap W)$.

Nach dem Basisergänzungssatz (angewandt in U bzw. in W) ergänzen wir:

$$\text{Basis von } U: \ (\mathbf{d}_1, \ldots, \mathbf{d}_k, \ \mathbf{u}_1, \ldots, \mathbf{u}_p), \qquad \dim U = k + p,$$

$$\text{Basis von } W: \ (\mathbf{d}_1, \ldots, \mathbf{d}_k, \ \mathbf{w}_1, \ldots, \mathbf{w}_q), \qquad \dim W = k + q.$$

Behauptung: $(\mathbf{d}_1, \ldots, \mathbf{d}_k, \mathbf{u}_1, \ldots, \mathbf{u}_p, \mathbf{w}_1, \ldots, \mathbf{w}_q)$ ist eine Basis von $U + W$.

Erzeugendensystem: Jedes Element von $U + W$ ist Summe eines Elements aus U und eines aus W; beide sind Linearkombinationen der jeweiligen Basis, also der Gesamtfamilie.

Unabhängigkeit: Sei

$$\sum_i \alpha_i \mathbf{d}_i + \sum_j \beta_j \mathbf{u}_j + \sum_l \gamma_l \mathbf{w}_l = \mathbf{0}.$$

Wir setzen

$$\mathbf{x} := \sum_l \gamma_l \mathbf{w}_l = -\sum_i \alpha_i \mathbf{d}_i - \sum_j \beta_j \mathbf{u}_j.$$

Die linke Darstellung zeigt $\mathbf{x} \in W$; die rechte zeigt $\mathbf{x} \in U$. Also $\mathbf{x} \in U \cap W$, und damit ist $\mathbf{x}$ Linearkombination der $\mathbf{d}_i$:

$$\mathbf{x} = \sum_i \delta_i \mathbf{d}_i.$$

Zusammen mit $\mathbf{x} = \sum_l \gamma_l \mathbf{w}_l$ ergibt sich

$$\sum_i \delta_i \mathbf{d}_i - \sum_l \gamma_l \mathbf{w}_l = \mathbf{0}.$$

Das ist eine Relation zwischen den Vektoren der Basis von W – die sind unabhängig, also sind alle δ_i und alle γ_l null.

Mit $\gamma_l = 0$ reduziert sich die Ausgangsgleichung auf

$$\sum_i \alpha_i \mathbf{d}_i + \sum_j \beta_j \mathbf{u}_j = \mathbf{0},$$

und das ist eine Relation in der Basis von U – also sind auch alle α_i, β_j null.

Abzählen. Die Basis von $U + W$ hat $k + p + q$ Elemente. Also

$$\dim(U + W) + \dim(U \cap W) = (k + p + q) + k = (k + p) + (k + q) = \dim U + \dim W.$$

■

Aufgabe 4.2. Im $\mathbb{R}^4$ seien

$$U = \operatorname{span}\left(\begin{pmatrix}1\\0\\1\\0\end{pmatrix}, \begin{pmatrix}0\\1\\0\\1\end{pmatrix}\right), \qquad W = \operatorname{span}\left(\begin{pmatrix}1\\1\\1\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\1\end{pmatrix}\right).$$

Bestimmen Sie $\dim U$, $\dim W$, $\dim(U + W)$ und $\dim(U \cap W)$.

Lösung Schritt für Schritt.

Schritt 1 – $\dim U$**.** Die beiden Erzeuger sind keine Vielfachen voneinander (der erste hat eine 0 an zweiter Stelle, der zweite eine 1), also unabhängig: $\dim U = 2$.

Schritt 2 – $\dim W$**.** Ebenso: $(1,1,1,1)$ und $(1,0,0,1)$ sind keine Vielfachen. $\dim W = 2$.

Schritt 3 – $\dim(U + W)$**.** Der Raum $U + W$ wird von allen vier Vektoren erzeugt. Wir bestimmen den Rang. Vektoren als *Zeilen* (das ist bequemer, weil Zeilenumformungen den Zeilenraum nicht ändern):

$$\begin{pmatrix}1&0&1&0\\0&1&0&1\\1&1&1&1\\1&0&0&1\end{pmatrix}$$

$Z_3 - Z_1$: $(0,1,0,1)$. $\quad Z_4 - Z_1$: $(0,0,-1,1)$.

$$\begin{pmatrix}1&0&1&0\\0&1&0&1\\0&1&0&1\\0&0&-1&1\end{pmatrix} \xrightarrow{Z_3 - Z_2} \begin{pmatrix}1&0&1&0\\0&1&0&1\\0&0&0&0\\0&0&-1&1\end{pmatrix} \xrightarrow{Z_3 \leftrightarrow Z_4} \begin{pmatrix}1&0&1&0\\0&1&0&1\\0&0&-1&1\\0&0&0&0\end{pmatrix}$$

Drei Nichtnullzeilen: $\dim(U + W) = 3$.

Schritt 4 – $\dim(U \cap W)$ **über die Dimensionsformel.**

$$\dim(U \cap W) = \dim U + \dim W - \dim(U + W) = 2 + 2 - 3 = 1.$$

Schritt 5 – Den Durchschnitt explizit bestimmen (zur Kontrolle). Gesucht sind $\mathbf{x}$ mit

$$\mathbf{x} = a\begin{pmatrix}1\\0\\1\\0\end{pmatrix} + b\begin{pmatrix}0\\1\\0\\1\end{pmatrix} = c\begin{pmatrix}1\\1\\1\\1\end{pmatrix} + d\begin{pmatrix}1\\0\\0\\1\end{pmatrix}.$$

Komponentenweise:

$$\begin{aligned} a &= c + d \\ b &= c \\ a &= c \\ b &= c + d \end{aligned}$$

Aus Zeile 2 und 3: $a = c = b$. Aus Zeile 1: $a = c + d = a + d$, also $d = 0$. Zeile 4 ist dann konsistent.
Mit $c = 1$, $d = 0$ erhalten wir $\mathbf{x} = (1,1,1,1)$. Prüfung: In U mit $a = b = 1$? Das ergibt $(1,0,1,0) + (0,1,0,1) = (1,1,1,1)$. ✓ In W offensichtlich. ✓
Also $U \cap W = \operatorname{span}((1,1,1,1))$, Dimension 1. ✓ Stimmt mit der Formel überein.

4.5 Zeilenrang gleich Spaltenrang

Wir schließen die Lücke aus Kapitel 1.

Definition 4.14. Für $A \in \mathbb{K}^{m\times n}$ sei der **Zeilenraum** der Spann der Zeilen (ein Unterraum von $\mathbb{K}^n$) und der **Spaltenraum** der Spann der Spalten (ein Unterraum von $\mathbb{K}^m$).

Satz 4.15 (Rangsatz für Matrizen)**.** *Für jede Matrix gilt*

$$\dim(\textit{Zeilenraum}) = \dim(\textit{Spaltenraum}).$$

*Diese Zahl ist der **Rang** von A und stimmt mit der Anzahl der Pivots in jeder Zeilenstufenform überein.*

Beweis. **Schritt 1 – Zeilenumformungen ändern den Zeilenraum nicht.** Jede neue Zeile ist Linearkombination der alten, also liegt der neue Zeilenraum im alten. Da die Umformungen umkehrbar sind, gilt auch die Umkehrung. Die Räume sind gleich.

Schritt 2 – In Zeilenstufenform ist der Zeilenrang die Pivotzahl. Die Nichtnullzeilen einer ZSF sind unabhängig: Betrachtet man eine Relation $\sum \lambda_i z_i = \mathbf{0}$ und die Spalte des ersten Pivots, so kommt dort nur z_1 mit einem Eintrag $\neq 0$ vor – also $\lambda_1 = 0$. Induktiv folgt $\lambda_2 = 0$, und so fort.

Schritt 3 – Zeilenumformungen ändern die *Abhängigkeitsrelationen* zwischen den Spalten nicht. Das ist der entscheidende Punkt. Eine Relation zwischen Spalten ist eine Gleichung

$$A\mathbf{x} = \mathbf{0}$$

(die Komponenten von $\mathbf{x}$ sind die Koeffizienten). Nach Satz 1.3 ändern Zeilenumformungen die Lösungsmenge dieses Systems nicht. Also gelten für die Spalten der umgeformten Matrix *genau dieselben* Relationen.

Schritt 4 – In ZSF ist der Spaltenrang die Pivotzahl. Die Pivotspalten sind unabhängig (in der reduzierten Form sind sie Einheitsvektoren). Jede Nichtpivotspalte ist Linearkombination der links von ihr stehenden Pivotspalten – das liest man beim Rückwärtseinsetzen ab. Also ist der Spaltenrang gleich der Pivotzahl.

Nach Schritt 3 gilt das auch für die ursprüngliche Matrix. ■

Warum dieser Satz erstaunlich ist

Nehmen Sie eine 3×100-Matrix. Der Zeilenraum lebt in $\mathbb{K}^{100}$, der Spaltenraum in $\mathbb{K}^3$. Es sind Unterräume *völlig verschiedener* Räume. Und trotzdem haben sie dieselbe Dimension – und diese ist höchstens 3.

Anders gesagt: Wenn 100 Spaltenvektoren nur einen dreidimensionalen Raum aufspannen, dann liegt das daran, dass die drei Zeilen ihrerseits nur einen dreidimensionalen Raum aufspannen. Diese Symmetrie ist keineswegs offensichtlich.

Folgerung: $\operatorname{Rang} A = \operatorname{Rang} A^{\mathsf{T}}$ für jede Matrix.

Part III

Lineare Abbildungen

5 Lineare Abbildungen

5.1 Der eigentliche Gegenstand

Bisher haben wir Räume studiert. Jetzt kommen die *Abbildungen* zwischen ihnen – und das ist der eigentliche Gegenstand der linearen Algebra. Ein Vektorraum allein ist ziemlich langweilig; interessant wird es, wenn man ihn bewegt.

Definition 5.1. Seien V, W Vektorräume über $\mathbb{K}$. Eine Abbildung $f : V \to W$ heißt **linear** (oder **Homomorphismus**), wenn für alle $\mathbf{u}, \mathbf{v} \in V$ und $\lambda \in \mathbb{K}$ gilt:

$$\text{(L1)} \quad f(\mathbf{u}+\mathbf{v}) = f(\mathbf{u}) + f(\mathbf{v}), \qquad \text{(L2)} \quad f(\lambda\mathbf{v}) = \lambda f(\mathbf{v}).$$

Was Linearität bedeutet

„Es ist gleichgültig, ob man erst rechnet und dann abbildet, oder erst abbildet und dann rechnet."
Die Abbildung *verträgt* sich mit der Struktur. Solche strukturverträglichen Abbildungen heißen in der ganzen Mathematik **Homomorphismen** – bei Gruppen, Ringen, Körpern, topologischen Räumen. Es ist eines der universellsten Konzepte überhaupt.
Kurzfassung beider Axiome in einem:

$$f(\lambda\mathbf{u} + \mu\mathbf{v}) = \lambda f(\mathbf{u}) + \mu f(\mathbf{v}).$$

Satz 5.2. *Für jede lineare Abbildung gilt* $f(\mathbf{0}) = \mathbf{0}$.

Beweis. $f(\mathbf{0}) = f(0 \cdot \mathbf{0}) \overset{\text{(L2)}}{=} 0 \cdot f(\mathbf{0}) = \mathbf{0}$, wobei am Ende Satz 3.4(b) benutzt wurde. ∎

„Linear" im Alltag heißt etwas anderes

Die Funktion $f(x) = 3x + 5$ heißt in der Schule „lineare Funktion". Sie ist im Sinne dieser Definition *nicht* linear:

$$f(0) = 5 \neq 0.$$

Prüfen wir (L1): $f(1+2) = f(3) = 14$, aber $f(1) + f(2) = 8 + 11 = 19$. Verletzt.
Solche Abbildungen heißen **affin**: $f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$. Sie sind linear plus Verschiebung. Der Unterschied ist genau derselbe wie zwischen homogenen und inhomogenen Gleichungssystemen.

Beispiel 5.3 (Wichtige lineare Abbildungen).

- $f : \mathbb{R}^n \to \mathbb{R}^m$, $\mathbf{x} \mapsto A\mathbf{x}$ für eine feste Matrix A.

- Die Ableitung $D : \mathbb{K}[x] \to \mathbb{K}[x]$, $p \mapsto p'$. Linear, denn $(p+q)' = p' + q'$.
- Das Integral $I : C([0,1]) \to \mathbb{R}$, $f \mapsto \int_0^1 f(t)\,dt$. Linear.
- Drehung der Ebene um den Ursprung um den Winkel φ.
- Die Spur Spur : $\mathbb{K}^{n\times n} \to \mathbb{K}$, $A \mapsto \sum_i a_{ii}$.
- Die Transposition $A \mapsto A^\mathsf{T}$.

Nicht linear sind dagegen: die Determinante ($\det(A+B) \neq \det A + \det B$), die Norm ($\|\lambda\mathbf{v}\| = |\lambda|\,\|\mathbf{v}\|$, nicht $\lambda\|\mathbf{v}\|$), und alles mit Quadraten.

5.2 Der Fortsetzungssatz

Satz 5.4 (Lineare Fortsetzung). *Sei $(\mathbf{b}_1, \ldots, \mathbf{b}_n)$ eine Basis von V und $\mathbf{w}_1, \ldots, \mathbf{w}_n \in W$ beliebige Vektoren. Dann gibt es genau eine lineare Abbildung $f : V \to W$ mit*

$$f(\mathbf{b}_i) = \mathbf{w}_i \qquad \text{für } i = 1, \ldots, n.$$

Beweis. **Eindeutigkeit.** Sei f eine solche Abbildung und $\mathbf{v} \in V$ beliebig. Nach Satz 4.4 gibt es eindeutige λ_i mit $\mathbf{v} = \sum \lambda_i \mathbf{b}_i$. Dann erzwingt die Linearität

$$f(\mathbf{v}) = f\left(\sum \lambda_i \mathbf{b}_i\right) = \sum \lambda_i f(\mathbf{b}_i) = \sum \lambda_i \mathbf{w}_i.$$

Der Wert ist also festgelegt.

Existenz. Wir *definieren* f durch die letzte Formel:

$$f(\mathbf{v}) := \sum_{i=1}^{n} \lambda_i \mathbf{w}_i, \qquad \text{wobei } \mathbf{v} = \sum \lambda_i \mathbf{b}_i.$$

Das ist wohldefiniert, weil die λ_i eindeutig sind – hier geht die Basiseigenschaft entscheidend ein.

Linearität nachprüfen: Seien $\mathbf{v} = \sum \lambda_i \mathbf{b}_i$ und $\mathbf{u} = \sum \mu_i \mathbf{b}_i$. Dann ist $\mathbf{v} + \mathbf{u} = \sum(\lambda_i + \mu_i)\mathbf{b}_i$, und das sind die Koordinaten der Summe. Also

$$f(\mathbf{v}+\mathbf{u}) = \sum(\lambda_i+\mu_i)\mathbf{w}_i = \sum \lambda_i \mathbf{w}_i + \sum \mu_i \mathbf{w}_i = f(\mathbf{v}) + f(\mathbf{u}).$$

Analog für (L2). ∎

> **Die weitreichendste Konsequenz**
>
> *Eine lineare Abbildung ist durch die Bilder einer Basis vollständig bestimmt – und diese Bilder dürfen völlig beliebig gewählt werden.*
>
> Das ist eine ungeheure Reduktion. Statt unendlich viele Werte anzugeben (für jeden Vektor einen), genügen n Werte. Und genau das macht Matrizen möglich: Eine Matrix ist nichts anderes als die Liste der Bilder der Basisvektoren.

5.3 Kern und Bild

Definition 5.5. Für $f : V \to W$ linear sei

$$\operatorname{Kern} f := \{\mathbf{v} \in V : f(\mathbf{v}) = \mathbf{0}\} \subseteq V, \qquad \operatorname{Bild} f := \{f(\mathbf{v}) : \mathbf{v} \in V\} \subseteq W.$$

Satz 5.6. $\operatorname{Kern} f$ *ist ein Untervektorraum von* V, $\operatorname{Bild} f$ *einer von* W.

Beweis. **Kern.** (U1): $f(\mathbf{0}) = \mathbf{0}$, also $\mathbf{0} \in \operatorname{Kern} f$. (U2): Sind $\mathbf{u}, \mathbf{v} \in \operatorname{Kern} f$, so $f(\mathbf{u}+\mathbf{v}) = f(\mathbf{u}) + f(\mathbf{v}) = \mathbf{0}+\mathbf{0} = \mathbf{0}$. (U3): $f(\lambda\mathbf{u}) = \lambda f(\mathbf{u}) = \lambda\mathbf{0} = \mathbf{0}$.

Bild. (U1): $\mathbf{0} = f(\mathbf{0}) \in \operatorname{Bild} f$. (U2): $f(\mathbf{u}) + f(\mathbf{v}) = f(\mathbf{u}+\mathbf{v}) \in \operatorname{Bild} f$. (U3): $\lambda f(\mathbf{u}) = f(\lambda\mathbf{u}) \in \operatorname{Bild} f$. ■

Satz 5.7 (Injektivitätskriterium). *f ist genau dann injektiv, wenn* $\operatorname{Kern} f = \{\mathbf{0}\}$.

Beweis. „⇒“: Sei f injektiv und $\mathbf{v} \in \operatorname{Kern} f$. Dann $f(\mathbf{v}) = \mathbf{0} = f(\mathbf{0})$, also $\mathbf{v} = \mathbf{0}$.

„⇐“: Sei $\operatorname{Kern} f = \{\mathbf{0}\}$ und $f(\mathbf{u}) = f(\mathbf{v})$. Dann

$$f(\mathbf{u}-\mathbf{v}) = f(\mathbf{u}) - f(\mathbf{v}) = \mathbf{0},$$

also $\mathbf{u}-\mathbf{v} \in \operatorname{Kern} f = \{\mathbf{0}\}$, also $\mathbf{u} = \mathbf{v}$. ■

> **Warum das bemerkenswert ist**
>
> Injektivität ist normalerweise eine Aussage über *alle Paare* von Punkten – man müsste unendlich viele Vergleiche anstellen. Bei linearen Abbildungen genügt die Betrachtung *eines einzigen* Punktes: der Null.
> Der Grund ist, dass Linearität die Abbildung überall gleich aussehen lässt. Was am Nullpunkt passiert, passiert überall.

5.4 Der Dimensionssatz

Satz 5.8 (Rangsatz / Dimensionsformel). *Sei $f : V \to W$ linear und* $\dim V < \infty$. *Dann*

$$\dim V = \dim \operatorname{Kern} f + \dim \operatorname{Bild} f.$$

Man nennt $\dim \operatorname{Bild} f$ *den* ***Rang*** *und* $\dim \operatorname{Kern} f$ *den* ***Defekt*** *von f.*

Beweis. Sei $k := \dim \operatorname{Kern} f$ und $(\mathbf{c}_1, \dots, \mathbf{c}_k)$ eine Basis von $\operatorname{Kern} f$.

Nach dem Basisergänzungssatz ergänzen wir zu einer Basis von V:

$$(\mathbf{c}_1, \dots, \mathbf{c}_k, \mathbf{d}_1, \dots, \mathbf{d}_r), \qquad n := \dim V = k + r.$$

Behauptung: $(f(\mathbf{d}_1), \dots, f(\mathbf{d}_r))$ ist eine Basis von $\operatorname{Bild} f$. Dann folgt $\dim \operatorname{Bild} f = r = n - k$, und das ist die Behauptung.

Teil 1: Erzeugendensystem. Sei $\mathbf{w} \in \operatorname{Bild} f$, also $\mathbf{w} = f(\mathbf{v})$ für ein $\mathbf{v} \in V$. Wir schreiben $\mathbf{v}$ in der Basis:

$$\mathbf{v} = \sum_{i=1}^{k} \alpha_i \mathbf{c}_i + \sum_{j=1}^{r} \beta_j \mathbf{d}_j.$$

Anwenden von f:

$$\mathbf{w} = f(\mathbf{v}) = \sum_i \alpha_i \underbrace{f(\mathbf{c}_i)}_{=\mathbf{0}} + \sum_j \beta_j f(\mathbf{d}_j) = \sum_j \beta_j f(\mathbf{d}_j).$$

(Die $\mathbf{c}_i$ liegen im Kern, deshalb verschwinden ihre Bilder.) Also ist $\mathbf{w}$ Linearkombination der $f(\mathbf{d}_j)$.

Teil 2: Unabhängigkeit. Sei

$$\sum_{j=1}^{r} \gamma_j f(\mathbf{d}_j) = \mathbf{0}.$$

Wegen der Linearität ist das

$$f\left(\sum_j \gamma_j \mathbf{d}_j\right) = \mathbf{0}, \qquad \text{also} \qquad \sum_j \gamma_j \mathbf{d}_j \in \operatorname{Kern} f.$$

Als Element des Kerns lässt sich das durch die Kernbasis darstellen:

$$\sum_j \gamma_j \mathbf{d}_j = \sum_i \delta_i \mathbf{c}_i.$$

Umstellen:

$$\sum_j \gamma_j \mathbf{d}_j - \sum_i \delta_i \mathbf{c}_i = \mathbf{0}.$$

Das ist eine Relation zwischen den Vektoren der *Basis von V*. Diese sind unabhängig, also sind alle Koeffizienten null – insbesondere alle γ_j. ■

Was der Satz anschaulich sagt

„Was die Abbildung an Dimension zerstört, fehlt im Bild."
Bildet $f : \mathbb{R}^3 \to \mathbb{R}^3$ auf eine Ebene ab (Rang 2), so muss der Kern eindimensional sein – eine ganze Gerade wird auf die Null gedrückt. Das ist die *Buchhaltung der Dimensionen*, und sie geht immer auf.
Für ein LGS: Kern A ist die Lösungsmenge des homogenen Systems, Bild A der Spaltenraum. Der Rangsatz wird zu

$$n = \dim\{\text{homogene Lösungen}\} + \operatorname{Rang} A,$$

also genau der Aussage von Satz 1.6(b), die wir dort nur behauptet hatten.

Korollar 5.9. *Sei $\dim V = \dim W < \infty$ und $f : V \to W$ linear. Dann sind äquivalent: f injektiv, f surjektiv, f bijektiv.*

Beweis. Sei $n = \dim V = \dim W$.

f injektiv $\iff \dim \operatorname{Kern} f = 0 \iff \dim \operatorname{Bild} f = n$ (Rangsatz) $\iff \operatorname{Bild} f = W$ (denn ein n-dimensionaler Unterraum eines n-dimensionalen Raums ist der ganze Raum) $\iff f$ surjektiv. ■

Die Endlichkeit ist wesentlich

Im unendlichdimensionalen Fall bricht das zusammen. Betrachten Sie den **Shift-Operator** auf dem Raum der Folgen:

$$S(a_1, a_2, a_3, \dots) := (0, a_1, a_2, \dots).$$

S ist injektiv (nichts geht verloren), aber nicht surjektiv (Folgen mit $a_1 \neq 0$ werden nicht getroffen).
Der Rückwärtsshift $T(a_1, a_2, \dots) := (a_2, a_3, \dots)$ ist surjektiv, aber nicht injektiv.
Diese Asymmetrie ist der Ausgangspunkt der Funktionalanalysis und der Fredholm-Theorie.

Aufgabe 5.1. Sei $f : \mathbb{R}^4 \to \mathbb{R}^3$ gegeben durch $f(\mathbf{x}) = A\mathbf{x}$ mit

$$A = \begin{pmatrix} 1 & 2 & 0 & 1 \\ 2 & 4 & 1 & 3 \\ 1 & 2 & 1 & 2 \end{pmatrix}.$$

Bestimmen Sie Basen von Kern f und Bild f und verifizieren Sie den Rangsatz.

Lösung Schritt für Schritt.

Schritt 1 – Zeilenstufenform.

$$A \xrightarrow[Z_3 - Z_1]{Z_2 - 2Z_1} \begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{pmatrix} \xrightarrow{Z_3 - Z_2} \begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Nachrechnen: $Z_2 - 2Z_1 = (0, 4-4, 1-0, 3-2) = (0, 0, 1, 1)$. ✓ $Z_3 - Z_1 = (0, 0, 1, 1)$. ✓
Schritt 2 – Rang ablesen. Zwei Nichtnullzeilen, also $\operatorname{Rang} A = 2$, das heißt $\dim \operatorname{Bild} f = 2$.
Pivots stehen in Spalte 1 und Spalte 3.
Schritt 3 – Basis des Bildes. Das Bild ist der Spaltenraum. Eine Basis bilden die *Pivotspalten der ursprünglichen Matrix* (nicht der umgeformten!):

$$\operatorname{Bild} f = \operatorname{span}\left(\begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \right).$$

Warum die ursprünglichen Spalten? Zeilenumformungen erhalten die Abhängigkeitsrelationen zwischen den Spalten, verändern aber die Spalten selbst. Welche Spalten unabhängig sind, liest man aus der ZSF ab; *welche Vektoren* das sind, muss man in A nachschlagen.
Schritt 4 – Kern bestimmen. Wir lösen $A\mathbf{x} = \mathbf{0}$. Freie Variablen: x_2 und x_4.

Zeile 2: $x_3 + x_4 = 0 \Longrightarrow x_3 = -x_4$.
Zeile 1: $x_1 + 2x_2 + x_4 = 0 \Longrightarrow x_1 = -2x_2 - x_4$.
Mit $x_2 =: s$, $x_4 =: t$:

$$\mathbf{x} = \begin{pmatrix} -2s - t \\ s \\ -t \\ t \end{pmatrix} = s \begin{pmatrix} -2 \\ 1 \\ 0 \\ 0 \end{pmatrix} + t \begin{pmatrix} -1 \\ 0 \\ -1 \\ 1 \end{pmatrix}.$$

$$\operatorname{Kern} f = \operatorname{span}\left(\begin{pmatrix} -2 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ -1 \\ 1 \end{pmatrix} \right), \qquad \dim \operatorname{Kern} f = 2.$$

Schritt 5 – Probe. Wir prüfen den zweiten Kernvektor:

$$A \begin{pmatrix} -1 \\ 0 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1\cdot(-1) + 2\cdot 0 + 0\cdot(-1) + 1\cdot 1 \\ 2(-1) + 4\cdot 0 + 1(-1) + 3\cdot 1 \\ 1(-1) + 2\cdot 0 + 1(-1) + 2\cdot 1 \end{pmatrix} = \begin{pmatrix} -1+1 \\ -2-1+3 \\ -1-1+2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}. \checkmark$$

Schritt 6 – Rangsatz verifizieren.

$$\dim \mathbb{R}^4 = 4, \qquad \dim \operatorname{Kern} f + \dim \operatorname{Bild} f = 2 + 2 = 4. \checkmark$$

Interpretation. Die Abbildung drückt den $\mathbb{R}^4$ auf eine Ebene im $\mathbb{R}^3$. Dabei geht eine zweidimensionale Menge von Richtungen verloren – sie wird auf den Nullpunkt abgebildet.

5.5 Darstellungsmatrizen

Definition 5.10. Sei $f : V \to W$ linear, $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ eine Basis von V und $C = (\mathbf{c}_1, \dots, \mathbf{c}_m)$ eine von W. Schreibt man

$$f(\mathbf{b}_j) = \sum_{i=1}^{m} a_{ij}\, \mathbf{c}_i,$$

so heißt $A = (a_{ij}) \in \mathbb{K}^{m \times n}$ die **Darstellungsmatrix** von f bezüglich B und C, geschrieben $M_C^B(f)$.

> **Die Merkregel, die alles rettet**
>
> *In der j-ten Spalte von A stehen die Koordinaten von $f(\mathbf{b}_j)$ bezüglich C.*
> Bild des ersten Basisvektors → erste Spalte. Bild des zweiten → zweite Spalte. Und so fort.

Die Indexstellung in der Formel $f(\mathbf{b}_j) = \sum_i a_{ij}\mathbf{c}_i$ ist genau so gewählt, dass anschließend gilt:

$$\big(f(\mathbf{v})\big)_C = A \cdot \mathbf{v}_B,$$

also „Koordinaten des Bildes = Matrix mal Koordinaten“. Das ist der ganze Zweck der Konstruktion.

Satz 5.11. *Mit den Bezeichnungen oben gilt für jedes $\mathbf{v} \in V$:*

$$\big(f(\mathbf{v})\big)_C = M_C^B(f) \cdot \mathbf{v}_B.$$

Beweis. Sei $\mathbf{v} = \sum_j \lambda_j \mathbf{b}_j$, also $\mathbf{v}_B = (\lambda_1, \dots, \lambda_n)$. Dann

$$f(\mathbf{v}) = \sum_j \lambda_j f(\mathbf{b}_j) = \sum_j \lambda_j \sum_i a_{ij}\mathbf{c}_i = \sum_i \left(\sum_j a_{ij}\lambda_j \right) \mathbf{c}_i.$$

Die Koordinate von $f(\mathbf{v})$ bezüglich $\mathbf{c}_i$ ist also $\sum_j a_{ij}\lambda_j = (A\mathbf{v}_B)_i$. ∎

Satz 5.12 (Verkettung). *Für $f : V \to W$ und $g : W \to U$ mit Basen B, C, D gilt*

$$M_D^B(g \circ f) = M_D^C(g) \cdot M_C^B(f).$$

Beweis. Für jedes $\mathbf{v}$:

$$\big((g \circ f)(\mathbf{v})\big)_D = \big(g(f(\mathbf{v}))\big)_D = M_D^C(g) \cdot \big(f(\mathbf{v})\big)_C = M_D^C(g)\, M_C^B(f)\, \mathbf{v}_B.$$

Da das für alle $\mathbf{v}$ gilt und eine lineare Abbildung durch ihre Werte eindeutig bestimmt ist, stimmen die Matrizen überein. ∎

Damit ist die eingangs behauptete Rechtfertigung der Matrixmultiplikation vollständig: *Sie ist definiert, damit dieser Satz gilt.*

Aufgabe 5.2. Sei $D : \mathbb{R}[x]_{\le 3} \to \mathbb{R}[x]_{\le 3}$ die Ableitung. Bestimmen Sie die Darstellungsmatrix bezüglich der Monombasis $B = (1, x, x^2, x^3)$.

Lösung Schritt für Schritt.

Schritt 1 – Bilder der Basisvektoren berechnen.

$$D(1) = 0, \qquad D(x) = 1, \qquad D(x^2) = 2x, \qquad D(x^3) = 3x^2.$$

Schritt 2 – Als Koordinatenvektoren schreiben. Die Basis ist $(1, x, x^2, x^3)$, die Koordinaten sind also (a_0, a_1, a_2, a_3) für $a_0 + a_1 x + a_2 x^2 + a_3 x^3$.

$$D(1) = 0 \;\to\; (0,0,0,0)$$

$$D(x) = 1 = 1 \cdot 1 \;\to\; (1,0,0,0)$$

$$D(x^2) = 2x \;\to\; (0,2,0,0)$$

$$D(x^3) = 3x^2 \;\to\; (0,0,3,0)$$

Schritt 3 – Als Spalten anordnen.

$$M_B^B(D) = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 3 \\ 0 & 0 & 0 & 0 \end{pmatrix}.$$

Schritt 4 – Probe an einem Beispiel. Nehmen wir $p(x) = 5 + 2x - x^2 + 4x^3$, also $p_B = (5, 2, -1, 4)$.

$$M \cdot \begin{pmatrix} 5 \\ 2 \\ -1 \\ 4 \end{pmatrix} = \begin{pmatrix} 0\cdot 5 + 1\cdot 2 + 0 + 0 \\ 0 + 0 + 2\cdot(-1) + 0 \\ 0 + 0 + 0 + 3\cdot 4 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ -2 \\ 12 \\ 0 \end{pmatrix}.$$

Das entspricht dem Polynom $2 - 2x + 12x^2$.
Direkt gerechnet: $p'(x) = 2 - 2x + 12x^2$. ✓
Beobachtung. Die Matrix ist *nilpotent*: $M^4 = 0$. Das entspricht der Tatsache, dass die vierte Ableitung jedes Polynoms vom Grad ≤ 3 verschwindet. Nilpotente Matrizen spielen bei der Jordanschen Normalform (Kapitel 8) die Hauptrolle.

5.6 Basiswechsel

Dasselbe f hat in verschiedenen Basen verschiedene Matrizen. Wie hängen sie zusammen?

Definition 5.13. Seien $B = (\mathbf{b}_1, \ldots, \mathbf{b}_n)$ und $B' = (\mathbf{b}'_1, \ldots, \mathbf{b}'_n)$ zwei Basen von V. Die **Basiswechselmatrix** $S = M_B^{B'}(\mathrm{id})$ ist definiert durch

$$\mathbf{b}'_j = \sum_i s_{ij} \mathbf{b}_i,$$

enthält also in Spalte j die Koordinaten des neuen Basisvektors $\mathbf{b}'_j$ *bezüglich der alten Basis*.

Satz 5.14 (Transformationsformel). *Sei $f : V \to V$ linear mit Darstellungsmatrix A bezüglich B und A' bezüglich B'. Dann*

$$A' = S^{-1} A\, S.$$

Beweis. Nach dem Verkettungssatz, angewandt auf $f = \mathrm{id} \circ f \circ \mathrm{id}$:

$$M_{B'}^{B'}(f) = M_{B'}^{B}(\mathrm{id}) \cdot M_B^B(f) \cdot M_B^{B'}(\mathrm{id}) = S^{-1}\, A\, S,$$

wobei $M_{B'}^{B}(\mathrm{id}) = \left(M_B^{B'}(\mathrm{id})\right)^{-1} = S^{-1}$, weil die beiden Basiswechsel invers zueinander sind. ∎

Definition 5.15. Zwei Matrizen A, A' heißen **ähnlich**, wenn es ein invertierbares S gibt mit $A' = S^{-1}AS$.

Das Leitmotiv der zweiten Buchhälfte

Ähnliche Matrizen beschreiben *dieselbe Abbildung* in verschiedenen Koordinaten. Alle Eigenschaften, die von der Basiswahl unabhängig sind – Rang, Determinante, Spur, Eigenwerte, charakteristisches Polynom –, müssen unter Ähnlichkeit invariant sein.
Und daraus ergibt sich die Leitfrage der gesamten Eigenwerttheorie:

Welche Basis macht die Matrix am einfachsten?

Die Antworten heißen *Diagonalisierung* (Kapitel 7), *Jordansche Normalform* (Kapitel 8) und *Singulärwertzerlegung* (Kapitel 11).

Aufgabe 5.3. Sei $f : \mathbb{R}^2 \to \mathbb{R}^2$ die Spiegelung an der Geraden $y = x$. Bestimmen Sie die Darstellungsmatrix bezüglich der Standardbasis E und bezüglich $B' = \left(\binom{1}{1}, \binom{1}{-1}\right)$.

Lösung Schritt für Schritt.

Schritt 1 – Standardbasis. Die Spiegelung an $y = x$ vertauscht die Koordinaten:

$$f\begin{pmatrix}1\\0\end{pmatrix} = \begin{pmatrix}0\\1\end{pmatrix}, \qquad f\begin{pmatrix}0\\1\end{pmatrix} = \begin{pmatrix}1\\0\end{pmatrix}.$$

Also

$$A = M_E^E(f) = \begin{pmatrix}0 & 1\\1 & 0\end{pmatrix}.$$

Schritt 2 – Bilder der neuen Basisvektoren.

$$f\begin{pmatrix}1\\1\end{pmatrix} = \begin{pmatrix}1\\1\end{pmatrix} \qquad \text{(liegt auf der Spiegelachse, bleibt fest)}$$

$$f\begin{pmatrix}1\\-1\end{pmatrix} = \begin{pmatrix}-1\\1\end{pmatrix} = -\begin{pmatrix}1\\-1\end{pmatrix} \qquad \text{(steht senkrecht, wird umgeklappt)}$$

Schritt 3 – Darstellungsmatrix bezüglich B' ablesen. Das erste Bild ist $1 \cdot \mathbf{b}_1' + 0 \cdot \mathbf{b}_2'$, das zweite $0 \cdot \mathbf{b}_1' + (-1)\mathbf{b}_2'$:

$$A' = \begin{pmatrix}1 & 0\\0 & -1\end{pmatrix}.$$

Schritt 4 – Über die Transformationsformel kontrollieren. Die Basiswechselmatrix enthält die neuen Basisvektoren als Spalten (in Standardkoordinaten):

$$S = \begin{pmatrix}1 & 1\\1 & -1\end{pmatrix}.$$

Inverse nach Satz 2.9: $\det S = 1 \cdot (-1) - 1 \cdot 1 = -2$, also

$$S^{-1} = \frac{1}{-2}\begin{pmatrix} -1 & -1 \\ -1 & 1 \end{pmatrix} = \frac{1}{2}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Nun rechnen wir $S^{-1}AS$. Zuerst AS:

$$AS = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}.$$

(Zeile 1 von A ist $(0,1)$; mal Spalte 1 von S, also $\binom{1}{1}$: $0+1=1$. Mal Spalte 2, also $\binom{1}{-1}$: $0+(-1)=-1$. Zeile 2 ist $(1,0)$: liefert 1 und 1.)
Dann

$$S^{-1}(AS) = \frac{1}{2}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}\begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix} = \frac{1}{2}\begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}. \checkmark$$

Was hier eigentlich passiert. In der Standardbasis sieht die Spiegelung nach „Vertauschen“ aus; man erkennt nicht, was sie tut. In der angepassten Basis wird sie zu einer Diagonalmatrix, und man liest sofort ab: eine Richtung bleibt fest $(+1)$, die dazu senkrechte wird umgekehrt (-1).
Die richtige Basis macht die Abbildung durchsichtig. $\mathbf{b}'_1$ und $\mathbf{b}'_2$ sind genau die *Eigenvektoren* von f – das Thema von Kapitel 7.

5.7 Isomorphismen

Definition 5.16. Eine bijektive lineare Abbildung heißt **Isomorphismus**. Existiert einer zwischen V und W, so heißen die Räume **isomorph**, $V \cong W$.

Satz 5.17 (Klassifikationssatz). *Zwei endlichdimensionale $\mathbb{K}$-Vektorräume sind genau dann isomorph, wenn sie dieselbe Dimension haben. Insbesondere gilt*

$$\dim V = n \quad \Longrightarrow \quad V \cong \mathbb{K}^n.$$

Beweis. „$\Leftarrow$“: Seien $\dim V = \dim W = n$ mit Basen $(\mathbf{b}_i)$ und $(\mathbf{c}_i)$. Nach dem Fortsetzungssatz gibt es eine lineare Abbildung f mit $f(\mathbf{b}_i) = \mathbf{c}_i$. Sie ist surjektiv (das Bild enthält eine Basis von W), nach Korollar 5.9 also bijektiv.

„$\Rightarrow$“: Sei $f : V \to W$ ein Isomorphismus. Ist $(\mathbf{b}_i)$ eine Basis von V, so ist $(f(\mathbf{b}_i))$ eine Basis von W: Erzeugend wegen Surjektivität; unabhängig, weil aus $\sum \lambda_i f(\mathbf{b}_i) = \mathbf{0}$ folgt $f(\sum \lambda_i \mathbf{b}_i) = \mathbf{0}$, also wegen Injektivität $\sum \lambda_i \mathbf{b}_i = \mathbf{0}$, also $\lambda_i = 0$. ∎

Der ernüchternde und der befreiende Aspekt

Ernüchternd: Es gibt, bis auf Isomorphie, für jede Dimension *genau einen* Vektorraum. Der Raum der Polynome vom Grad ≤ 3, der Raum der 2×2-Matrizen und $\mathbb{R}^4$ sind alle „derselbe“ Raum. Die Klassifikation ist trivial: eine Zahl.
Befreiend: Man darf immer im $\mathbb{K}^n$ rechnen. Jedes endlichdimensionale Problem lässt sich nach Basiswahl in Zahlentupel übersetzen.
Der Haken: Der Isomorphismus ist *nicht kanonisch* – er hängt von der Basiswahl ab. Es gibt keinen ausgezeichneten Isomorphismus $V \to \mathbb{K}^n$. Das klingt pedantisch, ist aber der Grund, warum in der Differentialgeometrie und der Physik so großer Wert auf koordinatenfreie Formulierungen gelegt wird: Eine physikalische Aussage darf nicht vom gewählten Koordinatensystem abhängen.
Eine bemerkenswerte Ausnahme: Der *Bidualraum* V^{**} ist kanonisch isomorph zu V, der Dualraum V^* dagegen nur nach Basiswahl. Das ist kein Zufall, sondern ein Satz der Kategorientheorie.

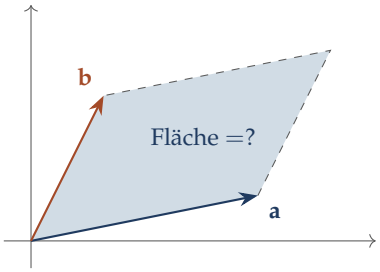
Part IV

Determinanten

6 Die Determinante

6.1 Die Frage nach dem Volumen

Nehmen wir zwei Vektoren $\mathbf{a}, \mathbf{b}$ in der Ebene. Sie spannen ein Parallelogramm auf. Wie groß ist dessen Fläche?



Statt die Fläche auszurechnen, fragen wir, welche *Eigenschaften* eine Flächenfunktion $F(\mathbf{a}, \mathbf{b})$ haben muss.

Die drei Forderungen

(D1) Linearität in jedem Argument. Verdoppelt man $\mathbf{a}$, so verdoppelt sich die Fläche:

$$F(\lambda \mathbf{a}, \mathbf{b}) = \lambda F(\mathbf{a}, \mathbf{b}), \qquad F(\mathbf{a} + \mathbf{a}', \mathbf{b}) = F(\mathbf{a}, \mathbf{b}) + F(\mathbf{a}', \mathbf{b}),$$

und ebenso im zweiten Argument. Man nennt das **Multilinearität**.

(D2) Entartung. Sind die Vektoren gleich (oder allgemeiner: linear abhängig), so ist das Parallelogramm platt:

$$F(\mathbf{a}, \mathbf{a}) = 0.$$

Man nennt das **alternierend**.

(D3) Normierung. Das Einheitsquadrat hat Fläche 1:

$$F(\mathbf{e}_1, \mathbf{e}_2) = 1.$$

Warum Additivität für Flächen plausibel ist

(D1) sieht auf den ersten Blick falsch aus – Flächen addieren sich doch nicht so einfach? Doch, hier schon: Legt man zwei Parallelogramme mit gemeinsamer Seite $\mathbf{b}$ aneinander, indem man die Grundseiten $\mathbf{a}$ und $\mathbf{a}'$ addiert, so entsteht ein Parallelogramm mit Grundseite $\mathbf{a} + \mathbf{a}'$, und die Flächen addieren sich (Scherung erhält den Flächeninhalt – das ist der Satz des Cavalieri).

Und die Folgerung (D2) ist offensichtlich: Zwei gleiche Vektoren spannen kein Parallelogramm auf, sondern eine Strecke.
Ein Preis ist zu zahlen: Aus (D1) und (D2) folgt, dass F auch negative Werte annimmt (siehe Satz 6.1). Es handelt sich also um ein *orientiertes* Volumen – das Vorzeichen kodiert den Umlaufsinn.

Satz 6.1 (Antisymmetrie). *Aus (D1) und (D2) folgt*

$$F(\mathbf{b},\mathbf{a}) = -F(\mathbf{a},\mathbf{b}).$$

Beweis. Wir werten F auf zwei gleichen Argumenten aus und multiplizieren aus:

$$0 \overset{(D2)}{=} F(\mathbf{a}+\mathbf{b},\ \mathbf{a}+\mathbf{b}) \overset{(D1)}{=} \underbrace{F(\mathbf{a},\mathbf{a})}_{=0} + F(\mathbf{a},\mathbf{b}) + F(\mathbf{b},\mathbf{a}) + \underbrace{F(\mathbf{b},\mathbf{b})}_{=0}.$$

Also $F(\mathbf{a},\mathbf{b}) + F(\mathbf{b},\mathbf{a}) = 0$. ∎

Satz 6.2 (Die Formel für $n = 2$). *Die einzige Funktion mit (D1)–(D3) ist*

$$F\left(\begin{pmatrix}a_1\\a_2\end{pmatrix},\begin{pmatrix}b_1\\b_2\end{pmatrix}\right) = a_1b_2 - a_2b_1.$$

Beweis. Wir zerlegen beide Vektoren in die Standardbasis und multiplizieren mit (D1) aus:

$$\begin{aligned} F(\mathbf{a},\mathbf{b}) &= F(a_1\mathbf{e}_1 + a_2\mathbf{e}_2,\ b_1\mathbf{e}_1 + b_2\mathbf{e}_2) \\ &= a_1b_1\underbrace{F(\mathbf{e}_1,\mathbf{e}_1)}_{=0} + a_1b_2\underbrace{F(\mathbf{e}_1,\mathbf{e}_2)}_{=1} + a_2b_1\underbrace{F(\mathbf{e}_2,\mathbf{e}_1)}_{=-1} + a_2b_2\underbrace{F(\mathbf{e}_2,\mathbf{e}_2)}_{=0} \\ &= a_1b_2 - a_2b_1. \end{aligned}$$

∎

Das ist der Kern der ganzen Determinantentheorie
Man rechnet nicht die Fläche aus. Man schreibt hin, welche *Eigenschaften* sie hat, und stellt fest, dass diese Eigenschaften sie bereits *eindeutig festlegen*. Die Formel ist eine Folge, keine Definition.
Genau dieses Verfahren skalieren wir jetzt auf n Dimensionen.

6.2 Permutationen

Für n Dimensionen brauchen wir ein Hilfsmittel.

Definition 6.3. Eine **Permutation** von $\{1,\dots,n\}$ ist eine bijektive Abbildung $\sigma : \{1,\dots,n\} \to \{1,\dots,n\}$. Die Menge aller solchen heißt S_n und hat $n!$ Elemente.
Eine **Transposition** ist eine Permutation, die genau zwei Elemente vertauscht.

Satz 6.4 (Signum). *Jede Permutation lässt sich als Produkt von Transpositionen schreiben. Die* Parität *der Anzahl ist dabei eindeutig bestimmt. Man setzt*

$$\operatorname{sgn}(\sigma) := (-1)^{\#\text{Transpositionen}} \in \{+1, -1\}.$$

Äquivalent: $\operatorname{sgn}(\sigma) = (-1)^{\text{Anzahl der Fehlstände}}$, *wobei ein* ***Fehlstand*** *ein Paar* $i < j$ *mit* $\sigma(i) > \sigma(j)$ *ist.*

Beweis der Eindeutigkeit der Parität. Wir betrachten das Polynom

$$P(x_1, \ldots, x_n) := \prod_{1 \le i < j \le n} (x_j - x_i)$$

und definieren die Wirkung von σ darauf durch Vertauschen der Variablen:

$$(\sigma \cdot P)(x_1, \ldots, x_n) := \prod_{i<j} (x_{\sigma(j)} - x_{\sigma(i)}).$$

Jeder Faktor des Ursprungspolynoms tritt wieder auf, eventuell mit umgekehrtem Vorzeichen – nämlich genau bei den Fehlständen. Also

$$\sigma \cdot P = (-1)^{f(\sigma)} P$$

mit $f(\sigma) =$ Anzahl der Fehlstände.

Eine Transposition τ erzeugt eine ungerade Anzahl von Vorzeichenwechseln (das rechnet man für die Vertauschung benachbarter Elemente direkt nach; allgemeine Transpositionen sind Produkte einer ungeraden Anzahl benachbarter). Also gilt $\tau \cdot P = -P$.

Ist $\sigma = \tau_1 \cdots \tau_k$, so folgt $\sigma \cdot P = (-1)^k P$. Da $P \neq 0$, ist $(-1)^k$ eindeutig bestimmt – und damit die Parität von k. ■

Beispiel 6.5. $\sigma = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 3 & 1 \end{pmatrix}$ (also $1 \mapsto 2, 2 \mapsto 3, 3 \mapsto 1$).

Fehlstände: Paare (i, j) mit $i < j$ und $\sigma(i) > \sigma(j)$:

- $(1,2)$: $\sigma(1) = 2 < 3 = \sigma(2)$ – kein Fehlstand.
- $(1,3)$: $2 > 1$ – Fehlstand.
- $(2,3)$: $3 > 1$ – Fehlstand.

Zwei Fehlstände, also $\operatorname{sgn}(\sigma) = (-1)^2 = +1$.

6.3 Die Leibniz-Formel

Satz 6.6 (Existenz und Eindeutigkeit der Determinante). *Es gibt genau eine Abbildung* $\det : \mathbb{K}^{n \times n} \to \mathbb{K}$, *die*

(D1) linear in jeder Spalte ist,

(D2) null wird, sobald zwei Spalten gleich sind,

(D3) $\det I_n = 1$ *erfüllt,*

nämlich

$$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^{n} a_{i,\sigma(i)}.$$

Beweisskizze mit den entscheidenden Schritten. **Eindeutigkeit.** Sei $\mathbf{s}_j$ die j-te Spalte von A; wir schreiben $\mathbf{s}_j = \sum_i a_{ij}\mathbf{e}_i$. Multilinearität liefert

$$\det A = \det(\mathbf{s}_1, \dots, \mathbf{s}_n) = \sum_{i_1=1}^{n} \cdots \sum_{i_n=1}^{n} a_{i_1 1} \cdots a_{i_n n} \det(\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_n}).$$

Nach (D2) verschwindet $\det(\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_n})$, sobald zwei Indizes gleich sind. Es überleben also nur die Terme, in denen $(i_1, \dots, i_n)$ eine *Permutation* ist.

Für eine Permutation σ ist $\det(\mathbf{e}_{\sigma(1)}, \dots, \mathbf{e}_{\sigma(n)}) = \operatorname{sgn}(\sigma) \det(\mathbf{e}_1, \dots, \mathbf{e}_n) = \operatorname{sgn}(\sigma)$ – man sortiert durch Transpositionen um und sammelt bei jeder ein Minuszeichen ein (Satz 6.1).

Damit ist $\det A$ durch die Formel festgelegt.

Existenz. Man definiert det durch die Formel und prüft (D1)–(D3) nach. (D3) ist klar: Bei $A = I$ trägt nur $\sigma = \mathrm{id}$ bei, mit Produkt 1. (D1) gilt, weil in jedem Produkt aus jeder Spalte genau ein Faktor stammt. (D2) erfordert eine kleine Rechnung: Sind Spalte p und q gleich, so paart man σ mit $\sigma \circ (p\,q)$; beide liefern dasselbe Produkt, aber entgegengesetztes Vorzeichen, und heben sich weg. ∎

> **Die Formel ist unbrauchbar – und trotzdem wichtig**
>
> Für $n = 10$ hat die Summe $10! = 3\,628\,800$ Summanden. Für $n = 20$ sind es $2{,}4 \cdot 10^{18}$. Niemand rechnet so.
>
> Ihr Wert ist *theoretisch*: Sie zeigt, dass $\det A$ ein *Polynom* in den Einträgen ist. Daraus folgt zum Beispiel sofort, dass det stetig ist – und damit, dass die invertierbaren Matrizen eine offene Menge bilden.
>
> Praktisch berechnet man Determinanten mit dem Gauß-Algorithmus (siehe unten): $O(n^3)$ statt $O(n!)$.

Beispiel 6.7 (Die Fälle $n = 2, 3$)**.** Für $n = 2$ gibt es zwei Permutationen: id (Signum $+1$) und die Transposition (Signum -1):

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc.$$

Für $n = 3$ gibt es sechs Permutationen; man erhält die **Regel von Sarrus**:

$$\det \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}.$$

Sarrus gilt NUR für 3×3

Die verbreitete Merkregel mit den Diagonalen funktioniert für $n = 4$ *nicht*. Dort gibt es $4! = 24$ Summanden, die Diagonalenregel liefert aber nur 8. Der häufigste Fehler in Klausuren.

6.4 Eigenschaften und Berechnung

Satz 6.8 (Verhalten bei Zeilenumformungen). *(a) Vertauschen zweier Zeilen:* det *wechselt das Vorzeichen.*

(b) Multiplikation einer Zeile mit λ: det *wird mit λ multipliziert.*

(c) Addition eines Vielfachen einer Zeile zu einer anderen: det *bleibt* unverändert.

(d) Für eine Dreiecksmatrix ist det *das Produkt der Diagonaleinträge.*

Beweis. (a) und (b) folgen unmittelbar aus (D1) und Satz 6.1 (angewandt auf Zeilen statt Spalten – das ist zulässig wegen $\det A^{\mathsf{T}} = \det A$, siehe unten).

(c) ist der wichtigste Punkt. Sei $Z_i' = Z_i + \lambda Z_k$ mit $i \neq k$. Wegen der Linearität in der i-ten Zeile:

$$\det(\dots, Z_i + \lambda Z_k, \dots) = \det(\dots, Z_i, \dots) + \lambda \det(\dots, Z_k, \dots).$$

Im zweiten Summanden steht die Zeile Z_k an *zwei* Stellen (an Position i und an ihrer eigenen Position k). Nach (D2) ist diese Determinante null. Es bleibt nur der erste Summand.

(d) Bei einer oberen Dreiecksmatrix ist in der Leibniz-Formel $a_{i\sigma(i)} = 0$, sobald $\sigma(i) < i$ für ein i. Die einzige Permutation ohne diese Eigenschaft ist die Identität (man zeigt das durch Induktion von unten: $\sigma(n)$ muss n sein, dann $\sigma(n-1) = n-1$, usw.). Es bleibt $a_{11}a_{22}\cdots a_{nn}$. ∎

Das praktische Verfahren

Man bringt A mit dem Gauß-Algorithmus auf Dreiecksform und protokolliert dabei:

- jede Zeilenvertauschung $\to$ Faktor (-1),
- jede Multiplikation mit $\lambda \to$ Faktor λ,
- Addition von Vielfachen $\to$ nichts (kostenlos!).

Am Ende: Produkt der Diagonale, korrigiert um die gesammelten Faktoren. Aufwand: $O(n^3)$.

Aufgabe 6.1. Berechnen Sie

$$\det A, \qquad A = \begin{pmatrix} 2 & 1 & 3 & 1 \\ 4 & 3 & 8 & 3 \\ 6 & 5 & 15 & 8 \\ 2 & 2 & 7 & 5 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Erste Spalte ausräumen (kostenlose Umformungen):
$Z_2 - 2Z_1$: $(0,\, 3-2,\, 8-6,\, 3-2) = (0,1,2,1)$.
$Z_3 - 3Z_1$: $(0,\, 5-3,\, 15-9,\, 8-3) = (0,2,6,5)$.
$Z_4 - Z_1$: $(0,\, 2-1,\, 7-3,\, 5-1) = (0,1,4,4)$.

$$\det A = \det \begin{pmatrix} 2 & 1 & 3 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 2 & 6 & 5 \\ 0 & 1 & 4 & 4 \end{pmatrix}$$

Schritt 2 – Zweite Spalte ausräumen.
$Z_3 - 2Z_2$: $(0,\, 0,\, 6-4,\, 5-2) = (0,0,2,3)$.
$Z_4 - Z_2$: $(0,\, 0,\, 4-2,\, 4-1) = (0,0,2,3)$.

$$= \det \begin{pmatrix} 2 & 1 & 3 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 2 & 3 \\ 0 & 0 & 2 & 3 \end{pmatrix}$$

Schritt 3 – Dritte Spalte. $Z_4 - Z_3 = (0,0,0,0)$.

$$= \det \begin{pmatrix} 2 & 1 & 3 & 1 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 2 & 3 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Schritt 4 – Ablesen. Dreiecksform; Produkt der Diagonale:

$$\det A = 2 \cdot 1 \cdot 2 \cdot 0 = 0.$$

Es gab keine Vertauschungen und keine Skalierungen, also keine Korrekturfaktoren.
Ergebnis: $\det A = 0$, die Matrix ist nicht invertierbar.
Kontrolle über die Struktur. Wir haben unterwegs gesehen, dass $Z_3 = Z_4$ nach dem zweiten Schritt gilt. Rückverfolgt heißt das

$$(Z_3 - 3Z_1) - 2(Z_2 - 2Z_1) = (Z_4 - Z_1) - (Z_2 - 2Z_1),$$

also $Z_3 - 2Z_2 + Z_1 = Z_4 - Z_2 + Z_1$, mithin $Z_3 = Z_4 + Z_2$. Prüfen wir das an der Originalmatrix:

$$Z_4 + Z_2 = (2+4,\ 2+3,\ 7+8,\ 5+3) = (6,5,15,8) = Z_3.\checkmark$$

Die dritte Zeile ist die Summe der zweiten und vierten – daher die Abhängigkeit.

Satz 6.9 (Multiplikationssatz). *Für $A, B \in \mathbb{K}^{n\times n}$ gilt*

$$\det(AB) = \det A \cdot \det B.$$

Beweis. **Fall 1: A nicht invertierbar.** Dann ist $\operatorname{Rang} A < n$, also auch $\operatorname{Rang}(AB) \leq \operatorname{Rang} A < n$, also sind beide Determinanten null (siehe Satz 6.10 unten). Gleichheit $0 = 0$.

Fall 2: A invertierbar. Wir betrachten bei festem A die Funktion

$$\Phi(B) := \frac{\det(AB)}{\det A}$$

als Funktion der Spalten von B.

Φ *ist multilinear:* Die j-te Spalte von AB ist $A \cdot (j\text{-te Spalte von } B)$; die Abbildung $\mathbf{s} \mapsto A\mathbf{s}$ ist linear, und det ist multilinear in den Spalten. Die Verkettung ist wieder multilinear.

Φ *ist alternierend:* Sind zwei Spalten von B gleich, so auch die entsprechenden Spalten von AB.

Φ *ist normiert:* $\Phi(I) = \frac{\det A}{\det A} = 1$.

Nach dem Eindeutigkeitsteil von Satz 6.6 folgt $\Phi = \det$, also $\det(AB) = \det A \det B$. ∎

Warum dieser Beweis so elegant ist

Ein direkter Beweis über die Leibniz-Formel wäre eine Orgie aus Doppelsummen. Der Trick besteht darin, die Eindeutigkeitsaussage als *Werkzeug* zu benutzen: Man zeigt nicht, dass die Formeln übereinstimmen, sondern dass beide Seiten dieselben charakterisierenden Eigenschaften haben.
Dieses Muster – *Eindeutigkeit als Beweismittel* – ist eines der wirksamsten in der ganzen Mathematik.

Korollar 6.10. *A ist invertierbar $\iff \det A \neq 0$. In diesem Fall* $\det(A^{-1}) = (\det A)^{-1}$.

Beweis. Ist A invertierbar, so $1 = \det I = \det(AA^{-1}) = \det A \cdot \det(A^{-1})$, also $\det A \neq 0$.

Ist A nicht invertierbar, so $\operatorname{Rang} A < n$, also sind die Spalten linear abhängig; eine Spalte ist Linearkombination der anderen. Zieht man diese Linearkombination ab (kostenlose Umformungen), entsteht eine Nullspalte, und wegen (D1) ist die Determinante null. ∎

Satz 6.11. $\det A^{\mathsf{T}} = \det A$.

Beweis. Aus der Leibniz-Formel:

$$\det A^{\mathsf{T}} = \sum_{\sigma} \operatorname{sgn}(\sigma) \prod_{i} a_{\sigma(i),i}.$$

Wir substituieren $j := \sigma(i)$, also $i = \sigma^{-1}(j)$; das Produkt läuft über dieselben Faktoren in anderer Reihenfolge:

$$\prod_{i} a_{\sigma(i),i} = \prod_{j} a_{j,\sigma^{-1}(j)}.$$

Ferner ist $\operatorname{sgn}(\sigma^{-1}) = \operatorname{sgn}(\sigma)$ (die Umkehrung braucht dieselbe Anzahl Transpositionen). Da mit σ auch σ^{-1} ganz S_n durchläuft, ist die Summe dieselbe. ∎

> **Konsequenz**
> Alle Aussagen über Spalten gelten genauso für Zeilen. Deshalb durften wir in Satz 6.8 mit Zeilenumformungen arbeiten, obwohl die Axiome für Spalten formuliert waren.

6.5 Laplace-Entwicklung und Cramersche Regel

Satz 6.12 (Laplace-Entwicklung)**.** *Sei A_{ij} die Matrix, die aus A durch Streichen der i-ten Zeile und j-ten Spalte entsteht. Dann gilt für jedes feste i:*

$$\det A = \sum_{j=1}^{n} (-1)^{i+j} a_{ij} \det A_{ij} \qquad \textit{(Entwicklung nach der } i\textit{-ten Zeile)}$$

und analog nach Spalten.

> **Das Schachbrettmuster**
> Die Vorzeichen $(-1)^{i+j}$ ordnen sich wie folgt an:
>
> $$\begin{pmatrix} + & - & + & - \\ - & + & - & + \\ + & - & + & - \\ - & + & - & + \end{pmatrix}$$
>
> Links oben immer $+$, dann abwechselnd.
> **Praktischer Rat:** Entwickeln Sie stets nach der Zeile oder Spalte mit den *meisten Nullen* – jede Null spart eine Unterdeterminante.

Aufgabe 6.2. Berechnen Sie

$$\det \begin{pmatrix} 3 & 0 & 2 & 0 \\ 1 & 4 & -1 & 2 \\ 0 & 0 & 5 & 0 \\ 2 & 1 & 0 & 3 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Beste Zeile suchen. Zeile 3 lautet $(0,0,5,0)$ – drei Nullen! Wir entwickeln danach.

$$\det A = \sum_j (-1)^{3+j} a_{3j} \det A_{3j}.$$

Nur $j = 3$ trägt bei ($a_{33} = 5$), das Vorzeichen ist $(-1)^{3+3} = +1$:

$$\det A = 5 \cdot \det A_{33},$$

wobei A_{33} durch Streichen von Zeile 3 und Spalte 3 entsteht:

$$A_{33} = \begin{pmatrix} 3 & 0 & 0 \\ 1 & 4 & 2 \\ 2 & 1 & 3 \end{pmatrix}.$$

Schritt 2 – Die 3×3-Determinante. Zeile 1 hat zwei Nullen; wir entwickeln danach:

$$\det A_{33} = (-1)^{1+1} \cdot 3 \cdot \det \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix} = 3 \cdot (4 \cdot 3 - 2 \cdot 1) = 3 \cdot 10 = 30.$$

Schritt 3 – Zusammensetzen.

$$\det A = 5 \cdot 30 = 150.$$

Schritt 4 – Kontrolle mit Sarrus. Für A_{33}:

$3 \cdot 4 \cdot 3 + 0 \cdot 2 \cdot 2 + 0 \cdot 1 \cdot 1 - 0 \cdot 4 \cdot 2 - 3 \cdot 2 \cdot 1 - 0 \cdot 1 \cdot 3 = 36 + 0 + 0 - 0 - 6 - 0 = 30$. ✓

Satz 6.13 (Cramersche Regel). *Sei A invertierbar und $A\mathbf{x} = \mathbf{b}$. Dann gilt für jedes j*

$$x_j = \frac{\det A^{(j)}}{\det A},$$

wobei $A^{(j)}$ aus A entsteht, indem die j-te Spalte durch $\mathbf{b}$ ersetzt wird.

Beweis. Sei $\mathbf{s}_1, \ldots, \mathbf{s}_n$ die Spalten von A. Aus $A\mathbf{x} = \mathbf{b}$ folgt $\mathbf{b} = \sum_k x_k \mathbf{s}_k$. Setzen wir das in $A^{(j)}$ ein und nutzen Multilinearität:

$$\det A^{(j)} = \det(\mathbf{s}_1, \ldots, \underbrace{\textstyle\sum_k x_k \mathbf{s}_k}_{\text{Position } j}, \ldots, \mathbf{s}_n) = \sum_k x_k \det(\mathbf{s}_1, \ldots, \underbrace{\mathbf{s}_k}_{\text{Position } j}, \ldots, \mathbf{s}_n).$$

Für $k \neq j$ kommt die Spalte $\mathbf{s}_k$ doppelt vor – die Determinante verschwindet nach (D2). Es bleibt der Term $k = j$:

$$\det A^{(j)} = x_j \det A. \qquad \blacksquare$$

Aufgabe 6.3. Lösen Sie mit der Cramerschen Regel:

$$2x + y = 5, \qquad x + 3y = 10.$$

Lösung Schritt für Schritt.

Schritt 1 – Determinante der Koeffizientenmatrix.

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}, \qquad \det A = 2 \cdot 3 - 1 \cdot 1 = 5 \neq 0.$$

Eindeutig lösbar.

Schritt 2 – Erste Spalte ersetzen.

$$A^{(1)} = \begin{pmatrix} 5 & 1 \\ 10 & 3 \end{pmatrix}, \qquad \det A^{(1)} = 5 \cdot 3 - 1 \cdot 10 = 15 - 10 = 5.$$

$$x = \frac{5}{5} = 1.$$

Schritt 3 – Zweite Spalte ersetzen.

$$A^{(2)} = \begin{pmatrix} 2 & 5 \\ 1 & 10 \end{pmatrix}, \qquad \det A^{(2)} = 2 \cdot 10 - 5 \cdot 1 = 15.$$

$$y = \frac{15}{5} = 3.$$

Probe: $2 \cdot 1 + 3 = 5$ ✓; $1 + 3 \cdot 3 = 10$ ✓.

Wann man Cramer tatsächlich benutzt. Fast nie zum Rechnen. Wohl aber, wenn man wissen will, *wie* die Lösung von den Daten abhängt – etwa in der Sensitivitätsanalyse oder wenn Parameter auftreten. Die Formel zeigt: x_j ist eine rationale Funktion der Koeffizienten, mit $\det A$ im Nenner. Je kleiner $\det A$, desto empfindlicher reagiert die Lösung auf Störungen – das ist der Ausgangspunkt der Konditionsanalyse (Kapitel 12).

6.6 Geometrische Deutung

Satz 6.14. *Für $A \in \mathbb{R}^{n\times n}$ ist $|\det A|$ das n-dimensionale Volumen des von den Spalten aufgespannten Parallelotops. Ferner gilt für jede messbare Menge $M \subseteq \mathbb{R}^n$:*

$$\operatorname{vol}(A \cdot M) = |\det A| \cdot \operatorname{vol}(M).$$

Was das Vorzeichen bedeutet

$\det A > 0$: Die Abbildung erhält die **Orientierung**. In der Ebene: Ein gegen den Uhrzeigersinn durchlaufener Rand bleibt es.
$\det A < 0$: Die Orientierung kehrt sich um – die Abbildung enthält eine Spiegelung.
$\det A = 0$: Der Raum wird auf einen niedrigerdimensionalen Unterraum plattgedrückt; das Volumen verschwindet.
Anwendungen. Der Faktor $|\det|$ ist genau die **Jacobi-Determinante** in der Substitutionsregel für mehrdimensionale Integrale:

$$\int_{\Phi(U)} f(\mathbf{y})\, d\mathbf{y} = \int_U f(\Phi(\mathbf{x}))\, \left|\det D\Phi(\mathbf{x})\right| d\mathbf{x}.$$

Bei Polarkoordinaten etwa ergibt sich der berühmte Faktor r.
In der Physik: Die **Liouville-Gleichung** der Hamiltonschen Mechanik besagt, dass der Phasenraumfluss Determinante 1 hat – das Phasenraumvolumen bleibt erhalten. Und die spezielle Relativitätstheorie arbeitet mit $\mathrm{SO}(1,3)$, den Lorentztransformationen mit Determinante $+1$.

Aufgabe 6.4. Ein Dreieck hat die Ecken $P_1 = (1,2)$, $P_2 = (4,3)$, $P_3 = (2,6)$. Bestimmen Sie seinen Flächeninhalt.

Lösung Schritt für Schritt.

Schritt 1 – Auf den Ursprung verschieben. Wir betrachten die Kantenvektoren von P_1 aus:

$$\mathbf{a} = P_2 - P_1 = \begin{pmatrix} 3 \\ 1 \end{pmatrix}, \qquad \mathbf{b} = P_3 - P_1 = \begin{pmatrix} 1 \\ 4 \end{pmatrix}.$$

Schritt 2 – Parallelogrammfläche.

$$\det \begin{pmatrix} 3 & 1 \\ 1 & 4 \end{pmatrix} = 3 \cdot 4 - 1 \cdot 1 = 11.$$

Schritt 3 – Halbieren. Das Dreieck ist die Hälfte des Parallelogramms:

$$\text{Fläche} = \frac{|11|}{2} = 5{,}5.$$

Schritt 4 – Vorzeichen interpretieren. Da $\det > 0$, sind P_1, P_2, P_3 *gegen den Uhrzeigersinn* angeordnet. Wäre die Determinante negativ, läge die umgekehrte Orientierung vor.
Praktische Bedeutung. Genau dieser Vorzeichentest ist die Grundoperation der algorithmischen Geometrie – in der Computergrafik heißt er *orientation test* oder *cross product test*. Er entscheidet, ob ein Punkt links oder rechts einer Geraden liegt, und ist der Kern von Algorithmen für konvexe Hüllen, Triangulierungen und Kollisionserkennung.

Wer hat die Determinante erfunden?

Nicht Leibniz und nicht Cramer, obwohl beide Namen daran hängen.
Der erste war der japanische Mathematiker SEKI TAKAKAZU (auch Seki Kowa), der 1683 in *Kaifukudai no Ho* Determinanten bis zur Ordnung 5 zur Elimination von Unbekannten verwendete – zehn Jahre vor Leibniz.
LEIBNIZ beschrieb das Konzept 1693 in einem Brief an de l'Hospital; die Stelle blieb bis 1850 unveröffentlicht. CRAMER publizierte seine Regel 1750 in einem Anhang zu einer Arbeit über algebraische Kurven – ohne Beweis.
Den Namen *Determinante* prägte GAUSS 1801 in den *Disquisitiones*, allerdings für die Diskriminante quadratischer Formen. In der heutigen Bedeutung setzte ihn CAUCHY 1812 durch, der auch den Multiplikationssatz bewies.
Die systematische Theorie stammt von JACOBI (1841), dessen Arbeit *De formatione et proprietatibus determinantium* das Gebiet als eigenständige Disziplin etablierte.
Eine Ironie: Bis etwa 1930 galten Determinanten als der Kern der linearen Algebra; Matrizen waren Beiwerk. Heute ist es umgekehrt. SHELDON AXLER hat 1995 mit dem provokanten Aufsatz *Down with Determinants!*[2] und dem darauf aufbauenden Lehrbuch[3] gezeigt, dass sich die gesamte Eigenwerttheorie determinantenfrei entwickeln lässt – mit besserer begrifflicher Klarheit.

Part V

Eigenwerte

7 Eigenwerte und Eigenvektoren

7.1 Die Leitfrage

Am Ende von Kapitel 5 stand die Frage: *Welche Basis macht die Matrix am einfachsten?*

Am einfachsten wäre eine *Diagonalmatrix*. Dann würde die Abbildung jede Basisrichtung einfach strecken oder stauchen, unabhängig von den anderen. Wann geht das?

Definition 7.1. Sei $f : V \to V$ linear. Ein Vektor $\mathbf{v} \neq \mathbf{0}$ heißt **Eigenvektor** zum **Eigenwert** $\lambda \in \mathbb{K}$, wenn

$$f(\mathbf{v}) = \lambda \mathbf{v}.$$

Zwei Feinheiten

(a) $\mathbf{v} \neq \mathbf{0}$ ist zwingend. Für $\mathbf{v} = \mathbf{0}$ gilt $f(\mathbf{0}) = \mathbf{0} = \lambda\mathbf{0}$ für *jedes* λ. Ließe man den Nullvektor zu, wäre jede Zahl ein Eigenwert, und der Begriff wäre wertlos.
(b) $\lambda = 0$ ist erlaubt. Ein Eigenvektor zum Eigenwert 0 ist ein Vektor mit $f(\mathbf{v}) = \mathbf{0}$, also ein Kernelement. Es gilt:

$$0 \text{ ist Eigenwert} \iff \operatorname{Kern} f \neq \{\mathbf{0}\} \iff f \text{ nicht injektiv.}$$

Die geometrische Bedeutung

Ein Eigenvektor spannt eine Gerade auf, die von f *auf sich selbst* abgebildet wird. Die Abbildung dreht diese Richtung nicht – sie streckt sie nur um den Faktor λ.

- $\lambda > 1$: Streckung. $0 < \lambda < 1$: Stauchung.
- $\lambda = 1$: Die Richtung bleibt punktweise fest.
- $\lambda < 0$: Umkehrung der Richtung.
- $\lambda = 0$: Die Richtung wird auf den Nullpunkt kollabiert.

Eine Drehung der Ebene um $90°$ hat keine reellen Eigenvektoren – keine Richtung bleibt erhalten. Über $\mathbb{C}$ dagegen schon. Das ist der Grund, warum man in der Eigenwerttheorie meist über $\mathbb{C}$ arbeitet.

7.2 Das charakteristische Polynom

Satz 7.2. *λ ist genau dann Eigenwert von $A \in \mathbb{K}^{n\times n}$, wenn*

$$\det(A - \lambda I) = 0.$$

Beweis. Die Gleichung $A\mathbf{v} = \lambda\mathbf{v}$ ist äquivalent zu

$$A\mathbf{v} - \lambda\mathbf{v} = \mathbf{0}, \qquad \text{also} \qquad (A - \lambda I)\mathbf{v} = \mathbf{0}.$$

(Beachten Sie, dass man λ als λI schreiben muss – $A - \lambda$ wäre nicht definiert, weil man eine Matrix nicht minus eine Zahl rechnen kann.)

Ein Eigenvektor ist also ein *nichttriviales* Element von $\operatorname{Kern}(A - \lambda I)$. So etwas existiert genau dann, wenn $A - \lambda I$ nicht injektiv ist, also nicht invertierbar – und nach Korollar 6.10 genau dann, wenn die Determinante verschwindet. ∎

Definition 7.3. $\chi_A(t) := \det(A - tI)$ heißt **charakteristisches Polynom** von A.

Satz 7.4. *χ_A ist ein Polynom vom Grad n mit*

$$\chi_A(t) = (-1)^n t^n + (-1)^{n-1} \operatorname{Spur}(A)\, t^{n-1} + \cdots + \det A.$$

Beweisidee. In der Leibniz-Formel für $\det(A - tI)$ steht $-t$ nur auf der Diagonalen. Der Term mit der höchsten t-Potenz kommt von der Identitätspermutation:

$$(a_{11} - t)(a_{22} - t)\cdots(a_{nn} - t) = (-t)^n + (-t)^{n-1} \sum_i a_{ii} + \ldots$$

Alle anderen Permutationen lassen mindestens zwei Diagonalelemente aus, liefern also höchstens t^{n-2}. Damit sind die beiden führenden Koeffizienten wie behauptet. Das absolute Glied ist $\chi_A(0) = \det A$. ∎

Korollar 7.5. *Sind $\lambda_1, \ldots, \lambda_n$ die Eigenwerte mit Vielfachheit (über $\mathbb{C}$), so gilt*

$$\operatorname{Spur} A = \sum_i \lambda_i, \qquad \det A = \prod_i \lambda_i.$$

Beweis. Über $\mathbb{C}$ zerfällt $\chi_A(t) = (-1)^n \prod_i (t - \lambda_i)$. Koeffizientenvergleich mit der obigen Formel liefert die beiden Identitäten (Vieta). ∎

> **Zwei kostenlose Kontrollen**
>
> Nach jeder Eigenwertberechnung sollte man prüfen: Summe der Eigenwerte = Spur, Produkt = Determinante. Beide sind in Sekunden verifiziert und fangen die meisten Rechenfehler ab.

Definition 7.6. Für einen Eigenwert λ heißt

- die Vielfachheit von λ als Nullstelle von χ_A die **algebraische Vielfachheit** $\mu_a(\lambda)$;
- $\dim \operatorname{Kern}(A - \lambda I)$ die **geometrische Vielfachheit** $\mu_g(\lambda)$. Dieser Kern heißt **Eigenraum** E_λ.

Satz 7.7. *Stets gilt $1 \le \mu_g(\lambda) \le \mu_a(\lambda)$.*

Beweis. $\mu_g \geq 1$: Zu einem Eigenwert existiert per Definition ein Eigenvektor.

$\mu_g \leq \mu_a$: Sei $k := \mu_g(\lambda)$ und $(\mathbf{v}_1, \ldots, \mathbf{v}_k)$ eine Basis von E_λ. Wir ergänzen zu einer Basis B von V. Bezüglich B hat f die Blockgestalt

$$M = \begin{pmatrix} \lambda I_k & * \\ 0 & C \end{pmatrix},$$

denn die ersten k Basisvektoren werden auf ihr λ-faches abgebildet. Für Blockdreiecksmatrizen gilt (durch Laplace-Entwicklung nachweisbar)

$$\chi_M(t) = \det(\lambda I_k - t I_k) \cdot \chi_C(t) = (\lambda - t)^k \chi_C(t).$$

Also ist λ mindestens k-fache Nullstelle, das heißt $\mu_a \geq k = \mu_g$. ■

Aufgabe 7.1. Bestimmen Sie Eigenwerte und Eigenvektoren von

$$A = \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Charakteristisches Polynom.

$$\chi_A(t) = \det \begin{pmatrix} 4-t & -2 \\ 1 & 1-t \end{pmatrix} = (4-t)(1-t) - (-2)\cdot 1.$$

Ausmultiplizieren:

$$(4-t)(1-t) = 4 - 4t - t + t^2 = t^2 - 5t + 4.$$

Also

$$\chi_A(t) = t^2 - 5t + 4 + 2 = t^2 - 5t + 6.$$

Schritt 2 – Nullstellen. Mit der pq-Formel:

$$t_{1,2} = \frac{5 \pm \sqrt{25 - 24}}{2} = \frac{5 \pm 1}{2}.$$

$$\lambda_1 = 3, \qquad \lambda_2 = 2.$$

Kontrolle: Spur $A = 4 + 1 = 5 = 3 + 2$ ✓; $\det A = 4 \cdot 1 - (-2) \cdot 1 = 6 = 3 \cdot 2$ ✓.
Schritt 3 – Eigenraum zu $\lambda_1 = 3$. Wir lösen $(A - 3I)\mathbf{v} = \mathbf{0}$:

$$A - 3I = \begin{pmatrix} 4-3 & -2 \\ 1 & 1-3 \end{pmatrix} = \begin{pmatrix} 1 & -2 \\ 1 & -2 \end{pmatrix}.$$

Zeile 2 minus Zeile 1 ergibt eine Nullzeile. Es bleibt

$$v_1 - 2v_2 = 0 \quad \Longrightarrow \quad v_1 = 2v_2.$$

Mit $v_2 = 1$:

$$\mathbf{v}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Probe:

$$A\begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \cdot 2 + (-2) \cdot 1 \\ 1 \cdot 2 + 1 \cdot 1 \end{pmatrix} = \begin{pmatrix} 6 \\ 3 \end{pmatrix} = 3\begin{pmatrix} 2 \\ 1 \end{pmatrix}. \checkmark$$

Schritt 4 – Eigenraum zu $\lambda_2 = 2$.

$$A - 2I = \begin{pmatrix} 2 & -2 \\ 1 & -1 \end{pmatrix}.$$

Zeile 1 ist das Doppelte von Zeile 2. Es bleibt $v_1 - v_2 = 0$, also $v_1 = v_2$:

$$\mathbf{v}_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Probe: $A\binom{1}{1} = \binom{4-2}{1+1} = \binom{2}{2} = 2\binom{1}{1}$. ✓
Ergebnis.

$$\lambda_1 = 3 \text{ mit } E_3 = \operatorname{span}\begin{pmatrix} 2 \\ 1 \end{pmatrix}, \qquad \lambda_2 = 2 \text{ mit } E_2 = \operatorname{span}\begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Beide Eigenwerte haben algebraische und geometrische Vielfachheit 1.

7.3 Diagonalisierbarkeit

Definition 7.8. $A \in \mathbb{K}^{n\times n}$ heißt **diagonalisierbar**, wenn es ein invertierbares S gibt mit

$$S^{-1}AS = D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n).$$

Satz 7.9 (Diagonalisierbarkeitskriterium)**.** *A ist genau dann diagonalisierbar, wenn eine der folgenden äquivalenten Bedingungen gilt:*

(i) *Es gibt eine Basis aus Eigenvektoren.*
(ii) *χ_A zerfällt in Linearfaktoren, und für jeden Eigenwert gilt $\mu_g(\lambda) = \mu_a(\lambda)$.*
(iii) *$V = \bigoplus_\lambda E_\lambda$.*

In diesem Fall enthält S die Eigenvektoren als Spalten und D die zugehörigen Eigenwerte in derselben Reihenfolge.

Beweis von (i) und der Konstruktion. Sei $(\mathbf{v}_1, \ldots, \mathbf{v}_n)$ eine Basis aus Eigenvektoren mit $A\mathbf{v}_j = \lambda_j \mathbf{v}_j$. Wir setzen die $\mathbf{v}_j$ als Spalten in S. Dann ist die j-te Spalte von AS gerade

$$A\mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

also

$$AS = \left(\lambda_1\mathbf{v}_1 \,\middle|\, \lambda_2\mathbf{v}_2 \,\middle|\, \cdots \,\middle|\, \lambda_n\mathbf{v}_n\right) = S\,D,$$

denn die Rechtsmultiplikation mit einer Diagonalmatrix skaliert die Spalten. Da S invertierbar ist (die Spalten bilden eine Basis), folgt $S^{-1}AS = D$.

Umgekehrt: Gilt $S^{-1}AS = D$, so ist $AS = SD$, und der Spaltenvergleich liefert $A\mathbf{s}_j = \lambda_j \mathbf{s}_j$ – die Spalten von S sind Eigenvektoren und als Spalten einer invertierbaren Matrix eine Basis. ■

Satz 7.10 (Unabhängigkeit von Eigenvektoren)**.** *Eigenvektoren zu* paarweise verschiedenen *Eigenwerten sind linear unabhängig.*

Beweis. Induktion über die Anzahl k der Eigenwerte.

Anfang $k = 1$**:** Ein Eigenvektor ist per Definition $\neq \mathbf{0}$, also unabhängig.

Schritt. Seien $\mathbf{v}_1, \ldots, \mathbf{v}_k$ Eigenvektoren zu paarweise verschiedenen $\lambda_1, \ldots, \lambda_k$, und

$$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k = \mathbf{0}. \tag{$*$}$$

Wir wenden A an:

$$\alpha_1 \lambda_1 \mathbf{v}_1 + \cdots + \alpha_k \lambda_k \mathbf{v}_k = \mathbf{0}. \tag{$**$}$$

Nun multiplizieren wir $(*)$ mit λ_k und subtrahieren von $(**)$:

$$\alpha_1(\lambda_1 - \lambda_k)\mathbf{v}_1 + \cdots + \alpha_{k-1}(\lambda_{k-1} - \lambda_k)\mathbf{v}_{k-1} + \underbrace{\alpha_k(\lambda_k - \lambda_k)}_{=0}\mathbf{v}_k = \mathbf{0}.$$

Der letzte Term verschwindet – *das ist der ganze Trick*. Es bleibt eine Relation zwischen $k-1$ Eigenvektoren, die nach Induktionsvoraussetzung unabhängig sind. Also

$$\alpha_i(\lambda_i - \lambda_k) = 0 \qquad \text{für } i = 1, \ldots, k-1.$$

Da die Eigenwerte paarweise verschieden sind, ist $\lambda_i - \lambda_k \neq 0$, also $\alpha_i = 0$.

Setzt man das in $(*)$ ein, bleibt $\alpha_k \mathbf{v}_k = \mathbf{0}$ mit $\mathbf{v}_k \neq \mathbf{0}$, also $\alpha_k = 0$. ■

Korollar 7.11. *Hat $A \in \mathbb{K}^{n\times n}$ genau n paarweise verschiedene Eigenwerte in $\mathbb{K}$, so ist A diagonalisierbar.*

Die Umkehrung gilt nicht

Die Einheitsmatrix I_n ist diagonalisierbar (sie *ist* schon diagonal), hat aber nur den einen Eigenwert 1.

Es gibt also zwei verschiedene Gründe, warum Diagonalisierung scheitern kann:

- **Das Polynom zerfällt nicht.** Über $\mathbb{R}$ hat die Drehmatrix $\left(\begin{smallmatrix} 0 & -1 \\ 1 & 0 \end{smallmatrix}\right)$ das Polynom $t^2 + 1$ ohne reelle Nullstellen. *Reparatur:* zu $\mathbb{C}$ übergehen.
- **Zu wenige Eigenvektoren.** Bei $\left(\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right)$ ist $\chi(t) = (1-t)^2$, also $\mu_a = 2$; aber $\operatorname{Kern}(A - I) = \operatorname{Kern}\left(\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right)$ ist nur eindimensional, also $\mu_g = 1$. *Keine Reparatur möglich* – solche Matrizen sind über keinem Körper diagonalisierbar. Für sie braucht man die Jordansche Normalform (Kapitel 8).

Aufgabe 7.2. Diagonalisieren Sie

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 1 & -1 \\ 0 & 2 & 4 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Charakteristisches Polynom. Wir entwickeln nach der ersten Spalte (dort stehen zwei Nullen):

$$\chi_A(t) = \det \begin{pmatrix} 2-t & 1 & 0 \\ 0 & 1-t & -1 \\ 0 & 2 & 4-t \end{pmatrix} = (2-t) \cdot \det \begin{pmatrix} 1-t & -1 \\ 2 & 4-t \end{pmatrix}.$$

Die 2×2-Determinante:

$$(1-t)(4-t) - (-1) \cdot 2 = 4 - t - 4t + t^2 + 2 = t^2 - 5t + 6 = (t-2)(t-3).$$

Also

$$\chi_A(t) = (2-t)(t-2)(t-3) = -(t-2)^2(t-3).$$

Eigenwerte: $\lambda_1 = 2$ mit $\mu_a = 2$, $\lambda_2 = 3$ mit $\mu_a = 1$.
Kontrolle: Spur $A = 2 + 1 + 4 = 7$; Eigenwertsumme $2 + 2 + 3 = 7$ ✓.
Schritt 2 – Eigenraum zu $\lambda = 2$.

$$A - 2I = \begin{pmatrix} 0 & 1 & 0 \\ 0 & -1 & -1 \\ 0 & 2 & 2 \end{pmatrix}.$$

Zeilenumformung: $Z_3 + 2Z_2$ ergibt $(0,0,0)$. Ferner $Z_2 + Z_1 = (0,0,-1)$.

$$\to \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix}$$

Die Gleichungen lauten $v_2 = 0$ und $v_3 = 0$; v_1 ist frei. Also

$$E_2 = \operatorname{span} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \qquad \mu_g(2) = 1.$$

Schritt 3 – Entscheidung. Es gilt

$$\mu_g(2) = 1 < 2 = \mu_a(2).$$

Nach Satz 7.9(ii) ist A **nicht diagonalisierbar**.

Schritt 4 – Trotzdem: Eigenraum zu $\lambda = 3$ (wir brauchen ihn später).

$$A - 3I = \begin{pmatrix} -1 & 1 & 0 \\ 0 & -2 & -1 \\ 0 & 2 & 1 \end{pmatrix}.$$

$Z_3 + Z_2 = (0, 0, 0)$. Es bleiben

$$-v_1 + v_2 = 0, \qquad -2v_2 - v_3 = 0.$$

Mit $v_2 = 1$: $v_1 = 1$ und $v_3 = -2$.

$$E_3 = \operatorname{span} \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix}.$$

Probe:

$$A \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \cdot 1 + 1 \cdot 1 + 0 \\ 0 + 1 \cdot 1 + (-1)(-2) \\ 0 + 2 \cdot 1 + 4(-2) \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \\ -6 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix}. \checkmark$$

Fazit. Wir haben nur zwei unabhängige Eigenvektoren für einen dreidimensionalen Raum. Es fehlt einer. Kapitel 8 zeigt, wie man diese Lücke mit einem *Hauptvektor* füllt.

7.4 Anwendung: Potenzen und Rekursionen

Warum man diagonalisiert

Ist $A = SDS^{-1}$, so gilt

$$A^k = (SDS^{-1})^k = SDS^{-1} \cdot SDS^{-1} \cdots SDS^{-1} = SD^kS^{-1},$$

weil sich alle inneren $S^{-1}S$ zu I kürzen. Und D^k ist trivial:

$$D^k = \operatorname{diag}(\lambda_1^k, \ldots, \lambda_n^k).$$

Eine Aufgabe, die $k - 1$ Matrixmultiplikationen erfordert hätte, wird zu n Potenzierungen von Zahlen.

Aufgabe 7.3. Leiten Sie mit linearer Algebra eine geschlossene Formel für die Fibonacci-Zahlen her:

$$F_0 = 0, \quad F_1 = 1, \quad F_{n+1} = F_n + F_{n-1}.$$

Lösung Schritt für Schritt.

Schritt 1 – Die Rekursion als Matrix schreiben. Wir fassen zwei aufeinanderfolgende Glieder zu einem Vektor zusammen:

$$\begin{pmatrix} F_{n+1} \\ F_n \end{pmatrix} = \begin{pmatrix} F_n + F_{n-1} \\ F_n \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} F_n \\ F_{n-1} \end{pmatrix}.$$

Mit $A := \left(\begin{smallmatrix} 1 & 1 \\ 1 & 0 \end{smallmatrix}\right)$ und $\mathbf{u}_n := \left(\begin{smallmatrix} F_{n+1} \\ F_n \end{smallmatrix}\right)$ heißt das $\mathbf{u}_n = A\mathbf{u}_{n-1}$, also

$$\mathbf{u}_n = A^n \mathbf{u}_0, \qquad \mathbf{u}_0 = \begin{pmatrix} F_1 \\ F_0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Schritt 2 – Eigenwerte.

$$\chi_A(t) = \det \begin{pmatrix} 1-t & 1 \\ 1 & -t \end{pmatrix} = (1-t)(-t) - 1 = t^2 - t - 1.$$

Nullstellen:

$$t_{1,2} = \frac{1 \pm \sqrt{1+4}}{2} = \frac{1 \pm \sqrt{5}}{2}.$$

Wir setzen

$$\varphi := \frac{1+\sqrt{5}}{2} \approx 1{,}618 \quad \text{(goldener Schnitt)}, \qquad \psi := \frac{1-\sqrt{5}}{2} \approx -0{,}618.$$

Nützliche Beziehungen: $\varphi + \psi = 1$, $\varphi\psi = -1$, $\varphi - \psi = \sqrt{5}$.
Schritt 3 – Eigenvektoren. Für λ lösen wir $(A - \lambda I)\mathbf{v} = \mathbf{0}$:

$$\begin{pmatrix} 1-\lambda & 1 \\ 1 & -\lambda \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \mathbf{0}.$$

Die zweite Zeile liefert $v_1 = \lambda v_2$. Mit $v_2 = 1$:

$$\mathbf{v}_\lambda = \begin{pmatrix} \lambda \\ 1 \end{pmatrix}.$$

Also $\mathbf{v}_1 = \left(\begin{smallmatrix} \varphi \\ 1 \end{smallmatrix}\right)$ und $\mathbf{v}_2 = \left(\begin{smallmatrix} \psi \\ 1 \end{smallmatrix}\right)$.
Schritt 4 – Startvektor zerlegen. Wir suchen a, b mit

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} = a \begin{pmatrix} \varphi \\ 1 \end{pmatrix} + b \begin{pmatrix} \psi \\ 1 \end{pmatrix}.$$

Zweite Komponente: $a + b = 0$, also $b = -a$. Erste Komponente:

$$a\varphi - a\psi = 1 \Longrightarrow a(\varphi - \psi) = 1 \Longrightarrow a = \frac{1}{\sqrt{5}}.$$

Also $a = \frac{1}{\sqrt{5}}$, $b = -\frac{1}{\sqrt{5}}$.

Schritt 5 – Potenzieren. Da $A\mathbf{v}_\lambda = \lambda\mathbf{v}_\lambda$, gilt $A^n\mathbf{v}_\lambda = \lambda^n\mathbf{v}_\lambda$. Also

$$\mathbf{u}_n = A^n\begin{pmatrix}1\\0\end{pmatrix} = \frac{1}{\sqrt{5}}\varphi^n\begin{pmatrix}\varphi\\1\end{pmatrix} - \frac{1}{\sqrt{5}}\psi^n\begin{pmatrix}\psi\\1\end{pmatrix}.$$

Schritt 6 – Zweite Komponente ablesen. Diese ist F_n:

$$\boxed{F_n = \frac{\varphi^n - \psi^n}{\sqrt{5}} = \frac{1}{\sqrt{5}}\left[\left(\frac{1+\sqrt{5}}{2}\right)^n - \left(\frac{1-\sqrt{5}}{2}\right)^n\right]}$$

Das ist die **Formel von Binet** (1843; tatsächlich bereits 1730 von de Moivre und 1765 von Euler gefunden).
Schritt 7 – Probe für $n = 5$.

$$\varphi^5 = ? \quad \text{Wir nutzen } \varphi^2 = \varphi + 1.$$

$$\varphi^2 = \varphi + 1, \quad \varphi^3 = \varphi\cdot\varphi^2 = \varphi^2 + \varphi = 2\varphi + 1, \quad \varphi^4 = 3\varphi + 2, \quad \varphi^5 = 5\varphi + 3.$$

Dasselbe gilt für ψ: $\psi^5 = 5\psi + 3$. Also

$$F_5 = \frac{(5\varphi+3) - (5\psi+3)}{\sqrt{5}} = \frac{5(\varphi-\psi)}{\sqrt{5}} = \frac{5\sqrt{5}}{\sqrt{5}} = 5.\checkmark$$

(Die Folge lautet $0, 1, 1, 2, 3, 5, \ldots$)
Was daran bemerkenswert ist. Die Formel enthält $\sqrt{5}$ – eine irrationale Zahl –, liefert aber für jedes n eine ganze Zahl. Die irrationalen Anteile heben sich exakt weg.
Praktische Folgerung. Wegen $|\psi| < 1$ gilt $\psi^n \to 0$, also

$$F_n \approx \frac{\varphi^n}{\sqrt{5}}, \qquad \text{genauer: } F_n = \text{nächste ganze Zahl zu } \frac{\varphi^n}{\sqrt{5}}.$$

Die Fibonacci-Zahlen wachsen also exponentiell mit Basis φ, und das Verhältnis F_{n+1}/F_n konvergiert gegen den goldenen Schnitt. Genau das brauchten wir in Band 1 für die Laufzeitanalyse des euklidischen Algorithmus.

7.5 Der Satz von Cayley–Hamilton

Satz 7.12 (Cayley–Hamilton). *Jede quadratische Matrix erfüllt ihr eigenes charakteristisches Polynom:*

$$\chi_A(A) = 0.$$

Der Beweis, der keiner ist

Man liest gelegentlich: „Setze $t = A$ in $\chi_A(t) = \det(A - tI)$ ein; dann steht dort $\det(A - A) = \det 0 = 0$.“
Das ist *falsch*. Der Ausdruck $\det(A - AI)$ ist eine *Zahl*, $\chi_A(A)$ dagegen eine *Matrix*. Man hat zwei verschiedene Objekte verwechselt. Der Fehler ist so verführerisch, dass er einen eigenen Namen hat.

Beweis für diagonalisierbare Matrizen. Sei $A = SDS^{-1}$ mit $D = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$. Für jedes Polynom p gilt

$$p(A) = p(SDS^{-1}) = S\,p(D)\,S^{-1},$$

denn $A^k = SD^kS^{-1}$ und die Bildung ist linear.

Nun ist $p(D) = \operatorname{diag}(p(\lambda_1), \dots, p(\lambda_n))$. Setzen wir $p = \chi_A$, so ist jedes $\chi_A(\lambda_i) = 0$, da die λ_i gerade die Nullstellen sind. Also $\chi_A(D) = 0$ und damit $\chi_A(A) = S \cdot 0 \cdot S^{-1} = 0$. ∎

Warum der allgemeine Fall folgt

Über $\mathbb{C}$ sind die diagonalisierbaren Matrizen *dicht* in $\mathbb{C}^{n\times n}$: Zu jeder Matrix A und jedem $\varepsilon > 0$ gibt es eine diagonalisierbare Matrix im ε-Abstand (man stört die Diagonaleinträge einer Dreiecksform minimal, bis alle Eigenwerte verschieden sind).
Die Abbildung $A \mapsto \chi_A(A)$ ist stetig (polynomial in den Einträgen). Sie verschwindet auf einer dichten Menge, also überall.
Für allgemeine Körper argumentiert man algebraisch über die adjunkte Matrix.

Aufgabe 7.4. Berechnen Sie mit Cayley–Hamilton die Inverse von $A = \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}$.

Lösung Schritt für Schritt.

Schritt 1 – Charakteristisches Polynom. Wir kennen es bereits: $\chi_A(t) = t^2 - 5t + 6$.
Schritt 2 – Cayley–Hamilton anwenden.

$$A^2 - 5A + 6I = 0.$$

Probe: $A^2 = \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}^2 = \begin{pmatrix} 16-2 & -8-2 \\ 4+1 & -2+1 \end{pmatrix} = \begin{pmatrix} 14 & -10 \\ 5 & -1 \end{pmatrix}$.

$$A^2 - 5A + 6I = \begin{pmatrix} 14-20+6 & -10+10+0 \\ 5-5+0 & -1-5+6 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}. \checkmark$$

Schritt 3 – Nach I auflösen.

$$6I = 5A - A^2 = A(5I - A).$$

Division durch 6:

$$I = A \cdot \frac{1}{6}(5I - A).$$

Also

$$A^{-1} = \frac{1}{6}(5I - A) = \frac{1}{6}\left[\begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix} - \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}\right] = \frac{1}{6}\begin{pmatrix} 1 & 2 \\ -1 & 4 \end{pmatrix}.$$

Schritt 4 – Probe.

$$A \cdot A^{-1} = \frac{1}{6}\begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}\begin{pmatrix} 1 & 2 \\ -1 & 4 \end{pmatrix} = \frac{1}{6}\begin{pmatrix} 4+2 & 8-8 \\ 1-1 & 2+4 \end{pmatrix} = \frac{1}{6}\begin{pmatrix} 6 & 0 \\ 0 & 6 \end{pmatrix} = I. \checkmark$$

Die allgemeine Einsicht. Ist $\chi_A(t) = t^n + c_{n-1}t^{n-1} + \cdots + c_0$ mit $c_0 = \pm \det A \neq 0$, so liefert Cayley–Hamilton

$$A^{-1} = -\frac{1}{c_0}\left(A^{n-1} + c_{n-1}A^{n-2} + \cdots + c_1 I\right).$$

Die Inverse ist also stets ein *Polynom in* A vom Grad $\leq n-1$. Das ist theoretisch bedeutsam: Es zeigt, dass die von A erzeugte Algebra unter Inversenbildung abgeschlossen ist.

8 Die Jordansche Normalform

8.1 Was tun, wenn Diagonalisieren scheitert?

Wir haben gesehen: Manche Matrizen sind nicht diagonalisierbar, weil es zu wenige Eigenvektoren gibt. Die Frage lautet nun: Was ist die *einfachste* Form, die man immer erreichen kann?

Definition 8.1 (Jordanblock)**.** Ein **Jordanblock** zur Größe k und zum Eigenwert λ ist

$$J_k(\lambda) := \begin{pmatrix} \lambda & 1 & & \\ & \lambda & \ddots & \\ & & \ddots & 1 \\ & & & \lambda \end{pmatrix} \in \mathbb{K}^{k\times k}$$

– also λ auf der Diagonalen, Einsen auf der oberen Nebendiagonalen, sonst Nullen.

Satz 8.2 (Jordansche Normalform)**.** *Sei $\mathbb{K}$ algebraisch abgeschlossen (etwa $\mathbb{K} = \mathbb{C}$) und $A \in \mathbb{K}^{n\times n}$. Dann gibt es ein invertierbares S mit*

$$S^{-1}AS = \begin{pmatrix} J_{k_1}(\lambda_1) & & \\ & \ddots & \\ & & J_{k_r}(\lambda_r) \end{pmatrix},$$

und diese Darstellung ist bis auf die Reihenfolge der Blöcke eindeutig.

Wie man die Blockstruktur bestimmt

Für jeden Eigenwert λ gilt:

- **Summe der Blockgrößen** zu $\lambda = \mu_a(\lambda)$ (algebraische Vielfachheit).
- **Anzahl der Blöcke** zu $\lambda = \mu_g(\lambda) = \dim \operatorname{Kern}(A - \lambda I)$.
- **Genaue Größen:** Sei $d_j := \dim \operatorname{Kern}(A - \lambda I)^j$. Dann ist die Anzahl der Blöcke der Größe $\geq j$ gleich $d_j - d_{j-1}$.

Die Folge $d_1 < d_2 < \ldots$ wird stationär, sobald $d_j = \mu_a(\lambda)$ erreicht ist.

Beispiel 8.3 (Ablesen der Struktur)**.** Sei λ ein Eigenwert mit $\mu_a = 5$ und $\mu_g = 2$. Dann gibt es *zwei* Blöcke, deren Größen sich zu 5 addieren. Möglich sind $(4,1)$ und $(3,2)$.

Um zu entscheiden, berechnet man $d_2 = \dim \operatorname{Kern}(A - \lambda I)^2$:

- $d_2 = 4$: Beide Blöcke haben Größe ≥ 2, also $(3,2)$.
- $d_2 = 3$: Nur ein Block hat Größe ≥ 2, also $(4,1)$.

8.2 Hauptvektoren

Definition 8.4. $\mathbf{v}$ heißt **Hauptvektor** der Stufe k zum Eigenwert λ, wenn

$$(A-\lambda I)^k\mathbf{v}=\mathbf{0}, \qquad (A-\lambda I)^{k-1}\mathbf{v}\neq\mathbf{0}.$$

Der Raum $H_\lambda := \operatorname{Kern}(A-\lambda I)^n$ heißt **Hauptraum**.

Die Jordankette

Ist $\mathbf{v}$ Hauptvektor der Stufe k, so bilden

$$\mathbf{v}_k := \mathbf{v}, \quad \mathbf{v}_{k-1} := (A-\lambda I)\mathbf{v}, \quad \ldots, \quad \mathbf{v}_1 := (A-\lambda I)^{k-1}\mathbf{v}$$

eine Kette, in der jeder Vektor durch $(A-\lambda I)$ auf den nächsten abgebildet wird und der letzte, $\mathbf{v}_1$, ein echter Eigenvektor ist.
Ordnet man $\mathbf{v}_1,\ldots,\mathbf{v}_k$ als Spalten (in dieser Reihenfolge!), so entsteht genau ein Jordanblock. Denn

$$A\mathbf{v}_j = \lambda\mathbf{v}_j + \mathbf{v}_{j-1}$$

– was bei $j=1$ zu $A\mathbf{v}_1=\lambda\mathbf{v}_1$ wird.

Aufgabe 8.1. Bestimmen Sie die Jordansche Normalform und eine Jordanbasis für

$$A=\begin{pmatrix}2&1&0\\0&1&-1\\0&2&4\end{pmatrix}$$

(die Matrix aus Aufgabe 12.4, die nicht diagonalisierbar war).

Lösung Schritt für Schritt.

Schritt 1 – Was wir schon wissen.

$$\chi_A(t)=-(t-2)^2(t-3), \qquad \mu_a(2)=2,\ \mu_g(2)=1, \qquad \mu_a(3)=\mu_g(3)=1.$$

$$E_2=\operatorname{span}\begin{pmatrix}1\\0\\0\end{pmatrix}, \qquad E_3=\operatorname{span}\begin{pmatrix}1\\1\\-2\end{pmatrix}.$$

Schritt 2 – Blockstruktur bestimmen.
Zu $\lambda=2$: Summe der Blockgrößen $=\mu_a=2$; Anzahl der Blöcke $=\mu_g=1$. Also *ein* Block der Größe 2.
Zu $\lambda=3$: Ein Block der Größe 1.

$$J=\begin{pmatrix}2&1&0\\0&2&0\\0&0&3\end{pmatrix}.$$

Schritt 3 – Hauptvektor zu $\lambda = 2$ finden. Wir brauchen ein $\mathbf{v}$ mit

$$(A - 2I)\mathbf{v} = \mathbf{v}_1 := \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \qquad \text{(der Eigenvektor).}$$

Also lösen wir das inhomogene System

$$\begin{pmatrix} 0 & 1 & 0 \\ 0 & -1 & -1 \\ 0 & 2 & 2 \end{pmatrix} \mathbf{v} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}.$$

Zeile 1: $v_2 = 1$.
Zeile 2: $-v_2 - v_3 = 0 \Longrightarrow v_3 = -v_2 = -1$.
Zeile 3: $2v_2 + 2v_3 = 2 - 2 = 0$ ✓(konsistent).
v_1 ist frei; wir wählen $v_1 = 0$:

$$\mathbf{v}_2 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

Schritt 4 – Probe.

$$(A - 2I)\mathbf{v}_2 = \begin{pmatrix} 0 & 1 & 0 \\ 0 & -1 & -1 \\ 0 & 2 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0+1+0 \\ 0-1+1 \\ 0+2-2 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \mathbf{v}_1. \checkmark$$

Und $(A - 2I)^2\mathbf{v}_2 = (A - 2I)\mathbf{v}_1 = \mathbf{0}$, denn $\mathbf{v}_1$ ist Eigenvektor. ✓
Schritt 5 – Transformationsmatrix aufstellen. Reihenfolge: erst der Eigenvektor, dann der Hauptvektor, dann der zweite Eigenwert.

$$S = (\mathbf{v}_1 \mid \mathbf{v}_2 \mid \mathbf{w}) = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & -1 & -2 \end{pmatrix}.$$

Schritt 6 – Verifikation über $AS = SJ$. Das ist bequemer als $S^{-1}AS$ auszurechnen. *Linke Seite, Spalte für Spalte:*

$$A\mathbf{v}_1 = \begin{pmatrix} 2 \\ 0 \\ 0 \end{pmatrix}, \quad A\mathbf{v}_2 = \begin{pmatrix} 0 \cdot 2 + 1 \cdot 1 + 0 \\ 0 + 1 - (-1) \\ 0 + 2 \cdot 1 + 4(-1) \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ -2 \end{pmatrix}, \quad A\mathbf{w} = \begin{pmatrix} 3 \\ 3 \\ -6 \end{pmatrix}.$$

Also

$$AS = \begin{pmatrix} 2 & 1 & 3 \\ 0 & 2 & 3 \\ 0 & -2 & -6 \end{pmatrix}.$$

Rechte Seite:

$$SJ = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & -1 & -2 \end{pmatrix} \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}.$$

Spalte 1: $2 \cdot \mathbf{v}_1 = (2,0,0)$. ✓
Spalte 2: $1 \cdot \mathbf{v}_1 + 2 \cdot \mathbf{v}_2 = (1,0,0) + (0,2,-2) = (1,2,-2)$. ✓
Spalte 3: $3 \cdot \mathbf{w} = (3,3,-6)$. ✓
Beide Seiten stimmen überein. Die Jordanform ist bestätigt.

Warum die Jordanform theoretisch wichtig und praktisch heikel ist

Theoretisch: Sie klassifiziert alle Matrizen bis auf Ähnlichkeit vollständig. Zwei Matrizen sind genau dann ähnlich, wenn sie dieselbe Jordanform haben (bis auf Blockreihenfolge). Das ist ein Klassifikationssatz von großer Reichweite.
Praktisch: Die Jordanform ist *numerisch instabil*. Die Matrix

$$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \quad \text{hat einen } 2 \times 2\text{-Block, aber} \quad \begin{pmatrix} 1 & 1 \\ \varepsilon & 1 \end{pmatrix}$$

hat für jedes noch so kleine $\varepsilon > 0$ zwei verschiedene Eigenwerte $1 \pm \sqrt{\varepsilon}$ und ist diagonalisierbar. Eine beliebig kleine Störung ändert die Jordanstruktur vollständig. Deshalb verwendet die numerische Mathematik statt der Jordanform die **Schur-Zerlegung** $A = QRQ^*$ mit unitärem Q und oberer Dreiecksmatrix R – diese ist stabil berechenbar.

8.3 Anwendung: Lineare Differentialgleichungssysteme

Das Matrixexponential

Für $A \in \mathbb{K}^{n\times n}$ definiert man

$$e^A := \sum_{k=0}^{\infty} \frac{A^k}{k!} = I + A + \frac{A^2}{2} + \frac{A^3}{6} + \dots$$

Die Reihe konvergiert für jede Matrix. Es gilt

$$\frac{d}{dt} e^{tA} = A e^{tA},$$

und die eindeutige Lösung des Anfangswertproblems

$$\mathbf{x}'(t) = A\mathbf{x}(t), \qquad \mathbf{x}(0) = \mathbf{x}_0$$

lautet

$$\mathbf{x}(t) = e^{tA}\mathbf{x}_0.$$

Satz 8.5. *Ist $A = SJS^{-1}$, so gilt $e^{tA} = S\,e^{tJ}\,S^{-1}$, und für einen Jordanblock*

$$e^{tJ_k(\lambda)} = e^{\lambda t} \begin{pmatrix} 1 & t & \frac{t^2}{2} & \cdots & \frac{t^{k-1}}{(k-1)!} \\ & 1 & t & \cdots & \frac{t^{k-2}}{(k-2)!} \\ & & \ddots & \ddots & \vdots \\ & & & 1 & t \\ & & & & 1 \end{pmatrix}.$$

Beweisidee. Man schreibt $J_k(\lambda) = \lambda I + N$ mit der nilpotenten Matrix N (Einsen auf der Nebendiagonalen). Da λI und N kommutieren, gilt

$$e^{t(\lambda I + N)} = e^{\lambda t I} e^{tN} = e^{\lambda t}\, e^{tN}.$$

Und $N^k = 0$, also bricht die Exponentialreihe ab:

$$e^{tN} = I + tN + \frac{t^2}{2}N^2 + \cdots + \frac{t^{k-1}}{(k-1)!}N^{k-1}.$$

Da N^j die j-te Nebendiagonale mit Einsen besetzt, ergibt sich die angegebene Gestalt. ∎

Die Physik dahinter

Die Eigenwerte bestimmen das Langzeitverhalten:

- $\operatorname{Re}\lambda < 0$ für alle λ: Alle Lösungen streben gegen 0. Das System ist **asymptotisch stabil**.
- $\operatorname{Re}\lambda > 0$ für ein λ: Es gibt exponentiell wachsende Lösungen. **Instabil**.
- $\operatorname{Im}\lambda \neq 0$: Oszillationen mit Kreisfrequenz $|\operatorname{Im}\lambda|$.

- Jordanblöcke der Größe $k > 1$: zusätzliche Polynomfaktoren t^j – das ist der Fall der **aperiodischen Grenzdämpfung** beziehungsweise, bei $\operatorname{Re}\lambda = 0$, der *Resonanzkatastrophe*.

Genau deshalb interessiert sich jeder Regelungstechniker für Eigenwerte: Sie entscheiden, ob eine Brücke, ein Flugzeug oder ein Reaktor stabil ist.

Aufgabe 8.2. Lösen Sie das System

$$x' = 4x - 2y, \qquad y' = x + y, \qquad x(0) = 1,\ y(0) = 0.$$

Lösung Schritt für Schritt.

Schritt 1 – Als Matrixgleichung schreiben.

$$\mathbf{x}' = A\mathbf{x}, \qquad A = \begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix}, \qquad \mathbf{x}_0 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Diese Matrix kennen wir bereits: Eigenwerte 3 und 2, Eigenvektoren $\binom{2}{1}$ und $\binom{1}{1}$.
Schritt 2 – Ansatz über Eigenvektoren. Für einen Eigenvektor $\mathbf{v}$ zum Eigenwert λ ist $\mathbf{x}(t) = e^{\lambda t}\mathbf{v}$ eine Lösung, denn

$$\mathbf{x}'(t) = \lambda e^{\lambda t}\mathbf{v} = e^{\lambda t}(\lambda \mathbf{v}) = e^{\lambda t} A\mathbf{v} = A\mathbf{x}(t). \checkmark$$

Die allgemeine Lösung ist die Linearkombination:

$$\mathbf{x}(t) = c_1 e^{3t}\begin{pmatrix} 2 \\ 1 \end{pmatrix} + c_2 e^{2t}\begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Schritt 3 – Anfangsbedingung einsetzen. Bei $t = 0$ ist $e^0 = 1$:

$$c_1\begin{pmatrix} 2 \\ 1 \end{pmatrix} + c_2\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Komponentenweise:

$$2c_1 + c_2 = 1, \qquad c_1 + c_2 = 0.$$

Aus der zweiten: $c_2 = -c_1$. Einsetzen: $2c_1 - c_1 = 1$, also $c_1 = 1$ und $c_2 = -1$.
Schritt 4 – Lösung hinschreiben.

$$\mathbf{x}(t) = e^{3t}\begin{pmatrix} 2 \\ 1 \end{pmatrix} - e^{2t}\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2e^{3t} - e^{2t} \\ e^{3t} - e^{2t} \end{pmatrix}.$$

Also

$$x(t) = 2e^{3t} - e^{2t}, \qquad y(t) = e^{3t} - e^{2t}.$$

Schritt 5 – Probe.

Anfangswerte: $x(0) = 2 - 1 = 1$ ✓; $y(0) = 1 - 1 = 0$ ✓.
Erste Gleichung: $x'(t) = 6e^{3t} - 2e^{2t}$. Andererseits

$$4x - 2y = 4(2e^{3t} - e^{2t}) - 2(e^{3t} - e^{2t}) = 8e^{3t} - 4e^{2t} - 2e^{3t} + 2e^{2t} = 6e^{3t} - 2e^{2t}.\checkmark$$

Zweite Gleichung: $y'(t) = 3e^{3t} - 2e^{2t}$. Andererseits

$$x + y = 2e^{3t} - e^{2t} + e^{3t} - e^{2t} = 3e^{3t} - 2e^{2t}.\checkmark$$

Interpretation. Beide Eigenwerte sind positiv, das System ist instabil – die Lösung wächst exponentiell. Für große t dominiert e^{3t}, und die Bahn nähert sich asymptotisch der Richtung des Eigenvektors $\binom{2}{1}$.

8.4 Anwendung: Markow-Ketten und PageRank

Definition 8.6. Eine Matrix $P \in \mathbb{R}^{n\times n}$ heißt **stochastisch**, wenn alle Einträge ≥ 0 sind und jede Spalte sich zu 1 summiert.

Satz 8.7. *Jede stochastische Matrix hat den Eigenwert 1, und alle Eigenwerte erfüllen* $|\lambda| \leq 1$.

Beweis. **Eigenwert 1.** Die Spaltensummen von P sind alle 1, das heißt: Die Zeilensummen von P^{T} sind alle 1. Also

$$P^{\mathsf{T}} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Somit ist 1 Eigenwert von P^{T}, und wegen $\chi_{P^{\mathsf{T}}} = \chi_P$ auch von P.

Betragsschranke. Sei $P^{\mathsf{T}}\mathbf{v} = \lambda\mathbf{v}$ mit $\mathbf{v} \neq \mathbf{0}$. Sei i ein Index mit $|v_i|$ maximal. Dann

$$|\lambda|\,|v_i| = \left|\sum_j p_{ji}\, v_j\right| \leq \sum_j p_{ji}|v_j| \leq |v_i| \sum_j p_{ji} = |v_i|.$$

Division durch $|v_i| > 0$ liefert $|\lambda| \leq 1$. ∎

Satz 8.8 (Perron–Frobenius, Spezialfall). *Ist P stochastisch und hat nur positive Einträge, so ist der Eigenwert 1 einfach, alle anderen erfüllen $|\lambda| < 1$, und es gibt einen eindeutigen **stationären Verteilungsvektor** $\boldsymbol{\pi}$ mit $P\boldsymbol{\pi} = \boldsymbol{\pi}$, $\pi_i > 0$, $\sum \pi_i = 1$. Für jeden Startvektor $\mathbf{x}_0$ mit nichtnegativen Einträgen und Summe 1 gilt*

$$P^k \mathbf{x}_0 \longrightarrow \boldsymbol{\pi} \qquad (k \to \infty).$$

Aufgabe 8.3. Ein Mietwagenunternehmen hat Stationen in A und B. Von den in A gemieteten Wagen werden 70 % in A und 30 % in B zurückgegeben; von den in B gemieteten 40 % in A und 60 % in B. Wie verteilt sich der Bestand langfristig?

Lösung Schritt für Schritt.
Schritt 1 – Übergangsmatrix. Spalte j beschreibt, wohin die Wagen aus Station j gehen:

$$P = \begin{pmatrix} 0{,}7 & 0{,}4 \\ 0{,}3 & 0{,}6 \end{pmatrix}.$$

Spaltensummen: $0{,}7 + 0{,}3 = 1$ ✓, $0{,}4 + 0{,}6 = 1$ ✓.
Schritt 2 – Eigenwerte.

$$\chi_P(t) = (0{,}7 - t)(0{,}6 - t) - 0{,}4 \cdot 0{,}3.$$

Ausmultiplizieren:

$$0{,}42 - 0{,}7t - 0{,}6t + t^2 - 0{,}12 = t^2 - 1{,}3t + 0{,}30.$$

Nullstellen:

$$t_{1,2} = \frac{1{,}3 \pm \sqrt{1{,}69 - 1{,}2}}{2} = \frac{1{,}3 \pm \sqrt{0{,}49}}{2} = \frac{1{,}3 \pm 0{,}7}{2}.$$

$$\lambda_1 = 1, \qquad \lambda_2 = 0{,}3.$$

Kontrolle: Spur $= 0{,}7 + 0{,}6 = 1{,}3 = 1 + 0{,}3$ ✓.
Schritt 3 – Stationärer Vektor (Eigenvektor zu 1).

$$P - I = \begin{pmatrix} -0{,}3 & 0{,}4 \\ 0{,}3 & -0{,}4 \end{pmatrix}.$$

Beide Zeilen sind proportional. Aus $-0{,}3\pi_1 + 0{,}4\pi_2 = 0$ folgt

$$\pi_1 = \frac{0{,}4}{0{,}3}\pi_2 = \frac{4}{3}\pi_2.$$

Mit $\pi_2 = 3$: $\pi_1 = 4$. Normieren auf Summe 1:

$$\mathfrak{ß} = \frac{1}{7}\begin{pmatrix} 4 \\ 3 \end{pmatrix} = \begin{pmatrix} 4/7 \\ 3/7 \end{pmatrix} \approx \begin{pmatrix} 0{,}571 \\ 0{,}429 \end{pmatrix}.$$

Ergebnis: Langfristig stehen etwa 57,1 % der Wagen in A und 42,9 % in B.
Schritt 4 – Probe.

$$P\mathfrak{ß} = \begin{pmatrix} 0{,}7 \cdot \frac{4}{7} + 0{,}4 \cdot \frac{3}{7} \\ 0{,}3 \cdot \frac{4}{7} + 0{,}6 \cdot \frac{3}{7} \end{pmatrix} = \begin{pmatrix} \frac{2{,}8}{7} + \frac{1{,}2}{7} \\ \frac{1{,}2}{7} + \frac{1{,}8}{7} \end{pmatrix} = \begin{pmatrix} \frac{4}{7} \\ \frac{3}{7} \end{pmatrix} = \mathfrak{ß}.\checkmark$$

Schritt 5 – Konvergenzgeschwindigkeit. Der zweitgrößte Eigenwert ist 0,3. Die Abweichung vom Gleichgewicht schrumpft also pro Schritt um den Faktor 0,3. Nach 10 Schritten ist sie auf $0{,}3^{10} \approx 6 \cdot 10^{-6}$ des Anfangswerts gefallen – praktisch Gleichgewicht.
Die allgemeine Regel: Der Betrag des zweitgrößten Eigenwerts heißt **spektrale Lücke** und bestimmt die Mischzeit einer Markow-Kette. Je kleiner er ist, desto schneller die Konvergenz.

PageRank – der teuerste Eigenvektor der Welt

1998 beschrieben LARRY PAGE und SERGEY BRIN ihr Ranking-Verfahren[5]: Man modelliert das Web als Graph und einen zufällig surfenden Nutzer, der jeweils einem zufälligen Link folgt. Die Übergangsmatrix ist

$$G = d\,P + \frac{1-d}{n}\,\mathbf{1}\mathbf{1}^{\mathsf{T}},$$

wobei P die Linkstruktur beschreibt und $d \approx 0{,}85$ der **Dämpfungsfaktor** ist. Der Zusatzterm modelliert, dass der Nutzer mit Wahrscheinlichkeit $1-d$ zu einer zufälligen Seite springt.

Warum dieser Zusatzterm nötig ist: Ohne ihn wäre die Matrix nicht positiv, und Perron–Frobenius wäre nicht anwendbar. Es gäbe „Senken“ – Seiten ohne ausgehende Links –, in denen sich die gesamte Wahrscheinlichkeitsmasse ansammelt. Der Dämpfungsfaktor macht die Kette irreduzibel und aperiodisch.

Der PageRank-Vektor ist der stationäre Eigenvektor von G. Bei etwa 10^{11} indexierten Seiten ist G eine Matrix mit 10^{22} Einträgen – undenkbar, sie explizit hinzuschreiben. Man berechnet den Eigenvektor mit der **Potenzmethode**: wiederholtes Anwenden von G auf einen Startvektor, wobei die Struktur von P (dünn besetzt) ausgenutzt wird.

Die spektrale Lücke ist hier $|\lambda_2| \le d = 0{,}85$; man braucht also etwa $\log(10^{-8}) / \log(0{,}85) \approx 113$ Iterationen für achtstellige Genauigkeit.

Google verwendet PageRank seit Jahren nur noch als einen unter Hunderten von Faktoren. Die Grundidee – Wichtigkeit als Fixpunkt einer Selbstbezüglichkeit – prägt aber bis heute die Netzwerkanalyse, von der Zitationsanalyse bis zur Betrugserkennung.

Part VI

Geometrie: Skalarprodukte

9 Skalarprodukte und Orthogonalität

9.1 Was in einem Vektorraum fehlt

Bis hierher konnten wir nicht von *Längen* und *Winkeln* sprechen. Die Vektorraumaxiome sagen nichts darüber. Und tatsächlich sind Begriffe wie „orthogonal“ nicht durch die lineare Struktur bestimmt – man muss sie zusätzlich einführen.

Definition 9.1 (Skalarprodukt, reeller Fall)**.** Ein **Skalarprodukt** auf einem $\mathbb{R}$-Vektorraum V ist eine Abbildung $\langle \cdot, \cdot \rangle : V \times V \to \mathbb{R}$ mit

(S1) **Bilinearität:** linear in jedem Argument;
(S2) **Symmetrie:** $\langle \mathbf{u}, \mathbf{v} \rangle = \langle \mathbf{v}, \mathbf{u} \rangle$;
(S3) **Positive Definitheit:** $\langle \mathbf{v}, \mathbf{v} \rangle > 0$ für alle $\mathbf{v} \neq \mathbf{0}$.

Beispiel 9.2. **Standardskalarprodukt** auf $\mathbb{R}^n$:

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^{\mathsf{T}} \mathbf{y} = \sum_{i=1}^{n} x_i y_i.$$

Auf Funktionenräumen: Für $f, g \in C([a,b])$

$$\langle f, g \rangle := \int_a^b f(t) g(t)\, dt.$$

Die Axiome prüft man mit den Rechenregeln des Integrals nach; (S3) folgt daraus, dass $\int f^2 > 0$ für stetiges $f \neq 0$.

Gewichtete Varianten: $\langle \mathbf{x}, \mathbf{y} \rangle_G := \mathbf{x}^{\mathsf{T}} G \mathbf{y}$ mit einer symmetrischen, positiv definiten Matrix G.

> **Der komplexe Fall**
>
> Über $\mathbb{C}$ würde (S3) mit Bilinearität scheitern: Wäre $\langle \mathbf{v}, \mathbf{v} \rangle > 0$, so wäre
>
> $$\langle i\mathbf{v}, i\mathbf{v} \rangle = i \cdot i \langle \mathbf{v}, \mathbf{v} \rangle = -\langle \mathbf{v}, \mathbf{v} \rangle < 0.$$
>
> Man ersetzt deshalb Symmetrie durch **hermitesche Symmetrie** $\langle \mathbf{u}, \mathbf{v} \rangle = \overline{\langle \mathbf{v}, \mathbf{u} \rangle}$ und fordert Linearität nur im zweiten Argument (Konvention der Physik) beziehungsweise im ersten (Konvention der Mathematik). Man spricht von **Sesquilinearität** – „anderthalbfach linear“.
> Das Standardskalarprodukt auf $\mathbb{C}^n$ lautet dann $\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i \overline{x_i} y_i$.

Definition 9.3. $\|\mathbf{v}\| := \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}$ heißt **Norm** von $\mathbf{v}$. Zwei Vektoren heißen **orthogonal**, geschrieben $\mathbf{u} \perp \mathbf{v}$, wenn $\langle \mathbf{u}, \mathbf{v} \rangle = 0$.

9.2 Die Cauchy–Schwarz-Ungleichung

Satz 9.4 (Cauchy–Schwarz). *Für alle* $\mathbf{u}, \mathbf{v} \in V$ *gilt*

$$|\langle \mathbf{u}, \mathbf{v} \rangle| \leq \|\mathbf{u}\| \cdot \|\mathbf{v}\|,$$

mit Gleichheit genau dann, wenn $\mathbf{u}, \mathbf{v}$ *linear abhängig sind.*

Beweis. Für $\mathbf{v} = \mathbf{0}$ sind beide Seiten null. Sei also $\mathbf{v} \neq \mathbf{0}$.

Der Trick: eine geschickte Wahl. Wir betrachten für beliebiges $t \in \mathbb{R}$

$$0 \leq \|\mathbf{u} - t\mathbf{v}\|^2 = \langle \mathbf{u} - t\mathbf{v}, \mathbf{u} - t\mathbf{v} \rangle.$$

Ausmultiplizieren mit Bilinearität und Symmetrie:

$$= \langle \mathbf{u}, \mathbf{u} \rangle - 2t\langle \mathbf{u}, \mathbf{v} \rangle + t^2 \langle \mathbf{v}, \mathbf{v} \rangle = \|\mathbf{u}\|^2 - 2t\langle \mathbf{u}, \mathbf{v} \rangle + t^2 \|\mathbf{v}\|^2.$$

Das ist ein nach oben geöffnetes Polynom in t, das nie negativ wird. Wir wählen t so, dass der Ausdruck minimal wird – Ableiten und Nullsetzen liefert

$$t_0 = \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{v}\|^2}.$$

Einsetzen:

$$0 \leq \|\mathbf{u}\|^2 - 2\frac{\langle \mathbf{u}, \mathbf{v} \rangle^2}{\|\mathbf{v}\|^2} + \frac{\langle \mathbf{u}, \mathbf{v} \rangle^2}{\|\mathbf{v}\|^4} \|\mathbf{v}\|^2 = \|\mathbf{u}\|^2 - \frac{\langle \mathbf{u}, \mathbf{v} \rangle^2}{\|\mathbf{v}\|^2}.$$

Multiplikation mit $\|\mathbf{v}\|^2 > 0$:

$$\langle \mathbf{u}, \mathbf{v} \rangle^2 \leq \|\mathbf{u}\|^2 \|\mathbf{v}\|^2.$$

Wurzelziehen liefert die Behauptung.

Gleichheitsfall. Gleichheit bedeutet, dass das Minimum null ist, also $\|\mathbf{u} - t_0\mathbf{v}\| = 0$, also $\mathbf{u} = t_0\mathbf{v}$ – lineare Abhängigkeit. ∎

Wozu die Ungleichung gut ist

Sie erlaubt die Definition des *Winkels*. Da

$$-1 \leq \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\| \|\mathbf{v}\|} \leq 1,$$

existiert genau ein $\alpha \in [0, \pi]$ mit

$$\cos \alpha = \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\| \, \|\mathbf{v}\|}.$$

Ohne Cauchy–Schwarz wäre nicht garantiert, dass der Quotient im Definitionsbereich des Arkuskosinus liegt.

Weitere Erscheinungsformen derselben Ungleichung:

- In $\mathbb{R}^n$: $\left(\sum x_i y_i\right)^2 \le \left(\sum x_i^2\right)\left(\sum y_i^2\right)$.
- Für Integrale: $\left(\int fg\right)^2 \le \int f^2 \int g^2$.
- In der Stochastik: $\operatorname{Cov}(X,Y)^2 \le \operatorname{Var}(X)\operatorname{Var}(Y)$ – daraus folgt, dass der Korrelationskoeffizient zwischen -1 und 1 liegt.

Dass diese drei Aussagen dieselbe sind, ist ein Musterbeispiel dafür, was Abstraktion leistet.

Korollar 9.5 (Dreiecksungleichung). $\|\mathbf{u}+\mathbf{v}\| \le \|\mathbf{u}\| + \|\mathbf{v}\|$.

Beweis.

$$\|\mathbf{u}+\mathbf{v}\|^2 = \|\mathbf{u}\|^2 + 2\langle \mathbf{u}, \mathbf{v}\rangle + \|\mathbf{v}\|^2 \le \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2,$$

wobei im mittleren Schritt Cauchy–Schwarz einging. Wurzelziehen. ∎

Satz 9.6 (Satz des Pythagoras). *Ist* $\mathbf{u} \perp \mathbf{v}$, *so gilt* $\|\mathbf{u}+\mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$.

Beweis. In der obigen Rechnung fällt der Mischterm $2\langle \mathbf{u}, \mathbf{v}\rangle$ weg. ∎

9.3 Orthonormalbasen und Gram–Schmidt

Definition 9.7. Eine Familie $(\mathbf{b}_1, \dots, \mathbf{b}_n)$ heißt **Orthonormalbasis** (ONB), wenn

$$\langle \mathbf{b}_i, \mathbf{b}_j\rangle = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j. \end{cases}$$

Satz 9.8 (Warum ONB so bequem sind). *Ist* $(\mathbf{b}_i)$ *eine ONB, so gilt für jedes* $\mathbf{v}$*:*

$$\mathbf{v} = \sum_{i=1}^{n} \langle \mathbf{b}_i, \mathbf{v}\rangle\, \mathbf{b}_i, \qquad \|\mathbf{v}\|^2 = \sum_{i=1}^{n} \langle \mathbf{b}_i, \mathbf{v}\rangle^2.$$

Beweis. Sei $\mathbf{v} = \sum_j \lambda_j \mathbf{b}_j$ (die Darstellung existiert, weil eine ONB eine Basis ist – Orthogonalität impliziert Unabhängigkeit, siehe unten). Wir bilden das Skalarprodukt mit $\mathbf{b}_i$:

$$\langle \mathbf{b}_i, \mathbf{v}\rangle = \Big\langle \mathbf{b}_i, \sum_j \lambda_j \mathbf{b}_j \Big\rangle = \sum_j \lambda_j \underbrace{\langle \mathbf{b}_i, \mathbf{b}_j\rangle}_{=\delta_{ij}} = \lambda_i.$$

Die Koeffizienten sind also direkt ablesbar – *kein Gleichungssystem nötig*. Die zweite Formel (**Parsevalsche Gleichung**) folgt analog. ∎

Der praktische Unterschied

In einer beliebigen Basis kostet die Bestimmung der Koordinaten eines Vektors das Lösen eines $n \times n$-Systems: $O(n^3)$.
In einer Orthonormalbasis kostet sie n Skalarprodukte: $O(n^2)$.

Deshalb lohnt sich der einmalige Aufwand, eine ONB zu konstruieren, fast immer. Und deshalb sind Fourierreihen, Wavelets und Hauptkomponenten so nützlich: Es sind Orthonormalbasen für interessante Funktionenräume.

Satz 9.9. *Orthogonale, von null verschiedene Vektoren sind linear unabhängig.*

Beweis. Sei $\sum \lambda_i \mathbf{v}_i = \mathbf{0}$ mit paarweise orthogonalen $\mathbf{v}_i \neq \mathbf{0}$. Skalarprodukt mit $\mathbf{v}_j$:

$$0 = \langle \mathbf{v}_j, \textstyle\sum_i \lambda_i \mathbf{v}_i \rangle = \lambda_j \|\mathbf{v}_j\|^2.$$

Da $\|\mathbf{v}_j\|^2 > 0$, folgt $\lambda_j = 0$. ∎

Satz 9.10 (Gram–Schmidt-Verfahren)**.** *Sei $(\mathbf{a}_1, \ldots, \mathbf{a}_n)$ linear unabhängig. Definiere rekursiv*

$$\mathbf{w}_1 := \mathbf{a}_1, \qquad \mathbf{w}_k := \mathbf{a}_k - \sum_{j=1}^{k-1} \frac{\langle \mathbf{w}_j, \mathbf{a}_k \rangle}{\langle \mathbf{w}_j, \mathbf{w}_j \rangle} \mathbf{w}_j,$$

und normiere $\mathbf{b}_k := \mathbf{w}_k / \|\mathbf{w}_k\|$. Dann ist $(\mathbf{b}_1, \ldots, \mathbf{b}_n)$ eine ONB mit

$$\operatorname{span}(\mathbf{b}_1, \ldots, \mathbf{b}_k) = \operatorname{span}(\mathbf{a}_1, \ldots, \mathbf{a}_k) \quad \textit{für alle } k.$$

Beweis. Induktion über k. Für $k = 1$ ist nichts zu zeigen.

Sei $(\mathbf{w}_1, \ldots, \mathbf{w}_{k-1})$ paarweise orthogonal mit demselben Spann wie $(\mathbf{a}_1, \ldots, \mathbf{a}_{k-1})$. Wir prüfen $\mathbf{w}_k \perp \mathbf{w}_i$ für $i < k$:

$$\langle \mathbf{w}_i, \mathbf{w}_k \rangle = \langle \mathbf{w}_i, \mathbf{a}_k \rangle - \sum_{j<k} \frac{\langle \mathbf{w}_j, \mathbf{a}_k \rangle}{\langle \mathbf{w}_j, \mathbf{w}_j \rangle} \underbrace{\langle \mathbf{w}_i, \mathbf{w}_j \rangle}_{=0 \text{ für } j \neq i}.$$

Nur der Term $j = i$ überlebt:

$$= \langle \mathbf{w}_i, \mathbf{a}_k \rangle - \frac{\langle \mathbf{w}_i, \mathbf{a}_k \rangle}{\langle \mathbf{w}_i, \mathbf{w}_i \rangle} \langle \mathbf{w}_i, \mathbf{w}_i \rangle = \langle \mathbf{w}_i, \mathbf{a}_k \rangle - \langle \mathbf{w}_i, \mathbf{a}_k \rangle = 0. \checkmark$$

$\mathbf{w}_k \neq \mathbf{0}$: Sonst wäre $\mathbf{a}_k$ Linearkombination von $\mathbf{w}_1, \ldots, \mathbf{w}_{k-1}$, also nach Induktionsvoraussetzung von $\mathbf{a}_1, \ldots, \mathbf{a}_{k-1}$ – im Widerspruch zur Unabhängigkeit.

Gleicher Spann: $\mathbf{w}_k$ entsteht aus $\mathbf{a}_k$ durch Abziehen von Elementen des vorherigen Spanns; umgekehrt lässt sich $\mathbf{a}_k$ aus $\mathbf{w}_k$ und den vorherigen zurückgewinnen. ∎

Was das Verfahren anschaulich tut

„Nimm den nächsten Vektor und ziehe alles ab, was in Richtung der bereits vorhandenen zeigt."
Der abgezogene Anteil

$$\sum_{j<k} \frac{\langle \mathbf{w}_j, \mathbf{a}_k \rangle}{\|\mathbf{w}_j\|^2} \mathbf{w}_j$$

ist genau die *orthogonale Projektion* von $\mathbf{a}_k$ auf den bereits aufgebauten Raum. Was übrig bleibt, steht senkrecht darauf.

Aufgabe 9.1. Orthonormalisieren Sie

$$\mathbf{a}_1 = \begin{pmatrix}1\\1\\0\end{pmatrix}, \quad \mathbf{a}_2 = \begin{pmatrix}1\\0\\1\end{pmatrix}, \quad \mathbf{a}_3 = \begin{pmatrix}0\\1\\1\end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Erster Vektor.

$$\mathbf{w}_1 = \begin{pmatrix}1\\1\\0\end{pmatrix}, \qquad \|\mathbf{w}_1\| = \sqrt{1+1+0} = \sqrt{2}, \qquad \mathbf{b}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\\0\end{pmatrix}.$$

Schritt 2 – Zweiter Vektor. Zuerst die Skalarprodukte:

$$\langle \mathbf{w}_1, \mathbf{a}_2\rangle = 1\cdot 1 + 1\cdot 0 + 0\cdot 1 = 1, \qquad \langle \mathbf{w}_1, \mathbf{w}_1\rangle = 2.$$

Also

$$\mathbf{w}_2 = \mathbf{a}_2 - \frac{1}{2}\mathbf{w}_1 = \begin{pmatrix}1\\0\\1\end{pmatrix} - \frac{1}{2}\begin{pmatrix}1\\1\\0\end{pmatrix} = \begin{pmatrix}1/2\\-1/2\\1\end{pmatrix}.$$

Orthogonalitätsprobe: $\langle \mathbf{w}_1, \mathbf{w}_2\rangle = 1\cdot\frac{1}{2} + 1\cdot(-\frac{1}{2}) + 0 = 0$. ✓
Norm:

$$\|\mathbf{w}_2\| = \sqrt{\tfrac{1}{4}+\tfrac{1}{4}+1} = \sqrt{\tfrac{3}{2}} = \frac{\sqrt{6}}{2}.$$

$$\mathbf{b}_2 = \frac{2}{\sqrt{6}}\begin{pmatrix}1/2\\-1/2\\1\end{pmatrix} = \frac{1}{\sqrt{6}}\begin{pmatrix}1\\-1\\2\end{pmatrix}.$$

Schritt 3 – Dritter Vektor. Skalarprodukte:

$$\langle \mathbf{w}_1, \mathbf{a}_3\rangle = 1\cdot 0 + 1\cdot 1 + 0\cdot 1 = 1,$$

$$\langle \mathbf{w}_2, \mathbf{a}_3\rangle = \tfrac{1}{2}\cdot 0 + (-\tfrac{1}{2})\cdot 1 + 1\cdot 1 = \tfrac{1}{2}, \qquad \langle \mathbf{w}_2, \mathbf{w}_2\rangle = \tfrac{3}{2}.$$

Also

$$\mathbf{w}_3 = \mathbf{a}_3 - \frac{1}{2}\mathbf{w}_1 - \frac{1/2}{3/2}\mathbf{w}_2 = \mathbf{a}_3 - \frac{1}{2}\mathbf{w}_1 - \frac{1}{3}\mathbf{w}_2.$$

Komponentenweise:

$$\mathbf{w}_3 = \begin{pmatrix}0\\1\\1\end{pmatrix} - \frac{1}{2}\begin{pmatrix}1\\1\\0\end{pmatrix} - \frac{1}{3}\begin{pmatrix}1/2\\-1/2\\1\end{pmatrix} = \begin{pmatrix}0-\frac{1}{2}-\frac{1}{6}\\1-\frac{1}{2}+\frac{1}{6}\\1-0-\frac{1}{3}\end{pmatrix} = \begin{pmatrix}-2/3\\2/3\\2/3\end{pmatrix}.$$

Nachrechnen der ersten Komponente: $0 - \frac{1}{2} - \frac{1}{6} = -\frac{3}{6} - \frac{1}{6} = -\frac{4}{6} = -\frac{2}{3}$. ✓
Zweite: $1 - \frac{1}{2} + \frac{1}{6} = \frac{6}{6} - \frac{3}{6} + \frac{1}{6} = \frac{4}{6} = \frac{2}{3}$. ✓
Orthogonalitätsproben:

$$\langle \mathbf{w}_1, \mathbf{w}_3 \rangle = -\tfrac{2}{3} + \tfrac{2}{3} + 0 = 0 \checkmark,$$

$$\langle \mathbf{w}_2, \mathbf{w}_3 \rangle = \tfrac{1}{2}\left(-\tfrac{2}{3}\right) + \left(-\tfrac{1}{2}\right)\tfrac{2}{3} + \tfrac{2}{3} = -\tfrac{1}{3} - \tfrac{1}{3} + \tfrac{2}{3} = 0 \checkmark.$$

Norm:

$$\|\mathbf{w}_3\| = \sqrt{3 \cdot \tfrac{4}{9}} = \sqrt{\tfrac{4}{3}} = \frac{2}{\sqrt{3}}.$$

$$\mathbf{b}_3 = \frac{\sqrt{3}}{2} \cdot \frac{2}{3} \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{3}} \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}.$$

Ergebnis.

$$\mathbf{b}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{b}_2 = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad \mathbf{b}_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}.$$

Schlussprobe der Normen: $\frac{1}{2}(1+1+0) = 1$ ✓; $\frac{1}{6}(1+1+4) = 1$ ✓; $\frac{1}{3}(1+1+1) = 1$ ✓.

Warum man Gram–Schmidt in dieser Form nicht programmiert

Das klassische Verfahren ist numerisch instabil: Rundungsfehler zerstören die Orthogonalität, und zwar umso stärker, je schlechter konditioniert die Ausgangsvektoren sind.
Die **modifizierte** Variante zieht die Projektionen sequentiell ab statt alle auf einmal:

$$\mathbf{w}_k \leftarrow \mathbf{a}_k; \qquad \text{für } j = 1, \dots, k-1: \quad \mathbf{w}_k \leftarrow \mathbf{w}_k - \frac{\langle \mathbf{b}_j, \mathbf{w}_k \rangle}{1} \mathbf{b}_j.$$

Mathematisch identisch, numerisch erheblich besser – der Orthogonalitätsverlust ist proportional zur Maschinengenauigkeit statt zum Quadrat der Konditionszahl. In der Praxis bevorzugt man ohnehin **Householder-Reflexionen**, die eine QR-Zerlegung mit garantierter Orthogonalität liefern. Details in Kapitel 12.

9.4 Orthogonale Projektion und kleinste Quadrate

Definition 9.11. Für einen Untervektorraum $U \subseteq V$ sei

$$U^{\perp} := \{\mathbf{v} \in V : \langle \mathbf{u}, \mathbf{v} \rangle = 0 \text{ für alle } \mathbf{u} \in U\}$$

das **orthogonale Komplement**.

Satz 9.12 (Orthogonale Zerlegung). *Ist* $\dim V < \infty$, *so gilt* $V = U \oplus U^\perp$. *Die Zerlegung* $\mathbf{v} = \mathbf{p} + \mathbf{q}$ *mit* $\mathbf{p} \in U$, $\mathbf{q} \in U^\perp$ *ist eindeutig, und* $\mathbf{p}$ *ist der* eindeutige *Punkt in* U *mit kleinstem Abstand zu* $\mathbf{v}$.

Ist $(\mathbf{b}_1, \dots, \mathbf{b}_k)$ *eine ONB von* U, *so*

$$\mathbf{p} = \sum_{i=1}^{k} \langle \mathbf{b}_i, \mathbf{v} \rangle \, \mathbf{b}_i.$$

Beweis. **Die Formel liefert eine Zerlegung.** Setze $\mathbf{p}$ wie angegeben und $\mathbf{q} := \mathbf{v} - \mathbf{p}$. Für jedes j:

$$\langle \mathbf{b}_j, \mathbf{q} \rangle = \langle \mathbf{b}_j, \mathbf{v} \rangle - \sum_i \langle \mathbf{b}_i, \mathbf{v} \rangle \underbrace{\langle \mathbf{b}_j, \mathbf{b}_i \rangle}_{=\delta_{ji}} = \langle \mathbf{b}_j, \mathbf{v} \rangle - \langle \mathbf{b}_j, \mathbf{v} \rangle = 0.$$

Da $\mathbf{q}$ auf allen Basisvektoren von U senkrecht steht, steht es auf ganz U senkrecht.

Eindeutigkeit / Direktheit. Ist $\mathbf{v} \in U \cap U^\perp$, so $\langle \mathbf{v}, \mathbf{v} \rangle = 0$, also $\mathbf{v} = \mathbf{0}$ nach (S3).

Minimalitätseigenschaft. Sei $\mathbf{u} \in U$ beliebig. Dann ist $\mathbf{p} - \mathbf{u} \in U$ und $\mathbf{q} \in U^\perp$, also stehen sie senkrecht aufeinander. Pythagoras liefert

$$\|\mathbf{v} - \mathbf{u}\|^2 = \| \underbrace{(\mathbf{v} - \mathbf{p})}_{=\mathbf{q}} + \underbrace{(\mathbf{p} - \mathbf{u})}_{\in U} \|^2 = \|\mathbf{q}\|^2 + \|\mathbf{p} - \mathbf{u}\|^2 \geq \|\mathbf{q}\|^2 = \|\mathbf{v} - \mathbf{p}\|^2,$$

mit Gleichheit genau für $\mathbf{u} = \mathbf{p}$. ∎

Das Problem der kleinsten Quadrate

Gegeben ein überbestimmtes System $A\mathbf{x} = \mathbf{b}$ (mehr Gleichungen als Unbekannte), das keine Lösung hat. Gesucht ist das $\mathbf{x}$, für das der *Fehler*

$$\|A\mathbf{x} - \mathbf{b}\|$$

minimal wird.

Die Lösung ist geometrisch klar: $A\mathbf{x}$ durchläuft den Spaltenraum von A. Der nächstgelegene Punkt zu $\mathbf{b}$ ist die orthogonale Projektion. Also muss der Residuenvektor $\mathbf{b} - A\mathbf{x}$ senkrecht auf allen Spalten von A stehen:

$$A^\mathsf{T}(\mathbf{b} - A\mathbf{x}) = \mathbf{0},$$

und das sind die **Normalgleichungen**

$$\boxed{A^\mathsf{T} A \, \mathbf{x} = A^\mathsf{T} \mathbf{b}.}$$

Satz 9.13. *Hat* $A \in \mathbb{R}^{m \times n}$ *vollen Spaltenrang* n, *so ist* $A^\mathsf{T} A$ *invertierbar und die Lösung eindeutig:*

$$\mathbf{x} = (A^\mathsf{T} A)^{-1} A^\mathsf{T} \mathbf{b}.$$

Beweis. Sei $A^{\mathsf{T}}A\mathbf{x} = \mathbf{0}$. Dann

$$0 = \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} = (A\mathbf{x})^{\mathsf{T}}(A\mathbf{x}) = \|A\mathbf{x}\|^2,$$

also $A\mathbf{x} = \mathbf{0}$, also $\mathbf{x} = \mathbf{0}$ wegen des vollen Spaltenrangs. Somit ist $A^{\mathsf{T}}A$ injektiv und als quadratische Matrix invertierbar. ■

Aufgabe 9.2. Bestimmen Sie die Ausgleichsgerade $y = a + bx$ durch die Punkte

$$(1,2), \quad (2,3), \quad (3,5), \quad (4,6).$$

Lösung Schritt für Schritt.

Schritt 1 – Als überbestimmtes System schreiben. Wir suchen a, b mit

$$a + b\cdot 1 = 2, \quad a + b\cdot 2 = 3, \quad a + b\cdot 3 = 5, \quad a + b\cdot 4 = 6.$$

Also

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{pmatrix}, \qquad \mathbf{x} = \begin{pmatrix} a \\ b \end{pmatrix}, \qquad \mathbf{b} = \begin{pmatrix} 2 \\ 3 \\ 5 \\ 6 \end{pmatrix}.$$

Das System ist nicht exakt lösbar (die Punkte liegen nicht auf einer Geraden).

Schritt 2 – $A^{\mathsf{T}}A$ berechnen.

$$A^{\mathsf{T}}A = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{pmatrix}.$$

Position $(1,1)$: $1+1+1+1 = 4$.
Position $(1,2)$: $1+2+3+4 = 10$.
Position $(2,1)$: dasselbe, 10 (die Matrix ist symmetrisch).
Position $(2,2)$: $1+4+9+16 = 30$.

$$A^{\mathsf{T}}A = \begin{pmatrix} 4 & 10 \\ 10 & 30 \end{pmatrix}.$$

Schritt 3 – $A^{\mathsf{T}}\mathbf{b}$ berechnen.

$$A^{\mathsf{T}}\mathbf{b} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \\ 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 2+3+5+6 \\ 2+6+15+24 \end{pmatrix} = \begin{pmatrix} 16 \\ 47 \end{pmatrix}.$$

Schritt 4 – Normalgleichungen lösen.

$$\begin{pmatrix} 4 & 10 \\ 10 & 30 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 16 \\ 47 \end{pmatrix}.$$

Determinante: $4 \cdot 30 - 10 \cdot 10 = 120 - 100 = 20$.
Nach Cramer:

$$a = \frac{1}{20} \det \begin{pmatrix} 16 & 10 \\ 47 & 30 \end{pmatrix} = \frac{16 \cdot 30 - 10 \cdot 47}{20} = \frac{480 - 470}{20} = \frac{10}{20} = 0{,}5.$$

$$b = \frac{1}{20} \det \begin{pmatrix} 4 & 16 \\ 10 & 47 \end{pmatrix} = \frac{4 \cdot 47 - 16 \cdot 10}{20} = \frac{188 - 160}{20} = \frac{28}{20} = 1{,}4.$$

Ergebnis: $y = 0{,}5 + 1{,}4\,x$.
Schritt 5 – Residuen prüfen.

x	y (gemessen)	$\hat{y} = 0{,}5 + 1{,}4x$	Residuum $y - \hat{y}$
1	2	1,9	$+0{,}1$
2	3	3,3	$-0{,}3$
3	5	4,7	$+0{,}3$
4	6	6,1	$-0{,}1$

Summe der Residuen: $0{,}1 - 0{,}3 + 0{,}3 - 0{,}1 = 0$. ✓
Das ist kein Zufall: Die Normalgleichungen fordern $A^{\mathsf{T}}(\mathbf{b} - A\mathbf{x}) = \mathbf{0}$; die erste Zeile von A^{T} besteht aus lauter Einsen, liefert also genau die Bedingung „Residuensumme null“.
Auch die zweite Zeile muss verschwinden: $1(0{,}1) + 2(-0{,}3) + 3(0{,}3) + 4(-0{,}1) = 0{,}1 - 0{,}6 + 0{,}9 - 0{,}4 = 0$. ✓
Summe der Fehlerquadrate: $0{,}01 + 0{,}09 + 0{,}09 + 0{,}01 = 0{,}2$. Keine andere Gerade erreicht einen kleineren Wert.

Der Streit um die Methode

Die Methode der kleinsten Quadrate wurde 1805 von ADRIEN-MARIE LEGENDRE in einem Anhang zu einer Arbeit über Kometenbahnen publiziert – als reines Rechenverfahren, ohne Wahrscheinlichkeitsbegründung.
1809 veröffentlichte GAUSS in *Theoria Motus Corporum Coelestium* eine Herleitung aus der Normalverteilung und bemerkte beiläufig, er habe die Methode seit 1795 verwendet. Legendre reagierte mit einem empörten Brief; der Prioritätsstreit vergiftete das Verhältnis dauerhaft.
Die Wahrheit ist vermutlich: Gauß hatte die Methode wirklich früher, publizierte sie aber nicht – ein wiederkehrendes Muster bei ihm (vgl. die nichteuklidische Geometrie). Sein Notizbuch stützt die Behauptung, war aber der Öffentlichkeit unbekannt.
Der berühmte Anwendungsfall: Am 1. Januar 1801 entdeckte GIUSEPPE PIAZZI den Kleinplaneten *Ceres*, verlor ihn aber nach 41 Tagen Beobachtung in der Sonnennähe aus den Augen. Aus den wenigen, fehlerbehafteten Daten berechnete der

24-jährige Gauß mit seiner Methode die Bahn – und am 7. Dezember 1801 fand FRANZ XAVER VON ZACH Ceres genau dort wieder, wo Gauß es vorhergesagt hatte. Das machte Gauß mit einem Schlag in ganz Europa berühmt.

10 Der Spektralsatz

10.1 Die Adjungierte

Bisher waren Skalarprodukt und lineare Abbildung zwei getrennte Dinge. Jetzt bringen wir sie zusammen – und es entsteht die schönste Theorie des ganzen Buches.

Definition 10.1. Sei $f : V \to V$ linear auf einem Raum mit Skalarprodukt. Eine Abbildung $f^* : V \to V$ heißt **adjungiert** zu f, wenn

$$\langle f(\mathbf{u}), \mathbf{v}\rangle = \langle \mathbf{u}, f^*(\mathbf{v})\rangle \qquad \text{für alle } \mathbf{u}, \mathbf{v} \in V.$$

Satz 10.2. *Zu jedem f existiert genau eine Adjungierte. Bezüglich einer ONB gilt*

$$M(f^*) = M(f)^{\mathsf{T}} \quad \textit{(reell)}, \qquad M(f^*) = \overline{M(f)}^{\mathsf{T}} =: M(f)^* \quad \textit{(komplex)}.$$

Beweis. Sei $(\mathbf{b}_i)$ eine ONB und $A = M(f)$, also $f(\mathbf{b}_j) = \sum_i a_{ij}\mathbf{b}_i$. Nach Satz 9.8 gilt

$$a_{ij} = \langle \mathbf{b}_i, f(\mathbf{b}_j)\rangle.$$

Sei nun B die Matrix einer Abbildung g mit $\langle f(\mathbf{u}), \mathbf{v}\rangle = \langle \mathbf{u}, g(\mathbf{v})\rangle$. Dann

$$b_{ij} = \langle \mathbf{b}_i, g(\mathbf{b}_j)\rangle = \langle f(\mathbf{b}_i), \mathbf{b}_j\rangle = \overline{\langle \mathbf{b}_j, f(\mathbf{b}_i)\rangle} = \overline{a_{ji}}.$$

Das ist genau die konjugiert Transponierte; im reellen Fall entfällt die Konjugation. Da die Matrix eindeutig bestimmt ist, ist es auch g. ∎

Definition 10.3. f heißt **selbstadjungiert**, wenn $f^* = f$. Für Matrizen heißt das

$$A^{\mathsf{T}} = A \quad (\textbf{symmetrisch}) \qquad \text{bzw.} \qquad A^* = A \quad (\textbf{hermitesch}).$$

Ferner heißt A **orthogonal** (reell) bzw. **unitär** (komplex), wenn $A^{\mathsf{T}}A = I$ bzw. $A^*A = I$.

> **Was orthogonale Matrizen tun**
>
> $A^{\mathsf{T}}A = I$ bedeutet: Die Spalten bilden eine Orthonormalbasis. Äquivalent:
>
> $$\langle A\mathbf{x}, A\mathbf{y}\rangle = (A\mathbf{x})^{\mathsf{T}}(A\mathbf{y}) = \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{y} = \mathbf{x}^{\mathsf{T}}\mathbf{y} = \langle \mathbf{x}, \mathbf{y}\rangle.$$
>
> *Orthogonale Abbildungen erhalten Längen und Winkel* – es sind genau die Drehungen und Spiegelungen. Wegen $\det(A^{\mathsf{T}}A) = (\det A)^2 = 1$ gilt $\det A = \pm 1$: $+1$ für Drehungen, -1 für orientierungsumkehrende Abbildungen.

10.2 Der Spektralsatz

Satz 10.4 (Reeller Spektralsatz)**.** *Sei $A \in \mathbb{R}^{n\times n}$ symmetrisch. Dann gilt:*

(a) Alle Eigenwerte von A sind reell.

(b) Eigenvektoren zu verschiedenen Eigenwerten stehen senkrecht aufeinander.

(c) Es gibt eine Orthonormalbasis *des $\mathbb{R}^n$ aus Eigenvektoren von A. Insbesondere existiert eine orthogonale Matrix Q mit*

$$Q^{\mathsf{T}} A Q = \operatorname{diag}(\lambda_1, \dots, \lambda_n).$$

Beweis. (a) Reellität. Wir fassen A als komplexe Matrix auf. Sei $A\mathbf{v} = \lambda\mathbf{v}$ mit $\mathbf{v} \neq \mathbf{0}$ in $\mathbb{C}^n$. Wir bilden

$$\mathbf{v}^* A \mathbf{v}.$$

Einerseits ist $A\mathbf{v} = \lambda\mathbf{v}$, also

$$\mathbf{v}^* A \mathbf{v} = \lambda\, \mathbf{v}^*\mathbf{v} = \lambda \|\mathbf{v}\|^2.$$

Andererseits ist $\mathbf{v}^* A \mathbf{v}$ eine 1×1-Matrix, also gleich ihrer konjugiert Transponierten:

$$\mathbf{v}^* A \mathbf{v} = (\mathbf{v}^* A \mathbf{v})^* = \mathbf{v}^* A^* \mathbf{v} = \mathbf{v}^* A \mathbf{v} \quad (\text{da } A \text{ reell symmetrisch, also } A^* = A).$$

Eine Zahl, die gleich ihrer Konjugierten ist, ist reell. Also ist $\lambda\|\mathbf{v}\|^2$ reell, und da $\|\mathbf{v}\|^2 > 0$ reell ist, ist λ reell.

(b) Orthogonalität. Sei $A\mathbf{u} = \lambda\mathbf{u}$ und $A\mathbf{w} = \mu\mathbf{w}$ mit $\lambda \neq \mu$. Dann

$$\lambda\langle \mathbf{u}, \mathbf{w}\rangle = \langle \lambda\mathbf{u}, \mathbf{w}\rangle = \langle A\mathbf{u}, \mathbf{w}\rangle = \langle \mathbf{u}, A\mathbf{w}\rangle = \langle \mathbf{u}, \mu\mathbf{w}\rangle = \mu\langle \mathbf{u}, \mathbf{w}\rangle.$$

(Im mittleren Schritt geht die Selbstadjungiertheit ein.) Also

$$(\lambda - \mu)\langle \mathbf{u}, \mathbf{w}\rangle = 0,$$

und wegen $\lambda \neq \mu$ folgt $\langle \mathbf{u}, \mathbf{w}\rangle = 0$.

(c) Existenz der ONB. Induktion über n.

Für $n = 1$ ist nichts zu zeigen.

Sei $n > 1$. Nach (a) hat A einen reellen Eigenwert λ_1 mit einem normierten Eigenvektor $\mathbf{b}_1$ (Existenz: Über $\mathbb{C}$ zerfällt χ_A, und nach (a) ist die Nullstelle reell; der zugehörige Eigenraum enthält dann auch einen reellen Vektor, da $\operatorname{Kern}(A - \lambda_1 I)$ von einer reellen Matrix stammt).

Sei $U := \mathbf{b}_1^{\perp}$, ein $(n-1)$-dimensionaler Unterraum.

Behauptung: U ist invariant unter A. Sei $\mathbf{u} \in U$, also $\langle \mathbf{b}_1, \mathbf{u}\rangle = 0$. Dann

$$\langle \mathbf{b}_1, A\mathbf{u}\rangle = \langle A\mathbf{b}_1, \mathbf{u}\rangle = \lambda_1\langle \mathbf{b}_1, \mathbf{u}\rangle = 0,$$

also $A\mathbf{u} \in U$. ✓

Die Einschränkung $A|_U$ ist wieder selbstadjungiert (die definierende Gleichung gilt erst recht auf einem Teilraum). Nach Induktionsvoraussetzung besitzt U eine ONB aus Eigenvektoren. Zusammen mit $\mathbf{b}_1$ ergibt das eine ONB von $\mathbb{R}^n$.

Matrixform. Setzt man die ONB als Spalten in Q, so ist Q orthogonal ($Q^{\mathsf{T}}Q = I$), und wie in Satz 7.9 folgt $Q^{\mathsf{T}} A Q = Q^{-1} A Q = D$. ∎

Warum das ein Höhepunkt ist

Für allgemeine Matrizen ist Diagonalisierbarkeit die Ausnahme. Für symmetrische Matrizen ist sie *garantiert* – und sogar mit einer Orthonormalbasis, also mit einer besonders angenehmen Transformation ($Q^{-1} = Q^{\mathsf{T}}$, keine Inversion nötig).
Wo das gebraucht wird:

- **Quantenmechanik.** Observable werden durch selbstadjungierte Operatoren dargestellt. Der Spektralsatz garantiert, dass die Messwerte (Eigenwerte) reell sind und dass es eine vollständige Basis von Eigenzuständen gibt. Ohne ihn hätte die Theorie keinen Sinn.
- **Statistik.** Kovarianzmatrizen sind symmetrisch und positiv semidefinit; ihre orthogonale Diagonalisierung ist die Hauptkomponentenanalyse.
- **Mechanik.** Der Trägheitstensor ist symmetrisch; seine Eigenvektoren sind die Hauptträgheitsachsen eines starren Körpers.
- **Schwingungen.** Die Eigenwerte der Steifigkeitsmatrix sind die Quadrate der Eigenfrequenzen.

Satz 10.5 (Komplexe Version)**.** *Eine Matrix $A \in \mathbb{C}^{n\times n}$ ist genau dann unitär diagonalisierbar ($U^*AU = D$ mit unitärem U), wenn sie* ***normal*** *ist, das heißt*

$$A^*A = AA^*.$$

Hermitesche, unitäre und schiefhermitesche Matrizen sind normal.

Aufgabe 10.1. Diagonalisieren Sie orthogonal:

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 0 – Symmetrie prüfen. $A^{\mathsf{T}} = A$. ✓ Der Spektralsatz ist anwendbar.
Schritt 1 – Charakteristisches Polynom.

$$\chi_A(t) = (5-t)(2-t) - 4 = 10 - 5t - 2t + t^2 - 4 = t^2 - 7t + 6.$$

Nullstellen:

$$t = \frac{7 \pm \sqrt{49-24}}{2} = \frac{7 \pm 5}{2}.$$
$$\lambda_1 = 6, \qquad \lambda_2 = 1.$$

Kontrolle: Spur $= 7 = 6 + 1$ ✓; det $= 10 - 4 = 6 = 6 \cdot 1$ ✓.
Schritt 2 – Eigenvektor zu $\lambda_1 = 6$.

$$A - 6I = \begin{pmatrix} -1 & 2 \\ 2 & -4 \end{pmatrix}.$$

Zeile 2 ist $-2\times$ Zeile 1. Es bleibt $-v_1 + 2v_2 = 0$, also $v_1 = 2v_2$:

$$\mathbf{w}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \qquad \|\mathbf{w}_1\| = \sqrt{5}, \qquad \mathbf{b}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Schritt 3 – Eigenvektor zu $\lambda_2 = 1$.

$$A - I = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}.$$

Es bleibt $2v_1 + v_2 = 0$, also $v_2 = -2v_1$:

$$\mathbf{w}_2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \qquad \mathbf{b}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

Schritt 4 – Orthogonalität prüfen (der Spektralsatz verspricht sie):

$$\langle \mathbf{w}_1, \mathbf{w}_2 \rangle = 2 \cdot 1 + 1 \cdot (-2) = 0. \checkmark$$

Schritt 5 – Transformationsmatrix.

$$Q = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix}.$$

Prüfung der Orthogonalität:

$$Q^{\mathsf{T}} Q = \frac{1}{5} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} 4+1 & 2-2 \\ 2-2 & 1+4 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix} = I. \checkmark$$

(Hier ist Q zufällig symmetrisch, deshalb sieht die Rechnung so aus.)
Schritt 6 – Verifikation über $AQ = QD$ mit $D = \operatorname{diag}(6, 1)$.
Linke Seite, Spalte 1:

$$A \cdot \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 10+2 \\ 4+2 \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 12 \\ 6 \end{pmatrix} = \frac{6}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix}. \checkmark$$

Spalte 2:

$$A \cdot \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 5-4 \\ 2-4 \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ -2 \end{pmatrix}. \checkmark$$

Also $Q^{\mathsf{T}} A Q = \begin{pmatrix} 6 & 0 \\ 0 & 1 \end{pmatrix}$.

10.3 Quadratische Formen

Definition 10.6. Zu einer symmetrischen Matrix $A \in \mathbb{R}^{n\times n}$ heißt

$$q(\mathbf{x}) := \mathbf{x}^{\mathsf{T}} A\mathbf{x} = \sum_{i,j} a_{ij} x_i x_j$$

die zugehörige **quadratische Form**.

> **Übersetzung Form ↔ Matrix**
> Aus $q(x,y) = 3x^2 + 4xy + 5y^2$ liest man ab:
> - Die Diagonaleinträge sind die Koeffizienten der reinen Quadrate: $a_{11} = 3$, $a_{22} = 5$.
> - Der gemischte Koeffizient wird *halbiert* und auf beide Nebenpositionen verteilt: $a_{12} = a_{21} = 2$.
>
> $$A = \begin{pmatrix} 3 & 2 \\ 2 & 5 \end{pmatrix}.$$
>
> **Die Halbierung ist der häufigste Fehler.** Sie ist nötig, weil in $\mathbf{x}^{\mathsf{T}} A\mathbf{x}$ der Term $a_{12}x_1x_2$ zweimal vorkommt (einmal als a_{12}, einmal als a_{21}).

Definition 10.7. q (bzw. A) heißt

- **positiv definit**, wenn $q(\mathbf{x}) > 0$ für alle $\mathbf{x} \neq \mathbf{0}$;
- **positiv semidefinit**, wenn $q(\mathbf{x}) \geq 0$ für alle $\mathbf{x}$;
- **negativ (semi)definit**, wenn $-q$ positiv (semi)definit ist;
- **indefinit** sonst.

Satz 10.8 (Hauptachsentransformation). *Sei A symmetrisch mit Eigenwerten $\lambda_1, \ldots, \lambda_n$ und orthogonaler Diagonalisierung $Q^{\mathsf{T}} AQ = D$. Substituiert man $\mathbf{x} = Q\mathbf{y}$, so wird*

$$q(\mathbf{x}) = \mathbf{y}^{\mathsf{T}} D\mathbf{y} = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2.$$

Insbesondere:

$$A \text{ positiv definit} \iff \text{alle } \lambda_i > 0, \qquad A \text{ indefinit} \iff \text{es gibt } \lambda_i > 0 \text{ und } \lambda_j < 0.$$

Beweis.

$$q(Q\mathbf{y}) = (Q\mathbf{y})^{\mathsf{T}} A(Q\mathbf{y}) = \mathbf{y}^{\mathsf{T}} Q^{\mathsf{T}} AQ\mathbf{y} = \mathbf{y}^{\mathsf{T}} D\mathbf{y} = \sum_i \lambda_i y_i^2.$$

Da Q invertierbar ist, durchläuft mit $\mathbf{y}$ auch $\mathbf{x}$ alle Werte, und $\mathbf{y} \neq \mathbf{0} \iff \mathbf{x} \neq \mathbf{0}$. Die Vorzeichenaussagen folgen unmittelbar. ∎

> **Die geometrische Deutung**

Die Menge $\{q(\mathbf{x}) = 1\}$ ist ein **Kegelschnitt** (in der Ebene) bzw. eine **Quadrik** (im Raum). Nach der Hauptachsentransformation lautet die Gleichung

$$\lambda_1 y_1^2 + \lambda_2 y_2^2 = 1,$$

und man liest sofort ab:

- beide $\lambda_i > 0$: **Ellipse** mit Halbachsen $1/\sqrt{\lambda_i}$;
- ein $\lambda_i > 0$, einer < 0: **Hyperbel**;
- ein $\lambda_i = 0$: **Parabel** oder entartete Fälle.

Die Eigenvektoren sind die Hauptachsen. Die Transformation dreht das Koordinatensystem so, dass die Achsen mit der Figur ausgerichtet sind – und die gemischten Terme verschwinden.

Satz 10.9 (Hauptminorenkriterium, Sylvester)**.** *Eine symmetrische Matrix A ist genau dann positiv definit, wenn alle **führenden Hauptminoren** positiv sind:*

$$\det A_1 > 0, \quad \det A_2 > 0, \quad \dots, \quad \det A_n = \det A > 0,$$

wobei A_k die linke obere $k \times k$-Teilmatrix ist.

Satz 10.10 (Sylverscher Trägheitssatz)**.** *Die Anzahl der positiven, negativen und verschwindenden Eigenwerte einer symmetrischen Matrix ist unter* beliebigen *Kongruenztransformationen $A \mapsto S^{\mathsf{T}} A S$ (S invertierbar) invariant. Das Tripel heißt **Signatur**.*

Warum der Trägheitssatz nicht trivial ist

Bei einer Kongruenztransformation $S^{\mathsf{T}} A S$ ändern sich die Eigenwerte im Allgemeinen *sehr wohl* – nur ihre *Vorzeichen* in der Bilanz bleiben erhalten. Das ist eine erstaunliche Invarianz.
In der Relativitätstheorie heißt die Signatur $(+,-,-,-)$ die *Lorentz-Signatur* der Raumzeitmetrik; sie ist koordinatenunabhängig, und genau das macht die Unterscheidung von zeitartigen und raumartigen Richtungen physikalisch sinnvoll.

Aufgabe 10.2. Bestimmen Sie Typ und Hauptachsen des Kegelschnitts

$$5x^2 + 4xy + 2y^2 = 6.$$

Lösung Schritt für Schritt.

Schritt 1 – Matrix aufstellen. Diagonale: 5 und 2. Gemischter Term $4xy$, halbiert: 2.

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}.$$

Das ist genau die Matrix aus Aufgabe 15.1.

Schritt 2 – Eigenwerte und -vektoren übernehmen.

$$\lambda_1 = 6 \text{ mit } \mathbf{b}_1 = \tfrac{1}{\sqrt{5}}\begin{pmatrix}2\\1\end{pmatrix}, \qquad \lambda_2 = 1 \text{ mit } \mathbf{b}_2 = \tfrac{1}{\sqrt{5}}\begin{pmatrix}1\\-2\end{pmatrix}.$$

Schritt 3 – Transformierte Gleichung. In den neuen Koordinaten (y_1, y_2):

$$6y_1^2 + 1 \cdot y_2^2 = 6.$$

Durch 6 teilen:

$$\frac{y_1^2}{1} + \frac{y_2^2}{6} = 1.$$

Schritt 4 – Typ und Halbachsen ablesen.
Beide Koeffizienten positiv: **Ellipse.**

$$\text{Halbachse in } \mathbf{b}_1\text{-Richtung: } a = \sqrt{1} = 1,$$

$$\text{Halbachse in } \mathbf{b}_2\text{-Richtung: } b = \sqrt{6} \approx 2{,}449.$$

Die *große* Halbachse liegt also in Richtung $\mathbf{b}_2 = \frac{1}{\sqrt{5}}(1,-2)$, die kleine in Richtung $\mathbf{b}_1$.
Merke: Große Halbachse $\leftrightarrow$ *kleiner* Eigenwert. Das verwirrt oft, ist aber logisch: Ein kleiner Eigenwert bedeutet, dass die Form in dieser Richtung langsam wächst – man kommt weit, bevor der Wert 6 erreicht wird.
Schritt 5 – Probe. Der Punkt $\sqrt{6} \cdot \mathbf{b}_2 = \frac{\sqrt{6}}{\sqrt{5}}(1,-2)$ sollte auf der Ellipse liegen. Mit $c := \sqrt{6/5}$ ist $(x,y) = (c,-2c)$:

$$5c^2 + 4c(-2c) + 2(4c^2) = 5c^2 - 8c^2 + 8c^2 = 5c^2 = 5 \cdot \frac{6}{5} = 6.\checkmark$$

Und der Punkt $1 \cdot \mathbf{b}_1 = \frac{1}{\sqrt{5}}(2,1)$, also $(x,y) = (2d,d)$ mit $d = 1/\sqrt{5}$:

$$5 \cdot 4d^2 + 4 \cdot 2d \cdot d + 2d^2 = 20d^2 + 8d^2 + 2d^2 = 30d^2 = 30 \cdot \frac{1}{5} = 6.\checkmark$$

Schritt 6 – Definitheit kontrollieren. Nach dem Hauptminorenkriterium:

$$\det A_1 = 5 > 0, \qquad \det A_2 = 5 \cdot 2 - 2 \cdot 2 = 6 > 0.$$

Positiv definit ✓ – daher eine Ellipse und keine Hyperbel.

Anwendung: Der zweite Ableitungstest

Für eine zweimal stetig differenzierbare Funktion $f : \mathbb{R}^n \to \mathbb{R}$ mit $\nabla f(\mathbf{x}_0) = \mathbf{0}$ entscheidet die **Hesse-Matrix**

$$H = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}_0) \right)$$

über die Art des kritischen Punktes:

- H positiv definit $\Longrightarrow$ striktes lokales **Minimum**;
- H negativ definit $\Longrightarrow$ striktes lokales **Maximum**;
- H indefinit $\Longrightarrow$ **Sattelpunkt**;
- H semidefinit, aber nicht definit $\Longrightarrow$ keine Entscheidung möglich.

H ist nach dem Satz von Schwarz symmetrisch – deshalb ist der Spektralsatz anwendbar und die Eigenwerte sind reell.
Das ist die vielleicht wichtigste Anwendung des Spektralsatzes in der Analysis: Der gesamte Bereich der Optimierung, vom Gradientenverfahren bis zum Training neuronaler Netze, beruht auf der lokalen Approximation durch quadratische Formen.

11 Die Singulärwertzerlegung

11.1 Die Verallgemeinerung, die alles umfasst

Der Spektralsatz ist schön, hat aber zwei Einschränkungen: Er gilt nur für *quadratische* und nur für *symmetrische* Matrizen. Die meisten Matrizen in der Praxis sind weder das eine noch das andere – eine Datenmatrix mit 10 000 Messungen und 50 Merkmalen ist $10\,000 \times 50$.

Die Singulärwertzerlegung (SVD) beseitigt beide Einschränkungen. Sie gilt für *jede* Matrix.

Satz 11.1 (Singulärwertzerlegung)**.** *Zu jeder Matrix $A \in \mathbb{R}^{m\times n}$ gibt es orthogonale Matrizen $U \in \mathbb{R}^{m\times m}$, $V \in \mathbb{R}^{n\times n}$ und eine „Diagonalmatrix“ $\Sigma \in \mathbb{R}^{m\times n}$ mit*

$$A = U\Sigma V^{\mathsf{T}}, \qquad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix},$$

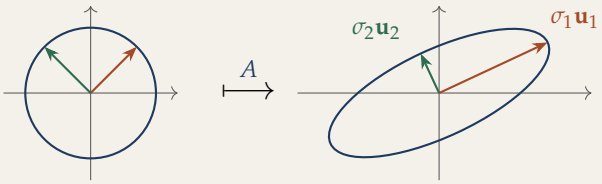
*wobei $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ und $r = \operatorname{Rang} A$. Die σ_i heißen **Singulärwerte** und sind eindeutig bestimmt.*

Was die SVD geometrisch aussagt

Jede lineare Abbildung lässt sich zerlegen in:

1. eine **Drehung/Spiegelung** im Urbildraum (V^{T}),
2. eine **Skalierung** entlang der Koordinatenachsen (Σ),
3. eine **Drehung/Spiegelung** im Bildraum (U).

Anders gesagt: Jede lineare Abbildung bildet die Einheitskugel auf ein *Ellipsoid* ab. Die Singulärwerte sind die Halbachsenlängen, die Spalten von U die Halbachsenrichtungen.



Einheitskreis Ellipse

Konstruktiver Beweis. **Schritt 1 – Die Hilfsmatrix.** Betrachte $A^{\mathsf{T}}A \in \mathbb{R}^{n\times n}$. Diese Matrix ist

- *symmetrisch:* $(A^\mathsf{T}A)^\mathsf{T} = A^\mathsf{T}(A^\mathsf{T})^\mathsf{T} = A^\mathsf{T}A$;
- *positiv semidefinit:* $\mathbf{x}^\mathsf{T}A^\mathsf{T}A\mathbf{x} = \|A\mathbf{x}\|^2 \geq 0$.

Nach dem Spektralsatz gibt es eine ONB $(\mathbf{v}_1, \ldots, \mathbf{v}_n)$ des $\mathbb{R}^n$ aus Eigenvektoren mit Eigenwerten $\mu_1 \geq \cdots \geq \mu_n \geq 0$ (nichtnegativ wegen der Semidefinitheit).

Schritt 2 – Singulärwerte definieren. Setze $\sigma_i := \sqrt{\mu_i}$. Sei r die Anzahl der positiven μ_i.

Behauptung: $r = \operatorname{Rang} A$. Für $i > r$ ist

$$\|A\mathbf{v}_i\|^2 = \mathbf{v}_i^\mathsf{T}A^\mathsf{T}A\mathbf{v}_i = \mu_i\|\mathbf{v}_i\|^2 = 0,$$

also $A\mathbf{v}_i = \mathbf{0}$. Und für $i \leq r$ ist $\|A\mathbf{v}_i\| = \sigma_i > 0$. Da die $\mathbf{v}_i$ eine Basis bilden, ist $\operatorname{Bild} A = \operatorname{span}(A\mathbf{v}_1, \ldots, A\mathbf{v}_r)$, und diese Vektoren sind (siehe Schritt 3) orthogonal, also unabhängig. Somit $\operatorname{Rang} A = r$.

Schritt 3 – Die Bildvektoren. Für $i \leq r$ setze

$$\mathbf{u}_i := \frac{1}{\sigma_i}A\mathbf{v}_i.$$

Diese sind orthonormal:

$$\langle \mathbf{u}_i, \mathbf{u}_j\rangle = \frac{1}{\sigma_i\sigma_j}(A\mathbf{v}_i)^\mathsf{T}(A\mathbf{v}_j) = \frac{1}{\sigma_i\sigma_j}\mathbf{v}_i^\mathsf{T}A^\mathsf{T}A\mathbf{v}_j = \frac{\mu_j}{\sigma_i\sigma_j}\langle \mathbf{v}_i, \mathbf{v}_j\rangle = \frac{\sigma_j^2}{\sigma_i\sigma_j}\delta_{ij} = \delta_{ij}.$$

(Für $i = j$ ergibt sich $\sigma_i^2/\sigma_i^2 = 1$.) ✓

Schritt 4 – Ergänzen und zusammensetzen. Man ergänzt $(\mathbf{u}_1, \ldots, \mathbf{u}_r)$ zu einer ONB von $\mathbb{R}^m$ (Basisergänzung plus Gram–Schmidt). Setzt man die $\mathbf{u}_i$ als Spalten in U und die $\mathbf{v}_j$ in V, so gilt nach Konstruktion

$$A\mathbf{v}_i = \sigma_i\mathbf{u}_i \quad (i \leq r), \qquad A\mathbf{v}_i = \mathbf{0} \quad (i > r),$$

also $AV = U\Sigma$, und wegen $V^\mathsf{T} = V^{-1}$ folgt $A = U\Sigma V^\mathsf{T}$. ■

Die Beziehungen, die man sich merken sollte

$$A^\mathsf{T}A = V\Sigma^\mathsf{T}\Sigma V^\mathsf{T}, \qquad AA^\mathsf{T} = U\Sigma\Sigma^\mathsf{T}U^\mathsf{T}.$$

Also:

- Die $\mathbf{v}_i$ (**Rechtssingulärvektoren**) sind Eigenvektoren von $A^\mathsf{T}A$.
- Die $\mathbf{u}_i$ (**Linkssingulärvektoren**) sind Eigenvektoren von AA^T.
- Die σ_i^2 sind die gemeinsamen von null verschiedenen Eigenwerte beider Matrizen.

Für symmetrische positiv definite A gilt $\sigma_i = \lambda_i$ – die SVD fällt mit der Spektralzerlegung zusammen. Für symmetrische Matrizen mit negativen Eigenwerten ist $\sigma_i = |\lambda_i|$.

Aufgabe 11.1. Bestimmen Sie die SVD von

$$A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – $A^\mathsf{T}A$ berechnen.

$$A^\mathsf{T} = \begin{pmatrix} 3 & 4 \\ 0 & 5 \end{pmatrix}, \qquad A^\mathsf{T}A = \begin{pmatrix} 3 & 4 \\ 0 & 5 \end{pmatrix}\begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}.$$

Position $(1,1)$: $9+16=25$. $(1,2)$: $0+20=20$.
Position $(2,1)$: $0+20=20$. $(2,2)$: $0+25=25$.

$$A^\mathsf{T}A = \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix}.$$

Schritt 2 – Eigenwerte.

$$\chi(t) = (25-t)^2 - 400.$$

Also $(25-t)^2 = 400$, das heißt $25-t = \pm 20$:

$$\mu_1 = 45, \qquad \mu_2 = 5.$$

Kontrolle: Spur $= 50 = 45+5$ ✓; det $= 625-400 = 225 = 45\cdot 5$ ✓.

Singulärwerte:

$$\sigma_1 = \sqrt{45} = 3\sqrt{5} \approx 6{,}708, \qquad \sigma_2 = \sqrt{5} \approx 2{,}236.$$

Kontrolle über die Determinante: $\sigma_1\sigma_2 = 3\sqrt{5}\cdot\sqrt{5} = 15$, und $|\det A| = |3\cdot 5 - 0\cdot 4| = 15$ ✓.

Schritt 3 – Rechtssingulärvektoren.

Zu $\mu_1 = 45$:

$$A^\mathsf{T}A - 45I = \begin{pmatrix} -20 & 20 \\ 20 & -20 \end{pmatrix}.$$

Es bleibt $-v_1 + v_2 = 0$, also $v_1 = v_2$:

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Zu $\mu_2 = 5$:

$$A^\mathsf{T}A - 5I = \begin{pmatrix} 20 & 20 \\ 20 & 20 \end{pmatrix} \Longrightarrow v_1 + v_2 = 0.$$

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Schritt 4 – Linkssingulärvektoren über $\mathbf{u}_i = \frac{1}{\sigma_i} A\mathbf{v}_i$.

$$A\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 \\ 9 \end{pmatrix}.$$

$$\mathbf{u}_1 = \frac{1}{3\sqrt{5}} \cdot \frac{1}{\sqrt{2}}\begin{pmatrix} 3 \\ 9 \end{pmatrix} = \frac{3}{3\sqrt{10}}\begin{pmatrix} 1 \\ 3 \end{pmatrix} = \frac{1}{\sqrt{10}}\begin{pmatrix} 1 \\ 3 \end{pmatrix}.$$

Norm prüfen: $\frac{1}{10}(1+9) = 1$ ✓.

$$A\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}\begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 \\ -1 \end{pmatrix}.$$

$$\mathbf{u}_2 = \frac{1}{\sqrt{5}} \cdot \frac{1}{\sqrt{2}}\begin{pmatrix} 3 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{10}}\begin{pmatrix} 3 \\ -1 \end{pmatrix}.$$

Orthogonalitätsprobe: $\langle \mathbf{u}_1, \mathbf{u}_2 \rangle = \frac{1}{10}(1 \cdot 3 + 3 \cdot (-1)) = 0$ ✓.
Schritt 5 – Zerlegung hinschreiben.

$$U = \frac{1}{\sqrt{10}}\begin{pmatrix} 1 & 3 \\ 3 & -1 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{pmatrix}, \qquad V = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Schritt 6 – Probe: $U\Sigma V^{\mathsf{T}}$ ausrechnen.

$$U\Sigma = \frac{1}{\sqrt{10}}\begin{pmatrix} 1 & 3 \\ 3 & -1 \end{pmatrix}\begin{pmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{pmatrix} = \frac{\sqrt{5}}{\sqrt{10}}\begin{pmatrix} 3 & 3 \\ 9 & -1 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 & 3 \\ 9 & -1 \end{pmatrix}.$$

(Denn $\sqrt{5}/\sqrt{10} = 1/\sqrt{2}$.)
Nun mit $V^{\mathsf{T}} = \frac{1}{\sqrt{2}}\left(\begin{smallmatrix} 1 & 1 \\ 1 & -1 \end{smallmatrix}\right)$ (symmetrisch):

$$U\Sigma V^{\mathsf{T}} = \frac{1}{2}\begin{pmatrix} 3 & 3 \\ 9 & -1 \end{pmatrix}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = \frac{1}{2}\begin{pmatrix} 3+3 & 3-3 \\ 9-1 & 9+1 \end{pmatrix} = \frac{1}{2}\begin{pmatrix} 6 & 0 \\ 8 & 10 \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}. \checkmark$$

Geometrische Deutung. A bildet den Einheitskreis auf eine Ellipse mit Halbachsen $3\sqrt{5} \approx 6{,}71$ und $\sqrt{5} \approx 2{,}24$ ab. Die lange Halbachse zeigt in Richtung $(1,3)/\sqrt{10}$, also etwa $71{,}6°$ zur x-Achse.

11.2 Niedrigrangapproximation

Die Dyadendarstellung

Multipliziert man die SVD aus, so erhält man

$$A = \sum_{i=1}^{r} \sigma_i \, \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}.$$

Jeder Summand $\mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ ist eine Matrix vom *Rang 1* (alle Spalten sind Vielfache von $\mathbf{u}_i$).
Die Matrix ist also eine gewichtete Summe einfachster Bausteine – und die Gewichte $\sigma_1 \geq \sigma_2 \geq \dots$ sagen, wie wichtig jeder Baustein ist.

Satz 11.2 (Eckart–Young–Mirsky). *Sei $A_k := \sum_{i=1}^{k} \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ die abgeschnittene SVD. Dann ist A_k die* beste *Approximation von A durch eine Matrix vom Rang $\leq k$, sowohl bezüglich der Spektralnorm als auch der Frobeniusnorm:*

$$\min_{\operatorname{Rang} B \leq k} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1},$$

$$\min_{\operatorname{Rang} B \leq k} \|A - B\|_F = \|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

Warum dieser Satz so folgenreich ist

Er sagt: *Die optimale Datenkompression ist explizit berechenbar.* Man muss keine Optimierung durchführen – man schneidet die SVD ab.
Das ist in der Mathematik selten. Die meisten Approximationsprobleme haben keine geschlossene Lösung.
Rechenbeispiel Bildkompression. Ein Graustufenbild mit 1000×1000 Pixeln braucht 10^6 Zahlen. Die Rang-k-Approximation braucht

$$k \cdot (1000 + 1000 + 1) \approx 2001k$$

Zahlen. Bei $k = 50$ sind das etwa 100 000 – ein Zehntel. Für natürliche Bilder fallen die Singulärwerte rasch ab, sodass der Qualitätsverlust bei $k = 50$ oft kaum wahrnehmbar ist.
(In der Praxis benutzt man für Bilder JPEG, das auf der diskreten Kosinustransformation beruht und noch effizienter ist. Das Prinzip – Transformation in eine Basis, in der die Information konzentriert ist, dann Abschneiden – ist dasselbe.)

11.3 Die Pseudoinverse

Definition 11.3. Zu $A = U\Sigma V^{\mathsf{T}}$ sei

$$A^{+} := V\Sigma^{+}U^{\mathsf{T}}, \qquad \Sigma^{+} = \operatorname{diag}\left(\tfrac{1}{\sigma_1}, \dots, \tfrac{1}{\sigma_r}, 0, \dots, 0\right)$$

die **Moore–Penrose-Pseudoinverse**.

Satz 11.4. $\mathbf{x}^+ := A^+\mathbf{b}$ *ist unter allen Vektoren, die* $\|A\mathbf{x} - \mathbf{b}\|$ *minimieren, derjenige mit kleinster Norm.*

Warum man die Pseudoinverse den Normalgleichungen vorzieht

In Kapitel 9 haben wir kleinste Quadrate über $A^\mathsf{T}A\mathbf{x} = A^\mathsf{T}\mathbf{b}$ gelöst. Das funktioniert – aber es gibt ein numerisches Problem:

$$\operatorname{cond}(A^\mathsf{T}A) = \operatorname{cond}(A)^2.$$

Die Konditionszahl wird *quadriert*. Ist A schon mäßig schlecht konditioniert (etwa 10^6), so hat $A^\mathsf{T}A$ die Kondition 10^{12} – bei doppelter Genauigkeit ($\approx 10^{16}$) bleiben nur noch vier gültige Stellen.
Die SVD (oder eine QR-Zerlegung) vermeidet das Quadrieren. Sie ist teurer, aber verlässlich. **Faustregel der numerischen Linearen Algebra:** Bilden Sie nie $A^\mathsf{T}A$, wenn Sie es vermeiden können.
Ferner behandelt die Pseudoinverse den Fall Rang $A < n$ korrekt, in dem $A^\mathsf{T}A$ gar nicht invertierbar wäre – sie liefert dann die Lösung minimaler Norm.

11.4 Hauptkomponentenanalyse

PCA in fünf Schritten

Gegeben eine Datenmatrix $X \in \mathbb{R}^{m\times n}$ mit m Beobachtungen und n Merkmalen.

1. **Zentrieren.** Von jeder Spalte den Mittelwert abziehen: $\tilde{X}$.
2. **Kovarianzmatrix.** $C = \frac{1}{m-1}\tilde{X}^\mathsf{T}\tilde{X}$ – symmetrisch und positiv semidefinit.
3. **Spektralzerlegung.** $C = Q\Lambda Q^\mathsf{T}$ mit $\lambda_1 \geq \lambda_2 \geq \dots$
4. **Hauptkomponenten.** Die Spalten von Q sind die Richtungen maximaler Varianz; λ_i ist die Varianz entlang der i-ten Richtung.
5. **Projizieren.** $\tilde{X}Q_k$ mit den ersten k Spalten reduziert die Dimension auf k.

Der Anteil erklärter Varianz ist $\frac{\lambda_1+\dots+\lambda_k}{\lambda_1+\dots+\lambda_n}$.
Der Zusammenhang zur SVD: Ist $\tilde{X} = U\Sigma V^\mathsf{T}$, so ist $C = \frac{1}{m-1}V\Sigma^\mathsf{T}\Sigma V^\mathsf{T}$. Die Hauptkomponenten sind also die Rechtssingulärvektoren, und $\lambda_i = \sigma_i^2/(m-1)$. Man berechnet PCA in der Praxis *immer* über die SVD von $\tilde{X}$, nie über die Kovarianzmatrix – aus dem eben genannten Konditionsgrund.

Aufgabe 11.2. Führen Sie eine PCA für die zentrierten Daten

$$\tilde{X} = \begin{pmatrix} 2 & 1 \\ -2 & -1 \\ 1 & 2 \\ -1 & -2 \end{pmatrix}$$

durch.

Lösung Schritt für Schritt.

Schritt 1 – Zentrierung prüfen. Spaltensummen: $2-2+1-1=0$ ✓; $1-1+2-2=0$ ✓. Die Daten sind bereits zentriert.

Schritt 2 – Kovarianzmatrix. Mit $m=4$, also $m-1=3$:

$$\tilde{X}^{\mathsf{T}}\tilde{X} = \begin{pmatrix} 2 & -2 & 1 & -1 \\ 1 & -1 & 2 & -2 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ -2 & -1 \\ 1 & 2 \\ -1 & -2 \end{pmatrix}.$$

Position $(1,1)$: $4+4+1+1=10$.
Position $(1,2)$: $2+2+2+2=8$.
Position $(2,2)$: $1+1+4+4=10$.

$$\tilde{X}^{\mathsf{T}}\tilde{X} = \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix}, \qquad C = \frac{1}{3}\begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix}.$$

Schritt 3 – Eigenwerte von $\tilde{X}^{\mathsf{T}}\tilde{X}$.

$$(10-t)^2 - 64 = 0 \Longrightarrow 10-t = \pm 8 \Longrightarrow t_1 = 18,\ t_2 = 2.$$

Die Eigenwerte von C sind also $\lambda_1 = 6$ und $\lambda_2 = \frac{2}{3}$.

Schritt 4 – Eigenvektoren. Für $t=18$: $-8v_1+8v_2=0$, also $v_1=v_2$:

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Für $t=2$: $8v_1+8v_2=0$:

$$\mathbf{q}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Schritt 5 – Interpretation.
Erklärte Varianz der ersten Hauptkomponente:

$$\frac{6}{6+\frac{2}{3}} = \frac{6}{20/3} = \frac{18}{20} = 90\,\%.$$

Die Daten liegen also weitgehend entlang der Richtung $(1,1)$ – die beiden Merkmale sind stark positiv korreliert.

Schritt 6 – Projektion auf eine Dimension. Die neuen Koordinaten sind $\tilde{X}\mathbf{q}_1$:

$$\frac{1}{\sqrt{2}}\begin{pmatrix} 2+1 \\ -2-1 \\ 1+2 \\ -1-2 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 3 \\ -3 \\ 3 \\ -3 \end{pmatrix} \approx \begin{pmatrix} 2{,}12 \\ -2{,}12 \\ 2{,}12 \\ -2{,}12 \end{pmatrix}.$$

Die vier Datenpunkte reduzieren sich auf zwei Werte – was die starke Struktur der konstruierten Daten widerspiegelt.

Schritt 7 – Kontrolle. Die Varianz der projizierten Daten sollte $\lambda_1 = 6$ sein:

$$\frac{1}{3}\left(4 \cdot \frac{9}{2}\right) = \frac{18}{3} = 6.\checkmark$$

Wo die SVD heute überall steckt

Empfehlungssysteme. Beim Netflix-Preis (2006–2009) waren SVD-basierte Verfahren die Grundlage der Siegerlösung. Die Nutzer-Film-Matrix ist riesig und größtenteils unbekannt; man sucht eine Niedrigrangapproximation, die die bekannten Einträge gut trifft. Die *latenten Faktoren* entsprechen dabei interpretierbaren Dimensionen wie „Anteil Action“ oder „Erscheinungsjahr“.

Latent Semantic Analysis. In der Textanalyse zerlegt man die Term-Dokument-Matrix; die Singulärvektoren entsprechen „Themen“. Das ist der historische Vorläufer moderner Wort-Einbettungen.

Modellkompression. Große Sprachmodelle enthalten Gewichtsmatrizen mit Milliarden Einträgen. Verfahren wie **LoRA** (Low-Rank Adaptation, Hu et al. 2021) trainieren statt der vollen Matrix nur eine Niedrigrangkorrektur $\Delta W = BA$ mit Rang $\leq r$. Bei $r = 8$ und einer 4096×4096-Matrix reduziert sich die Zahl der trainierbaren Parameter von 16,8 Millionen auf 65 536 – ein Faktor 256. Das ist Eckart–Young in der Praxis.

Robuste Statistik. Die Konditionszahl $\operatorname{cond}(A) = \sigma_1/\sigma_r$ misst, wie empfindlich ein Problem auf Störungen reagiert. Sie ist unmittelbar aus der SVD ablesbar.

Bildentrauschen und Matrixvervollständigung. Der Ansatz „finde die Matrix niedrigsten Ranges, die zu den Beobachtungen passt“ ist NP-schwer; CANDÈS und RECHT zeigten 2009, dass die Ersetzung des Rangs durch die **Nuklearnorm** $\sum_i \sigma_i$ (die konvexe Hülle) unter milden Bedingungen dasselbe Ergebnis liefert – eines der einflussreichsten Resultate der letzten zwanzig Jahre in diesem Feld.

Part VII

Numerik und aktueller Stand

12 Numerische lineare Algebra

12.1 Warum exakte Mathematik nicht genügt

Alles bisher Bewiesene ist richtig – in exakter Arithmetik. Ein Computer rechnet aber mit endlich vielen Stellen. Bei doppelter Genauigkeit sind das etwa 16 Dezimalstellen; die **Maschinengenauigkeit** beträgt

$$\varepsilon_{\text{mach}} = 2^{-52} \approx 2{,}22 \cdot 10^{-16}.$$

Aufgabe 12.1. Lösen Sie das System

$$\begin{aligned} 0{,}0001\,x \;+\; y &= 1 \\ x \;+\; y &= 2 \end{aligned}$$

einmal mit dem Pivotelement 0,0001 und einmal mit Zeilentausch – unter der Annahme, dass nur drei signifikante Stellen zur Verfügung stehen.

Lösung Schritt für Schritt.

Die exakte Lösung. Subtraktion der Gleichungen liefert $(1 - 0{,}0001)x = 1$, also

$$x = \frac{1}{0{,}9999} = 1{,}00010\ldots, \qquad y = 2 - x = 0{,}99990\ldots$$

Variante A – ohne Zeilentausch. Wir eliminieren mit dem Faktor

$$\ell = \frac{1}{0{,}0001} = 10\,000.$$

Zeile 2 neu: y-Koeffizient wird $1 - 10\,000 \cdot 1 = -9999$, rechte Seite $2 - 10\,000 \cdot 1 = -9998$.
Auf drei Stellen gerundet: $-9999 \to -1{,}00 \cdot 10^4$ und $-9998 \to -1{,}00 \cdot 10^4$.
Also

$$y = \frac{-1{,}00 \cdot 10^4}{-1{,}00 \cdot 10^4} = 1{,}00.$$

Rückwärtseinsetzen in Zeile 1:

$$0{,}0001\,x = 1 - 1{,}00 = 0 \quad \Longrightarrow \quad x = 0.$$

Ergebnis: $x = 0$, $y = 1$. Der Wert von y ist auf drei Stellen richtig, aber x ist *katastrophal* falsch – der wahre Wert ist etwa 1.
Warum? Die Information über x steckte in der Differenz $2 - 10\,000$, und bei der Rundung ging der Term „2“ vollständig verloren. Man nennt das **Auslöschung**.

Variante B – mit Zeilentausch. Wir tauschen zuerst:

$$x + y = 2, \qquad 0{,}0001x + y = 1.$$

Eliminationsfaktor $\ell = 0{,}0001$. Zeile 2 neu:

$$y\text{-Koeffizient} : 1 - 0{,}0001 = 0{,}9999 \to 1{,}00 \text{ (drei Stellen)},$$

$$\text{rechte Seite} : 1 - 0{,}0001 \cdot 2 = 0{,}9998 \to 1{,}00.$$

Also $y = 1{,}00$. Rückwärtseinsetzen:

$$x = 2 - 1{,}00 = 1{,}00.$$

Ergebnis: $x = 1{,}00$, $y = 1{,}00$ – beide auf drei Stellen korrekt. ✓
Die Lehre. Dasselbe Verfahren, dieselbe Genauigkeit, völlig verschiedene Ergebnisse. Der Unterschied liegt allein in der Reihenfolge der Zeilen.

Spaltenpivotisierung

Man wählt in jedem Eliminationsschritt als Pivot das betragsgrößte Element der aktuellen Spalte und tauscht es nach oben. Damit sind alle Eliminationsfaktoren betragsmäßig ≤ 1, und Fehler werden nicht verstärkt.
Das ist die *Standardvariante* in jeder Bibliothek. Die Zerlegung lautet dann

$$PA = LR$$

mit einer Permutationsmatrix P. In LAPACK heißt die Routine `dgetrf`.
Vollständige Pivotisierung (Suche über die ganze Restmatrix) ist theoretisch noch stabiler, aber teurer und praktisch fast nie nötig.

12.2 Kondition

Definition 12.1. Für eine invertierbare Matrix ist die **Konditionszahl**

$$\operatorname{cond}(A) := \|A\| \cdot \|A^{-1}\|.$$

Bezüglich der Spektralnorm gilt $\operatorname{cond}_2(A) = \sigma_1/\sigma_n$ – das Verhältnis von größtem zu kleinstem Singulärwert.

Satz 12.2 (Fehlerabschätzung). *Sei $A\mathbf{x} = \mathbf{b}$ und $A\tilde{\mathbf{x}} = \mathbf{b} + \Delta\mathbf{b}$. Dann gilt*

$$\frac{\|\tilde{\mathbf{x}} - \mathbf{x}\|}{\|\mathbf{x}\|} \leq \operatorname{cond}(A) \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}.$$

Beweis. Aus $A(\tilde{\mathbf{x}} - \mathbf{x}) = \Delta\mathbf{b}$ folgt $\tilde{\mathbf{x}} - \mathbf{x} = A^{-1}\Delta\mathbf{b}$, also

$$\|\tilde{\mathbf{x}} - \mathbf{x}\| \leq \|A^{-1}\| \, \|\Delta\mathbf{b}\|.$$

Ferner ist $\|\mathbf{b}\| = \|A\mathbf{x}\| \le \|A\|\,\|\mathbf{x}\|$, also $\frac{1}{\|\mathbf{x}\|} \le \frac{\|A\|}{\|\mathbf{b}\|}$. Multiplikation beider Ungleichungen liefert die Behauptung. ∎

Die Faustregel

Man verliert etwa $\log_{10}\operatorname{cond}(A)$ *Dezimalstellen an Genauigkeit.*
Bei $\operatorname{cond}(A) = 10^{10}$ und doppelter Genauigkeit (16 Stellen) bleiben also nur etwa 6 gültige Stellen – unabhängig davon, wie gut der Algorithmus ist. Das ist keine Schwäche des Verfahrens, sondern eine Eigenschaft des *Problems*.
Das berüchtigte Beispiel ist die **Hilbert-Matrix** $H_{ij} = \frac{1}{i+j-1}$:

$$\operatorname{cond}(H_{10}) \approx 1{,}6 \cdot 10^{13}, \qquad \operatorname{cond}(H_{20}) \approx 10^{28}.$$

Bei $n = 20$ ist das Problem in doppelter Genauigkeit vollständig unlösbar – *kein* Ergebnis hat auch nur eine gültige Stelle.

12.3 QR-Zerlegung mit Householder-Reflexionen

Satz 12.3 (QR-Zerlegung). *Zu jeder Matrix $A \in \mathbb{R}^{m\times n}$ mit $m \ge n$ gibt es eine orthogonale Matrix $Q \in \mathbb{R}^{m\times m}$ und eine obere Dreiecksmatrix R mit*

$$A = QR.$$

Householder-Reflexionen

Zu einem Vektor $\mathbf{w}$ mit $\|\mathbf{w}\| = 1$ ist

$$H = I - 2\mathbf{w}\mathbf{w}^{\mathsf{T}}$$

die Spiegelung an der Hyperebene $\mathbf{w}^{\perp}$.
Eigenschaften: H ist symmetrisch und orthogonal ($H^2 = I$), und $\det H = -1$.
Der Trick: Zu jedem Vektor $\mathbf{a}$ findet man ein $\mathbf{w}$, sodass $H\mathbf{a}$ ein Vielfaches von $\mathbf{e}_1$ ist – man spiegelt $\mathbf{a}$ auf die erste Koordinatenachse. Konkret:

$$\mathbf{v} := \mathbf{a} + \operatorname{sign}(a_1)\|\mathbf{a}\|\,\mathbf{e}_1, \qquad \mathbf{w} := \frac{\mathbf{v}}{\|\mathbf{v}\|}.$$

Das Vorzeichen wird so gewählt, dass keine Auslöschung auftritt.
Nacheinander angewandt auf die Spalten erzeugt das die Dreiecksform. Aufwand: $\frac{4}{3}n^3$ für $m = n$ – doppelt so teuer wie LR, dafür *rückwärtsstabil* ohne jede Pivotisierung.

Aufgabe 12.2. Bestimmen Sie eine Householder-Matrix, die $\mathbf{a} = (3, 4)$ auf ein Vielfaches von $\mathbf{e}_1$ abbildet.

Lösung Schritt für Schritt.

Schritt 1 – Norm. $\|\mathbf{a}\| = \sqrt{9+16} = 5$.
Schritt 2 – Hilfsvektor. Da $a_1 = 3 > 0$, wählen wir das Vorzeichen $+$:

$$\mathbf{v} = \begin{pmatrix}3\\4\end{pmatrix} + 5\begin{pmatrix}1\\0\end{pmatrix} = \begin{pmatrix}8\\4\end{pmatrix}.$$

$$\|\mathbf{v}\| = \sqrt{64+16} = \sqrt{80} = 4\sqrt{5}.$$

Schritt 3 – Reflexionsmatrix. Es ist $\mathbf{w} = \frac{1}{4\sqrt{5}}\binom{8}{4} = \frac{1}{\sqrt{5}}\binom{2}{1}$.

$$\mathbf{w}\mathbf{w}^{\mathsf{T}} = \frac{1}{5}\begin{pmatrix}2\\1\end{pmatrix}(2\ \ 1) = \frac{1}{5}\begin{pmatrix}4 & 2\\2 & 1\end{pmatrix}.$$

$$H = I - 2\mathbf{w}\mathbf{w}^{\mathsf{T}} = \begin{pmatrix}1 & 0\\0 & 1\end{pmatrix} - \frac{2}{5}\begin{pmatrix}4 & 2\\2 & 1\end{pmatrix} = \begin{pmatrix}1-\frac{8}{5} & -\frac{4}{5}\\-\frac{4}{5} & 1-\frac{2}{5}\end{pmatrix} = \frac{1}{5}\begin{pmatrix}-3 & -4\\-4 & 3\end{pmatrix}.$$

Schritt 4 – Wirkung prüfen.

$$H\mathbf{a} = \frac{1}{5}\begin{pmatrix}-3 & -4\\-4 & 3\end{pmatrix}\begin{pmatrix}3\\4\end{pmatrix} = \frac{1}{5}\begin{pmatrix}-9-16\\-12+12\end{pmatrix} = \frac{1}{5}\begin{pmatrix}-25\\0\end{pmatrix} = \begin{pmatrix}-5\\0\end{pmatrix}.\checkmark$$

Das Ergebnis ist $-\|\mathbf{a}\|\,\mathbf{e}_1$ – die Länge bleibt erhalten (5), wie es sich für eine Spiegelung gehört.
Schritt 5 – Orthogonalität prüfen.

$$H^{\mathsf{T}}H = \frac{1}{25}\begin{pmatrix}-3 & -4\\-4 & 3\end{pmatrix}\begin{pmatrix}-3 & -4\\-4 & 3\end{pmatrix} = \frac{1}{25}\begin{pmatrix}9+16 & 12-12\\12-12 & 16+9\end{pmatrix} = I.\checkmark$$

Warum das Vorzeichen wichtig war. Hätten wir $\mathbf{v} = \mathbf{a} - 5\mathbf{e}_1 = (-2, 4)$ gewählt, wäre die erste Komponente eine Differenz fast gleich großer Zahlen gewesen. Bei $\mathbf{a} = (5, 0{,}001)$ etwa wäre $a_1 - \|\mathbf{a}\| \approx 5 - 5{,}000\,000\,1$ – reine Auslöschung. Die Regel „gleiches Vorzeichen wie a_1“ vermeidet das systematisch.

12.4 Cholesky-Zerlegung

Satz 12.4 (Cholesky). *Ist A symmetrisch und positiv definit, so gibt es genau eine untere Dreiecksmatrix L mit positiver Diagonale und*

$$A = LL^{\mathsf{T}}.$$

Der Aufwand beträgt $\frac{1}{3}n^3$ – die Hälfte *der LR-Zerlegung.*

Die Rekursionsformeln

$$\ell_{jj} = \sqrt{a_{jj} - \sum_{k<j} \ell_{jk}^2}, \qquad \ell_{ij} = \frac{1}{\ell_{jj}} \left(a_{ij} - \sum_{k<j} \ell_{ik}\ell_{jk} \right) \quad (i > j).$$

Ein kostenloser Definitheitstest: Bricht das Verfahren ab, weil unter einer Wurzel eine nichtpositive Zahl steht, so ist A *nicht* positiv definit. Das ist der schnellste bekannte Test – schneller als die Berechnung der Eigenwerte oder der Hauptminoren.

Aufgabe 12.3. Bestimmen Sie die Cholesky-Zerlegung von

$$A = \begin{pmatrix} 4 & 2 & -2 \\ 2 & 5 & -1 \\ -2 & -1 & 6 \end{pmatrix}.$$

Lösung Schritt für Schritt.

Schritt 1 – Erste Spalte.

$$\ell_{11} = \sqrt{a_{11}} = \sqrt{4} = 2.$$

$$\ell_{21} = \frac{a_{21}}{\ell_{11}} = \frac{2}{2} = 1, \qquad \ell_{31} = \frac{a_{31}}{\ell_{11}} = \frac{-2}{2} = -1.$$

Schritt 2 – Zweite Spalte.

$$\ell_{22} = \sqrt{a_{22} - \ell_{21}^2} = \sqrt{5 - 1} = 2.$$

$$\ell_{32} = \frac{1}{\ell_{22}} (a_{32} - \ell_{31}\ell_{21}) = \frac{1}{2}\big(-1 - (-1)(1)\big) = \frac{1}{2}(-1 + 1) = 0.$$

Schritt 3 – Dritte Spalte.

$$\ell_{33} = \sqrt{a_{33} - \ell_{31}^2 - \ell_{32}^2} = \sqrt{6 - 1 - 0} = \sqrt{5}.$$

Ergebnis.

$$L = \begin{pmatrix} 2 & 0 & 0 \\ 1 & 2 & 0 \\ -1 & 0 & \sqrt{5} \end{pmatrix}.$$

Schritt 4 – Probe: LL^{T}.

$$L^{\mathsf{T}} = \begin{pmatrix} 2 & 1 & -1 \\ 0 & 2 & 0 \\ 0 & 0 & \sqrt{5} \end{pmatrix}.$$

Zeile 1 von L ist $(2, 0, 0)$:

$$(2, 0, 0) \cdot \text{Spalten von } L^{\mathsf{T}}: \quad 4, \quad 2, \quad -2. \checkmark$$

Zeile 2 ist $(1, 2, 0)$:

$$1 \cdot 2 = 2; \qquad 1 \cdot 1 + 2 \cdot 2 = 5; \qquad 1 \cdot (-1) + 2 \cdot 0 = -1. \checkmark$$

Zeile 3 ist $(-1, 0, \sqrt{5})$:

$$-2; \qquad -1; \qquad 1 + 0 + 5 = 6. \checkmark$$

Nebenergebnis: Da alle Wurzeln positiv waren, ist A positiv definit.
Zweites Nebenergebnis: $\det A = (\det L)^2 = (2 \cdot 2 \cdot \sqrt{5})^2 = (4\sqrt{5})^2 = 80$.

12.5 Iterative Verfahren

Bei sehr großen, dünn besetzten Matrizen – etwa aus der Diskretisierung partieller Differentialgleichungen – ist $O(n^3)$ untragbar. Man iteriert stattdessen.

Die klassischen Splitting-Verfahren

Man zerlegt $A = D + L + R$ (Diagonale, strikt unterer, strikt oberer Teil).
Jacobi: $\mathbf{x}^{(k+1)} = D^{-1}\big(\mathbf{b} - (L + R)\mathbf{x}^{(k)}\big)$.
Gauß–Seidel: $\mathbf{x}^{(k+1)} = (D + L)^{-1}\big(\mathbf{b} - R\mathbf{x}^{(k)}\big)$ – man benutzt bereits aktualisierte Komponenten sofort.
SOR (Überrelaxation): Gauß–Seidel mit einem Extrapolationsfaktor $\omega \in (1, 2)$.
Konvergenz genau dann, wenn der Spektralradius der Iterationsmatrix kleiner als 1 ist. Hinreichend ist strikte Diagonaldominanz:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \text{für alle } i.$$

Satz 12.5 (Verfahren der konjugierten Gradienten, Hestenes–Stiefel 1952)**.** *Für symmetrisches, positiv definites A liefert das CG-Verfahren in exakter Arithmetik nach höchstens n Schritten die exakte Lösung. Der Fehler nach k Schritten erfüllt*

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}\|_A, \qquad \kappa = \operatorname{cond}_2(A).$$

Warum CG so wichtig ist

Der Aufwand pro Schritt ist *eine* Matrix-Vektor-Multiplikation. Bei einer dünn besetzten Matrix mit $O(n)$ Einträgen kostet das $O(n)$ statt $O(n^3)$.
Der Faktor $\sqrt{\kappa}$ statt κ in der Konvergenzrate ist der eigentliche Durchbruch: Bei $\kappa = 10^6$ braucht ein einfaches Gradientenverfahren etwa 10^6 Schritte, CG etwa 10^3.

Durch **Vorkonditionierung** – Ersetzen von $A\mathbf{x} = \mathbf{b}$ durch $M^{-1}A\mathbf{x} = M^{-1}\mathbf{b}$ mit einem leicht invertierbaren $M \approx A$ – lässt sich κ weiter drücken. Die Wahl von M ist eine Kunst für sich und Gegenstand aktiver Forschung.
Für unsymmetrische Systeme gibt es Verwandte: GMRES (Saad–Schultz 1986), BiCGSTAB, IDR(s).

12.6 Eigenwertberechnung

Warum man niemals das charakteristische Polynom benutzt

Der Schulweg – Polynom aufstellen, Nullstellen suchen – ist numerisch katastrophal. Zwei Gründe:
1. Die Nullstellen eines Polynoms reagieren extrem empfindlich auf Koeffizientenstörungen. Das **Wilkinson-Polynom**

$$p(x) = \prod_{k=1}^{20}(x-k)$$

hat die Nullstellen $1, \dots, 20$. Ändert man den Koeffizienten von x^{19} um $2^{-23} \approx 10^{-7}$, so wandern die Nullstellen 16 und 17 in die komplexe Ebene ab, mit Imaginärteilen von etwa $\pm 2{,}8$.
2. Nach Abel–Ruffini gibt es ab Grad 5 ohnehin keine Lösungsformel. Man müsste iterieren – also kann man auch gleich die Matrix iterativ behandeln.
Ironie der Geschichte: MATLAB berechnet Polynomnullstellen, indem es die *Begleitmatrix* aufstellt und deren Eigenwerte bestimmt. Genau umgekehrt zum Schulweg.

Die Potenzmethode

$$\mathbf{x}^{(k+1)} = \frac{A\mathbf{x}^{(k)}}{\|A\mathbf{x}^{(k)}\|}.$$

Konvergiert gegen den Eigenvektor zum betragsgrößten Eigenwert, mit Rate $|\lambda_2/\lambda_1|^k$.
Varianten:

- *Inverse Iteration* mit A^{-1}: liefert den betragskleinsten Eigenwert.
- *Inverse Iteration mit Shift* $(A-\mu I)^{-1}$: liefert den Eigenwert nahe μ – und konvergiert umso schneller, je besser μ geschätzt ist.
- *Rayleigh-Quotienten-Iteration*: aktualisiert μ in jedem Schritt durch $\mu = \frac{\mathbf{x}^{\mathsf{T}}A\mathbf{x}}{\mathbf{x}^{\mathsf{T}}\mathbf{x}}$. Konvergiert für symmetrische Matrizen *kubisch* – die Stellenzahl verdreifacht sich pro Schritt.

PageRank ist nichts anderes als die Potenzmethode auf einer sehr großen Matrix.

Der QR-Algorithmus

Das Standardverfahren für alle Eigenwerte:

$$A_0 := A; \qquad A_k = Q_k R_k \text{ (QR-Zerlegung)}, \qquad A_{k+1} := R_k Q_k.$$

Man zerlegt und multipliziert in umgekehrter Reihenfolge zurück. Da $A_{k+1} = R_k Q_k = Q_k^{\mathsf{T}} A_k Q_k$, sind alle A_k ähnlich – die Eigenwerte bleiben erhalten. Unter milden Bedingungen konvergiert A_k gegen eine obere Dreiecksmatrix, deren Diagonale die Eigenwerte trägt.

In der Praxis kombiniert man das mit einer Vorab-Reduktion auf **Hessenberg-Form** (obere Dreiecksmatrix plus eine Nebendiagonale) und mit **Shift-Strategien** (Wilkinson-Shift), was den Aufwand von $O(n^4)$ auf $O(n^3)$ senkt.

Der Algorithmus wurde 1961 unabhängig von JOHN FRANCIS in England und VERA KUBLANOVSKAYA in der Sowjetunion gefunden. Er gilt als einer der zehn einflussreichsten Algorithmen des 20. Jahrhunderts – so das gemeinsame Ranking von *Computing in Science & Engineering* (2000), in dem er neben dem Simplexverfahren, der schnellen Fourier-Transformation und dem Metropolis-Algorithmus steht.

Bemerkenswert ist, dass Francis' Arbeit lange kaum beachtet wurde; er verließ die Wissenschaft und arbeitete jahrzehntelang in der Industrie, ohne zu wissen, welche Bedeutung sein Verfahren erlangt hatte. Erst 2007 wurde er von der Fachgemeinschaft wiederentdeckt und geehrt.

Die Aufwandstabelle

Aufgabe	Verfahren	Aufwand
LGS, allgemein	LR mit Pivotisierung	$\frac{2}{3}n^3$
LGS, symmetrisch pos. definit	Cholesky	$\frac{1}{3}n^3$
LGS, dünn besetzt	CG / GMRES	$O(n)$ pro Schritt
Kleinste Quadrate	QR (Householder)	$2mn^2 - \frac{2}{3}n^3$
Eigenwerte, symmetrisch	QR mit Shifts	$\approx 9n^3$ (mit Vektoren)
Eigenwerte, allgemein	Hessenberg + QR	$\approx 25n^3$
SVD	Golub–Kahan	$\approx 21n^3$

Alle Werte für $n \times n$ bzw. $m \times n$ und übliche Implementierungen (LAPACK).

13 Der aktuelle Forschungsstand

Dieses Kapitel gibt eine Bestandsaufnahme mit Stand August 2026. Es ist naturgemäß dasjenige, das am schnellsten veraltet – gerade deshalb sind alle Angaben mit Quellen versehen.

13.1 Wie schnell kann man Matrizen multiplizieren?

Die naive Schranke

Die Definition der Matrixmultiplikation liefert für zwei $n \times n$-Matrizen

$$n^2 \text{ Einträge} \times n \text{ Multiplikationen} = n^3$$

Operationen. Bis 1969 hielten praktisch alle Fachleute das für optimal. VOLKER STRASSEN wollte sogar beweisen, dass es nicht besser geht – und fand dabei das Gegenteil.

Der Algorithmus von Strassen (1969)

Für 2×2-Blockmatrizen

$$\begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix} = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}$$

braucht man naiv *acht* Blockmultiplikationen. Strassen kommt mit *sieben* aus:

$$\begin{aligned} M_1 &= (A_{11} + A_{22})(B_{11} + B_{22}) \\ M_2 &= (A_{21} + A_{22})B_{11} \\ M_3 &= A_{11}(B_{12} - B_{22}) \\ M_4 &= A_{22}(B_{21} - B_{11}) \\ M_5 &= (A_{11} + A_{12})B_{22} \\ M_6 &= (A_{21} - A_{11})(B_{11} + B_{12}) \\ M_7 &= (A_{12} - A_{22})(B_{21} + B_{22}) \end{aligned}$$

Daraus setzt man zusammen:

$$C_{11} = M_1 + M_4 - M_5 + M_7, \quad C_{12} = M_3 + M_5,$$

$$C_{21} = M_2 + M_4, \quad C_{22} = M_1 - M_2 + M_3 + M_6.$$

Verifikation von C_{12}:

$$M_3 + M_5 = A_{11}B_{12} - A_{11}B_{22} + A_{11}B_{22} + A_{12}B_{22} = A_{11}B_{12} + A_{12}B_{22}. \checkmark$$

Verifikation von C_{21}:

$$M_2 + M_4 = A_{21}B_{11} + A_{22}B_{11} + A_{22}B_{21} - A_{22}B_{11} = A_{21}B_{11} + A_{22}B_{21}. \checkmark$$

Der Preis: Man handelt eine Multiplikation gegen 18 Additionen ein. Bei Zahlen wäre das ein schlechtes Geschäft – bei *Blöcken* nicht, denn Multiplikation ist $O(n^3)$, Addition nur $O(n^2)$.

Satz 13.1. *Rekursive Anwendung von Strassens Verfahren führt auf die Laufzeit*

$$T(n) = 7\,T(n/2) + O(n^2) \quad \Longrightarrow \quad T(n) = O\Big(n^{\log_2 7}\Big) = O\big(n^{2{,}807\ldots}\big)\,.$$

Beweis. Nach dem Master-Theorem der Rekursionsanalyse: Bei $T(n) = a\,T(n/b) + O(n^d)$ mit $a > b^d$ gilt $T(n) = \Theta(n^{\log_b a})$. Hier ist $a = 7$, $b = 2$, $d = 2$, und $7 > 4$. Also

$$T(n) = \Theta\Big(n^{\log_2 7}\Big)\,, \qquad \log_2 7 = \frac{\ln 7}{\ln 2} \approx \frac{1{,}9459}{0{,}6931} \approx 2{,}8074. \qquad \blacksquare$$

Wann sich Strassen lohnt

Die versteckte Konstante ist größer als beim naiven Verfahren, deshalb rentiert sich der Wechsel erst ab einer gewissen Größe. Die **Übergangsschwelle** liegt in optimierten Implementierungen bei etwa $n \approx 500$ bis 1000.
Bei $n = 10\,000$ beträgt der theoretische Gewinn

$$\frac{n^3}{n^{2{,}807}} = n^{0{,}193} \approx 10\,000^{0{,}193} \approx 5{,}6.$$

Das ist real. Bibliotheken wie Intel MKL und einige BLAS-Implementierungen schalten bei großen Matrizen auf Strassen um.
Der Haken: Strassen ist numerisch weniger stabil als das naive Verfahren. Die Fehlerschranke ist nicht mehr elementweise, sondern nur noch normweise. Für sicherheitskritische Anwendungen wird das Verfahren deshalb gemieden.

Der Exponent ω

Definition 13.2. Der **Matrixmultiplikationsexponent** ω ist das Infimum aller c, für die zwei $n \times n$-Matrizen in $O(n^c)$ Operationen multipliziert werden können.

Was man weiß

Untere Schranke: $\omega \geq 2$. Denn man muss allein die $2n^2$ Eingabeeinträge lesen und n^2 Ausgabeeinträge schreiben. Eine bessere untere Schranke als 2 ist *nicht bekannt* – das ist der eigentliche Skandal des Gebiets. Selbst $\omega > 2 + 10^{-100}$ konnte niemand beweisen.

Obere Schranken – die historische Entwicklung:

Jahr	Autoren	Schranke für ω
bis 1969	—	3
1969	Strassen	2,8074
1978	Pan	2,796
1979	Bini u.a.	2,78
1981	Schönhage	2,522
1986	Strassen	2,479
1990	Coppersmith, Winograd	2,3755
2011	Stothers	2,3737
2012	Vassilevska Williams	2,3729
2014	Le Gall	2,3728639
2020	Alman, Vassilevska Williams	2,3728596
2024	Alman, Duan, Vassilevska Williams, Xu, Xu, Zhou	2,371552
2024	Williams, Xu, Xu, Zhou	2,371339

Galaktische Algorithmen

Alle Verfahren nach Strassen – und insbesondere die seit Coppersmith–Winograd – sind praktisch *völlig unbrauchbar*. Die versteckten Konstanten sind so gigantisch, dass der Vorteil erst bei Matrizengrößen einsetzt, die die Zahl der Atome im beobachtbaren Universum übersteigen.

RICHARD LIPTON prägte dafür 2010 den Begriff **galaktischer Algorithmus**. Der Wert dieser Resultate ist rein theoretisch: Sie sagen etwas über die *Struktur* des Problems aus, nicht über seine Berechnung.

Die offene Frage lautet, ob $\omega = 2$ gilt. Viele Fachleute vermuten es; ein Beweis ist nicht in Sicht. COHN und UMANS entwickelten ab 2003 einen gruppentheoretischen Zugang, für den 2017 allerdings gezeigt wurde, dass er in seiner ursprünglichen Form nicht bis $\omega = 2$ reichen kann.

13.2 Maschinelles Lernen entdeckt Algorithmen

AlphaTensor (2022) und AlphaEvolve (2025)

AlphaTensor. Im Oktober 2022 veröffentlichte DeepMind in *Nature* ein System, das die Suche nach Multiplikationsalgorithmen als Einpersonenspiel formuliert: Man zerlegt den *Matrixmultiplikationstensor* in möglichst wenige Rang-1-Terme – jeder Term entspricht einer Multiplikation. Ein Verstärkungslernverfahren nach dem Vorbild von AlphaZero sucht solche Zerlegungen.

Das Ergebnis: Für 4×4-Matrizen über dem Körper $\mathbb{F}_2$ fand das System eine Zerlegung mit **47 Multiplikationen** statt der zuvor besten 49 (zweimal Strassen rekursiv). Für mehrere andere Formate wurden ebenfalls Verbesserungen gefunden.
Die Einschränkung: Das Resultat galt zunächst nur für $\mathbb{F}_2$, also modulo 2. Über allgemeinen Körpern – und damit für praktische Zwecke – blieb 49 die Bestmarke.

AlphaEvolve. Im Mai 2025 stellte DeepMind ein System vor, das große Sprachmodelle mit evolutionärer Suche kombiniert: Ein Modell schlägt Programmvarianten vor, ein Bewerter prüft sie, die besten werden mutiert und rekombiniert.
Das aufsehenerregendste Einzelergebnis: eine Zerlegung für 4×4-Matrizen mit **48 Multiplikationen** über $\mathbb{C}$. Das ist die *erste* Verbesserung gegenüber Strassens rekursiv angewandtem Verfahren (49) über einem Körper der Charakteristik 0 seit 1969 – nach 56 Jahren.
Praktisch ändert das wenig: $\log_4 48 \approx 2{,}7936$ gegenüber 2,8074 ist ein marginaler Gewinn, und die zusätzlichen Additionen fressen ihn bei realistischen Größen wieder auf. Symbolisch ist es dennoch bemerkenswert – ein Problem, an dem Generationen von Fachleuten gearbeitet haben, wurde von einem automatisierten System bewegt.

Was man daraus lernen sollte – und was nicht.
Nicht: „Die KI hat die Mathematik überholt." Die Suchräume sind hier sehr speziell strukturiert, die Zielfunktion ist maschinell exakt prüfbar, und die gefundenen Objekte sind endliche kombinatorische Konfigurationen. Das ist genau das Profil, bei dem solche Systeme stark sind.
Sondern: Es gibt eine Klasse von Problemen – explizite Konstruktionen mit maschinell verifizierbarer Korrektheit –, in der automatisierte Suche menschliche Intuition inzwischen überflügeln kann. Diese Beobachtung deckt sich mit dem, was in der Zahlentheorie beim Erdős-Gegenbeispiel 2026 geschah (siehe Band 1).

13.3 Randomisierte numerische lineare Algebra

Die Grundidee: Skizzieren

Statt mit $A \in \mathbb{R}^{m \times n}$ zu arbeiten, multipliziert man mit einer zufälligen Matrix $S \in \mathbb{R}^{k \times m}$ mit $k \ll m$ und rechnet mit der **Skizze** $SA \in \mathbb{R}^{k \times n}$ weiter.
Warum das funktioniert: Nach dem **Johnson–Lindenstrauss-Lemma** (1984) lassen sich N Punkte im $\mathbb{R}^m$ in einen Raum der Dimension

$$k = O\left(\frac{\log N}{\varepsilon^2}\right)$$

einbetten, sodass alle paarweisen Abstände bis auf einen Faktor $(1 \pm \varepsilon)$ erhalten bleiben – und zwar mit hoher Wahrscheinlichkeit durch eine *zufällige* lineare Abbildung.
Bemerkenswert daran: Die Zieldimension hängt *nicht* von m ab, sondern nur von der Punktzahl und der gewünschten Genauigkeit.

Randomisierte SVD (Halko, Martinsson, Tropp 2011)

1. Ziehe eine zufällige Gaußmatrix $\Omega \in \mathbb{R}^{n \times (k+p)}$ mit kleinem Überschuss p (typisch $p = 5$ bis 10).
2. Berechne $Y = A\Omega$ – eine zufällige Stichprobe des Spaltenraums.
3. Orthonormalisiere: $Y = QR$.
4. Berechne die (kleine) SVD von $B := Q^{\mathsf{T}} A \in \mathbb{R}^{(k+p) \times n}$: $B = \tilde{U} \Sigma V^{\mathsf{T}}$.
5. Setze $U := Q\tilde{U}$. Dann ist $A \approx U \Sigma V^{\mathsf{T}}$.

Aufwand: $O(mn \log k)$ statt $O(mn^2)$ – und man braucht nur zwei Durchläufe über die Daten, was bei Matrizen entscheidend ist, die nicht in den Hauptspeicher passen.
Fehlerschranke: Mit Wahrscheinlichkeit $\geq 1 - 3p^{-p}$ gilt

$$\|A - QQ^{\mathsf{T}} A\|_2 \leq \left(1 + 11\sqrt{k+p}\sqrt{\min(m,n)}\right) \sigma_{k+1}.$$

Der Vergleich mit Eckart–Young (Satz 11.2) zeigt: Man verliert nur einen moderaten Faktor gegenüber dem Optimum.

Stand des Gebiets

Randomisierte Verfahren haben sich von einer theoretischen Kuriosität zur Standardtechnik entwickelt. Die Übersichtsarbeit von MARTINSSON und TROPP in *Acta Numerica* (2020) markiert den Punkt, an dem das Gebiet in den Kanon aufgenommen wurde[22].
Ein Bericht mehrerer US-Forschungseinrichtungen zur „Randomized Numerical Linear Algebra“ (2023) empfahl die Aufnahme randomisierter Routinen in die Standardbibliotheken; entsprechende Implementierungen sind inzwischen in `RandLAPACK` und in Bibliotheken wie `scikit-learn` (`randomized_svd`) verfügbar.
Aktuelle Forschungsrichtungen:

- *Sketch-and-precondition* für kleinste Quadrate: Man skizziert nur, um einen Vorkonditionierer zu bauen, und iteriert dann exakt. Das liefert Ergebnisse in Maschinengenauigkeit bei skizzenartigem Aufwand.

- *Leverage-Score-Sampling*: nichtuniformes Ziehen von Zeilen mit Wahrscheinlichkeiten proportional zu ihrer statistischen Hebelwirkung.
- *Tensor-Sketching* für höherdimensionale Datenstrukturen.

13.4 Lineare Algebra im maschinellen Lernen

Was ein Transformer rechnet

Der Aufmerksamkeitsmechanismus, seit 2017 die Grundlage praktisch aller großen Sprachmodelle, lautet

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right) V.$$

Darin sind Q, K, V Matrizen, die durch *lineare* Abbildungen aus der Eingabe entstehen. Der einzige nichtlineare Schritt ist die Softmax-Funktion.

Die Kernoperation QK^{T} ist eine Matrixmultiplikation – und sie ist quadratisch in der Sequenzlänge n. Das ist der Engpass, den die gesamte Forschung zu „effizienter Aufmerksamkeit“ (Linformer, Performer, FlashAttention) zu umgehen versucht, meist mit Niedrigrang- oder Skizzierungsideen aus diesem Kapitel.

Skalenordnung. Das Training eines großen Modells besteht zu über 90 % der Rechenzeit aus Matrixmultiplikationen. Moderne Beschleuniger sind im Wesentlichen Spezialhardware für genau diese Operation – die *Tensor Cores* einer GPU führen 4×4-Matrixmultiplikationen als einzelne Instruktion aus.

Das ist die schlagendste Antwort auf die Frage „Wozu braucht man das?“: Der größte Teil der weltweit verbrauchten Rechenleistung führt derzeit die Operation aus, die in Kapitel 2 definiert wurde.

13.5 Gitter und Post-Quanten-Kryptographie

Definition 13.3. Ein **Gitter** in $\mathbb{R}^n$ ist die Menge aller ganzzahligen Linearkombinationen linear unabhängiger Vektoren:

$$\Lambda = \left\{ \sum_{i=1}^{n} z_i \mathbf{b}_i : z_i \in \mathbb{Z} \right\}.$$

Warum Gitter jetzt wichtig sind

Das **kürzeste-Vektor-Problem** (SVP) – finde den kürzesten von null verschiedenen Gittervektor – ist NP-schwer unter randomisierten Reduktionen und gilt auch für Quantencomputer als schwer. Damit ist es der aussichtsreichste Kandidat für Kryptographie nach dem Ende von RSA.

Der Zusammenhang zur linearen Algebra: Ein Gitter ist ein „Vektorraum über $\mathbb{Z}$“ – ein $\mathbb{Z}$-Modul. Fast alles aus diesem Buch gilt *nicht* mehr: Es gibt keine Basisergänzung im gewohnten Sinn, Gram–Schmidt führt aus dem Gitter heraus, und der Übergang zu einer „guten“ Basis ist algorithmisch schwer. Genau diese Schwierigkeit ist die kryptographische Ressource.
Der LLL-Algorithmus (Lenstra, Lenstra, Lovász 1982) liefert in Polynomzeit eine „einigermaßen kurze“ Basis – genauer: einen Vektor, der höchstens um den Faktor $2^{(n-1)/2}$ länger ist als der kürzeste. Er ist eines der vielseitigsten Werkzeuge der algorithmischen Zahlentheorie und wird unter anderem zur Faktorisierung von Polynomen, zum Auffinden ganzzahliger Relationen und zu Angriffen auf schlecht parametrisierte Kryptosysteme eingesetzt.
Standardisierung. Das NIST verabschiedete 2024 die ersten Post-Quanten-Standards:

- **ML-KEM** (FIPS 203), basierend auf CRYSTALS-Kyber – Schlüsselkapselung, gitterbasiert;
- **ML-DSA** (FIPS 204), basierend auf CRYSTALS-Dilithium – Signaturen, gitterbasiert;
- **SLH-DSA** (FIPS 205), basierend auf SPHINCS+ – Signaturen, hashbasiert.

2025 kam mit HQC ein codebasiertes Verfahren als Rückfallebene hinzu, um nicht ausschließlich von Gitterannahmen abzuhängen.
Die Migration ist bereits im Gange: Große Browser und Messenger setzen seit 2024/25 hybride Schlüsselaustauschverfahren ein, die klassische und gitterbasierte Verfahren kombinieren.

13.6 Quantenalgorithmen

Der HHL-Algorithmus

HARROW, HASSIDIM und LLOYD zeigten 2009, dass ein Quantencomputer lineare Gleichungssysteme in einem gewissen Sinn exponentiell schneller lösen kann: in $O(\log n \cdot \kappa^2/\varepsilon)$ statt $O(n)$.
Das Kleingedruckte – und es ist umfangreich:

- Die Eingabe $\mathbf{b}$ muss bereits als Quantenzustand vorliegen oder effizient präparierbar sein.
- Die Matrix muss dünn besetzt und effizient beschreibbar sein.
- Die Ausgabe ist ein *Quantenzustand* $|x\rangle$, kein klassischer Vektor. Man kann daraus Erwartungswerte gewinnen, aber nicht ohne weiteres die Lösung auslesen – das würde die Beschleunigung wieder zunichte machen.
- Die Abhängigkeit von der Konditionszahl κ ist quadratisch.

Die Dequantisierung. 2018 zeigte Ewin Tang – damals achtzehnjährige Bachelor-Studentin bei Scott Aaronson –, dass ein vermuteter Quantenvorteil bei Empfehlungssystemen gar keiner war: Sie konstruierte einen klassischen Algorithmus mit vergleichbarer Laufzeit, gestützt auf Stichprobenzugriff auf die Daten. Es folgte eine Welle weiterer **Dequantisierungen** für niedrigrangige Probleme.
Stand 2026: Der Konsens lautet, dass der Quantenvorteil in der linearen Algebra deutlich enger begrenzt ist als 2009 angenommen. Für dünn besetzte, schlecht konditionierte Systeme hoher Dimension bleibt eine mögliche Beschleunigung; für Niedrigrangprobleme ist sie weitgehend verschwunden.

13.7 Ein Ausblick für den Leser

Sie haben nun das Handwerkszeug einer Einführungsvorlesung – und in einigen Kapiteln deutlich mehr. Was kommt als Nächstes?

- **Multilineare Algebra und Tensoren.** Tensorprodukte, äußere Algebra, Differentialformen. Die Sprache der Differentialgeometrie und der allgemeinen Relativitätstheorie. Empfehlung: Greub, *Multilinear Algebra*[15].
- **Darstellungstheorie.** Wie wirken Gruppen linear auf Vektorräume? Der Schlüssel zur Teilchenphysik und zur Kristallographie. Empfehlung: Fulton–Harris[11].
- **Funktionalanalysis.** Lineare Algebra in unendlichdimensionalen Räumen: Hilberträume, Banachräume, Spektraltheorie unbeschränkter Operatoren. Das mathematische Fundament der Quantenmechanik. Empfehlung: Werner[27].
- **Numerische lineare Algebra.** Empfehlung: Trefethen–Bau[25] als eleganter Einstieg, Golub–Van Loan[13] als Referenzwerk.
- **Konvexe Optimierung.** Fast alles, was in der Praxis optimiert wird, ist lokal quadratisch. Empfehlung: Boyd–Vandenberghe[4].

Ein letzter Gedanke

Am Anfang dieses Buches stand ein Witz: Die Mathematik zerfalle in die lineare Algebra und den Rest, und der Rest werde gelöst, indem man ihn linearisiert.
Nach zwanzig Kapiteln sollte klar sein, warum das kein Witz ist. Die Ableitung ist eine lineare Approximation. Die Fourieranalyse ist ein Basiswechsel. Die Quantenmechanik ist Spektraltheorie. Ein neuronales Netz ist eine Verkettung von Matrixmultiplikationen. Die Statistik ist Projektion.
Das ist keine Zufälligkeit. Linearität ist die einzige Struktur, die reich genug ist, um interessante Phänomene zu beschreiben, und zugleich einfach genug, um vollständig verstanden zu werden. Alles andere in der Mathematik ist entweder trivial oder unlösbar – oder wird auf lineare Algebra zurückgeführt.
Sie haben jetzt das Werkzeug. Der Rest ist Übung.

Part VIII

Anhänge

A Formelsammlung

Gleichungssysteme

$A\mathbf{x} = \mathbf{b}$ lösbar $\iff \operatorname{Rang} A = \operatorname{Rang}(A \mid \mathbf{b})$

$\dim(\text{Lösungsmenge}) = n - \operatorname{Rang} A$ (im lösbaren Fall)

$L = \mathbf{x}_0 + \operatorname{Kern} A$ (spezielle + homogene Lösung)

Gauß-Aufwand $\approx \frac{2}{3}n^3$

Matrizen

$(AB)_{ik} = \sum_j a_{ij} b_{jk}$ Zeile mal Spalte

$(AB)^\mathsf{T} = B^\mathsf{T} A^\mathsf{T}, \qquad (AB)^{-1} = B^{-1}A^{-1}$ Reihenfolge kehrt sich um

$A^{-1} = \frac{1}{ad-bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$ für $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$

$(A \mid I) \to (I \mid A^{-1})$ Gauß–Jordan

$A = LR, \quad PA = LR$ mit/ohne Pivotisierung

Vektorräume

UVR-Test: $\mathbf{0} \in U$, abgeschlossen unter $+$, $\cdot$

unabhängig : $\sum \lambda_i \mathbf{v}_i = \mathbf{0} \Longrightarrow$ alle $\lambda_i = 0$

Basis = unabhängig + erzeugend = eindeutige Darstellung

$\dim(U + W) + \dim(U \cap W) = \dim U + \dim W$

$\dim V = n$: n Vektoren unabhängig $\iff$ Basis $\iff$ erzeugend

Zeilenrang = Spaltenrang = $\operatorname{Rang} A = \operatorname{Rang} A^\mathsf{T}$

Lineare Abbildungen

f injektiv $\iff \operatorname{Kern} f = \{\mathbf{0}\}$

$\dim V = \dim \operatorname{Kern} f + \dim \operatorname{Bild} f$ Rangsatz

$\big(f(\mathbf{v})\big)_C = M_C^B(f) \cdot \mathbf{v}_B$ Darstellungsmatrix

$M_D^B(g \circ f) = M_D^C(g)\, M_C^B(f)$

$A' = S^{-1}AS$ Basiswechsel / Ähnlichkeit

$V \cong W \iff \dim V = \dim W$

Determinanten

$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_i a_{i\sigma(i)}$ — Leibniz

$\det(AB) = \det A \det B, \qquad \det A^{\mathsf{T}} = \det A$

$\det A^{-1} = (\det A)^{-1}, \qquad \det(\lambda A) = \lambda^n \det A$

A invertierbar $\iff \det A \neq 0$

Zeilentausch $\to -1$; Zeile $\cdot\, \lambda \to \lambda$; Zeilenaddition $\to$ unverändert

$\det A = \sum_j (-1)^{i+j} a_{ij} \det A_{ij}$ — Laplace

$x_j = \det A^{(j)} / \det A$ — Cramer

$|\det A|$ = Volumen des Parallelotops

Eigenwerte

$A\mathbf{v} = \lambda \mathbf{v},\ \mathbf{v} \neq \mathbf{0} \iff \det(A - \lambda I) = 0$

Spur $A = \sum \lambda_i, \qquad \det A = \prod \lambda_i$ — Kontrollen!

$1 \leq \mu_g(\lambda) \leq \mu_a(\lambda)$

A diagonalisierbar $\iff$ Basis aus EV $\iff \mu_g = \mu_a$ für alle λ

n verschiedene EW $\implies$ diagonalisierbar (nicht umgekehrt)

$A^k = S D^k S^{-1}, \qquad e^{tA} = S e^{tD} S^{-1}$

$\chi_A(A) = 0$ — Cayley–Hamilton

Jordan: #Blöcke $= \mu_g$, $\quad \sum$ Blockgrößen $= \mu_a$

Skalarprodukt und Orthogonalität

$|\langle \mathbf{u}, \mathbf{v} \rangle| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ — Cauchy–Schwarz

$\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$ — Dreiecksungleichung

$\mathbf{u} \perp \mathbf{v} \implies \|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$ — Pythagoras

ONB: $\mathbf{v} = \sum_i \langle \mathbf{b}_i, \mathbf{v} \rangle \mathbf{b}_i$

$\mathbf{w}_k = \mathbf{a}_k - \sum_{j<k} \frac{\langle \mathbf{w}_j, \mathbf{a}_k \rangle}{\langle \mathbf{w}_j, \mathbf{w}_j \rangle} \mathbf{w}_j$ — Gram–Schmidt

$V = U \oplus U^{\perp}$

$A^{\mathsf{T}} A \mathbf{x} = A^{\mathsf{T}} \mathbf{b}$ — Normalgleichungen

Q orthogonal $\iff Q^{\mathsf{T}} Q = I \iff$ längenerhaltend

Spektralsatz und quadratische Formen

$A^\mathsf{T} = A \Longrightarrow$ EW reell, ONB aus EV, $Q^\mathsf{T} A Q = D$

A normal $(A^* A = A A^*) \Longleftrightarrow$ unitär diagonalisierbar

$q(\mathbf{x}) = \mathbf{x}^\mathsf{T} A \mathbf{x} \;\to\; \sum \lambda_i y_i^2$ — Hauptachsen

pos. definit $\Longleftrightarrow$ alle $\lambda_i > 0 \Longleftrightarrow$ alle Hauptminoren > 0

Signatur invariant unter $A \mapsto S^\mathsf{T} A S$ — Sylvester

Singulärwertzerlegung

$A = U \Sigma V^\mathsf{T}, \qquad \sigma_i = \sqrt{\lambda_i(A^\mathsf{T} A)}$

$\mathbf{u}_i = \frac{1}{\sigma_i} A \mathbf{v}_i$

$A = \sum_i \sigma_i \mathbf{u}_i \mathbf{v}_i^\mathsf{T}$ — Dyaden

$\|A - A_k\|_2 = \sigma_{k+1}$ — Eckart–Young

$A^+ = V \Sigma^+ U^\mathsf{T}$ — Pseudoinverse

$\mathrm{cond}_2(A) = \sigma_1 / \sigma_n$

Numerik: Aufwand

LR mit Pivotisierung	$\frac{2}{3} n^3$
Cholesky (spd)	$\frac{1}{3} n^3$
QR (Householder)	$\frac{4}{3} n^3$ bzw. $2mn^2 - \frac{2}{3} n^3$
Eigenwerte (symmetrisch, QR)	$\approx 9n^3$
SVD (Golub–Kahan)	$\approx 21n^3$
Strassen	$O(n^{2{,}807})$
beste bekannte Schranke	$O(n^{2{,}3713})$ (galaktisch)

B Zeitleiste

Zeit	Ereignis
∼200 v.	*Neun Kapitel der Rechenkunst* (China): Fangcheng-Verfahren – der Gauß-Algorithmus, zweitausend Jahre vor Gauß
1637	Descartes: analytische Geometrie – Punkte werden zu Zahlenpaaren
1683	Seki Takakazu (Japan): Determinanten bis Ordnung 5
1693	Leibniz: Determinanten im Brief an de l'Hospital (erst 1850 veröffentlicht)
1750	Cramer: die nach ihm benannte Regel, ohne Beweis
1801	Gauß: *Disquisitiones*; Bahnbestimmung der Ceres
1805/09	Legendre bzw. Gauß: Methode der kleinsten Quadrate; Prioritätsstreit
1812	Cauchy: Multiplikationssatz für Determinanten, Begriff „Determinante“ in heutigem Sinn
1826	Cauchy: Hauptachsentransformation quadratischer Formen
1829	Cauchy: reelle Eigenwerte symmetrischer Matrizen
1837	Möbius: baryzentrische Koordinaten
1843	Hamilton: Quaternionen – der erste nichtkommutative Zahlbereich
1844	**Graßmann:** ***Ausdehnungslehre*** – der Vektorraumbegriff, zu früh für seine Zeit
1850	Sylvester prägt den Begriff „Matrix“
1852	Sylvester: Trägheitssatz
1858	**Cayley:** ***Memoir on the Theory of Matrices*** – Matrizen als eigenständige Objekte, Cayley–Hamilton für $n \leq 3$
1870	Jordan: die Normalform (in der *Traité des substitutions*)
1873	Frobenius, Weierstraß: allgemeine Theorie der Elementarteiler
1888	**Peano: axiomatische Definition des Vektorraums** in *Calcolo geometrico*
1907	Schmidt: Orthonormalisierungsverfahren (nach Gram 1883)
1913	Steinitz: Austauschsatz, Wohldefiniertheit der Dimension
1918	Weyl: *Raum, Zeit, Materie* – Vektorräume in der Physik
1920	Moore: Pseudoinverse (wiederentdeckt von Penrose 1955)
1936	Eckart, Young: Optimalität der abgeschnittenen SVD

Zeit	Ereignis
1947	von Neumann, Goldstine: erste Fehleranalyse des Gauß-Algorithmus
1948	Turing: Begriff der Konditionszahl
1952	Hestenes, Stiefel: Verfahren der konjugierten Gradienten
1961	Francis, Kublanovskaya (unabhängig): der QR-Algorithmus
1965	Golub, Kahan: praktikabler SVD-Algorithmus
1969	**Strassen:** $O(n^{2{,}807})$ – die naive Schranke fällt
1979	LINPACK; 1992 LAPACK – Standardbibliotheken
1982	Lenstra, Lenstra, Lovász: LLL-Algorithmus für Gitterbasen
1984	Johnson, Lindenstrauss: das Einbettungslemma
1987	Karmarkar: Innere-Punkte-Verfahren – lineare Algebra in der Optimierung
1990	Coppersmith, Winograd: $\omega < 2{,}3755$
1998	Page, Brin: PageRank – der Eigenvektor als Geschäftsmodell
2009	Harrow, Hassidim, Lloyd: Quantenalgorithmus für lineare Systeme
2011	Halko, Martinsson, Tropp: randomisierte SVD wird Standardwerkzeug
2017	Vaswani u.a.: Transformer – Matrixmultiplikation als Kern moderner KI
2018	Tang: Dequantisierung des Empfehlungssystem-Quantenvorteils
2020	Martinsson, Tropp: Übersichtsarbeit etabliert randomisierte NLA
2022	DeepMind AlphaTensor: 4×4 über $\mathbb{F}_2$ mit 47 Multiplikationen
2024	NIST: erste Post-Quanten-Standards (ML-KEM, ML-DSA, SLH-DSA)
2024	Alman, Duan, Vassilevska Williams, Xu, Xu, Zhou u.a.: $\omega < 2{,}3714$
2025	DeepMind AlphaEvolve: 4×4 über $\mathbb{C}$ mit 48 Multiplikationen – erste Verbesserung gegenüber Strassen seit 56 Jahren

C Glossar

Adjungierte
f^* mit $\langle f(\mathbf{u}), \mathbf{v}\rangle = \langle \mathbf{u}, f^*(\mathbf{v})\rangle$. Bezüglich einer ONB die (konjugiert) Transponierte.

Ähnlichkeit
$A' = S^{-1}AS$. Ähnliche Matrizen beschreiben dieselbe Abbildung in verschiedenen Basen und haben gleichen Rang, gleiche Determinante, Spur und Eigenwerte.

Basis
Linear unabhängiges Erzeugendensystem; äquivalent: jede Darstellung ist eindeutig.

Cholesky-Zerlegung
$A = LL^{\mathsf{T}}$ für symmetrisch positiv definites A. Halber Aufwand gegenüber LR; zugleich Definitheitstest.

Defekt
$\dim \operatorname{Kern} f$. Gegenstück zum Rang; die Summe beider ist $\dim V$.

Determinante
Die eindeutige multilineare, alternierende, normierte Funktion der Spalten. Geometrisch das orientierte Volumen.

Diagonalisierbar
Ähnlich zu einer Diagonalmatrix; äquivalent zur Existenz einer Basis aus Eigenvektoren.

Dimension
Elementanzahl einer (und damit jeder) Basis. Wohldefiniert nach dem Steinitzschen Austauschsatz.

Direkte Summe
$U \oplus W$: Summe mit $U \cap W = \{\mathbf{0}\}$; die Zerlegung jedes Vektors ist dann eindeutig.

Eigenwert
λ mit $A\mathbf{v} = \lambda\mathbf{v}$ für ein $\mathbf{v} \neq \mathbf{0}$. Nullstelle des charakteristischen Polynoms.

Erzeugendensystem
Familie, deren Spann der ganze Raum ist.

Gram–Schmidt
Verfahren zur Konstruktion einer ONB aus einer beliebigen Basis. Numerisch instabil in der klassischen Form.

Hauptvektor
$\mathbf{v}$ mit $(A - \lambda I)^k\mathbf{v} = \mathbf{0}$, aber $(A - \lambda I)^{k-1}\mathbf{v} \neq \mathbf{0}$. Füllt die Lücken, wenn Eigenvektoren fehlen.

Jordanblock
λ auf der Diagonalen, Einsen darüber. Der Baustein der Jordanschen Normalform.

Kern
$\{\mathbf{v} : f(\mathbf{v}) = \mathbf{0}\}$. Trivialer Kern $\Longleftrightarrow$ Injektivität.

Kondition
$\operatorname{cond}(A) = \|A\|\|A^{-1}\| = \sigma_1/\sigma_n$. Misst die Fehlerverstärkung; man verliert etwa $\log_{10}\operatorname{cond}$ Stellen.

Linearkombination
$\sum \lambda_i \mathbf{v}_i$. Die einzige Operation, die ein Vektorraum kennt.

Multilinear
Linear in jedem Argument einzeln. Grundeigenschaft der Determinante.

Normal
$A^*A = AA^*$. Genau die unitär diagonalisierbaren Matrizen.

Orthogonale Matrix
$Q^\mathsf{T}Q = I$; erhält Längen und Winkel. Determinante ± 1.

Orthogonales Komplement
$U^\perp$; es gilt stets $V = U \oplus U^\perp$ im endlichdimensionalen Fall.

Pivot
Erstes von null verschiedenes Element einer Zeile in Stufenform. Ihre Anzahl ist der Rang.

Positiv definit
$\mathbf{x}^\mathsf{T} A\mathbf{x} > 0$ für $\mathbf{x} \neq \mathbf{0}$; äquivalent: alle Eigenwerte positiv.

Pseudoinverse
$A^+ = V\Sigma^+ U^\mathsf{T}$. Liefert die Kleinste-Quadrate-Lösung minimaler Norm, auch bei Rangdefekt.

Rang
dim Bild f bzw. Zeilenrang = Spaltenrang einer Matrix.

Singulärwert
$\sigma_i = \sqrt{\lambda_i(A^\mathsf{T}A)}$. Halbachsenlängen des Bildellipsoids der Einheitskugel.

Spann
Menge aller Linearkombinationen; der kleinste Unterraum, der die Vektoren enthält.

Spektralsatz
Jede symmetrische reelle Matrix ist orthogonal diagonalisierbar mit reellen Eigenwerten.

Spur
Spur $A = \sum a_{ii}$. Gleich der Summe der Eigenwerte; invariant unter Ähnlichkeit.

Vielfachheit
algebraisch = Nullstellenordnung in χ_A; *geometrisch* = dim des Eigenraums. Stets $\mu_g \leq \mu_a$.

Zeilenstufenform
Ergebnis des Gauß-Algorithmus; Pivots rücken von Zeile zu Zeile nach rechts.

D Kommentierte Literatur

Die Angaben sind vollständig bibliographisch; die hochgestellten Verweise im Text beziehen sich auf diese Nummerierung.

1. Alman, J.; Vassilevska Williams, V.: *A Refined Laser Method and Faster Matrix Multiplication*. Proceedings of SODA 2021, S. 522–539. arXiv:2010.05846.
   Die Arbeit, die $\omega < 2{,}37286$ etablierte und die Grundlage der Verbesserungen von 2024 legte.

2. Axler, S.: *Down with Determinants!* American Mathematical Monthly **102** (1995), Nr. 2, S. 139–154. DOI: 10.2307/2975348.
   Der Aufsatz, der die didaktische Debatte auslöste: Die gesamte Eigenwerttheorie ohne Determinanten.

3. Axler, S.: *Linear Algebra Done Right*. 4. Aufl., Springer (Undergraduate Texts in Mathematics), Cham 2024. ISBN 978-3-031-41025-3.
   Die Ausführung des obigen Programms als Lehrbuch. Seit der 4. Auflage frei als Open-Access-PDF verfügbar. Begrifflich außergewöhnlich klar; für rechnerische Fertigkeiten sollte man ergänzen.

4. Boyd, S.; Vandenberghe, L.: *Convex Optimization*. Cambridge University Press, Cambridge 2004. ISBN 978-0-521-83378-3.
   Frei verfügbar. Zeigt, wie lineare Algebra zur Grundlage der modernen Optimierung wird. Dieselben Autoren haben mit *Introduction to Applied Linear Algebra* (2018) auch einen anwendungsorientierten Einstieg vorgelegt.

5. Brin, S.; Page, L.: *The Anatomy of a Large-Scale Hypertextual Web Search Engine*. Computer Networks and ISDN Systems **30** (1998), S. 107–117.
   Die Gründungsarbeit von Google. Der mathematische Kern ist die Potenzmethode auf einer stochastischen Matrix.

6. Cayley, A.: *A Memoir on the Theory of Matrices*. Philosophical Transactions of the Royal Society of London **148** (1858), S. 17–37.
   Die Geburtsurkunde der Matrizenrechnung. Enthält Cayley–Hamilton für 2×2 mit Beweis und für 3×3 mit der Bemerkung, eine allgemeine Behandlung sei nicht nötig.

7. Cohn, H.; Umans, C.: *A Group-Theoretic Approach to Fast Matrix Multiplication*. Proceedings of FOCS 2003, S. 438–449.
   Ein alternativer Zugang zum Exponenten ω über Gruppenalgebren. 2017 wurde gezeigt, dass er in der ursprünglichen Form nicht bis $\omega = 2$ trägt.

8. Eckart, C.; Young, G.: *The Approximation of One Matrix by Another of Lower Rank*. Psychometrika **1** (1936), S. 211–218.
   Bemerkenswert: Das zentrale Resultat der modernen Datenkompression erschien in einer psychologischen Fachzeitschrift.

9. Fischer, G.; Springborn, B.: *Lineare Algebra. Eine Einführung für Studienanfänger*. 19. Aufl., Springer Spektrum, Berlin 2020. ISBN 978-3-662-61644-4.
Das deutschsprachige Standardwerk seit Jahrzehnten. Sorgfältig, vollständig, mit vielen Übungen.

10. Francis, J. G. F.: *The QR Transformation, Parts I and II*. The Computer Journal **4** (1961/62), S. 265–271 und S. 332–345.
Unabhängig von Kublanovskaya, V. N.: *On some algorithms for the solution of the complete eigenvalue problem*, USSR Comput. Math. Math. Phys. **1** (1961), S. 637–657.

11. Fulton, W.; Harris, J.: *Representation Theory: A First Course*. Graduate Texts in Mathematics 129, Springer, New York 1991. ISBN 978-0-387-97495-8.

12. Gauss, C. F.: *Theoria Motus Corporum Coelestium in Sectionibus Conicis Solem Ambientium*. Perthes und Besser, Hamburg 1809.
Enthält die Herleitung der Methode der kleinsten Quadrate aus der Normalverteilung – und den Prioritätsanspruch gegenüber Legendre.

13. Golub, G. H.; Van Loan, C. F.: *Matrix Computations*. 4. Aufl., Johns Hopkins University Press, Baltimore 2013. ISBN 978-1-4214-0794-4.
Das Referenzwerk der numerischen linearen Algebra. Zum Nachschlagen, nicht zum Durchlesen.

14. Grassmann, H.: *Die lineale Ausdehnungslehre, ein neuer Zweig der Mathematik*. Wigand, Leipzig 1844.
Enthält im Kern den Vektorraumbegriff, 44 Jahre vor Peano. Das Werk war so schwer zugänglich geschrieben, dass es zu Lebzeiten praktisch unbeachtet blieb; Graßmann wandte sich enttäuscht der Sanskritforschung zu, wo er als Übersetzer des Rigveda bekannt wurde.

15. Greub, W. H.: *Multilinear Algebra*. 2. Aufl., Springer, New York 1978. ISBN 978-0-387-90284-5.

16. Halko, N.; Martinsson, P.-G.; Tropp, J. A.: *Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions*. SIAM Review **53** (2011), Nr. 2, S. 217–288. DOI: 10.1137/090771806.
Die Arbeit, die randomisierte Matrixzerlegungen aus der Theorie in die Praxis brachte.

17. Hestenes, M. R.; Stiefel, E.: *Methods of Conjugate Gradients for Solving Linear Systems*. Journal of Research of the National Bureau of Standards **49** (1952), S. 409–436.

18. Hu, E. J.; Shen, Y.; Wallis, P.; Allen-Zhu, Z.; Li, Y.; Wang, S.; Wang, L.; Chen, W.: *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv:2106.09685 (2021); ICLR 2022.
Niedrigrangapproximation als Standardtechnik im Training großer Modelle.

19. Johnson, W. B.; Lindenstrauss, J.: *Extensions of Lipschitz mappings into a Hilbert space*. Contemporary Mathematics **26** (1984), S. 189–206.

20. Jordan, C.: *Traité des substitutions et des équations algébriques*. Gauthier-Villars, Paris 1870.
Enthält die Normalform – allerdings über endlichen Körpern, im Kontext der Galoistheorie. Die heute übliche Formulierung stammt von Weierstraß und Frobenius.

21. Lenstra, A. K.; Lenstra, H. W.; Lovász, L.: *Factoring polynomials with rational coefficients*. Mathematische Annalen **261** (1982), S. 515–534.

Der LLL-Algorithmus. Ursprünglich für Polynomfaktorisierung entwickelt, heute zentrales Werkzeug der Gitterkryptoanalyse.

22. MARTINSSON, P.-G.; TROPP, J. A.: *Randomized numerical linear algebra: Foundations and algorithms*. Acta Numerica **29** (2020), S. 403–572. DOI: 10.1017/S0962492920000021.
Die maßgebliche Übersichtsarbeit. Etwa 170 Seiten, sehr gut geschrieben.

23. PEANO, G.: *Calcolo geometrico secondo l'Ausdehnungslehre di H. Grassmann*. Bocca, Turin 1888.
Kapitel IX enthält die erste axiomatische Definition eines Vektorraums über $\mathbb{R}$ – in im Wesentlichen der heutigen Form. Auch dieses Werk wurde zunächst kaum wahrgenommen; erst Weyl (1918) und die Funktionalanalysis der 1920er Jahre setzten den Begriff durch.

24. STRASSEN, V.: *Gaussian Elimination is not Optimal*. Numerische Mathematik **13** (1969), S. 354–356. DOI: 10.1007/BF02165411.
Zweieinhalb Seiten, die ein ganzes Forschungsgebiet begründeten. Der Titel ist Programm.

25. TREFETHEN, L. N.; BAU, D.: *Numerical Linear Algebra*. SIAM, Philadelphia 1997 (25th Anniversary Edition 2022). ISBN 978-0-89871-361-9.
Ein außergewöhnlich gut geschriebenes Buch in 40 Vorlesungen. Wenn Sie nur eines über Numerik lesen, dann dieses.

26. WILLIAMS, V. V.; XU, Y.; XU, Z.; ZHOU, R.: *New Bounds for Matrix Multiplication: from Alpha to Omega*. Proceedings of SODA 2024, S. 3792–3835. arXiv:2307.07970.
Aktuelle obere Schranke $\omega < 2{,}371339$ (Stand 2026).

27. WERNER, D.: *Funktionalanalysis*. 8. Aufl., Springer Spektrum, Berlin 2018. ISBN 978-3-662-55406-7.
Die natürliche Fortsetzung: lineare Algebra in unendlichdimensionalen Räumen. Deutschsprachiges Standardwerk.

Wenn Sie nur drei Bücher kaufen

1. FISCHER/SPRINGBORN[9] für den soliden deutschsprachigen Grundkurs mit Übungen.
2. AXLER[3] für begriffliche Klarheit – das Buch, das zeigt, warum die Dinge so sind, wie sie sind. Frei verfügbar.
3. TREFETHEN/BAU[25], sobald Sie wissen wollen, was tatsächlich im Rechner passiert.