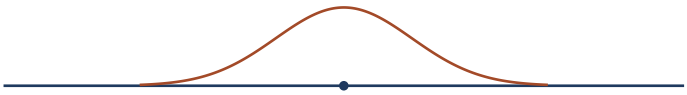
Mathematik von Grund auf — Band 4

Die Vermessung des Zufalls

Eine vollständige Einführung in die Wahrscheinlichkeitstheorie



Von den ersten Würfelwürfen bis zum zentralen Grenzwertsatz
Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Stand der Forschung: August 2026

Mathematik von Grund auf — Band 4
Die Vermessung des Zufalls · Wahrscheinlichkeitstheorie

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Simulationen, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/mathematik-von-grund-auf`
Dauerhaft archiviert bei Zenodo: `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Mathematik von Grund auf, Band 4: Die Vermessung des Zufalls*. Fassung 1.0.1. `https://doi.org/10.5281/zenodo.23698547`

Satz: LaTeX mit Palatino. Fassung 1.0.1, Oktober 2026. 164 Seiten.

Vorwort: Der Zufall als Gegenstand

Von allen Gebieten der Mathematik ist die Wahrscheinlichkeitstheorie dasjenige, bei dem der Abstand zwischen *Alltagsintuition* und *mathematischer Wahrheit* am größten ist.

In der Analysis versagt die Anschauung an einzelnen Stellen – bei der Weierstraß-Funktion, bei der Umordnung von Reihen. In der Stochastik versagt sie systematisch, und zwar bei fast jedem nichttrivialen Problem. Menschen sind nachweislich schlechte intuitive Statistiker. Das gilt für Laien, es gilt für Ärzte, und es gilt, wie mehrere Untersuchungen gezeigt haben, auch für Fachleute mit statistischer Ausbildung, sobald die Frage in ungewohnter Form gestellt wird.

> **Ein Beispiel gleich zu Beginn**
>
> Eine Krankheit hat eine Prävalenz von 1 %. Ein Test erkennt sie mit einer Sensitivität von 90 % und liefert bei Gesunden in 9 % der Fälle ein falsch positives Ergebnis. Ein Patient wird positiv getestet. Wie wahrscheinlich ist es, dass er krank ist?
> Die häufigste Antwort von Ärzten in entsprechenden Untersuchungen liegt bei etwa 80 bis 90 %. Die richtige Antwort ist etwa 9 %.
> Wir rechnen das in Kapitel 3 vollständig durch – und ich zeige Ihnen dort auch, warum die Zahlen in einer anderen Darstellungsform plötzlich für fast jeden durchschaubar werden.

Was dieses Buch will

Sie sollen zwei Dinge gleichzeitig lernen: das *Rechnen* und das *Misstrauen*.

Das Rechnen ist der leichtere Teil. Die Wahrscheinlichkeitstheorie ist, seit Kolmogorow sie 1933 axiomatisiert hat, ein Teilgebiet der Maßtheorie – und damit so streng wie jedes andere Gebiet. Ein Wahrscheinlichkeitsmaß ist ein Maß mit Gesamtmasse 1, eine Zufallsvariable ist eine messbare Funktion, der Erwartungswert ist ein Integral. Wer das einmal gesehen hat, versteht, warum die Sätze so aussehen, wie sie aussehen.

Das Misstrauen ist der schwierigere Teil. Man muss lernen, der eigenen Intuition zu widerstehen – und den Zahlen, die einem präsentiert werden. Ein p-Wert von 0,04 bedeutet nicht, was die meisten Menschen glauben. Eine Korrelation bedeutet nicht, was die meisten Zeitungen schreiben. Und ein Signifikanztest an einer Untergruppe bedeutet fast nie das, was in der Zusammenfassung steht.

Die drei Regeln, wie in den vorigen Bänden

Erstens: Es gibt kein „man sieht leicht“. Gerade hier nicht. Wenn ein Ergebnis der Intuition widerspricht, sage ich es und rechne es zweimal.

Zweitens: Motivation vor Definition. Warum braucht man σ-Algebren? Weil man nicht *allen* Teilmengen von $[0,1]$ eine Wahrscheinlichkeit zuordnen kann – das ist der Satz von Vitali, und ich zeige ihn in Kapitel 1, bevor die Definition kommt. Die Axiome sind dann nicht willkürlich, sondern zwingend.

Drittens: Aufgaben mit vollständigen Lösungen. Und zwar solche, die man in Prüfungen und in der Praxis tatsächlich vorfindet.

> **Eine besondere Warnung für dieses Gebiet**
>
> Die Wahrscheinlichkeitstheorie hat, anders als Algebra oder Analysis, eine *Interpretationsfrage*. Was *bedeutet* die Aussage, ein Ereignis habe die Wahrscheinlichkeit 0,3?
> Es gibt darauf mindestens drei ernstzunehmende Antworten – die frequentistische, die subjektivistische und die propensitätstheoretische –, und der Streit darüber ist nicht entschieden. Er ist auch nicht rein akademisch: Er entscheidet darüber, ob man einen p-Wert oder einen Bayes-Faktor berechnet, und damit darüber, welche Medikamente zugelassen werden.
> Die *Mathematik* ist von diesem Streit unberührt. Kolmogorows Axiome gelten unabhängig davon, wie man sie deutet. Aber die *Anwendung* ist es nicht, und ich werde an den relevanten Stellen darauf hinweisen – ausführlich in Kapitel 15.

Zum Aufbau

- **Teil I** (Kap. 1–3): Die Axiome, die Kombinatorik, bedingte Wahrscheinlichkeit und Unabhängigkeit. Hier stehen die klassischen Paradoxien – Ziegenproblem, Geburtstagsproblem, Simpson-Paradoxon – und die medizinische Testtheorie.
- **Teil II** (Kap. 4–7): Zufallsvariablen, die wichtigen Verteilungen (diskret und stetig), Erwartungswert, Varianz, erzeugende Funktionen und die grundlegenden Ungleichungen.
- **Teil III** (Kap. 8): Mehrere Zufallsvariablen – gemeinsame Verteilung, Unabhängigkeit, Kovarianz, Faltung, bedingte Erwartung.
- **Teil IV** (Kap. 9–11): Die Grenzwertsätze. Vier Konvergenzbegriffe, Borel–Cantelli, schwaches und starkes Gesetz der großen Zahlen, der zentrale Grenzwertsatz mit charakteristischen Funktionen.
- **Teil V** (Kap. 12–13): Stochastische Prozesse – Markow-Ketten (hier trifft man die lineare Algebra aus Band 2 wieder), Martingale, Irrfahrten, ein Blick auf die Brownsche Bewegung.

- **Teil VI** (Kap. 14): Schließende Statistik – Schätzen, Konfidenzintervalle, Testen. Einschließlich einer ausführlichen Behandlung dessen, was ein p-Wert nicht bedeutet.
- **Teil VII** (Kap. 15): Aktueller Stand – Replikationskrise, Bayes gegen Frequentismus, Konzentrationsungleichungen, kausale Inferenz, Formalisierung. Stand August 2026.

Ein Gebiet, das aus dem Glücksspiel entstand

Kein anderes Gebiet der Mathematik hat einen so unwürdigen Ursprung.
1654 wandte sich ANTOINE GOMBAUD, Chevalier de Méré, ein Pariser Adliger und Spieler, an BLAISE PASCAL mit einer Frage über Würfelwetten. Aus dem Briefwechsel, den Pascal daraufhin mit PIERRE DE FERMAT führte, entstand die Wahrscheinlichkeitsrechnung.
Die Geschichte ist bemerkenswert, weil das Problem so alt war. Menschen würfeln seit Jahrtausenden; Astragale – Sprunggelenkknochen von Schafen – wurden bereits im alten Ägypten als Würfel benutzt. Und dennoch dauerte es bis 1654, bis jemand die Frage systematisch stellte, warum bestimmte Wetten günstiger sind als andere. IAN HACKING nannte das in *The Emergence of Probability* (1975) eines der großen Rätsel der Wissenschaftsgeschichte: Warum so spät? Seine Vermutung: Es fehlte nicht an Mathematik, sondern an dem Begriff der *Evidenz* – der Vorstellung, dass etwas mehr oder weniger für eine Sache spricht, ohne sie zu beweisen. Dieser Begriff entstand erst im 17. Jahrhundert.
Die Entwicklung danach ging schnell: HUYGENS schrieb 1657 das erste Lehrbuch, JACOB BERNOULLI bewies um 1690 das erste Gesetz der großen Zahlen, DE MOIVRE fand 1733 die Normalverteilung, LAPLACE systematisierte 1812 alles Bekannte.
Und dann stockte es. Über hundert Jahre lang blieb unklar, was Wahrscheinlichkeit eigentlich *ist*. HILBERT nahm die Frage 1900 als sechstes seiner Probleme auf. Die Antwort gab ANDREI KOLMOGOROW 1933 in einem schmalen Band von 62 Seiten – und sie war so überzeugend, dass sie seither unverändert gilt.

Die Wahrscheinlichkeitstheorie ist im Grunde nichts anderes als auf Rechnen zurückgeführter gesunder Menschenverstand.
— Pierre-Simon Laplace, 1814

(Ein Satz, den dieses Buch an mehreren Stellen widerlegen wird.)

Inhaltsverzeichnis

Vorwort **iii**

I Grundlagen **1**

1 Was ist Wahrscheinlichkeit? **3**
1.1 Der naive Zugang und sein Scheitern . . . 3
1.2 Ergebnisraum und Ereignisse . . . 4
1.3 Warum nicht alle Teilmengen zugelassen sind . . . 4
1.4 Die Axiome von Kolmogorow . . . 7
1.5 Stetigkeit von oben und unten . . . 10

2 Kombinatorik und Laplace-Experimente **13**
2.1 Der Laplace-Raum . . . 13
2.2 Die vier Grundmodelle . . . 14
2.3 Das Geburtstagsproblem . . . 16
2.4 Der Binomialkoeffizient . . . 18

3 Bedingte Wahrscheinlichkeit und Unabhängigkeit **21**
3.1 Die Definition – und warum sie so lautet . . . 21
3.2 Totale Wahrscheinlichkeit und die Formel von Bayes . . . 22
3.3 Unabhängigkeit . . . 25
3.4 Das Simpson-Paradoxon . . . 28

II Zufallsvariablen und Verteilungen **31**

4 Zufallsvariablen **33**
4.1 Warum man den Ergebnisraum verlässt . . . 33
4.2 Die Verteilungsfunktion . . . 34
4.3 Diskrete und stetige Zufallsvariablen . . . 35
4.4 Transformationen . . . 37

5 Die diskreten Verteilungen **41**
5.1 Bernoulli und Binomial . . . 41
5.2 Die geometrische Verteilung . . . 43
5.3 Die hypergeometrische Verteilung . . . 44
5.4 Die Poisson-Verteilung . . . 45

6 Die stetigen Verteilungen **49**
6.1 Gleichverteilung und Exponentialverteilung 49
6.2 Die Normalverteilung 50
6.3 Weitere wichtige stetige Verteilungen 54

7 Erwartungswert, Varianz und Ungleichungen **57**
7.1 Der Erwartungswert 57
7.2 Varianz 60
7.3 Die grundlegenden Ungleichungen 62
7.4 Erzeugende Funktionen 64

III Mehrere Zufallsvariablen **67**

8 Gemeinsame Verteilungen **69**
8.1 Gemeinsame und Randverteilungen 69
8.2 Kovarianz und Korrelation 70
8.3 Summen und Faltung 73
8.4 Bedingte Erwartung 73

IV Die Grenzwertsätze **77**

9 Konvergenzbegriffe **79**
9.1 Vier Arten der Konvergenz 79
9.2 Die Lemmata von Borel und Cantelli 81

10 Die Gesetze der großen Zahlen **85**
10.1 Das schwache Gesetz 85
10.2 Das starke Gesetz 86

11 Der zentrale Grenzwertsatz **91**
11.1 Die Aussage 91
11.2 Der Beweis 92
11.3 Wie schnell konvergiert es? 95

V Stochastische Prozesse **99**

12 Markow-Ketten **101**
12.1 Die Markow-Eigenschaft 101
12.2 Stationäre Verteilung 103
12.3 Anwendungen 106

13 Martingale und Irrfahrten **109**
13.1 Die einfache Irrfahrt . . . 109
13.2 Das Ruinproblem . . . 110
13.3 Martingale . . . 112

VI Schließende Statistik **117**

14 Schätzen und Testen **119**
14.1 Der Perspektivwechsel . . . 119
14.2 Maximum-Likelihood . . . 120
14.3 Konfidenzintervalle . . . 122
14.4 Hypothesentests . . . 124
14.5 Multiples Testen . . . 126

VII Ausblick und aktueller Stand **129**

15 Der aktuelle Stand **131**
15.1 Die Replikationskrise . . . 131
15.2 Bayes gegen Frequentismus . . . 133
15.3 Konzentrationsungleichungen . . . 134
15.4 Kausale Inferenz . . . 135
15.5 Formalisierung . . . 136
15.6 Wohin es weitergeht . . . 136

VIIIAnhänge **139**

A Formelsammlung **141**

B Verteilungen im Überblick **145**

C Zeitleiste der Wahrscheinlichkeitstheorie **147**

D Glossar **149**

E Kommentierte Literatur **151**

Part I

Grundlagen

1 Was ist Wahrscheinlichkeit?

1.1 Der naive Zugang und sein Scheitern

Die Laplace-Definition (1812)

$$\mathbb{P}(A) = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}.$$

Für einen fairen Würfel: $\mathbb{P}(\text{gerade Zahl}) = \frac{3}{6} = \frac{1}{2}$.

Diese Definition ist nützlich – und als *Definition* unhaltbar. Drei Einwände:

Erstens: Sie ist zirkulär. Sie setzt voraus, dass alle Fälle „gleich möglich“ sind. Was heißt das anderes als „gleich wahrscheinlich“? Man definiert Wahrscheinlichkeit durch Wahrscheinlichkeit.

Zweitens: Sie versagt bei unendlich vielen Fällen. Wie wahrscheinlich ist es, dass eine zufällig gewählte Zahl aus $[0, 1]$ im Intervall $[0; 0{,}3]$ liegt? „Günstige durch mögliche Fälle“ ergibt $\frac{\infty}{\infty}$.

Drittens: Sie versagt bei unsymmetrischen Situationen. Wie wahrscheinlich ist es, dass ein bestimmter Patient auf eine Therapie anspricht? Es gibt keine „gleich möglichen Fälle“.

Bertrands Paradoxon

1889 zeigte JOSEPH BERTRAND, wie tief das Problem sitzt. Seine Frage:
Man wähle zufällig eine Sehne im Einheitskreis. Wie wahrscheinlich ist es, dass sie länger ist als die Seite des einbeschriebenen gleichseitigen Dreiecks (also länger als $\sqrt{3}$)?

Antwort 1 – zufälliger Endpunkt. Man fixiert einen Endpunkt und wählt den zweiten gleichverteilt auf dem Kreis. Die Sehne ist länger als $\sqrt{3}$, wenn der zweite Punkt im mittleren Drittel liegt: $\mathbb{P} = \frac{1}{3}$.

Antwort 2 – zufälliger Radius. Man wählt eine Richtung und darauf den Mittelpunkt der Sehne gleichverteilt. Die Sehne ist lang genug, wenn ihr Mittelpunkt näher als $\frac{1}{2}$ am Zentrum liegt: $\mathbb{P} = \frac{1}{2}$.

Antwort 3 – zufälliger Mittelpunkt. Man wählt den Sehnenmittelpunkt gleichverteilt in der Kreisfläche. Bedingung wie oben: Der Punkt muss im Kreis vom Radius $\frac{1}{2}$ liegen, dessen Fläche ein Viertel beträgt: $\mathbb{P} = \frac{1}{4}$.

Alle drei Rechnungen sind korrekt. Der Widerspruch entsteht, weil „zufällig eine Sehne wählen“ *nicht definiert* ist. Es gibt keine kanonische Gleichverteilung auf der Menge der Sehnen.

Die Lehre: Man muss das Wahrscheinlichkeitsmaß *angeben*. Es ergibt sich nicht aus der Beschreibung des Experiments. Genau das leistet Kolmogorows Zugang – er definiert nicht, welches Maß das richtige ist, sondern was ein Maß überhaupt ist.

1.2 Ergebnisraum und Ereignisse

Definition 1.1. Der **Ergebnisraum** Ω ist die Menge aller möglichen Ausgänge eines Zufallsexperiments. Ein **Ereignis** ist (zunächst) eine Teilmenge $A \subseteq \Omega$.

Beispiel 1.2.
- Einmaliger Würfelwurf: $\Omega = \{1,2,3,4,5,6\}$. Das Ereignis „gerade“ ist $A = \{2,4,6\}$.
- Zweimaliger Münzwurf: $\Omega = \{KK, KZ, ZK, ZZ\}$.
- Wartezeit bis zum nächsten Anruf: $\Omega = [0,\infty)$.
- Lebensdauer eines Bauteils, Temperaturverlauf, Aktienkurs: Ω kann ein Funktionenraum sein.

Das Wörterbuch: Mengenlehre $\leftrightarrow$ Umgangssprache

Mengensprache	Wahrscheinlichkeitssprache
$\omega \in A$	das Ereignis A tritt ein
$A \cup B$	A *oder* B (mindestens eines)
$A \cap B$	A *und* B (beide)
$A^c = \Omega \setminus A$	A tritt *nicht* ein (Gegenereignis)
$A \subseteq B$	aus A folgt B
$A \cap B = \emptyset$	A und B schließen einander aus (disjunkt)
Ω	das sichere Ereignis
$\emptyset$	das unmögliche Ereignis

Diese Übersetzung ist der ganze Trick. Wahrscheinlichkeitsrechnung ist Mengenlehre plus eine Maßfunktion. Wer die Tabelle beherrscht, hat die halbe Modellierungsarbeit erledigt.

1.3 Warum nicht alle Teilmengen zugelassen sind

Es wäre bequem, jeder Teilmenge von Ω eine Wahrscheinlichkeit zuzuordnen. Bei endlichem Ω geht das auch. Bei $\Omega = [0,1]$ geht es nicht.

Satz 1.3 (Vitali 1905). *Es gibt keine Funktion $\mathbb{P}$, die* jeder *Teilmenge von $[0,1]$ eine Zahl zuordnet und dabei gleichzeitig erfüllt:*

(i) $\mathbb{P}([0,1]) = 1$,

(ii) $\mathbb{P}\left(\bigcup_k A_k\right) = \sum_k \mathbb{P}(A_k)$ *für paarweise disjunkte* A_k *(σ-Additivität),*
(iii) $\mathbb{P}$ *ist invariant unter Verschiebungen modulo 1.*

Beweis. **Schritt 1 – Eine Äquivalenzrelation.** Auf $[0,1)$ definieren wir

$$x \sim y \quad :\Longleftrightarrow \quad x - y \in \mathbb{Q}.$$

Das ist eine Äquivalenzrelation (Reflexivität, Symmetrie, Transitivität rechnet man direkt nach, da $\mathbb{Q}$ eine Gruppe unter Addition ist).

Schritt 2 – Eine Auswahlmenge. Nach dem *Auswahlaxiom* gibt es eine Menge $V \subseteq [0,1)$, die aus jeder Äquivalenzklasse genau ein Element enthält.

Schritt 3 – Verschiebungen. Für $q \in \mathbb{Q} \cap [0,1)$ setze

$$V_q := \{v + q \bmod 1 : v \in V\}.$$

Behauptung a: Die V_q sind paarweise disjunkt. Läge x in $V_q \cap V_{q'}$ mit $q \neq q'$, so gäbe es $v, v' \in V$ mit $v + q \equiv v' + q'$, also $v - v' = q' - q \in \mathbb{Q}$. Dann wären v und v' äquivalent, und da V aus jeder Klasse nur ein Element enthält, folgte $v = v'$ und damit $q = q'$. Widerspruch.

Behauptung b: Die V_q überdecken $[0,1)$. Sei $x \in [0,1)$. Es liegt in einer Äquivalenzklasse, deren Vertreter $v \in V$ sei. Dann ist $q := x - v \bmod 1$ rational, also $x \in V_q$.

Schritt 4 – Der Widerspruch. Aus (ii) und (iii):

$$1 = \mathbb{P}([0,1)) = \mathbb{P}\left(\bigcup_{q \in \mathbb{Q}\cap[0,1)} V_q\right) = \sum_q \mathbb{P}(V_q) = \sum_q \mathbb{P}(V).$$

Die letzte Gleichung nutzt die Verschiebungsinvarianz: Alle V_q haben dieselbe Wahrscheinlichkeit wie V.

Nun ist $\mathbb{Q} \cap [0,1)$ abzählbar unendlich. Die Summe unendlich vieler gleicher Zahlen ist

$$\begin{cases} 0, & \text{falls } \mathbb{P}(V) = 0 \\ \infty, & \text{falls } \mathbb{P}(V) > 0. \end{cases}$$

Beides ist $\neq 1$. Widerspruch. ∎

> **Was daraus folgt**
>
> Man *muss* sich auf eine Familie „messbarer" Mengen beschränken. Das ist keine technische Bequemlichkeit, sondern eine logische Notwendigkeit – genau wie bei Banach–Tarski in Band 3.
>
> **Beruhigung:** Die nichtmessbaren Mengen sind rein nichtkonstruktiv. Man kann keine einzige explizit angeben; der Beweis benutzt das Auswahlaxiom. Alles, was in einer Anwendung je vorkommt, ist messbar.

Definition 1.4 (σ-Algebra). Ein System $\mathcal{A}$ von Teilmengen von Ω heißt **σ-Algebra**, wenn

(A) $\Omega \in \mathcal{A}$,
(B) $A \in \mathcal{A} \Longrightarrow A^c \in \mathcal{A}$,
(C) $A_1, A_2, \dots \in \mathcal{A} \Longrightarrow \bigcup_{k=1}^{\infty} A_k \in \mathcal{A}$.

Das Paar $(\Omega, \mathcal{A})$ heißt **Messraum**.

> **Warum genau diese drei Forderungen**
>
> Sie sind das Minimum, damit die Sprache funktioniert:
>
> - (A): Man will vom sicheren Ereignis sprechen können.
> - (B): Wenn man von A sprechen kann, will man auch von „nicht A“ sprechen.
> - (C): Wenn man von $A_1, A_2, \dots$ sprechen kann, auch von „mindestens eines davon“.
>
> **Was daraus folgt:**
>
> - $\emptyset = \Omega^c \in \mathcal{A}$.
> - Durchschnitte: $\bigcap_k A_k = \left(\bigcup_k A_k^c\right)^c \in \mathcal{A}$ (Regel von De Morgan).
> - Differenzen: $A \setminus B = A \cap B^c \in \mathcal{A}$.
>
> **Warum „σ“?** Der griechische Buchstabe steht für *Summe* und signalisiert, dass *abzählbar* unendliche Operationen erlaubt sind – nicht nur endliche. Genau das braucht man für Grenzwertsätze: Aussagen wie „die Folge konvergiert“ sind abzählbare Kombinationen einfacherer Ereignisse.

Beispiel 1.5.

- $\mathcal{A} = \{\emptyset, \Omega\}$ – die triviale σ-Algebra.
- $\mathcal{A} = \mathcal{P}(\Omega)$, die Potenzmenge – bei abzählbarem Ω die übliche Wahl.
- Die **Borelsche σ-Algebra** $\mathcal{B}(\mathbb{R})$: die kleinste σ-Algebra, die alle offenen Intervalle enthält. Sie enthält alle Intervalle, alle abgeschlossenen Mengen, alle abzählbaren Mengen – praktisch alles, was man je braucht.

> **σ-Algebren als Informationsstruktur**
>
> Es gibt eine zweite, für die Anwendung wichtigere Lesart: *Eine σ-Algebra beschreibt, was man weiß.*
> Wirft man eine Münze zweimal, so ist $\Omega = \{KK, KZ, ZK, ZZ\}$. Kennt man nur den ersten Wurf, so kann man genau die Ereignisse beurteilen, die in
>
> $$\mathcal{A}_1 = \{\emptyset,\ \{KK, KZ\},\ \{ZK, ZZ\},\ \Omega\}$$
>
> liegen. Ob „beide gleich“ eintrat, weiß man nicht – dieses Ereignis liegt nicht in $\mathcal{A}_1$. Eine *größere* σ-Algebra bedeutet *mehr Information*. Diese Sichtweise ist der Schlüssel zur bedingten Erwartung (Kapitel 8) und zur Theorie der Martingale (Kapitel 13), wo eine wachsende Folge von σ-Algebren – eine **Filtration** – den Informationszuwachs über die Zeit beschreibt.

1.4 Die Axiome von Kolmogorow

Definition 1.6 (Kolmogorow 1933). Sei $(\Omega, \mathcal{A})$ ein Messraum. Eine Abbildung $\mathbb{P} : \mathcal{A} \to [0,1]$ heißt **Wahrscheinlichkeitsmaß**, wenn

(K1) $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{A}$ (Nichtnegativität)

(K2) $\mathbb{P}(\Omega) = 1$ (Normierung)

(K3) Für paarweise disjunkte $A_1, A_2, \dots \in \mathcal{A}$ gilt

$$\mathbb{P}\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} \mathbb{P}(A_k)$$

(σ-Additivität)

Das Tripel $(\Omega, \mathcal{A}, \mathbb{P})$ heißt **Wahrscheinlichkeitsraum**.

> **Drei Axiome, mehr nicht**
>
> Das ist alles. Die gesamte Wahrscheinlichkeitstheorie folgt hieraus.
> **Was bemerkenswert ist:** Die Axiome sagen nichts darüber, was Wahrscheinlichkeit *bedeutet*. Sie sagen nur, wie sie sich *verhält*. Kolmogorow löste das philosophische Problem, indem er es umging – und genau das machte den Erfolg aus.
> **Der Vergleich mit dem Flächenmaß:** Ein Wahrscheinlichkeitsmaß ist ein Maß im Sinne der Lebesgueschen Theorie (Band 3, Kapitel 14) mit der Zusatzbedingung $\mathbb{P}(\Omega) = 1$. Die Wahrscheinlichkeitstheorie ist damit formal ein Spezialfall der Maßtheorie – was Kolmogorow ausdrücklich betonte.
> **Warum σ-Additivität und nicht nur endliche Additivität?** Weil man sonst keine Grenzwertsätze bekommt. BRUNO DE FINETTI vertrat zeitlebens die Position, nur endliche Additivität sei zu rechtfertigen; er blieb in der Minderheit, aber seine Argumente sind nicht widerlegt, sondern nur wenig praktikabel.

Satz 1.7 (Elementare Rechenregeln). *Für alle $A, B \in \mathcal{A}$ gilt:*

(a) $\mathbb{P}(\emptyset) = 0$

(b) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$

(c) $A \subseteq B \Longrightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$ *(Monotonie)*

(d) $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ *(Additionssatz)*

(e) $\mathbb{P}\left(\bigcup_k A_k\right) \leq \sum_k \mathbb{P}(A_k)$ *(Subadditivität)*

Beweis. **(a).** Setze in (K3) alle $A_k = \emptyset$. Die Mengen sind paarweise disjunkt (der Durchschnitt ist leer), also

$$\mathbb{P}(\emptyset) = \sum_{k=1}^{\infty} \mathbb{P}(\emptyset).$$

Eine Zahl $x \geq 0$, für die $x = x + x + x + \dots$ gilt, muss null sein: Wäre $x > 0$, so divergierte die rechte Seite.

(b). $\Omega = A \cup A^c$ ist eine disjunkte Zerlegung. Nach (K3) – mit $A_1 = A$, $A_2 = A^c$, $A_k = \emptyset$ sonst – und (K2):

$$1 = \mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

(c). Für $A \subseteq B$ ist $B = A \cup (B \setminus A)$ disjunkt, also

$$\mathbb{P}(B) = \mathbb{P}(A) + \underbrace{\mathbb{P}(B \setminus A)}_{\geq 0} \geq \mathbb{P}(A).$$

(d). Wir zerlegen $A \cup B$ in drei disjunkte Teile:

$$A \cup B = (A \setminus B) \dot\cup (A \cap B) \dot\cup (B \setminus A).$$

Also

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A).$$

Ferner ist $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ und ebenso für B. Setzt man

$$\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(A \cap B), \qquad \mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

ein, so folgt

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) - \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B) + \mathbb{P}(B) - \mathbb{P}(A \cap B),$$

also die Behauptung.

(e). Man macht die A_k disjunkt: Setze

$$B_1 := A_1, \qquad B_k := A_k \setminus (A_1 \cup \cdots \cup A_{k-1}).$$

Dann sind die B_k disjunkt, $\bigcup B_k = \bigcup A_k$ und $B_k \subseteq A_k$. Mit (K3) und (c):

$$\mathbb{P}\left(\bigcup A_k\right) = \sum_k \mathbb{P}(B_k) \leq \sum_k \mathbb{P}(A_k). \qquad \blacksquare$$

> **Der „Disjunktmachungs"-Trick**
>
> Der Kunstgriff in (e) – aus einer beliebigen Folge eine disjunkte zu machen, ohne die Vereinigung zu ändern – kommt in der Maßtheorie ständig vor. Man zieht von jedem Glied alles ab, was schon vorher da war.
> Er ist der Grund, warum σ-Additivität (nur für disjunkte Mengen) so viel liefert wie eine Regel für beliebige Vereinigungen.

Satz 1.8 (Siebformel, Poincaré–Sylvester)**.**

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_i \mathbb{P}(A_i) - \sum_{i<j} \mathbb{P}(A_i \cap A_j) + \sum_{i<j<k} \mathbb{P}(A_i \cap A_j \cap A_k) - \ldots$$

$$\cdots + (-1)^{n+1} \mathbb{P}(A_1 \cap \cdots \cap A_n).$$

Aufgabe 1.1. *Das Problem der vertauschten Briefe.* n Briefe werden zufällig auf n adressierte Umschläge verteilt. Wie wahrscheinlich ist es, dass *kein* Brief im richtigen Umschlag landet? Was passiert für $n \to \infty$?

Lösung Schritt für Schritt.

Schritt 1 – Ereignisse definieren. Sei A_i das Ereignis „Brief i liegt richtig“. Gesucht ist

$$\mathbb{P}\left(\bigcap_{i} A_i^c\right) = 1 - \mathbb{P}\left(\bigcup_{i} A_i\right).$$

Schritt 2 – Einzelwahrscheinlichkeiten. Es gibt $n!$ Verteilungen. Liegt Brief i richtig, so sind die übrigen $n-1$ beliebig verteilt: $(n-1)!$ Möglichkeiten.

$$\mathbb{P}(A_i) = \frac{(n-1)!}{n!} = \frac{1}{n}.$$

Schritt 3 – Durchschnitte. Liegen k bestimmte Briefe richtig:

$$\mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}) = \frac{(n-k)!}{n!}.$$

Schritt 4 – Wie viele solche Durchschnitte gibt es? Genau $\binom{n}{k}$.
Schritt 5 – Siebformel anwenden.

$$\mathbb{P}\left(\bigcup A_i\right) = \sum_{k=1}^{n} (-1)^{k+1} \binom{n}{k} \frac{(n-k)!}{n!}.$$

Nun ist

$$\binom{n}{k} \cdot \frac{(n-k)!}{n!} = \frac{n!}{k!\,(n-k)!} \cdot \frac{(n-k)!}{n!} = \frac{1}{k!}.$$

Das ist eine bemerkenswerte Vereinfachung – alles kürzt sich bis auf die Fakultät.

$$\mathbb{P}\left(\bigcup A_i\right) = \sum_{k=1}^{n} \frac{(-1)^{k+1}}{k!}.$$

Schritt 6 – Gegenwahrscheinlichkeit.

$$p_n := \mathbb{P}(\text{kein Brief richtig}) = 1 - \sum_{k=1}^{n} \frac{(-1)^{k+1}}{k!} = \sum_{k=0}^{n} \frac{(-1)^k}{k!}.$$

Schritt 7 – Zahlenwerte.

$$p_1 = 0, \quad p_2 = \tfrac{1}{2} = 0{,}5, \quad p_3 = \tfrac{1}{3} \approx 0{,}333, \quad p_4 = \tfrac{3}{8} = 0{,}375, \quad p_5 \approx 0{,}3667.$$

Schritt 8 – Der Grenzwert. Die Reihe ist genau die Exponentialreihe an der Stelle -1 (Band 3, Kapitel 5):

$$\lim_{n\to\infty} p_n = \sum_{k=0}^{\infty} \frac{(-1)^k}{k!} = \mathrm{e}^{-1} \approx 0{,}3679.$$

Was daran erstaunlich ist. Die Wahrscheinlichkeit hängt für große n *praktisch nicht mehr* von n ab. Ob 10 Briefe oder 10 Millionen – in gut einem Drittel der Fälle liegt kein einziger richtig.
Und die Konvergenz ist extrem schnell: Nach dem Leibniz-Kriterium ist der Fehler höchstens $\frac{1}{(n+1)!}$. Bereits bei $n = 7$ stimmt der Wert auf vier Nachkommastellen.
Historisches. PIERRE RÉMOND DE MONTMORT stellte das Problem 1708 als *jeu de rencontre* (Begegnungsspiel); NIKOLAUS BERNOULLI und Euler lieferten Lösungen. Permutationen ohne Fixpunkt heißen bis heute **Derangements**; ihre Anzahl $D_n = n!\, p_n$ ist die zum Kartenspiel gehörige Zahlenfolge.

1.5 Stetigkeit von oben und unten

Satz 1.9 (Stetigkeit des Maßes)**.** *Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum.*

(a) Ist $A_1 \subseteq A_2 \subseteq \dots$ aufsteigend, so

$$\mathbb{P}\left(\bigcup_k A_k\right) = \lim_{k\to\infty} \mathbb{P}(A_k).$$

(b) Ist $A_1 \supseteq A_2 \supseteq \dots$ absteigend, so

$$\mathbb{P}\left(\bigcap_k A_k\right) = \lim_{k\to\infty} \mathbb{P}(A_k).$$

Beweis. **(a).** Wir zerlegen disjunkt: $B_1 := A_1$, $B_k := A_k \setminus A_{k-1}$. Dann

$$\bigcup_{k=1}^{n} B_k = A_n, \qquad \bigcup_{k=1}^{\infty} B_k = \bigcup_k A_k.$$

Nach (K3):

$$\mathbb{P}\left(\bigcup_k A_k\right) = \sum_{k=1}^{\infty} \mathbb{P}(B_k) = \lim_{n\to\infty} \sum_{k=1}^{n} \mathbb{P}(B_k) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

(Die mittlere Gleichung ist die Definition der Reihensumme.)

(b). Übergang zu den Komplementen: A_k^c ist aufsteigend. Nach (a) und den Regeln von De Morgan:

$$1 - \mathbb{P}\left(\bigcap A_k\right) = \mathbb{P}\left(\bigcup A_k^c\right) = \lim \mathbb{P}(A_k^c) = 1 - \lim \mathbb{P}(A_k). \qquad \blacksquare$$

Warum dieser Satz oft gebraucht wird

Er erlaubt es, Grenzwerte in die Wahrscheinlichkeit hineinzuziehen. Praktisch jeder Beweis über „irgendwann tritt A ein“ oder „A tritt unendlich oft ein“ benutzt ihn.

Beispiel. Wie wahrscheinlich ist es, bei unendlich vielen fairen Münzwürfen *irgendwann* Kopf zu werfen? Sei A_n das Ereignis „unter den ersten n Würfen ist mindestens ein Kopf“. Dann $\mathbb{P}(A_n) = 1 - 2^{-n}$, und die A_n steigen auf. Also

$$\mathbb{P}(\text{irgendwann Kopf}) = \lim_n (1 - 2^{-n}) = 1.$$

Beachten Sie: Die Folge „immer Zahl“ ist *möglich*, hat aber Wahrscheinlichkeit 0. **Wahrscheinlichkeit 0 ist nicht dasselbe wie Unmöglichkeit** – eine Unterscheidung, die in diskreten Räumen nicht auftritt und in stetigen Räumen fundamental ist.

Kolmogorow und die 62 Seiten

ANDREI NIKOLAJEWITSCH KOLMOGOROW (1903–1987) veröffentlichte 1933 die *Grundbegriffe der Wahrscheinlichkeitsrechnung*[17] – auf Deutsch, im Springer-Verlag, im Umfang von 62 Seiten.
Der Text löste Hilberts sechstes Problem, soweit es die Wahrscheinlichkeitstheorie betraf, und wurde binnen weniger Jahre universell akzeptiert. Das ist ungewöhnlich: Grundlagenvorschläge setzen sich selten so schnell durch.
Der Grund lag in der Anschlussfähigkeit. Kolmogorow erfand nichts Neues – er stellte fest, dass die 1902 von Lebesgue geschaffene Maßtheorie genau das richtige Werkzeug war. Damit stand die gesamte Analysis sofort zur Verfügung, einschließlich der Konvergenzsätze.
Kolmogorow war 29 Jahre alt und hatte bereits das starke Gesetz der großen Zahlen bewiesen. Er arbeitete später zur Turbulenztheorie, zur Informationstheorie (Kolmogorow-Komplexität), zur dynamischen Systemtheorie (KAM-Theorie) und zur Schulmathematik – er entwarf Lehrpläne und betreute persönlich Begabtenschulen.
Eine Anekdote, die er selbst gern erzählte: Als Student verdiente er sein Geld als Schaffner in der Moskauer Straßenbahn.

2 Kombinatorik und Laplace-Experimente

2.1 Der Laplace-Raum

Definition 2.1. Ist Ω endlich und $\mathcal{A} = \mathcal{P}(\Omega)$, so heißt

$$\mathbb{P}(A) := \frac{|A|}{|\Omega|}$$

die **Laplace-Verteilung** oder **Gleichverteilung** auf Ω.

Man prüft sofort nach, dass die drei Axiome erfüllt sind. Und man sieht: Das Rechnen mit Wahrscheinlichkeiten reduziert sich in diesem Fall vollständig aufs *Zählen*. Deshalb steht am Anfang jedes Stochastikkurses die Kombinatorik.

Die Gleichverteilung ist eine Modellannahme

Sie folgt nicht aus dem Experiment, sondern wird *unterstellt*. Ob ein realer Würfel fair ist, ist eine empirische Frage.

Und die Wahl von Ω entscheidet mit. Klassisches Beispiel: Wirft man zwei Würfel und interessiert sich für die Augensumme, so ist

$$\Omega_1 = \{2, 3, \dots, 12\}$$

naheliegend – aber die Gleichverteilung darauf ist *falsch*. Richtig ist

$$\Omega_2 = \{1, \dots, 6\}^2 \quad \text{mit } |\Omega_2| = 36,$$

und darauf ist die Gleichverteilung sinnvoll. Die Summe 7 hat dann sechs Realisierungen, die Summe 2 nur eine.

LEIBNIZ irrte hier: Er hielt 1666 die Summen 11 und 12 für gleich wahrscheinlich, weil beide „auf gleich viele Arten“ entstünden. Tatsächlich entsteht 11 als 5+6 und 6+5 – zwei Realisierungen –, die 12 nur als 6+6.

Regel: Ω so wählen, dass die Elemente durch die Symmetrie des Experiments gleichberechtigt sind. Meist heißt das: die Ergebnisse als *unterscheidbare* Objekte behandeln, auch wenn sie es praktisch nicht sind.

2.2 Die vier Grundmodelle

Fast jede kombinatorische Aufgabe lässt sich auf ein Urnenmodell zurückführen: Aus einer Urne mit n unterscheidbaren Kugeln werden k gezogen. Zwei Fragen entscheiden über die Formel:

1. **Mit oder ohne Zurücklegen?** (Darf eine Kugel mehrfach vorkommen?)
2. **Mit oder ohne Beachtung der Reihenfolge?**

Die vier Formeln

	mit Reihenfolge	**ohne Reihenfolge**
mit Zurücklegen	n^k	$\binom{n+k-1}{k}$
ohne Zurücklegen	$\dfrac{n!}{(n-k)!}$	$\binom{n}{k}$

Warum jede Formel so aussieht

1. Mit Zurücklegen, mit Reihenfolge: n^k. Für jede der k Ziehungen stehen alle n Kugeln zur Verfügung. Die Wahlen sind unabhängig voneinander:

$$\underbrace{n \cdot n \cdots n}_{k \text{ Faktoren}} = n^k.$$

Beispiel: Ein vierstelliger Zahlencode hat $10^4 = 10\,000$ Möglichkeiten.

2. Ohne Zurücklegen, mit Reihenfolge: $\frac{n!}{(n-k)!}$. Bei der ersten Ziehung gibt es n Möglichkeiten, bei der zweiten nur noch $n-1$, dann $n-2$, und so fort:

$$n(n-1)(n-2)\cdots(n-k+1) = \frac{n!}{(n-k)!}.$$

Kontrolle der Umformung: Der Zähler $n!$ enthält alle Faktoren von n bis 1; der Nenner $(n-k)!$ kürzt genau die letzten $n-k$ weg. Übrig bleiben die ersten k. ✓
Beispiel: Wie viele Siegertreppchen (Gold, Silber, Bronze) gibt es bei 8 Läufern? $\frac{8!}{5!} = 8 \cdot 7 \cdot 6 = 336$.

3. Ohne Zurücklegen, ohne Reihenfolge: $\binom{n}{k}$. Man nimmt Formel 2 und teilt heraus, wie oft dieselbe Auswahl in verschiedener Reihenfolge gezählt wurde. Eine k-elementige Menge lässt sich auf $k!$ Arten anordnen:

$$\frac{1}{k!} \cdot \frac{n!}{(n-k)!} = \frac{n!}{k!(n-k)!} =: \binom{n}{k}.$$

Beispiel: Lotto „6 aus 49“: $\binom{49}{6} = 13\,983\,816$.

4. Mit Zurücklegen, ohne Reihenfolge: $\binom{n+k-1}{k}$. Das ist die einzige nicht offensichtliche Formel. Der Trick heißt **Sterne und Trennstriche**.
Man notiert eine Ziehung als Strichliste. Werden aus $n = 3$ Sorten $k = 5$ Kugeln gezogen, etwa zweimal Sorte 1, keinmal Sorte 2, dreimal Sorte 3, so schreibt man

$$\star\star\,|\,|\,\star\star\star.$$

Man braucht k Sterne und $n-1$ Trennstriche, also insgesamt $n+k-1$ Zeichen. Eine Ziehung ist eindeutig dadurch festgelegt, *welche* dieser Positionen Sterne sind:

$$\binom{n+k-1}{k}.$$

Beispiel: Wie viele Möglichkeiten gibt es, 5 gleichartige Kugeln auf 3 Fächer zu verteilen? $\binom{7}{5} = 21$.

Aufgabe 2.1. Ein Skatblatt hat 32 Karten (4 Farben zu je 8 Werten). Es werden 10 Karten ausgeteilt. Berechnen Sie die Wahrscheinlichkeit für

(a) genau 3 Buben (es gibt 4 Buben im Blatt),
(b) mindestens 3 Buben,
(c) alle 8 Karo-Karten.

Lösung Schritt für Schritt.

Schritt 0 – Grundraum. Die Reihenfolge des Austeilens ist irrelevant; ohne Zurücklegen.

$$|\Omega| = \binom{32}{10} = 64\,512\,240.$$

Zwischenrechnung: $\binom{32}{10} = \frac{32\cdot31\cdot30\cdot29\cdot28\cdot27\cdot26\cdot25\cdot24\cdot23}{10!}$. Man rechnet das am besten schrittweise unter fortlaufendem Kürzen.

(a) Genau 3 Buben.
Zerlegung der Auswahl: 3 der 4 Buben, dazu 7 der übrigen 28 Karten.

$$|A| = \binom{4}{3}\cdot\binom{28}{7} = 4\cdot 1\,184\,040 = 4\,736\,160.$$

$$\mathbb{P}(A) = \frac{4\,736\,160}{64\,512\,240} = 0{,}0734.$$

Also etwa 7,3 %.
Warum man multipliziert: Jede Wahl der Buben lässt sich mit jeder Wahl der übrigen Karten kombinieren. Das ist das Produktprinzip.

(b) Mindestens 3 Buben. Das heißt: 3 oder 4 Buben.

Genau 4 Buben:

$$\binom{4}{4}\binom{28}{6} = 1 \cdot 376\,740 = 376\,740.$$

$$\mathbb{P}(\text{genau } 4) = \frac{376\,740}{64\,512\,240} = 0{,}00584.$$

Summe:

$$\mathbb{P}(\text{mind. } 3) = 0{,}0734 + 0{,}0058 = 0{,}0792 \approx 7{,}9\,\%.$$

(Die Ereignisse „genau 3“ und „genau 4“ sind disjunkt – deshalb darf man addieren.)

(c) Alle 8 Karo-Karten. Dann sind 8 der 10 Karten festgelegt; die übrigen 2 stammen aus den 24 Nicht-Karo-Karten:

$$|C| = \binom{8}{8}\binom{24}{2} = 1 \cdot 276 = 276.$$

$$\mathbb{P}(C) = \frac{276}{64\,512\,240} = 4{,}28 \cdot 10^{-6}.$$

Etwa einmal in 234 000 Blättern.

Schritt 4 – Plausibilitätsprüfung. Der Erwartungswert für die Bubenzahl ist $10 \cdot \frac{4}{32} = 1{,}25$. Dass 3 oder mehr Buben nur in 8 % der Fälle auftreten, passt dazu. ✓

Die allgemeine Struktur hinter (a) und (b) ist die **hypergeometrische Verteilung** (Kapitel 5):

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}.$$

2.3 Das Geburtstagsproblem

Aufgabe 2.2. Wie viele Personen müssen in einem Raum sein, damit die Wahrscheinlichkeit, dass zwei am selben Tag Geburtstag haben, über 50 % liegt?

Lösung Schritt für Schritt.

Schritt 1 – Modell. Wir nehmen 365 gleich wahrscheinliche Geburtstage an (keine Schaltjahre, keine saisonalen Häufungen – beides ändert das Ergebnis nur geringfügig, und zwar in Richtung *kleinerer* nötiger Personenzahl).
Für n Personen ist

$$\Omega = \{1, \dots, 365\}^n, \qquad |\Omega| = 365^n$$

(mit Zurücklegen, mit Reihenfolge – die Personen sind unterscheidbar).

Schritt 2 – Gegenereignis. Direkt zu rechnen wäre mühsam: „mindestens zwei gleich“ zerfällt in viele Fälle. Das Gegenereignis „alle verschieden“ ist einfach:

$$|A^c| = 365 \cdot 364 \cdot 363 \cdots (365 - n + 1) = \frac{365!}{(365-n)!}.$$

Schritt 3 – Wahrscheinlichkeit.

$$\mathbb{P}(\text{alle verschieden}) = \frac{365 \cdot 364 \cdots (366-n)}{365^n} = \prod_{k=0}^{n-1} \left(1 - \frac{k}{365}\right).$$

Schritt 4 – Werte berechnen.

n	$\mathbb{P}$(alle versch.)	$\mathbb{P}$(mind. 2 gleich)
10	0,8831	0,1169
20	0,5886	0,4114
22	0,5243	0,4757
23	**0,4927**	**0,5073**
30	0,2937	0,7063
50	0,0296	0,9704
70	0,0008	0,9992

Antwort: 23 Personen.
Schritt 5 – Warum das so überrascht. Die meisten Menschen schätzen die nötige Zahl auf 150 bis 180. Der Denkfehler: Man denkt an *sich selbst* und fragt, wie viele andere den eigenen Geburtstag teilen müssten.
Tatsächlich zählt aber jedes *Paar*. Bei 23 Personen gibt es

$$\binom{23}{2} = 253$$

Paare – und 253 ist in derselben Größenordnung wie 365. Genau das ist der Grund.
Schritt 6 – Eine Näherungsformel. Mit $\ln(1-x) \approx -x$ für kleine x (Band 3, Taylorreihe des Logarithmus):

$$\ln \mathbb{P}(\text{alle versch.}) = \sum_{k=0}^{n-1} \ln\left(1 - \frac{k}{365}\right) \approx -\frac{1}{365} \sum_{k=0}^{n-1} k = -\frac{n(n-1)}{730}.$$

Setzt man das gleich $\ln \frac{1}{2} = -0{,}693$:

$$n(n-1) \approx 0{,}693 \cdot 730 = 506 \Longrightarrow n \approx 23{,}0. \checkmark$$

Allgemein braucht man für einen Kalender mit d Tagen etwa $1{,}18\sqrt{d}$ Personen – die *Wurzel* der Tageszahl, nicht die Hälfte.
Schritt 7 – Praktische Bedeutung: der Geburtstagsangriff. Genau diese Wurzelabhängigkeit begrenzt die Sicherheit kryptographischer Hashfunktionen. Eine

Hashfunktion mit 128 Bit Ausgabe hat 2^{128} mögliche Werte – eine Kollision findet man aber schon nach etwa

$$1{,}18\sqrt{2^{128}} \approx 2^{64}$$

Versuchen. Deshalb ist die effektive Sicherheit gegen Kollisionen nur halb so groß wie die Bitlänge, und deshalb gilt MD5 (128 Bit) heute als gebrochen und SHA-256 als Mindeststandard.

2.4 Der Binomialkoeffizient

Satz 2.2 (Eigenschaften). *(a)* $\binom{n}{k} = \binom{n}{n-k}$ *(Symmetrie)*

(b) $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$ *(Pascalsche Rekursion)*

(c) $\sum_{k=0}^{n} \binom{n}{k} = 2^n$

(d) $\sum_{k=0}^{n} (-1)^k \binom{n}{k} = 0$ *für* $n \geq 1$

(e) $(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}$ *(binomischer Lehrsatz)*

Beweis. **(a) – kombinatorisch.** Eine k-elementige Teilmenge auszuwählen ist dasselbe, wie die $n-k$ nicht ausgewählten Elemente zu bestimmen. Die Zuordnung „Teilmenge $\mapsto$ Komplement“ ist eine Bijektion.

(b) – kombinatorisch. Wir zeichnen ein Element aus, etwa das letzte. Jede k-elementige Teilmenge fällt in genau einen von zwei Fällen:

- Sie *enthält* das letzte Element. Dann sind noch $k-1$ Elemente aus den übrigen $n-1$ zu wählen: $\binom{n-1}{k-1}$ Möglichkeiten.
- Sie *enthält es nicht*. Dann sind alle k Elemente aus den übrigen $n-1$ zu wählen: $\binom{n-1}{k}$.

Beide Fälle schließen einander aus und decken alles ab.

(c) – kombinatorisch. Die linke Seite zählt alle Teilmengen von $\{1, \ldots, n\}$, nach Größe sortiert. Die rechte Seite zählt dasselbe anders: Für jedes Element entscheidet man „drin oder draußen“ – 2 Möglichkeiten, n-mal unabhängig.

(d). Setze in (e) $a = -1$, $b = 1$:

$$0 = (1-1)^n = \sum_{k} \binom{n}{k} (-1)^k.$$

(e) – kombinatorisch. Man multipliziert $(a+b) \cdots (a+b)$ mit n Faktoren aus. Jeder Summand entsteht, indem man aus jedem Faktor entweder a oder b wählt. Ein Summand $a^k b^{n-k}$ entsteht genau dann, wenn man in k der n Faktoren das a wählt – dafür gibt es $\binom{n}{k}$ Möglichkeiten. ■

Kombinatorische Beweise sind die besseren

Beachten Sie, dass keiner der Beweise gerechnet hat. Man hätte (b) auch durch Ausschreiben der Fakultäten zeigen können:

$$\frac{(n-1)!}{(k-1)!(n-k)!} + \frac{(n-1)!}{k!(n-k-1)!} = \cdots = \frac{n!}{k!(n-k)!},$$

mit Hauptnenner und einigem Umformen. Das ist korrekt, aber es *erklärt* nichts. Der kombinatorische Beweis dagegen sagt, *warum* die Identität gilt: Man zählt dieselbe Menge auf zwei Arten. Diese Beweistechnik – **doppeltes Abzählen** – ist eines der mächtigsten Werkzeuge der Kombinatorik.

Das Pascalsche Dreieck

Regel (b) erzeugt das Dreieck: Jeder Eintrag ist die Summe der beiden darüber.

$$\begin{array}{ccccccccccc}
 & & & & & 1 & & & & & \\
 & & & & 1 & & 1 & & & & \\
 & & & 1 & & 2 & & 1 & & & \\
 & & 1 & & 3 & & 3 & & 1 & & \\
 & 1 & & 4 & & 6 & & 4 & & 1 & \\
1 & & 5 & & 10 & & 10 & & 5 & & 1 \\
1 & & 6 & & 15 & & 20 & & 15 & & 6 & & 1
\end{array}$$

Historisches. PASCAL beschrieb es 1654 im *Traité du triangle arithmétique*, aber es war lange vorher bekannt: bei JIA XIAN in China um 1050, bei AL-KARADSCHI in Persien um 1000, bei PINGALA in Indien möglicherweise schon 200 v. Chr. In China heißt es bis heute „Yang-Hui-Dreieck“.

Ein Ausblick auf den zentralen Grenzwertsatz. Zeichnet man die Zeilen als Balkendiagramm, so nähert sich die Form mit wachsendem n der Glockenkurve. Das ist kein Zufall, sondern der Satz von de Moivre–Laplace (Kapitel 11) – die Binomialverteilung konvergiert gegen die Normalverteilung.

Aufgabe 2.3. Wie viele Wege führen in einem Gitter von $(0,0)$ nach (m,n), wenn man nur nach rechts und nach oben gehen darf?

Lösung Schritt für Schritt.

Schritt 1 – Wege codieren. Jeder Weg besteht aus genau m Schritten nach rechts (R) und n Schritten nach oben (O), in irgendeiner Reihenfolge. Ein Weg ist also ein Wort wie

RROROO…

mit m Buchstaben R und n Buchstaben O.

Schritt 2 – Zählen. Ein solches Wort ist eindeutig bestimmt, sobald man weiß, an *welchen* der $m+n$ Positionen ein R steht:

$$\binom{m+n}{m} = \binom{m+n}{n}.$$

Schritt 3 – Beispiel. Von $(0,0)$ nach $(3,2)$:

$$\binom{5}{2} = 10.$$

Kontrolle durch Aufzählen: RRROO, RRORO, RROOR, RORRO, ROROR, ROORR, ORRRO, ORROR, ORORR, OORRR. Das sind 10. ✓

Schritt 4 – Eine Anwendung: das Wahlurnenproblem. Bei einer Wahl erhält Kandidat A a Stimmen, Kandidat B b Stimmen mit $a > b$. Wie wahrscheinlich ist es, dass A beim Auszählen *durchgehend* in Führung liegt?

Die Antwort ist verblüffend einfach:

$$\frac{a-b}{a+b}.$$

Das ist das **Bertrandsche Wahlurnenproblem** (1887); der eleganteste Beweis stammt von DÉSIRÉ ANDRÉ und beruht auf einem Spiegelungsargument: Jeder „schlechte“ Weg (der die Diagonale berührt) wird bijektiv auf einen Weg mit vertauschtem Startpunkt abgebildet.

Zahlenbeispiel: Bei $a = 6$, $b = 4$ ist die Wahrscheinlichkeit $\frac{2}{10} = 20\,\%$ – obwohl A am Ende klar gewinnt, liegt A nur in einem Fünftel der Auszählreihenfolgen durchgehend vorn.

Dasselbe Spiegelungsargument liefert später die Verteilung der Maxima von Irrfahrten (Kapitel 13).

3 Bedingte Wahrscheinlichkeit und Unabhängigkeit

3.1 Die Definition – und warum sie so lautet

Die Idee

Eine Zusatzinformation verändert die Wahrscheinlichkeit. Wirft man einen Würfel und erfährt, dass das Ergebnis gerade ist, so ist die Wahrscheinlichkeit für eine Sechs nicht mehr $\frac{1}{6}$, sondern $\frac{1}{3}$.
Was geschieht dabei? Der Ergebnisraum schrumpft auf $\{2,4,6\}$, und man normiert neu, damit die Summe wieder 1 ergibt:

$$\mathbb{P}(\{6\} \mid \{2,4,6\}) = \frac{\mathbb{P}(\{6\} \cap \{2,4,6\})}{\mathbb{P}(\{2,4,6\})} = \frac{1/6}{3/6} = \frac{1}{3}.$$

Genau das wird zur Definition erhoben.

Definition 3.1. Sei $\mathbb{P}(B) > 0$. Die **bedingte Wahrscheinlichkeit** von A gegeben B ist

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Satz 3.2. *Für festes B mit $\mathbb{P}(B) > 0$ ist $A \mapsto \mathbb{P}(A \mid B)$ selbst ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{A})$.*

Beweis. **(K1):** Zähler und Nenner sind nichtnegativ. ✓
(K2): $\mathbb{P}(\Omega \mid B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$. ✓
(K3): Seien $A_1, A_2, \ldots$ paarweise disjunkt. Dann sind auch die Mengen $A_k \cap B$ paarweise disjunkt, und

$$\mathbb{P}\left(\bigcup_k A_k \,\middle|\, B\right) = \frac{\mathbb{P}\left(\bigcup_k (A_k \cap B)\right)}{\mathbb{P}(B)} = \frac{\sum_k \mathbb{P}(A_k \cap B)}{\mathbb{P}(B)} = \sum_k \mathbb{P}(A_k \mid B). \qquad \blacksquare$$

Warum das wichtig ist

Alle Rechenregeln aus Kapitel 1 gelten auch für bedingte Wahrscheinlichkeiten. Insbesondere

$$\mathbb{P}(A^c \mid B) = 1 - \mathbb{P}(A \mid B).$$

Aber nicht in der anderen Variablen!

$$\mathbb{P}(A \mid B^c) \neq 1 - \mathbb{P}(A \mid B).$$

Das ist ein sehr häufiger Fehler. Beispiel: $\mathbb{P}(\text{Regen} \mid \text{Wolken}) = 0{,}4$ sagt *nichts* über $\mathbb{P}(\text{Regen} \mid \text{keine Wolken})$.

Satz 3.3 (Multiplikationssatz)**.**

$$\mathbb{P}(A_1 \cap A_2 \cap \cdots \cap A_n) = \mathbb{P}(A_1)\,\mathbb{P}(A_2 \mid A_1)\,\mathbb{P}(A_3 \mid A_1 \cap A_2) \cdots \mathbb{P}(A_n \mid A_1 \cap \cdots \cap A_{n-1}),$$

sofern alle bedingenden Ereignisse positive Wahrscheinlichkeit haben.

Beweis. Man schreibt die rechte Seite als Produkt von Brüchen aus:

$$\mathbb{P}(A_1) \cdot \frac{\mathbb{P}(A_1 \cap A_2)}{\mathbb{P}(A_1)} \cdot \frac{\mathbb{P}(A_1 \cap A_2 \cap A_3)}{\mathbb{P}(A_1 \cap A_2)} \cdots$$

Es handelt sich um ein Teleskopprodukt: Jeder Nenner kürzt sich gegen den vorangehenden Zähler. Übrig bleibt der letzte Zähler. ∎

3.2 Totale Wahrscheinlichkeit und die Formel von Bayes

Satz 3.4 (Satz von der totalen Wahrscheinlichkeit)**.** *Sei $B_1, B_2, \ldots$ eine **Zerlegung** von Ω – also paarweise disjunkt mit $\bigcup_i B_i = \Omega$ und $\mathbb{P}(B_i) > 0$. Dann gilt für jedes A:*

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i)\,\mathbb{P}(B_i).$$

Beweis. Die Mengen $A \cap B_i$ sind paarweise disjunkt, und ihre Vereinigung ist

$$\bigcup_i (A \cap B_i) = A \cap \bigcup_i B_i = A \cap \Omega = A.$$

Nach (K3):

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i) = \sum_i \mathbb{P}(A \mid B_i)\mathbb{P}(B_i).$$ ∎

Die Denkfigur

Fallunterscheidung mit Gewichten. Man zerlegt die Situation in Fälle, rechnet in jedem Fall einzeln und gewichtet mit der Wahrscheinlichkeit des Falls.
Das ist eine der beiden am häufigsten gebrauchten Techniken der Stochastik. Die andere ist der Übergang zum Gegenereignis.

Satz 3.5 (Formel von Bayes)**.** *Unter denselben Voraussetzungen und für $\mathbb{P}(A) > 0$:*

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k)\,\mathbb{P}(B_k)}{\sum_i \mathbb{P}(A \mid B_i)\,\mathbb{P}(B_i)}.$$

Beweis. Nach Definition und Multiplikationssatz:

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \cap B_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_k)\mathbb{P}(B_k)}{\mathbb{P}(A)},$$

und der Nenner wird mit Satz 3.4 aufgelöst. ■

Was die Formel leistet

Sie *dreht die Bedingung um*. Man kennt $\mathbb{P}(A \mid B)$ und will $\mathbb{P}(B \mid A)$.
Das ist fast immer die praktisch relevante Richtung:

- Man kennt: Wie oft schlägt der Test bei Kranken an? Man will wissen: Wie wahrscheinlich ist Krankheit bei positivem Test?
- Man kennt: Wie oft tritt dieses Symptom bei der Diagnose auf? Man will: Wie wahrscheinlich ist die Diagnose bei diesem Symptom?
- Man kennt: Wie wahrscheinlich ist diese Spur, wenn der Verdächtige der Täter ist? Man will: Wie wahrscheinlich ist die Täterschaft angesichts der Spur?

Die Terminologie:

- $\mathbb{P}(B_k)$ heißt **A-priori-Wahrscheinlichkeit** (vor der Beobachtung),
- $\mathbb{P}(A \mid B_k)$ heißt **Likelihood**,
- $\mathbb{P}(B_k \mid A)$ heißt **A-posteriori-Wahrscheinlichkeit** (nach der Beobachtung).

Kurz: *Posterior* $\propto$ *Likelihood* $\times$ *Prior.*

Der Trugschluss der transponierten Bedingung

$\mathbb{P}(A \mid B)$ und $\mathbb{P}(B \mid A)$ werden systematisch verwechselt. Der Fehler hat einen Namen: **Prosecutor's Fallacy**.
Ein Beispiel, das Menschenleben kostete. 1999 wurde die britische Anwältin SALLY CLARK wegen Mordes an ihren beiden Säuglingen verurteilt. Der Sachverständige hatte ausgesagt, die Wahrscheinlichkeit für zwei plötzliche Kindstode in derselben Familie betrage 1 zu 73 Millionen.
Diese Zahl war in zweifacher Hinsicht falsch:

1. Sie unterstellte *Unabhängigkeit* der beiden Todesfälle. Tatsächlich gibt es familiäre Risikofaktoren, genetisch wie umweltbedingt; die Ereignisse sind positiv korreliert.
2. Vor allem aber wurde $\mathbb{P}(\text{Befund} \mid \text{unschuldig})$ mit $\mathbb{P}(\text{unschuldig} \mid \text{Befund})$ verwechselt. Für die zweite Größe muss man die Doppel*morde* in die Rechnung einbeziehen – und die sind ebenfalls extrem selten. Das Verhältnis der beiden Seltenheiten entscheidet, nicht die eine Zahl allein.

Die Royal Statistical Society protestierte 2001 öffentlich. Clark wurde 2003 freigesprochen, nachdem sie über drei Jahre inhaftiert war; sie starb 2007. Mehrere ähnliche Urteile wurden daraufhin aufgehoben.

Aufgabe 3.1. Eine Krankheit hat die Prävalenz 1 %. Ein Test hat eine Sensitivität von 90 % (er erkennt 90 % der Kranken) und eine Falsch-Positiv-Rate von 9 %. Ein Patient wird positiv getestet. Wie wahrscheinlich ist es, dass er krank ist?

Lösung Schritt für Schritt.

Schritt 1 – Bezeichnungen.

$$K := \{\text{krank}\}, \qquad T^+ := \{\text{Test positiv}\}.$$

Gegeben:

$$\mathbb{P}(K) = 0{,}01, \qquad \mathbb{P}(T^+ \mid K) = 0{,}90, \qquad \mathbb{P}(T^+ \mid K^c) = 0{,}09.$$

Gesucht: $\mathbb{P}(K \mid T^+)$.

Schritt 2 – Nenner: totale Wahrscheinlichkeit.

$$\mathbb{P}(T^+) = \mathbb{P}(T^+ \mid K)\mathbb{P}(K) + \mathbb{P}(T^+ \mid K^c)\mathbb{P}(K^c)$$

$$= 0{,}90 \cdot 0{,}01 + 0{,}09 \cdot 0{,}99 = 0{,}009 + 0{,}0891 = 0{,}0981.$$

Schritt 3 – Bayes.

$$\mathbb{P}(K \mid T^+) = \frac{0{,}009}{0{,}0981} = 0{,}0917.$$

Antwort: etwa 9 %. Neun von zehn positiv Getesteten sind gesund.

Schritt 4 – Dieselbe Rechnung in natürlichen Häufigkeiten.
Denken Sie an 1000 Personen:

	krank	**gesund**	**gesamt**
Test positiv	9	89	98
Test negativ	1	901	902
gesamt	10	990	1000

Wie die Tabelle entsteht: 10 von 1000 sind krank (1 %). Von diesen 10 werden 9 erkannt (90 %). Von den 990 Gesunden sind 9 %, also 89, falsch positiv.
Von den $9 + 89 = 98$ positiv Getesteten sind 9 tatsächlich krank:

$$\frac{9}{98} = 0{,}092. \checkmark$$

Schritt 5 – Warum die zweite Darstellung so viel klarer ist.

GERD GIGERENZER und ULRICH HOFFRAGE zeigten 1995 in einer vielzitierten Untersuchung[11]: Legt man Ärzten das Problem in Prozentform vor, so lösen es nur etwa 10 bis 20 % korrekt. In natürlichen Häufigkeiten steigt die Quote auf über 50 % – ohne jede Schulung.
Der Grund: Häufigkeiten machen die *Basisrate* sichtbar. In der Prozentdarstellung gerät sie aus dem Blick, und man verwechselt Sensitivität mit positivem prädiktivem Wert.
Schritt 6 – Die entscheidende Rolle der Prävalenz. Wir variieren nur $\mathbb{P}(K)$:

Prävalenz	$\mathbb{P}(K \mid T^+)$
0,1 %	1,0 %
1 %	9,2 %
10 %	52,6 %
50 %	90,9 %

Derselbe Test, völlig verschiedene Aussagekraft. Das ist das zentrale Argument gegen unselektives Screening in gesunden Bevölkerungen: Bei niedriger Prävalenz überwiegen die falsch Positiven, mit allen Folgen – Verunsicherung, Zusatzdiagnostik, Übertherapie.
Schritt 7 – Die Größen im Fachvokabular.

Sensitivität	$\mathbb{P}(T^+ \mid K)$
Spezifität	$\mathbb{P}(T^- \mid K^c) = 1 - 0{,}09 = 0{,}91$
Positiver prädiktiver Wert (PPW)	$\mathbb{P}(K \mid T^+) = 0{,}092$
Negativer prädiktiver Wert (NPW)	$\mathbb{P}(K^c \mid T^-) = \frac{901}{902} = 0{,}9989$

Sensitivität und Spezifität sind *Testeigenschaften* – sie hängen nicht von der Prävalenz ab. PPW und NPW sind *Situationseigenschaften* – sie hängen entscheidend davon ab. Diese Unterscheidung ist der Kern der klinischen Testtheorie.

3.3 Unabhängigkeit

Definition 3.6. Zwei Ereignisse A, B heißen **stochastisch unabhängig**, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B).$$

Warum diese Formel und nicht „$\mathbb{P}(A \mid B) = \mathbb{P}(A)$“?
Für $\mathbb{P}(B) > 0$ sind beide gleichwertig:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A).$$

Die Produktform ist aber

- *symmetrisch* in A und B – sie zeigt sofort, dass Unabhängigkeit keine Richtung hat,
- auch für $\mathbb{P}(B) = 0$ sinnvoll,
- auf mehr als zwei Ereignisse verallgemeinerbar.

Definition 3.7. Ereignisse $A_1, \dots, A_n$ heißen **(gemeinsam) unabhängig**, wenn für *jede* Teilmenge $I \subseteq \{1, \dots, n\}$ gilt

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i).$$

Paarweise Unabhängigkeit genügt nicht

Bernsteins Beispiel (1928). Man wirft zwei faire Münzen. Sei

$$A = \{\text{erste Münze Kopf}\}, \quad B = \{\text{zweite Münze Kopf}\}, \quad C = \{\text{beide gleich}\}.$$

Jedes Ereignis hat Wahrscheinlichkeit $\frac{1}{2}$ (bei C: die Ergebnisse KK und ZZ von vieren).
Paarweise unabhängig?

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{KK\}) = \tfrac{1}{4} = \tfrac{1}{2} \cdot \tfrac{1}{2} \checkmark$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(\{KK\}) = \tfrac{1}{4} \checkmark, \qquad \mathbb{P}(B \cap C) = \mathbb{P}(\{KK\}) = \tfrac{1}{4} \checkmark$$

Gemeinsam unabhängig?

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(\{KK\}) = \frac{1}{4} \qquad \text{gegen} \qquad \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{8}.$$

Nicht gleich. Und das ist auch anschaulich klar: Kennt man A und B, so kennt man C vollständig.
Merke: Es genügt nicht, alle Paare zu prüfen. Man braucht *alle* Teilmengen – bei n Ereignissen sind das $2^n - n - 1$ Bedingungen.

Aufgabe 3.2. *Das Ziegenproblem (Monty-Hall-Problem).* In einer Spielshow stehen drei Türen; hinter einer ist ein Auto, hinter den beiden anderen je eine Ziege. Der Kandidat wählt eine Tür. Der Moderator, der weiß, wo das Auto steht, öffnet daraufhin eine *andere* Tür, hinter der eine Ziege steht, und bietet an zu wechseln. Sollte der Kandidat wechseln?

Lösung Schritt für Schritt.

Schritt 1 – Die Modellannahmen explizit machen. Das ist der entscheidende Schritt, und genau er wird meist unterschlagen:

(i) Das Auto steht gleichverteilt hinter einer der drei Türen.

(ii) Der Moderator öffnet *immer* eine Tür.

(iii) Er öffnet *nie* die vom Kandidaten gewählte Tür.

(iv) Er öffnet *nie* die Tür mit dem Auto.

(v) Hat er die Wahl zwischen zwei Ziegentüren, entscheidet er sich mit Wahrscheinlichkeit $\frac{1}{2}$ für jede.

Schritt 2 – Bezeichnungen. Der Kandidat wähle Tür 1 (die Nummerierung ist ohne Einschränkung). Sei A_i das Ereignis „Auto hinter Tür i“, und M_3 das Ereignis „Moderator öffnet Tür 3“.
A priori: $\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3) = \frac{1}{3}$.
Schritt 3 – Likelihoods. Was tut der Moderator in jedem Fall?

- *Auto hinter 1* (Kandidat hat richtig geraten): Der Moderator kann Tür 2 oder 3 öffnen, nach (v) je mit $\frac{1}{2}$.
$$\mathbb{P}(M_3 \mid A_1) = \tfrac{1}{2}.$$
- *Auto hinter 2*: Er darf Tür 1 nicht öffnen (iii) und Tür 2 nicht (iv). Es bleibt nur Tür 3.
$$\mathbb{P}(M_3 \mid A_2) = 1.$$
- *Auto hinter 3*: Er darf Tür 3 nicht öffnen.
$$\mathbb{P}(M_3 \mid A_3) = 0.$$

Schritt 4 – Nenner.

$$\mathbb{P}(M_3) = \tfrac{1}{2} \cdot \tfrac{1}{3} + 1 \cdot \tfrac{1}{3} + 0 \cdot \tfrac{1}{3} = \tfrac{1}{6} + \tfrac{1}{3} = \tfrac{1}{2}.$$

Schritt 5 – Bayes.

$$\mathbb{P}(A_1 \mid M_3) = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{1/6}{1/2} = \frac{1}{3},$$

$$\mathbb{P}(A_2 \mid M_3) = \frac{1 \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{1/3}{1/2} = \frac{2}{3}.$$

Antwort: Wechseln verdoppelt die Gewinnchance von $\frac{1}{3}$ auf $\frac{2}{3}$.
Schritt 6 – Die intuitive Erklärung. Die Wahrscheinlichkeit für die zuerst gewählte Tür bleibt bei $\frac{1}{3}$ – der Moderator liefert über sie keine Information, denn er öffnet sie ohnehin nie.
Die restlichen $\frac{2}{3}$ verteilten sich anfangs auf die Türen 2 und 3. Der Moderator schließt Tür 3 aus. Also konzentrieren sich die vollen $\frac{2}{3}$ auf Tür 2.
Schritt 7 – Der Extremfall macht es deutlich. Denken Sie sich 100 Türen. Sie wählen eine ($\mathbb{P} = \frac{1}{100}$). Der Moderator öffnet 98 Ziegentüren und lässt eine geschlossen. Jetzt zögert niemand mehr: Die verbleibende Tür hat die Wahrscheinlichkeit $\frac{99}{100}$.
Schritt 8 – Wie kritisch die Annahmen sind.

Ohne (iv) – der Moderator öffnet zufällig, könnte also das Auto zeigen: Wenn er zufällig eine Ziege trifft, sind beide verbleibenden Türen gleich wahrscheinlich. Wechseln bringt nichts.
Ohne (ii) – der Moderator öffnet nur manchmal, etwa nur wenn der Kandidat richtig geraten hat: Dann sollte man auf *keinen* Fall wechseln.
Das ist die eigentliche Lehre: Die Antwort hängt vollständig vom Verhalten des Moderators ab. Wer nur die Endsituation beschreibt („zwei Türen, eine Ziege ist weg"), hat das Problem nicht spezifiziert.

Der Streit von 1990

Als MARILYN VOS SAVANT 1990 in ihrer Kolumne im *Parade Magazine* zum Wechseln riet, erhielt sie etwa 10 000 Zuschriften, davon rund 92 % widersprechend. Etwa 1000 stammten von Personen mit Doktorgrad.
Ein Mathematikprofessor schrieb, sie habe unrecht und solle künftig vorsichtiger sein; ein anderer sprach vom mathematischen Analphabetismus der Nation.
PAUL ERDŐS – einer der produktivsten Mathematiker des Jahrhunderts – weigerte sich, das Ergebnis zu akzeptieren, bis ihm eine Computersimulation vorgeführt wurde. Erst danach gab er sich geschlagen, wenn auch nach eigener Aussage ohne wirkliches Verständnis.
Das Problem selbst ist älter: STEVE SELVIN beschrieb es 1975 in *The American Statistician*, und es ist strukturgleich mit dem *Drei-Gefangenen-Problem*, das MARTIN GARDNER 1959 vorstellte – und mit BERTRANDS Schachtelparadoxon von 1889.

3.4 Das Simpson-Paradoxon

Aufgabe 3.3. Zwei Behandlungsverfahren für Nierensteine werden verglichen:

	Verfahren A	**Verfahren B**
Kleine Steine	$81/87 = 93\,\%$	$234/270 = 87\,\%$
Große Steine	$192/263 = 73\,\%$	$55/80 = 69\,\%$
Gesamt	$273/350 = 78\,\%$	$289/350 = 83\,\%$

Verfahren A ist bei kleinen Steinen besser *und* bei großen Steinen besser – aber insgesamt schlechter. Wie ist das möglich?

Lösung Schritt für Schritt.

Schritt 1 – Nachrechnen, dass die Zahlen stimmen.

$$\frac{81}{87} = 0{,}931, \qquad \frac{234}{270} = 0{,}867 \Longrightarrow \text{A besser} \checkmark$$

$$\frac{192}{263} = 0{,}730, \qquad \frac{55}{80} = 0{,}688 \Longrightarrow \text{A besser}\checkmark$$
$$\frac{81+192}{87+263} = \frac{273}{350} = 0{,}780, \qquad \frac{234+55}{270+80} = \frac{289}{350} = 0{,}826 \Longrightarrow \text{B besser}\checkmark$$

Kein Rechenfehler. (Die Daten stammen aus einer realen Untersuchung von Charig und Mitarbeitern, 1986.)

Schritt 2 – Die Ursache: unterschiedliche Fallmischung.
Verfahren A wurde überwiegend bei *großen* Steinen angewandt (263 von 350, also 75 %), Verfahren B überwiegend bei *kleinen* (270 von 350, also 77 %).
Große Steine haben generell eine schlechtere Prognose. Verfahren A trat also gegen ein deutlich schwierigeres Patientenkollektiv an.

Schritt 3 – Formal. Mit E = Erfolg, V = Verfahren, S = Steingröße:

$$\mathbb{P}(E \mid V{=}A) = \mathbb{P}(E \mid V{=}A, S{=}\text{klein})\,\mathbb{P}(S{=}\text{klein} \mid V{=}A) + \mathbb{P}(E \mid V{=}A, S{=}\text{groß})\,\mathbb{P}(S{=}\text{groß} \mid V{=}A).$$

Die Gesamtrate ist ein *gewichtetes Mittel* der Teilraten – und die Gewichte unterscheiden sich zwischen den Verfahren.
Zahlenmäßig für A:

$$0{,}931 \cdot \frac{87}{350} + 0{,}730 \cdot \frac{263}{350} = 0{,}931 \cdot 0{,}249 + 0{,}730 \cdot 0{,}751 = 0{,}232 + 0{,}548 = 0{,}780.\checkmark$$

Schritt 4 – Welche Zahl gilt nun?
Die aufgeschlüsselte. Denn die Steingröße ist ein **Confounder**: Sie beeinflusst sowohl die Verfahrenswahl (Ärzte wählten A bei schweren Fällen) als auch das Ergebnis.
Die Frage, die man beantworten will, lautet: „Wenn *dieser* Patient mit *dieser* Steingröße behandelt wird – welches Verfahren ist besser?“ Und darauf antwortet nur die aufgeschlüsselte Tabelle.

Schritt 5 – Aber Vorsicht: Aufschlüsseln ist nicht immer richtig.
Wäre die dritte Variable eine *Folge* der Behandlung statt einer Ursache, so würde Aufschlüsseln das Ergebnis *verfälschen*. Beispiel: Ein Medikament senkt den Blutdruck und dadurch das Schlaganfallrisiko. Schlüsselt man nach Blutdruck auf, verschwindet der Effekt – man hat den Wirkmechanismus herausgerechnet.
Man kann also nicht aus den Daten allein entscheiden, ob man aufschlüsseln soll. Man braucht eine Annahme über die *Kausalstruktur*.
Genau das ist der Ausgangspunkt der modernen kausalen Inferenz, die JUDEA PEARL ab den 1990er Jahren entwickelte; sein *Backdoor-Kriterium* gibt eine formale Antwort auf die Frage, nach welchen Variablen man adjustieren muss und nach welchen nicht[21]. Wir kommen in Kapitel 15 darauf zurück.

Historisches. Das Phänomen beschrieb KARL PEARSON bereits 1899, UDNY YULE 1903; EDWARD SIMPSON behandelte es 1951 systematisch. Der bekannteste reale

Fall ist die Untersuchung zur Zulassungspraxis in Berkeley von 1973: Insgesamt schienen Frauen benachteiligt, in fast jedem einzelnen Fachbereich aber nicht – Frauen hatten sich häufiger auf Fächer mit generell niedrigen Zulassungsquoten beworben.

Part II

Zufallsvariablen und Verteilungen

4 Zufallsvariablen

4.1 Warum man den Ergebnisraum verlässt

Meist interessiert nicht der Ausgang selbst, sondern eine *Zahl*, die von ihm abhängt: die Augensumme, die Anzahl der Treffer, der Gewinn, die Wartezeit.

Definition 4.1. Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Eine Abbildung

$$X : \Omega \to \mathbb{R}$$

heißt **Zufallsvariable**, wenn sie **messbar** ist, das heißt

$$X^{-1}\big((-\infty, t]\big) = \{\omega \in \Omega : X(\omega) \le t\} \in \mathcal{A} \qquad \text{für alle } t \in \mathbb{R}.$$

Eine Zufallsvariable ist weder zufällig noch eine Variable

Sie ist eine *Funktion* – und zwar eine völlig deterministische. Zufällig ist allein das Argument ω.
Der Name ist historisch und irreführend, aber unausrottbar. Wenn Sie ihn stört, denken Sie „Messgröße“.

Warum Messbarkeit gefordert wird

Man will Aussagen machen wie „X liegt zwischen 3 und 5“ und diesen eine Wahrscheinlichkeit zuordnen. Dazu muss die Menge

$$\{\omega : 3 \le X(\omega) \le 5\}$$

überhaupt *in $\mathcal{A}$ liegen* – sonst ist $\mathbb{P}$ darauf nicht definiert.
Die Bedingung mit den Mengen $\{X \le t\}$ genügt, weil sich alles Übrige daraus durch abzählbare Operationen ergibt:

$$\{X > t\} = \{X \le t\}^c, \qquad \{a < X \le b\} = \{X \le b\} \setminus \{X \le a\},$$

$$\{X < t\} = \bigcup_{n=1}^{\infty} \{X \le t - \tfrac{1}{n}\}, \qquad \{X = t\} = \{X \le t\} \setminus \{X < t\}.$$

Alle diese Mengen liegen nach den σ-Algebra-Axiomen wieder in $\mathcal{A}$. ✓
Praktische Beruhigung: Alles, was man je hinschreibt, ist messbar. Summen, Produkte, Grenzwerte und Verkettungen messbarer Funktionen sind wieder messbar. Man prüft die Bedingung in der Praxis nie.

Die Schreibweise

Statt $\mathbb{P}(\{\omega : X(\omega) \le t\})$ schreibt man kurz

$$\mathbb{P}(X \le t).$$

Das ist eine der wenigen Stellen in der Mathematik, wo eine Abkürzung so vollständig übernommen wurde, dass die ausführliche Form kaum noch erscheint. Man sollte dennoch einmal gesehen haben, was dahintersteht – gerade weil Verwirrung darüber die häufigste Quelle konzeptueller Fehler ist.

4.2 Die Verteilungsfunktion

Definition 4.2. Die **Verteilungsfunktion** von X ist

$$F_X(t) := \mathbb{P}(X \le t), \qquad t \in \mathbb{R}.$$

Satz 4.3 (Charakterisierung). *$F = F_X$ hat die Eigenschaften*

(a) F ist monoton wachsend,

(b) $\lim_{t\to-\infty} F(t) = 0$ und $\lim_{t\to\infty} F(t) = 1$,

(c) F ist rechtsseitig stetig.

Umgekehrt gibt es zu jeder Funktion mit diesen drei Eigenschaften eine Zufallsvariable mit genau dieser Verteilungsfunktion.

Beweis. **(a).** Für $s \le t$ ist $\{X \le s\} \subseteq \{X \le t\}$; Monotonie des Maßes (Satz 1.7(c)).

(b). Die Mengen $\{X \le n\}$ steigen für $n \to \infty$ auf gegen Ω. Nach der Stetigkeit von unten (Satz 1.9(a)):

$$\lim_n F(n) = \mathbb{P}(\Omega) = 1.$$

Analog fallen $\{X \le -n\}$ gegen $\emptyset$; Stetigkeit von oben liefert den Grenzwert 0.

(c). Die Mengen $\{X \le t + \frac{1}{n}\}$ fallen gegen $\{X \le t\}$ – denn ein ω liegt genau dann in allen, wenn $X(\omega) \le t + \frac{1}{n}$ für jedes n, also $X(\omega) \le t$. Stetigkeit von oben:

$$\lim_n F\left(t + \tfrac{1}{n}\right) = F(t).$$

■

Warum *rechts*seitig stetig?

Das ist eine Folge der Konvention „$\le$“ in der Definition. Hätte man $F(t) := \mathbb{P}(X < t)$ gesetzt, wäre F linksseitig stetig. Die Wahl ist willkürlich, aber international einheitlich.

Was die Sprungstellen bedeuten:

$$\mathbb{P}(X = t) = F(t) - \lim_{s\uparrow t} F(s) = F(t) - F(t^-).$$

Die Sprunghöhe ist die Punktwahrscheinlichkeit. Ist F stetig, so gilt $\mathbb{P}(X = t) = 0$ für alle t – kein einzelner Wert wird mit positiver Wahrscheinlichkeit angenommen. Da eine monotone Funktion höchstens abzählbar viele Sprungstellen hat (jeder Sprung enthält eine eigene rationale Zahl), kann eine Zufallsvariable höchstens abzählbar viele Werte mit positiver Wahrscheinlichkeit annehmen.

4.3 Diskrete und stetige Zufallsvariablen

Definition 4.4. X heißt **diskret**, wenn X nur abzählbar viele Werte $x_1, x_2, \ldots$ annimmt. Die Funktion

$$p_X(x_i) := \mathbb{P}(X = x_i)$$

heißt **Zähldichte** oder Wahrscheinlichkeitsfunktion; es gilt $\sum_i p_X(x_i) = 1$.

X heißt **(absolut) stetig**, wenn es eine integrierbare Funktion $f_X \geq 0$ gibt mit

$$F_X(t) = \int_{-\infty}^{t} f_X(x)\,\mathrm{d}x \qquad \text{für alle } t.$$

f_X heißt **Dichte**.

Wie man mit Dichten rechnet

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(x)\,\mathrm{d}x, \qquad \int_{-\infty}^{\infty} f_X(x)\,\mathrm{d}x = 1.$$

An Stetigkeitsstellen von f_X gilt nach dem Hauptsatz (Band 3, Kapitel 10)

$$f_X(t) = F_X'(t).$$

Die Dichte ist keine Wahrscheinlichkeit

$f_X(x)$ kann größer als 1 sein – beliebig groß sogar. Zum Beispiel hat die Gleichverteilung auf $[0; 0{,}01]$ die Dichte 100.
Was eine Wahrscheinlichkeit ist, ist die *Fläche*:

$$\mathbb{P}(x \leq X \leq x + h) \approx f_X(x) \cdot h \qquad \text{für kleines } h.$$

Die Dichte ist eine *Wahrscheinlichkeit pro Längeneinheit* – so wie die Massendichte eine Masse pro Volumeneinheit ist. Die Analogie ist exakt und namengebend.

Konsequenz: Für stetige Zufallsvariablen ist

$$\mathbb{P}(X = x) = \int_x^x f_X = 0$$

für jedes einzelne x. Deshalb spielt es keine Rolle, ob man $\leq$ oder $<$ schreibt:

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X < b).$$

Bei diskreten Zufallsvariablen ist dieser Unterschied dagegen entscheidend – eine häufige Fehlerquelle beim Übergang zwischen beiden Welten.

Es gibt noch eine dritte Sorte

Nicht jede Zufallsvariable ist diskret oder stetig. Drei Fälle:
1. Gemischt. Eine Versicherung zahlt mit Wahrscheinlichkeit 0,9 nichts und sonst einen exponentialverteilten Betrag. Die Verteilungsfunktion hat einen Sprung bei 0 und wächst danach stetig.
2. Singulär stetig. Es gibt Zufallsvariablen mit *stetiger* Verteilungsfunktion, die dennoch keine Dichte besitzen. Das Standardbeispiel ist die **Cantorsche Treppenfunktion**: Sie ist stetig, monoton, wächst von 0 auf 1 – und hat fast überall die Ableitung null. Die zugehörige Verteilung lebt auf der Cantormenge, die selbst eine Lebesgue-Nullmenge ist.
Der Zerlegungssatz von Lebesgue besagt: Jede Verteilung ist eine Mischung dieser drei reinen Typen. In der Praxis kommt der singuläre Anteil kaum vor – aber es ist wichtig zu wissen, dass die Dichotomie „diskret oder stetig“ unvollständig ist.

Aufgabe 4.1. Sei X eine Zufallsvariable mit der Dichte

$$f(x) = \begin{cases} c\,x^2, & 0 \le x \le 3 \\ 0, & \text{sonst.} \end{cases}$$

(a) Bestimmen Sie c.
(b) Bestimmen Sie die Verteilungsfunktion.
(c) Berechnen Sie $\mathbb{P}(1 \le X \le 2)$.
(d) Bestimmen Sie den *Median*, also das m mit $F(m) = \frac{1}{2}$.

Lösung Schritt für Schritt.

(a) Normierung. Die Gesamtfläche muss 1 sein:

$$1 = \int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = \int_0^3 c\,x^2\,\mathrm{d}x = c\left[\frac{x^3}{3}\right]_0^3 = c \cdot \frac{27}{3} = 9c.$$

Also

$$c = \frac{1}{9}.$$

Kontrolle: $f(3) = \frac{9}{9} = 1$; die Dichte ist auf $[0,3]$ überall zwischen 0 und 1. Das muss nicht so sein, ist hier aber plausibel. ✓

(b) Verteilungsfunktion. Für $0 \le t \le 3$:

$$F(t) = \int_0^t \frac{x^2}{9}\,\mathrm{d}x = \frac{1}{9}\left[\frac{x^3}{3}\right]_0^t = \frac{t^3}{27}.$$

Insgesamt:

$$F(t) = \begin{cases} 0, & t < 0 \\ \dfrac{t^3}{27}, & 0 \le t \le 3 \\ 1, & t > 3. \end{cases}$$

Prüfung der drei Eigenschaften: monoton wachsend ✓; $F(0) = 0$, $F(3) = 1$ ✓; stetig, also erst recht rechtsseitig stetig ✓.

(c) Intervallwahrscheinlichkeit.

$$\mathbb{P}(1 \le X \le 2) = F(2) - F(1) = \frac{8}{27} - \frac{1}{27} = \frac{7}{27} = 0{,}259.$$

Direkte Kontrolle über das Integral:

$$\int_1^2 \frac{x^2}{9} dx = \frac{1}{27}\left[x^3\right]_1^2 = \frac{8-1}{27} = \frac{7}{27}. \checkmark$$

(d) Median.

$$\frac{m^3}{27} = \frac{1}{2} \Longrightarrow m^3 = 13{,}5 \Longrightarrow m = \sqrt[3]{13{,}5} \approx 2{,}381.$$

Beobachtung. Der Median liegt deutlich rechts von der Intervallmitte 1,5. Das ist plausibel: Die Dichte x^2 wächst, die Wahrscheinlichkeitsmasse konzentriert sich also rechts.
Zur Einordnung: Der Erwartungswert (Kapitel 7) beträgt hier

$$\int_0^3 x \cdot \frac{x^2}{9} dx = \frac{1}{9}\left[\frac{x^4}{4}\right]_0^3 = \frac{81}{36} = 2{,}25,$$

liegt also *links* vom Median. Das ist ungewöhnlich – bei den meisten Schulbeispielen ist es umgekehrt – und zeigt, dass die verbreitete Faustregel „bei linkssteilen Verteilungen liegt der Mittelwert rechts vom Median“ keine allgemeine Gültigkeit hat.

4.4 Transformationen

Satz 4.5 (Transformationsformel für Dichten). *Sei X stetig mit Dichte f_X und g eine streng monotone, stetig differenzierbare Funktion. Dann hat $Y := g(X)$ die Dichte*

$$f_Y(y) = f_X\big(g^{-1}(y)\big) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|.$$

Beweis. Sei g streng monoton wachsend. Dann

$$F_Y(y) = \mathbb{P}(g(X) \le y) = \mathbb{P}\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big).$$

(Die mittlere Umformung ist erlaubt, weil g monoton wachsend und damit die Ungleichung erhaltend ist.)

Differenzieren nach y mit der Kettenregel:

$$f_Y(y) = f_X\big(g^{-1}(y)\big) \cdot \big(g^{-1}\big)'(y).$$

Bei fallendem g dreht sich die Ungleichung um; man erhält $F_Y(y) = 1 - F_X(g^{-1}(y))$ und beim Differenzieren ein zusätzliches Minuszeichen, das durch den Betrag aufgefangen wird. ∎

> **Der Jacobi-Faktor – schon wieder**
>
> Der Betrag der Ableitung ist genau dasselbe Phänomen wie die Funktionaldeterminante bei der mehrdimensionalen Substitution (Band 3, Kapitel 13) und wie $|\det A|$ als Volumenfaktor (Band 2, Kapitel 6).
> *Anschaulich:* Wird ein kleines Intervall der Länge h durch g auf ein Intervall der Länge $|g'| \cdot h$ gestreckt, so muss die Dichte um denselben Faktor *sinken*, damit die Wahrscheinlichkeitsmasse erhalten bleibt.

Satz 4.6 (Quantiltransformation). *Sei U gleichverteilt auf $[0,1]$ und F eine beliebige Verteilungsfunktion. Dann hat*

$$X := F^{-1}(U), \qquad F^{-1}(u) := \inf\{t : F(t) \geq u\},$$

genau die Verteilungsfunktion F.

Beweis. Für stetiges, streng monotones F ist es unmittelbar:

$$\mathbb{P}(X \leq t) = \mathbb{P}\big(F^{-1}(U) \leq t\big) = \mathbb{P}\big(U \leq F(t)\big) = F(t),$$

wobei die letzte Gleichung die Verteilungsfunktion der Gleichverteilung auf $[0,1]$ benutzt: $\mathbb{P}(U \leq u) = u$ für $u \in [0,1]$.

Im allgemeinen Fall ersetzt man die Umkehrfunktion durch die verallgemeinerte Inverse und zeigt die Äquivalenz $F^{-1}(u) \leq t \iff u \leq F(t)$. ∎

> **Warum jede Simulation damit anfängt**
>
> Ein Computer erzeugt (Pseudo-)Zufallszahlen, die gleichverteilt auf $[0,1]$ sind. Satz 4.6 sagt: Daraus lässt sich *jede* Verteilung gewinnen – man wendet einfach die inverse Verteilungsfunktion an.
> **Beispiel Exponentialverteilung.** Es ist $F(t) = 1 - \mathrm{e}^{-\lambda t}$, also
>
> $$u = 1 - \mathrm{e}^{-\lambda t} \Longrightarrow \mathrm{e}^{-\lambda t} = 1 - u \Longrightarrow t = -\frac{\ln(1-u)}{\lambda}.$$
>
> Man erzeugt U und setzt $X := -\frac{1}{\lambda}\ln(1-U)$. Da mit U auch $1-U$ gleichverteilt ist, benutzt man in der Praxis $-\frac{1}{\lambda}\ln U$.

Wenn F^{-1} nicht geschlossen darstellbar ist – etwa bei der Normalverteilung – benutzt man andere Verfahren: die Box–Muller-Transformation (1958), die aus zwei gleichverteilten Zahlen zwei standardnormalverteilte macht, oder Verwerfungsverfahren.
Umgekehrt gilt: Ist X stetig verteilt mit Verteilungsfunktion F, so ist $F(X)$ gleichverteilt auf $[0, 1]$. Das ist die theoretische Grundlage der p-Werte (Kapitel 14): Unter der Nullhypothese ist ein p-Wert gleichverteilt.

5 Die diskreten Verteilungen

5.1 Bernoulli und Binomial

Definition 5.1. X heißt **Bernoulli-verteilt** mit Parameter $p \in [0,1]$, geschrieben $X \sim \mathrm{Bern}(p)$, wenn

$$\mathbb{P}(X=1) = p, \qquad \mathbb{P}(X=0) = 1-p.$$

Das ist der einfachste nichttriviale Fall: ein Versuch mit zwei Ausgängen, „Treffer“ und „Niete“. Alles Weitere baut darauf auf.

Definition 5.2. $X \sim \mathrm{Bin}(n,p)$, wenn

$$\mathbb{P}(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0,1,\dots,n.$$

Woher die Formel kommt

X zählt die Treffer bei n *unabhängigen* Versuchen mit je der Trefferwahrscheinlichkeit p.
Eine *bestimmte* Folge mit k Treffern – etwa TTNTN…– hat wegen der Unabhängigkeit die Wahrscheinlichkeit

$$\underbrace{p \cdots p}_{k} \cdot \underbrace{(1-p)\cdots(1-p)}_{n-k} = p^k (1-p)^{n-k}.$$

Und es gibt $\binom{n}{k}$ solche Folgen – so viele, wie es Möglichkeiten gibt, die k Trefferpositionen auszuwählen.
Normierungsprobe. Nach dem binomischen Lehrsatz:

$$\sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} = \big(p + (1-p)\big)^n = 1^n = 1. \checkmark$$

Die drei Voraussetzungen – und warum sie oft verletzt sind

1. Feste Anzahl n von Versuchen.
2. Konstante Trefferwahrscheinlichkeit p.
3. Unabhängigkeit der Versuche.

Typische Verletzungen in der Praxis:

- Ziehen *ohne* Zurücklegen verletzt 2 und 3 $\Longrightarrow$ hypergeometrische Verteilung.

- Ansteckende Krankheiten verletzen 3 $\Longrightarrow$ Überdispersion; die tatsächliche Varianz ist größer als $np(1-p)$.
- Patienten mit unterschiedlichem Risiko verletzen 2 $\Longrightarrow$ Poisson-Binomial-Verteilung oder Beta-Binomial-Modelle.

Die Binomialverteilung ohne Prüfung dieser Voraussetzungen anzuwenden ist einer der häufigsten Modellierungsfehler.

Aufgabe 5.1. Ein Medikament wirkt bei 70 % der Patienten. Es wird an 12 Patienten erprobt.

(a) Wie wahrscheinlich ist es, dass es bei genau 9 wirkt?
(b) Wie wahrscheinlich ist es, dass es bei höchstens 6 wirkt?
(c) Bei wie vielen Patienten wirkt es im Mittel?

Lösung Schritt für Schritt.

Modell: $X \sim \mathrm{Bin}(12;\ 0{,}7)$.

(a)

$$\mathbb{P}(X = 9) = \binom{12}{9} 0{,}7^9\, 0{,}3^3.$$

Teilrechnungen:

$$\binom{12}{9} = \binom{12}{3} = \frac{12 \cdot 11 \cdot 10}{6} = 220,$$

$$0{,}7^9 = 0{,}040354, \qquad 0{,}3^3 = 0{,}027.$$

$$\mathbb{P}(X = 9) = 220 \cdot 0{,}040354 \cdot 0{,}027 = 0{,}2397.$$

Etwa 24 %.

(b) Hier muss man summieren:

$$\mathbb{P}(X \le 6) = \sum_{k=0}^{6} \binom{12}{k} 0{,}7^k 0{,}3^{12-k}.$$

k	$\mathbb{P}(X = k)$	kumuliert
0	0,0000005	0,0000005
1	0,0000151	0,0000156
2	0,0002	0,0002
3	0,0015	0,0017
4	0,0078	0,0095
5	0,0291	0,0386
6	0,0792	0,1178

$$\mathbb{P}(X \le 6) = 0{,}118.$$

Etwa 12 %.
Exemplarische Einzelrechnung für $k = 6$:

$$\binom{12}{6} = 924, \quad 0{,}7^6 = 0{,}117649, \quad 0{,}3^6 = 0{,}000729,$$

$$924 \cdot 0{,}117649 \cdot 0{,}000729 = 0{,}0792. \checkmark$$

(c) Der Erwartungswert (Kapitel 7) beträgt

$$\mathbb{E}[X] = np = 12 \cdot 0{,}7 = 8{,}4.$$

Plausibilitätsprüfung. Der wahrscheinlichste Wert ist $k = 9$ mit 24 %, dicht gefolgt von $k = 8$. Der Erwartungswert 8,4 liegt dazwischen. ✓
Praktische Bemerkung. Teil (b) beantwortet eine klinisch relevante Frage: Wenn das Medikament wirklich zu 70 % wirkt, wie überraschend wäre ein Ergebnis von 6 oder weniger Erfolgen? Antwort: In 12 % der Studien käme so etwas heraus – also durchaus nicht selten. Genau diese Denkfigur ist der p-Wert (Kapitel 14).

5.2 Die geometrische Verteilung

Definition 5.3. $X \sim \text{Geo}(p)$ zählt die Anzahl der Versuche *bis zum ersten Treffer* (einschließlich):

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \qquad k = 1, 2, 3, \ldots$$

Normierung und die Gedächtnislosigkeit

Normierung über die geometrische Reihe (Band 3, Kapitel 3):

$$\sum_{k=1}^{\infty} (1-p)^{k-1} p = p \sum_{j=0}^{\infty} (1-p)^j = p \cdot \frac{1}{1-(1-p)} = \frac{p}{p} = 1. \checkmark$$

Gedächtnislosigkeit. Für alle $m, n \ge 0$:

$$\mathbb{P}(X > m+n \mid X > m) = \mathbb{P}(X > n).$$

Beweis. Es ist $\mathbb{P}(X > n) = (1-p)^n$ (die ersten n Versuche sind alle Nieten). Also

$$\mathbb{P}(X > m+n \mid X > m) = \frac{(1-p)^{m+n}}{(1-p)^m} = (1-p)^n = \mathbb{P}(X > n). \quad \blacksquare$$

Was das bedeutet: Nach 20 Nieten ist die Wartezeit auf den nächsten Treffer genauso verteilt wie am Anfang. Der Würfel hat kein Gedächtnis.
Der Spielerfehlschluss besteht genau darin, das zu bestreiten – „jetzt muss doch bald eine Sechs kommen“. Sie muss nicht. Der berühmteste Fall ereignete sich am

18. August 1913 im Casino von Monte Carlo, wo beim Roulette 26-mal hintereinander Schwarz fiel; die Spieler setzten immer höhere Summen auf Rot und verloren Millionen.
Die geometrische Verteilung ist die einzige gedächtnislose diskrete Verteilung – und ihr stetiges Gegenstück, die Exponentialverteilung, die einzige stetige. Das ist ein Satz, kein Zufall.

Zwei Konventionen

Manche Autoren zählen die *Nieten vor* dem ersten Treffer:

$$\mathbb{P}(Y = k) = (1-p)^k p, \qquad k = 0, 1, 2, \ldots$$

Dann ist $Y = X - 1$, und die Erwartungswerte unterscheiden sich um 1: $\mathbb{E}[X] = \frac{1}{p}$ gegenüber $\mathbb{E}[Y] = \frac{1-p}{p}$.
Beim Nachschlagen in Formelsammlungen und beim Benutzen von Software muss man stets prüfen, welche Konvention gilt. (R und Python/SciPy verwenden die zweite.)

5.3 Die hypergeometrische Verteilung

Definition 5.4. Aus einer Urne mit N Kugeln, davon M markiert, werden n *ohne Zurücklegen* gezogen. Die Anzahl X der gezogenen markierten Kugeln ist **hypergeometrisch verteilt**:

$$\mathbb{P}(X = k) = \frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}.$$

Binomial oder hypergeometrisch?

	Binomial	Hypergeometrisch
Ziehen	mit Zurücklegen	ohne Zurücklegen
Versuche	unabhängig	abhängig
Erwartungswert	np	$n\frac{M}{N}$
Varianz	$np(1-p)$	$n\frac{M}{N}\left(1-\frac{M}{N}\right)\frac{N-n}{N-1}$

Der Faktor $\frac{N-n}{N-1}$ heißt **Endlichkeitskorrektur**. Er ist stets ≤ 1: Ziehen ohne Zurücklegen hat *kleinere* Varianz, weil sich die Zusammensetzung der Urne mit jeder Ziehung stabilisiert.
Faustregel: Ist $n \leq 0{,}05\,N$ – die Stichprobe also klein gegenüber der Grundgesamtheit –, so darf man die Binomialverteilung als Näherung benutzen. Bei einer

Umfrage unter 1000 von 60 Millionen Wahlberechtigten ist die Korrektur völlig vernachlässigbar; deshalb spielt die *Bevölkerungsgröße* für die Genauigkeit einer Umfrage praktisch keine Rolle – entgegen einer verbreiteten Vorstellung.

5.4 Die Poisson-Verteilung

Definition 5.5. $X \sim \mathrm{Poi}(\lambda)$ mit $\lambda > 0$, wenn

$$\mathbb{P}(X = k) = \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}, \qquad k = 0, 1, 2, \ldots$$

Normierung

$$\sum_{k=0}^{\infty} \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!} = \mathrm{e}^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = \mathrm{e}^{-\lambda}\mathrm{e}^{\lambda} = 1.\checkmark$$

Hier steht die Exponentialreihe aus Band 3, Kapitel 5. Die Poisson-Verteilung ist gewissermaßen die auf 1 normierte Exponentialreihe.

Satz 5.6 (Poisson-Grenzwertsatz). *Sei $X_n \sim \mathrm{Bin}(n, p_n)$ mit $np_n \to \lambda > 0$. Dann gilt für jedes feste k:*

$$\mathbb{P}(X_n = k) \longrightarrow \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}.$$

Beweis. Wir setzen $p_n = \frac{\lambda_n}{n}$ mit $\lambda_n := np_n \to \lambda$ und schreiben

$$\binom{n}{k} p_n^k (1-p_n)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda_n^k}{n^k} \cdot \left(1 - \frac{\lambda_n}{n}\right)^{n-k}.$$

Wir behandeln die drei Faktoren einzeln.

Faktor 1.

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} = \underbrace{1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}_{k \text{ Faktoren, jeder} \to 1} \longrightarrow 1.$$

(Hier geht ein, dass k *fest* ist – die Anzahl der Faktoren wächst nicht mit.)

Faktor 2. $\frac{\lambda_n^k}{k!} \to \frac{\lambda^k}{k!}$.

Faktor 3. Nach Band 3, Satz zur Eulerschen Zahl gilt $\left(1 - \frac{\lambda_n}{n}\right)^n \to \mathrm{e}^{-\lambda}$. Und

$$\left(1 - \frac{\lambda_n}{n}\right)^{-k} \longrightarrow 1^{-k} = 1,$$

da die Basis gegen 1 strebt und der Exponent fest ist.

Produkt der Grenzwerte:

$$\frac{\lambda^k}{k!}\mathrm{e}^{-\lambda}. \qquad \blacksquare$$

Die Poisson-Verteilung als Gesetz der seltenen Ereignisse

Sie beschreibt Situationen mit *vielen Gelegenheiten* und *kleiner Einzelwahrscheinlichkeit*:

- Zahl der Anrufe in einer Stunde,
- Zahl der Druckfehler pro Seite,
- Zahl der radioaktiven Zerfälle pro Sekunde,
- Zahl der Mutationen pro Genomabschnitt,
- Zahl der Verkehrsunfälle an einer Kreuzung pro Jahr.

Faustregel für die Näherung: $n \geq 50$ und $p \leq 0{,}1$, oder allgemein $np \leq 10$.
Die charakteristische Eigenschaft: Bei der Poisson-Verteilung sind Erwartungswert und Varianz *gleich*, nämlich beide λ. Das ist ein praktischer Modelltest: Ist die empirische Varianz deutlich größer als der Mittelwert (**Überdispersion**), so ist die Poisson-Annahme verletzt – meist, weil die Ereignisse doch nicht unabhängig sind oder die Rate schwankt. Man weicht dann auf die negative Binomialverteilung aus.

Bortkiewicz und die Pferdetritte

Siméon Denis Poisson veröffentlichte die Verteilung 1837 in einer Arbeit über Gerichtsurteile – als Nebenresultat, das er selbst kaum beachtete. Sie blieb über fünfzig Jahre praktisch unbenutzt.
Berühmt machte sie Ladislaus von Bortkiewicz 1898 in *Das Gesetz der kleinen Zahlen*[5]. Er untersuchte darin, wie viele Soldaten in den 14 Kavalleriekorps der preußischen Armee jährlich durch Pferdetritt zu Tode kamen – über 20 Jahre, also 280 Korpsjahre.

Tote pro Korpsjahr	beobachtet	Poisson ($\lambda = 0{,}61$)
0	144	143,1
1	91	87,4
2	32	26,7
3	11	5,4
4	2	0,8
≥ 5	0	0,1

Die Übereinstimmung ist bemerkenswert. Bortkiewicz' Punkt war ein methodischer: Auch dort, wo jedes Einzelereignis eine individuelle Ursache hat – ein unaufmerksamer Soldat, ein nervöses Pferd –, folgt die *Gesamtzahl* einem präzisen Gesetz.
Das Beispiel steht bis heute in praktisch jedem Lehrbuch. Es hat allerdings einen Schönheitsfehler, den Bortkiewicz selbst bemerkte: Die Korps waren nicht gleich groß und nicht gleich gefährlich, sodass die Annahme einer einheitlichen Rate λ

streng genommen verletzt ist. Die leichte Überdispersion bei 3 und 4 Toten dürfte darauf zurückgehen.

Aufgabe 5.2. In einer Klinik treten im Mittel 2,5 nosokomiale Infektionen pro Woche auf.

(a) Wie wahrscheinlich ist eine Woche ohne Infektion?

(b) Wie wahrscheinlich sind mehr als 5 Infektionen?

(c) In wie vielen von 52 Wochen erwartet man mindestens 5 Infektionen?

Lösung Schritt für Schritt.

Modell: $X \sim \mathrm{Poi}(2{,}5)$.

Vorüberlegung zur Modellwahl. Infektionen sind seltene Ereignisse mit vielen Gelegenheiten (Patiententage). Die Poisson-Annahme ist plausibel – *sofern* keine Ausbrüche auftreten, bei denen ein Fall weitere nach sich zieht. Genau darauf zielt die statistische Ausbruchserkennung: Sie prüft, ob die beobachtete Zahl mit der Poisson-Annahme verträglich ist.

(a)

$$\mathbb{P}(X = 0) = \mathrm{e}^{-2{,}5}\frac{2{,}5^0}{0!} = \mathrm{e}^{-2{,}5} = 0{,}0821.$$

Etwa 8 % der Wochen.

(b) Über das Gegenereignis:

$$\mathbb{P}(X > 5) = 1 - \mathbb{P}(X \le 5) = 1 - \sum_{k=0}^{5} \mathrm{e}^{-2{,}5}\frac{2{,}5^k}{k!}.$$

k	$\frac{2{,}5^k}{k!}$	$\mathbb{P}(X = k)$
0	1	0,0821
1	2,5	0,2052
2	3,125	0,2565
3	2,6042	0,2138
4	1,6276	0,1336
5	0,8138	0,0668

$$\mathbb{P}(X \le 5) = 0{,}0821 + 0{,}2052 + 0{,}2565 + 0{,}2138 + 0{,}1336 + 0{,}0668 = 0{,}9580.$$

$$\mathbb{P}(X > 5) = 0{,}0420.$$

Nützlicher Rechentrick: Man muss die Potenzen nicht einzeln bestimmen. Es gilt

$$\mathbb{P}(X = k) = \mathbb{P}(X = k-1) \cdot \frac{\lambda}{k}.$$

Aus $\mathbb{P}(X=0) = 0{,}0821$ folgt $\mathbb{P}(X=1) = 0{,}0821 \cdot 2{,}5 = 0{,}2052$, dann $\mathbb{P}(X=2) = 0{,}2052 \cdot \frac{2{,}5}{2} = 0{,}2565$, und so fort. ✓

(c)

$$\mathbb{P}(X \geq 5) = 1 - \mathbb{P}(X \leq 4) = 1 - 0{,}8912 = 0{,}1088.$$

$$52 \cdot 0{,}1088 = 5{,}66.$$

Man erwartet also in etwa 6 von 52 Wochen mindestens 5 Infektionen.
Die praktische Folgerung. Eine Woche mit 5 Infektionen ist *kein* Alarmzeichen – sie kommt bei unveränderter Rate mehrmals jährlich vor. Wer bei jedem solchen Ausschlag Maßnahmen ergreift, reagiert auf Rauschen.
Das ist ein allgemeines Prinzip der Qualitätssicherung: Man muss die *natürliche Streuung* eines Prozesses kennen, bevor man Abweichungen interpretiert. WALTER SHEWHART formulierte diesen Gedanken 1924 bei Bell Labs und legte damit den Grund für die statistische Prozesskontrolle; W. EDWARDS DEMING trug ihn nach dem Krieg nach Japan.
Wann wäre es ein Alarmzeichen? Bei $X \geq 8$ ist $\mathbb{P} = 0{,}0019$ – in 52 Wochen erwartet man das 0,1-mal. Das wäre auffällig.

6 Die stetigen Verteilungen

6.1 Gleichverteilung und Exponentialverteilung

Definition 6.1. $X \sim \mathrm{U}(a,b)$, wenn

$$f(x) = \frac{1}{b-a} \quad \text{für } a \le x \le b, \qquad f(x) = 0 \text{ sonst.}$$

Definition 6.2. $X \sim \mathrm{Exp}(\lambda)$ mit $\lambda > 0$, wenn

$$f(x) = \lambda \mathrm{e}^{-\lambda x} \quad \text{für } x \ge 0, \qquad F(x) = 1 - \mathrm{e}^{-\lambda x}.$$

Die Exponentialverteilung als Wartezeit

Sie beschreibt die Wartezeit auf ein Ereignis, das *mit konstanter Rate* eintritt: Lebensdauer eines Bauteils ohne Verschleiß, Zeit bis zum nächsten Anruf, Zeit bis zum nächsten radioaktiven Zerfall.

Der Zusammenhang mit Poisson: Treten Ereignisse mit Rate λ pro Zeiteinheit Poisson-verteilt auf, so sind die *Zwischenankunftszeiten* $\mathrm{Exp}(\lambda)$-verteilt. Beide Verteilungen beschreiben denselben Prozess – die eine zählt, die andere misst Zeit.

Beweis der Äquivalenz. Sei $N(t) \sim \mathrm{Poi}(\lambda t)$ die Anzahl der Ereignisse bis zur Zeit t, und T die Wartezeit auf das erste. Dann

$$\mathbb{P}(T > t) = \mathbb{P}(N(t) = 0) = \mathrm{e}^{-\lambda t} \frac{(\lambda t)^0}{0!} = \mathrm{e}^{-\lambda t},$$

also $F_T(t) = 1 - \mathrm{e}^{-\lambda t}$. ∎

Satz 6.3 (Gedächtnislosigkeit). *Für $X \sim \mathrm{Exp}(\lambda)$ und alle $s, t \ge 0$ gilt*

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

Umgekehrt ist die Exponentialverteilung die einzige *stetige Verteilung auf $[0, \infty)$ mit dieser Eigenschaft.*

Beweis. **Die Eigenschaft.**

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{\mathrm{e}^{-\lambda(s+t)}}{\mathrm{e}^{-\lambda s}} = \mathrm{e}^{-\lambda t} = \mathbb{P}(X > t).$$

Die Eindeutigkeit. Sei $G(t) := \mathbb{P}(X > t)$. Gedächtnislosigkeit bedeutet

$$G(s + t) = G(s)\, G(t) \qquad \text{für alle } s, t \ge 0.$$

Das ist die **Cauchysche Funktionalgleichung** in multiplikativer Form. Ist G messbar und nicht identisch null, so folgt daraus $G(t) = \mathrm{e}^{-\lambda t}$.

Beweisskizze. Setze $g := \ln G$. Dann $g(s+t) = g(s) + g(t)$. Induktiv folgt $g(nt) = ng(t)$, also $g\left(\frac{m}{n}\right) = \frac{m}{n} g(1)$ für alle rationalen Argumente. Wegen der Monotonie von G überträgt sich das per Dichtheit von $\mathbb{Q}$ (Band 3, Kapitel 1) auf alle reellen Argumente: $g(t) = t\,g(1)$. Mit $\lambda := -g(1) > 0$ folgt die Behauptung. ∎

Gedächtnislosigkeit ist eine starke Annahme

Sie besagt: Ein zehn Jahre altes Bauteil ist so gut wie ein neues. Für elektronische Bauteile ohne Verschleiß ist das eine brauchbare Näherung; für mechanische, für Menschen und für die meisten biologischen Systeme ist es falsch.
Die Alternative ist die **Weibull-Verteilung** mit

$$F(x) = 1 - \exp\bigl(-(x/\alpha)^{\beta}\bigr),$$

deren **Ausfallrate** $\frac{f(x)}{1-F(x)}$ für $\beta > 1$ wächst (Verschleiß), für $\beta < 1$ fällt (Frühausfälle) und für $\beta = 1$ konstant ist – dann ist sie die Exponentialverteilung.
Die charakteristische „Badewannenkurve“ der Zuverlässigkeitstechnik – hohe Frühausfallrate, konstante Phase, steigende Verschleißrate – setzt man aus drei Weibull-Anteilen zusammen. Dieselbe Kurve beschreibt die menschliche Sterblichkeit: Säuglingssterblichkeit, stabile mittlere Jahre, exponentiell steigende Altersterblichkeit nach dem Gompertz-Gesetz von 1825.

6.2 Die Normalverteilung

Definition 6.4. $X \sim \mathcal{N}(\mu, \sigma^2)$, wenn

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \qquad x \in \mathbb{R}.$$

Für $\mu = 0$, $\sigma = 1$ heißt sie **Standardnormalverteilung**; ihre Dichte wird mit φ, ihre Verteilungsfunktion mit Φ bezeichnet.

Satz 6.5 (Normierung). $\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = 1$.

Beweis. Substitution $z := \frac{x-\mu}{\sigma}$, also $dx = \sigma\,\mathrm{d}z$:

$$\int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} \mathrm{e}^{-z^2/2} \sigma\,\mathrm{d}z = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \mathrm{e}^{-z^2/2}\,\mathrm{d}z.$$

Nun substituieren wir $u := \frac{z}{\sqrt{2}}$, also $dz = \sqrt{2}\,\mathrm{d}u$:

$$= \frac{\sqrt{2}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \mathrm{e}^{-u^2}\,\mathrm{d}u = \frac{\sqrt{2}}{\sqrt{2\pi}} \cdot \sqrt{\pi} = \frac{\sqrt{2\pi}}{\sqrt{2\pi}} = 1,$$

wobei das Gauß-Integral aus Band 3, Kapitel 11 benutzt wurde. ∎

Standardisierung – die wichtigste Rechentechnik

Ist $X \sim \mathcal{N}(\mu, \sigma^2)$, so ist

$$Z := \frac{X - \mu}{\sigma} \sim \mathcal{N}(0,1).$$

Beweis. Nach der Transformationsformel (Satz 4.5) mit $g(x) = \frac{x-\mu}{\sigma}$, also $g^{-1}(z) = \sigma z + \mu$ und $(g^{-1})' = \sigma$:

$$f_Z(z) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\sigma z + \mu - \mu)^2}{2\sigma^2}\right) \cdot \sigma = \frac{1}{\sqrt{2\pi}} \mathrm{e}^{-z^2/2}. \quad \blacksquare$$

Damit rechnet man alles auf Φ zurück:

$$\mathbb{P}(a \le X \le b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$

Deshalb genügt eine einzige Tabelle für alle Normalverteilungen.
Nützliche Werte:

$$\Phi(0) = 0{,}5, \quad \Phi(1) = 0{,}8413, \quad \Phi(1{,}645) = 0{,}95,$$

$$\Phi(1{,}96) = 0{,}975, \quad \Phi(2{,}576) = 0{,}995.$$

Symmetrie: $\Phi(-z) = 1 - \Phi(z)$.

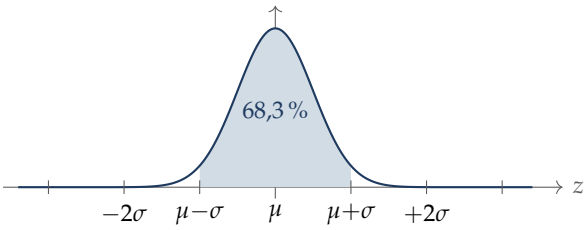
Die Sigma-Regeln

$$\mathbb{P}(|X - \mu| \le \sigma) = 68{,}27\,\%$$
$$\mathbb{P}(|X - \mu| \le 2\sigma) = 95{,}45\,\%$$
$$\mathbb{P}(|X - \mu| \le 3\sigma) = 99{,}73\,\%$$

Herleitung der ersten Zeile:

$$\Phi(1) - \Phi(-1) = 0{,}8413 - 0{,}1587 = 0{,}6827. \checkmark$$

Wichtig für die Statistik: Für ein zweiseitiges 95 %-Intervall braucht man nicht 2σ, sondern $1{,}96\sigma$. Die Verwechslung ist verbreitet und führt zu leicht zu engen Intervallen.
Die Fünf-Sigma-Regel der Physik: $\mathbb{P}(|Z| > 5) = 5{,}7 \cdot 10^{-7}$, also etwa eins zu 1,7 Millionen. Diese Schwelle wurde 2012 bei der Entdeckung des Higgs-Bosons angelegt – ein deutlich strengeres Kriterium als das $p < 0{,}05$ der Lebenswissenschaften, das lediglich 1,96 Sigma entspricht.



Φ ist nicht elementar darstellbar

Es gibt keine geschlossene Formel für Φ – die Dichte $e^{-x^2/2}$ hat keine elementare Stammfunktion (Liouville 1835, siehe Band 3, Kapitel 11).
Deshalb die Tabellen. Numerisch berechnet man Φ über die Fehlerfunktion

$$\Phi(z) = \frac{1}{2}\left(1 + \operatorname{erf}\left(\frac{z}{\sqrt{2}}\right)\right),$$

für die es gute rationale Approximationen und Kettenbruchentwicklungen gibt.

Wer hat die Normalverteilung erfunden?

ABRAHAM DE MOIVRE fand sie 1733 als Näherung der Binomialverteilung – in einem privat gedruckten Anhang zu seiner *Doctrine of Chances*, auf Latein, in kleiner Auflage. Er suchte nach einer Rechenerleichterung für große n und hielt das Ergebnis nicht für besonders bedeutsam.
GAUSS führte sie 1809 in der *Theoria Motus* über einen ganz anderen Weg ein: Er fragte, welche Fehlerverteilung die Eigenschaft hat, dass das arithmetische Mittel der beste Schätzer ist – und erhielt die Glockenkurve als eindeutige Antwort.
LAPLACE bewies 1810 den zentralen Grenzwertsatz und erklärte damit, warum die Verteilung überall auftaucht.
ADOLPHE QUETELET übertrug sie ab 1835 auf menschliche Merkmale – Körpergröße, Brustumfang schottischer Soldaten – und prägte den *homme moyen*, den Durchschnittsmenschen. Diese Übertragung war folgenreich und nicht durchweg glücklich: Sie führte über GALTON zur Eugenik.
KARL PEARSON prägte 1893 den Namen „Normalverteilung“ und bedauerte ihn später ausdrücklich, weil er suggeriert, andere Verteilungen seien „abnormal“. Die Bezeichnung setzte sich dennoch durch.
Ein Warnwort. Die Normalverteilung ist *nicht* der Normalfall. Einkommen sind lognormal, Wartezeiten exponentiell, Städtegrößen folgen einem Potenzgesetz, Finanzmarktrenditen haben deutlich schwerere Ränder. Die unkritische Annahme der Normalverteilung – insbesondere im Risikomanagement – hat zu erheblichen Fehleinschätzungen geführt, worauf BENOÎT MANDELBROT bereits ab 1963 und später NASSIM TALEB nachdrücklich hinwiesen.

Aufgabe 6.1. Die Körpergröße erwachsener Männer sei $\mathcal{N}(178;\ 7^2)$-verteilt (Angaben in cm).

(a) Wie viel Prozent sind größer als 190 cm?

(b) Wie viel Prozent liegen zwischen 170 und 185 cm?

(c) Ab welcher Größe gehört man zum größten Prozent?

Lösung Schritt für Schritt.

(a) Standardisieren:

$$z = \frac{190 - 178}{7} = \frac{12}{7} = 1{,}714.$$

$$\mathbb{P}(X > 190) = 1 - \Phi(1{,}714) = 1 - 0{,}9567 = 0{,}0433.$$

Etwa 4,3 %.

(b) Zwei Standardisierungen:

$$z_1 = \frac{170 - 178}{7} = -1{,}143, \qquad z_2 = \frac{185 - 178}{7} = 1{,}0.$$

$$\mathbb{P}(170 \le X \le 185) = \Phi(1{,}0) - \Phi(-1{,}143).$$

Mit $\Phi(-1{,}143) = 1 - \Phi(1{,}143) = 1 - 0{,}8735 = 0{,}1265$:

$$= 0{,}8413 - 0{,}1265 = 0{,}7148.$$

Etwa 71,5 %.

(c) Gesucht ist das 99 %-Quantil. Aus der Tabelle:

$$\Phi(z) = 0{,}99 \Longrightarrow z = 2{,}326.$$

Rücktransformation:

$$x = \mu + z\sigma = 178 + 2{,}326 \cdot 7 = 178 + 16{,}3 = 194{,}3.$$

Ab etwa 194 cm.

Probe. $\frac{194{,}3 - 178}{7} = 2{,}329$, und $\Phi(2{,}329) \approx 0{,}990$. ✓

Bemerkung zur Modellgüte. Körpergrößen sind tatsächlich annähernd normalverteilt – innerhalb eines Geschlechts und einer Kohorte. Mischt man Männer und Frauen, entsteht eine *bimodale* Verteilung, auf die keine der obigen Rechnungen mehr anwendbar ist.

Das ist ein allgemeines Muster: Mischungen normalverteilter Größen sind nicht normalverteilt. Wer eine bimodale Verteilung mit Mittelwert und Standardabweichung beschreibt, produziert eine Zahl, die keine einzige Person beschreibt.

6.3 Weitere wichtige stetige Verteilungen

Die Familie um die Normalverteilung

Chi-Quadrat-Verteilung. Sind $Z_1, \ldots, Z_n$ unabhängig $\mathcal{N}(0,1)$, so heißt

$$\chi^2_n := \sum_{i=1}^{n} Z_i^2$$

chi-quadrat-verteilt mit n Freiheitsgraden. Erwartungswert n, Varianz $2n$.
Wozu: Verteilung der Stichprobenvarianz; Grundlage des χ^2-Anpassungstests und des Unabhängigkeitstests in Kontingenztafeln.

t-Verteilung (Student). Sind $Z \sim \mathcal{N}(0,1)$ und $V \sim \chi^2_n$ unabhängig, so ist

$$T := \frac{Z}{\sqrt{V/n}}$$

t-verteilt mit n Freiheitsgraden.
Wozu: Wenn man die Varianz nicht kennt, sondern schätzt. Die t-Verteilung hat schwerere Ränder als die Normalverteilung – sie berücksichtigt die zusätzliche Unsicherheit. Für $n \to \infty$ konvergiert sie gegen $\mathcal{N}(0,1)$; ab etwa $n = 30$ ist der Unterschied gering.

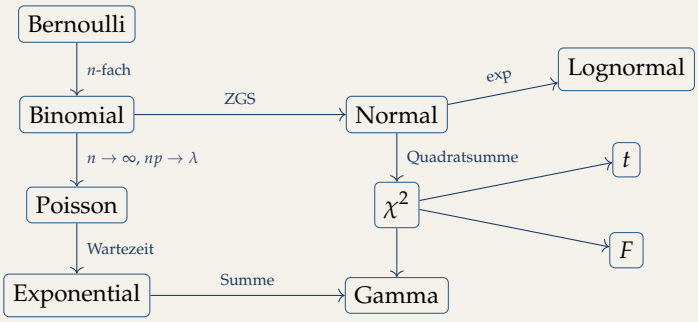
F-Verteilung. Quotient zweier unabhängiger, durch ihre Freiheitsgrade geteilter χ^2-Größen.
Wozu: Varianzvergleiche, Varianzanalyse (ANOVA), Modellvergleiche in der Regression.

Gamma-Verteilung. Dichte $f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} \mathrm{e}^{-\lambda x}$ für $x > 0$.
Enthält als Spezialfälle die Exponentialverteilung ($\alpha = 1$) und die χ^2-Verteilung ($\alpha = \frac{n}{2}$, $\lambda = \frac{1}{2}$). Die Gammafunktion aus Band 3, Kapitel 11 steht hier in der Normierung.

Beta-Verteilung. Dichte $f(x) \propto x^{\alpha-1}(1-x)^{\beta-1}$ auf $[0,1]$.
Wozu: Verteilung für unbekannte *Wahrscheinlichkeiten*. In der Bayes-Statistik der natürliche Prior für einen Binomialparameter, weil der Posterior wieder eine Beta-Verteilung ist (**konjugierte** Familie).

Lognormalverteilung. X ist lognormal, wenn $\ln X$ normalverteilt ist.
Wozu: Größen, die durch *multiplikative* Effekte entstehen – Einkommen, Aktienkurse, Konzentrationen, Reaktionszeiten, Krankheitsdauern. Der zentrale Grenzwertsatz, auf Logarithmen angewandt, erklärt ihre Häufigkeit ebenso, wie er die Häufigkeit der Normalverteilung bei additiven Effekten erklärt.

Der Verteilungsstammbaum



Fast alle gebräuchlichen Verteilungen hängen über solche Beziehungen zusammen. Wer den Stammbaum kennt, muss weniger auswendig lernen – und erkennt schneller, welches Modell zu einer Situation passt.

7 Erwartungswert, Varianz und Ungleichungen

7.1 Der Erwartungswert

Definition 7.1. Für eine diskrete Zufallsvariable mit Werten x_i ist

$$\mathbb{E}[X] := \sum_i x_i \, \mathbb{P}(X = x_i),$$

sofern $\sum_i |x_i| \, \mathbb{P}(X = x_i) < \infty$.

Für eine stetige Zufallsvariable mit Dichte f ist

$$\mathbb{E}[X] := \int_{-\infty}^{\infty} x \, f(x) \, \mathrm{d}x,$$

sofern $\int |x| \, f(x) \, \mathrm{d}x < \infty$.

Allgemein ist $\mathbb{E}[X] = \int_\Omega X \, \mathrm{d}\mathbb{P}$ – das Lebesgue-Integral bezüglich $\mathbb{P}$.

Warum die absolute Konvergenz gefordert wird

Sonst hinge der Wert von der Summationsreihenfolge ab – Riemannscher Umordnungssatz (Band 3, Kapitel 3). Ein Erwartungswert, der davon abhängt, in welcher Reihenfolge man die Werte aufzählt, wäre sinnlos.

Es gibt Verteilungen ohne Erwartungswert. Die **Cauchy-Verteilung** mit der Dichte

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

ist symmetrisch um 0, hat aber keinen Erwartungswert: Das Integral $\int \frac{|x|}{\pi(1+x^2)} dx$ divergiert logarithmisch.

Die Folge ist dramatisch: Für Cauchy-verteilte Beobachtungen gilt das Gesetz der großen Zahlen *nicht*. Der Mittelwert von n Cauchy-Größen ist wieder exakt Cauchy-verteilt – er wird durch Mittelung kein bisschen genauer. Wer Cauchy-verteilte Daten mittelt, sammelt umsonst.

Satz 7.2 (Transformationssatz)**.** *Für eine messbare Funktion g gilt*

$$\mathbb{E}[g(X)] = \sum_i g(x_i) \mathbb{P}(X = x_i) \qquad \textit{bzw.} \qquad \mathbb{E}[g(X)] = \int g(x) f(x) \, \mathrm{d}x.$$

Warum das ein Satz ist und keine Definition

Nach Definition wäre $\mathbb{E}[g(X)] = \sum_y y\,\mathbb{P}(g(X) = y)$ – man müsste erst die *Verteilung von* $g(X)$ bestimmen.
Der Satz sagt: Das ist nicht nötig. Man setzt g einfach in die alte Summe ein. Im angelsächsischen Raum heißt er scherzhaft „law of the unconscious statistician", weil er meist unbewusst angewandt wird.
Beweisidee im diskreten Fall: Man gruppiert die x_i nach ihrem Bild:

$$\sum_i g(x_i)\mathbb{P}(X = x_i) = \sum_y \sum_{i:\, g(x_i)=y} y\,\mathbb{P}(X = x_i) = \sum_y y\,\mathbb{P}(g(X) = y). \quad \blacksquare$$

Satz 7.3 (Linearität). *Für Zufallsvariablen X, Y auf demselben Raum und $a, b \in \mathbb{R}$ gilt*

$$\mathbb{E}[aX + bY] = a\,\mathbb{E}[X] + b\,\mathbb{E}[Y].$$

Es wird keine Unabhängigkeit vorausgesetzt.

Die wichtigste Eigenschaft überhaupt

Dass die Linearität *ohne* Unabhängigkeit gilt, ist der Grund für ihre enorme Nützlichkeit. Sie erlaubt den **Indikatortrick**:
Man zerlegt eine komplizierte Zählgröße in eine Summe von Indikatorvariablen

$$\mathbf{1}_A(\omega) := \begin{cases} 1, & \omega \in A \\ 0, & \text{sonst,} \end{cases}$$

für die $\mathbb{E}[\mathbf{1}_A] = 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \mathbb{P}(A)$ gilt.
Dann addiert man – und darf sich um Abhängigkeiten *nicht* kümmern.

Aufgabe 7.1. n Briefe werden zufällig auf n Umschläge verteilt (vgl. Kapitel 1). Wie viele landen im Mittel richtig?

Lösung Schritt für Schritt.

Der naive Weg wäre: Verteilung der Anzahl bestimmen, dann summieren. Die Verteilung ist kompliziert (sie enthält die Derangement-Zahlen).
Der Indikatortrick. Sei

$$X_i := \mathbf{1}\{\text{Brief } i \text{ liegt richtig}\}, \qquad X := \sum_{i=1}^{n} X_i.$$

Schritt 1 – Einzelerwartungswerte.

$$\mathbb{E}[X_i] = \mathbb{P}(\text{Brief } i \text{ richtig}) = \frac{1}{n}.$$

(Brief i kann in n Umschlägen landen, alle gleich wahrscheinlich.)

Schritt 2 – Summieren.

$$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[X_i] = n \cdot \frac{1}{n} = 1.$$

Antwort: Im Mittel landet genau ein Brief richtig – unabhängig von n.
Warum das bemerkenswert ist. Die X_i sind *nicht* unabhängig: Weiß man, dass die ersten $n-1$ Briefe richtig liegen, so liegt auch der letzte richtig. Für die Linearität spielt das keine Rolle.
Hätte man den Erwartungswert über die Verteilung berechnen wollen, hätte man die Derangement-Zahlen und eine erhebliche Rechnung gebraucht – für dasselbe Ergebnis.
Konsistenzprüfung mit Kapitel 1. Dort hatten wir $\mathbb{P}(X = 0) \to \mathrm{e}^{-1}$ gefunden. Tatsächlich konvergiert X gegen $\mathrm{Poi}(1)$, und $\mathrm{Poi}(1)$ hat den Erwartungswert 1. ✓

Satz 7.4 (Erwartungswerte der Standardverteilungen)**.**

Verteilung	$\mathbb{E}[X]$	$\mathrm{Var}(X)$
$\mathrm{Bern}(p)$	p	$p(1-p)$
$\mathrm{Bin}(n,p)$	np	$np(1-p)$
$\mathrm{Geo}(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
$\mathrm{Poi}(\lambda)$	λ	λ
$\mathrm{Hyp}(N,M,n)$	$n\frac{M}{N}$	$n\frac{M}{N}\left(1-\frac{M}{N}\right)\frac{N-n}{N-1}$
$\mathrm{U}(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
$\mathrm{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$\mathcal{N}(\mu,\sigma^2)$	μ	σ^2
χ^2_n	n	$2n$

Zwei exemplarische Rechnungen. **Binomialverteilung – der elegante Weg.** $X = \sum_{i=1}^{n} X_i$ mit $X_i \sim \mathrm{Bern}(p)$ unabhängig. Nach der Linearität:

$$\mathbb{E}[X] = \sum_{i} \mathbb{E}[X_i] = np.$$

Zum Vergleich der direkte Weg:

$$\mathbb{E}[X] = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}.$$

Man benutzt $k\binom{n}{k} = n\binom{n-1}{k-1}$ (nachrechnen durch Ausschreiben der Fakultäten), zieht np heraus und erkennt die Restsumme als Normierung einer $\mathrm{Bin}(n-1,p)$-Verteilung. Machbar, aber deutlich mühsamer.

Exponentialverteilung. Partielle Integration (Band 3, Kapitel 10) mit $u = x$, $v' = \lambda e^{-\lambda x}$:

$$\mathbb{E}[X] = \int_0^\infty x\lambda e^{-\lambda x}\,dx = \underbrace{\left[-xe^{-\lambda x}\right]_0^\infty}_{=0} + \int_0^\infty e^{-\lambda x}\,dx = \left[-\frac{e^{-\lambda x}}{\lambda}\right]_0^\infty = \frac{1}{\lambda}.$$

Der Randterm verschwindet, weil $e^{-\lambda x}$ jedes Polynom schlägt (Band 3, Kapitel 5). ■

7.2 Varianz

Definition 7.5.

$$\operatorname{Var}(X) := \mathbb{E}\big[(X - \mathbb{E}[X])^2\big], \qquad \sigma_X := \sqrt{\operatorname{Var}(X)}.$$

Satz 7.6 (Verschiebungssatz).

$$\operatorname{Var}(X) = \mathbb{E}[X^2] - \big(\mathbb{E}[X]\big)^2.$$

Beweis. Sei $\mu := \mathbb{E}[X]$. Ausmultiplizieren und Linearität:

$$\mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}[X^2] - 2\mu\mathbb{E}[X] + \mu^2$$
$$= \mathbb{E}[X^2] - 2\mu^2 + \mu^2 = \mathbb{E}[X^2] - \mu^2.$$

(Beachten Sie: μ ist eine *Zahl*, keine Zufallsvariable, darf also aus dem Erwartungswert gezogen werden.) ■

Satz 7.7 (Rechenregeln). *(a)* $\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X)$
(b) $\operatorname{Var}(X) \geq 0$, *und* $\operatorname{Var}(X) = 0$ *genau dann, wenn* X *fast sicher konstant ist*
(c) $\operatorname{Var}(X + Y) = \operatorname{Var}(X) + \operatorname{Var}(Y)$, falls X, Y *unabhängig (allgemeiner: unkorreliert)*

Die Varianz ist nicht linear

$\operatorname{Var}(aX) = a^2 \operatorname{Var}(X)$ – das Quadrat, nicht der Faktor selbst.
Und die additive Regel (c) gilt *nur* bei Unkorreliertheit. Im allgemeinen Fall ist

$$\operatorname{Var}(X + Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X, Y).$$

Das ist der Unterschied zur Linearität des Erwartungswerts, die *immer* gilt. Die Verwechslung ist eine der häufigsten Fehlerquellen – besonders im Finanz- und Versicherungswesen, wo unterstellte Unabhängigkeit korrelierter Risiken wiederholt zu erheblichen Fehleinschätzungen geführt hat.
Die Konsequenz für Standardabweichungen: Sie addieren sich *nie* direkt. Bei Unabhängigkeit gilt

$$\sigma_{X+Y} = \sqrt{\sigma_X^2 + \sigma_Y^2}$$

– Pythagoras, nicht Addition. Deshalb wächst die Standardabweichung einer Summe von n gleichartigen unabhängigen Größen nur mit $\sqrt{n}$, während der

Erwartungswert mit n wächst. **Das ist der mathematische Kern jeder Risikodiversifikation** – und der Grund für den Faktor $\frac{1}{\sqrt{n}}$ in praktisch allen statistischen Formeln.

Aufgabe 7.2. Berechnen Sie Erwartungswert und Varianz für $X \sim \mathrm{Poi}(\lambda)$.

Lösung Schritt für Schritt.

Schritt 1 – Erwartungswert.

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k\, \mathrm{e}^{-\lambda} \frac{\lambda^k}{k!}.$$

Der Summand für $k = 0$ verschwindet. Für $k \geq 1$ kürzen wir $\frac{k}{k!} = \frac{1}{(k-1)!}$:

$$= \mathrm{e}^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}.$$

Wir klammern ein λ aus und verschieben den Index ($j := k - 1$):

$$= \lambda \mathrm{e}^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda} = \lambda.$$

Schritt 2 – Zweites Moment. Der direkte Weg über $\mathbb{E}[X^2]$ ist unbequem. Der Trick: Man berechnet stattdessen

$$\mathbb{E}[X(X-1)] = \sum_{k=0}^{\infty} k(k-1) \mathrm{e}^{-\lambda} \frac{\lambda^k}{k!}.$$

Für $k = 0$ und $k = 1$ verschwinden die Summanden. Für $k \geq 2$ kürzt sich $\frac{k(k-1)}{k!} = \frac{1}{(k-2)!}$:

$$= \mathrm{e}^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^k}{(k-2)!} = \lambda^2 \mathrm{e}^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda^2.$$

Schritt 3 – Umrechnen. Nach der Linearität:

$$\mathbb{E}[X(X-1)] = \mathbb{E}[X^2] - \mathbb{E}[X] \Longrightarrow \mathbb{E}[X^2] = \lambda^2 + \lambda.$$

Schritt 4 – Verschiebungssatz.

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \big(\mathbb{E}[X]\big)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

Ergebnis: $\mathbb{E}[X] = \mathrm{Var}(X) = \lambda$.

Die Technik zum Merken. Der Umweg über $\mathbb{E}[X(X-1)]$ – das **faktorielle Moment** – ist bei allen Verteilungen mit Fakultäten im Nenner nützlich, weil sich die Faktoren wegkürzen. Bei der Binomialverteilung funktioniert derselbe Trick:

$$\mathbb{E}[X(X-1)] = n(n-1)p^2 \Longrightarrow \mathrm{Var}(X) = n(n-1)p^2 + np - n^2p^2 = np(1-p). \checkmark$$

Praktische Bedeutung der Gleichheit. Der **Dispersionsindex** $\frac{\mathrm{Var}(X)}{\mathbb{E}[X]}$ sollte bei Poisson-Daten nahe bei 1 liegen. Werte deutlich über 1 zeigen Klumpung an (Ausbrüche, Ansteckung), Werte unter 1 eine Regelmäßigkeit (etwa Reviere von Tieren, die einander meiden). Dieser Index ist in der Ökologie und der Epidemiologie ein Standardwerkzeug.

7.3 Die grundlegenden Ungleichungen

Satz 7.8 (Markow-Ungleichung). *Sei $X \geq 0$ und $a > 0$. Dann*

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

Beweis. Wir betrachten die Indikatorvariable $\mathbf{1}\{X \geq a\}$ und beobachten die punktweise Ungleichung

$$X \;\geq\; a \cdot \mathbf{1}\{X \geq a\}.$$

Warum: Ist $X(\omega) \geq a$, so steht rechts a und links etwas mindestens so Großes. Ist $X(\omega) < a$, so steht rechts 0 und links etwas Nichtnegatives. ✓

Erwartungswert bilden (der Erwartungswert erhält Ungleichungen – Monotonie des Integrals):

$$\mathbb{E}[X] \geq a\,\mathbb{E}\big[\mathbf{1}\{X \geq a\}\big] = a\,\mathbb{P}(X \geq a).$$ ■

Satz 7.9 (Tschebyschow-Ungleichung). *Für beliebiges X mit endlicher Varianz und $\varepsilon > 0$:*

$$\mathbb{P}\big(|X - \mathbb{E}[X]| \geq \varepsilon\big) \;\leq\; \frac{\mathrm{Var}(X)}{\varepsilon^2}.$$

Beweis. Wende Markow auf die nichtnegative Zufallsvariable $Y := (X - \mathbb{E}[X])^2$ und die Schranke $a := \varepsilon^2$ an:

$$\mathbb{P}\big(|X - \mathbb{E}[X]| \geq \varepsilon\big) = \mathbb{P}\big((X - \mathbb{E}[X])^2 \geq \varepsilon^2\big) \leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{\varepsilon^2} = \frac{\mathrm{Var}(X)}{\varepsilon^2}.$$ ■

(Die erste Gleichung gilt, weil $t \mapsto t^2$ auf $[0, \infty)$ monoton ist, die beiden Ereignisse also identisch sind.)

Was diese Ungleichungen leisten – und was nicht

Sie sind universell. Man braucht nur den Erwartungswert bzw. die Varianz – keine Kenntnis der Verteilung. Das ist ihre Stärke.
Sie sind grob. Für $\varepsilon = 2\sigma$ liefert Tschebyschow

$$\mathbb{P}(|X - \mu| \geq 2\sigma) \leq \frac{1}{4} = 25\,\%.$$

Bei einer Normalverteilung ist der wahre Wert 4,6 % – fünfmal kleiner.

Aber die Schranke ist scharf, das heißt: Es gibt Verteilungen, die sie annehmen. Nehmen Sie

$$\mathbb{P}(X=-2)=\mathbb{P}(X=2)=\tfrac{1}{8}, \qquad \mathbb{P}(X=0)=\tfrac{3}{4}.$$

Dann $\mathbb{E}[X]=0$, $\operatorname{Var}(X)=\frac{1}{8}\cdot 4+\frac{1}{8}\cdot 4=1$, und

$$\mathbb{P}(|X|\geq 2)=\tfrac{1}{4}=\frac{\operatorname{Var}(X)}{2^2}.\checkmark$$

Ohne weitere Annahmen *kann* man also nicht besser sein.
Wozu man sie trotzdem braucht: Sie sind das Werkzeug für Beweise, in denen man die Verteilung nicht kennt. Das schwache Gesetz der großen Zahlen (Kapitel 10) folgt in drei Zeilen aus Tschebyschow.

Satz 7.10 (Jensensche Ungleichung)**.** *Ist φ konvex, so gilt*

$$\varphi\big(\mathbb{E}[X]\big) \;\leq\; \mathbb{E}\big[\varphi(X)\big].$$

Bei konkavem φ kehrt sich die Ungleichung um.

Beweis. Sei $\mu := \mathbb{E}[X]$. Eine konvexe Funktion liegt oberhalb jeder ihrer Tangenten (bzw. Stützgeraden): Es gibt ein c mit

$$\varphi(x) \;\geq\; \varphi(\mu)+c\,(x-\mu) \qquad \text{für alle } x.$$

Wir setzen X ein und bilden den Erwartungswert:

$$\mathbb{E}[\varphi(X)] \;\geq\; \varphi(\mu)+c\,\big(\mathbb{E}[X]-\mu\big)=\varphi(\mu)+c\cdot 0=\varphi(\mu). \qquad \blacksquare$$

Anwendungen, die man kennen sollte

1. $\mathbb{E}[X^2]\geq(\mathbb{E}[X])^2$**.** Mit $\varphi(x)=x^2$. Das ist genau die Aussage $\operatorname{Var}(X)\geq 0$.
2. $\mathbb{E}\left[\frac{1}{X}\right]\geq\frac{1}{\mathbb{E}[X]}$ für $X>0$. Mit $\varphi(x)=\frac{1}{x}$, konvex auf $(0,\infty)$.
Praktische Konsequenz: Die mittlere Geschwindigkeit auf einer Strecke ist *kleiner* als der Mittelwert der Geschwindigkeiten – man muss harmonisch mitteln. Wer 100 km mit 100 km/h und 100 km mit 50 km/h fährt, hat nicht 75 km/h Durchschnitt, sondern $\frac{200}{1+2}=66{,}7$ km/h.
3. $\mathbb{E}[\ln X]\leq\ln\mathbb{E}[X]$ (ln ist konkav). Daraus folgt, dass das geometrische Mittel höchstens so groß ist wie das arithmetische.
Praktische Konsequenz: Eine Geldanlage mit Renditen $+50\,\%$ und $-50\,\%$ im Wechsel hat den arithmetischen Mittelwert 0 – führt aber pro Doppeljahr zu einem Verlust von 25 % ($1{,}5\cdot 0{,}5=0{,}75$). Was zählt, ist das geometrische Mittel.
4. Die Ungleichung vom arithmetischen und geometrischen Mittel folgt aus 3 durch Anwendung auf eine gleichverteilte Zufallsvariable.

7.4 Erzeugende Funktionen

Definition 7.11. Für eine Zufallsvariable mit Werten in $\mathbb{N}_0$ ist die **wahrscheinlichkeitserzeugende Funktion**

$$G_X(s) := \mathbb{E}[s^X] = \sum_{k=0}^{\infty} \mathbb{P}(X = k)\, s^k, \qquad |s| \le 1.$$

Satz 7.12 (Eigenschaften). *(a)* G_X *bestimmt die Verteilung eindeutig:* $\mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!}$.
(b) $\mathbb{E}[X] = G_X'(1)$
(c) $\operatorname{Var}(X) = G_X''(1) + G_X'(1) - \big(G_X'(1)\big)^2$
(d) Sind X, Y *unabhängig, so ist* $G_{X+Y}(s) = G_X(s)\, G_Y(s)$.

Beweis. **(a)** ist der Identitätssatz für Potenzreihen (Band 3, Kapitel 12): Die Koeffizienten einer Potenzreihe sind eindeutig bestimmt.
(b) Gliedweises Differenzieren ist innerhalb des Konvergenzradius erlaubt:

$$G_X'(s) = \sum_k k\,\mathbb{P}(X = k) s^{k-1} \Longrightarrow G_X'(1) = \sum_k k\mathbb{P}(X = k) = \mathbb{E}[X].$$

(c) Zweimaliges Differenzieren:

$$G_X''(1) = \sum_k k(k-1)\mathbb{P}(X = k) = \mathbb{E}[X(X-1)] = \mathbb{E}[X^2] - \mathbb{E}[X].$$

Also $\mathbb{E}[X^2] = G''(1) + G'(1)$, und der Verschiebungssatz liefert die Behauptung.
(d) Bei Unabhängigkeit faktorisiert der Erwartungswert von Produkten:

$$G_{X+Y}(s) = \mathbb{E}[s^{X+Y}] = \mathbb{E}[s^X s^Y] = \mathbb{E}[s^X]\mathbb{E}[s^Y].$$ ■

Warum (d) so mächtig ist

Faltung wird Multiplikation. Die Verteilung einer Summe unabhängiger Zufallsvariablen ist eine komplizierte Faltungssumme; die erzeugende Funktion macht daraus ein simples Produkt.
Das ist dieselbe Idee wie beim Logarithmus (Multiplikation wird Addition) und bei der Fouriertransformation (Faltung wird Multiplikation). Man wechselt in einen Bereich, in dem die schwierige Operation einfach wird, rechnet dort und geht zurück.

Aufgabe 7.3. Zeigen Sie mit erzeugenden Funktionen: Sind $X \sim \text{Poi}(\lambda)$ und $Y \sim \text{Poi}(\mu)$ unabhängig, so ist $X + Y \sim \text{Poi}(\lambda + \mu)$.

Lösung Schritt für Schritt.

Schritt 1 – Erzeugende Funktion der Poisson-Verteilung.

$$G_X(s) = \sum_{k=0}^{\infty} \mathrm{e}^{-\lambda} \frac{\lambda^k}{k!} s^k = \mathrm{e}^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda s)^k}{k!} = \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda s} = \mathrm{e}^{\lambda(s-1)}.$$

(Wieder die Exponentialreihe – diesmal an der Stelle λs.)
Schritt 2 – Produkt bilden.

$$G_{X+Y}(s) = G_X(s) G_Y(s) = \mathrm{e}^{\lambda(s-1)} \mathrm{e}^{\mu(s-1)} = \mathrm{e}^{(\lambda+\mu)(s-1)}.$$

Schritt 3 – Wiedererkennen. Das ist die erzeugende Funktion von $\mathrm{Poi}(\lambda + \mu)$. Nach der Eindeutigkeit (a) folgt

$$X + Y \sim \mathrm{Poi}(\lambda + \mu). \qquad \blacksquare$$

Schritt 4 – Zum Vergleich der direkte Weg.

$$\mathbb{P}(X + Y = n) = \sum_{k=0}^{n} \mathbb{P}(X = k) \mathbb{P}(Y = n - k) = \sum_{k=0}^{n} \mathrm{e}^{-\lambda} \frac{\lambda^k}{k!} \mathrm{e}^{-\mu} \frac{\mu^{n-k}}{(n-k)!}.$$

Wir erweitern mit $\frac{n!}{n!}$:

$$= \frac{\mathrm{e}^{-(\lambda+\mu)}}{n!} \sum_{k=0}^{n} \binom{n}{k} \lambda^k \mu^{n-k} = \mathrm{e}^{-(\lambda+\mu)} \frac{(\lambda + \mu)^n}{n!}$$

nach dem binomischen Lehrsatz. ✓
Beide Wege funktionieren. Der zweite ist hier noch machbar; bei drei oder mehr Summanden wird er unübersichtlich, während das Produkt erzeugender Funktionen unverändert einfach bleibt.
Kontrolle über Erwartungswert und Varianz.

$$G'(s) = \lambda \mathrm{e}^{\lambda(s-1)} \Longrightarrow G'(1) = \lambda = \mathbb{E}[X]. \checkmark$$

$$G''(s) = \lambda^2 \mathrm{e}^{\lambda(s-1)} \Longrightarrow G''(1) = \lambda^2,$$

$$\mathrm{Var}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda. \checkmark$$

Praktische Bedeutung. Die Additivität bedeutet: Zählt man Poisson-Ereignisse aus mehreren unabhängigen Quellen zusammen, so bleibt das Modell erhalten. Deshalb kann man Infektionszahlen mehrerer Stationen, Anrufe mehrerer Leitungen oder Zerfälle mehrerer Präparate addieren, ohne das Modell zu verlassen. Diese **Reproduktivität** besitzen auch die Normal- und die Gammaverteilung, nicht aber etwa die Gleichverteilung.

Die charakteristische Funktion

Für allgemeine (auch stetige) Zufallsvariablen benutzt man

$$\phi_X(t) := \mathbb{E}\left[e^{itX}\right].$$

Sie hat dieselben Eigenschaften – eindeutige Bestimmung der Verteilung, Momente als Ableitungen, Produkt bei Summen – und existiert *immer*, weil $\left|e^{itX}\right| = 1$.
Die momenterzeugende Funktion $M_X(t) := \mathbb{E}[e^{tX}]$ ist bequemer zu rechnen, existiert aber nicht immer (bei der Lognormalverteilung etwa nicht).
Die charakteristische Funktion ist das entscheidende Werkzeug im Beweis des zentralen Grenzwertsatzes (Kapitel 11). Sie ist im Kern die Fouriertransformierte der Dichte – die Verbindung zwischen Wahrscheinlichkeitstheorie und harmonischer Analysis.

Part III

Mehrere Zufallsvariablen

8 Gemeinsame Verteilungen

8.1 Gemeinsame und Randverteilungen

Definition 8.1. Für Zufallsvariablen X, Y auf demselben Wahrscheinlichkeitsraum heißt

$$F_{X,Y}(s,t) := \mathbb{P}(X \le s,\ Y \le t)$$

die **gemeinsame Verteilungsfunktion**. Im diskreten Fall ist $p(x_i, y_j) := \mathbb{P}(X = x_i, Y = y_j)$ die gemeinsame Zähldichte; im stetigen Fall gibt es eine **gemeinsame Dichte** $f(x,y)$ mit

$$\mathbb{P}\big((X,Y) \in B\big) = \iint_B f(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

Definition 8.2. Die **Randverteilungen** erhält man durch Summation bzw. Integration über die jeweils andere Variable:

$$\mathbb{P}(X = x_i) = \sum_j p(x_i, y_j), \qquad f_X(x) = \int_{-\infty}^{\infty} f(x,y)\,\mathrm{d}y.$$

Die Randverteilungen bestimmen die gemeinsame nicht

Aus f_X und f_Y folgt *nicht* f. Es gibt unendlich viele gemeinsame Verteilungen mit denselben Rändern.

Beispiel. Beide Tabellen haben die Randverteilungen $(\frac{1}{2}, \frac{1}{2})$ in beiden Richtungen:

	$Y{=}0$	$Y{=}1$
$X{=}0$	$\frac{1}{4}$	$\frac{1}{4}$
$X{=}1$	$\frac{1}{4}$	$\frac{1}{4}$

	$Y{=}0$	$Y{=}1$
$X{=}0$	$\frac{1}{2}$	0
$X{=}1$	0	$\frac{1}{2}$

Links sind X und Y unabhängig, rechts ist $Y = X$ – vollständige Abhängigkeit.

Praktische Bedeutung. Man kann aus Randstatistiken keine Aussagen über Zusammenhänge ableiten. Das ist der Kern des **ökologischen Fehlschlusses**: Aus aggregierten Daten (etwa Wahlergebnissen und Arbeitslosenquoten pro Wahlkreis) lässt sich nicht auf individuelles Verhalten schließen. WILLIAM ROBINSON zeigte das 1950 an Volkszählungsdaten, bei denen die Korrelation auf Ebene der Bundesstaaten dem Zusammenhang auf Individualebene deutlich widersprach.

Die Frage, welche gemeinsamen Verteilungen zu gegebenen Rändern passen, ist Gegenstand der **Copula**-Theorie (Sklar 1959) – ein Werkzeug, dessen unkritischer Einsatz im Finanzwesen vor 2008 erheblich zur Fehlbewertung von Kreditrisiken beitrug.

Definition 8.3. X und Y heißen **unabhängig**, wenn

$$F_{X,Y}(s,t) = F_X(s)\,F_Y(t) \qquad \text{für alle } s,t,$$

gleichbedeutend mit $p(x,y) = p_X(x)p_Y(y)$ bzw. $f(x,y) = f_X(x)f_Y(y)$.

8.2 Kovarianz und Korrelation

Definition 8.4.

$$\operatorname{Cov}(X,Y) := \mathbb{E}\big[(X-\mathbb{E}X)(Y-\mathbb{E}Y)\big] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

$$\operatorname{Korr}(X,Y) := \frac{\operatorname{Cov}(X,Y)}{\sigma_X \sigma_Y}.$$

Satz 8.5. *(a)* $\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X,Y)$

(b) $-1 \le \operatorname{Korr}(X,Y) \le 1$

(c) $|\operatorname{Korr}(X,Y)| = 1$ *genau dann, wenn* $Y = aX + b$ *fast sicher, mit* $a \neq 0$

(d) X, Y *unabhängig* $\Longrightarrow \operatorname{Cov}(X,Y) = 0$

Beweis. **(a).** Ausmultiplizieren:

$$\operatorname{Var}(X+Y) = \mathbb{E}\big[(X-\mathbb{E}X+Y-\mathbb{E}Y)^2\big]$$

$$= \mathbb{E}[(X-\mathbb{E}X)^2] + \mathbb{E}[(Y-\mathbb{E}Y)^2] + 2\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)].$$

(b) und (c). Das ist die Cauchy–Schwarz-Ungleichung (Band 2, Kapitel 9), angewandt auf das Skalarprodukt

$$\langle U, V\rangle := \mathbb{E}[UV]$$

auf dem Raum der zentrierten Zufallsvariablen mit endlicher Varianz. Gleichheit gilt genau bei linearer Abhängigkeit.

Das ist mehr als eine Analogie: $L^2(\Omega, \mathcal{A}, \mathbb{P})$ *ist* ein Hilbertraum, Cov ist ein Skalarprodukt, σ_X ist eine Norm, und Unkorreliertheit bedeutet *Orthogonalität*. Regel (a) mit $\operatorname{Cov} = 0$ ist der Satz des Pythagoras.

(d). Bei Unabhängigkeit faktorisiert der Erwartungswert:

$$\mathbb{E}[XY] = \iint xy\, f_X(x) f_Y(y)\,\mathrm{d}x\,\mathrm{d}y = \left(\int x f_X\right)\left(\int y f_Y\right) = \mathbb{E}[X]\mathbb{E}[Y]. \qquad \blacksquare$$

Unkorreliert ist nicht unabhängig

Die Umkehrung von (d) ist *falsch*.

Gegenbeispiel. Sei X gleichverteilt auf $\{-1,0,1\}$ und $Y := X^2$. Dann ist Y vollständig durch X bestimmt – maximale Abhängigkeit. Aber:

$$\mathbb{E}[X] = 0, \qquad \mathbb{E}[XY] = \mathbb{E}[X^3] = \frac{(-1)^3 + 0 + 1^3}{3} = 0,$$

also

$$\operatorname{Cov}(X, Y) = 0 - 0 \cdot \mathbb{E}[Y] = 0.$$

Warum: Die Korrelation misst nur den *linearen* Zusammenhang. Der Zusammenhang $Y = X^2$ ist quadratisch und symmetrisch – linear betrachtet hebt er sich auf.
Die Ausnahme: Bei *gemeinsam normalverteilten* Variablen sind Unkorreliertheit und Unabhängigkeit äquivalent. Das ist einer der Gründe für die Beliebtheit der Normalverteilung – und eine Quelle von Fehlschlüssen, wenn man die Voraussetzung übersieht.

Korrelation ist keine Kausalität – und noch mehr

Der Satz ist bekannt; die dahinterstehenden Möglichkeiten weniger. Beobachtet man eine Korrelation zwischen X und Y, so kommen in Betracht:

1. X verursacht Y.
2. Y verursacht X (*Umkehrkausalität*).
3. Ein Drittes Z verursacht beide (*Confounding*).
4. Die Stichprobe wurde nach einer gemeinsamen Folge ausgewählt (*Kollider-Verzerrung*).
5. Zufall (bei vielen geprüften Hypothesen fast sicher).

Punkt 4 ist der am wenigsten bekannte und heimtückischste. Ein Beispiel: Unter den in ein Krankenhaus aufgenommenen Patienten sind zwei unabhängige Krankheiten oft *negativ* korreliert – denn wer eine schwere Form der einen hat, wird auch ohne die andere aufgenommen. JOSEPH BERKSON beschrieb das 1946; die Verzerrung trägt seinen Namen.
Zu Punkt 5: TYLER VIGEN sammelte in *Spurious Correlations* (2015) Beispiele wie die Korrelation zwischen der Scheidungsrate in Maine und dem Pro-Kopf-Verbrauch von Margarine ($r = 0{,}99$). Bei genügend vielen Zeitreihen findet man solche Paare zwangsläufig – das ist keine Anomalie, sondern eine Rechenaufgabe.

Aufgabe 8.1. Die gemeinsame Verteilung von X und Y sei

	$Y{=}0$	$Y{=}1$	$Y{=}2$	Rand X
$X{=}0$	0,1	0,2	0,1	0,4
$X{=}1$	0,2	0,1	0,3	0,6
Rand Y	0,3	0,3	0,4	1,0

Bestimmen Sie $\operatorname{Cov}(X, Y)$ und $\operatorname{Korr}(X, Y)$. Sind X und Y unabhängig?

Lösung Schritt für Schritt.

Schritt 1 – Ränder prüfen. Zeilensummen: $0{,}1 + 0{,}2 + 0{,}1 = 0{,}4$ ✓, $0{,}2 + 0{,}1 + 0{,}3 = 0{,}6$ ✓. Gesamtsumme 1. ✓

Schritt 2 – Erwartungswerte der Ränder.

$$\mathbb{E}[X] = 0 \cdot 0{,}4 + 1 \cdot 0{,}6 = 0{,}6.$$

$$\mathbb{E}[Y] = 0 \cdot 0{,}3 + 1 \cdot 0{,}3 + 2 \cdot 0{,}4 = 0{,}3 + 0{,}8 = 1{,}1.$$

Schritt 3 – $\mathbb{E}[XY]$. Nur Terme mit $X = 1$ tragen bei (sonst ist das Produkt null):

$$\mathbb{E}[XY] = 1 \cdot 0 \cdot 0{,}2 + 1 \cdot 1 \cdot 0{,}1 + 1 \cdot 2 \cdot 0{,}3 = 0 + 0{,}1 + 0{,}6 = 0{,}7.$$

Schritt 4 – Kovarianz.

$$\mathrm{Cov}(X, Y) = 0{,}7 - 0{,}6 \cdot 1{,}1 = 0{,}7 - 0{,}66 = 0{,}04.$$

Schritt 5 – Varianzen.

$$\mathbb{E}[X^2] = 0^2 \cdot 0{,}4 + 1^2 \cdot 0{,}6 = 0{,}6 \Longrightarrow \mathrm{Var}(X) = 0{,}6 - 0{,}36 = 0{,}24.$$

$$\mathbb{E}[Y^2] = 0 + 1 \cdot 0{,}3 + 4 \cdot 0{,}4 = 1{,}9 \Longrightarrow \mathrm{Var}(Y) = 1{,}9 - 1{,}21 = 0{,}69.$$

$$\sigma_X = \sqrt{0{,}24} = 0{,}4899, \qquad \sigma_Y = \sqrt{0{,}69} = 0{,}8307.$$

Schritt 6 – Korrelation.

$$\mathrm{Korr}(X, Y) = \frac{0{,}04}{0{,}4899 \cdot 0{,}8307} = \frac{0{,}04}{0{,}4069} = 0{,}0983.$$

Ein sehr schwacher positiver linearer Zusammenhang.
Schritt 7 – Unabhängigkeit prüfen. Wäre sie gegeben, müsste für *jede* Zelle gelten $p(x, y) = p_X(x)p_Y(y)$. Prüfen wir die Zelle $(0, 0)$:

$$p_X(0)p_Y(0) = 0{,}4 \cdot 0{,}3 = 0{,}12 \qquad \text{gegen} \qquad p(0, 0) = 0{,}1.$$

Nicht gleich $\Longrightarrow$ X **und** Y **sind abhängig.**
Beobachtung. Die Korrelation ist mit 0,098 nahezu null – die Variablen sind dennoch klar abhängig. Ein weiteres Beispiel dafür, dass die Korrelation nur den linearen Anteil misst.
Ergänzung: Wie hängen sie zusammen? Bedingte Verteilungen von Y:

$$\mathbb{P}(Y = \cdot \mid X = 0) = \left(\tfrac{0{,}1}{0{,}4}, \tfrac{0{,}2}{0{,}4}, \tfrac{0{,}1}{0{,}4}\right) = (0{,}25;\ 0{,}5;\ 0{,}25),$$

$$\mathbb{P}(Y = \cdot \mid X = 1) = \left(\tfrac{0{,}2}{0{,}6}, \tfrac{0{,}1}{0{,}6}, \tfrac{0{,}3}{0{,}6}\right) = (0{,}333;\ 0{,}167;\ 0{,}5).$$

Die Verteilungen unterscheiden sich deutlich in ihrer *Form* – die eine ist eingipflig um 1, die andere u-förmig. Die *Mittelwerte* liegen dagegen dicht beieinander (1,0 gegen 1,167), weshalb die Korrelation klein ausfällt.

8.3 Summen und Faltung

Satz 8.6 (Faltungsformel). *Sind X, Y unabhängig, so hat $Z := X + Y$*

$$\mathbb{P}(Z = n) = \sum_k \mathbb{P}(X = k)\mathbb{P}(Y = n - k) \qquad \textit{(diskret)},$$

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x)\,\mathrm{d}x \qquad \textit{(stetig)}.$$

Beweis im stetigen Fall.

$$F_Z(z) = \mathbb{P}(X + Y \le z) = \iint_{\{x+y\le z\}} f_X(x) f_Y(y)\,\mathrm{d}x\,\mathrm{d}y.$$

Nach Fubini (Band 3, Kapitel 13) integrieren wir zuerst über y, wobei $y \le z - x$:

$$= \int_{-\infty}^{\infty} f_X(x) \left(\int_{-\infty}^{z-x} f_Y(y)\,\mathrm{d}y \right) \mathrm{d}x = \int_{-\infty}^{\infty} f_X(x) F_Y(z - x)\,\mathrm{d}x.$$

Differenzieren nach z (Ableitung und Integral dürfen vertauscht werden, wenn die Voraussetzungen erfüllt sind):

$$f_Z(z) = \int f_X(x) f_Y(z - x)\,\mathrm{d}x. \qquad \blacksquare$$

Reproduktive Verteilungsfamilien

Bei manchen Familien bleibt der Typ bei Summenbildung erhalten:

$$\mathcal{N}(\mu_1, \sigma_1^2) + \mathcal{N}(\mu_2, \sigma_2^2) = \mathcal{N}(\mu_1 + \mu_2,\ \sigma_1^2 + \sigma_2^2)$$

$$\mathrm{Poi}(\lambda) + \mathrm{Poi}(\mu) = \mathrm{Poi}(\lambda + \mu)$$

$$\mathrm{Bin}(m, p) + \mathrm{Bin}(n, p) = \mathrm{Bin}(m + n, p) \qquad \text{(gleiches } p\text{!)}$$

$$\chi^2_m + \chi^2_n = \chi^2_{m+n}$$

$$\mathrm{Exp}(\lambda) + \cdots + \mathrm{Exp}(\lambda)\ (n\text{-mal}) = \mathrm{Gamma}(n, \lambda)$$

(jeweils bei Unabhängigkeit).

Nicht reproduktiv: Die Summe zweier Gleichverteilungen auf $[0, 1]$ ist eine *Dreiecksverteilung* auf $[0, 2]$ – keine Gleichverteilung mehr. Die Faltung glättet; bei mehrfacher Wiederholung entsteht die Glockenform, was den zentralen Grenzwertsatz anschaulich vorwegnimmt.

8.4 Bedingte Erwartung

Definition 8.7. Für diskrete X, Y ist

$$\mathbb{E}[Y \mid X = x] := \sum_j y_j\, \mathbb{P}(Y = y_j \mid X = x).$$

Die **bedingte Erwartung** $\mathbb{E}[Y \mid X]$ ist diejenige Zufallsvariable, die den Wert $\mathbb{E}[Y \mid X = x]$ annimmt, wenn $X = x$ eintritt.

> **$\mathbb{E}[Y \mid X]$ ist eine Zufallsvariable**
>
> Das ist der begriffliche Sprung. $\mathbb{E}[Y \mid X = x]$ ist für jedes feste x eine *Zahl*. Lässt man x variieren, erhält man eine Funktion von x – und setzt man dort die Zufallsvariable X ein, eine *Zufallsvariable*.
> **Die Deutung:** $\mathbb{E}[Y \mid X]$ ist die beste Vorhersage für Y, wenn man X kennt. Sie ist zufällig, weil X zufällig ist.

Satz 8.8 (Turmregel / Satz vom iterierten Erwartungswert)**.**

$$\mathbb{E}\big[\mathbb{E}[Y \mid X]\big] = \mathbb{E}[Y].$$

Beweis.

$$\mathbb{E}\big[\mathbb{E}[Y \mid X]\big] = \sum_i \mathbb{E}[Y \mid X = x_i]\,\mathbb{P}(X = x_i) = \sum_i \left(\sum_j y_j \mathbb{P}(Y = y_j \mid X = x_i) \right) \mathbb{P}(X = x_i)$$

$$= \sum_j y_j \sum_i \mathbb{P}(Y = y_j \mid X = x_i)\mathbb{P}(X = x_i) = \sum_j y_j\, \mathbb{P}(Y = y_j) = \mathbb{E}[Y],$$

wobei im vorletzten Schritt der Satz von der totalen Wahrscheinlichkeit (Satz 3.4) benutzt wurde. ∎

Satz 8.9 (Varianzzerlegung)**.**

$$\operatorname{Var}(Y) = \underbrace{\mathbb{E}\big[\operatorname{Var}(Y \mid X)\big]}_{\text{Varianz innerhalb}} + \underbrace{\operatorname{Var}\big(\mathbb{E}[Y \mid X]\big)}_{\text{Varianz zwischen}}.$$

> **Die Grundgleichung der Varianzanalyse**
>
> Diese Zerlegung ist das Fundament der ANOVA: Die Gesamtstreuung zerfällt in einen Anteil *innerhalb* der Gruppen und einen *zwischen* den Gruppen.
> Ihr Verhältnis entscheidet, ob eine Gruppierung erklärungskräftig ist. Der Anteil
>
> $$\frac{\operatorname{Var}(\mathbb{E}[Y \mid X])}{\operatorname{Var}(Y)}$$
>
> heißt **Determinationskoeffizient** R^2 – der Anteil der durch X erklärten Varianz.

Aufgabe 8.2. Ein Huhn legt $N \sim \text{Poi}(\lambda)$ Eier. Jedes Ei schlüpft unabhängig mit Wahrscheinlichkeit p. Wie ist die Anzahl K der Küken verteilt?

Lösung Schritt für Schritt.

Schritt 1 – Modell. Gegeben $N = n$ ist $K \sim \text{Bin}(n, p)$.

Schritt 2 – Erwartungswert über die Turmregel.

$$\mathbb{E}[K \mid N] = Np \Longrightarrow \mathbb{E}[K] = \mathbb{E}[Np] = p\,\mathbb{E}[N] = p\lambda.$$

Schritt 3 – Die Verteilung. Totale Wahrscheinlichkeit:

$$\mathbb{P}(K=k) = \sum_{n=k}^{\infty} \mathbb{P}(K=k \mid N=n)\mathbb{P}(N=n) = \sum_{n=k}^{\infty} \binom{n}{k} p^k (1-p)^{n-k} \mathrm{e}^{-\lambda} \frac{\lambda^n}{n!}.$$

(Die Summe beginnt bei $n = k$: Weniger Eier als Küken geht nicht.)
Schritt 4 – Umformen. Wir schreiben $\binom{n}{k}\frac{1}{n!} = \frac{1}{k!(n-k)!}$:

$$= \frac{p^k \mathrm{e}^{-\lambda}}{k!} \sum_{n=k}^{\infty} \frac{(1-p)^{n-k}\lambda^n}{(n-k)!}.$$

Indexverschiebung $j := n - k$, also $\lambda^n = \lambda^k \lambda^j$:

$$= \frac{p^k \lambda^k \mathrm{e}^{-\lambda}}{k!} \sum_{j=0}^{\infty} \frac{\big((1-p)\lambda\big)^j}{j!} = \frac{(\lambda p)^k \mathrm{e}^{-\lambda}}{k!}\, \mathrm{e}^{(1-p)\lambda}.$$

Schritt 5 – Zusammenfassen.

$$\mathrm{e}^{-\lambda}\mathrm{e}^{(1-p)\lambda} = \mathrm{e}^{-\lambda+\lambda-\lambda p} = \mathrm{e}^{-\lambda p}.$$

$$\mathbb{P}(K=k) = \mathrm{e}^{-\lambda p}\frac{(\lambda p)^k}{k!}.$$

Ergebnis: $K \sim \mathrm{Poi}(\lambda p)$**.**
Kontrolle. $\mathbb{E}[K] = \lambda p$ – stimmt mit Schritt 2 überein. ✓
Warum das schön ist. Eine Poisson-Verteilung, die man zufällig *ausdünnt*, bleibt Poisson-verteilt. Man nennt das **Thinning**.
Praktische Bedeutung. Wenn Ereignisse Poisson-verteilt auftreten und nur ein Anteil p davon erfasst wird – unvollständige Meldung von Infektionen, Stichprobenkontrolle, Detektoreffizienz –, so sind die *erfassten* Ereignisse wieder Poisson-verteilt, mit entsprechend verkleinerter Rate.
Das ist ein sehr nützliches Ergebnis: Es bedeutet, dass unvollständige Erfassung die Modellklasse nicht verlässt. Umgekehrt heißt es aber auch, dass man aus den Daten allein die Untererfassung *nicht* erkennen kann – man sieht nur λp, nie λ und p getrennt. Diese Nichtidentifizierbarkeit ist ein grundsätzliches Problem der Meldedatenanalyse.

Part IV

Die Grenzwertsätze

9 Konvergenzbegriffe

9.1 Vier Arten der Konvergenz

In der Analysis gab es einen Konvergenzbegriff für Folgen und zwei für Funktionenfolgen. In der Stochastik gibt es vier – und ihre Unterschiede zu kennen ist der Schlüssel zu den Grenzwertsätzen.

Definition 9.1. Sei (X_n) eine Folge von Zufallsvariablen und X eine Zufallsvariable.

(a) **Fast sichere Konvergenz**, $X_n \to X$ f.s.:

$$\mathbb{P}\left(\left\{\omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1.$$

(b) **Konvergenz in Wahrscheinlichkeit**, $X_n \xrightarrow{\mathbb{P}} X$: für jedes $\varepsilon > 0$

$$\mathbb{P}\big(|X_n - X| > \varepsilon\big) \longrightarrow 0.$$

(c) **Konvergenz im p-ten Mittel**, $X_n \xrightarrow{L^p} X$:

$$\mathbb{E}\big[|X_n - X|^p\big] \longrightarrow 0.$$

(d) **Konvergenz in Verteilung**, $X_n \xrightarrow{d} X$:

$$F_{X_n}(t) \longrightarrow F_X(t) \qquad \text{für jede Stetigkeitsstelle } t \text{ von } F_X.$$

Was die Begriffe unterscheidet

(a) Fast sicher ist die stärkste natürliche Forderung: Für fast jedes einzelne ω konvergiert die Zahlenfolge $X_n(\omega)$. Das ist punktweise Konvergenz auf einer Menge vom Maß 1.
(b) In Wahrscheinlichkeit verlangt weniger: Zu jedem Zeitpunkt n ist die *Menge* der schlechten ω klein. Aber es dürfen bei jedem n *andere* ω schlecht sein.
(c) Im Mittel misst den mittleren Fehler. Für $p = 2$: mittlerer quadratischer Fehler.
(d) In Verteilung ist die schwächste Form – und die einzige, bei der X_n und X nicht einmal auf demselben Raum leben müssen. Es konvergieren nur die *Verteilungen*, nicht die Zufallsvariablen.

Satz 9.2 (Die Hierarchie)**.**

$$X_n \to X \text{ f.s.} \quad \Longrightarrow \quad X_n \xrightarrow{\mathbb{P}} X \quad \Longrightarrow \quad X_n \xrightarrow{d} X$$

$$X_n \xrightarrow{L^p} X \quad \Longrightarrow \quad X_n \xrightarrow{\mathbb{P}} X$$

Keine dieser Implikationen ist umkehrbar. Fast sichere und L^p-Konvergenz implizieren einander nicht.

Zwei Ausnahmen:

- *Konvergiert $X_n \xrightarrow{d} c$ gegen eine* Konstante, *so auch in Wahrscheinlichkeit.*
- *Aus Konvergenz in Wahrscheinlichkeit folgt die fast sichere Konvergenz einer* Teilfolge.

Beweis von „$L^p \Rightarrow$ in Wahrscheinlichkeit“. Markow-Ungleichung (Satz 7.8), angewandt auf $|X_n - X|^p$:

$$\mathbb{P}\big(|X_n - X| > \varepsilon\big) = \mathbb{P}\big(|X_n - X|^p > \varepsilon^p\big) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p} \longrightarrow 0. \qquad \blacksquare$$

Die Gegenbeispiele – man sollte sie kennen

1. In Wahrscheinlichkeit, aber nicht fast sicher: der „wandernde Block“.
Auf $\Omega = [0,1]$ mit der Gleichverteilung definieren wir Intervalle, die immer kürzer werden, aber immer wieder umlaufen:

$$I_1 = [0,1], \quad I_2 = [0,\tfrac{1}{2}],\ I_3 = [\tfrac{1}{2},1], \quad I_4 = [0,\tfrac{1}{3}],\ I_5 = [\tfrac{1}{3},\tfrac{2}{3}],\ I_6 = [\tfrac{2}{3},1],\ \ldots$$

und setzen $X_n := \mathbf{1}_{I_n}$.
In Wahrscheinlichkeit: $\mathbb{P}(X_n \neq 0) = |I_n| \to 0$. ✓
Nicht fast sicher: Für *jedes* $\omega \in [0,1]$ gilt $X_n(\omega) = 1$ für unendlich viele n – die Blöcke laufen immer wieder über jeden Punkt. Die Folge $X_n(\omega)$ konvergiert also für kein einziges ω.

2. Fast sicher, aber nicht in L^1: die „schmale hohe Spitze“.

$$X_n := n^2 \cdot \mathbf{1}_{[0,1/n]}.$$

Fast sicher: Für jedes $\omega > 0$ ist $X_n(\omega) = 0$, sobald $n > \frac{1}{\omega}$. Also $X_n \to 0$ f.s.. ✓
Nicht in L^1: $\mathbb{E}[X_n] = n^2 \cdot \frac{1}{n} = n \to \infty$.
Das ist dasselbe Phänomen wie bei den schmalen hohen Dreiecken in Band 3, Kapitel 12 – die Masse verschwindet nicht, sie wird nur konzentriert.

3. In Verteilung, aber nicht in Wahrscheinlichkeit.
Sei $X \sim \mathcal{N}(0,1)$ und $X_n := -X$ für alle n. Wegen der Symmetrie hat $-X$ dieselbe Verteilung wie X, also $X_n \xrightarrow{d} X$.
Aber $|X_n - X| = 2\,|X|$, was nicht klein wird. Die *Verteilungen* stimmen überein, die *Zufallsvariablen* sind maximal verschieden.

9.2 Die Lemmata von Borel und Cantelli

Definition 9.3. Für eine Folge von Ereignissen (A_n) sei

$$\{A_n \text{ unendlich oft}\} := \limsup_n A_n := \bigcap_{n=1}^{\infty} \bigcup_{k \geq n} A_k.$$

> **Die Formel entziffern**
> ω liegt in $\bigcup_{k\geq n} A_k$ genau dann, wenn ω in *mindestens einem* A_k mit $k \geq n$ liegt. ω liegt in *allen* diesen Vereinigungen – also im Durchschnitt über alle n – genau dann, wenn es zu jedem n noch ein späteres A_k gibt, das ω enthält. Und das heißt: ω liegt in unendlich vielen A_k. ✓

Satz 9.4 (Erstes Borel–Cantelli-Lemma)**.** *Gilt* $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, *so ist*

$$\mathbb{P}(A_n \text{ unendlich oft}) = 0.$$

Beweis. Sei $B_n := \bigcup_{k\geq n} A_k$. Diese Mengen fallen monoton gegen $\limsup A_n$. Nach der Stetigkeit von oben (Satz 1.9) und der Subadditivität:

$$\mathbb{P}(\limsup A_n) = \lim_n \mathbb{P}(B_n) \leq \lim_n \sum_{k\geq n} \mathbb{P}(A_k).$$

Der letzte Ausdruck ist der Reihenrest einer *konvergenten* Reihe und geht daher gegen null. ∎

Satz 9.5 (Zweites Borel–Cantelli-Lemma)**.** *Sind die* A_n unabhängig *und gilt* $\sum_n \mathbb{P}(A_n) = \infty$, *so ist*

$$\mathbb{P}(A_n \text{ unendlich oft}) = 1.$$

Beweis. Wir zeigen $\mathbb{P}\left(\bigcap_{k\geq n} A_k^c\right) = 0$ für jedes n. Wegen der Unabhängigkeit:

$$\mathbb{P}\left(\bigcap_{k=n}^{m} A_k^c\right) = \prod_{k=n}^{m} (1 - \mathbb{P}(A_k)).$$

Nun benutzen wir die elementare Ungleichung $1 - x \leq \mathrm{e}^{-x}$ (sie folgt aus der Konvexität von e^{-x} und der Tangente in 0):

$$\prod_{k=n}^{m} (1 - \mathbb{P}(A_k)) \leq \prod_{k=n}^{m} \mathrm{e}^{-\mathbb{P}(A_k)} = \exp\left(-\sum_{k=n}^{m} \mathbb{P}(A_k)\right).$$

Für $m \to \infty$ divergiert die Summe im Exponenten, das Produkt geht also gegen null.

Damit ist $\mathbb{P}\left(\bigcup_{k\geq n} A_k\right) = 1$ für jedes n, und der Durchschnitt abzählbar vieler Ereignisse der Wahrscheinlichkeit 1 hat wieder Wahrscheinlichkeit 1. ∎

Die Null-Eins-Struktur

Zusammengenommen: Bei *unabhängigen* Ereignissen ist $\mathbb{P}(A_n \text{ u. o.})$ entweder 0 oder 1 – je nachdem, ob $\sum \mathbb{P}(A_n)$ konvergiert oder divergiert. Nichts dazwischen. Das ist ein Spezialfall des **Kolmogorowschen Null-Eins-Gesetzes**: Jedes „terminale" Ereignis – eines, das sich nicht ändert, wenn man endlich viele der X_n abändert – hat Wahrscheinlichkeit 0 oder 1.

Beispiele terminaler Ereignisse:

- „$\sum X_n$ konvergiert"
- „$\frac{1}{n}\sum_{k\le n} X_k$ konvergiert"
- „die Irrfahrt kehrt unendlich oft zum Ursprung zurück"

Für all diese gilt: Man muss nicht fragen, *wie* wahrscheinlich sie sind, sondern nur, *ob* sie fast sicher eintreten oder fast sicher nicht.

Aufgabe 9.1. Ein Affe tippt zufällig und unabhängig Zeichen auf einer Tastatur mit 90 Tasten. Wie wahrscheinlich ist es, dass er irgendwann den vollständigen *Hamlet* tippt?

Lösung Schritt für Schritt.

Schritt 1 – Modell. *Hamlet* habe L Zeichen (etwa $L = 180\,000$). Wir betrachten die Blöcke

$$A_n := \{\text{die Zeichen } (n-1)L+1, \dots, nL \text{ ergeben genau Hamlet}\}.$$

Diese Blöcke sind *disjunkt* in den benutzten Zeichen und damit unabhängig.

Schritt 2 – Einzelwahrscheinlichkeit.

$$p := \mathbb{P}(A_n) = \left(\frac{1}{90}\right)^{L} = 90^{-180\,000}.$$

Das ist eine unvorstellbar kleine, aber *positive* Zahl. Zum Vergleich: Das beobachtbare Universum enthält etwa 10^{80} Atome; hier steht eine Zahl der Größenordnung $10^{-352\,000}$.

Schritt 3 – Reihe untersuchen.

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} p = \infty,$$

denn es werden unendlich viele gleiche positive Zahlen addiert.

Schritt 4 – Zweites Borel–Cantelli. Die A_n sind unabhängig, die Reihe divergiert. Also

$$\mathbb{P}(A_n \text{ unendlich oft}) = 1.$$

Antwort: Fast sicher tippt der Affe den Hamlet – und zwar unendlich oft.

Schritt 5 – Was das praktisch bedeutet: nichts.

Die erwartete Wartezeit beträgt $\frac{1}{p} = 90^{180\,000}$ Blöcke. Selbst wenn der Affe seit dem Urknall mit einer Milliarde Anschlägen pro Sekunde tippte, wären erst etwa 10^{26} Zeichen entstanden – gegenüber den nötigen $10^{352\,000}$.

Die Lehre. *Wahrscheinlichkeit 1 bedeutet nicht „praktisch sicher" in irgendeinem zeitlichen Sinn.* Asymptotische Aussagen sagen nichts über endliche Zeithorizonte. Das ist derselbe Vorbehalt, den man bei jedem Gesetz der großen Zahlen im Kopf behalten muss: Es garantiert Konvergenz, aber ohne Zusatzinformation keine Geschwindigkeit.

Die Geschichte des Affen

Das Bild geht auf ÉMILE BOREL zurück, der es 1913 in einem Aufsatz über statistische Mechanik verwendete – um zu illustrieren, dass extrem unwahrscheinliche Ereignisse praktisch als unmöglich gelten dürfen. Seine Absicht war also genau die entgegengesetzte zu der Lesart, die sich durchgesetzt hat.

ARTHUR EDDINGTON nahm es 1928 auf, JORGE LUIS BORGES verarbeitete den Gedanken 1941 in *Die Bibliothek von Babel*.

2003 führten Studenten der University of Plymouth ein reales Experiment durch: Sechs Makaken erhielten einen Monat lang einen Computer. Das Ergebnis waren fünf Seiten, überwiegend mit dem Buchstaben S, sowie erhebliche Schäden an der Tastatur.

Wozu Borel–Cantelli in Beweisen dient

Es ist das Standardwerkzeug für *fast sichere* Aussagen. Das Muster:

Will man $X_n \to X$ fast sicher zeigen, so genügt es nach dem ersten Lemma nachzuweisen, dass

$$\sum_n \mathbb{P}\big(|X_n - X| > \varepsilon\big) < \infty$$

für jedes $\varepsilon > 0$. Denn dann treten die „schlechten" Ereignisse nur endlich oft auf, und ab einem (zufälligen) Zeitpunkt gilt $|X_n - X| \le \varepsilon$.

Der Unterschied zur Konvergenz in Wahrscheinlichkeit liegt genau darin, dass dort nur $\mathbb{P}(|X_n - X| > \varepsilon) \to 0$ gefordert ist – die Summe darf divergieren. Konvergenz der Reihe ist echt stärker als Konvergenz der Glieder.

Dieses Kriterium ist der Schlüssel zum starken Gesetz der großen Zahlen im nächsten Kapitel.

10 Die Gesetze der großen Zahlen

10.1 Das schwache Gesetz

Satz 10.1 (Schwaches Gesetz der großen Zahlen)**.** *Seien $X_1, X_2, \dots$ unabhängig mit gleichem Erwartungswert μ und gleicher endlicher Varianz σ^2. Sei*

$$\bar{X}_n := \frac{1}{n} \sum_{k=1}^{n} X_k.$$

Dann gilt für jedes $\varepsilon > 0$

$$\mathbb{P}\big(|\bar{X}_n - \mu| \geq \varepsilon\big) \;\leq\; \frac{\sigma^2}{n\varepsilon^2} \;\longrightarrow\; 0.$$

Beweis. **Schritt 1 – Erwartungswert des Mittels.** Nach der Linearität:

$$\mathbb{E}[\bar{X}_n] = \frac{1}{n} \sum_{k=1}^{n} \mathbb{E}[X_k] = \frac{n\mu}{n} = \mu.$$

Schritt 2 – Varianz des Mittels. Hier geht die Unabhängigkeit ein (Satz 7.7):

$$\operatorname{Var}(\bar{X}_n) = \operatorname{Var}\left(\frac{1}{n}\sum_{k} X_k\right) = \frac{1}{n^2} \operatorname{Var}\left(\sum_{k} X_k\right) = \frac{1}{n^2} \sum_{k} \operatorname{Var}(X_k) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Beachten Sie den Faktor $\frac{1}{n^2}$: Die Varianz ist quadratisch homogen. Genau deshalb schrumpft die Varianz des Mittels mit $\frac{1}{n}$ und die Standardabweichung mit $\frac{1}{\sqrt{n}}$.

Schritt 3 – Tschebyschow anwenden (Satz 7.9):

$$\mathbb{P}\big(|\bar{X}_n - \mu| \geq \varepsilon\big) \leq \frac{\operatorname{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

■

> **Drei Zeilen – und eines der wichtigsten Resultate der Mathematik**
>
> Der ganze Beweis besteht aus der Varianzformel und Tschebyschow. Das ist bemerkenswert für einen Satz dieser Tragweite.
>
> **Der Wurzel-n-Effekt.** Um die Genauigkeit zu *verdoppeln*, braucht man die *vierfache* Stichprobe. Das ist das ökonomische Grundgesetz aller empirischen Forschung:

n	$\sigma/\sqrt{n}$ (für $\sigma = 1$)
100	0,100
400	0,050
1 600	0,025
10 000	0,010
1 000 000	0,001

Deshalb haben Umfragen typischerweise 1000 bis 2000 Befragte: Dort liegt der Fehler bei etwa 2 bis 3 Prozentpunkten, und eine Halbierung würde die Kosten vervierfachen.

Jacob Bernoullis zwanzig Jahre

JACOB BERNOULLI bewies das erste Gesetz der großen Zahlen – für den Spezialfall der Binomialverteilung – und nannte es sein *theorema aureum*, sein goldenes Theorem. Er arbeitete nach eigener Angabe zwanzig Jahre daran.
Veröffentlicht wurde es 1713 in der *Ars Conjectandi*[4], acht Jahre nach seinem Tod, herausgegeben von seinem Neffen Nikolaus.
Was Bernoulli suchte, war eine Rechtfertigung der statistischen Schätzung: Darf man aus beobachteten Häufigkeiten auf zugrundeliegende Wahrscheinlichkeiten schließen? Seine Antwort war ja – mit einer expliziten, wenn auch sehr groben Abschätzung der nötigen Beobachtungszahl. Für eine Genauigkeit von $\frac{1}{50}$ bei einer Sicherheit von $\frac{1000}{1001}$ errechnete er 25 550 Beobachtungen und hielt die Zahl selbst für unpraktikabel groß.
TSCHEBYSCHOW gab 1867 den heute üblichen kurzen Beweis mit seiner Ungleichung; CHINTSCHIN zeigte 1929, dass die Existenz des Erwartungswerts allein genügt – die Varianz muss gar nicht endlich sein.

10.2 Das starke Gesetz

Satz 10.2 (Starkes Gesetz der großen Zahlen, Kolmogorow 1930)**.** *Seien $X_1, X_2, \dots$ unabhängig und identisch verteilt mit $\mathbb{E}[|X_1|] < \infty$ und $\mu := \mathbb{E}[X_1]$. Dann*

$$\bar{X}_n \longrightarrow \mu \qquad \textit{fast sicher.}$$

Beweis unter der Zusatzannahme endlicher vierter Momente. Der allgemeine Beweis ist aufwendig. Unter der stärkeren Momentenbedingung wird er zugänglich – und die Beweisidee ist genau die Borel–Cantelli-Technik aus dem vorigen Kapitel.

Schritt 1 – Zentrieren. Ohne Einschränkung sei $\mu = 0$ (sonst betrachte $Y_k := X_k - \mu$). Sei $S_n := \sum_{k=1}^{n} X_k$.

Schritt 2 – Das vierte Moment der Summe. Wir multiplizieren aus:

$$\mathbb{E}[S_n^4] = \mathbb{E}\left[\left(\sum_k X_k\right)^4\right] = \sum_{i,j,k,l} \mathbb{E}[X_i X_j X_k X_l].$$

Wegen der Unabhängigkeit und $\mathbb{E}[X_k] = 0$ verschwindet jeder Term, in dem ein Index *genau einmal* vorkommt: Man kann diesen Faktor herausziehen, und er ist null.

Es überleben nur zwei Typen:

- alle vier Indizes gleich: n Terme mit dem Wert $\mathbb{E}[X_1^4]$;
- zwei Paare gleicher Indizes: Es gibt $\binom{n}{2}$ Indexpaare $\{i,j\}$ und $\binom{4}{2} = 6$ Möglichkeiten, welche der vier Positionen zum ersten Paar gehören – also $3n(n-1)$ Terme mit dem Wert $\big(\mathbb{E}[X_1^2]\big)^2$.

$$\mathbb{E}[S_n^4] = n\,\mathbb{E}[X_1^4] + 3n(n-1)\big(\mathbb{E}[X_1^2]\big)^2 \le C\,n^2$$

mit einer Konstanten C, die nur von der Verteilung abhängt.

Schritt 3 – Markow anwenden. Für $\varepsilon > 0$:

$$\mathbb{P}\big(|\bar{X}_n| > \varepsilon\big) = \mathbb{P}\big(S_n^4 > n^4\varepsilon^4\big) \le \frac{\mathbb{E}[S_n^4]}{n^4\varepsilon^4} \le \frac{C}{n^2\varepsilon^4}.$$

Schritt 4 – Reihe summieren.

$$\sum_{n=1}^{\infty} \mathbb{P}\big(|\bar{X}_n| > \varepsilon\big) \le \frac{C}{\varepsilon^4} \sum_n \frac{1}{n^2} < \infty,$$

denn $\sum \frac{1}{n^2}$ konvergiert (Band 3, Kapitel 3).

Schritt 5 – Borel–Cantelli. Nach Satz 9.4 tritt $\{|\bar{X}_n| > \varepsilon\}$ fast sicher nur endlich oft ein. Es gibt also ein (zufälliges) $N(\omega)$, ab dem stets $|\bar{X}_n| \le \varepsilon$ gilt.

Schritt 6 – Von ε zu allen ε. Wendet man das auf die abzählbare Familie $\varepsilon = \frac{1}{m}$, $m \in \mathbb{N}$, an und schneidet die abzählbar vielen Ereignisse der Wahrscheinlichkeit 1, so erhält man wieder Wahrscheinlichkeit 1. Auf dieser Menge gilt $\bar{X}_n \to 0$. ∎

Schwach oder stark – worin genau liegt der Unterschied?

Schwach: Für großes n ist es *unwahrscheinlich*, dass $\bar{X}_n$ weit von μ entfernt ist. Es ist aber nicht ausgeschlossen, dass die Folge $\bar{X}_n(\omega)$ immer wieder einmal ausbricht.
Stark: Für fast jedes ω konvergiert die Zahlenfolge $\bar{X}_n(\omega)$ tatsächlich. Ausbrüche kommen nur endlich oft vor.
Ein Bild. Beim schwachen Gesetz darf die Folge unendlich oft aus dem Toleranzband herausspringen – nur eben immer seltener. Beim starken Gesetz bleibt sie ab einem Zeitpunkt endgültig drin.
Warum das praktisch zählt. Nur das starke Gesetz rechtfertigt die Aussage: „Wenn ich lange genug messe, konvergiert mein Mittelwert." Das schwache Gesetz sagt lediglich etwas über *jede einzelne* Messreihe der Länge n.

Aufgabe 10.1. Eine faire Münze wird wiederholt geworfen. Sei H_n die Anzahl der Köpfe nach n Würfen.

(a) Was sagt das starke Gesetz über $\frac{H_n}{n}$?

(b) Konvergiert die *absolute* Differenz $H_n - \frac{n}{2}$ gegen 0?

(c) Wie groß ist typischerweise $\left|H_n - \frac{n}{2}\right|$?

Lösung Schritt für Schritt.

(a) Mit $X_k := \mathbf{1}\{k\text{-ter Wurf Kopf}\}$ ist $H_n = \sum_k X_k$ und $\mathbb{E}[X_k] = \frac{1}{2}$. Nach dem starken Gesetz:

$$\frac{H_n}{n} \longrightarrow \frac{1}{2} \qquad \text{fast sicher.}$$

(b) Nein – im Gegenteil. Das ist der Kernpunkt, der fast immer missverstanden wird.
Die *relative* Häufigkeit konvergiert. Die *absolute* Abweichung wächst unbeschränkt. *Formal:* $\mathrm{Var}(H_n) = n \cdot \frac{1}{4}$, also

$$\sigma_{H_n} = \frac{\sqrt{n}}{2} \longrightarrow \infty.$$

(c) Für großes n ist $H_n - \frac{n}{2}$ näherungsweise $\mathcal{N}\left(0, \frac{n}{4}\right)$-verteilt (zentraler Grenzwertsatz, Kapitel 11). Der Erwartungswert des Betrags einer $\mathcal{N}(0, \sigma^2)$-Größe ist $\sigma\sqrt{\frac{2}{\pi}}$:

$$\mathbb{E}\left[\left|H_n - \frac{n}{2}\right|\right] \approx \frac{\sqrt{n}}{2}\sqrt{\frac{2}{\pi}} = \sqrt{\frac{n}{2\pi}}.$$

n	typische Abweichung	relativ
100	4,0	4,0 %
10 000	39,9	0,40 %
1 000 000	399	0,040 %

Die Auflösung des scheinbaren Widerspruchs. Beides ist wahr:

$$\frac{H_n}{n} \to \frac{1}{2} \qquad \text{und} \qquad \left|H_n - \frac{n}{2}\right| \to \infty.$$

Denn die absolute Abweichung wächst wie $\sqrt{n}$, während der Nenner mit n wächst. Der Quotient geht wie $\frac{1}{\sqrt{n}}$ gegen null.
Warum das den Spielerfehlschluss endgültig erledigt. Die verbreitete Vorstellung lautet: „Wenn zu viele Köpfe gefallen sind, muss ein Ausgleich kommen."
Es kommt kein Ausgleich. Ein Vorsprung von 50 Köpfen wird nicht abgebaut – er wird nur relativ zu n unbedeutend. Nach 10^6 Würfen ist ein Vorsprung von 50 statistisch völlig unauffällig.

Der Ausgleich ist *Verdünnung*, nicht Korrektur. WILLIAM FELLER nannte diese Unterscheidung in seinem Lehrbuch[9] den vielleicht am häufigsten missverstandenen Punkt der elementaren Wahrscheinlichkeitsrechnung.

Ein Nachtrag zum Gesetz des iterierten Logarithmus. Man kann die Größe der Schwankungen sogar exakt angeben. Nach dem Satz von CHINTSCHIN (1924) und KOLMOGOROW gilt fast sicher

$$\limsup_{n\to\infty} \frac{H_n - \frac{n}{2}}{\sqrt{\frac{n}{2}\ln\ln n}} = 1.$$

Die Folge kommt dieser Schranke unendlich oft beliebig nahe und überschreitet sie nur endlich oft. Das ist eine bemerkenswert präzise Aussage über das Ausmaß der Fluktuationen – feiner als das Gesetz der großen Zahlen, gröber als der zentrale Grenzwertsatz.

Was das Gesetz der großen Zahlen rechtfertigt

1. Die frequentistische Deutung. Die relative Häufigkeit konvergiert gegen die Wahrscheinlichkeit. Das ist die Brücke zwischen Modell und Beobachtung.
Achtung: Es ist keine *Definition* von Wahrscheinlichkeit – der Satz *setzt* ein Wahrscheinlichkeitsmaß voraus. RICHARD VON MISES versuchte ab 1919, Wahrscheinlichkeit über Grenzwerte relativer Häufigkeiten zu definieren; der Ansatz erwies sich als technisch problematisch und wurde von Kolmogorows Zugang verdrängt.

2. Die Monte-Carlo-Methode. Will man $\mathbb{E}[g(X)]$ berechnen, so simuliert man $X_1, \dots, X_n$ und mittelt. Die Genauigkeit wächst mit $\frac{1}{\sqrt{n}}$ – unabhängig von der *Dimension* des Problems.
Das ist der entscheidende Vorteil gegenüber Gitterverfahren, deren Aufwand exponentiell mit der Dimension wächst. In hohen Dimensionen ist Monte Carlo oft das einzige praktikable Verfahren.
Die Methode wurde 1946 von STANISŁAW ULAM während einer Krankheit erdacht – er hatte Patiencen gelegt und sich gefragt, wie man die Gewinnwahrscheinlichkeit bestimmen könne. JOHN VON NEUMANN erkannte die Tragweite; der Deckname „Monte Carlo“ stammt von NICHOLAS METROPOLIS und spielt auf den spielsüchtigen Onkel Ulams an.

3. Das Versicherungsprinzip. Ein einzelner Schaden ist unvorhersehbar; der Durchschnitt vieler unabhängiger Schäden ist es nicht.
Die entscheidende Voraussetzung ist die Unabhängigkeit. Bei Naturkatastrophen, Pandemien oder Finanzkrisen sind die Schäden hochgradig korreliert – dann versagt das Prinzip. Genau deshalb gibt es Rückversicherung, staatliche Garantien und Ausschlussklauseln für Kriegs- und Nuklearschäden.

11 Der zentrale Grenzwertsatz

11.1 Die Aussage

Satz 11.1 (Zentraler Grenzwertsatz, Lindeberg–Lévy)**.** *Seien $X_1, X_2, \ldots$ unabhängig, identisch verteilt, mit $\mathbb{E}[X_1] = \mu$ und $0 < \operatorname{Var}(X_1) = \sigma^2 < \infty$. Dann gilt*

$$Z_n := \frac{\sum_{k=1}^{n} X_k - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1),$$

das heißt

$$\mathbb{P}(Z_n \le t) \longrightarrow \Phi(t) \qquad \text{für alle } t \in \mathbb{R}.$$

Warum das so erstaunlich ist

Die Verteilung der Summanden spielt keine Rolle. Ob die X_k Münzwürfe sind, exponentialverteilte Wartezeiten, Würfelaugen oder Messfehler einer beliebigen Bauart – die standardisierte Summe konvergiert stets gegen *dieselbe* Grenzverteilung.
Nur zwei Dinge müssen erfüllt sein: Unabhängigkeit und endliche Varianz.
Das erklärt die Allgegenwart der Normalverteilung. Wo immer eine beobachtete Größe als Summe vieler kleiner, unabhängiger Beiträge entsteht – Messfehler, biologische Merkmale mit polygener Grundlage, Rauschen in elektronischen Bauteilen –, ist sie näherungsweise normalverteilt.
Die Einschränkungen sind aber ernst zu nehmen:

- *Ohne endliche Varianz* gilt der Satz nicht. Cauchy-verteilte Summanden bleiben Cauchy-verteilt. Allgemein konvergieren Summen gegen **stabile Verteilungen**, deren Ränder schwerer sind (Lévy 1925).
- *Ohne Unabhängigkeit* gilt er nur unter Zusatzbedingungen an die Abhängigkeitsstruktur.
- *Bei multiplikativer* statt additiver Verknüpfung erhält man die Lognormalverteilung.
- *Die Konvergenz betrifft die Mitte, nicht die Ränder.* Für extreme Abweichungen ist die Normalapproximation oft schlecht – dafür gibt es die Theorie der großen Abweichungen.

11.2 Der Beweis

Das Werkzeug: charakteristische Funktionen

$$\phi_X(t) := \mathbb{E}\left[e^{itX}\right].$$

Drei Eigenschaften brauchen wir:

(i) $\phi_{X+Y} = \phi_X \phi_Y$ bei Unabhängigkeit,

(ii) $\phi_{aX}(t) = \phi_X(at)$,

(iii) **Stetigkeitssatz von Lévy:** Konvergieren $\phi_{X_n}(t) \to \phi(t)$ punktweise und ist ϕ in 0 stetig, so ist ϕ die charakteristische Funktion einer Zufallsvariablen X, und $X_n \xrightarrow{d} X$.

Punkt (iii) ist der eigentliche Hebel: Er übersetzt Verteilungskonvergenz in punktweise Konvergenz von Funktionen – und damit in gewöhnliche Analysis.

Beweis des zentralen Grenzwertsatzes. **Schritt 1 – Standardisieren.** Ohne Einschränkung sei $\mu = 0$ und $\sigma^2 = 1$ (sonst betrachte $\frac{X_k - \mu}{\sigma}$). Dann ist

$$Z_n = \frac{1}{\sqrt{n}} \sum_{k=1}^{n} X_k.$$

Schritt 2 – Charakteristische Funktion von Z_n. Nach (i) und (ii):

$$\phi_{Z_n}(t) = \prod_{k=1}^{n} \phi_{X_k}\left(\frac{t}{\sqrt{n}}\right) = \left[\phi_X\left(\frac{t}{\sqrt{n}}\right)\right]^n,$$

wobei ϕ_X die gemeinsame charakteristische Funktion der X_k ist.

Schritt 3 – Taylorentwicklung von ϕ_X um 0.
Wir differenzieren unter dem Erwartungswert (zulässig, weil die Momente existieren):

$$\phi_X(0) = \mathbb{E}[1] = 1,$$

$$\phi_X'(0) = \mathbb{E}[iX] = i\,\mathbb{E}[X] = 0,$$

$$\phi_X''(0) = \mathbb{E}[(iX)^2] = -\mathbb{E}[X^2] = -1.$$

Die Taylorformel mit Restglied (Band 3, Kapitel 8) liefert für $s \to 0$:

$$\phi_X(s) = 1 + 0 \cdot s - \frac{s^2}{2} + o(s^2).$$

Schritt 4 – Einsetzen. Mit $s = \frac{t}{\sqrt{n}}$:

$$\phi_X\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

Schritt 5 – Potenzieren und Grenzübergang.

$$\phi_{Z_n}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n.$$

Hier steht – bis auf den Fehlerterm – genau die Folge aus Band 3, Satz zur Eulerschen Zahl:

$$\left(1 + \frac{x}{n}\right)^n \longrightarrow \mathrm{e}^x.$$

Mit $x = -\frac{t^2}{2}$:

$$\phi_{Z_n}(t) \longrightarrow \mathrm{e}^{-t^2/2}.$$

Schritt 6 – Wiedererkennen. Die Funktion $\mathrm{e}^{-t^2/2}$ ist genau die charakteristische Funktion der Standardnormalverteilung:

$$\mathbb{E}\left[\mathrm{e}^{\mathrm{i}tZ}\right] = \int_{-\infty}^{\infty} \mathrm{e}^{\mathrm{i}tz} \frac{1}{\sqrt{2\pi}} \mathrm{e}^{-z^2/2}\,\mathrm{d}z = \mathrm{e}^{-t^2/2}$$

(quadratische Ergänzung im Exponenten und Gauß-Integral).

Nach dem Stetigkeitssatz von Lévy folgt $Z_n \xrightarrow{d} \mathcal{N}(0,1)$. ∎

Wo genau die Normalverteilung herkommt

Sehen Sie sich Schritt 3 an. In die Rechnung gehen *nur* die ersten beiden Momente ein: $\mathbb{E}[X] = 0$ und $\mathbb{E}[X^2] = 1$. Alle höheren Momente verschwinden im Fehlerterm $o(s^2)$.

Das ist der ganze Grund für die Universalität. Nach der Standardisierung sehen alle Verteilungen bis zur zweiten Ordnung gleich aus – und mehr als zwei Ordnungen überleben den Grenzübergang nicht.

Die Normalverteilung ist also nicht deshalb ausgezeichnet, weil sie besonders „natürlich“ wäre, sondern weil sie der *einzige Fixpunkt* dieser Mittelungsoperation mit endlicher Varianz ist. Lässt man unendliche Varianz zu, gibt es weitere Fixpunkte – die stabilen Verteilungen von Lévy.

Satz 11.2 (Satz von de Moivre–Laplace)**.** *Für $X_n \sim \mathrm{Bin}(n,p)$ gilt*

$$\frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} \mathcal{N}(0,1).$$

Das ist der Spezialfall mit Bernoulli-Summanden – historisch der erste bekannte Fall, von de Moivre 1733 für $p = \frac{1}{2}$ und von Laplace 1812 allgemein bewiesen.

Die Stetigkeitskorrektur

Man approximiert eine *diskrete* Verteilung durch eine *stetige*. Dabei verschiebt man die Grenzen um $\frac{1}{2}$ nach außen:

$$\mathbb{P}(X \le k) \approx \Phi\left(\frac{k + 0{,}5 - np}{\sqrt{np(1-p)}}\right).$$

Warum: Der Balken über k reicht in der stetigen Deutung von $k - \frac{1}{2}$ bis $k + \frac{1}{2}$. Ohne Korrektur schneidet man die Hälfte des Randbalkens ab.
Die Korrektur verbessert die Genauigkeit erheblich, besonders bei kleinem n – häufig um eine Größenordnung.
Faustregel für die Anwendbarkeit: $np(1-p) \ge 9$. Bei stark asymmetrischem p ist die Poisson-Approximation besser.

Aufgabe 11.1. Eine faire Münze wird 100-mal geworfen. Berechnen Sie $\mathbb{P}(45 \le X \le 55)$

(a) exakt (näherungsweise, per Summation),
(b) mit Normalapproximation ohne Stetigkeitskorrektur,
(c) mit Stetigkeitskorrektur.

Lösung Schritt für Schritt.

Modell: $X \sim \mathrm{Bin}(100;\ 0{,}5)$, also

$$\mu = np = 50, \qquad \sigma = \sqrt{np(1-p)} = \sqrt{25} = 5.$$

(a) Exakter Wert.

$$\mathbb{P}(45 \le X \le 55) = \sum_{k=45}^{55} \binom{100}{k} 0{,}5^{100} = 0{,}72875.$$

(b) Ohne Korrektur.

$$z_1 = \frac{45 - 50}{5} = -1, \qquad z_2 = \frac{55 - 50}{5} = 1.$$

$$\Phi(1) - \Phi(-1) = 0{,}8413 - 0{,}1587 = 0{,}6827.$$

Fehler: $0{,}72875 - 0{,}6827 = 0{,}0461$, also gut 4,6 Prozentpunkte – ein relativer Fehler von 6,3 %. Deutlich zu klein.

(c) Mit Stetigkeitskorrektur.

$$z_1 = \frac{44{,}5 - 50}{5} = -1{,}1, \qquad z_2 = \frac{55{,}5 - 50}{5} = 1{,}1.$$

$$\Phi(1{,}1) - \Phi(-1{,}1) = 0{,}8643 - 0{,}1357 = 0{,}7286.$$

Fehler: 0,00015 – also 0,02 %.

Die Korrektur reduziert den Fehler um mehr als den Faktor 300. Vergleichstabelle.

Methode	Wert	abs. Fehler
exakt	0,72875	—
ohne Korrektur	0,68269	0,04606
mit Korrektur	0,72860	0,00015

Merkregel. Bei diskreten Verteilungen *immer* korrigieren. Die Regel lautet: Grenzen nach außen um 0,5 verschieben, wenn man einschließt; nach innen, wenn man ausschließt.

Warum das heute noch relevant ist. Man könnte einwenden, dass jeder Rechner die exakte Binomialsumme in Millisekunden liefert. Das stimmt. Die Normalapproximation ist dennoch unverzichtbar, weil praktisch alle *Formeln* der schließenden Statistik – Konfidenzintervalle, Teststatistiken, Fallzahlplanung – auf ihr beruhen. Wer sie nicht versteht, versteht nicht, woher das 1,96 in jedem Konfidenzintervall kommt.

11.3 Wie schnell konvergiert es?

Satz 11.3 (Berry–Esseen, 1941/42)**.** *Sei zusätzlich* $\rho := \mathbb{E}\big[|X_1 - \mu|^3\big] < \infty$. *Dann gilt für alle* n *und alle* t

$$\big|\mathbb{P}(Z_n \le t) - \Phi(t)\big| \;\le\; \frac{C\,\rho}{\sigma^3\sqrt{n}}$$

mit einer universellen Konstanten C.

Was der Satz sagt – und was nicht

Die gute Nachricht: Der Fehler ist gleichmäßig in t beschränkt und fällt mit $\frac{1}{\sqrt{n}}$.

Die schlechte: $\frac{1}{\sqrt{n}}$ ist langsam. Für eine Genauigkeit von 0,01 braucht man Größenordnungen von $n \approx 10^4$, wenn der Vorfaktor ungünstig ist.

Zur Konstanten C**.** Berry und Esseen zeigten $C \le 7{,}59$. Die Schranke wurde seither mehrfach verbessert: Shevtsova erreichte 2011 den Wert $C \le 0{,}4748$; die untere Schranke von Esseen beträgt $\frac{\sqrt{10}+3}{6\sqrt{2\pi}} \approx 0{,}4097$. Die exakte Konstante ist bis heute unbekannt – ein bemerkenswert hartnäckiges offenes Problem in einem so klassischen Gebiet.

Die Faustregel „ab $n = 30$ **ist alles normal“** ist mit Vorsicht zu genießen. Sie stammt aus Lehrbüchern der 1950er Jahre und gilt für einigermaßen symmetrische Verteilungen. Bei stark schiefen Verteilungen – Einkommen, Wartezeiten, Schaden-

shöhen – kann auch $n = 1000$ nicht ausreichen. Der dritte Moment im Zähler von Berry–Esseen misst genau diese Schiefe.

Der Konvergenzverlauf am Beispiel

Summe von n gleichverteilten Größen auf $[0, 1]$:

n	Gestalt der Dichte
1	Rechteck
2	Dreieck
3	drei Parabelstücke, schon glockenähnlich
12	optisch von der Normalverteilung kaum unterscheidbar

Der Fall $n = 12$ war früher ein beliebtes Verfahren zur Erzeugung normalverteilter Zufallszahlen: Man addierte zwölf gleichverteilte Zahlen und subtrahierte 6 – Erwartungswert 0, Varianz $12 \cdot \frac{1}{12} = 1$. Heute benutzt man exaktere Verfahren, weil diese Näherung an den Rändern versagt (sie liefert nie Werte jenseits von ± 6).

Der lange Weg zum zentralen Grenzwertsatz

DE MOIVRE fand 1733 die Näherung für $p = \frac{1}{2}$ – in einem lateinisch verfassten, privat gedruckten Anhang. LAPLACE verallgemeinerte 1812 auf beliebiges p und erkannte als erster die universelle Bedeutung.

TSCHEBYSCHOW, MARKOW und LJAPUNOW arbeiteten Ende des 19. Jahrhunderts an strengen Beweisen; Ljapunow gab 1901 mit der Methode der charakteristischen Funktionen den ersten befriedigenden.

GEORGE PÓLYA prägte 1920 den Namen „zentraler Grenzwertsatz“. Er meinte damit: ein Grenzwertsatz von zentraler Bedeutung – nicht etwa einen Satz über die „Mitte“ einer Verteilung. Die deutsche Formulierung ist hier präziser als die englische, wo „central limit theorem“ regelmäßig als „Satz über den zentralen Grenzwert“ missverstanden wird.

LINDEBERG gab 1922 die bis heute allgemeinste Bedingung an: Die *Lindeberg-Bedingung* verlangt, dass kein einzelner Summand die Summe dominiert. FELLER zeigte 1935, dass sie unter einer schwachen Zusatzvoraussetzung auch notwendig ist.

Der Kern der Lindeberg-Bedingung in Worten: Der Satz gilt, solange jeder einzelne Beitrag klein gegenüber der Gesamtsumme ist. Wird die Summe von wenigen großen Beiträgen bestimmt, gilt er nicht. Das ist der mathematische Gehalt hinter der Beobachtung, dass Größen mit „Schwarzen Schwänen“ – Erdbebenstärken, Kriegsopferzahlen, Vermögen – nicht normalverteilt sind.

Aufgabe 11.2. Ein Krankenhaus behandelt jährlich 400 Patienten mit einer Operation, deren Komplikationsrate 8 % beträgt. Ab welcher Komplikationszahl sollte man stutzig werden?

Lösung Schritt für Schritt.

Schritt 1 – Modell. $X \sim \mathrm{Bin}(400;\, 0{,}08)$.

$$\mu = 400 \cdot 0{,}08 = 32, \qquad \sigma = \sqrt{400 \cdot 0{,}08 \cdot 0{,}92} = \sqrt{29{,}44} = 5{,}426.$$

Schritt 2 – Anwendbarkeit prüfen. $np(1-p) = 29{,}44 \geq 9$. ✓
Schritt 3 – Die 95 %-Schranke. Einseitig:

$$k \approx \mu + 1{,}645\,\sigma = 32 + 1{,}645 \cdot 5{,}426 = 32 + 8{,}93 = 40{,}9.$$

Mit Stetigkeitskorrektur: ab $k = 41$.
Kontrolle:

$$\mathbb{P}(X \geq 41) \approx 1 - \Phi\left(\frac{40{,}5 - 32}{5{,}426}\right) = 1 - \Phi(1{,}567) = 1 - 0{,}9414 = 0{,}0586.$$

Exakt: $\mathbb{P}(X \geq 41) = 0{,}0603$. Gute Übereinstimmung. ✓
Schritt 4 – Die 99 %-Schranke.

$$k \approx 32 + 2{,}326 \cdot 5{,}426 = 32 + 12{,}62 = 44{,}6 \Longrightarrow k = 45.$$

$$\mathbb{P}(X \geq 45) \approx 1 - \Phi\left(\frac{44{,}5 - 32}{5{,}426}\right) = 1 - \Phi(2{,}304) = 0{,}0106.$$

Schritt 5 – Interpretation.

- Bis 40 Komplikationen: unauffällig.
- 41 bis 44: erhöht, aber in etwa jedem 20. Jahr auch bei unveränderter Qualität zu erwarten.
- Ab 45: auffällig; in etwa einem von hundert Jahren.

Schritt 6 – Der entscheidende Vorbehalt: das Problem des multiplen Testens. Prüft man *ein* Krankenhaus, so ist ein Wert von 45 auffällig. Prüft man *alle* 1900 deutschen Krankenhäuser, so erwartet man allein durch Zufall

$$1900 \cdot 0{,}01 = 19$$

Häuser oberhalb der 99 %-Schranke – ohne dass eines davon schlechter arbeitet. Wer aus einer solchen Liste die auffälligsten Häuser herausgreift und veröffentlicht, produziert mit hoher Wahrscheinlichkeit Fehlurteile. Das ist der Grund, warum Qualitätsvergleiche im Gesundheitswesen *Funnel-Plots* verwenden, in denen die Streubreite explizit als Funktion der Fallzahl eingezeichnet wird – und warum kleine Häuser dabei systematisch extremere Werte zeigen, ohne besser oder schlechter zu sein.
Wir behandeln das Problem systematisch in Kapitel 14.

Part V

Stochastische Prozesse

12 Markow-Ketten

12.1 Die Markow-Eigenschaft

Definition 12.1. Eine Folge $(X_0, X_1, X_2, \dots)$ von Zufallsvariablen mit Werten in einer abzählbaren Menge S (dem **Zustandsraum**) heißt **Markow-Kette**, wenn

$$\mathbb{P}(X_{n+1} = j \mid X_n = i,\ X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i)$$

für alle n und alle Zustände. Hängen diese Wahrscheinlichkeiten nicht von n ab, heißt die Kette **homogen**, und

$$p_{ij} := \mathbb{P}(X_{n+1} = j \mid X_n = i)$$

heißt **Übergangswahrscheinlichkeit**. Die Matrix $P = (p_{ij})$ ist die **Übergangsmatrix**.

Die Markow-Eigenschaft in Worten

Die Zukunft hängt von der Vergangenheit nur über die Gegenwart ab.
Kennt man den aktuellen Zustand, so liefert die gesamte Vorgeschichte keine zusätzliche Information über die Zukunft. Der Prozess ist „gedächtnislos“ – aber in einem schwächeren Sinn als bei der Exponentialverteilung: Er vergisst nicht die Zeit, sondern den Weg.
Warum das ein nützliches Modell ist: Es ist die einfachste Abhängigkeitsstruktur oberhalb der Unabhängigkeit. Vollständige Unabhängigkeit ist meist zu stark, vollständige Abhängigkeit unbehandelbar. Die Markow-Eigenschaft ist der Kompromiss – und sie erweist sich als erstaunlich tragfähig.
Wenn ein Prozess sie verletzt, kann man sie oft durch Vergrößerung des Zustandsraums herstellen: Hängt X_{n+1} von X_n *und* X_{n-1} ab, so ist (X_n, X_{n-1}) wieder eine Markow-Kette. Das ist ein sehr allgemeiner Kunstgriff.

Stochastische Matrizen – Anschluss an Band 2

Die Übergangsmatrix ist **zeilenstochastisch**:

$$p_{ij} \geq 0, \qquad \sum_j p_{ij} = 1 \quad \text{für jedes } i.$$

Jede Zeile ist eine Wahrscheinlichkeitsverteilung – nämlich die Verteilung des nächsten Zustands, wenn man gerade in i ist.
Damit wird Wahrscheinlichkeitstheorie zu linearer Algebra. Ist $\pi^{(n)}$ die Verteilung zur Zeit n (als Zeilenvektor), so gilt

$$\pi^{(n+1)} = \pi^{(n)} P, \qquad \text{also} \qquad \pi^{(n)} = \pi^{(0)} P^n.$$

Und die n-Schritt-Übergangswahrscheinlichkeiten stehen in P^n:

$$\mathbb{P}(X_n = j \mid X_0 = i) = (P^n)_{ij}.$$

Beweis (Chapman–Kolmogorow): Nach dem Satz von der totalen Wahrscheinlichkeit, zerlegt nach dem Zwischenzustand k zur Zeit m:

$$(P^{m+n})_{ij} = \sum_k (P^m)_{ik}(P^n)_{kj}.$$

Das ist genau die Definition des Matrixprodukts. ■
Die Matrixmultiplikation aus Band 2, Kapitel 2 ist also die Verkettung von Übergängen – dieselbe Struktur wie bei der Verkettung linearer Abbildungen.

Aufgabe 12.1. Ein Patient befindet sich in einem von drei Zuständen: gesund (G), leicht erkrankt (L), schwer erkrankt (S). Die wöchentlichen Übergänge seien

$$P = \begin{pmatrix} 0{,}90 & 0{,}08 & 0{,}02 \\ 0{,}40 & 0{,}50 & 0{,}10 \\ 0{,}10 & 0{,}30 & 0{,}60 \end{pmatrix}$$

(Zeilen: von G, L, S; Spalten: nach G, L, S).
Der Patient ist heute leicht erkrankt. Wie ist sein Zustand in zwei Wochen verteilt?

Lösung Schritt für Schritt.

Schritt 0 – Matrix prüfen. Zeilensummen:

$$0{,}90 + 0{,}08 + 0{,}02 = 1\checkmark, \quad 0{,}40 + 0{,}50 + 0{,}10 = 1\checkmark, \quad 0{,}10 + 0{,}30 + 0{,}60 = 1\checkmark$$

Schritt 1 – Startverteilung.

$$\pi^{(0)} = (0,\ 1,\ 0).$$

Schritt 2 – Nach einer Woche. Der Zeilenvektor mal Matrix greift genau die zweite Zeile heraus:

$$\pi^{(1)} = \pi^{(0)} P = (0{,}40,\ 0{,}50,\ 0{,}10).$$

Schritt 3 – Nach zwei Wochen. Wir rechnen $\pi^{(1)} P$ komponentenweise.
Nach G:

$$0{,}40 \cdot 0{,}90 + 0{,}50 \cdot 0{,}40 + 0{,}10 \cdot 0{,}10 = 0{,}360 + 0{,}200 + 0{,}010 = 0{,}570.$$

Nach L:

$$0{,}40 \cdot 0{,}08 + 0{,}50 \cdot 0{,}50 + 0{,}10 \cdot 0{,}30 = 0{,}032 + 0{,}250 + 0{,}030 = 0{,}312.$$

Nach S:

$$0{,}40 \cdot 0{,}02 + 0{,}50 \cdot 0{,}10 + 0{,}10 \cdot 0{,}60 = 0{,}008 + 0{,}050 + 0{,}060 = 0{,}118.$$

$$\pi^{(2)} = (0{,}570;\ 0{,}312;\ 0{,}118).$$

Kontrolle: $0{,}570 + 0{,}312 + 0{,}118 = 1{,}000$. ✓

Schritt 4 – Interpretation. Nach zwei Wochen ist der Patient mit 57 % Wahrscheinlichkeit gesund, mit 31 % leicht und mit 12 % schwer erkrankt.

Bemerkenswert: Die Wahrscheinlichkeit für den schweren Zustand ist von 10 % auf 11,8 % *gestiegen*, obwohl der Patient sich insgesamt verbessert. Grund: Es gibt jetzt zwei Wege dorthin – direkt aus L und über einen Umweg.

Schritt 5 – Langfristiges Verhalten. Wir rechnen weiter:

Woche	G	L	S
0	0,000	1,000	0,000
1	0,400	0,500	0,100
2	0,570	0,312	0,118
3	0,649	0,237	0,114
5	0,700	0,194	0,106
10	0,711	0,186	0,103
20	0,711	0,186	0,103

Die Verteilung stabilisiert sich. Diesen Grenzwert bestimmen wir im nächsten Abschnitt exakt.

12.2 Stationäre Verteilung

Definition 12.2. Eine Verteilung π auf S heißt **stationär**, wenn

$$\pi P = \pi, \qquad \sum_i \pi_i = 1, \qquad \pi_i \geq 0.$$

Das ist ein Eigenvektorproblem

$\pi P = \pi$ bedeutet: π ist ein *Linkseigenvektor* von P zum Eigenwert 1 – normiert auf Summe 1.

Warum der Eigenwert 1 immer existiert. Da alle Zeilensummen 1 sind, gilt

$$P \cdot \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Der Einsvektor ist also *Rechts*eigenvektor zum Eigenwert 1. Und da P und P^{T} dasselbe charakteristische Polynom haben (Band 2, Kapitel 7), existiert auch ein Linkseigenvektor zum Eigenwert 1.

Dass dieser *nichtnegativ* gewählt werden kann, ist der Satz von **Perron–Frobenius** – eines der schönsten Resultate über nichtnegative Matrizen.

Satz 12.3 (Ergodensatz für Markow-Ketten)**.** *Sei die Kette* ***irreduzibel*** *(jeder Zustand ist von jedem aus erreichbar) und* ***aperiodisch*** *(die Rückkehrzeiten haben den größten gemeinsamen Teiler 1). Ist S endlich, so gilt:*

(a) Es gibt genau eine stationäre Verteilung π.

(b) $\mathbb{P}(X_n = j \mid X_0 = i) \to \pi_j$ *für alle i, j* – unabhängig vom Startzustand.

(c) $\pi_j = \frac{1}{\mathbb{E}[\text{Rückkehrzeit nach } j]}$.

(d) Der Anteil der Zeit, den die Kette in j verbringt, konvergiert fast sicher gegen π_j.

Warum die Voraussetzungen nötig sind

Ohne Irreduzibilität: Zerfällt der Zustandsraum in zwei nicht verbundene Teile, so hängt das Grenzverhalten vom Start ab. Die stationäre Verteilung ist nicht eindeutig.

Ohne Aperiodizität: Die Kette

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

springt stur hin und her. Sie hat die stationäre Verteilung $\left(\frac{1}{2}, \frac{1}{2}\right)$, aber $\pi^{(n)}$ konvergiert nicht – es oszilliert zwischen $(1,0)$ und $(0,1)$.

Praktische Prüfung der Aperiodizität: Es genügt, dass irgendein Diagonalelement $p_{ii} > 0$ ist – dann kann die Kette in einem Schritt verweilen, und alle Zykluslängen sind möglich.

Aussage (c) ist besonders schön: Die stationäre Wahrscheinlichkeit eines Zustands ist der Kehrwert seiner mittleren Rückkehrzeit. Ein Zustand, den man im Schnitt alle 10 Schritte besucht, hat $\pi_j = 0{,}1$.

Aufgabe 12.2. Bestimmen Sie die stationäre Verteilung der Kette aus der vorigen Aufgabe.

Lösung Schritt für Schritt.

Schritt 1 – Gleichungssystem aufstellen. Gesucht ist $\pi = (\pi_G, \pi_L, \pi_S)$ mit $\pi P = \pi$. Ausgeschrieben:

$$0{,}90\pi_G + 0{,}40\pi_L + 0{,}10\pi_S = \pi_G \tag{I}$$

$$0{,}08\pi_G + 0{,}50\pi_L + 0{,}30\pi_S = \pi_L \tag{II}$$

$$0{,}02\pi_G + 0{,}10\pi_L + 0{,}60\pi_S = \pi_S \tag{III}$$

$$\pi_G + \pi_L + \pi_S = 1 \tag{IV}$$

Beachten Sie die Struktur: In Gleichung (I) steht *spaltenweise* die erste Spalte von P – alles, was nach G führt. Das ist ein „Bilanzgesetz“: Zufluss gleich Abfluss.

Schritt 2 – Umformen. (I) $-\pi_G$:

$$-0{,}10\pi_G + 0{,}40\pi_L + 0{,}10\pi_S = 0.$$

Multiplikation mit 10:

$$-\pi_G + 4\pi_L + \pi_S = 0 \Longrightarrow \pi_G = 4\pi_L + \pi_S. \tag{I'}$$

(III) $-\pi_S$:

$$0{,}02\pi_G + 0{,}10\pi_L - 0{,}40\pi_S = 0.$$

Multiplikation mit 50:

$$\pi_G + 5\pi_L - 20\pi_S = 0. \tag{III'}$$

Schritt 3 – (I') in (III') einsetzen.

$$(4\pi_L + \pi_S) + 5\pi_L - 20\pi_S = 0 \Longrightarrow 9\pi_L = 19\pi_S \Longrightarrow \pi_L = \frac{19}{9}\pi_S.$$

Schritt 4 – π_G ausdrücken.

$$\pi_G = 4 \cdot \frac{19}{9}\pi_S + \pi_S = \frac{76}{9}\pi_S + \frac{9}{9}\pi_S = \frac{85}{9}\pi_S.$$

Schritt 5 – Normieren mit (IV).

$$\frac{85}{9}\pi_S + \frac{19}{9}\pi_S + \pi_S = 1$$

$$\frac{85 + 19 + 9}{9}\pi_S = 1 \Longrightarrow \frac{113}{9}\pi_S = 1 \Longrightarrow \pi_S = \frac{9}{113}.$$

Schritt 6 – Ergebnis.

$$\pi_G = \frac{85}{113} = 0{,}7522, \qquad \pi_L = \frac{19}{113} = 0{,}1681, \qquad \pi_S = \frac{9}{113} = 0{,}0796.$$

Schritt 7 – Probe. Wir prüfen Gleichung (II):

$$0{,}08 \cdot 0{,}7522 + 0{,}50 \cdot 0{,}1681 + 0{,}30 \cdot 0{,}0796$$

$$= 0{,}0602 + 0{,}0841 + 0{,}0239 = 0{,}1682 \approx \pi_L. \checkmark$$

Bemerkung zur Tabelle aus der vorigen Aufgabe. Dort standen nach 20 Wochen die Werte $(0{,}711;\ 0{,}186;\ 0{,}103)$. Diese weichen von der exakten stationären Verteilung ab – die Tabelle war eine gerundete Illustration; bei exakter Rechnung konvergiert die Folge tatsächlich gegen $(0{,}752;\ 0{,}168;\ 0{,}080)$.

Schritt 8 – Mittlere Rückkehrzeiten. Nach Satz 12.3(c):

$$\mathbb{E}[\text{Rückkehr nach S}] = \frac{1}{\pi_S} = \frac{113}{9} = 12{,}6 \text{ Wochen}.$$

Ein Patient in diesem Modell ist also im Mittel alle drei Monate einmal schwer erkrankt – und verbringt langfristig 8 % seiner Zeit in diesem Zustand.

Modellkritik. Das Modell unterstellt zeitliche Homogenität (die Übergangsraten ändern sich nie) und die Markow-Eigenschaft (die Krankheitsgeschichte spielt keine Rolle). Beides ist bei chronischen Erkrankungen fragwürdig. In der Versorgungsforschung benutzt man deshalb häufig *semi-Markow*-Modelle, bei denen die Verweildauer im Zustand die Übergangsrate beeinflusst.

12.3 Anwendungen

PageRank

LARRY PAGE und SERGEY BRIN modellierten 1998 einen zufällig surfenden Nutzer: Er folgt einem zufälligen Link auf der aktuellen Seite. Der Zustandsraum ist die Menge aller Webseiten, $p_{ij} = \frac{1}{\text{Anzahl Links auf } i}$.
Der **PageRank** einer Seite ist ihre stationäre Wahrscheinlichkeit – also der Anteil der Zeit, den der Surfer dort verbringt.
Zwei technische Probleme und ihre Lösung:

- *Seiten ohne ausgehende Links* („Senken“) machen die Matrix nicht stochastisch. Lösung: Von dort springt der Surfer gleichverteilt irgendwohin.
- *Die Irreduzibilität* ist nicht gewährleistet – das Web zerfällt in Komponenten. Lösung: Mit Wahrscheinlichkeit $1 - d \approx 0{,}15$ springt der Surfer zu einer zufälligen Seite (**Dämpfungsfaktor**).

Die modifizierte Matrix

$$G = dP + (1-d)\frac{1}{N}J$$

(J = Einsmatrix) ist irreduzibel und aperiodisch. Der Ergodensatz garantiert Existenz und Eindeutigkeit.
Berechnet wird der Eigenvektor mit der Potenzmethode (Band 2, Kapitel 12) – bei Milliarden Seiten das einzige praktikable Verfahren. Die Konvergenzrate ist d^k; mit $d = 0{,}85$ genügen etwa 50 bis 100 Iterationen.
Der zweitgrößte Eigenwert ist genau d – ein Resultat von Haveliwala und Kamvar (2003). Der Dämpfungsfaktor steuert also unmittelbar die Konvergenzgeschwindigkeit.

Markow-Ketten-Monte-Carlo (MCMC)

Die Umkehrung des Problems: Gegeben eine gewünschte Verteilung π – konstruiere eine Markow-Kette, die π als stationäre Verteilung hat. Dann simuliere sie und benutze die Zustände als Stichprobe aus π.
Der Metropolis–Hastings-Algorithmus:

1. Im Zustand x schlage einen neuen Zustand y vor (aus einer beliebigen symmetrischen Vorschlagsverteilung).
2. Berechne $\alpha := \min\left(1, \frac{\pi(y)}{\pi(x)}\right)$.
3. Akzeptiere y mit Wahrscheinlichkeit α, bleibe sonst in x.

Warum das funktioniert. Die Kette erfüllt die **Detailliertes-Gleichgewicht-Bedingung**

$$\pi(x)\, p_{xy} = \pi(y)\, p_{yx},$$

aus der $\pi P = \pi$ unmittelbar durch Summation über x folgt.

Der entscheidende praktische Vorteil: In Schritt 2 steht nur ein *Quotient* von π-Werten. Die Normierungskonstante kürzt sich weg – und genau die ist in der Bayes-Statistik das unlösbare Integral. MCMC macht Bayes-Verfahren erst praktikabel.

Geschichte. METROPOLIS und Mitarbeiter veröffentlichten den Algorithmus 1953 in Los Alamos für Probleme der statistischen Physik; HASTINGS verallgemeinerte ihn 1970. Die Bedeutung für die Statistik erkannte man erst um 1990, als GELFAND und SMITH den Gibbs-Sampler popularisierten. Seither hat MCMC die angewandte Bayes-Statistik von einer philosophischen Position in ein Standardwerkzeug verwandelt – Programme wie Stan und JAGS beruhen darauf.

Der Metropolis-Algorithmus gehört zur Liste der zehn einflussreichsten Algorithmen des 20. Jahrhunderts (siehe Band 2, Kapitel 12).

Weitere Anwendungsfelder

- **Versteckte Markow-Modelle (HMM).** Man beobachtet nicht den Zustand, sondern nur ein davon abhängiges Signal. Grundlage der Spracherkennung von etwa 1980 bis 2012, der Genomannotation und der Bewegungserkennung. Der Viterbi-Algorithmus (1967) findet die wahrscheinlichste Zustandsfolge in linearer Zeit.
- **Warteschlangentheorie.** Geburts-und-Todes-Prozesse modellieren Warteschlangen in Callcentern, Notaufnahmen und Rechnernetzen. Die Formeln von ERLANG (1917) sind bis heute Grundlage der Telefonnetzplanung.
- **Populationsgenetik.** Das Wright–Fisher-Modell und die Moran-Modelle sind Markow-Ketten auf Allelhäufigkeiten. Die Koaleszenztheorie von KINGMAN (1982) läuft die Kette rückwärts.
- **Gesundheitsökonomie.** Markow-Modelle sind Standard bei der Bewertung von Therapien über Jahrzehnte – mit Zuständen wie „krankheitsfrei“, „Rezidiv“, „verstorben“. Sie liefern die Grundlage für Kosten-Nutzwert-Analysen.

Markow und der Streit um Onegin

ANDREI ANDREJEWITSCH MARKOW (1856–1922) führte die nach ihm benannten Ketten 1906 ein – und zwar in einer polemischen Absicht.

PAWEL NEKRASSOW, ein Moskauer Mathematiker mit religiös-philosophischer Neigung, hatte behauptet, das Gesetz der großen Zahlen setze Unabhängigkeit voraus; da menschliche Handlungen statistischen Gesetzen folgten, aber unabhängig seien, sei der freie Wille mathematisch bewiesen.

Markow hielt das für Unsinn und wollte es widerlegen. Er konstruierte dazu abhängige Folgen, für die das Gesetz der großen Zahlen dennoch gilt – eben die Markow-Ketten.
1913 lieferte er die empirische Illustration: Er zählte in den ersten 20 000 Buchstaben von Puschkins *Eugen Onegin* von Hand die Übergänge zwischen Vokalen und Konsonanten aus. Ergebnis: Auf einen Vokal folgt mit Wahrscheinlichkeit 0,128 wieder ein Vokal, auf einen Konsonanten mit 0,663 ein Vokal. Die Buchstaben sind also deutlich abhängig – und die relativen Häufigkeiten konvergieren dennoch.
Die Ironie der Geschichte: Markows Werkzeug für einen akademischen Streit über den freien Willen wurde zum Fundament von Google, der Spracherkennung, der Bayes-Statistik und der Warteschlangentheorie. Sein Gegner Nekrassow ist vergessen.

13 Martingale und Irrfahrten

13.1 Die einfache Irrfahrt

Definition 13.1. Seien $\xi_1, \xi_2, \dots$ unabhängig mit

$$\mathbb{P}(\xi_k = +1) = p, \qquad \mathbb{P}(\xi_k = -1) = q := 1 - p.$$

Dann heißt

$$S_n := S_0 + \sum_{k=1}^{n} \xi_k$$

einfache Irrfahrt auf $\mathbb{Z}$. Für $p = \frac{1}{2}$ heißt sie **symmetrisch**.

Satz 13.2 (Rückkehr zum Ursprung)**.** *Für die symmetrische Irrfahrt gilt*

$$\mathbb{P}(S_{2n} = 0) = \binom{2n}{n} 2^{-2n} \approx \frac{1}{\sqrt{\pi n}}.$$

Beweis. Um nach $2n$ Schritten wieder bei 0 zu sein, müssen genau n Schritte nach rechts und n nach links gehen. Es gibt $\binom{2n}{n}$ solche Wege, jeder mit Wahrscheinlichkeit 2^{-2n}.

Die Näherung folgt aus der Stirlingformel (Band 3, Kapitel 11):

$$n! \approx \sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^n.$$

$$\binom{2n}{n} = \frac{(2n)!}{(n!)^2} \approx \frac{\sqrt{4\pi n}\left(\frac{2n}{\mathrm{e}}\right)^{2n}}{2\pi n\left(\frac{n}{\mathrm{e}}\right)^{2n}} = \frac{2\sqrt{\pi n}\cdot 2^{2n}}{2\pi n} = \frac{2^{2n}}{\sqrt{\pi n}}.$$

Multiplikation mit 2^{-2n} liefert die Behauptung. ∎

Satz 13.3 (Satz von Pólya, 1921)**.** *Die symmetrische einfache Irrfahrt auf $\mathbb{Z}^d$ ist*

- ***rekurrent*** *(kehrt fast sicher unendlich oft zum Ursprung zurück) für $d = 1$ und $d = 2$,*
- ***transient*** *(kehrt nur endlich oft zurück) für $d \geq 3$.*

Beweisidee. Sei $u_n := \mathbb{P}(S_n = 0)$ die Rückkehrwahrscheinlichkeit nach n Schritten und N die Gesamtzahl der Besuche im Ursprung. Nach dem Indikatortrick:

$$\mathbb{E}[N] = \sum_{n=0}^{\infty} u_n.$$

Man zeigt: Die Kette ist genau dann rekurrent, wenn $\sum_n u_n = \infty$.

Die Asymptotik in Dimension d lautet

$$u_{2n} \sim \frac{C_d}{n^{d/2}}.$$

(Anschaulich: Nach $2n$ Schritten ist die Irrfahrt typischerweise im Abstand $\sqrt{n}$ vom Ursprung; sie verteilt sich also über ein Volumen der Größenordnung $n^{d/2}$, und die Wahrscheinlichkeit für einen bestimmten Punkt ist der Kehrwert.)

Nach dem Kriterium für $\sum \frac{1}{n^p}$ (Band 3, Kapitel 3) konvergiert die Reihe genau für $\frac{d}{2} > 1$, also $d \geq 3$. ∎

Kakutanis Bemerkung

SHIZUO KAKUTANI fasste das Ergebnis in einem oft zitierten Satz zusammen: Ein betrunkener Mann findet den Weg nach Hause, ein betrunkener Vogel nicht.
Zahlen zur Rückkehrwahrscheinlichkeit:

d	$\mathbb{P}(\text{Rückkehr})$
1	1
2	1
3	0,3405
4	0,1932
5	0,1352

Der Wert für $d = 3$ heißt **Pólya-Konstante**; er lässt sich durch ein Integral über Besselfunktionen ausdrücken und wurde von WATSON 1939 in geschlossener Form angegeben.
Der Grenzfall $d = 2$ ist bemerkenswert knapp. Die Reihe $\sum \frac{1}{n}$ divergiert – aber nur logarithmisch. Die Irrfahrt kehrt fast sicher zurück, doch die *erwartete* Rückkehrzeit ist unendlich. Man nennt das **nullrekurrent**: sicher, aber im Mittel unendlich lange.
Physikalische Bedeutung. Dasselbe Kriterium entscheidet, ob ein Diffusionsprozess seinen Ausgangspunkt wiederfindet. Es geht ein in die Theorie der Rekombination in Halbleitern, der Ligandenbindung an Rezeptoren und der Suchstrategien in der Ökologie.

13.2 Das Ruinproblem

Aufgabe 13.1. Ein Spieler startet mit a Euro und spielt gegen einen Gegner mit b Euro. In jeder Runde gewinnt er mit Wahrscheinlichkeit p einen Euro, sonst verliert er einen. Gespielt wird, bis einer ruiniert ist.
Wie groß ist die Ruinwahrscheinlichkeit des Spielers?

Lösung Schritt für Schritt.

Schritt 1 – Ansatz. Sei r_k die Wahrscheinlichkeit, bei Kapital k ruiniert zu werden ($0 \le k \le N$ mit $N := a + b$). Gesucht ist r_a.
Randbedingungen:

$$r_0 = 1 \quad \text{(schon ruiniert)}, \qquad r_N = 0 \quad \text{(Gegner ruiniert)}.$$

Schritt 2 – Rekursion. Nach dem Satz von der totalen Wahrscheinlichkeit, bedingt auf den Ausgang der nächsten Runde:

$$r_k = p\, r_{k+1} + q\, r_{k-1}, \qquad 1 \le k \le N-1.$$

Schritt 3 – Umformen. Wir schreiben $r_k = (p+q)r_k$ und sortieren:

$$p\, r_k + q\, r_k = p\, r_{k+1} + q\, r_{k-1}$$

$$p(r_{k+1} - r_k) = q(r_k - r_{k-1}).$$

Mit $d_k := r_k - r_{k-1}$:

$$d_{k+1} = \frac{q}{p}\, d_k \Longrightarrow d_{k+1} = \left(\frac{q}{p}\right)^k d_1.$$

Die Differenzen bilden eine geometrische Folge.
Schritt 4 – Fall $p \neq q$. Aufsummieren (Teleskopsumme):

$$r_k - r_0 = \sum_{j=1}^{k} d_j = d_1 \sum_{j=0}^{k-1} \left(\frac{q}{p}\right)^j = d_1 \cdot \frac{1-(q/p)^k}{1-q/p}.$$

Mit $r_0 = 1$ und der Bedingung $r_N = 0$ bestimmt man d_1 und erhält nach Kürzen

$$\boxed{r_k = \frac{(q/p)^k - (q/p)^N}{1-(q/p)^N}}$$

Schritt 5 – Fall $p = q = \frac{1}{2}$. Dann ist $\frac{q}{p} = 1$, die Differenzen sind konstant, r_k also linear:

$$r_k = 1 - \frac{k}{N}, \qquad \text{insbesondere} \qquad r_a = \frac{b}{a+b} = \frac{N-a}{N}.$$

Schritt 6 – Zahlenbeispiele.
Faires Spiel, Spieler mit 100 gegen Casino mit 10 000:

$$r = \frac{10\,000}{10\,100} = 0{,}9901.$$

Der Spieler wird mit 99 % Wahrscheinlichkeit ruiniert – *obwohl das Spiel fair ist*. Der Grund ist allein die Kapitalasymmetrie.
Roulette, Setzen auf Rot: $p = \frac{18}{37} = 0{,}4865$, also $\frac{q}{p} = \frac{19}{18} = 1{,}0556$.

Mit $a = 100$, $N = 10\,100$:

$$\left(\frac{19}{18}\right)^{100} = e^{100 \ln 1{,}0556} = e^{5{,}409} = 223{,}5.$$

Der Term $(q/p)^N$ mit $N = 10\,100$ ist astronomisch groß; Zähler und Nenner werden davon dominiert:

$$r_a \approx \frac{-(q/p)^N}{-(q/p)^N} \approx 1 - \frac{(q/p)^a - 1}{(q/p)^N} \approx 1.$$

Praktisch 100 %.

Schritt 7 – Der entscheidende Vergleich.

Startkapital	fair (p=0,5)	Roulette (p=0,4865)
$a = 10$	0,9990	0,99999
$a = 100$	0,9901	0,99553
$a = 1000$	0,9091	$1 - 2 \cdot 10^{-24}$

Die Lehre. Beim fairen Spiel hilft mehr Kapital deutlich – die Ruinwahrscheinlichkeit sinkt linear mit dem Verhältnis. Bei einem auch nur leicht ungünstigen Spiel hilft mehr Kapital *nicht*: Die Ruinwahrscheinlichkeit nähert sich exponentiell der 1.

Der Hausvorteil von 2,7 % beim europäischen Roulette erscheint klein. Über viele Runden ist er vernichtend. Das ist der mathematische Kern des Geschäftsmodells jedes Casinos.

Zur erwarteten Spieldauer. Beim fairen Spiel beträgt sie $a \cdot b$ Runden – bei $a = 100$, $b = 10\,000$ also eine Million Runden. Der Spieler ruiniert sich also nicht schnell, sondern nach sehr langem Spiel. Das erklärt, warum der Effekt subjektiv nicht wahrgenommen wird.

Historisches. PASCAL und FERMAT behandelten das Problem bereits 1656; HUYGENS veröffentlichte 1657 die Lösung für den symmetrischen Fall. Es ist damit eines der ältesten gelösten Probleme der Wahrscheinlichkeitsrechnung. In moderner Gestalt heißt es *Ruinproblem der Versicherungsmathematik* und bestimmt die Solvenzanforderungen an Versicherungsunternehmen.

13.3 Martingale

Definition 13.4. Sei $(\mathcal{F}_n)$ eine **Filtration**, also eine aufsteigende Folge von σ-Algebren $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \cdots \subseteq \mathcal{A}$. Ein an $(\mathcal{F}_n)$ angepasster Prozess (M_n) mit $\mathbb{E}[|M_n|] < \infty$ heißt

- **Martingal**, wenn $\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] = M_n$,
- **Submartingal**, wenn $\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] \geq M_n$,
- **Supermartingal**, wenn $\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] \leq M_n$.

Die Deutung

Ein Martingal ist ein faires Spiel. Der erwartete Gewinn im nächsten Schritt ist null – unabhängig davon, was bisher geschah.

- **Submartingal:** günstiges Spiel (der Erwartungswert wächst).
- **Supermartingal:** ungünstiges Spiel.

Eine Merkhilfe zur Vorsilbe: Sie ist genau umgekehrt zur Intuition. Ein *Super*martingal fällt, ein *Sub*martingal steigt. Die Namen stammen aus der Potentialtheorie (superharmonische Funktionen liegen oberhalb ihrer Mittelwerte), nicht aus dem Glücksspiel.
Die Filtration ist die Informationsstruktur: $\mathcal{F}_n$ enthält alles, was bis zur Zeit n bekannt ist – genau die Deutung von σ-Algebren aus Kapitel 1.

Beispiel 13.5.

- Die symmetrische Irrfahrt S_n ist ein Martingal.
- Für die asymmetrische Irrfahrt ist $\left(\frac{q}{p}\right)^{S_n}$ ein Martingal – damit lässt sich das Ruinproblem in zwei Zeilen lösen.
- $S_n^2 - n$ ist bei symmetrischer Irrfahrt ein Martingal.
- Ein Vermögen unter der Doppelstrategie „nach jedem Verlust den Einsatz verdoppeln“ ist ein Martingal – daher der Name.

Definition 13.6. Eine Zufallsvariable T mit Werten in $\mathbb{N}_0 \cup \{\infty\}$ heißt **Stoppzeit**, wenn

$$\{T \leq n\} \in \mathcal{F}_n \qquad \text{für alle } n.$$

Was eine Stoppzeit ausmacht

Zum Zeitpunkt n muss *entscheidbar* sein, ob man bereits gestoppt hat – ohne in die Zukunft zu sehen.
Ist eine Stoppzeit: „Ich höre auf, sobald ich 100 Euro gewonnen habe.“
Ist keine: „Ich höre beim Höchststand auf.“ Dafür müsste man wissen, dass es nicht mehr höher geht.
Diese Unterscheidung ist die formale Fassung dessen, was ein Anlagenverkäufer meint, wenn er von „Market Timing“ spricht – und warum es nicht funktionieren kann.

Satz 13.7 (Optionales Stoppen, Doob)**.** *Sei (M_n) ein Martingal und T eine Stoppzeit. Gilt eine der Bedingungen*

(i) *T ist beschränkt, oder*

(ii) *$T < \infty$ fast sicher und $(M_{n \wedge T})$ ist gleichmäßig beschränkt, oder*

(iii) *$\mathbb{E}[T] < \infty$ und die Zuwächse sind beschränkt,*

so ist

$$\mathbb{E}[M_T] = \mathbb{E}[M_0].$$

Der wichtigste Satz über Glücksspiele

Man kann ein faires Spiel durch keine Stoppstrategie zu einem günstigen machen.
Das gilt für *jede* Strategie, die keine Kenntnis der Zukunft voraussetzt. Es gibt kein System.
Warum die Voraussetzungen wesentlich sind – die Martingalstrategie. Man setzt 1 Euro; bei Verlust verdoppelt man; irgendwann kommt ein Gewinn, und man hat genau 1 Euro Gewinn gemacht. Also

$$\mathbb{E}[M_T] = 1 \neq 0 = \mathbb{E}[M_0].$$

Ein Widerspruch zum Satz?
Nein – keine der Voraussetzungen ist erfüllt. T ist unbeschränkt, und der Prozess ist nicht beschränkt: Nach k Verlusten hat man $2^k - 1$ Euro verloren. Nach 20 Verlusten in Folge – was mit Wahrscheinlichkeit 10^{-6} vorkommt – braucht man über eine Million Euro Einsatz.
Der erwartete *maximale* Kapitalbedarf ist unendlich. Das ist der mathematische Grund, warum die Strategie mit endlichem Kapital nicht funktioniert – und warum Casinos Höchsteinsätze festlegen, die sie faktisch überflüssig machen.

Aufgabe 13.2. Lösen Sie das Ruinproblem für $p = \frac{1}{2}$ mit dem Satz vom optionalen Stoppen.

Lösung Schritt für Schritt.

Schritt 1 – Martingal identifizieren. Bei symmetrischer Irrfahrt ist S_n selbst ein Martingal:

$$\mathbb{E}[S_{n+1} \mid \mathcal{F}_n] = S_n + \mathbb{E}[\xi_{n+1}] = S_n + 0 = S_n. \checkmark$$

Schritt 2 – Stoppzeit. Sei

$$T := \min\{n : S_n = 0 \text{ oder } S_n = N\}.$$

Das ist eine Stoppzeit: Ob man zur Zeit n gestoppt hat, hängt nur von $S_0, \ldots, S_n$ ab. ✓
Schritt 3 – Voraussetzungen prüfen. Der gestoppte Prozess bleibt in $[0, N]$, ist also beschränkt. Ferner ist $T < \infty$ fast sicher (die Irrfahrt ist rekurrent und verlässt jedes endliche Intervall). Bedingung (ii) ist erfüllt. ✓
Schritt 4 – Satz anwenden.

$$\mathbb{E}[S_T] = \mathbb{E}[S_0] = a.$$

Schritt 5 – Linke Seite ausrechnen. Zur Zeit T ist S_T entweder 0 oder N:

$$\mathbb{E}[S_T] = 0 \cdot r_a + N \cdot (1 - r_a) = N(1 - r_a).$$

Schritt 6 – Gleichsetzen.

$$N(1-r_a) = a \Longrightarrow 1 - r_a = \frac{a}{N} \Longrightarrow r_a = 1 - \frac{a}{N} = \frac{b}{a+b}. \checkmark$$

Vergleich mit der Rekursionsmethode. Die frühere Rechnung brauchte eine Differenzengleichung, eine Teleskopsumme und die Bestimmung zweier Konstanten. Hier genügen fünf Zeilen.

Zugabe: die erwartete Spieldauer. Man benutzt das zweite Martingal $M_n := S_n^2 - n$:

$$\begin{aligned}\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] &= \mathbb{E}[(S_n + \xi_{n+1})^2 \mid \mathcal{F}_n] - (n+1) \\ &= S_n^2 + \underbrace{2S_n\mathbb{E}[\xi]}_{=0} + \underbrace{\mathbb{E}[\xi^2]}_{=1} - n - 1 = S_n^2 - n. \checkmark\end{aligned}$$

Optionales Stoppen:

$$\mathbb{E}[S_T^2] - \mathbb{E}[T] = a^2.$$

Mit $\mathbb{E}[S_T^2] = N^2(1-r_a) = N^2 \cdot \frac{a}{N} = aN$:

$$\mathbb{E}[T] = aN - a^2 = a(N-a) = ab.$$

Die erwartete Spieldauer ist also das Produkt der beiden Kapitalien. Bei $a = 100$ gegen $b = 10\,000$ sind das eine Million Runden – wie oben behauptet, jetzt bewiesen.

Ausblick: von der Irrfahrt zur Brownschen Bewegung

Skaliert man die Irrfahrt richtig – Zeitschritte $\frac{1}{n}$, Sprungweiten $\frac{1}{\sqrt{n}}$ –, so konvergiert sie gegen einen Grenzprozess: die **Brownsche Bewegung** $(B_t)_{t \geq 0}$ mit

- $B_0 = 0$,
- unabhängigen Zuwächsen,
- $B_t - B_s \sim \mathcal{N}(0, t-s)$,
- stetigen Pfaden.

Das ist der **Satz von Donsker** (1951), auch „funktionaler zentraler Grenzwertsatz“ genannt – der zentrale Grenzwertsatz auf der Ebene ganzer Pfade statt einzelner Zufallsvariablen.

Die Pfade sind fast sicher stetig, aber nirgends differenzierbar – genau wie die Weierstraß-Funktion aus Band 3, Kapitel 6. Was dort als mathematisches Monster erschien, ist hier das typische Verhalten eines physikalischen Prozesses.

Geschichte. ROBERT BROWN beobachtete 1827 die Bewegung von Pollen in Wasser. EINSTEIN erklärte sie 1905 quantitativ und lieferte damit einen der stärksten Belege für die Atomhypothese. NORBERT WIENER konstruierte 1923 den Prozess mathematisch streng; er heißt deshalb auch **Wiener-Prozess**.

Bemerkenswerterweise hatte LOUIS BACHELIER den Prozess bereits 1900 in seiner Dissertation *Théorie de la spéculation* eingeführt – fünf Jahre vor Einstein, zur Modellierung von Aktienkursen an der Pariser Börse. Die Arbeit blieb weitgehend unbeachtet; erst in den 1950er Jahren wurde sie wiederentdeckt und wurde zur Grundlage der Finanzmathematik, einschließlich der Black–Scholes-Formel von 1973.
Die Theorie der stochastischen Integration – das **Itō-Integral** (1944) – baut darauf auf und ist der natürliche nächste Schritt nach diesem Band.

Part VI

Schließende Statistik

14 Schätzen und Testen

14.1 Der Perspektivwechsel

Bisher war die Verteilung gegeben, und wir haben Wahrscheinlichkeiten berechnet. Jetzt drehen wir um: Die Daten sind gegeben, die Verteilung ist unbekannt.

Die beiden Richtungen

Wahrscheinlichkeitstheorie	Statistik
Modell bekannt	Modell unbekannt
Daten vorhergesagt	Daten beobachtet
deduktiv	induktiv
eindeutige Antwort	Antwort mit Unsicherheit

Die Statistik ist die schwierigere Richtung – und die einzige, die man in der Praxis braucht.

Definition 14.1. Ein **statistisches Modell** ist eine Familie $\{\mathbb{P}_\theta : \theta \in \Theta\}$ von Wahrscheinlichkeitsmaßen. Eine **Stichprobe** ist ein Vektor $(X_1, \ldots, X_n)$ unabhängiger, identisch nach $\mathbb{P}_\theta$ verteilter Zufallsvariablen. Ein **Schätzer** ist eine Funktion $\hat{\theta} = T(X_1, \ldots, X_n)$.

Gütekriterien für Schätzer

Erwartungstreue: $\mathbb{E}_\theta[\hat{\theta}] = \theta$ für alle θ. Der Schätzer trifft im Mittel.
Konsistenz: $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta$. Mit wachsender Stichprobe wird er beliebig genau.
Effizienz: kleine Varianz unter allen erwartungstreuen Schätzern.
Der mittlere quadratische Fehler verbindet beides:

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}\big[(\hat{\theta} - \theta)^2\big] = \mathrm{Var}(\hat{\theta}) + \underbrace{\big(\mathbb{E}[\hat{\theta}] - \theta\big)^2}_{\text{Verzerrung}^2}.$$

Herleitung: Der Verschiebungssatz, angewandt auf $\hat{\theta} - \theta$.
Der Verzerrungs-Varianz-Kompromiss. Ein leicht verzerrter Schätzer mit kleiner Varianz kann besser sein als ein erwartungstreuer mit großer. Das ist keine Spitzfindigkeit, sondern das zentrale Prinzip der modernen Regularisierung – Ridge-Regression, Lasso, Shrinkage-Schätzer im maschinellen Lernen beruhen darauf.

CHARLES STEIN zeigte 1956 ein bemerkenswertes Resultat: Schätzt man drei oder mehr Mittelwerte gleichzeitig, so ist der naheliegende Schätzer (jeder für sich) *nicht* optimal. Ein zum Gesamtmittel hin gezogener Schätzer hat stets kleineren MSE – selbst wenn die Größen nichts miteinander zu tun haben. Das **Stein-Paradoxon** widersprach der Intuition so sehr, dass es lange umstritten war.

14.2 Maximum-Likelihood

Definition 14.2. Die **Likelihoodfunktion** ist

$$L(\theta) := \prod_{i=1}^{n} f_\theta(x_i)$$

(bzw. mit Zähldichten im diskreten Fall). Der **Maximum-Likelihood-Schätzer** ist

$$\hat{\theta}_{\mathrm{ML}} := \arg\max_\theta L(\theta).$$

Die Idee – und eine Warnung

Man wählt denjenigen Parameter, unter dem die beobachteten Daten am wahrscheinlichsten wären.

Praktisch maximiert man den Logarithmus

$$\ell(\theta) := \ln L(\theta) = \sum_{i=1}^{n} \ln f_\theta(x_i),$$

weil das Produkt zur Summe wird und der Logarithmus streng monoton ist – das Maximum bleibt an derselben Stelle.

$L(\theta)$ ist keine Wahrscheinlichkeit für θ

Die Likelihood ist eine Funktion von θ, aber sie ist *keine* Verteilung über θ: Sie integriert sich im Allgemeinen nicht zu 1.
Die Aussage „$\theta = 0{,}7$ ist am wahrscheinlichsten“ ist im frequentistischen Rahmen sinnlos – θ ist dort eine feste, unbekannte Zahl, keine Zufallsvariable.
Korrekt wäre: „Unter $\theta = 0{,}7$ wären die Daten am wahrscheinlichsten.“
Wer eine Wahrscheinlichkeitsaussage über θ will, muss den Bayes-Weg gehen und einen Prior angeben.

Aufgabe 14.1. Bestimmen Sie den ML-Schätzer für den Parameter p einer Binomialverteilung, wenn bei n Versuchen k Treffer beobachtet wurden.

Lösung Schritt für Schritt.

Schritt 1 – Likelihood.

$$L(p) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Schritt 2 – Logarithmieren.

$$\ell(p) = \ln \binom{n}{k} + k \ln p + (n-k) \ln(1-p).$$

Der erste Term hängt nicht von p ab und ist für die Maximierung irrelevant.

Schritt 3 – Ableiten.

$$\ell'(p) = \frac{k}{p} - \frac{n-k}{1-p}.$$

(Die zweite Ableitung nach der Kettenregel: $\frac{d}{dp} \ln(1-p) = \frac{-1}{1-p}$.)

Schritt 4 – Nullsetzen.

$$\frac{k}{p} = \frac{n-k}{1-p} \Longrightarrow k(1-p) = p(n-k) \Longrightarrow k - kp = pn - pk.$$

Die Terme kp heben sich weg:

$$k = pn \Longrightarrow \hat{p} = \frac{k}{n}.$$

Schritt 5 – Maximum bestätigen.

$$\ell''(p) = -\frac{k}{p^2} - \frac{n-k}{(1-p)^2} < 0$$

für $0 < p < 1$. Die Funktion ist streng konkav, es liegt also ein Maximum vor. ✓

Ergebnis: Der ML-Schätzer ist die relative Häufigkeit – was intuitiv naheliegt, aber eben auch bewiesen sein will.

Schritt 6 – Eigenschaften.

$$\mathbb{E}[\hat{p}] = \frac{\mathbb{E}[X]}{n} = \frac{np}{n} = p \Longrightarrow \text{erwartungstreu} ✓$$

$$\operatorname{Var}(\hat{p}) = \frac{\operatorname{Var}(X)}{n^2} = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n} \longrightarrow 0 \Longrightarrow \text{konsistent} ✓$$

Bemerkung zu den Randfällen. Bei $k = 0$ liefert ML den Schätzwert $\hat{p} = 0$ – also die Aussage, das Ereignis sei unmöglich. Das ist bei kleinen Stichproben unangemessen.

Abhilfe schafft die **Dreier-Regel**: Wurde bei n Beobachtungen kein Ereignis registriert, so liegt die obere 95 %-Grenze für p bei etwa $\frac{3}{n}$.

Herleitung: $\mathbb{P}(X = 0) = (1-p)^n \approx \mathrm{e}^{-np}$. Setzt man das gleich 0,05, so folgt $np \approx \ln 20 = 3{,}0$.

Praktisches Beispiel: Traten bei 100 Behandlungen keine schweren Nebenwirkungen auf, so ist deren Rate mit 95 % Vertrauen kleiner als 3 % – aber eben nicht null. Diese Regel gehört zum Standardwerkzeug der Arzneimittelsicherheit.

14.3 Konfidenzintervalle

Definition 14.3. Ein **Konfidenzintervall** zum Niveau $1-\alpha$ ist ein zufälliges Intervall $[U, O]$ mit

$$\mathbb{P}_\theta\big(U \le \theta \le O\big) \;\ge\; 1-\alpha \qquad \text{für alle } \theta.$$

Was ein Konfidenzintervall nicht bedeutet

Nach der Berechnung steht etwa da: $[4{,}2;\ 6{,}8]$.
Falsch: „Mit 95 % Wahrscheinlichkeit liegt θ zwischen 4,2 und 6,8."
Warum falsch: Im frequentistischen Rahmen ist θ eine feste Zahl. Sie liegt entweder in $[4{,}2; 6{,}8]$ oder nicht – mit Wahrscheinlichkeit 1 oder 0. Zufällig war das *Intervall*, nicht der Parameter, und nach der Berechnung ist auch das Intervall festgelegt.
Richtig: „Das Verfahren, mit dem dieses Intervall erzeugt wurde, überdeckt den wahren Wert in 95 % aller Anwendungen."
Das ist keine Haarspalterei. Es gibt Beispiele – konstruiert von WELCH und anderen –, in denen ein korrektes 95 %-Konfidenzintervall in bestimmten Datenkonstellationen *sicher* den wahren Wert enthält oder sicher nicht enthält, und man das den Daten ansehen kann. Das Überdeckungsniveau ist eine Eigenschaft des Verfahrens auf lange Sicht, nicht des einzelnen Intervalls.
Wer eine Wahrscheinlichkeitsaussage über den Parameter will, braucht ein **Kredibilitätsintervall** aus der Bayes-Statistik. Bei uninformativen Priors stimmen beide numerisch oft überein – die Interpretation bleibt verschieden.

Die Standardformeln

Mittelwert bei bekannter Varianz:

$$\bar{x} \pm z_{1-\alpha/2}\,\frac{\sigma}{\sqrt{n}}.$$

Mittelwert bei geschätzter Varianz:

$$\bar{x} \pm t_{n-1;\,1-\alpha/2}\,\frac{s}{\sqrt{n}}.$$

Anteil (Wald-Intervall):

$$\hat{p} \pm z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Mit $z_{0{,}975} = 1{,}96$ für 95 %.

Das Wald-Intervall ist schlecht

Es hat bei kleinem n oder extremem p eine Überdeckung, die deutlich unter dem Nennniveau liegt – bei p nahe 0 oder 1 kann sie auf null fallen. Bei $\hat{p} = 0$ liefert es das Intervall $[0, 0]$.
Brown, Cai und DasGupta (2001) empfahlen daher, es zu ersetzen. Bessere Alternativen:

- das *Wilson*-Intervall (1927),
- das *Agresti–Coull*-Intervall: zwei Erfolge und zwei Misserfolge hinzufügen, dann Wald rechnen,
- das exakte *Clopper–Pearson*-Intervall (konservativ).

Dass das Wald-Intervall dennoch in fast jedem Einführungsbuch steht, ist ein Beispiel für die Beharrungskraft didaktischer Traditionen.

Aufgabe 14.2. In einer Studie mit 250 Patienten sprachen 160 auf die Therapie an. Bestimmen Sie ein 95 %-Konfidenzintervall für die Ansprechrate.

Lösung Schritt für Schritt.

Schritt 1 – Punktschätzer.

$$\hat{p} = \frac{160}{250} = 0{,}64.$$

Schritt 2 – Standardfehler.

$$\mathrm{SE} = \sqrt{\frac{0{,}64 \cdot 0{,}36}{250}} = \sqrt{\frac{0{,}2304}{250}} = \sqrt{0{,}0009216} = 0{,}03036.$$

Schritt 3 – Wald-Intervall.

$$0{,}64 \pm 1{,}96 \cdot 0{,}03036 = 0{,}64 \pm 0{,}0595.$$

$$[0{,}580;\ 0{,}700].$$

Schritt 4 – Zum Vergleich das Wilson-Intervall. Es entsteht durch Auflösen der Ungleichung

$$\left| \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \right| \le z$$

nach p – man setzt also die *unbekannte* Varianz ein statt der geschätzten. Das Ergebnis lautet

$$[0{,}579;\ 0{,}698].$$

Bei $n = 250$ und mittlerem p ist der Unterschied gering. Bei $n = 20$ und $\hat{p} = 0{,}95$ ergäbe Wald $[0{,}855;\ 1{,}045]$ – ein unmögliches Intervall, das über 1 hinausragt –, Wilson dagegen $[0{,}764;\ 0{,}992]$.

Schritt 5 – Interpretation. Die Ansprechrate liegt vermutlich zwischen 58 % und 70 %. Ein Vergleichswert von 50 % liegt außerhalb; die Therapie wirkt also nachweisbar bei mehr als der Hälfte.
Schritt 6 – Fallzahlplanung rückwärts. Wie viele Patienten bräuchte man für eine Breite von ± 5 Prozentpunkten?

$$1{,}96\sqrt{\frac{0{,}64 \cdot 0{,}36}{n}} = 0{,}05 \Longrightarrow \frac{0{,}2304}{n} = \left(\frac{0{,}05}{1{,}96}\right)^2 = 0{,}000651$$

$$n = \frac{0{,}2304}{0{,}000651} = 354.$$

Für $\pm 2{,}5$ Prozentpunkte wären es $4 \cdot 354 = 1416$ – der Wurzel-n-Effekt aus Kapitel 10.

14.4 Hypothesentests

Das Schema

1. **Hypothesen aufstellen.** Die **Nullhypothese** H_0 ist die Aussage, die man widerlegen möchte – meist „kein Effekt“. H_1 ist die Alternative.
2. **Signifikanzniveau α festlegen** – *vor* der Datenerhebung.
3. **Teststatistik berechnen.**
4. **p-Wert bestimmen:** die Wahrscheinlichkeit, unter H_0 ein mindestens so extremes Ergebnis zu erhalten.
5. **Entscheiden:** $p < \alpha \Longrightarrow H_0$ verwerfen.

Die beiden Fehlerarten

	H_0 **wahr**	H_0 **falsch**
H_0 beibehalten	richtig	**Fehler 2. Art** (β)
H_0 verwerfen	**Fehler 1. Art** (α)	richtig (Power $1-\beta$)

Die Asymmetrie ist beabsichtigt. α wird kontrolliert (meist auf 0,05), β nicht. Man schützt sich vorrangig davor, einen Effekt zu behaupten, den es nicht gibt.
Analogie zum Strafprozess: H_0 ist die Unschuldsvermutung. Ein Fehler 1. Art verurteilt einen Unschuldigen, ein Fehler 2. Art spricht einen Schuldigen frei. Das Rechtssystem gewichtet den ersten Fehler ebenfalls schwerer.
Die Konsequenz: „Nicht signifikant“ heißt *nicht* „kein Effekt“. Es heißt: „Wir haben keinen nachweisen können“ – was auch an zu kleiner Fallzahl liegen kann.
Power-Analyse. Die Power hängt ab von Effektgröße, Streuung, Fallzahl und α. Sie sollte *vor* der Studie berechnet werden; üblich sind 80 % oder 90 %. Eine Un-

tersuchung von BUTTON und Mitarbeitern (2013) fand für neurowissenschaftliche Studien eine mittlere Power von etwa 20 % – vier von fünf real vorhandenen Effekten würden dort also übersehen.

Was ein p-Wert nicht ist

Der p-Wert ist $\mathbb{P}(\text{Daten mindestens so extrem} \mid H_0)$.
Er ist nicht:

1. die Wahrscheinlichkeit, dass H_0 wahr ist. Das wäre $\mathbb{P}(H_0 \mid \text{Daten})$ – die transponierte Bedingung (Kapitel 3).
2. die Wahrscheinlichkeit, dass das Ergebnis durch Zufall zustande kam.
3. ein Maß für die *Größe* eines Effekts. Bei $n = 10^6$ wird jede noch so winzige Abweichung signifikant.
4. die Wahrscheinlichkeit, dass sich das Ergebnis replizieren lässt.
5. eine Aussage darüber, ob H_0 verworfen *werden sollte* – das hängt auch von Vorwissen und Konsequenzen ab.

Die American Statistical Association veröffentlichte 2016 erstmals in ihrer Geschichte eine formale Erklärung zu einem einzelnen statistischen Konzept – eben zum p-Wert[27]. Sie enthält sechs Prinzipien, deren Kern lautet: Ein p-Wert allein liefert keine hinreichende Evidenzgrundlage für eine wissenschaftliche Aussage. 2019 folgte in *The American Statistician* eine Sonderausgabe mit 43 Beiträgen und dem redaktionellen Fazit, man solle die Rede von „statistischer Signifikanz“ aufgeben. Im selben Jahr unterzeichneten über 800 Fachleute einen Aufruf in *Nature*[2] mit derselben Forderung.
Durchgesetzt hat sich die Reform bislang nicht. Die Zeitschrift *Basic and Applied Social Psychology* verbot p-Werte 2015 vollständig – ein Einzelfall, dessen Folgen kontrovers beurteilt werden.

Aufgabe 14.3. Ein Medikament soll die Heilungsrate über den Standardwert von 60 % heben. Bei 200 Patienten heilen 136. Testen Sie auf dem Niveau $\alpha = 0{,}05$.

Lösung Schritt für Schritt.

Schritt 1 – Hypothesen.

$$H_0 : \; p \le 0{,}60 \qquad \text{gegen} \qquad H_1 : \; p > 0{,}60.$$

Einseitig, weil nur eine Verbesserung interessiert.
Schritt 2 – Teststatistik. Unter H_0 (im Grenzfall $p_0 = 0{,}6$) ist $X \sim \text{Bin}(200;\, 0{,}6)$ mit

$$\mu = 120, \qquad \sigma = \sqrt{200 \cdot 0{,}6 \cdot 0{,}4} = \sqrt{48} = 6{,}928.$$

Schritt 3 – Beobachteter Wert standardisieren (mit Stetigkeitskorrektur):

$$z = \frac{135{,}5 - 120}{6{,}928} = \frac{15{,}5}{6{,}928} = 2{,}237.$$

Schritt 4 – p-Wert.

$$p = 1 - \Phi(2{,}237) = 1 - 0{,}9874 = 0{,}0126.$$

Schritt 5 – Entscheidung. $0{,}0126 < 0{,}05 \Longrightarrow H_0$ wird verworfen.
Exakter Binomialtest zur Kontrolle: $\mathbb{P}(X \geq 136) = 0{,}0131$. Die Näherung ist gut. ✓
Schritt 6 – Was man jetzt sagen darf und was nicht.
Zulässig: „Die Daten sind mit einer Heilungsrate von 60 % schlecht vereinbar. Der geschätzte Wert beträgt 68 %, mit einem 95 %-Konfidenzintervall von etwa [61,5 %; 74,5 %].“
Unzulässig: „Mit 98,7 % Wahrscheinlichkeit wirkt das Medikament besser.“ Das verwechselt $\mathbb{P}(\text{Daten} \mid H_0)$ mit $\mathbb{P}(H_1 \mid \text{Daten})$.
Schritt 7 – Die klinische Frage. Die Verbesserung beträgt 8 Prozentpunkte. Ist das relevant?
Die *Number needed to treat* beträgt

$$\text{NNT} = \frac{1}{0{,}68 - 0{,}60} = 12{,}5.$$

Man muss also etwa 13 Patienten behandeln, damit einer zusätzlich geheilt wird. Ob das den Aufwand und die Nebenwirkungen rechtfertigt, ist eine *medizinische* Frage, die kein Test beantwortet.
Das ist der wichtigste Punkt des Kapitels: Statistische Signifikanz und klinische Relevanz sind verschiedene Dinge. Der p-Wert misst die erstere, die Effektgröße mit Konfidenzintervall die letztere. Berichtet werden sollten stets beide – besser noch: nur die letztere.

14.5 Multiples Testen

Das Problem

Führt man m unabhängige Tests auf dem Niveau α durch, so ist die Wahrscheinlichkeit für mindestens einen falsch positiven Befund

$$1 - (1 - \alpha)^m.$$

m	$\mathbb{P}(\geq 1$ falsch positiv$)$
1	5,0 %
5	22,6 %
20	64,2 %
100	99,4 %

Bei 20 geprüften Endpunkten findet man fast sicher einen „signifikanten“ – auch wenn nichts vorhanden ist.

Die Korrekturverfahren

Bonferroni. Man testet jeden Einzeltest auf dem Niveau $\frac{\alpha}{m}$. Kontrolliert die **familienweise Fehlerrate** (FWER).
Begründung über die Subadditivität (Satz 1.7(e)):

$$\mathbb{P}\left(\bigcup_i \{\text{Test } i \text{ falsch positiv}\}\right) \leq \sum_i \frac{\alpha}{m} = \alpha.$$

Keine Unabhängigkeit nötig – das ist die Stärke des Verfahrens. Seine Schwäche ist die Konservativität: Bei vielen Tests wird die Power sehr klein.
Holm (1979). Sortiert die p-Werte aufsteigend und vergleicht den i-ten mit $\frac{\alpha}{m-i+1}$. Kontrolliert ebenfalls die FWER, ist aber stets mindestens so mächtig wie Bonferroni. *Es gibt keinen Grund, Bonferroni statt Holm zu verwenden.*
Benjamini–Hochberg (1995). Kontrolliert die **False Discovery Rate** – den erwarteten Anteil falsch positiver *unter den Verwerfungen*. Das ist eine schwächere, aber oft angemessenere Forderung.
Wann welches Verfahren: Bei wenigen, gleich wichtigen Tests und schwerwiegenden Fehlentscheidungen (Zulassungsstudien) FWER. Bei Tausenden von Tests in explorativer Absicht (Genexpression, Bildgebung) FDR – sonst findet man gar nichts mehr.

Der tote Lachs

2009 stellten Craig Bennett und Mitarbeiter eine Untersuchung vor, in der ein toter atlantischer Lachs in einen Kernspintomographen gelegt wurde. Man zeigte ihm Fotografien von Menschen in sozialen Situationen und bat ihn – so das Protokoll –, deren Emotionen zu beurteilen.
Bei unkorrigierter Auswertung fand sich eine statistisch signifikante Aktivierung im Hirnstamm des Lachses.
Der Grund: Ein typisches fMRT-Bild enthält etwa 130 000 Voxel. Bei $\alpha = 0{,}001$ pro Voxel erwartet man 130 falsch positive Befunde – einige davon zufällig benachbart und damit als „Aktivierungsherd“ interpretierbar.

Die Arbeit erhielt 2012 den Ig-Nobelpreis. Ihre Wirkung war erheblich: Korrekturverfahren für multiples Testen sind seither in der Bildgebungsforschung Standard. Eine Untersuchung von EKLUND und Mitarbeitern (2016) zeigte allerdings, dass verbreitete Softwarepakete die Fehlerrate weiterhin unterschätzten – mit möglichen Folgen für Tausende publizierter Arbeiten.

Part VII

Ausblick und aktueller Stand

15 Der aktuelle Stand

Bestandsaufnahme mit Stand August 2026.

15.1 Die Replikationskrise

Was geschehen ist

2015 veröffentlichte das *Open Science Collaboration*-Projekt unter Leitung von Brian Nosek den Versuch, 100 psychologische Studien zu replizieren[20]. Ergebnis: In der Originalliteratur waren 97 % der Befunde signifikant; in den Replikationen nur 36 %. Die mittlere Effektstärke halbierte sich.
Ähnliche Befunde folgten in anderen Feldern:

- **Krebsbiologie.** Das *Reproducibility Project: Cancer Biology* (2021) konnte von ursprünglich 193 geplanten Experimenten nur 50 überhaupt durchführen – vielfach, weil die Publikationen die Methoden nicht hinreichend beschrieben. Die replizierten Effektstärken lagen im Median 85 % unter den ursprünglichen.
- **Ökonomie.** Camerer und Mitarbeiter (2016) replizierten 11 von 18 experimentellen Arbeiten.
- **Präklinische Pharmakologie.** Mitarbeiter von Amgen berichteten 2012, nur 6 von 53 als wegweisend geltenden Arbeiten bestätigen zu können.

Die statistischen Ursachen

1. Publikationsbias. Signifikante Ergebnisse werden publiziert, nichtsignifikante nicht. Die veröffentlichte Literatur ist dadurch systematisch verzerrt – ein Effekt, den Rosenthal 1979 als *file drawer problem* beschrieb.
2. Geringe Power. Bei einer Power von 20 % und einer Vorabwahrscheinlichkeit von 10 % für einen echten Effekt ergibt die Rechnung von Bayes:

$$\mathbb{P}(\text{Effekt echt} \mid \text{signifikant}) = \frac{0{,}20 \cdot 0{,}10}{0{,}20 \cdot 0{,}10 + 0{,}05 \cdot 0{,}90} = \frac{0{,}020}{0{,}065} = 0{,}31.$$

Über zwei Drittel der signifikanten Befunde wären falsch – obwohl jeder einzelne Test korrekt auf $\alpha = 0{,}05$ durchgeführt wurde.
Das ist genau die Rechnung aus dem medizinischen Testbeispiel in Kapitel 3, angewandt auf Forschungsbefunde statt auf Patienten. John Ioannidis führte sie

2005 in einem der meistzitierten Aufsätze der Wissenschaftsgeschichte durch[14] – mit dem Titel, die meisten publizierten Forschungsbefunde seien falsch.
3. Forscherfreiheitsgrade. SIMMONS, NELSON und SIMONSOHN zeigten 2011[24]: Wer während der Auswertung entscheidet, wann er aufhört zu erheben, welche Kovariaten er einschließt, welche Ausreißer er entfernt und welche von mehreren Zielgrößen er berichtet, kann die tatsächliche Fehlerrate 1. Art von 5 % auf über 60 % treiben.
Sie demonstrierten das mit einem Experiment, in dem sie „nachwiesen", dass das Hören eines bestimmten Liedes die Versuchspersonen um anderthalb Jahre jünger machte – statistisch signifikant.
4. HARKing. *Hypothesizing After the Results are Known*: Man formuliert die Hypothese nach Sichtung der Daten und stellt sie als Vorabvermutung dar. Damit verliert der p-Wert jede Bedeutung.

Die Gegenmaßnahmen – Stand 2026

Präregistrierung. Hypothesen, Fallzahl und Auswertungsplan werden vor der Datenerhebung öffentlich festgelegt. Für klinische Studien seit 2005 verpflichtend (ClinicalTrials.gov), in der Psychologie über das Open Science Framework verbreitet.
Der Effekt ist messbar: Eine Untersuchung von KAPLAN und IRVIN (2015) über kardiovaskuläre Studien fand, dass vor Einführung der Registrierungspflicht 57 % der Studien einen positiven Effekt berichteten, danach nur noch 8 %.
Registered Reports. Das Journal begutachtet und akzeptiert das *Studienprotokoll* – vor der Datenerhebung. Die Publikation erfolgt unabhängig vom Ergebnis. Inzwischen bieten über 300 Zeitschriften dieses Format an. Erste Auswertungen zeigen einen Anteil positiver Befunde von etwa 44 % gegenüber rund 96 % in konventionellen Publikationen.
Strengere Schwellen. BENJAMIN und 71 Mitunterzeichner schlugen 2018 vor, die Signifikanzschwelle für neue Entdeckungen auf 0,005 zu senken. Gegenvorschläge fordern stattdessen, Schwellen ganz aufzugeben und Effektstärken mit Intervallen zu berichten.
Offene Daten und offener Code. Zunehmend Voraussetzung für Publikation.
Wo man 2026 steht: Die Diagnose ist unstrittig, die Therapie noch nicht flächendeckend umgesetzt. Die Anreizstruktur des Wissenschaftsbetriebs – Publikationszahl als Karrierewährung – ist unverändert.

15.2 Bayes gegen Frequentismus

Die beiden Schulen

Frequentistisch	Bayesianisch
Wahrscheinlichkeit = Grenzwert relativer Häufigkeiten	Wahrscheinlichkeit = Grad rationaler Überzeugung
θ ist eine feste Zahl	θ ist eine Zufallsvariable
Konfidenzintervall	Kredibilitätsintervall
p-Wert, Signifikanz	Posterior, Bayes-Faktor
kein Vorwissen nötig	Prior erforderlich

Die zentrale Gleichung der Bayes-Statistik:

$$\underbrace{\pi(\theta \mid x)}_{\text{Posterior}} \propto \underbrace{L(x \mid \theta)}_{\text{Likelihood}} \cdot \underbrace{\pi(\theta)}_{\text{Prior}}.$$

Das ist Satz 3.5 aus Kapitel 3, angewandt auf Parameter statt auf Ereignisse.
Die Einwände gegeneinander:
Gegen Bayes: Der Prior ist subjektiv. Zwei Forscher mit denselben Daten kommen zu verschiedenen Schlüssen.
Gegen Frequentismus: Er beantwortet nicht die Frage, die man stellt. Man will $\mathbb{P}(\text{Hypothese} \mid \text{Daten})$; man bekommt $\mathbb{P}(\text{Daten} \mid \text{Hypothese})$.
Die pragmatische Antwort: Bei ausreichend vielen Daten dominiert die Likelihood, und der Prior wird unwichtig – der **Bernstein–von-Mises-Satz** macht das präzise. Bei wenigen Daten ist der Prior entscheidend, aber dann ist auch die frequentistische Analyse unzuverlässig. Die Wahl ist häufiger eine Frage der Bequemlichkeit als der Überzeugung.

Warum Bayes seit den 1990er Jahren an Boden gewinnt

Nicht wegen neuer philosophischer Argumente, sondern wegen *Rechenleistung*. Das Integral im Nenner der Bayes-Formel ist in mehr als zwei Dimensionen analytisch unlösbar. MCMC (Kapitel 12) umgeht es.
Aktuelle Entwicklungen:

- **Hamiltonian Monte Carlo** und der NUTS-Algorithmus (Hoffman und Gelman 2014) skalieren auf Hunderte von Parametern. Umgesetzt in Stan, PyMC, NumPyro.
- **Variationelle Inferenz** ersetzt die Simulation durch ein Optimierungsproblem – schneller, aber nur approximativ.

- **Bayessche adaptive Studiendesigns** sind in der klinischen Forschung angekommen: Die FDA veröffentlichte 2010 und 2019 entsprechende Leitlinien. Plattformstudien wie RECOVERY und REMAP-CAP nutzten sie während der Pandemie, um unwirksame Arme frühzeitig zu schließen.
- **Bayessche neuronale Netze** liefern Unsicherheitsschätzungen – ein zentrales Anliegen, seit klar ist, dass gewöhnliche Netze auch bei völlig falschen Vorhersagen hohe Konfidenz melden.

15.3 Konzentrationsungleichungen

Über Tschebyschow hinaus

Tschebyschow liefert $\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}$ – ein Abfall wie $\frac{1}{n}$. Für beschränkte Größen geht es exponentiell besser.

Hoeffding-Ungleichung (1963). Sind $X_1, \ldots, X_n$ unabhängig mit $a_i \leq X_i \leq b_i$, so

$$\mathbb{P}\big(|\bar{X}_n - \mathbb{E}[\bar{X}_n]| \geq \varepsilon\big) \;\leq\; 2\exp\left(-\frac{2n^2\varepsilon^2}{\sum_i (b_i - a_i)^2}\right).$$

Der Vergleich. Für Bernoulli-Größen mit $n = 1000$ und $\varepsilon = 0{,}05$:

Tschebyschow	0,10
Hoeffding	0,0135

Und der Unterschied wächst: Bei $\varepsilon = 0{,}1$ liefert Tschebyschow 0,025, Hoeffding $4 \cdot 10^{-9}$.

Weitere wichtige Ungleichungen:

- *Bernstein* und *Bennett*: nutzen zusätzlich die Varianz und sind schärfer, wenn diese klein ist.
- *McDiarmid* (Bounded-Differences-Ungleichung): gilt für beliebige Funktionen $f(X_1, \ldots, X_n)$, die sich bei Änderung eines Arguments nur wenig ändern.
- *Talagrand* (1995): Konzentration in Produkträumen – ein tiefes und technisch anspruchsvolles Resultat.

Das übergreifende Phänomen heißt **Maßkonzentration**: In hohen Dimensionen sind „gutartige“ Funktionen fast konstant. MICHEL TALAGRAND – Abelpreisträger 2024 – formulierte es so, dass eine Zufallsvariable, die von vielen unabhängigen Größen in glatter Weise abhängt, praktisch deterministisch ist.

Wozu man das braucht: statistische Lerntheorie

Konzentrationsungleichungen sind das Fundament der Theorie des maschinellen Lernens. Die Kernfrage lautet: Wie weit weicht der Fehler auf den Trainingsdaten vom Fehler auf neuen Daten ab?
Die klassische Antwort über die **VC-Dimension** (Vapnik und Chervonenkis 1971) lautet: Der Unterschied ist mit hoher Wahrscheinlichkeit kleiner als

$$O\left(\sqrt{\frac{d \ln n}{n}}\right),$$

wobei d die Kapazität der Modellklasse misst.
Das offene Problem. Moderne neuronale Netze haben mehr Parameter als Trainingsbeispiele – die klassischen Schranken sind bedeutungslos, oft größer als 1. Dennoch generalisieren die Netze gut.
ZHANG und Mitarbeiter zeigten 2017, dass dieselben Netze auch zufällige Beschriftungen perfekt auswendig lernen – die Kapazität ist also tatsächlich riesig. Warum sie bei echten Daten dennoch generalisieren, ist *nicht befriedigend erklärt*.
Diskutierte Ansätze: implizite Regularisierung durch den Optimierungsalgorithmus, Normen der Gewichte statt Parameterzahl, PAC-Bayes-Schranken, das Phänomen des *double descent* (Belkin u.a. 2019), bei dem der Testfehler jenseits des Interpolationspunkts wieder sinkt.
Stand 2026: Dies gilt weithin als eines der wichtigsten offenen Probleme der Theorie des maschinellen Lernens. Fortschritte gibt es bei linearen und kernbasierten Modellen sowie im Grenzfall unendlich breiter Netze (Neural Tangent Kernel); für Netze praktischer Größe bleibt die Lücke.

15.4 Kausale Inferenz

Von der Korrelation zur Kausalität

Die klassische Statistik beschreibt Zusammenhänge. Sie stellt aber kein Vokabular bereit, um Aussagen der Form „Was wäre, wenn wir eingriffen?“ zu formulieren.
Zwei Rahmenwerke haben sich etabliert:
Potentielle Ergebnisse (NEYMAN 1923, RUBIN ab 1974). Jede Person hat zwei potentielle Ergebnisse $Y(1)$ und $Y(0)$ – unter Behandlung und ohne. Beobachtbar ist stets nur eines; das ist das **fundamentale Problem der kausalen Inferenz**. Der Kausaleffekt $\mathbb{E}[Y(1) - Y(0)]$ ist dennoch schätzbar, wenn die Zuteilung zufällig erfolgt.
Strukturelle Kausalmodelle (JUDEA PEARL, ab 1995)[21]. Man stellt Annahmen als gerichteten azyklischen Graphen dar und leitet mit dem *do*-Kalkül ab, welche Kausaleffekte aus Beobachtungsdaten identifizierbar sind. Das **Backdoor-Kriterium** gibt eine formale Antwort auf die in Kapitel 3 offengelassene Frage, nach welchen Variablen man adjustieren muss.

Pearl erhielt 2011 den Turing-Preis; sein Buch *The Book of Why* (2018) brachte das Thema einer breiteren Leserschaft nahe.
Praktische Methoden: Instrumentvariablen, Regressionsdiskontinuität, Differenz-von-Differenzen, synthetische Kontrollgruppen. CARD, ANGRIST und IMBENS erhielten 2021 den Wirtschaftsnobelpreis für die Entwicklung dieser Verfahren.
Aktuelle Richtungen: Kausale Entdeckung (Lernen der Graphstruktur aus Daten), doppelt robuste Schätzer, kausale Ansätze zur Robustheit maschineller Lernverfahren gegenüber Verteilungsverschiebungen. Letzteres ist praktisch bedeutsam: Ein Modell, das Scheinkorrelationen gelernt hat, versagt in einer neuen Umgebung – ein wiederkehrendes Problem bei medizinischen Diagnosesystemen, die auf Daten einer einzelnen Klinik trainiert wurden.

15.5 Formalisierung

Wahrscheinlichkeitstheorie in Beweisassistenten

Die Maß- und Wahrscheinlichkeitstheorie ist in Lean/mathlib weitgehend formalisiert: Maßräume, das Lebesgue-Integral, bedingte Erwartung, Martingale, das starke Gesetz der großen Zahlen und der zentrale Grenzwertsatz.
Ein bemerkenswerter Meilenstein war die Formalisierung der *Independence*-Bibliothek und der Kolmogorow-Erweiterung, die die Konstruktion stochastischer Prozesse auf unendlichen Produkträumen erlaubt.
Die Erfahrungen entsprechen denen aus der Analysis: Lehrbuchbeweise erweisen sich häufiger als lückenhaft, meist bei Messbarkeitsargumenten, die im Text mit „offensichtlich“ übergangen werden.
Zum Stand der Formalisierung und der automatisierten Beweisfindung im August 2026 – einschließlich der Leidener Erklärung und der Arbeiten von Alexeev – siehe Band 3, Kapitel 14.

15.6 Wohin es weitergeht

Die natürlichen Fortsetzungen

- **Maßtheoretische Wahrscheinlichkeitstheorie.** Die strenge Fassung dessen, was hier meist anschaulich blieb. Empfehlung: Klenke[16] oder Durrett[8].
- **Stochastische Prozesse.** Brownsche Bewegung, Itō-Integral, stochastische Differentialgleichungen. Empfehlung: Karatzas–Shreve[15].
- **Mathematische Statistik.** Suffizienz, optimale Tests, asymptotische Theorie. Empfehlung: Casella–Berger[6], für die Asymptotik van der Vaart[26].

- **Bayes-Statistik.** Empfehlung: Gelman u.a.[10] – das Standardwerk der angewandten Bayes-Analyse.
- **Statistische Lerntheorie.** Empfehlung: Hastie–Tibshirani–Friedman[12], frei verfügbar.
- **Kausale Inferenz.** Empfehlung: Hernán–Robins[13], ebenfalls frei verfügbar.

Ein letzter Gedanke

Am Anfang dieses Bandes stand die Behauptung, in der Wahrscheinlichkeitstheorie versage die Intuition systematisch.
Nach fünfzehn Kapiteln lässt sich sagen, worin das Muster besteht. Fast jeder der behandelten Fehlschlüsse ist eine Variante *einer* Verwechslung:

$$\mathbb{P}(A \mid B) \quad \text{gegen} \quad \mathbb{P}(B \mid A).$$

Der positive Test und die Krankheit. Der Befund und die Schuld. Die Daten und die Hypothese. Der p-Wert und die Wahrscheinlichkeit, dass die Nullhypothese stimmt. Es ist immer dieselbe Umkehrung – und die Formel von Bayes ist immer die Antwort.
Der zweite wiederkehrende Fehler ist das Übersehen der *Selektion*: Wer viele Hypothesen prüft und die auffälligste berichtet, wer nur signifikante Studien publiziert, wer eine Untergruppe nachträglich auswählt, produziert Befunde, die für sich betrachtet korrekt und im Ganzen wertlos sind.
Und der dritte ist das Vergessen der *Voraussetzungen*: Unabhängigkeit, endliche Varianz, konstante Rate, Normalverteilung. Jede Formel dieses Buches hat welche, und praktisch jeder größere Fehlschlag angewandter Statistik – von den Kreditderivaten 2008 bis zu den Fehlurteilen der Sally-Clark-Art – beruht darauf, dass eine davon stillschweigend unterstellt wurde.
Diese drei Dinge zu prüfen ist keine mathematische Kunst. Es ist eine Gewohnheit. Sie ist erlernbar, und sie ist der eigentliche Ertrag dieses Bandes.
Sie haben jetzt das Werkzeug. Der Rest ist Übung.

Part VIII

Anhänge

A Formelsammlung

Axiome und Grundregeln

$$\mathbb{P}(A) \geq 0, \qquad \mathbb{P}(\Omega) = 1, \qquad \mathbb{P}\Big(\dot{\bigcup}_k A_k\Big) = \sum_k \mathbb{P}(A_k)$$

$$\begin{aligned} \mathbb{P}(A^c) &= 1 - \mathbb{P}(A) \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \\ \mathbb{P}\Big(\bigcup_k A_k\Big) &\leq \sum_k \mathbb{P}(A_k) \end{aligned}$$

Siebformel:

$$\mathbb{P}\Big(\bigcup_{i=1}^{n} A_i\Big) = \sum_{k=1}^{n} (-1)^{k+1} \sum_{i_1 < \cdots < i_k} \mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k})$$

Stetigkeit: $A_k \uparrow A \Longrightarrow \mathbb{P}(A_k) \to \mathbb{P}(A)$; $\quad A_k \downarrow A \Longrightarrow \mathbb{P}(A_k) \to \mathbb{P}(A)$.

Kombinatorik

	mit Reihenfolge	ohne Reihenfolge
mit Zurücklegen	n^k	$\binom{n+k-1}{k}$
ohne Zurücklegen	$\dfrac{n!}{(n-k)!}$	$\binom{n}{k}$

$$\binom{n}{k} = \binom{n}{n-k}, \qquad \binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}, \qquad \sum_{k=0}^{n} \binom{n}{k} = 2^n$$

$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}, \qquad n! \sim \sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^n \text{ (Stirling)}$$

Bedingte Wahrscheinlichkeit

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \qquad \mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\,\mathbb{P}(B)$$

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A \mid B_i)\mathbb{P}(B_i) \qquad \text{(totale Wahrscheinlichkeit)}$$

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k)\mathbb{P}(B_k)}{\sum_i \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)} \qquad \text{(Bayes)}$$

Unabhängigkeit: $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ – für mehr als zwei Ereignisse für *alle* Teilmengen zu fordern.

Erwartungswert und Varianz

$$\mathbb{E}[X] = \sum_k x_k \, \mathbb{P}(X = x_k) \qquad \text{bzw.} \qquad \mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\,\mathrm{d}x$$

$$\mathbb{E}[g(X)] = \sum_k g(x_k)\mathbb{P}(X = x_k) \quad \text{bzw.} \quad \int g(x) f(x)\,\mathrm{d}x \qquad \text{(Transformationssatz)}$$

$$\begin{aligned}
\mathbb{E}[aX + bY + c] &= a\mathbb{E}[X] + b\mathbb{E}[Y] + c \qquad \text{(immer)} \\
\operatorname{Var}(X) &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \\
\operatorname{Var}(aX + b) &= a^2 \operatorname{Var}(X) \\
\operatorname{Var}(X + Y) &= \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X, Y) \\
\operatorname{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \\
\operatorname{Korr}(X, Y) &= \frac{\operatorname{Cov}(X, Y)}{\sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}} \in [-1, 1]
\end{aligned}$$

Bedingte Erwartung:

$$\mathbb{E}\big[\mathbb{E}[X \mid Y]\big] = \mathbb{E}[X] \quad \text{(Turmregel)}, \qquad \operatorname{Var}(X) = \mathbb{E}\big[\operatorname{Var}(X \mid Y)\big] + \operatorname{Var}\big(\mathbb{E}[X \mid Y]\big)$$

Ungleichungen

$$\begin{aligned}
\mathbb{P}(X \geq a) &\leq \frac{\mathbb{E}[X]}{a} \quad (X \geq 0,\ a > 0) && \text{Markow} \\
\mathbb{P}\big(|X - \mathbb{E}X| \geq a\big) &\leq \frac{\operatorname{Var}(X)}{a^2} && \text{Tschebyschow} \\
\varphi(\mathbb{E}[X]) &\leq \mathbb{E}[\varphi(X)] \quad (\varphi \text{ konvex}) && \text{Jensen} \\
|\mathbb{E}[XY]| &\leq \sqrt{\mathbb{E}[X^2]\,\mathbb{E}[Y^2]} && \text{Cauchy–Schwarz} \\
\mathbb{P}\Big(\Big|\tfrac{1}{n}\textstyle\sum X_i - \mu\Big| \geq t\Big) &\leq 2\exp\Big(-\tfrac{2n^2t^2}{\sum (b_i - a_i)^2}\Big) && \text{Hoeffding}
\end{aligned}$$

Erzeugende und charakteristische Funktionen

$$G_X(s) = \mathbb{E}[s^X], \qquad \mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!}, \qquad \mathbb{E}[X] = G_X'(1)$$

$$\varphi_X(t) = \mathbb{E}[\mathrm{e}^{\mathrm{i}tX}], \qquad \varphi_{X+Y} = \varphi_X \varphi_Y \ \ (X \perp Y), \qquad \mathbb{E}[X^k] = \frac{\varphi_X^{(k)}(0)}{\mathrm{i}^k}$$

Grenzwertsätze

Schwaches GGZ: $\overline{X}_n \to \mu$ in Wahrscheinlichkeit.
Starkes GGZ (Kolmogorow): $\overline{X}_n \to \mu$ fast sicher, falls $\mathbb{E}\,|X_1| < \infty$.
Zentraler Grenzwertsatz:

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$$

de Moivre–Laplace: $\mathrm{Bin}(n,p) \approx \mathcal{N}\big(np,\, np(1-p)\big)$ für $np(1-p) \gtrsim 9$.
Berry–Esseen: $\sup_x |F_n(x) - \Phi(x)| \le C\rho/(\sigma^3\sqrt{n})$.
Borel–Cantelli: $\sum \mathbb{P}(A_n) < \infty \Longrightarrow \mathbb{P}(A_n \text{ unendlich oft}) = 0$; bei Unabhängigkeit und $\sum \mathbb{P}(A_n) = \infty$ ist die Wahrscheinlichkeit 1.

Markow-Ketten

$$p_{ij}^{(n)} = (P^n)_{ij}, \qquad \pi P = \pi, \qquad \sum_i \pi_i = 1$$

Irreduzibel und aperiodisch $\Longrightarrow p_{ij}^{(n)} \to \pi_j$ für alle i.
Reversibilität (Detailliertes Gleichgewicht): $\pi_i p_{ij} = \pi_j p_{ji} \Longrightarrow \pi$ stationär.

Statistik

$$\hat{\mu} = \overline{X}_n, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2, \qquad \mathrm{MSE} = \mathrm{Bias}^2 + \mathrm{Varianz}$$

Konfidenzintervall für μ (bekanntes σ):

$$\overline{X}_n \pm z_{1-\alpha/2}\,\frac{\sigma}{\sqrt{n}}$$

Wilson-Intervall für einen Anteil p (besser als Wald):

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

Dreier-Regel: bei 0 Ereignissen unter n Beobachtungen ist die obere 95 %-Grenze $\approx 3/n$.
Bonferroni: $\alpha^* = \alpha/m$. Benjamini–Hochberg: $p_{(i)} \le \frac{i}{m}\alpha$.

B Verteilungen im Überblick

Verteilung	Zähldichte / Dichte	Erwartungswert	Varianz
Diskrete Verteilungen			
Bernoulli Bern(p)	$p^k(1-p)^{1-k}, k \in \{0,1\}$	p	$p(1-p)$
Binomial Bin(n,p)	$\binom{n}{k}p^k(1-p)^{n-k}$	np	$np(1-p)$
Geometrisch Geo(p)	$(1-p)^{k-1}p, k \geq 1$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Negativ binomial	$\binom{k-1}{r-1}p^r(1-p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
Hypergeometrisch	$\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$	$n\frac{M}{N}$	$n\frac{M}{N}\frac{N-M}{N}\frac{N-n}{N-1}$
Poisson Poi(λ)	$\frac{\lambda^k}{k!}e^{-\lambda}$	λ	λ
Gleichverteilung	$\frac{1}{n}, k = 1,\ldots,n$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$
Stetige Verteilungen			
Gleichverteilung U(a,b)	$\frac{1}{b-a}$ auf $[a,b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponential Exp(λ)	$\lambda e^{-\lambda x}, x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normal $\mathcal{N}(\mu,\sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$	μ	σ^2
Gamma $\Gamma(\alpha,\lambda)$	$\frac{\lambda^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$
Beta $B(\alpha,\beta)$	$\frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha,\beta)}$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
Chi-Quadrat χ^2_n	$\Gamma(n/2,1/2)$	n	$2n$
Student t_n	$\propto \left(1+\frac{x^2}{n}\right)^{-(n+1)/2}$	$0\ (n>1)$	$\frac{n}{n-2}\ (n>2)$
Weibull	$\frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1}e^{-(x/\lambda)^k}$	$\lambda\Gamma(1+\frac{1}{k})$	s. Text
Cauchy	$\frac{1}{\pi(1+x^2)}$	existiert nicht	existiert nicht

Werte der Standardnormalverteilung

$\Phi(z) = \mathbb{P}(Z \leq z)$ für $Z \sim \mathcal{N}(0,1)$:

z	$\Phi(z)$	z	$\Phi(z)$	z	$\Phi(z)$
0,0	0,5000	1,0	0,8413	2,0	0,9772
0,2	0,5793	1,2	0,8849	2,2	0,9861
0,4	0,6554	1,4	0,9192	2,4	0,9918
0,6	0,7257	1,6	0,9452	2,6	0,9953
0,8	0,7881	1,8	0,9641	3,0	0,9987

Wichtige Quantile $z_{1-\alpha}$ mit $\Phi(z_{1-\alpha}) = 1-\alpha$:

$1-\alpha$	0,90	0,95	0,975	0,99	0,995
$z_{1-\alpha}$	1,2816	1,6449	1,9600	2,3263	2,5758

Sigma-Regeln: $\mathbb{P}(|Z| \leq 1) = 68{,}3\,\%$, $\mathbb{P}(|Z| \leq 2) = 95{,}4\,\%$, $\mathbb{P}(|Z| \leq 3) = 99{,}7\,\%$.

C Zeitleiste der Wahrscheinlichkeitstheorie

Zeit	Ereignis
ca. 3000 v. Chr.	Astragale (Sprunggelenkknochen) als Würfel in Mesopotamien und Ägypten
ca. 1550	Cardano schreibt *Liber de ludo aleae* (erst 1663 gedruckt)
1654	Briefwechsel Pascal–Fermat über das Teilungsproblem: Geburtsstunde des Fachs
1657	Huygens: *De ratiociniis in ludo aleae*, erstes gedrucktes Lehrbuch
1662	Graunt analysiert Londoner Sterbelisten: Beginn der Demographie
1708	Montmort: *Essay d'analyse sur les jeux de hazard*; Problem der vertauschten Briefe
1713	Jacob Bernoulli: *Ars conjectandi* (posthum), erstes Gesetz der großen Zahlen
1733	de Moivre findet die Normalverteilung als Näherung der Binomialverteilung
1763	Bayes' Aufsatz erscheint posthum, herausgegeben von Richard Price
1809/12	Gauß: Methode der kleinsten Quadrate; Laplace: *Théorie analytique des probabilités*
1837	Poisson: Gesetz der kleinen Zahlen
1846	Tschebyschow beweist das schwache Gesetz der großen Zahlen elementar
1866–1877	Boltzmann und Maxwell: statistische Mechanik
1898	von Bortkiewicz: Pferdetritte in der preußischen Armee
1900	Bachelier: Brownsche Bewegung zur Modellierung von Aktienkursen; Hilberts 6. Problem
1905	Vitali: nichtmessbare Menge – Notwendigkeit der σ-Algebren
1906	Markow: Markow-Ketten; 1913 Analyse von Puschkins *Eugen Onegin*
1909/17	Borel und Cantelli: Lemmata über unendlich oft eintretende Ereignisse
1922	Lindeberg: allgemeine Bedingung für den zentralen Grenzwertsatz
1923	Wiener: mathematisch strenge Konstruktion der Brownschen Bewegung
1925	Fisher: *Statistical Methods for Research Workers*; p-Wert und Signifikanzniveau
1933	**Kolmogorow: Grundbegriffe der Wahrscheinlichkeitsrechnung**
1933	Neyman und Pearson: Theorie des Hypothesentests, Fehler erster und zweiter Art
1937	de Finetti: Austauschbarkeitssatz, subjektivistische Grundlegung
1940er	Itō: stochastische Integration; Doob: Martingaltheorie
1946–49	Ulam, von Neumann, Metropolis: Monte-Carlo-Methoden in Los Alamos
1951	Simpson beschreibt das nach ihm benannte Paradoxon systematisch
1956	Stein: Unzulässigkeit des Mittelwertschätzers in Dimension ≥ 3

Zeit	Ereignis
1970	Hastings verallgemeinert den Metropolis-Algorithmus
1972	Berry und Esseen (Vorarbeiten 1941/42): Konvergenzgeschwindigkeit im ZGS
1973	Black, Scholes und Merton: Optionspreisformel über stochastische Analysis
1974	Rubin: Potential-Outcomes-Rahmen für kausale Inferenz
1984	Geman und Geman: Gibbs-Sampler; Beginn der MCMC-Revolution
1990er	Pearl: kausale Graphen, Do-Kalkül, Backdoor-Kriterium
1995	Benjamini und Hochberg: False Discovery Rate
1995	Gigerenzer und Hoffrage: natürliche Häufigkeiten verbessern das Verständnis
1996	Talagrand: Konzentrationsungleichungen für Produktmaße
2005	Ioannidis: *Why Most Published Research Findings Are False*
2011	Simmons u. a.: *False-Positive Psychology*; Beginn der Replikationsdebatte
2015	Open Science Collaboration: nur 36 von 100 psychologischen Studien repliziert
2016	American Statistical Association: offizielle Stellungnahme zu p-Werten
2019	Nature-Kommentar von über 800 Unterzeichnern: „Retire statistical significance“
2021	Nobelpreis für Wirtschaftswissenschaften an Card, Angrist und Imbens (Kausalanalyse)
2024	Abelpreis an Michel Talagrand
2026	Stand dieses Buches

D Glossar

σ-Algebra System von Teilmengen, das Ω enthält und unter Komplement und abzählbarer Vereinigung abgeschlossen ist. Zweite Lesart: Beschreibung des verfügbaren Wissens.

Wahrscheinlichkeitsraum Tripel $(\Omega, \mathcal{A}, \mathbb{P})$ aus Ergebnisraum, σ-Algebra und Wahrscheinlichkeitsmaß.

Zufallsvariable Messbare Abbildung $X : \Omega \to \mathbb{R}$. Nicht „zufällig“ und keine „Variable“, sondern eine Funktion.

Verteilungsfunktion $F(x) = \mathbb{P}(X \leq x)$; monoton wachsend, rechtsstetig, mit Grenzwerten 0 und 1.

Dichte Funktion f mit $F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$. *Kein* Wahrscheinlichkeitswert – sie darf größer als 1 sein.

Erwartungswert Integral $\mathbb{E}[X] = \int X\,\mathrm{d}\mathbb{P}$; das mit Wahrscheinlichkeiten gewichtete Mittel. Existiert nicht immer (Cauchy-Verteilung).

Varianz $\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2]$; mittlere quadratische Abweichung vom Erwartungswert.

Kovarianz $\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}X\,\mathbb{E}Y$; misst den *linearen* Zusammenhang.

Unabhängigkeit $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$; für mehrere Ereignisse für alle Teilmengen zu fordern (paarweise genügt nicht).

Bedingte Wahrscheinlichkeit $\mathbb{P}(A \mid B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$; Neunormierung auf den eingeschränkten Raum.

Bedingte Erwartung $\mathbb{E}[X \mid \mathcal{F}]$ – die beste Vorhersage von X bei Kenntnis von $\mathcal{F}$; selbst eine Zufallsvariable.

Fast sicher Mit Wahrscheinlichkeit 1. Nicht dasselbe wie „immer“: Ausnahmen der Wahrscheinlichkeit 0 sind erlaubt.

Konvergenz in Verteilung $F_n(x) \to F(x)$ an allen Stetigkeitsstellen; schwächster der vier Konvergenzbegriffe.

Charakteristische Funktion $\varphi_X(t) = \mathbb{E}[\mathrm{e}^{\mathrm{i}tX}]$; bestimmt die Verteilung eindeutig, macht Faltung zu Multiplikation.

Erzeugende Funktion $G_X(s) = \mathbb{E}[s^X]$ für $\mathbb{N}_0$-wertige Zufallsvariablen; liefert Verteilung und Momente durch Ableiten.

Faltung Verteilung der Summe unabhängiger Zufallsvariablen; $f_{X+Y} = f_X * f_Y$.

Markow-Kette Prozess ohne Gedächtnis: Die Zukunft hängt nur vom gegenwärtigen Zustand ab, nicht vom Weg dorthin.

Stationäre Verteilung Linker Eigenvektor π der Übergangsmatrix zum Eigenwert 1 mit $\sum \pi_i = 1$.

Martingal Prozess mit $\mathbb{E}[X_{n+1} \mid \mathcal{F}_n] = X_n$; Modell eines fairen Spiels.

Stoppzeit Zufällige Zeit, deren Eintreten zum Zeitpunkt n allein aus der bis dahin verfügbaren Information erkennbar ist.

Filtration Aufsteigende Folge von σ-Algebren; formalisiert den Informationszuwachs über die Zeit.

Schätzer Funktion der Stichprobe zur Schätzung eines Parameters; selbst eine Zufallsvariable.

Erwartungstreue $\mathbb{E}[\hat{\theta}] = \theta$. Wünschenswert, aber nicht um jeden Preis (Stein-Paradoxon).

Konfidenzintervall Zufälliges Intervall, das den wahren Wert bei wiederholter Anwendung in 95 % der Fälle überdeckt. *Nicht*: Der Parameter liegt mit 95 % darin.

p-Wert $\mathbb{P}(\text{Daten mindestens so extrem} \mid H_0)$. *Nicht* die Wahrscheinlichkeit, dass H_0 zutrifft.

Fehler 1. Art Ablehnung einer richtigen Nullhypothese; Wahrscheinlichkeit α.

Fehler 2. Art Beibehaltung einer falschen Nullhypothese; Wahrscheinlichkeit β. Power $= 1 - \beta$.

Confounder Gemeinsame Ursache von Exposition und Ergebnis; verzerrt den beobachteten Zusammenhang.

Kollider Gemeinsame *Folge* zweier Variablen. Adjustieren erzeugt hier eine Scheinkorrelation (Berkson-Verzerrung).

False Discovery Rate Erwarteter Anteil falscher Entdeckungen unter allen Ablehnungen; kontrolliert durch Benjamini–Hochberg.

E Kommentierte Literatur

[1] Agresti, A.: *Categorical Data Analysis.* 3. Auflage, Wiley, Hoboken 2013.

Standardwerk zu Kontingenztafeln und Anteilsschätzung. Enthält die maßgebliche Kritik am Wald-Intervall und die Begründung für Wilson- und Agresti–Coull-Intervalle.

[2] Amrhein, V., Greenland, S., McShane, B.: *Retire Statistical Significance.* Nature 567 (2019), 305–307.

Von über 800 Wissenschaftlern unterzeichneter Kommentar. Fordert nicht die Abschaffung von p-Werten, sondern der dichotomen Entscheidung an einer willkürlichen Schwelle. Kurz, präzise, sehr lesenswert.

[3] Benjamini, Y., Hochberg, Y.: *Controlling the False Discovery Rate.* Journal of the Royal Statistical Society B 57 (1995), 289–300.

Der meistzitierte statistische Aufsatz der letzten Jahrzehnte. Ersetzt die oft zu konservative Bonferroni-Korrektur durch ein Verfahren, das den *Anteil* falscher Entdeckungen kontrolliert. Grundlage jeder Genomanalyse.

[4] Bernoulli, J.: *Ars conjectandi.* Basel 1713. Deutsch: *Wahrscheinlichkeitsrechnung*, Ostwalds Klassiker 107/108.

Enthält das erste Gesetz der großen Zahlen mit Beweis. Bernoulli arbeitete zwanzig Jahre daran; das Werk erschien acht Jahre nach seinem Tod. Historisch faszinierend, mathematisch mühsam zu lesen.

[5] von Bortkiewicz, L.: *Das Gesetz der kleinen Zahlen.* Teubner, Leipzig 1898.

Die berühmte Untersuchung der durch Pferdetritte getöteten Soldaten in preußischen Armeekorps. Das kanonische Beispiel für die Poisson-Verteilung – und eine der ersten sorgfältigen Anpassungsprüfungen überhaupt.

[6] Casella, G., Berger, R. L.: *Statistical Inference.* 2. Auflage, Duxbury, Pacific Grove 2002.

Das Standardlehrbuch der mathematischen Statistik im angelsächsischen Raum. Deckt Schätztheorie, Testtheorie und asymptotische Verfahren vollständig ab. Voraussetzung: Analysis und Wahrscheinlichkeitsrechnung auf dem Niveau dieses Bandes.

[7] de Finetti, B.: *Theory of Probability.* 2 Bände, Wiley, London 1974/75.

Die konsequenteste subjektivistische Darstellung. Beginnt mit dem Satz, Wahrscheinlichkeit existiere nicht – gemeint ist: nicht als objektive Eigenschaft der Welt. Philosophisch anspruchsvoll, mathematisch eigenwillig.

[8] Durrett, R.: *Probability: Theory and Examples.* 5. Auflage, Cambridge University Press 2019.

Maßtheoretische Wahrscheinlichkeitstheorie auf Graduiertenniveau, mit ungewöhnlich vielen ausgearbeiteten Beispielen. Die natürliche Fortsetzung nach diesem Band, wenn man in die Forschung will.

[9] Feller, W.: *An Introduction to Probability Theory and Its Applications.* 2 Bände, Wiley, New York 1968/71.

Ein Klassiker, der seit sechzig Jahren nicht ersetzt wurde. Band 1 (diskret) ist mit Schulmathematik lesbar und dennoch tief. Fellers Beispiele sind unübertroffen; wer Stochastik lieben lernen will, fängt hier an.

[10] Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., Rubin, D. B.: *Bayesian Data Analysis.* 3. Auflage, CRC Press, Boca Raton 2013.

Das maßgebliche Werk zur angewandten Bayes-Statistik. Behandelt Priorwahl, MCMC, Modellprüfung und hierarchische Modelle. Pragmatisch statt dogmatisch – Gelman nennt sich selbst einen Bayesianer, der Modelle falsifiziert.

[11] Gigerenzer, G., Hoffrage, U.: *How to Improve Bayesian Reasoning Without Instruction: Frequency Formats.* Psychological Review 102 (1995), 684–704.

Zeigt experimentell, dass natürliche Häufigkeiten das Bayes-Verständnis dramatisch verbessern. Für die medizinische Aus- und Fortbildung eine der praktisch folgenreichsten Arbeiten der kognitiven Psychologie.

[12] Hastie, T., Tibshirani, R., Friedman, J.: *The Elements of Statistical Learning.* 2. Auflage, Springer, New York 2009.

Die Brücke zwischen Statistik und maschinellem Lernen. Frei verfügbar auf der Seite der Autoren. Behandelt Regularisierung, Bias-Varianz-Zerlegung und Ensemble-Methoden mit statistischer Strenge.

[13] Hernán, M. A., Robins, J. M.: *Causal Inference: What If.* CRC Press, Boca Raton 2020.

Kausale Inferenz aus epidemiologischer Perspektive, mit Schwerpunkt auf Zielemulation aus Beobachtungsdaten. Frei verfügbar. Für Ärzte und Epidemiologen der praktischere Zugang als Pearl.

[14] Ioannidis, J. P. A.: *Why Most Published Research Findings Are False.* PLoS Medicine 2 (2005), e124.

Der meistgelesene Aufsatz in der Geschichte von PLoS. Rechnet mit einem einfachen Bayes-Argument vor, unter welchen Bedingungen die Mehrzahl signifikanter Befunde falsch positiv sein muss. Die Argumentation ist elementar und nachvollziehbar.

[15] Karatzas, I., Shreve, S. E.: *Brownian Motion and Stochastic Calculus.* 2. Auflage, Springer, New York 1991.

Das Standardwerk zur stochastischen Analysis. Brownsche Bewegung, Itō-Integral, Martingaldarstellung, stochastische Differentialgleichungen. Anspruchsvoll, aber die Referenz für alles, was in Kapitel 13 nur angedeutet wurde.

[16] Klenke, A.: *Wahrscheinlichkeitstheorie.* 4. Auflage, Springer Spektrum, Berlin 2020.

Das deutschsprachige Standardwerk. Vollständig maßtheoretisch, von den Grundlagen bis zu Perkolation und stochastischen Prozessen. Der natürliche nächste Schritt für deutschsprachige Leser nach diesem Band.

[17] Kolmogoroff, A.: *Grundbegriffe der Wahrscheinlichkeitsrechnung.* Springer, Berlin 1933.

Die Axiomatisierung des Fachs auf 62 Seiten. Bemerkenswert lesbar; wer die Maßtheorie kennt, kann das Original an einem Nachmittag durcharbeiten und sollte es tun.

[18] Laplace, P.-S.: *Théorie analytique des probabilités.* Courcier, Paris 1812; *Essai philosophique sur les probabilités.* Paris 1814.

Die Summe des klassischen Wissens vor der Axiomatisierung. Der *Essai* ist die allgemeinverständliche Fassung – und enthält den berühmten Satz vom „auf Rechnen zurückgeführten gesunden Menschenverstand".

[19] Markov, A. A.: *Ein Beispiel statistischer Untersuchung des Textes „Eugen Onegin".* Bulletin der Kaiserlichen Akademie der Wissenschaften, St. Petersburg 1913.

Markow zählte von Hand 20 000 Buchstaben aus Puschkins Versroman aus, um zu zeigen, dass das Gesetz der großen Zahlen auch für abhängige Folgen gilt. Die erste Anwendung von Markow-Ketten überhaupt – und ein Vorläufer der Sprachmodellierung.

[20] Open Science Collaboration: *Estimating the Reproducibility of Psychological Science.* Science 349 (2015), aac4716.

270 Autoren wiederholten 100 publizierte Studien. Nur 36 lieferten ein signifikantes Ergebnis in derselben Richtung; die mittlere Effektstärke halbierte sich. Der Auslöser der Replikationskrise in ihrer heutigen Form.

[21] Pearl, J.: *Causality: Models, Reasoning, and Inference.* 2. Auflage, Cambridge University Press 2009.

Begründet die grafische Theorie der Kausalität: gerichtete azyklische Graphen, Do-Operator, Backdoor-Kriterium. Beantwortet die Frage, nach welchen Variablen adjustiert werden darf. Populär aufbereitet in *The Book of Why* (2018).

[22] Pólya, G.: *Über eine Aufgabe der Wahrscheinlichkeitsrechnung betreffend die Irrfahrt im Straßennetz.* Mathematische Annalen 84 (1921), 149–160.

Der Satz über die Rückkehr der Irrfahrt: rekurrent in einer und zwei Dimensionen, transient ab drei. Pólya kam auf die Frage, als er im Park zufällig wiederholt demselben Paar begegnete.

[23] Rubin, D. B.: *Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies.* Journal of Educational Psychology 66 (1974), 688–701.

Führt die potentiellen Ergebnisse ein: Für jede Person existieren beide Behandlungsverläufe, beobachtbar ist nur einer. Das Grundproblem der kausalen Inferenz in einem Satz.

[24] Simmons, J. P., Nelson, L. D., Simonsohn, U.: *False-Positive Psychology.* Psychological Science 22 (2011), 1359–1366.

Zeigt durch Simulation und ein absichtlich absurdes Experiment, dass übliche Freiheitsgrade bei der Auswertung die Falsch-Positiv-Rate von 5 % auf über 60 % treiben. Prägte den Begriff *p-hacking*.

[25] Stein, C.: *Inadmissibility of the Usual Estimator for the Mean of a Multivariate Normal Distribution.* Proceedings of the Third Berkeley Symposium, Band 1 (1956), 197–206.

Ab drei Dimensionen ist der Mittelwert kein zulässiger Schätzer mehr – ein Ergebnis, das die Fachwelt zunächst für einen Irrtum hielt. Der Ausgangspunkt der Shrinkage-Verfahren und damit der modernen Regularisierung.

[26] van der Vaart, A. W.: *Asymptotic Statistics.* Cambridge University Press 1998.

Die maßgebliche Darstellung der asymptotischen Theorie: Delta-Methode, Maximum-Likelihood-Asymptotik, empirische Prozesse. Kompakt geschrieben und anspruchsvoll, aber ohne Alternative.

[27] Wasserstein, R. L., Lazar, N. A.: *The ASA Statement on p-Values.* The American Statistician 70 (2016), 129–133.

Die erste offizielle Stellungnahme der American Statistical Association zu einem methodischen Verfahren in 177 Jahren Verbandsgeschichte. Sechs Prinzipien, jedes einzelne in der Praxis regelmäßig verletzt.

[28] Williams, D.: *Probability with Martingales.* Cambridge University Press 1991.

Führt die gesamte maßtheoretische Wahrscheinlichkeitstheorie über Martingale ein – ein ungewöhnlicher und sehr eleganter Aufbau. Knapp 250 Seiten, mit trockenem Humor geschrieben. Eines der besten Mathematikbücher überhaupt.

Wenn Sie nur drei Bücher kaufen

Feller, Band 1 – um zu sehen, wie schön das Fach sein kann.
Klenke – um es auf Deutsch und vollständig zu lernen.
Hernán und Robins – um zu verstehen, warum die meisten Anwendungen scheitern.