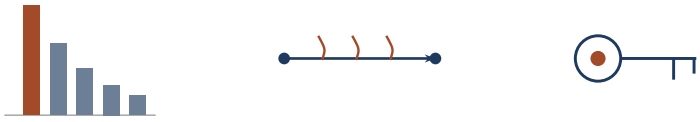
Mathematik von Grund auf — Band 20

Was Nachrichten wiegen

Information und Kryptographie



messen *übertragen* *verbergen*

Von der Entropie bis zum Schlüsseltausch

Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Stand der Forschung: August 2026

Mathematik von Grund auf — Band 20
Was Nachrichten wiegen · Information und Kryptographie

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Simulationen, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/mathematik-von-grund-auf`
Dauerhaft archiviert und zitierbar über Zenodo (DOI siehe dort).

Zitiervorschlag
Maier, J. (2026). *Mathematik von Grund auf, Band 20: Was Nachrichten wiegen*. Fassung 1.0.

Satz: LaTeX mit Palatino. Stand: Oktober 2026. 242 Seiten.

Inhaltsverzeichnis

Vorwort **1**

I Information messen **7**

1 Was Information ist **9**

1.1 Der Leitfall . . . 9
1.2 Was Information nicht ist . . . 9
1.3 Der Informationsgehalt eines Ereignisses . . . 10
1.4 Die Eigenschaften . . . 13
1.5 Der Bruchfall . . . 14
1.6 Übungsaufgaben . . . 15

2 Entropie **23**

2.1 Der Mittelwert . . . 23
2.2 Die Grenzen . . . 24
2.3 Die binäre Entropiefunktion . . . 26
2.4 Mehrere Größen . . . 27
2.5 Der Bruchfall . . . 29
2.6 Übungsaufgaben . . . 30

3 Quellencodierung **37**

3.1 Was ein brauchbarer Code leisten muss . . . 37
3.2 Die Kraftsche Ungleichung . . . 38
3.3 Die untere Schranke . . . 39
3.4 Die obere Schranke . . . 40
3.5 Das Huffman-Verfahren . . . 41
3.6 Blöcke codieren . . . 43
3.7 Der Bruchfall . . . 45
3.8 Übungsaufgaben . . . 45

II Der gestörte Kanal **53**

4 Transinformation und Kapazität **55**

4.1 Der Leitfall . . . 55
4.2 Transinformation . . . 55
4.3 Die relative Entropie . . . 56
4.4 Die Kanalkapazität . . . 58
4.5 Andere Kanäle . . . 60
4.6 Der Bruchfall . . . 60
4.7 Übungsaufgaben . . . 62

5 Das Kanalcodierungstheorem **69**

5.1 Die Aussage . . . 69
5.2 Typische Folgen . . . 69
5.3 Der Beweisgedanke . . . 71
5.4 Die Umkehrung . . . 73
5.5 Der Bruchfall . . . 75
5.6 Übungsaufgaben . . . 76

6 Fehlerkorrigierende Codes **83**

6.1 Der Hamming-Abstand . . . 83
6.2 Lineare Codes . . . 84
6.3 Der Hamming-Code . . . 84
6.4 Was Codes leisten . . . 86
6.5 Drei Schranken . . . 87
6.6 Reed-Solomon und Bündelfehler . . . 88
6.7 Der Bruchfall . . . 90
6.8 Übungsaufgaben . . . 91

III Zufall und Komplexität **97**

7 Kolmogorow-Komplexität **99**

7.1 Die offene Frage . . . 99
7.2 Die Definition . . . 100
7.3 Die meisten Folgen sind zufällig . . . 101
7.4 Die Komplexität ist nicht berechenbar . . . 103
7.5 Der Zusammenhang zur Entropie . . . 104

7.6 Der Bruchfall 105
7.7 Übungsaufgaben 106

8 Information in der Statistik **113**
8.1 Was die relative Entropie misst 113
8.2 Fisher-Information 115
8.3 Modellwahl als Kompression 116
8.4 Der Bruchfall 118
8.5 Übungsaufgaben 119

IV Geheimhaltung **127**

9 Perfekte Sicherheit **129**
9.1 Der Leitfall 129
9.2 Warum klassische Verfahren brechen 130
9.3 Perfekte Sicherheit 130
9.4 Shannons Schranke 131
9.5 Die Unizitätsdistanz 133
9.6 Der Bruchfall 134
9.7 Übungsaufgaben 135

10 Blockchiffren **141**
10.1 Der Übergang 141
10.2 Verwirrung und Verwischung 142
10.3 Betriebsarten 143
10.4 Der Bruchfall 145
10.5 Übungsaufgaben 146

11 Hashfunktionen und Unversehrtheit **153**
11.1 Die fehlende Eigenschaft 153
11.2 Drei Anforderungen 153
11.3 Beglaubigung 156
11.4 Zwei Anwendungen 157
11.5 Der Bruchfall 159
11.6 Übungsaufgaben 159

V Öffentliche Schlüssel **167**

12 Schlüsseltausch über offene Leitung **169**

12.1 Das Problem . . . 169
12.2 Rechnen mit Resten . . . 170
12.3 Das Verfahren . . . 171
12.4 Wie schwer ist es wirklich . . . 173
12.5 Der Bruchfall . . . 174
12.6 Übungsaufgaben . . . 176

13 RSA **181**

13.1 Die andere Aufgabe . . . 181
13.2 Der Satz von Euler . . . 181
13.3 Das Verfahren . . . 182
13.4 Wie sicher ist es . . . 184
13.5 Der Bruchfall . . . 185
13.6 Übungsaufgaben . . . 187

14 Elliptische Kurven und Signaturen **195**

14.1 Warum eine andere Gruppe . . . 195
14.2 Die Kurve . . . 195
14.3 Über endlichen Körpern . . . 197
14.4 Signaturen . . . 199
14.5 Der Bruchfall . . . 201
14.6 Übungsaufgaben . . . 202

VI Aktueller Stand **209**

15 Was Information leistet **211**

15.1 Die Bedrohung . . . 211
15.2 Was an die Stelle tritt . . . 212
15.3 Vier Muster . . . 214
15.4 Was nicht die Mathematik ist . . . 216
15.5 Sechs Sätze, die bleiben . . . 217

VII Anhang **219**

A Formelsammlung und Übersicht **221**

A.1 Information messen 221

A.2 Der Kanal 222

A.3 Zufall und Statistik 223

A.4 Kryptographie 223

A.5 Die Landkarte des Bandes 225

A.6 Zeittafel 227

A.7 Glossar 229

B Kommentierte Quellen **231**

Vorwort: Eine Größe, die niemand vermutet hatte

Bis 1948 war "Information" kein mathematischer Begriff. Danach war sie eine messbare Größe mit einer Einheit — und mit Sätzen, die bis heute überraschen.

Was dieser Band behauptet

Eine Nachricht hat ein Gewicht, das sich in Bit angeben lässt — und dieses Gewicht hängt nicht davon ab, was sie bedeutet, sondern nur davon, wie überraschend sie ist.

Das ist eine ungewöhnliche Behauptung, und sie hat einen Preis: Der Begriff sagt nichts über Bedeutung, Wahrheit oder Nutzen. Was er dafür leistet, sind Sätze von seltener Schärfe — über Grenzen, die niemand unterbieten kann, und über Verfahren, die sie erreichen.

Drei Ergebnisse, die der Anschauung widersprechen

Was in diesem Band bewiesen wird

Kapitel 3	Es gibt eine Grenze, unter die keine Kompression kommen kann — und Verfahren, die ihr beliebig nahe kommen.
Kapitel 5	Über einen *gestörten* Kanal lässt sich mit beliebig kleiner Fehlerrate übertragen. Nicht langsamer, sondern nur bis zu einer festen Rate.
Kapitel 9	Es gibt eine Verschlüsselung, die beweisbar unbrechbar ist — und einen Satz, der sagt, warum sie praktisch unbrauchbar bleibt.

Die mittlere Aussage ist die erstaunlichste. Vor 1948 hielt man es für selbstverständlich, dass Störungen die Fehlerrate erhöhen und man sie nur durch Wiederholung senken kann — also durch Verlangsamung.

*Shannon zeigte, dass das falsch ist. Es gibt eine feste Rate, die **Kanalkapazität**, unterhalb derer die Fehlerrate beliebig klein gemacht werden kann, ohne die Rate weiter zu senken. Oberhalb davon geht es gar nicht. Der Übergang ist scharf.*

Warum Kryptographie in denselben Band gehört

Derselbe Begriff, andere Richtung

	Teil I–III	**Teil IV–V**
Ziel	Information erhalten	Information verbergen
Gegner	Rauschen	ein Mitleser
Maß	Entropie	Entropie
Grenze	Kapazität	Schlüssellänge

Shannon hat beide Gebiete begründet — 1948 die Informationstheorie, 1949 die mathematische Kryptographie. Beide Arbeiten benutzen denselben Entropiebegriff.

Der Zusammenhang ist kein historischer Zufall. Perfekte Geheimhaltung bedeutet, dass der Geheimtext keine Information über den Klartext enthält — und das ist eine Aussage über Transinformation, also über genau die Größe aus Kapitel 4. Kapitel 9 beweist daraus, wie lang ein Schlüssel mindestens sein muss.

Was Sie mitbringen müssen

Die Voraussetzungen

Logarithmen	Rechenregeln, Basiswechsel. Schulmathematik.
Wahrscheinlichkeit	Verteilungen, Erwartungswert, Unabhängigkeit, bedingte Wahrscheinlichkeit. Band 12.
Konvexität	Nur die Jensensche Ungleichung, ab Kapitel 2. Band 19, Kapitel 7.
Modulare Arithmetik	Erst ab Kapitel 11 — und dort von Grund auf eingeführt. Band 8.
Gruppen	Erst ab Kapitel 12, ebenfalls dort erklärt. Band 6.

Die erste Hälfte kommt mit Wahrscheinlichkeitsrechnung aus. Die zweite braucht Zahlentheorie — aber nur einen kleinen, genau umrissenen Teil davon, der in den Kapiteln 11 und 12 vollständig entwickelt wird. Man muss Band 8 nicht gelesen haben.

Das Klinikum Neustadt

Der Leitfall

Wie in den Bänden 17 bis 19 läuft ein einziger erfundener Fall durch alle Kapitel — diesmal die Digitalisierung eines Krankenhauses.

Teil	Thema	Der Leitfall zeigt
I	Messen	wie klein Befunddaten werden können
II	Übertragen	Funk zum Rettungswagen
III	Zufall	was ein Datensatz hergibt
IV	Geheimhalten	Patientendaten verschlüsseln
V	Öffentliche Schlüssel	Arztbriefe signieren
VI	Stand	was morgen noch sicher ist

Drei Warnungen

Erstens: Information ist nicht Bedeutung

Der Informationsgehalt einer Nachricht hängt allein von ihrer Wahrscheinlichkeit ab.

> Eine zufällige Zeichenfolge hat mehr Information als ein Satz gleicher Länge — weil sie unvorhersehbarer ist. Für die Übertragungstechnik ist das die richtige Größe. Für die Frage, was eine Nachricht *wert* ist, taugt sie nicht.

Zweitens: Sätze gelten für Grenzwerte

Shannons Ergebnisse sind Aussagen über beliebig lange Nachrichten.

> *"Beliebig kleine Fehlerrate" heißt: für hinreichend große Blocklänge. Wie groß, sagt der Satz nicht — und für praktische Blocklängen kann die Lücke erheblich sein. Kapitel 6 behandelt, was tatsächlich erreichbar ist.*

Drittens: Sicherheit ist nicht beweisbar

Mit einer einzigen Ausnahme — dem Einmalschlüssel aus Kapitel 9 — beruht jedes praktisch verwendete Verfahren auf einer *Annahme*.

> **Man nimmt an, dass ein bestimmtes Rechenproblem schwer ist. Bewiesen ist das bei keinem einzigen.**
>
> *Das ist derselbe Stand wie bei* P *gegen* NP *in Band 19, Kapitel 12 — und hängt unmittelbar damit zusammen. Wäre* P = NP*, so wäre nahezu die gesamte heutige Kryptographie hinfällig.* ***Die Sicherheit der digitalen Welt ruht auf einer unbewiesenen Vermutung****, und dieser Band sagt das an jeder Stelle, an der es zutrifft.*

Der Aufbau

Sechs Teile, fünfzehn Kapitel

Teil	Thema	Die Leitfrage
I	Information messen (1–3)	Wie klein geht es?
II	Der gestörte Kanal (4–6)	Wie schnell geht es fehlerfrei?
III	Zufall (7–8)	Was heißt zufällig?
IV	Geheimhaltung (9–11)	Was ist beweisbar sicher?
V	Öffentliche Schlüssel (12–14)	Wie tauscht man Schlüssel ohne Kanal?
VI	Stand (15)	Was hält dem Quantenrechner stand?

Information ist die Auflösung
von Ungewissheit.

— nach Claude Shannon, 1948

Teil I

Information messen

Kapitel 1

Was Information ist

1.1 Der Leitfall

Das Klinikum Neustadt wird digital

Jeder Behandlungsfall erhält einen Diagnoseschlüssel aus acht Gruppen. Die Häufigkeiten über ein Jahr:

Gruppe	Anteil	Gruppe	Anteil
A	0,2500	*E*	0,0625
B	0,2500	*F*	0,0625
C	0,1250	*G*	0,0625
D	0,1250	*H*	0,0625

Die naheliegende Codierung

Acht Gruppen, also drei Bit je Fall: 000 für *A*, 001 für *B* und so fort.
Die Frage: Geht es kürzer?

> *Die Antwort lautet ja — und zwar auf* 2,75 *Bit im Mittel, nicht weniger. Beide Teile dieser Aussage sind Sätze: dass es geht, und dass es nicht besser geht. Kapitel 3 beweist sie. Zuvor muss geklärt werden, woher die Zahl* 2,75 *kommt.*

1.2 Was Information nicht ist

Drei Verwechslungen

Bedeutung	"Der Patient lebt" und "der Patient ist verstorben" können denselben Informationsgehalt haben. Der Begriff misst nicht, was es bedeutet.
Wahrheit	Eine falsche Nachricht hat denselben Gehalt wie eine richtige gleicher Wahrscheinlichkeit.
Nutzen	Eine unwahrscheinliche und völlig belanglose Nachricht hat viel Information.

Der Informationsgehalt misst allein, wie sehr eine Nachricht die Ungewissheit des Empfängers auflöst.

Shannon hat das ausdrücklich betont: Die Bedeutungsfrage sei für das technische Problem unerheblich. Das wurde ihm oft als Mangel ausgelegt und ist der Grund für den Erfolg der Theorie — eine Größe, die von der Bedeutung absieht, gilt für jede Art von Nachricht gleichermaßen.

1.3 Der Informationsgehalt eines Ereignisses

Drei Forderungen

Wir suchen eine Funktion $I(p)$, die den Gehalt eines Ereignisses der Wahrscheinlichkeit p angibt.

1	I hängt nur von p ab und ist stetig.
2	I ist monoton fallend: Seltenes überrascht mehr.
3	Für unabhängige Ereignisse addieren sich die Gehalte: $$I(p \cdot q) = I(p) + I(q)$$

Warum die dritte Forderung

Erfährt man zwei unabhängige Dinge, so soll die Gesamtinformation die Summe sein. Die Wahrscheinlichkeit des gemeinsamen Ereignisses ist das *Produkt*.

Gesucht ist also eine Funktion, die Produkte in Summen verwandelt. Damit ist die Antwort im Grunde schon gegeben.

Satz 1.1 — die Forderungen legen I fest

Erfüllt $I : (0,1] \to \mathbb{R}$ die drei Forderungen, so gibt es eine Konstante $C > 0$ mit

$$I(p) = -C \ln p.$$

Beweis — Schritt 1: die Substitution
Wir setzen $p = e^{-x}$ mit $x \geq 0$ und definieren

$$g(x) := I(e^{-x}).$$

Da $p \mapsto -\ln p$ stetig und streng fallend ist, ist g stetig.

Schritt 2 — die Funktionalgleichung
Aus $I(pq) = I(p) + I(q)$ mit $p = e^{-x}$ und $q = e^{-y}$, also $pq = e^{-(x+y)}$:

$$g(x+y) = g(x) + g(y) \qquad \text{für alle } x, y \geq 0.$$

Schritt 3 — ganzzahlige Vielfache
Setzt man $y = x$, so folgt $g(2x) = 2g(x)$; durch Wiederholung

$$g(nx) = n\, g(x) \qquad \text{für alle } n \in \mathbb{N}.$$

Mit $x = \frac{1}{n}$ und $c := g(1)$:

$$c = g(1) = g\left(n \cdot \tfrac{1}{n}\right) = n\, g\left(\tfrac{1}{n}\right) \quad \Longrightarrow \quad g\left(\tfrac{1}{n}\right) = \tfrac{c}{n}$$

Schritt 4 — rationale Zahlen
Für $x = \frac{m}{n}$:

$$g\left(\tfrac{m}{n}\right) = m\, g\left(\tfrac{1}{n}\right) = \tfrac{m}{n}\, c$$

Schritt 5 — alle reellen Zahlen
Die Funktion g ist stetig und stimmt auf den rationalen Zahlen mit $x \mapsto cx$ überein. Da die rationalen Zahlen dicht liegen, gilt

$$g(x) = c\, x \qquad \text{für alle } x \geq 0.$$

Schritt 6 — zurückübersetzen
Mit $x = -\ln p$:

$$I(p) = g(-\ln p) = -c \ln p$$

Aus Forderung 2 folgt $c > 0$: Für kleineres p ist $-\ln p$ größer, und I soll dann größer sein. ■

> *Bemerkenswert ist, wie wenig gefordert wurde. Drei sehr schwache Bedingungen — Stetigkeit, Monotonie, Additivität bei Unabhängigkeit — legen die Funktion bis auf einen Faktor vollständig fest. Der Faktor bestimmt nur die Maßeinheit.*

Definition 1.2 — das Bit

Wählt man $C = \frac{1}{\ln 2}$, so wird

$$I(p) = -\operatorname{ld} p = \operatorname{ld} \frac{1}{p}$$

mit dem Logarithmus zur Basis 2. Die Einheit heißt **Bit**.

Warum die Basis zwei

Ein Ereignis der Wahrscheinlichkeit $\frac{1}{2}$ hat genau ein Bit Information.

$$I\left(\tfrac{1}{2}\right) = \operatorname{ld} 2 = 1$$

Das entspricht einer Ja-Nein-Frage: Der Ausgang eines fairen Münzwurfs ist genau ein Bit.

Die Werte im Leitfall

Gruppe	p	$1/p$	$I = \operatorname{ld}(1/p)$
A, *B*	0,2500	4	2 Bit
C, *D*	0,1250	8	3 Bit
E–*H*	0,0625	16	4 Bit

Die häufigen Gruppen tragen zwei Bit, die seltenen vier. Genau darauf beruht die Ersparnis: Man gibt den häufigen Fällen kurze Codewörter.

Andere Einheiten

Basis	**Einheit**	**Umrechnung**
2	Bit	—
e	Nat	1 Nat = 1,443 Bit
10	Hartley	1 Hartley = 3,322 Bit

Die Umrechnung ist ein reiner Basiswechsel: $\operatorname{ld} x = \frac{\ln x}{\ln 2}$, *und* $\frac{1}{\ln 2} = 1{,}4427$. *In der Theorie rechnet man oft mit Nat, weil die Ableitungen einfacher werden; in der Technik stets mit Bit.*

1.4 Die Eigenschaften

Was die Formel leistet

p	$I(p)$	**Deutung**
1	0	Sicheres trägt nichts bei
0,5	1 Bit	Münzwurf
0,01	6,64 Bit	seltenes Ereignis
10^{-6}	19,93 Bit	sehr seltenes
$\to 0$	$\to \infty$	unbeschränkt

Die erste Zeile

$$I(1) = \operatorname{ld} 1 = 0$$

Die Mitteilung eines sicheren Ereignisses trägt null Bit. Wer sagt, dass die Sonne aufgegangen ist, teilt nichts mit.

Die letzte Zeile

Je unwahrscheinlicher, desto mehr Information — ohne obere Grenze.

Das Wachstum ist allerdings langsam: Eine millionenfach kleinere Wahrscheinlichkeit bringt nur den Faktor 20 statt 6,64, also gut das Dreifache. Der Logarithmus dämpft stark — und genau das macht die Größe handhabbar.

Die Additivität nachgerechnet

Zwei unabhängige Befunde: Gruppe A ($p = 0{,}25$) und ein positiver Laborwert ($p = 0{,}125$).

Ereignis	p	I
Gruppe A	0,2500	2 Bit
Labor positiv	0,1250	3 Bit
beides	0,03125	**5** Bit

Probe: $0{,}25 \cdot 0{,}125 = 0{,}03125 = \frac{1}{32}$, und $\operatorname{ld} 32 = 5$. ✓

Die Additivität ist keine Eigenschaft, die man beobachtet hätte — sie war die Forderung, aus der die Formel folgte. Das ist die übliche Reihenfolge in der Informationstheorie: Man schreibt auf, was eine Größe leisten soll, und findet, dass es nur eine gibt.

1.5 Der Bruchfall

Was vorausgesetzt wird

Die Verteilung	$I(p)$ setzt voraus, dass p bekannt ist. In der Praxis wird sie geschätzt — mit allen Schwierigkeiten aus Band 17.
Unabhängigkeit	Forderung 3 gilt nur dort. Bei abhängigen Ereignissen ist die Summe der Einzelgehalte zu groß.
Ein Empfänger	Der Gehalt hängt davon ab, was der Empfänger schon weiß. Für verschiedene Empfänger ist er verschieden.

Zur zweiten Zeile

Diagnosegruppe und Laborwert sind in Wirklichkeit nicht unabhängig. Gilt etwa

$$\Pr[\text{Labor} \mid A] = 0{,}5 \quad \text{statt} \quad 0{,}125,$$

so ist der gemeinsame Gehalt

$$I(0{,}25 \cdot 0{,}5) = I(0{,}125) = 3 \text{ Bit}$$

statt fünf.

> **Zwei Bit sind verschwunden — sie waren doppelt gezählt.** Diese Größe hat einen Namen: Sie ist die Transinformation zwischen Gruppe und Laborwert.
>
> *Damit ist der Begriff eingeführt, der Teil II trägt. **Abhängigkeit bedeutet, dass eine Größe etwas über die andere verrät** — und die Transinformation misst, wie viel. Kapitel 4 macht daraus eine Definition.*

Zur dritten Zeile

> *Der Informationsgehalt ist keine Eigenschaft der Nachricht, sondern der Beziehung zwischen Nachricht und Empfänger. Wer die Diagnose bereits kennt, erfährt null Bit. Das klingt nach einem Mangel und ist die richtige Modellierung: Information ist Auflösung von Ungewissheit, und Ungewissheit hat jemand.*

Und eine begriffliche Falle

Das Wort “Bit” bezeichnet zweierlei:

Als Einheit	Ein Maß für Information — kann jeden nichtnegativen reellen Wert annehmen, etwa 2,75.
Als Zeichen	Eine Binärstelle, also 0 oder 1. Davon gibt es immer ganze Zahlen.

Der ganze Teil I handelt vom Abstand zwischen beidem: Wie viele Binärstellen braucht man, um eine Information von 2,75 Bit zu übertragen?

Die Antwort ist nicht drei, sondern — im Mittel über viele Fälle — genau 2,75. Dass ein nicht ganzzahliger Wert erreichbar ist, obwohl jede einzelne Nachricht aus ganzen Binärstellen besteht, ist das erste überraschende Ergebnis dieses Bandes. Kapitel 3 zeigt, wie.

1.6 Übungsaufgaben

Aufgabe 1.1 — Informationsgehalte bestimmen

Berechnen Sie den Informationsgehalt in Bit:

(a)	Ein Würfel zeigt eine Sechs.
(b)	Ein Würfel zeigt eine gerade Zahl.
(c)	Zwei Würfel zeigen zusammen zwölf.
(d)	Eine zufällige Ziffernfolge der Länge 6.
(e)	Ein Patient gehört zur Gruppe E (Anteil 0,0625).

Lösung

(a)

$$p = \tfrac{1}{6}, \qquad I = \operatorname{ld} 6 = \frac{\ln 6}{\ln 2} = \frac{1{,}7918}{0{,}6931} = 2{,}585 \text{ Bit}$$

(b)

$$p = \tfrac{1}{2}, \qquad I = 1 \text{ Bit}$$

(c)

Beide müssen Sechsen zeigen:

$$p = \tfrac{1}{6} \cdot \tfrac{1}{6} = \tfrac{1}{36}, \qquad I = \operatorname{ld} 36 = 5{,}170 \text{ Bit}$$

Probe über die Additivität: $2 \cdot 2{,}585 = 5{,}170$ ✓

(d)

Jede der zehn Ziffern ist gleich wahrscheinlich, die Stellen sind unabhängig:

$$p = 10^{-6}, \qquad I = 6 \operatorname{ld} 10 = 6 \cdot 3{,}3219 = 19{,}93 \text{ Bit}$$

Zwanzig Bit für sechs Ziffern — das sind 3,32 Bit je Ziffer. Speichert man jede Ziffer in vier Binärstellen, so verschenkt man 0,68 Bit je Ziffer, also gut siebzehn Prozent. Genau diese Art von Verschwendung behebt Kapitel 3.

(e)

$$p = 0{,}0625 = \tfrac{1}{16}, \qquad I = \operatorname{ld} 16 = 4 \text{ Bit}$$

Die Übersicht

	p	I in Bit
(a)	0,1667	2,585
(b)	0,5000	1,000
(c)	0,0278	5,170
(d)	10^{-6}	19,93
(e)	0,0625	4,000

Bemerkenswert ist (d) im Vergleich zu (c): Eine millionenfach kleinere Wahrscheinlichkeit bringt nur den vierfachen Informationsgehalt. Der Logarithmus dämpft so stark, dass auch extrem seltene Ereignisse handhabbare Zahlen liefern.

Aufgabe 1.2 — Warum nur der Logarithmus

Prüfen Sie, welche der drei Forderungen die folgenden Funktionen verletzen.

(a)	$I(p) = 1 - p$
(b)	$I(p) = \frac{1}{p} - 1$
(c)	$I(p) = -\operatorname{ld} p$ für $p \geq \frac{1}{2}$, sonst 2
(d)	$I(p) = (-\ln p)^2$

Lösung

(a) $I(p) = 1 - p$
Forderung 1: stetig ✓
Forderung 2: fallend ✓
Forderung 3: Zu prüfen ist $I(pq) = I(p) + I(q)$:

$$1 - pq \stackrel{?}{=} (1 - p) + (1 - q) = 2 - p - q$$

Für $p = q = \frac{1}{2}$: links $1 - \frac{1}{4} = 0{,}75$, rechts $2 - 1 = 1$.
Forderung 3 verletzt.

(b) $I(p) = \frac{1}{p} - 1$

Forderungen 1 und 2: erfüllt.
Forderung 3:

$$\frac{1}{pq} - 1 \stackrel{?}{=} \frac{1}{p} + \frac{1}{q} - 2$$

Für $p = q = \frac{1}{2}$: links $4 - 1 = 3$, rechts $2 + 2 - 2 = 2$.
Verletzt.

> *Interessant ist, wie es verletzt wird: Der Gehalt wächst zu schnell. Bei $p = 10^{-6}$ lieferte diese Formel den Wert 999 999 statt 19,93. Ein solches Maß wäre von den seltenen Ereignissen beherrscht — dieselbe Schwierigkeit wie bei der Varianz in Band 17.*

(c) Die abschnittsweise Funktion

Bei $p = \frac{1}{2}$ ist $-\operatorname{ld}\frac{1}{2} = 1$; für p knapp unter $\frac{1}{2}$ springt der Wert auf 2.
Forderung 1 verletzt — nicht stetig.
Forderung 2 ist erfüllt (die Funktion fällt), *Forderung 3* nicht.

> *Dieses Beispiel zeigt, dass die Stetigkeit im Beweis von Satz 1.1 wirklich gebraucht wird: Ohne sie gibt es tatsächlich weitere Lösungen der Funktionalgleichung — allerdings sehr unangenehme, die sich nicht durch eine Formel hinschreiben lassen. Man nennt sie Hamel-Funktionen; ihre Existenz folgt aus dem Auswahlaxiom.*

(d) $I(p) = (-\ln p)^2$
Forderungen 1 und 2: erfüllt.
Forderung 3: Mit $u = -\ln p$, $v = -\ln q$ ist $-\ln(pq) = u + v$:

$$(u+v)^2 = u^2 + 2uv + v^2 \;\neq\; u^2 + v^2 \quad \text{für } u, v > 0$$

Verletzt — um den Term $2uv$.

Die Bilanz

	stetig	fallend	additiv
(a)	✓	✓	nein
(b)	✓	✓	nein
(c)	nein	✓	nein
(d)	✓	✓	nein

> *Alle vier scheitern an der Additivität — und das ist kein Zufall, sondern Satz 1.1: **Sie ist die eigentlich einschränkende Forderung.** Stetigkeit und Monotonie erfüllen unendlich viele Funktionen; die Additivität lässt nur eine übrig.*

Aufgabe 1.3 — Das Wägeproblem

Unter zwölf gleich aussehenden Münzen ist eine gefälscht — sie ist entweder leichter oder schwerer. Wie viele Wägungen mit einer Balkenwaage braucht man mindestens,

um sie zu finden *und* zu sagen, ob sie zu leicht oder zu schwer ist?

Lösung

Schritt 1 — Die zu gewinnende Information

Es gibt $12 \cdot 2 = 24$ mögliche Antworten, alle gleich wahrscheinlich:

$$I = \operatorname{ld} 24 = \frac{\ln 24}{\ln 2} = \frac{3{,}1781}{0{,}6931} = 4{,}585 \text{ Bit}$$

Schritt 2 — Die Information je Wägung

Eine Balkenwaage hat drei mögliche Ausgänge: links schwerer, rechts schwerer, Gleichgewicht.

> **Höchstens** $\operatorname{ld} 3 = 1{,}585$ Bit je Wägung — und zwar genau dann, wenn alle drei Ausgänge gleich wahrscheinlich sind.

Schritt 3 — Die untere Schranke

$$n \cdot 1{,}585 \;\geq\; 4{,}585 \quad\Longrightarrow\quad n \geq 2{,}89$$

Da n ganzzahlig ist: $n \geq 3$.

Schritt 4 — Die Probe

$$3^3 = 27 \;\geq\; 24 \quad \checkmark$$

$3^2 = 9 \;<\; 24$ — zwei Wägungen reichen nicht.

Schritt 5 — Dass drei genügen

Erste Wägung: Vier gegen vier.

Ausgang	Verdächtige	Rest
Gleichgewicht	die übrigen 4	8 Fälle
links schwerer	diese 8	8 Fälle
rechts schwerer	diese 8	8 Fälle

In jedem Fall bleiben acht Möglichkeiten. Mit zwei weiteren Wägungen sind $3^2 = 9 \geq 8$ unterscheidbar — es geht.

> *Die Durchführung der beiden Restwägungen ist eine hübsche Knobelei und steht in jedem Rätselbuch. Der Punkt hier ist ein anderer:* ***Die Informationstheorie liefert die untere Schranke, ohne dass man das Verfahren kennt.*** *Sie sagt "weniger als drei geht nicht" — und zwar bevor irgendjemand eine Wägestrategie erdacht hat.*

Schritt 6 — Die Verallgemeinerung

Bei m Münzen sind $2m$ Antworten zu unterscheiden, also

$$n \;\geq\; \frac{\operatorname{ld}(2m)}{\operatorname{ld} 3} = \log_3(2m).$$

m	$2m$	**Schranke**
4	8	2
12	24	3
13	26	3
14	28	**4**
39	78	4

Bei dreizehn Münzen sagt die Schranke drei, und tatsächlich genügen drei nicht ganz — man kann die Fälschung finden, aber nicht immer sagen, ob sie leichter oder schwerer ist. ***Eine informationstheoretische Schranke ist notwendig, nicht hinreichend.*** *Sie schließt aus, sie garantiert nicht. Derselbe Vorbehalt gilt für alle Sätze dieses Bandes.*

Eine Arbeit von 1948

Claude Shannon (1916–2001) veröffentlichte im Juli und Oktober 1948 in zwei Teilen die Arbeit *A Mathematical Theory of Communication*. Sie umfasst gut fünfzig Seiten und begründete ein Fach.

Bemerkenswert ist die Geschlossenheit: Die Arbeit enthält den Entropiebegriff, den Quellencodierungssatz, die Kanalkapazität, das Kanalcodierungstheorem und die Erweiterung auf stetige Signale — alles auf einmal, alles neu, und alles im Wesentlichen in der bis heute gültigen Form.

Die Vorläufer

Harry Nyquist (1924) und **Ralph Hartley** (1928) hatten bei denselben Bell-Laboratorien vorgearbeitet. Hartley schlug vor, den Informationsgehalt einer Nachricht aus n Zeichen über einem Alphabet der Größe s als $n \log s$ zu messen.

Das ist der Sonderfall gleicher Wahrscheinlichkeiten: Bei s gleich wahrscheinlichen Zeichen ist jedes $\operatorname{ld} s$ Bit wert. Hartley fehlte der Schritt zu ungleichen Wahrscheinlichkeiten — und damit der ganze Rest. Die Einheit Hartley trägt seinen Namen.

Der Name

Shannon berichtete, **John von Neumann** habe ihm den Namen “Entropie” empfohlen — mit der Begründung, die Funktion sei in der statistischen Mechanik unter diesem Namen bereits bekannt, und im Übrigen wisse ohnehin niemand, was Entropie sei, was ihm in Diskussionen stets einen Vorteil verschaffen werde.

Die Anekdote ist vielfach überliefert und in ihren Einzelheiten unsicher. Der sachliche Kern stimmt aber: Die Formel $-\sum p_i \ln p_i$ stand seit ***Boltzmann*** *und* ***Gibbs*** *in der Physik, und der Zusammenhang ist mehr als eine Ähnlichkeit — Kapitel 2 kommt darauf zurück.*

Shannon selbst

Er arbeitete bis 1972 an den Bell-Laboratorien und lehrte am MIT. Seine Dissertation von 1937 — über die Anwendung der Booleschen Algebra auf Schaltkreise — gilt als eine der folgenreichsten überhaupt.

Shannon war für seine Zurückhaltung und seine Bastelfreude bekannt; er baute unter anderem eine jonglierende Maschine und ein Einrad mit außermittigem Sattel. Auf die Frage, warum er nach 1948 kaum noch zur Informationstheorie veröffentlichte, antwortete er sinngemäß, das Wesentliche sei gesagt.

Wo der Begriff heute steckt

Technik	Jede Datenübertragung und jede Kompression beruht auf den Sätzen dieses Bandes.
Statistik	Modellwahl über Informationskriterien; die Kullback-Leibler-Divergenz aus Kapitel 8.
Physik	Die Verbindung zur thermodynamischen Entropie; das Landauer-Prinzip.
Biologie	Informationsgehalt von Sequenzen, Kanalmodelle für die Signalübertragung in Zellen.

Zur dritten Zeile

Rolf Landauer zeigte 1961, dass das *Löschen* eines Bits mindestens die Wärmemenge $k_B T \ln 2$ freisetzen muss.

Bei Raumtemperatur sind das etwa $3 \cdot 10^{-21}$ Joule — verschwindend wenig gegenüber dem tatsächlichen Energieverbrauch heutiger Rechner, aber grundsätzlich. Die Aussage wurde 2012 erstmals experimentell bestätigt. Sie besagt, dass Information keine rein mathematische Größe ist: Ihre Vernichtung kostet Energie.

Und eine Warnung

Der Erfolg des Begriffs hat zu vielen Übertragungen geführt, die nicht tragen — Shannon selbst schrieb 1956 einen kurzen Aufsatz mit dem Titel The Bandwagon, in dem er davor warnte. ***Die Informationstheorie ist eine Theorie über Übertragung, nicht über Erkenntnis.*** *Wo die Wahrscheinlichkeiten nicht wohldefiniert sind, sind auch ihre Größen es nicht.*

Was Sie jetzt können

Drei Forderungen	stetig, fallend, additiv
Satz 1.1	sie legen $-C \ln p$ fest
Definition 1.2	Bit als Basis-Zwei-Einheit
Der Leitfall	2, 3 und 4 Bit je Gruppe
Der Bruchfall	Abhängigkeit, Empfänger, zwei Wortbedeutungen

Im nächsten Kapitel mitteln wir über alle Ereignisse — und erhalten die Größe, die den ganzen Band trägt.

Kapitel 2

Entropie

2.1 Der Mittelwert

Von einem Ereignis zu einer Quelle

Kapitel 1 gab den Gehalt *eines* Ereignisses. Eine Nachrichtenquelle liefert aber viele.

Die natürliche Kenngröße ist der Erwartungswert des Informationsgehalts.

Im Leitfall

Gruppe	p	I	$p \cdot I$
A, B	0,2500	2	$2 \times 0{,}500$
C, D	0,1250	3	$2 \times 0{,}375$
E–H	0,0625	4	$4 \times 0{,}250$
Summe	1		**2,75**

Nachrechnung: $2 \cdot 0{,}5 + 2 \cdot 0{,}375 + 4 \cdot 0{,}25 = 1{,}0 + 0{,}75 + 1{,}0 = 2{,}75$.

Das ist die Zahl aus Kapitel 1. Jetzt ist klar, woher sie kommt — und Kapitel 3 wird zeigen, dass sie erreichbar und nicht unterbietbar ist.

Definition 2.1 — Entropie

Sei X eine Zufallsgröße mit den Werten $x_1, \ldots, x_n$ und den Wahrscheinlichkeiten $p_1, \ldots, p_n$. Die **Entropie** von X ist

$$H(X) = \sum_{i=1}^{n} p_i \operatorname{ld} \frac{1}{p_i} = -\sum_{i=1}^{n} p_i \operatorname{ld} p_i .$$

Dabei setzt man $0 \cdot \operatorname{ld} 0 := 0$.

Zur Festsetzung $0 \cdot \operatorname{ld} 0 = 0$

Der Ausdruck ist zunächst undefiniert. Man betrachtet den Grenzwert:

$$\lim_{p \to 0^+} p \operatorname{ld} \frac{1}{p} = 0$$

Begründung: Mit $p = 2^{-t}$ wird der Ausdruck zu $t\,2^{-t}$, und die Exponentialfunktion wächst schneller als jede Potenz (Band 3).

> *Die Festsetzung ist also nicht willkürlich, sondern die stetige Fortsetzung. Sachlich bedeutet sie: Ein Wert, der nie vorkommt, trägt nichts zur mittleren Ungewissheit bei — obwohl sein einzelner Informationsgehalt unendlich wäre.*

2.2 Die Grenzen

Satz 2.2 — wie groß und wie klein

Für jede Zufallsgröße mit n möglichen Werten gilt

$$0 \;\le\; H(X) \;\le\; \operatorname{ld} n.$$

Links gilt Gleichheit genau dann, wenn ein Wert die Wahrscheinlichkeit 1 hat; rechts genau bei Gleichverteilung.

Beweis der unteren Schranke

Jeder Summand $p_i \operatorname{ld} \frac{1}{p_i}$ ist nichtnegativ, denn $p_i \ge 0$ und $\frac{1}{p_i} \ge 1$, also $\operatorname{ld} \frac{1}{p_i} \ge 0$. Die Summe ist null genau dann, wenn jeder Summand null ist — also wenn für jedes i entweder $p_i = 0$ oder $p_i = 1$ gilt. Da sich die Wahrscheinlichkeiten zu eins addieren, ist genau ein p_i gleich 1. ✓

Beweis der oberen Schranke

Wir betrachten die Differenz und ziehen $\operatorname{ld} n$ in die Summe hinein (was erlaubt ist, weil $\sum p_i = 1$):

$$\begin{aligned} H(X) - \operatorname{ld} n &= \sum_i p_i \operatorname{ld} \frac{1}{p_i} - \sum_i p_i \operatorname{ld} n \\ &= \sum_i p_i \left(\operatorname{ld} \frac{1}{p_i} - \operatorname{ld} n \right) \\ &= \sum_i p_i \operatorname{ld} \frac{1}{n\,p_i} \end{aligned}$$

Jensen anwenden

Der Logarithmus ist konkav (Band 19, Kapitel 7). Nach der Jensenschen Ungleichung gilt für konkave Funktionen

$$\sum_i p_i f(u_i) \;\le\; f\left(\sum_i p_i u_i \right)$$

mit $u_i = \frac{1}{n\,p_i}$:

$$\sum_i p_i \operatorname{ld} \frac{1}{n p_i} \;\leq\; \operatorname{ld}\left(\sum_i p_i \cdot \frac{1}{n p_i}\right) = \operatorname{ld}\left(\sum_i \frac{1}{n}\right) = \operatorname{ld} 1 = 0$$

Also $H(X) \leq \operatorname{ld} n$. ✓

Wann Gleichheit

Da der Logarithmus *streng* konkav ist, gilt in der Jensenschen Ungleichung Gleichheit genau dann, wenn alle u_i übereinstimmen:

$$\frac{1}{n p_i} = \text{const} \quad\Longleftrightarrow\quad p_i = \text{const} \quad\Longleftrightarrow\quad p_i = \frac{1}{n}$$

■

Der Kunstgriff in diesem Beweis — die Konstante in die Summe zu ziehen, um Jensen anwenden zu können — kehrt in diesem Band mehrfach wieder. Er ist die Standardtechnik der Informationstheorie, und Kapitel 8 zeigt, dass dahinter stets dieselbe Größe steckt: die Kullback-Leibler-Divergenz.

Die Bedeutung der Schranken

Verteilung über 4	H in Bit	
$(\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4})$	2,000	Maximum
$(0{,}4; 0{,}3; 0{,}2; 0{,}1)$	1,846	
$(0{,}7; 0{,}2; 0{,}07; 0{,}03)$	1,245	
$(0{,}97; 0{,}01; 0{,}01; 0{,}01)$	0,242	
$(1; 0; 0; 0)$	0,000	Minimum

Die Entropie misst, wie gleichmäßig eine Verteilung ist. Je ungleichmäßiger, desto kleiner — und desto besser lässt sich komprimieren.

Beachten Sie die zweite Zeile: Eine deutlich ungleiche Verteilung $(0{,}4; 0{,}3; 0{,}2; 0{,}1)$ hat noch 92 Prozent der maximalen Entropie. ***Die Entropie reagiert erstaunlich unempfindlich auf mäßige Ungleichheit*** *— erst starke Konzentration senkt sie deutlich. Das ist der Grund, warum sich Text gut, aber nicht beliebig gut komprimieren lässt.*

2.3 Die binäre Entropiefunktion

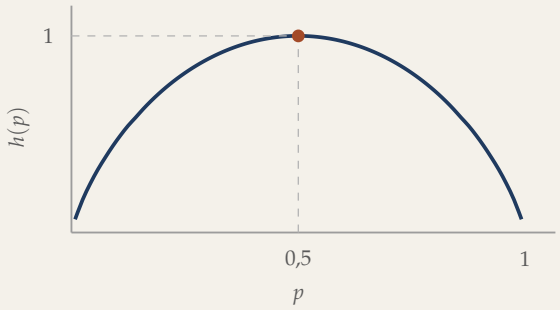
Definition 2.3

Für $p \in [0,1]$ setzt man

$$h(p) = -p \operatorname{ld} p - (1-p) \operatorname{ld}(1-p).$$

Die Werte

p	$h(p)$	p	$h(p)$
0,00	0,0000	0,25	0,8113
0,01	0,0808	0,50	**1,0000**
0,05	0,2864	0,75	0,8113
0,10	0,4690	0,90	0,4690
0,11	0,4999	1,00	0,0000



Drei Eigenschaften

Symmetrie	$h(p) = h(1-p)$ — es ist gleichgültig, welchen Ausgang man "Erfolg" nennt.
Maximum	bei $p = \frac{1}{2}$ mit dem Wert 1.
Steilheit	An den Rändern ist die Kurve *unendlich* steil: $h'(p) \to \infty$ für $p \to 0$.

Zur dritten Zeile:

$$h'(p) = \operatorname{ld} \frac{1-p}{p} \longrightarrow \infty \quad \text{für } p \to 0$$

Das hat eine praktische Folge: Bei $p = 0{,}11$ ist $h = 0{,}5$ — eine Münze, die nur in elf von hundert Fällen Kopf zeigt, trägt immer noch ein halbes Bit. ***Um die Entropie zu halbieren, muss man die Wahrscheinlichkeit auf ein Neuntel drücken.*** *Seltene Ereignisse tragen mehr zur Ungewissheit bei, als man vermutet.*

2.4 Mehrere Größen

Definition 2.4

Für zwei Zufallsgrößen X und Y mit gemeinsamer Verteilung $p(x,y)$:

Verbundentropie	$H(X,Y) = -\sum_{x,y} p(x,y)\ \mathrm{ld}\, p(x,y)$
Bedingte Entropie	$H(Y \mid X) = \sum_x p(x)\, H(Y \mid X = x)$

Satz 2.5 — die Kettenregel

$$H(X,Y) = H(X) + H(Y \mid X)$$

Beweis

Mit $p(x,y) = p(x)\, p(y \mid x)$ und der Rechenregel für Logarithmen:

$$\begin{aligned} H(X,Y) &= -\sum_{x,y} p(x,y)\ \mathrm{ld}\big(p(x)\, p(y \mid x)\big) \\ &= -\sum_{x,y} p(x,y)\ \mathrm{ld}\, p(x) \ - \sum_{x,y} p(x,y)\ \mathrm{ld}\, p(y \mid x) \end{aligned}$$

Erster Summand: Über y summieren ergibt $\sum_y p(x,y) = p(x)$:

$$-\sum_x p(x)\ \mathrm{ld}\, p(x) = H(X)$$

Zweiter Summand: Mit $p(x,y) = p(x)p(y \mid x)$:

$$-\sum_x p(x) \sum_y p(y \mid x)\ \mathrm{ld}\, p(y \mid x) = \sum_x p(x)\, H(Y \mid X = x) = H(Y \mid X)$$

■

In Worten: Die Ungewissheit über beides ist die Ungewissheit über das eine plus die verbleibende über das andere.

Satz 2.6 — Bedingen verringert die Entropie

$$H(Y \mid X) \ \leq\ H(Y)$$

mit Gleichheit genau dann, wenn X und Y unabhängig sind.

Zusätzliches Wissen kann die Ungewissheit nur verringern, nie vergrößern.

Der Beweis läuft wie bei Satz 2.2 über die Jensensche Ungleichung; wir führen ihn in Kapitel 4, wo die Differenz $H(Y) - H(Y \mid X)$ ihren Namen erhält. ***Vorsicht bei der Deutung:*** *Der Satz gilt für den Mittelwert über alle x. Ein einzelnes $H(Y \mid X = x)$ kann sehr wohl größer sein als $H(Y)$ — eine bestimmte Beobachtung kann verwirren, obwohl Beobachtungen im Mittel klären.*

Der Leitfall mit zwei Größen

X: Gehört der Fall zur Gruppe A? Y: Ist der Laborwert positiv?

	$Y = +$	$Y = -$	**Summe**
$X = A$	0,125	0,125	0,250
$X = \bar{A}$	0,075	0,675	0,750
Summe	0,200	0,800	1,000

Die Randentropien

$$H(X) = h(0{,}25) = 0{,}8113 \text{ Bit}$$
$$H(Y) = h(0{,}20) = 0{,}7219 \text{ Bit}$$

Die bedingte Entropie

$$\Pr[Y = + \mid X = A] = \frac{0{,}125}{0{,}250} = 0{,}5, \qquad \Pr[Y = + \mid X = \bar{A}] = \frac{0{,}075}{0{,}750} = 0{,}1$$
$$H(Y \mid X) = 0{,}25 \cdot h(0{,}5) + 0{,}75 \cdot h(0{,}1) = 0{,}25 \cdot 1 + 0{,}75 \cdot 0{,}4690 = 0{,}6017$$

Die Verbundentropie

Direkt:

$$H(X,Y) = -\left[2 \cdot 0{,}125 \operatorname{ld} 0{,}125 + 0{,}075 \operatorname{ld} 0{,}075 + 0{,}675 \operatorname{ld} 0{,}675\right]$$
$$= 0{,}750 + 0{,}2802 + 0{,}3828 = 1{,}4130 \text{ Bit}$$

Über die Kettenregel:

$$H(X) + H(Y \mid X) = 0{,}8113 + 0{,}6017 = 1{,}4130 \quad \checkmark$$

Die Bilanz

Größe	Bit	
$H(X)$	0,8113	
$H(Y)$	0,7219	
$H(X,Y)$	1,4130	
$H(Y \mid X)$	0,6017	$< H(Y)$ ✓
$H(X \mid Y)$	0,6911	$< H(X)$ ✓
Summe der Ränder	1,5332	$> H(X,Y)$
Differenz	**0,1202**	die Überschneidung

Die Verbundentropie ist kleiner als die Summe der Einzelentropien — um 0,12 Bit. Das ist die Information, die beide Größen gemeinsam haben.

Es ist genau der Betrag, der in Kapitel 1 "verschwunden" war. Der Laborwert verrät etwas über die Diagnosegruppe und umgekehrt — 0,12 Bit, in beide Richtungen gleich viel. Kapitel 4 zeigt, dass diese Symmetrie kein Zufall ist.

2.5 Der Bruchfall

Was die Entropie nicht sagt

Keine Ordnung	Die Entropie hängt nur von der *Menge* der Wahrscheinlichkeiten ab, nicht davon, welcher Wert welche hat. Eine Vertauschung ändert nichts.
Kein Abstand	Ob die Werte $1, 2, 3$ oder $1, 100, 10^6$ heißen, ist gleichgültig. Für Zahlengrößen ist das oft die falsche Beschreibung.
Keine Struktur	Eine Folge, die aus lauter Wiederholungen besteht, kann dieselbe Entropie haben wie eine zufällige — wenn man nur die Einzelhäufigkeiten betrachtet.

Zur dritten Zeile

Die Folge

$$010101010101\ldots$$

hat je zur Hälfte Nullen und Einsen, also eine Symbolentropie von einem Bit — obwohl sie vollkommen vorhersehbar ist.

Die Entropie einer Quelle ist nicht die Entropie ihrer Einzelsymbole. Sie muss über immer längere Blöcke gemessen werden.

*Bei Paaren ergibt sich für obige Folge nur noch ein halbes Bit je Symbol, bei Viergruppen ein Viertel — und im Grenzwert null. Man nennt das die **Entropierate**; sie ist die richtige Größe für Quellen mit Gedächtnis und wird in Kapitel 3 eingeführt. **Deutscher Text hat eine Symbolentropie von etwa** 4,1 **Bit und eine Entropierate von unter** 1,5 **Bit je Zeichen** — der Unterschied ist die Struktur der Sprache.*

Und die stetige Fassung hat eine Falle

Für eine stetige Größe mit Dichte f definiert man

$$H(X) = -\int f(x)\,\operatorname{ld} f(x)\,\mathrm{d}x.$$

Kann negativ sein	Bei einer Gleichverteilung auf $[0;\,0{,}5]$ ist $f = 2$ und $H = -1$ Bit.
Nicht invariant	Eine Skalierung $X \to aX$ ändert den Wert um $\operatorname{ld} a$.
Kein Grenzwert	Sie ist *nicht* der Grenzwert der diskreten Entropie feiner werdender Einteilungen — der wäre unendlich.

*Man nennt sie deshalb genauer **differentielle Entropie** und behandelt sie als eigenen Begriff. Die guten Eigenschaften bleiben dort erhalten, wo Differenzen gebildet werden — und genau das geschieht bei der Transinformation in Kapitel 4. Sie ist auch im stetigen Fall nichtnegativ und skaleninvariant.*

2.6 Übungsaufgaben

Aufgabe 2.1 — Entropien vergleichen

Berechnen Sie die Entropie und vergleichen Sie mit der oberen Schranke:

(a)	Ein fairer Würfel.
(b)	Ein gezinkter Würfel: die Sechs mit $\frac{1}{2}$, die übrigen gleich.
(c)	Ein Buchstabe aus 26 gleich häufigen.
(d)	Die Blutgruppen: 0 mit 0,41, A mit 0,43, B mit 0,11, AB mit 0,05.

Lösung

(a) Fairer Würfel
Gleichverteilung, also Maximum:

$$H = \operatorname{ld} 6 = 2{,}585 \text{ Bit}$$

(b) Gezinkter Würfel
Die Sechs hat $\frac{1}{2}$, die übrigen fünf je $\frac{1}{10}$.

$$H = \tfrac{1}{2} \operatorname{ld} 2 + 5 \cdot \tfrac{1}{10} \operatorname{ld} 10 = 0{,}5 + 0{,}5 \cdot 3{,}3219 = 0{,}5 + 1{,}6610 = 2{,}161 \text{ Bit}$$

Vergleich: 2,161 gegen 2,585 — eine Einbuße von 16,4 Prozent.

> *Bemerkenswert wenig für eine so grobe Verfälschung: Die Sechs kommt dreifach zu häufig, und die Entropie sinkt um ein Sechstel. Das ist die Unempfindlichkeit aus Abschnitt 2.2.*

(c) Buchstaben

$$H = \operatorname{ld} 26 = \frac{\ln 26}{\ln 2} = \frac{3{,}2581}{0{,}6931} = 4{,}700 \text{ Bit}$$

> *Deutscher Text erreicht diesen Wert bei weitem nicht: Die tatsächlichen Buchstabenhäufigkeiten ergeben etwa 4,1 Bit, und unter Berücksichtigung der Abhängigkeiten sinkt der Wert auf unter 1,5 Bit je Zeichen.*

(d) Blutgruppen

	p	$\operatorname{ld}(1/p)$	$p \cdot \operatorname{ld}(1/p)$
0	0,41	1,2863	0,5274
A	0,43	1,2176	0,5236
B	0,11	3,1844	0,3503
AB	0,05	4,3219	0,2161
	1,00		**1,617**

Obere Schranke: $\operatorname{ld} 4 = 2$ Bit.

Die Übersicht

	H	$\operatorname{ld} n$	**Ausnutzung**
(a)	2,585	2,585	100,0 %
(b)	2,161	2,585	83,6 %
(c)	4,700	4,700	100,0 %
(d)	1,617	2,000	80,9 %

> *Die letzte Spalte ist die interessante: Sie gibt an, wie viel der möglichen Ungewissheit tatsächlich vorhanden ist. Ihr Gegenstück 1 − Ausnutzung heißt* ***Redundanz*** *— bei den Blutgruppen also 19 Prozent. Genau so viel lässt sich durch Codierung einsparen.*

Aufgabe 2.2 — Die Kettenregel prüfen

Für die Verbundverteilung

	y_1	y_2	y_3
x_1	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{16}$
x_2	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{16}$
x_3	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{3}{8}$

berechnen Sie alle Entropien und prüfen Sie die Kettenregel.

Lösung

Schritt 1 — Die Ränder

	Summe	**Wert**
$p(x_1)$	$\frac{1}{8}+\frac{1}{16}+\frac{1}{16}$	$\frac{1}{4}$
$p(x_2)$	$\frac{1}{16}+\frac{1}{8}+\frac{1}{16}$	$\frac{1}{4}$
$p(x_3)$	$\frac{1}{16}+\frac{1}{16}+\frac{3}{8}$	$\frac{1}{2}$

Aus Symmetrie der Tabelle gilt dasselbe für Y.

Schritt 2 — Die Randentropien

$$H(X) = 2 \cdot \tfrac{1}{4}\,\mathrm{ld}\,4 + \tfrac{1}{2}\,\mathrm{ld}\,2 = 2 \cdot 0{,}5 + 0{,}5 = 1{,}5 \text{ Bit}$$

Ebenso $H(Y) = 1{,}5$ Bit.

Schritt 3 — Die Verbundentropie

Die neun Felder: viermal $\frac{1}{16}$? Zählen wir nach:

Wert	**Anzahl**	$\mathrm{ld}(1/p)$	**Beitrag**
$\frac{1}{8}$	2	3	$2 \cdot \frac{3}{8} = 0{,}750$
$\frac{1}{16}$	6	4	$6 \cdot \frac{1}{4} = 1{,}500$
$\frac{3}{8}$	1	1,4150	0,5306
Summe			**2,781**

Probe der Wahrscheinlichkeiten: $2 \cdot \frac{1}{8} + 6 \cdot \frac{1}{16} + \frac{3}{8} = \frac{1}{4} + \frac{3}{8} + \frac{3}{8} = 1$ ✓
Zum dritten Beitrag: $\mathrm{ld}\,\frac{8}{3} = 3 - \mathrm{ld}\,3 = 3 - 1{,}5850 = 1{,}4150$; $0{,}375 \cdot 1{,}4150 = 0{,}5306$.

Schritt 4 — Die bedingte Entropie

Gegeben x_1: Die bedingten Wahrscheinlichkeiten sind $\frac{1/8}{1/4} = \frac{1}{2}$ und zweimal $\frac{1/16}{1/4} = \frac{1}{4}$.

$$H(Y \mid x_1) = \tfrac{1}{2} \cdot 1 + 2 \cdot \tfrac{1}{4} \cdot 2 = 0{,}5 + 1{,}0 = 1{,}5$$

Ebenso $H(Y \mid x_2) = 1{,}5$.

Gegeben x_3: $\frac{1/16}{1/2} = \frac{1}{8}$ zweimal und $\frac{3/8}{1/2} = \frac{3}{4}$.

$$H(Y \mid x_3) = 2 \cdot \tfrac{1}{8} \cdot 3 + \tfrac{3}{4} \operatorname{ld} \tfrac{4}{3} = 0{,}750 + 0{,}75 \cdot 0{,}4150 = 0{,}750 + 0{,}3113 = 1{,}0613$$

$$H(Y \mid X) = \tfrac{1}{4} \cdot 1{,}5 + \tfrac{1}{4} \cdot 1{,}5 + \tfrac{1}{2} \cdot 1{,}0613 = 0{,}375 + 0{,}375 + 0{,}5306 = 1{,}2806$$

Schritt 5 — Die Kettenregel prüfen

$$H(X) + H(Y \mid X) = 1{,}5 + 1{,}2806 = \mathbf{2{,}781} \quad \checkmark$$

Schritt 6 — Satz 2.6 prüfen

$$H(Y \mid X) = 1{,}281 \;\leq\; 1{,}500 = H(Y) \quad \checkmark$$

Beachten Sie Schritt 4: Für x_1 und x_2 ist die bedingte Entropie genau so groß wie $H(Y)$ — diese Beobachtungen klären nichts. Erst x_3 senkt sie deutlich. ***Der Satz gilt im Mittel; einzelne Beobachtungen können wirkungslos sein.***

Schritt 7 — Die Überschneidung

$$H(X) + H(Y) - H(X,Y) = 1{,}5 + 1{,}5 - 2{,}781 = \mathbf{0{,}219}\ \text{Bit}$$

Aufgabe 2.3 — Die Gruppierungseigenschaft

Zeigen Sie: Fasst man zwei Werte mit den Wahrscheinlichkeiten p_1 und p_2 zu einem zusammen, so gilt

$$H(p_1, p_2, p_3, \ldots) = H(p_1{+}p_2,\ p_3, \ldots) + (p_1{+}p_2)\, h\!\left(\frac{p_1}{p_1 + p_2}\right).$$

Prüfen Sie die Formel am Leitfall.

Lösung

Schritt 1 — Die Idee

Man erfährt die Nachricht in zwei Schritten: erst, ob sie in der zusammengefassten Gruppe liegt, dann gegebenenfalls welcher der beiden Werte es ist.

Schritt 2 — Der Beweis

Sei $q = p_1 + p_2$. Die beiden fraglichen Summanden auf der linken Seite:

$$-p_1 \operatorname{ld} p_1 - p_2 \operatorname{ld} p_2$$

Wir schreiben $p_1 = q \cdot \frac{p_1}{q}$ und entsprechend p_2:

$$-p_1 \operatorname{ld} p_1 = -p_1 \left(\operatorname{ld} q + \operatorname{ld} \tfrac{p_1}{q}\right) = -p_1 \operatorname{ld} q - p_1 \operatorname{ld} \tfrac{p_1}{q}$$
$$-p_2 \operatorname{ld} p_2 = -p_2 \operatorname{ld} q - p_2 \operatorname{ld} \tfrac{p_2}{q}$$

Addieren:

$$-(p_1 + p_2) \operatorname{ld} q \;-\; q\left[\tfrac{p_1}{q} \operatorname{ld} \tfrac{p_1}{q} + \tfrac{p_2}{q} \operatorname{ld} \tfrac{p_2}{q}\right] = -q \operatorname{ld} q + q\, h\!\left(\tfrac{p_1}{q}\right)$$

Der erste Term ist genau der Beitrag des zusammengefassten Werts. ■

Schritt 3 — Am Leitfall

Wir fassen E und F (je 0,0625) zu einer Gruppe mit 0,125 zusammen.
Links: $H = 2{,}75$ (acht Gruppen).
Rechts, erster Teil: Sieben Gruppen mit (0,25; 0,25; 0,125; 0,125; **0,125**; 0,0625; 0,0625):

$$H = 2 \cdot 0{,}5 + 3 \cdot (0{,}125 \cdot 3) + 2 \cdot (0{,}0625 \cdot 4) = 1{,}0 + 1{,}125 + 0{,}5 = 2{,}625$$

Rechts, zweiter Teil:

$$0{,}125 \cdot h\left(\tfrac{0{,}0625}{0{,}125}\right) = 0{,}125 \cdot h(0{,}5) = 0{,}125 \cdot 1 = 0{,}125$$

$$2{,}625 + 0{,}125 = \mathbf{2{,}750} \quad \checkmark$$

Schritt 4 — Wozu das dient

Codierung	Das Huffman-Verfahren in Kapitel 3 fasst genau so zusammen — und die Formel sagt, was das kostet.
Entscheidungs-bäume	In der Statistik wählt man Aufteilungen nach dem Entropiegewinn; die Formel ist die Rechengrundlage.
Axiomatik	Zusammen mit Stetigkeit und dem Wert $h(\frac{1}{2}) = 1$ legt sie die Entropie vollständig fest.

Die dritte Zeile ist Shannons eigener Zugang von 1948: Er forderte Stetigkeit, Monotonie im Umfang bei Gleichverteilung und genau diese Gruppierungseigenschaft — und bewies, dass nur $-C\sum p_i \ln p_i$ übrigbleibt. Es ist derselbe Aufbau wie bei Satz 1.1, nur eine Ebene höher.

Eine Formel mit zwei Herkünften

Die Funktion $-\sum p_i \ln p_i$ stand in der Physik, bevor sie in der Nachrichtentechnik auftauchte.

Boltzmann, 1877

Ludwig Boltzmann (1844–1906) verband die thermodynamische Entropie mit der Zahl W der mikroskopischen Zustände, die zu einem makroskopischen gehören:

$$S = k_B \ln W$$

*Das ist der Sonderfall gleich wahrscheinlicher Zustände — genau Hartleys Formel aus Kapitel 1, nur in anderer Einheit. Die Gleichung steht auf Boltzmanns Grabstein in Wien, obwohl er sie in dieser Form nie aufschrieb; **Max Planck** gab ihr die heutige Gestalt.*

Gibbs, 1902

Josiah Willard Gibbs verallgemeinerte auf ungleiche Wahrscheinlichkeiten:

$$S = -k_B \sum_i p_i \ln p_i$$

Das ist Shannons Formel, sechsundvierzig Jahre früher und mit einer physikalischen Konstante davor. Dass beide Größen dieselbe Gestalt haben, ist kein Zufall: Beide zählen, wie viele Möglichkeiten es gibt — die eine für Moleküle, die andere für Nachrichten.

Der Zusammenhang

Leó Szilárd zeigte 1929 an einem Gedankenexperiment, dass der Maxwellsche Dämon — ein Wesen, das Moleküle sortiert und damit angeblich den zweiten Hauptsatz verletzt — genau dann keine Arbeit gewinnt, wenn man den Informationsgewinn mitbilanziert.

*Ein Bit Information entspricht dabei der Entropie $k_B \ln 2$. Die Auflösung des Paradoxons vollendete **Charles Bennett** 1982: Nicht das Messen kostet, sondern das Löschen des Gedächtnisses — nach dem Landauer-Prinzip aus Kapitel 1.*

Und eine Warnung

Die Gleichheit der Formeln hat zu weitreichenden Behauptungen geführt — über Information als physikalische Grundgröße, über das Universum als Rechner. Der sichere Kern ist schmaler: Beide Größen zählen Möglichkeiten, und wo eine physikalische Fragestellung auf ein Abzählen von Zuständen hinausläuft, tritt dieselbe Funktion auf. Mehr folgt daraus nicht von selbst.

Entropie als Werkzeug

Maximale Entropie	Unter allen Verteilungen mit gegebenen Erwartungswerten diejenige mit größter Entropie wählen — das Prinzip der geringsten Zusatzannahme.
Entscheidungsbäume	Aufteilungen werden nach dem Entropiegewinn gewählt.
Schätzung	Die Entropie aus Daten zu schätzen ist bei vielen Symbolen systematisch verzerrt — nach unten.

Zur ersten Zeile

Edwin Jaynes schlug 1957 vor, unter allen mit den Daten verträglichen Verteilungen die entropiereichste zu wählen.

Die Ergebnisse sind bemerkenswert: Gibt man nur den Mittelwert vor, so ergibt sich die Exponentialverteilung; gibt man Mittelwert und Varianz vor, die Normalverteilung. ***Die Normalverteilung ist also die Verteilung, die bei gegebener Streuung am wenigsten behauptet*** *— eine Begründung für ihre Sonderstellung, die neben dem zentralen Grenzwertsatz aus Band 12 steht.*

Zur dritten Zeile

Schätzt man H durch Einsetzen der beobachteten Häufigkeiten, so ist das Ergebnis zu klein.

Der Grund ist Jensen: Die Entropie ist eine konkave Funktion der Wahrscheinlichkeiten, und der Erwartungswert einer konkaven Funktion liegt unter der Funktion des Erwartungswerts. Der Fehler beträgt näherungsweise $\frac{n-1}{2N \ln 2}$ Bit bei n Symbolen und N Beobachtungen — bei vielen seltenen Symbolen also erheblich. Es ist derselbe Sachverhalt wie in Band 19, Kapitel 13, nur mit umgekehrtem Vorzeichen.

Was Sie jetzt können

Definition 2.1	$H = -\sum p_i \operatorname{ld} p_i$
Satz 2.2	$0 \le H \le \operatorname{ld} n$, Jensen
Definition 2.3	$h(p)$, Maximum bei $\frac{1}{2}$
Satz 2.5	Kettenregel
Satz 2.6	Bedingen verringert — im Mittel

Im nächsten Kapitel wird aus der Zahl 2,75 ein Satz: Sie ist erreichbar, und weniger geht nicht.

Kapitel 3

Quellencodierung

3.1 Was ein brauchbarer Code leisten muss

Das Problem der Trennung

Wir wollen häufigen Gruppen kurze Codewörter geben. Aber:

	A	B	C
Code 1	0	1	01

Die Folge 01 kann C bedeuten oder AB — der Code ist nicht eindeutig lesbar.

Die Abhilfe

Kein Codewort darf Anfangsstück eines anderen sein. Solche Codes heißen **präfixfrei**.

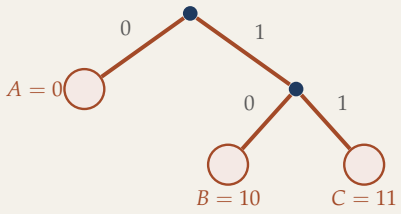
	A	B	C
Code 2	0	10	11

Probe: 01011 liest sich eindeutig als 0 | 10 | 11, also ABC.

Präfixfreie Codes lassen sich ohne jedes Zurückblicken lesen: Sobald ein Codewort erkannt ist, steht es fest. Man nennt sie deshalb auch augenblicklich decodierbar. Es gibt eindeutig lesbare Codes, die nicht präfixfrei sind — aber wie Satz 3.1 zeigt, gewinnt man dadurch nichts.

Der Codebaum

Jeder präfixfreie Binärcode entspricht einem Baum: Links bedeutet 0, rechts 1, und die Codewörter sitzen an den Blättern.



Präfixfreiheit heißt: Kein Codewort liegt auf dem Weg zu einem anderen.
Alle sitzen an Blättern, keines an einem inneren Knoten.

3.2 Die Kraftsche Ungleichung

Satz 3.1 — wann Wortlängen möglich sind

Zu vorgegebenen Längen $l_1, \ldots, l_n$ gibt es genau dann einen präfixfreien Binärcode, wenn

$$\sum_{i=1}^{n} 2^{-l_i} \;\leq\; 1.$$

Beweis der Notwendigkeit

Sei $L = \max_i l_i$ und der Code gegeben. Wir betrachten den vollständigen Binärbaum der Tiefe L mit seinen 2^L Blättern.

Schritt 1 — was ein Codewort blockiert

Ein Codewort der Länge l_i sitzt an einem Knoten der Tiefe l_i. Unter diesem Knoten liegen genau

$$2^{\,L-l_i}$$

Blätter der Tiefe L.

Schritt 2 — die Bereiche sind getrennt

Wären zwei dieser Blättermengen nicht disjunkt, so läge ein Codewort auf dem Weg zum anderen — Widerspruch zur Präfixfreiheit.

Schritt 3 — abzählen

Die Summe aller blockierten Blätter kann die Gesamtzahl nicht übersteigen:

$$\sum_{i=1}^{n} 2^{\,L-l_i} \;\leq\; 2^L$$

Division durch 2^L liefert die Behauptung. ✓

Beweis der Hinlänglichkeit

Sei die Ungleichung erfüllt. Wir ordnen die Längen aufsteigend: $l_1 \leq l_2 \leq \cdots \leq l_n$ und vergeben die Codewörter der Reihe nach.
Vor der Vergabe des k-ten Wortes sind

$$\sum_{i<k} 2^{\,L-l_i}$$

Blätter blockiert. Es bleiben

$$2^L - \sum_{i<k} 2^{\,L-l_i} \;\geq\; \sum_{i\geq k} 2^{\,L-l_i} \;\geq\; 2^{\,L-l_k}$$

Blätter frei — also mindestens so viele, wie das k-te Wort benötigt. Da die Längen aufsteigend sind, lässt sich stets ein passender freier Knoten finden. ■

Der Satz übersetzt eine Aussage über Bäume in eine Ungleichung über Zahlen — und macht sie damit dem Rechnen zugänglich. ***Dieselbe Ungleichung gilt auch für eindeutig lesbare Codes****, die nicht präfixfrei sind; der Beweis dafür ist länger. Deshalb verliert man durch die Beschränkung auf Präfixcodes nichts.*

Die Ungleichung nachgerechnet

Längen	$\sum 2^{-l_i}$	
$1,2,2$	$\frac{1}{2}+\frac{1}{4}+\frac{1}{4}=1$	möglich
$2,2,3,3,4,4,4,4$	1	möglich
$1,2,2,3$	$\frac{1}{2}+\frac{1}{4}+\frac{1}{4}+\frac{1}{8}$	>1
$2,2,3,4,5,5$	$0{,}75$	möglich, mit Reserve

Gleichheit bedeutet, dass der Baum vollständig ausgenutzt ist. Bleibt Reserve, so könnte man mindestens ein Codewort verkürzen.

Zur zweiten Zeile: $2\cdot\frac{1}{4}+2\cdot\frac{1}{8}+4\cdot\frac{1}{16}=0{,}5+0{,}25+0{,}25=1$. Das sind die Längen des Leitfalls.

3.3 Die untere Schranke

Satz 3.2 — keine Codierung unterbietet die Entropie

Für jeden präfixfreien Code mit den Wortlängen l_i gilt

$$L \;:=\; \sum_i p_i\, l_i \;\geq\; H(X).$$

Gleichheit gilt genau dann, wenn $l_i = -\operatorname{ld} p_i$ für alle i.

Beweis — Schritt 1: die Differenz

$$L - H(X) = \sum_i p_i\, l_i + \sum_i p_i \operatorname{ld} p_i = \sum_i p_i \operatorname{ld}\left(p_i\, 2^{l_i}\right)$$

Schritt 2 — Abkürzung

Wir setzen $q_i := 2^{-l_i}$ und $Q := \sum_i q_i$. Nach Satz 3.1 ist $Q \leq 1$.

$$L - H(X) = \sum_i p_i \operatorname{ld} \frac{p_i}{q_i}$$

Schritt 3 — Jensen

Wir betrachten das Negative und wenden die Jensensche Ungleichung auf den

konkaven Logarithmus an:

$$\begin{aligned} -\big(L - H(X)\big) &= \sum_i p_i \operatorname{ld} \frac{q_i}{p_i} \\ &\le \operatorname{ld}\left(\sum_i p_i \cdot \frac{q_i}{p_i}\right) && \text{(Jensen)} \\ &= \operatorname{ld} Q \;\le\; \operatorname{ld} 1 = 0 && \text{(Satz 3.1)} \end{aligned}$$

Also $L - H(X) \ge 0$. ✓

Schritt 4 — wann Gleichheit

Es müssen *beide* Ungleichungen mit Gleichheit gelten:

Jensen	alle $\frac{q_i}{p_i}$ gleich, also $q_i = c\, p_i$
Kraft	$Q = 1$, also $c = 1$ und damit $q_i = p_i$

Aus $q_i = 2^{-l_i} = p_i$ folgt $l_i = -\operatorname{ld} p_i$. ■

Die Entropie ist erreichbar genau dann, wenn alle Wahrscheinlichkeiten Zweierpotenzen sind. Dann ist $-\operatorname{ld} p_i$ ganzzahlig.

*Das ist der Leitfall: $\frac{1}{4}$, $\frac{1}{8}$ und $\frac{1}{16}$ ergeben die Längen 2, 3 und 4, und $L = H = 2{,}75$. Man nennt solche Verteilungen **dyadisch**. Für alle anderen bleibt eine Lücke — und der nächste Satz sagt, wie groß sie höchstens ist.*

3.4 Die obere Schranke

Satz 3.3 — der Quellencodierungssatz

Es gibt stets einen präfixfreien Code mit

$$H(X) \;\le\; L \;<\; H(X) + 1.$$

Beweis — die Konstruktion

Man wähle

$$l_i := \lceil -\operatorname{ld} p_i \rceil .$$

Schritt 1 — Kraft ist erfüllt

Aus $l_i \ge -\operatorname{ld} p_i$ folgt $2^{-l_i} \le 2^{\operatorname{ld} p_i} = p_i$, also

$$\sum_i 2^{-l_i} \;\le\; \sum_i p_i = 1.$$

Nach Satz 3.1 existiert ein solcher Code. ✓

Schritt 2 — die obere Abschätzung

Aus $\lceil x \rceil < x + 1$:

$$L = \sum_i p_i\, l_i \;<\; \sum_i p_i \,(-\operatorname{ld} p_i + 1) = H(X) + 1$$

Schritt 3 — die untere
Satz 3.2. ■

Die Konstruktion heißt Shannon-Code. Sie ist nicht die beste — das Aufrunden verschenkt bei jeder Wahrscheinlichkeit etwas —, aber sie beweist die Schranke. Für den Beweis genügt ein Code, für die Praxis will man den besten.

3.5 Das Huffman-Verfahren

Der Aufbau von unten

1	Die beiden kleinsten Wahrscheinlichkeiten zusammenfassen.
2	Die Summe als neues Symbol in die Liste aufnehmen.
3	Wiederholen, bis nur noch ein Symbol übrig ist.
4	Den entstandenen Baum von der Wurzel aus beschriften.

Der Gedanke stammt aus Aufgabe 2.3: Das Zusammenfassen zweier Werte kostet genau $q\,h(p_1/q)$ zusätzliche Entropie. Huffman fasst stets dort zusammen, wo dieser Aufpreis am kleinsten ist — bei den seltensten Symbolen.

Ein Durchlauf

Sechs Befundarten mit den Anteilen

$$0{,}40;\quad 0{,}25;\quad 0{,}15;\quad 0{,}10;\quad 0{,}06;\quad 0{,}04$$

Die Zusammenfassungen

Runde	zusammengefasst	neue Liste
1	$0{,}06 + 0{,}04 = 0{,}10$	0,40; 0,25; 0,15; 0,10; 0,10
2	$0{,}10 + 0{,}10 = 0{,}20$	0,40; 0,25; 0,20; 0,15
3	$0{,}15 + 0{,}20 = 0{,}35$	0,40; 0,35; 0,25
4	$0{,}25 + 0{,}35 = 0{,}60$	0,60; 0,40
5	$0{,}40 + 0{,}60 = 1{,}00$	fertig

Die Wortlängen

Jedes Symbol erhält so viele Bit, an wie vielen Zusammenfassungen es beteiligt war:

p	**Länge**	$p \cdot l$
0,40	1	0,40
0,25	2	0,50
0,15	3	0,45
0,10	4	0,40
0,06	5	0,30
0,04	5	0,20
		2,25

Kraft-Probe: $\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + 2 \cdot \frac{1}{32} = 0{,}5 + 0{,}25 + 0{,}125 + 0{,}0625 + 0{,}0625 = 1$ ✓

Der Vergleich

	Längen	L
Entropie	—	2,201
Huffman	1, 2, 3, 4, 5, 5	**2,250**
Shannon-Code	2, 2, 3, 4, 5, 5	2,650
Gleiche Länge	3, 3, 3, 3, 3, 3	3,000

Zum Shannon-Code: $\lceil -\operatorname{ld} 0{,}40 \rceil = \lceil 1{,}32 \rceil = 2$, $\lceil -\operatorname{ld} 0{,}25 \rceil = 2$, und so fort. Die Kraft-Summe beträgt nur 0,75 — es bleibt Reserve, also ist der Code nicht ausgereizt.

Huffman liegt 2,2 **Prozent über der Entropie, der Shannon-Code** 20,4 **Prozent.** Beide erfüllen Satz 3.3 — aber der Unterschied ist erheblich.

Satz 3.4 — Huffman ist optimal

Kein präfixfreier Code hat eine kleinere mittlere Länge als der Huffman-Code.

Die beiden tragenden Beobachtungen

1	In einem optimalen Code haben die beiden seltensten Symbole die größte und dieselbe Länge.
2	Sie können als Geschwister im Baum angeordnet werden, ohne die Länge zu ändern.

Zu 1: Hätte ein selteneres Symbol ein kürzeres Wort als ein häufigeres, so würde Vertauschen die mittlere Länge senken. Und ein längstes Codewort muss ein Geschwister haben — sonst könnte man sein letztes Bit streichen.

Der Schluss
Sind die beiden seltensten Geschwister, so ist der Code genau dann optimal für die ursprüngliche Verteilung, wenn der um sie verkürzte Code für die zusammengefasste Verteilung optimal ist.
Grund: Nach Aufgabe 2.3 unterscheiden sich die mittleren Längen um genau $p_1 + p_2$ — unabhängig davon, wie der Rest codiert ist.
Damit ist das Problem auf eines mit einem Symbol weniger zurückgeführt, und Induktion liefert die Behauptung. ■

> *Bemerkenswert an diesem Beweis ist, was er nicht braucht: keine Analysis, keine Ungleichung, nur ein Vertauschungsargument und Induktion.* ***Huffman fand ihn 1951 als Student****, nachdem sein Lehrer Fano die Aufgabe als offenes Problem gestellt hatte.*

3.6 Blöcke codieren

Die Lücke verkleinern

Satz 3.3 lässt bis zu einem Bit Verlust je Symbol zu. Bei kleiner Entropie ist das viel.

Der Ausweg
Man codiert nicht einzelne Symbole, sondern Blöcke der Länge n. Für unabhängige Symbole gilt

$$H(X_1, \ldots, X_n) = n\,H(X)$$

und Satz 3.3 liefert

$$n\,H(X) \;\le\; L_n \;<\; n\,H(X) + 1.$$

Je Symbol:

$$H(X) \;\le\; \frac{L_n}{n} \;<\; H(X) + \frac{1}{n}$$

Der Überhang schrumpft wie $1/n$ und geht gegen null.

Am Beispiel
Eine Quelle liefert “unauffällig” mit 0,8 und “auffällig” mit 0,2. Die Entropie beträgt $h(0{,}2) = 0{,}7219$ Bit.

n	L_n	L_n/n	**Überhang**
1	1,000	1,0000	0,2781
2	1,560	0,7800	0,0581
3	2,184	0,7280	**0,0061**
4	2,963	0,7408	0,0189
6	4,351	0,7253	0,0033

Von 38 Prozent Überhang bei Einzelcodierung auf unter ein Prozent bei Dreiergruppen.

Beachten Sie, dass der Überhang nicht monoton fällt: Bei $n = 4$ ist er größer als bei $n = 3$. Die Schranke $1/n$ gilt, der tatsächliche Wert schwankt darunter — je nachdem, wie gut die Blockwahrscheinlichkeiten zufällig zu Zweierpotenzen passen. ***Der Satz garantiert die Einhüllende, nicht den Verlauf.***

Der Preis

Bei n Symbolen und einem Alphabet der Größe m hat die Codetabelle m^n Einträge.

n	2^n	8^n
3	8	512
6	64	262 144
10	1024	10^9
20	10^6	10^{18}

Das ist der Grund, warum Huffman in der Praxis nicht auf lange Blöcke angewandt wird. Die arithmetische Codierung aus dem Forschungskasten umgeht das Problem: Sie erreicht die Entropie ohne Codetabelle, indem sie die gesamte Nachricht auf eine einzige Zahl abbildet.

Quellen mit Gedächtnis

Sind die Symbole abhängig, so ist $H(X_1, \ldots, X_n) < n\,H(X)$, und die richtige Größe ist die **Entropierate**

$$H_\infty = \lim_{n\to\infty} \frac{H(X_1, \ldots, X_n)}{n}.$$

Quelle	**Symbolentropie**	**Rate**
010101 …	1,00	0,00
Deutscher Text	$\approx 4{,}1$	$< 1{,}5$
Gleichverteilt, 26	4,70	4,70

Die zweite Zeile stammt aus Shannons Untersuchung von 1951, in der er Versuchspersonen den nächsten Buchstaben eines Textes raten ließ und aus ihrer Trefferquote die Rate abschätzte. Sie liegt bei etwa einem Bit je Zeichen — ***sprachlicher Text ist zu rund achtzig Prozent redundant.*** *Genau davon leben alle Textkompressionsverfahren.*

3.7 Der Bruchfall

Was der Satz nicht sagt

Die Verteilung	Sie muss bekannt sein. Wird sie aus den Daten geschätzt, so kostet das Speicherplatz für die Tabelle — und die Schätzung ist verzerrt.
Nur im Mittel	Einzelne Nachrichten können länger werden als vorher. Nur der Erwartungswert sinkt.
Keine Fehlertoleranz	Ein einziges gekipptes Bit kann den ganzen Rest unlesbar machen — der Code verliert den Tritt.

Zur zweiten Zeile

Im Beispiel erhält das seltenste Symbol fünf Bit statt drei bei gleicher Länge. Kommt es gehäuft vor, so ist die Nachricht länger.

> **Es gibt keinen Code, der *jede* Nachricht verkürzt.** Ein solcher müsste eine Abbildung sein, die eine endliche Menge in eine kleinere umkehrbar abbildet.
>
> *Das ist ein reines Abzählargument: Es gibt 2^n Folgen der Länge n und nur $2^n - 1$ kürzere insgesamt. Jedes Kompressionsverfahren verlängert also manche Eingaben — und zwar notwendig. Wer eine bereits komprimierte Datei erneut komprimiert, macht sie meist größer.*

Zur dritten Zeile

> *Kompression und Fehlerschutz ziehen in entgegengesetzte Richtungen: Die eine entfernt Redundanz, der andere fügt sie hinzu. Shannon zeigte, dass man beides getrennt und nacheinander tun darf, ohne etwas zu verlieren — das **Trennungsprinzip**. Kapitel 5 kommt darauf zurück; es gilt nicht immer.*

3.8 Übungsaufgaben

Aufgabe 3.1 — Ein Huffman-Code

Erstellen Sie einen Huffman-Code für

$$0{,}30; \quad 0{,}25; \quad 0{,}20; \quad 0{,}15; \quad 0{,}10$$

und vergleichen Sie mit Entropie und Gleichlängencode.

Lösung

Schritt 1 — Die Zusammenfassungen

Runde	zusammengefasst	neue Liste
1	$0{,}15 + 0{,}10 = 0{,}25$	0,30; 0,25; 0,25; 0,20
2	$0{,}25 + 0{,}20 = 0{,}45$	0,45; 0,30; 0,25
3	$0{,}30 + 0{,}25 = 0{,}55$	0,55; 0,45
4	$0{,}55 + 0{,}45 = 1{,}00$	fertig

Zu Runde 2: Die beiden kleinsten sind 0,20 und eines der beiden 0,25. Wir wählen das in Runde 1 entstandene.

Schritt 2 — Die Längen

p	**beteiligt an**	**Länge**	$p \cdot l$
0,30	3, 4	2	0,60
0,25	3, 4	2	0,50
0,20	2, 4	2	0,40
0,15	1, 2, 4	3	0,45
0,10	1, 2, 4	3	0,30
			2,25

Kraft-Probe: $3 \cdot \frac{1}{4} + 2 \cdot \frac{1}{8} = 0{,}75 + 0{,}25 = 1$ ✓

Schritt 3 — Ein konkreter Code

p	**Wort**	p	**Wort**
0,30	00	0,15	100
0,25	01	0,10	101
0,20	11		

Präfixfreiheit: Kein Wort ist Anfang eines anderen. ✓

Schritt 4 — Die Entropie

p	$\mathrm{ld}(1/p)$	$p \cdot \mathrm{ld}(1/p)$
0,30	1,7370	0,5211
0,25	2,0000	0,5000
0,20	2,3219	0,4644
0,15	2,7370	0,4105
0,10	3,3219	0,3322
		2,228

Schritt 5 — Der Vergleich

	L	**Überhang**
Entropie	2,228	—
Huffman	2,250	**1,0 %**
Gleiche Länge	3,000	34,6 %

Ein Viertel der Bits gespart, und nur ein Prozent über der theoretischen Grenze.

Schritt 6 — Eine Bemerkung zur Eindeutigkeit

In Runde 2 gab es zwei gleichwertige Wahlmöglichkeiten. Die andere hätte die Längen $2, 2, 2, 3, 3$ ebenfalls geliefert — nur andere Codewörter.

> *Huffman-Codes sind nicht eindeutig; ihre mittlere Länge sehr wohl. Bei ungünstigen Gleichständen können die Längen verschieden ausfallen — etwa $1, 2, 3, 3$ statt $2, 2, 2, 3$ — mit gleicher mittlerer Länge, aber verschiedener Streuung. Für die Übertragung bevorzugt man die gleichmäßigere.*

Aufgabe 3.2 — Kraft anwenden

Prüfen Sie, welche Längenfolgen möglich sind, und konstruieren Sie im positiven Fall einen Code.

(a)	$1, 2, 3, 3$
(b)	$2, 2, 2, 2, 2$
(c)	$1, 2, 3, 4, 4$
(d)	$2, 3, 3, 3, 4, 4$

Lösung

(a) $1, 2, 3, 3$

$$\tfrac{1}{2} + \tfrac{1}{4} + \tfrac{1}{8} + \tfrac{1}{8} = 1 \quad \checkmark$$

Möglich, und der Baum ist vollständig ausgenutzt.
Ein Code: 0, 10, 110, 111.

(b) $2, 2, 2, 2, 2$

$$5 \cdot \tfrac{1}{4} = 1{,}25 \; > \; 1$$

Nicht möglich. Bei fünf Symbolen und Länge zwei gäbe es nur vier Codewörter.

(c) $1, 2, 3, 4, 4$

$$\tfrac{1}{2} + \tfrac{1}{4} + \tfrac{1}{8} + \tfrac{1}{16} + \tfrac{1}{16} = \tfrac{8+4+2+1+1}{16} = 1 \quad \checkmark$$

Ein Code: 0, 10, 110, 1110, 1111.

(d) 2, 3, 3, 3, 4, 4

$$\tfrac{1}{4} + 3 \cdot \tfrac{1}{8} + 2 \cdot \tfrac{1}{16} = 0{,}25 + 0{,}375 + 0{,}125 = 0{,}75 \;\leq\; 1 \quad \checkmark$$

Möglich — mit Reserve.
Ein Code: 00, 010, 011, 100, 1010, 1011.

Schritt 5 — Die Reserve ausnutzen

Bei (d) bleibt ein Viertel des Baums frei. Man kann daher ein Codewort verkürzen:

$$2, 3, 3, 3, 4, 4 \;\longrightarrow\; 2, 2, 3, 3, 4, 4$$

$$2 \cdot \tfrac{1}{4} + 2 \cdot \tfrac{1}{8} + 2 \cdot \tfrac{1}{16} = 0{,}5 + 0{,}25 + 0{,}125 = 0{,}875 \;\leq\; 1 \quad \checkmark$$

Und weiter:

$$2, 2, 2, 3, 4, 4: \quad 3 \cdot \tfrac{1}{4} + \tfrac{1}{8} + 2 \cdot \tfrac{1}{16} = 0{,}75 + 0{,}125 + 0{,}125 = 1 \quad \checkmark$$

Ein Code mit Kraft-Summe unter eins ist stets verbesserungsfähig. Ein optimaler Code schöpft den Baum vollständig aus.

Das ist ein brauchbares Prüfkriterium: Findet man bei einem Code die Kraft-Summe kleiner als eins, so ist er sicher nicht optimal — ohne dass man die Wahrscheinlichkeiten kennen müsste. Umgekehrt gilt das nicht: Kraft-Summe eins ist notwendig, nicht hinreichend.

Gegenbeispiel dazu: Längen $1, 2, 3, 3$ bei den Wahrscheinlichkeiten $(0{,}1;\ 0{,}2;\ 0{,}3;\ 0{,}4)$ haben Kraft-Summe eins und die mittlere Länge $0{,}1 + 0{,}4 + 0{,}9 + 1{,}2 = 2{,}6$ — der Huffman-Code für diese Verteilung liefert $2 \cdot 0{,}4 + 2 \cdot 0{,}3 + 2 \cdot 0{,}2 + 2 \cdot 0{,}1 = 2{,}0$.

Aufgabe 3.3 — Warum kein Verfahren alles komprimiert

Zeigen Sie, dass es keine umkehrbare Abbildung gibt, die jede Binärfolge echt verkürzt.

Lösung

Schritt 1 — Die Behauptung

Sei C eine umkehrbare Abbildung von Binärfolgen auf Binärfolgen mit

$$|C(x)| < |x| \qquad \text{für alle } x.$$

Schritt 2 — Abzählen

Wir betrachten alle Folgen der Länge genau n. Davon gibt es 2^n.
Ihre Bilder haben Längen $0, 1, \ldots, n-1$. Die Zahl *aller* Folgen dieser Längen beträgt

$$\sum_{k=0}^{n-1} 2^k = 2^n - 1.$$

Schritt 3 — Der Widerspruch

$$2^n \text{ Urbilder} \quad \longrightarrow \quad 2^n - 1 \text{ mögliche Bilder}$$

Nach dem Schubfachprinzip müssen zwei Folgen dasselbe Bild haben — C ist nicht umkehrbar. ■

Schritt 4 — Die schärfere Aussage

Man kann mehr sagen: Verkürzt ein Verfahren *irgendeine* Folge, so verlängert es eine andere.
Begründung: Die Abbildung ist umkehrbar, also injektiv. Verkürzt sie eine Folge, so ist ein Bildwort kürzer besetzt, und für die verbleibenden Urbilder stehen entsprechend weniger kurze Bilder zur Verfügung.

Schritt 5 — Wie viele Folgen sich überhaupt verkürzen lassen

Wie viele Folgen der Länge n können um mindestens k Bit verkürzt werden?
Es gibt höchstens $2^{n-k+1} - 1 < 2^{n-k+1}$ Folgen kürzer als $n - k + 1$.

$$\frac{2^{n-k+1}}{2^n} = 2^{1-k}$$

Ersparnis	**Anteil höchstens**
1 Bit	100 %
5 Bit	6,3 %
10 Bit	0,20 %
20 Bit	0,0002 %

Weniger als ein Promille aller Folgen lässt sich um zehn Bit verkürzen.

Schritt 6 — Warum Kompression trotzdem funktioniert

> *Der scheinbare Widerspruch löst sich so auf: Die allermeisten Binärfolgen sind nicht komprimierbar — aber sie kommen auch nicht vor. Tatsächliche Daten stammen aus einer sehr kleinen Teilmenge, die durch Struktur ausgezeichnet ist.* ***Kompression funktioniert nicht, weil Daten komprimierbar wären, sondern weil die vorkommenden Daten es sind.***
>
> *Damit ist die Frage von Kapitel 7 gestellt: Was zeichnet die komprimierbaren Folgen aus? Die Antwort führt auf einen Zufallsbegriff, der ohne Wahrscheinlichkeiten auskommt — und auf einen Satz, der besagt, dass man einer gegebenen Folge ihre Komprimierbarkeit nicht ansehen kann.*

Eine Semesterarbeit

Robert Fano (1917–2016) lehrte 1951 am MIT Informationstheorie. Er stellte seinen Studenten frei, statt der Abschlussprüfung eine Semesterarbeit zu schreiben — und schlug als Thema vor, den bestmöglichen Präfixcode zu finden.

Was Fano den Studenten nicht sagte: Er selbst und Shannon hatten es vergeblich versucht. Ihr Verfahren — die Shannon-Fano-Codierung — teilt die Symbole von oben her in möglichst gleich wahrscheinliche Hälften und ist gut, aber nachweislich nicht optimal.

Huffman

David Huffman (1925–1999), damals Doktorand, arbeitete monatelang erfolglos. Er hatte die Arbeit bereits aufgegeben und wollte für die Prüfung lernen, als ihm die entscheidende Einsicht kam: Man muss den Baum nicht von oben, sondern *von unten* aufbauen.

Huffman erzählte später, er habe seine Notizen gerade in den Papierkorb geworfen, als ihm der Gedanke kam. Die Arbeit erschien 1952 auf vier Seiten. Sein Verfahren ist bis heute in Gebrauch — in Bildformaten, in Archivprogrammen, in praktisch jedem Gerät, das Daten komprimiert.

Warum von unten

Der Unterschied ist der zwischen zwei Denkweisen: Von oben teilt man auf und hofft, dass die Teilungen gut ausfallen — ein gieriges Verfahren im Sinn von Band 19, Kapitel 12. Von unten fängt man bei den Symbolen an, über die man etwas Sicheres weiß: dass die beiden seltensten die längsten Wörter bekommen müssen. ***Huffmans Verfahren ist ebenfalls gierig — aber an der richtigen Stelle.***

Was danach kam

Die arithmetische Codierung wurde in den 1970er Jahren entwickelt und erreicht die Entropie beliebig genau, ohne Codetabelle.

Sie war jahrzehntelang durch Patente belastet, was ihrer Verbreitung schadete und dem Huffman-Verfahren ein langes Leben sicherte. Seit dem Auslaufen der Patente ist sie in modernen Formaten die Regel.

Kompression heute

Arithmetisch	Die Nachricht wird auf ein Teilintervall von $[0,1)$ abgebildet; die Länge des Intervalls ist ihre Wahrscheinlichkeit.
Wörterbuch-verfahren	Wiederkehrende Teilfolgen durch Verweise ersetzen — erreicht die Entropierate ohne sie zu kennen.
Verlustbehaftet	Bild und Ton: Man verwirft Anteile, die der Empfänger nicht wahrnimmt.

Zur ersten Zeile

Die Zahl braucht etwa $-\operatorname{ld} p$ Bit, wenn p die Wahrscheinlichkeit der Nachricht ist —

also genau den Informationsgehalt.

Damit entfällt die Ganzzahligkeitsbeschränkung, die Satz 3.3 den Verlust von bis zu einem Bit einbrachte: Ein Symbol darf 0,03 Bit kosten, wenn es sehr häufig ist. Der Überhang beträgt bei arithmetischer Codierung wenige Bit für die gesamte Nachricht, nicht je Symbol.

Zur zweiten Zeile

Abraham Lempel und **Jacob Ziv** gaben 1977 und 1978 zwei Verfahren an, die ihr Wörterbuch während des Lesens aufbauen.

*Bemerkenswert ist ihre Eigenschaft, **universell** zu sein: Sie erreichen die Entropierate jeder stationären Quelle, ohne sie zu kennen. Das ist eine erstaunliche Aussage — ein Verfahren, das dieselbe Grenze erreicht wie eines, dem man die Verteilung mitteilt. Fast alle heutigen Archivformate beruhen darauf.*

Und die Grenze

*Seit etwa 2019 werden Kompressionsverfahren untersucht, die große Sprachmodelle als Wahrscheinlichkeitsschätzer verwenden. Sie erreichen bei Text deutlich bessere Werte als klassische Verfahren — um den Preis, dass Sender und Empfänger dasselbe Modell mit Milliarden Parametern besitzen müssen. **Der Modellumfang zählt bei einer ehrlichen Bilanz mit**, und das ist genau die Frage, die Kapitel 7 stellt.*

Was Sie jetzt können

Satz 3.1	Kraft: $\sum 2^{-l_i} \leq 1$
Satz 3.2	$L \geq H$, Gleichheit nur dyadisch
Satz 3.3	$H \leq L < H + 1$
Satz 3.4	Huffman ist optimal
Blöcke	Überhang schrumpft wie $1/n$

Damit endet Teil I. Bisher war die Übertragung fehlerfrei. Ab Kapitel 4 stört jemand — und die Frage lautet, was dann noch durchkommt.

Teil II

Der gestörte Kanal

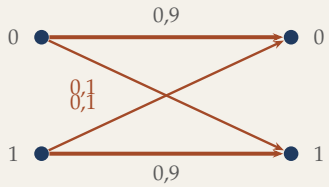
Kapitel 4

Transinformation und Kapazität

4.1 Der Leitfall

Funk zum Rettungswagen

Das Klinikum überträgt Vitaldaten per Funk. Die Strecke ist gestört: Jedes gesendete Bit kippt unabhängig mit der Wahrscheinlichkeit $f = 0{,}1$.



binärer symmetrischer Kanal

Die Frage: Wie viel lässt sich je Kanalbenutzung fehlerfrei übertragen?

> *Die naheliegende Antwort lautet: weniger als ein Bit, und zwar umso weniger, je fehlerfreier man es haben will. Die richtige Antwort ist* 0,531 *Bit — und zwar bei beliebig kleiner Fehlerrate. Dieses Kapitel erklärt, woher die Zahl kommt; Kapitel 5 beweist, dass sie erreichbar ist.*

4.2 Transinformation

Definition 4.1

Die **Transinformation** zwischen X und Y ist

$$I(X;Y) = H(X) - H(X \mid Y).$$

Satz 4.2 — drei gleichwertige Formen

$$I(X;Y) = H(X) - H(X \mid Y) = H(Y) - H(Y \mid X) = H(X) + H(Y) - H(X,Y)$$

Beweis

Nach der Kettenregel (Satz 2.5) gilt

$$H(X,Y) = H(Y) + H(X \mid Y) \quad \Longrightarrow \quad H(X \mid Y) = H(X,Y) - H(Y)$$

Einsetzen in Definition 4.1:

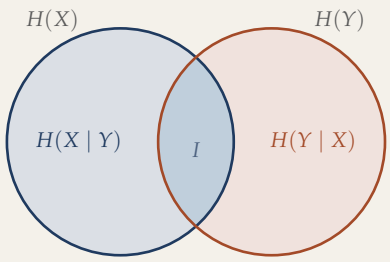
$$I(X;Y) = H(X) - H(X,Y) + H(Y)$$

Das ist die dritte Form. Sie ist in X und Y symmetrisch, also stimmt sie auch mit der zweiten überein. ■

Die Transinformation ist symmetrisch: Was Y über X verrät, ist genau so viel wie umgekehrt.

Das ist keineswegs selbstverständlich. Der Laborwert verrät 0,12 *Bit über die Diagnosegruppe, und die Diagnosegruppe genau so viel über den Laborwert — obwohl beide Größen ganz verschiedene Entropien haben* (0,81 *und* 0,72 *Bit).* ***Die Auskunft ist gegenseitig und gleich groß.***

Das Bild



$H(X,Y)$ *ist die Gesamtfläche*

Das Bild ist eine nützliche Merkhilfe und hat eine Grenze: Bei drei Größen kann der "Schnitt aller drei" negativ werden. Die Mengenanalogie trägt also nur bis zu zwei Größen; darüber hinaus muss man rechnen.

4.3 Die relative Entropie

Definition 4.3

Für zwei Verteilungen p und q über derselben Menge ist die **relative Entropie**

$$D(p \,\|\, q) = \sum_i p_i \operatorname{ld} \frac{p_i}{q_i}.$$

Satz 4.4 — sie ist nichtnegativ

$$D(p \,\|\, q) \;\geq\; 0,$$

mit Gleichheit genau dann, wenn $p = q$.

Beweis

$$\begin{aligned} -D(p \,\|\, q) &= \sum_i p_i \operatorname{ld} \frac{q_i}{p_i} \\ &\leq \operatorname{ld} \left(\sum_i p_i \cdot \frac{q_i}{p_i} \right) && \text{(Jensen, ld konkav)} \\ &= \operatorname{ld} \left(\sum_i q_i \right) = \operatorname{ld} 1 = 0 \end{aligned}$$

Gleichheit gilt wegen der strengen Konkavität genau dann, wenn alle $\frac{q_i}{p_i}$ übereinstimmen — und da beide Summen eins ergeben, bedeutet das $p_i = q_i$. ■

> *Dieser Beweis ist zum dritten Mal derselbe — nach Satz 2.2 und Satz 3.2. Tatsächlich sind beide Sonderfälle: Satz 2.2 ist $D(p \,\|\, \text{gleichverteilt}) \geq 0$, Satz 3.2 ist $D(p \,\|\, q) \geq 0$ mit $q_i = 2^{-l_i}$.* ***Die relative Entropie ist das gemeinsame Werkzeug hinter allen Ungleichungen dieses Bandes.***

Satz 4.5 — Transinformation ist nichtnegativ

$$I(X;Y) = D\big(p(x,y) \,\|\, p(x)p(y)\big) \;\geq\; 0$$

mit Gleichheit genau bei Unabhängigkeit.

Beweis der ersten Gleichung

$$\begin{aligned} D\big(p(x,y) \,\|\, p(x)p(y)\big) &= \sum_{x,y} p(x,y) \operatorname{ld} \frac{p(x,y)}{p(x)p(y)} \\ &= \sum_{x,y} p(x,y) \operatorname{ld} p(x,y) - \sum_{x,y} p(x,y) \operatorname{ld} p(x) - \sum_{x,y} p(x,y) \operatorname{ld} p(y) \\ &= -H(X,Y) + H(X) + H(Y) \end{aligned}$$

Das ist die dritte Form aus Satz 4.2. ✓

Der Rest

Folgt aus Satz 4.4. Gleichheit bedeutet $p(x,y) = p(x)p(y)$ — also Unabhängigkeit. ■

> **Damit ist auch Satz 2.6 bewiesen:** Aus $I \geq 0$ und $I = H(Y) - H(Y \mid X)$ folgt $H(Y \mid X) \leq H(Y)$.

Die Transinformation misst also, wie weit zwei Größen von der Unabhängigkeit entfernt sind — gemessen als relative Entropie zwischen der tatsächlichen Verbundverteilung und derjenigen, die bei Unabhängigkeit vorläge. Das ist ein Abhängigkeitsmaß, das im Gegensatz zur Korrelation aus Band 17 auch nichtlineare Zusammenhänge erfasst.

4.4 Die Kanalkapazität

Definition 4.6

Ein **diskreter gedächtnisloser Kanal** ist gegeben durch die Übergangswahrscheinlichkeiten $p(y \mid x)$. Seine **Kapazität** ist

$$C = \max_{p(x)} I(X;Y).$$

Was das Maximum bedeutet

Fest	Der Kanal, also $p(y \mid x)$ — den kann man nicht ändern.
Wählbar	Die Eingangsverteilung $p(x)$ — über sie verfügt der Sender.
Gesucht	Die beste Wahl und der dabei erreichte Wert.

Die Kapazität ist eine Eigenschaft des Kanals allein. Sie sagt zunächst nur, wie viel Information im besten Fall je Benutzung hindurchkommt. Dass sie zugleich die Grenze für fehlerfreie Übertragung ist, behauptet erst Kapitel 5 — und das ist der eigentliche Satz.

Satz 4.7 — die Kapazität des binären symmetrischen Kanals

$$C = 1 - h(f)$$

mit h als binärer Entropiefunktion, erreicht bei gleichverteiltem Eingang.

Beweis — Schritt 1: die bedingte Entropie
Ist $X = 0$, so ist Y mit Wahrscheinlichkeit f gleich 1:

$$H(Y \mid X = 0) = h(f)$$

Ebenso $H(Y \mid X = 1) = h(f)$.

$$H(Y \mid X) = p(0)\,h(f) + p(1)\,h(f) = h(f)$$

$H(Y \mid X)$ **hängt nicht von der Eingangsverteilung ab.** Das ist die Besonderheit symmetrischer Kanäle und macht die Rechnung kurz.

Schritt 2 — maximieren

$$I(X;Y) = H(Y) - H(Y \mid X) = H(Y) - h(f)$$

Da nur $H(Y)$ von $p(x)$ abhängt, ist $H(Y)$ zu maximieren. Nach Satz 2.2 ist $H(Y) \leq 1$, mit Gleichheit bei $p(Y=0) = \frac{1}{2}$.

Schritt 3 — das wird erreicht

Bei $p(X=0) = \frac{1}{2}$ gilt

$$p(Y=0) = \tfrac{1}{2}(1-f) + \tfrac{1}{2}f = \tfrac{1}{2} \quad \checkmark$$

Also $C = 1 - h(f)$. ■

Die Werte

f	$h(f)$	C	
0,00	0,0000	1,0000	ungestört
0,01	0,0808	0,9192	
0,05	0,2864	0,7136	
0,10	0,4690	**0,5310**	Leitfall
0,25	0,8113	0,1887	
0,50	1,0000	**0,0000**	wertlos
0,90	0,4690	0,5310	
1,00	0,0000	1,0000	

Die beiden bemerkenswerten Zeilen

Bei $f = \frac{1}{2}$ ist die Kapazität null. Der Ausgang ist dann von der Eingabe unabhängig — ein reiner Münzwurf.

Bei $f = 1$ ist sie wieder eins. Ein Kanal, der *jedes* Bit umkehrt, überträgt vollständig — man muss nur umdrehen.

Die Kurve ist symmetrisch um $f = \frac{1}{2}$, und dort liegt der einzige wertlose Fall. ***Nicht die Stärke der Störung ist entscheidend, sondern ihre Berechenbarkeit.*** *Eine Störung, die immer zuschlägt, ist keine.*

Der Leitfall

Bei $f = 0{,}1$ beträgt die Kapazität 0,531 Bit je Kanalbenutzung. Bei 10 000 Übertragungen je Sekunde sind das

5310 Bit je Sekunde

— fehlerfrei, mit geeigneter Codierung.

4.5 Andere Kanäle

Der Auslöschungskanal

Hier geht ein Bit mit Wahrscheinlichkeit e verloren — der Empfänger erhält ein drittes Zeichen "unbekannt", aber nie ein falsches.

$$C = 1 - e$$

Warum das anschaulich ist

Ein Anteil e der Bits geht verloren, der Rest kommt unversehrt an.

> *Der Vergleich ist lehrreich: Bei $e = 0{,}1$ ist $C = 0{,}9$, bei $f = 0{,}1$ nur 0,531.* ***Ein Fehler, von dem man weiß, dass er aufgetreten ist, kostet erheblich weniger als einer, den man nicht bemerkt.*** *Deshalb bauen viele Systeme absichtlich eine Erkennung ein und behandeln erkannte Fehler als Auslöschungen.*

Der Z-Kanal

Eine Null kommt sicher an, eine Eins kippt mit Wahrscheinlichkeit f — etwa bei einem Sensor, der Signale übersehen, aber nicht erfinden kann.

f	C	**bestes** $p(1)$
0,1	0,763	0,456
0,5	0,322	0,400

Die beste Eingangsverteilung ist nicht gleichverteilt. Man sendet die störanfällige Eins etwas seltener.

> *Und der Vergleich zum symmetrischen Kanal überrascht: Bei $f = 0{,}5$ hat der Z-Kanal noch 0,32 Bit Kapazität, der symmetrische null. Obwohl die Hälfte der Einsen verlorengeht, bleibt Information übrig — weil eine empfangene Eins sicher eine gesendete Eins war.* ***Asymmetrie ist ein Vorteil.***

4.6 Der Bruchfall

Was Definition 4.6 voraussetzt

Gedächtnislos	Jede Benutzung stört unabhängig. Tatsächliche Funkstrecken haben Schwundlöcher — Fehler treten gebündelt auf.
Bekannt	Die Übergangswahrscheinlichkeiten müssen bekannt sein. Sie schwanken mit Wetter, Entfernung und Störquellen.
Diskret	Reale Kanäle sind stetig; die Diskretisierung ist selbst eine Modellentscheidung.

Zur ersten Zeile

Bei gebündelten Fehlern ist die Kapazität *höher* als beim gedächtnislosen Kanal gleicher mittlerer Fehlerrate — die Bündelung ist zusätzliche Struktur, die man ausnutzen kann.

> *Praktisch nutzt man das durch **Verschachtelung**: Man verteilt die Bits eines Codeworts über einen längeren Zeitraum, so dass ein Schwundloch viele Codewörter leicht statt eines schwer trifft. Das ist eine Anpassung des Systems an den Kanal, nicht umgekehrt.*

Zur dritten Zeile

Für den stetigen Kanal mit Gaußschem Rauschen gilt

$$C = \tfrac{1}{2}\,\mathrm{ld}\left(1 + \frac{S}{N}\right)\ \text{Bit je Benutzung}$$

mit dem Verhältnis S/N von Signal- zu Rauschleistung.

> *Das ist die berühmteste Formel der Nachrichtentechnik. Sie besagt, dass die Kapazität nur logarithmisch mit der Sendeleistung wächst: Eine Verdopplung der Leistung bringt bei gutem Empfang etwa ein halbes Bit. Wer die Datenrate verdoppeln will, braucht bei hohem S/N die quadrierte Leistung — oder mehr Bandbreite.*

Und die Kapazität ist noch keine Aussage über Codes

Definition 4.6 definiert ein Maximum von Transinformation. Dass dieses Maximum die Grenze fehlerfreier Übertragung ist, steht dort nicht.

> *Beide Richtungen sind eigene Sätze. Dass man nicht mehr übertragen kann, folgt aus der Datenverarbeitungsungleichung; dass man so viel erreichen kann, war Shannons eigentliche Leistung — und sein Beweis ist nicht konstruktiv. Kapitel 5 behandelt beides.*

4.7 Übungsaufgaben

Aufgabe 4.1 — Transinformation berechnen

Für die Verbundverteilung aus Kapitel 2

	$Y=+$	$Y=-$
$X=A$	0,125	0,125
$X=\bar{A}$	0,075	0,675

berechnen Sie $I(X;Y)$ auf drei Wegen.

Lösung

Weg 1 — über $H(Y)-H(Y\mid X)$
Aus Kapitel 2: $H(Y)=0{,}7219$, $H(Y\mid X)=0{,}6017$.

$$I = 0{,}7219 - 0{,}6017 = \mathbf{0{,}1202}$$

Weg 2 — über $H(X)-H(X\mid Y)$
$H(X)=0{,}8113$, $H(X\mid Y)=H(X,Y)-H(Y)=1{,}4130-0{,}7219=0{,}6911$.

$$I = 0{,}8113 - 0{,}6911 = \mathbf{0{,}1202} \quad \checkmark$$

Weg 3 — über die relative Entropie

$$I = \sum_{x,y} p(x,y)\ \mathrm{ld}\,\frac{p(x,y)}{p(x)p(y)}$$

(x,y)	$p(x,y)$	$p(x)p(y)$	**Quotient**	**Beitrag**
$(A,+)$	0,125	0,050	2,500	0,1653
$(A,-)$	0,125	0,200	0,625	−0,0848
$(\bar{A},+)$	0,075	0,150	0,500	−0,0750
$(\bar{A},-)$	0,675	0,600	1,125	0,1147
				0,1202

Zum ersten Beitrag: $0{,}125\cdot \mathrm{ld}\,2{,}5 = 0{,}125\cdot 1{,}3219 = 0{,}1653$.
Zum zweiten: $0{,}125\cdot \mathrm{ld}\,0{,}625 = 0{,}125\cdot(-0{,}6781) = -0{,}0848$.

> **Beachten Sie die negativen Beiträge.** Die Transinformation ist als Ganzes nichtnegativ; einzelne Summanden können sehr wohl negativ sein.

Schritt 4 — Die Deutung

	Bit	**Anteil**
$H(X)$	0,8113	100 %
davon I	0,1202	14,8 %

Der Laborwert nimmt knapp fünfzehn Prozent der Ungewissheit über die Diagnosegruppe. Das ist ein brauchbarer, aber kein durchschlagender Befund — und die Zahl ist eine sinnvolle Kenngröße für die Güte eines diagnostischen Tests, die neben Empfindlichkeit und Trennschärfe aus Band 17 tritt.

Aufgabe 4.2 — Kapazitäten vergleichen

Bestimmen Sie die Kapazität:

(a)	Binärer symmetrischer Kanal mit $f = 0{,}05$.
(b)	Auslöschungskanal mit $e = 0{,}05$.
(c)	Zwei unabhängige Kanäle nach (a) nebeneinander.
(d)	Ein Kanal nach (a), zweimal hintereinander durchlaufen.

Lösung

(a)

$$h(0{,}05) = -0{,}05 \operatorname{ld} 0{,}05 - 0{,}95 \operatorname{ld} 0{,}95$$
$$= 0{,}05 \cdot 4{,}3219 + 0{,}95 \cdot 0{,}0740 = 0{,}2161 + 0{,}0703 = 0{,}2864$$
$$C = 1 - 0{,}2864 = \mathbf{0{,}7136}$$

(b)

$$C = 1 - 0{,}05 = \mathbf{0{,}9500}$$

Vergleich: Derselbe Störanteil kostet beim Auslöschungskanal 0,05 Bit, beim symmetrischen 0,29 — fast das Sechsfache.

(c) Zwei parallele Kanäle

Die Kapazitäten addieren sich:

$$C = 2 \cdot 0{,}7136 = \mathbf{1{,}4272}$$

Begründung: Die beiden Kanäle stören unabhängig, also ist die Transinformation des Paares die Summe.

(d) Zwei Kanäle hintereinander

Ein Bit kommt genau dann richtig an, wenn es entweder zweimal richtig oder zweimal falsch übertragen wurde:

$$f_{\text{ges}} = 2 \cdot 0{,}05 \cdot 0{,}95 = 0{,}095$$

$$h(0{,}095) = 0{,}095 \cdot 3{,}3959 + 0{,}905 \cdot 0{,}1440 = 0{,}3226 + 0{,}1303 = 0{,}4529$$
$$C = 1 - 0{,}4529 = \mathbf{0{,}5471}$$

Die Übersicht

	C	
(a) einfach	0,7136	
(b) Auslöschung	0,9500	erkennbare Fehler
(c) parallel	1,4272	doppelt
(d) hintereinander	0,5471	weniger als (a)

Hintereinandergeschaltete Kanäle können nur verlieren.

*Das ist ein Sonderfall der **Datenverarbeitungsungleichung**: Bilden $X \to Y \to Z$ eine Kette, in der Z nur über Y von X abhängt, so gilt $I(X;Z) \leq I(X;Y)$. **Keine Nachbearbeitung kann Information hinzufügen, die nicht angekommen ist.** Kapitel 5 beweist die Ungleichung und benutzt sie für die Umkehrung des Codierungstheorems.*

Aufgabe 4.3 — Der Wiederholungscode

Beim Leitfall ($f = 0{,}1$) wird jedes Bit n-mal gesendet; der Empfänger entscheidet nach Mehrheit. Bestimmen Sie Rate und Fehlerwahrscheinlichkeit und vergleichen Sie mit der Kapazität.

Lösung

Schritt 1 — Die Fehlerwahrscheinlichkeit

Ein Fehler tritt auf, wenn mehr als die Hälfte der Bits kippt:

$$P_e = \sum_{i=\lceil n/2 \rceil}^{n} \binom{n}{i} f^i \, (1-f)^{n-i}$$

Schritt 2 — Für $n = 3$

$$P_e = \binom{3}{2}(0{,}1)^2(0{,}9) + \binom{3}{3}(0{,}1)^3 = 3 \cdot 0{,}009 + 0{,}001 = 0{,}028$$

Schritt 3 — Für $n = 5$

$$P_e = 10\,(0{,}1)^3(0{,}9)^2 + 5\,(0{,}1)^4(0{,}9) + (0{,}1)^5$$

$$= 10 \cdot 0{,}00081 + 5 \cdot 0{,}00009 + 0{,}00001 = 0{,}0081 + 0{,}00045 + 0{,}00001 = 0{,}00856$$

Schritt 4 — Die Tabelle

n	**Rate**	P_e
1	1,0000	$1{,}0 \cdot 10^{-1}$
3	0,3333	$2{,}8 \cdot 10^{-2}$
5	0,2000	$8{,}6 \cdot 10^{-3}$
9	0,1111	$8{,}9 \cdot 10^{-4}$
11	0,0909	$3{,}0 \cdot 10^{-4}$
21	0,0476	$1{,}4 \cdot 10^{-6}$

Schritt 5 — Der Befund

Um die Fehlerrate zu senken, muss die Rate gesenkt werden — und für $P_e \to 0$ geht sie gegen null.

Schritt 6 — Der Vergleich mit der Kapazität

$$C = 1 - h(0{,}1) = 0{,}5310$$

	Rate	P_e
Wiederholung, $n = 21$	0,048	$1{,}4 \cdot 10^{-6}$
Shannon	**0,531**	**beliebig klein**

Die Kapazität liegt beim Elffachen dessen, was der Wiederholungscode bei dieser Fehlerrate schafft.

Schritt 7 — Warum Wiederholung so schlecht ist

Der Wiederholungscode schützt jedes Bit einzeln. Ein guter Code schützt einen ganzen Block gemeinsam — und nutzt dabei aus, dass die Zahl der möglichen Fehlermuster viel kleiner ist als die Zahl der möglichen Blöcke. Bei einem Block von 100 Bit und $f = 0{,}1$ sind typischerweise etwa zehn Bit falsch. Die Zahl der Fehlermuster mit höchstens zehn falschen Bit beträgt rund 2^{47} — gegenüber 2^{100} Blöcken.

Genauer: $100 \cdot h(0{,}1) = 46{,}9$, und das ist der Logarithmus der Zahl typischer Fehlermuster. Von den hundert Bit gehen also 46,9 an die Störung verloren, und 53,1 bleiben nutzbar — genau $100 \cdot C$. ***Das ist der ganze Gedanke des nächsten Kapitels, an einer einzigen Zahl abgelesen.***

Eine Zahl, die niemand erwartet hatte

Vor 1948 galt als ausgemacht, dass Störungen nur durch Wiederholung zu bekämpfen

sind — und dass fehlerfreie Übertragung deshalb unendlich langsam werden muss.

> *Die Rechnung aus Aufgabe 4.3 war bekannt und schien die Sache zu entscheiden: Die Fehlerrate fällt exponentiell, die Rate aber wie $1/n$. Für beliebig kleine Fehler muss man beliebig langsam werden.*

Der Bruch

Shannon zeigte, dass diese Schlussfolgerung nur für *Wiederholungscodes* gilt — und dass es bessere gibt.

> *Zeitgenossen berichteten, das Ergebnis sei zunächst auf Unglauben gestoßen. Es widerspricht nicht nur der Anschauung, sondern auch der Erfahrung jedes Nachrichtentechnikers. **Robert Fano** sagte später, er habe nicht geglaubt, dass so etwas möglich sei, bis er den Beweis mehrfach durchgegangen sei.*

Die Vorgeschichte der Größe

Der Begriff der Kanalkapazität stammt in Ansätzen von **Nyquist** (1924), der die höchste Symbolrate bei gegebener Bandbreite bestimmte, und von **Hartley** (1928).

> *Beiden fehlte die Behandlung des Rauschens. Shannons Beitrag war, Störungen nicht als technischen Mangel zu behandeln, sondern als wahrscheinlichkeitstheoretisches Objekt — und damit dieselbe Größe darauf anzuwenden, die er für Quellen entwickelt hatte.*

Die relative Entropie

Solomon Kullback und **Richard Leibler** führten sie 1951 ein, als Maß für die Unterscheidbarkeit zweier Verteilungen.

> *Kullback arbeitete zu dieser Zeit für den amerikanischen Nachrichtendienst und hatte während des Krieges an der Entzifferung japanischer Chiffren mitgewirkt. Die Größe, die heute in der Statistik und im maschinellen Lernen allgegenwärtig ist, entstand aus der Frage, wie gut sich zwei Hypothesen anhand abgefangener Nachrichten trennen lassen.*

Kapazität in der Praxis

Mehrantennen-systeme	Mehrere Sende- und Empfangsantennen erzeugen mehrere parallele Kanäle; die Kapazität wächst näherungsweise linear mit ihrer Zahl.
Netzwerke	Für Kanäle mit mehreren Sendern und Empfängern ist die Kapazität in vielen Fällen bis heute unbekannt.
Rückkanal	Eine Rückmeldung erhöht die Kapazität des gedächtnislosen Kanals *nicht* — sie vereinfacht aber die Codes erheblich.

Zur zweiten Zeile

Schon der einfachste Fall — zwei Sender, ein Empfänger, ein Störkanal — ist ungelöst.

> *Für den **Interferenzkanal** mit zwei Sender-Empfänger-Paaren ist die Kapazität seit den 1970er Jahren offen; man kennt Schranken, die sich um höchstens ein Bit unterscheiden — ein Ergebnis von 2008, das als Durchbruch galt. **Die Informationstheorie ist bei einem Sender vollständig und bei mehreren weitgehend offen.***

Zur dritten Zeile

Dass Rückmeldung die Kapazität nicht erhöht, ist ein Satz von Shannon.

> *Das überrascht, weil ein Rückkanal offensichtlich nützlich ist — man kann verlorene Blöcke nachfordern. Der Satz besagt, dass dieser Nutzen in der Einfachheit liegt, nicht in der erreichbaren Rate. Bei Kanälen mit Gedächtnis gilt er allerdings nicht mehr.*

Was Sie jetzt können

Satz 4.2	drei Formen, Symmetrie
Satz 4.4	$D(p\|q) \geq 0$ — das gemeinsame Werkzeug
Satz 4.5	$I \geq 0$, null bei Unabhängigkeit
Definition 4.6	$C = \max_{p(x)} I(X;Y)$
Satz 4.7	$C = 1 - h(f)$ beim BSC

> *Im nächsten Kapitel wird aus der Zahl 0,531 ein Satz — und zwar der überraschendste dieses Bandes.*

Kapitel 5

Das Kanalcodierungstheorem

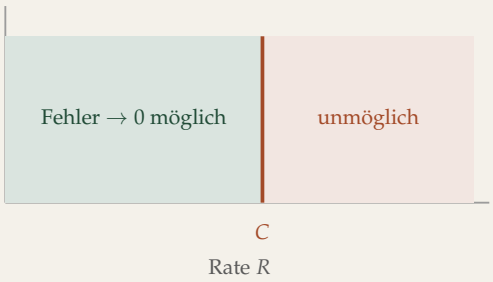
5.1 Die Aussage

Satz 5.1 — Shannon, 1948

Sei C die Kapazität eines diskreten gedächtnislosen Kanals.

Erreichbar	Für jede Rate $R < C$ und jedes $\varepsilon > 0$ gibt es ein n und einen Code der Länge n mit Rate R, dessen Fehlerwahrscheinlichkeit kleiner als ε ist.
Umkehrung	Für $R > C$ lässt sich die Fehlerwahrscheinlichkeit nicht beliebig klein machen.

Der Übergang bei $R = C$ ist scharf. Unterhalb geht alles, oberhalb nichts.



Beide Teile sind bemerkenswert. Die Umkehrung entspricht der Erwartung — irgendwo muss eine Grenze liegen. Die Erreichbarkeit widerspricht ihr: Sie behauptet, dass bis unmittelbar an diese Grenze heran beliebig zuverlässig übertragen werden kann.

5.2 Typische Folgen

Der Schlüsselbegriff

Eine Quelle liefert unabhängige Symbole. Betrachtet man lange Folgen, so zerfällt der Raum aller Folgen in zwei sehr ungleiche Teile.

Ein Zahlenbeispiel
Eine Binärquelle mit $p(1) = 0{,}1$, Folgen der Länge 100.

	Anzahl	**Gesamt-Wahrsch.**
Alle Folgen	2^{100}	1
Typische	$\approx 2^{46{,}9}$	≈ 1

Ein Anteil von $2^{-53{,}1} \approx 10^{-16}$ aller Folgen trägt nahezu die gesamte Wahrscheinlichkeit.

Anschaulich: Fast jede tatsächlich auftretende Folge hat etwa zehn Einsen. Folgen mit fünfzig Einsen gibt es zwar weit mehr, aber sie kommen praktisch nie vor. ***Die Menge der typischen Folgen ist winzig und trägt alles.***

Definition 5.2 — typische Menge

Für $\varepsilon > 0$ ist

$$A_\varepsilon^{(n)} = \left\{ (x_1, \ldots, x_n) \;:\; \left| -\tfrac{1}{n} \operatorname{ld} p(x_1, \ldots, x_n) - H(X) \right| \le \varepsilon \right\}.$$

Satz 5.3 — die asymptotische Gleichverteilungseigenschaft

1	$\Pr\left[A_\varepsilon^{(n)}\right] \to 1$ für $n \to \infty$.
2	$\left\lvert A_\varepsilon^{(n)} \right\rvert \le 2^{\,n(H+\varepsilon)}$.
3	$\left\lvert A_\varepsilon^{(n)} \right\rvert \ge (1-\varepsilon)\, 2^{\,n(H-\varepsilon)}$ für hinreichend großes n.

Beweis von 1
Für unabhängige Symbole gilt

$$-\frac{1}{n} \operatorname{ld} p(x_1, \ldots, x_n) = -\frac{1}{n} \sum_{i=1}^{n} \operatorname{ld} p(x_i).$$

Das ist der Mittelwert von n unabhängigen, gleichverteilten Zufallsgrößen $-\operatorname{ld} p(X_i)$ mit dem Erwartungswert

$$\mathbb{E}\left[-\operatorname{ld} p(X)\right] = -\sum_x p(x) \operatorname{ld} p(x) = H(X).$$

Nach dem schwachen Gesetz der großen Zahlen (Band 12) strebt dieser Mittelwert in Wahrscheinlichkeit gegen $H(X)$. ✓

Beweis von 2
Für jede typische Folge gilt nach Definition

$$p(x_1, \ldots, x_n) \;\ge\; 2^{-n(H+\varepsilon)}.$$

Da die Gesamtwahrscheinlichkeit höchstens eins ist:

$$1 \;\geq\; \sum_{\boldsymbol{x}\in A} p(\boldsymbol{x}) \;\geq\; \big|A\big| \cdot 2^{-n(H+\varepsilon)}$$

Umstellen liefert die Behauptung. ✓

Beweis von 3

Nach Teil 1 ist $\Pr[A] \geq 1-\varepsilon$ für großes n. Andererseits ist jede Einzelwahrscheinlichkeit höchstens $2^{-n(H-\varepsilon)}$:

$$1-\varepsilon \;\leq\; \Pr[A] \;\leq\; |A| \cdot 2^{-n(H-\varepsilon)}$$

■

Der Satz besagt, dass sich die typischen Folgen näherungsweise wie eine Gleichverteilung über 2^{nH} Möglichkeiten verhalten — daher der Name. Das ist der Grund, warum man in der Informationstheorie so oft mit Zweierpotenzen abzählen darf: Man arbeitet in Wahrheit stets auf der typischen Menge.

5.3 Der Beweisgedanke

Die Kugelpackung

Beim binären symmetrischen Kanal mit Fehlerrate f gilt: Wird $\boldsymbol{x}$ gesendet, so ist das Rauschmuster typisch — es enthält etwa nf Einsen.

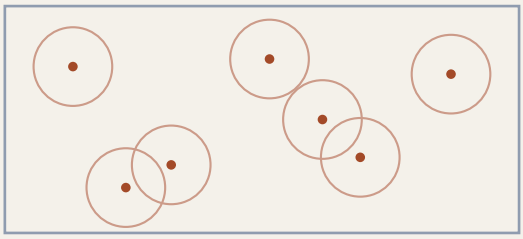
Der Empfangsvektor liegt also in einer "Kugel" von etwa $2^{n\,h(f)}$ Folgen um $\boldsymbol{x}$.

Die Abzählung

	allgemein	$n = 100$, $f = 0{,}1$
Alle Folgen	2^{n}	2^{100}
Eine Kugel	$2^{n\,h(f)}$	$2^{46{,}9}$
Kugeln, die passen	$2^{n(1-h(f))}$	$\mathbf{2^{53{,}1}}$

$$1 - h(f) = C$$

Es passen höchstens 2^{nC} überschneidungsfreie Kugeln in den Raum — also höchstens 2^{nC} Codewörter. Das ergibt die Rate C.



alle 2^n Folgen, je Codewort eine Kugel

Dieses Argument liefert nur die obere Schranke — dass nicht mehr geht. Dass so viele Codewörter tatsächlich unterzubringen sind, folgt daraus nicht: Kugelpackungen lassen im Allgemeinen Zwischenräume. Der zweite Teil ist der schwierigere.

Die Zufallscodierung

Shannons Kunstgriff: Statt einen guten Code zu *konstruieren*, wählt man ihn zufällig und zeigt, dass er im Mittel gut ist.

Der Aufbau

1	Man wähle 2^{nR} Codewörter der Länge n rein zufällig.
2	Sender und Empfänger kennen beide die Tabelle.
3	Der Empfänger entscheidet für dasjenige Codewort, das mit dem Empfangenen typisch verbunden ist.

Die Fehlerabschätzung

Ein Fehler entsteht, wenn ein *falsches* Codewort ebenfalls in die Entscheidungskugel fällt.

Für ein einzelnes falsches Wort:

$$\Pr[\text{fällt hinein}] \approx \frac{2^{n\,h(f)}}{2^n} = 2^{-n(1-h(f))} = 2^{-nC}$$

Für alle $2^{nR}-1$ falschen zusammen — über die Summenabschätzung:

$$\Pr[\text{Fehler}] \lesssim 2^{nR} \cdot 2^{-nC} = 2^{-n(C-R)}$$

Für $R < C$ ist der Exponent negativ — die Fehlerwahrscheinlichkeit fällt exponentiell in n.

Die Zahlen für den Leitfall

$f = 0{,}1$, also $C = 0{,}531$:

n	R	**Exponent**	**Schranke**
100	0,20	$-33{,}1$	$1{,}1 \cdot 10^{-10}$
100	0,40	$-13{,}1$	$1{,}1 \cdot 10^{-4}$
100	0,50	$-3{,}1$	$1{,}2 \cdot 10^{-1}$
1000	0,40	-131	$3{,}7 \cdot 10^{-40}$
1000	0,50	-31	$4{,}6 \cdot 10^{-10}$
10 000	0,52	-110	$7{,}5 \cdot 10^{-34}$

Die letzte Zeile ist der Punkt: Bei einer Rate von 0,52 — also 98 Prozent der Kapazität — ist die Fehlerwahrscheinlichkeit bei Blocklänge 10 000 kleiner als 10^{-33}. Zum Vergleich: Der Wiederholungscode aus Aufgabe 4.3 erreichte bei Rate 0,048 nur 10^{-6}.

Der letzte Schritt

Die Rechnung liefert den *Mittelwert* über alle zufälligen Codes. Ist der Mittelwert kleiner als ε, so muss mindestens ein Code mindestens so gut sein.

Also existiert ein guter Code. Welcher, sagt der Beweis nicht.

5.4 Die Umkehrung

Satz 5.4 — die Ungleichung von Fano

Schätzt man X aus Y mit der Fehlerwahrscheinlichkeit P_e, so gilt

$$H(X \mid Y) \;\le\; h(P_e) + P_e \,\operatorname{ld}\bigl(|\mathcal{X}| - 1\bigr).$$

Der Gedanke

Die verbleibende Ungewissheit zerfällt in zwei Teile: die Frage, *ob* ein Fehler vorliegt — höchstens $h(P_e)$ Bit — und im Fehlerfall die Frage, welcher der übrigen Werte richtig ist.

Ist P_e klein, so ist $H(X \mid Y)$ klein. Das ist die Richtung, die für die Umkehrung gebraucht wird.

P_e	**Schranke bei** $\lvert\mathcal{X}\rvert = 2$	
0,001	0,0114	
0,010	0,0808	
0,100	0,4690	
0,500	1,0000	wertlos

Satz 5.5 — die Datenverarbeitungsungleichung

Bilden $X \to Y \to Z$ eine Kette — also hängt Z nur über Y von X ab —, so gilt

$$I(X;Z) \;\leq\; I(X;Y).$$

Keine Nachbearbeitung kann Information hinzufügen, die nicht angekommen ist.

Das ist die Aussage hinter Aufgabe 4.2(d), wo zwei hintereinandergeschaltete Kanäle weniger leisteten als einer. Sie hat weitreichende Folgen: ***Kein noch so raffiniertes Verfahren kann aus verrauschten Daten mehr herausholen, als in ihnen steckt*** *— eine Warnung, die in der Datenauswertung so oft überhört wird wie in der Nachrichtentechnik.*

Die Umkehrung des Codierungstheorems

Der Aufbau

Eine Nachricht W aus 2^{nR} Möglichkeiten wird codiert, über den Kanal geschickt und zu $\hat{W}$ decodiert.

Schritt 1 — die Entropie der Nachricht

Bei gleichverteilter Nachricht:

$$H(W) = nR$$

Schritt 2 — zerlegen

$$nR = H(W) = I(W;\hat{W}) + H(W \mid \hat{W})$$

Schritt 3 — beide Teile abschätzen

$I(W;\hat{W})$	$\leq n\,C$ nach Satz 5.5, da $W \to X^n \to Y^n \to \hat{W}$
$H(W \mid \hat{W})$	$\leq 1 + P_e \cdot nR$ nach Satz 5.4

Schritt 4 — zusammensetzen

$$nR \;\leq\; nC + 1 + P_e\, nR$$

Division durch n:

$$R \;\leq\; C + \frac{1}{n} + P_e\, R$$

Schritt 5 — der Schluss

Soll $P_e \to 0$ gelten, so folgt im Grenzwert

$$R \;\leq\; C.$$

■

Umgestellt liefert die Ungleichung sogar mehr: $P_e \geq 1 - \frac{C}{R} - \frac{1}{nR}$. ***Oberhalb der Kapazität bleibt die Fehlerwahrscheinlichkeit nicht nur positiv, sondern über einer festen Schranke*** *— bei $R = 2C$ etwa über $\frac{1}{2}$. Es wird also nicht "ein bisschen schlechter", sondern unbrauchbar.*

5.5 Der Bruchfall

Was der Beweis nicht liefert

Keinen Code	Der Beweis zeigt, dass ein guter Code existiert. Er gibt keinen an.
Keine Blocklänge	"Für hinreichend großes n" — wie groß, steht nicht da.
Keine Decodierung	Die typische Decodierung erfordert den Vergleich mit allen 2^{nR} Codewörtern. Bei $n = 1000$ und $R = 0{,}5$ sind das 2^{500} Vergleiche.

Der Satz sagt, dass es geht — nicht, wie. Zwischen 1948 und der praktischen Erreichung der Kapazität lagen über fünfzig Jahre.

Die dritte Zeile ist die ernsteste. Ein zufälliger Code ist beweisbar gut und praktisch unbrauchbar, weil man weder die Tabelle speichern noch die Decodierung durchführen kann. ***Man braucht Codes mit Struktur*** *— und Struktur ist genau das, was der Beweis wegwirft. Kapitel 6 behandelt, wie man beides zusammenbringt.*

Und die Blocklänge kostet Verzögerung

Der Zielkonflikt	Große Blöcke bringen die Rate nahe an C — und erzeugen Wartezeit, weil der Block vollständig vorliegen muss.
Im Leitfall	Bei 10 000 Übertragungen je Sekunde bedeutet $n = 10\,000$ eine Sekunde Verzögerung.

Für die Übertragung eines Ruhe-EKG ist das gleichgültig; für die Fernsteuerung eines Eingriffs nicht. Die Theorie der ***endlichen Blocklängen*** *— seit etwa 2010 systematisch entwickelt — gibt an, wie nahe man bei gegebenem n und gegebener Fehlerrate an C herankommt.* ***Sie schließt genau die Lücke, die Shannons asymptotische Aussage offenlässt.***

5.6 Übungsaufgaben

Aufgabe 5.1 — Die typische Menge

Eine Quelle liefert unabhängig "auffällig" mit 0,2. Bestimmen Sie für $n = 50$ die Größe der typischen Menge und ihren Anteil.

Lösung

Schritt 1 — Die Entropie

$$H = h(0{,}2) = 0{,}7219 \text{ Bit}$$

Schritt 2 — Die typische Menge

$$|A| \approx 2^{50 \cdot 0{,}7219} = 2^{36{,}1} \approx 7{,}2 \cdot 10^{10}$$

Schritt 3 — Alle Folgen

$$2^{50} \approx 1{,}13 \cdot 10^{15}$$

Schritt 4 — Der Anteil

$$\frac{2^{36{,}1}}{2^{50}} = 2^{-13{,}9} \approx 6{,}5 \cdot 10^{-5}$$

Etwa sechs Hunderttausendstel aller Folgen tragen nahezu die gesamte Wahrscheinlichkeit.

Schritt 5 — Die Probe über die Anzahl der Einsen

Eine typische Folge hat etwa $50 \cdot 0{,}2 = 10$ Einsen. Die Zahl solcher Folgen:

$$\binom{50}{10} = 1{,}03 \cdot 10^{10}$$

Vergleich: $7{,}2 \cdot 10^{10}$ gegen $1{,}03 \cdot 10^{10}$ — dieselbe Größenordnung. ✓

Der Unterschied um den Faktor sieben rührt daher, dass die typische Menge nicht nur Folgen mit genau zehn Einsen enthält, sondern ein ganzes Band darum. Die Näherung $\binom{n}{np} \approx 2^{nh(p)}$ ist die Standardabschätzung dahinter; sie stimmt bis auf einen Faktor der Ordnung $\sqrt{n}$.

Schritt 6 — Was das für die Kompression bedeutet

Man braucht nur die typischen Folgen zu nummerieren:

$$\lceil 36{,}1 \rceil = 37 \text{ Bit statt } 50$$

Das ist ein zweiter Beweis des Quellencodierungssatzes — und der, den Shannon ursprünglich führte. ***Man codiert nur die typischen Folgen und nimmt in Kauf, dass der Rest scheitert****, weil dieser Rest mit wachsendem n verschwindend unwahrscheinlich wird. Die Ersparnis von 13 Bit entspricht $50 \cdot (1 - 0{,}7219) = 13{,}9$.*

Aufgabe 5.2 — Blocklänge bestimmen

Für den Leitfall ($f = 0{,}1$, $C = 0{,}531$) soll bei Rate $R = 0{,}45$ die Fehlerwahrscheinlichkeit unter 10^{-9} liegen. Welche Blocklänge genügt nach der Zufallscodierungsschranke?

Lösung

Schritt 1 — Die Schranke

$$P_e \lesssim 2^{-n(C-R)}$$

Schritt 2 — Auflösen

$$\begin{aligned} 2^{-n(0{,}531-0{,}45)} &\leq 10^{-9} \\ -n \cdot 0{,}081 &\leq \operatorname{ld} 10^{-9} = -29{,}90 \\ n &\geq \frac{29{,}90}{0{,}081} = 369 \end{aligned}$$

Eine Blocklänge von etwa 370 **genügt.**

Schritt 3 — Die Abhängigkeit vom Abstand zur Kapazität

R	$C - R$	**nötiges** n
0,30	0,231	130
0,45	0,081	370
0,50	0,031	965
0,52	0,011	2718
0,525	0,006	**4983**

Die nötige Blocklänge wächst wie $1/(C-R)$**.** Die letzten Prozente der Kapazität sind unverhältnismäßig teuer.

Schritt 4 — Ein Vorbehalt

Die Schranke $2^{-n(C-R)}$ ist eine Näherung; die genaue Zufallscodierungsschranke hat einen anderen Exponenten, der für R nahe C kleiner ausfällt.

> *Die tatsächlich nötigen Blocklängen sind daher größer als hier berechnet — meist um einen Faktor zwischen zwei und zehn. Die Größenordnung und vor allem das Verhalten $1/(C-R)^2$ bei der genaueren Rechnung bleiben bestehen.* ***Für Anwendungen in der Nähe der Kapazität rechnet man mit Blocklängen im Bereich von Tausenden.***

Schritt 5 — Die Einordnung

Moderne Codes erreichen bei Blocklängen um 10^4 tatsächlich Raten innerhalb weniger Prozent der Kapazität.

> *Die Rechnung sagt also die richtige Größenordnung vorher — und sie erklärt, warum die praktische Erreichung der Kapazität erst gelang, als Speicher und Rechenleistung für solche Blocklängen verfügbar wurden.*

Aufgabe 5.3 — Die Umkehrung anwenden

Über den Leitfall-Kanal wird mit Rate $R = 0{,}8$ gesendet. Wie klein kann die Fehlerwahrscheinlichkeit höchstens werden?

Lösung

Schritt 1 — Die Ungleichung

Aus Schritt 4 der Umkehrung:

$$R \;\leq\; C + \frac{1}{n} + P_e\, R$$

Für großes n entfällt $\frac{1}{n}$:

$$P_e \;\geq\; 1 - \frac{C}{R}$$

Schritt 2 — Einsetzen

$$P_e \;\geq\; 1 - \frac{0{,}531}{0{,}8} = 1 - 0{,}664 = \mathbf{0{,}336}$$

Mindestens jede dritte Nachricht kommt falsch an — unabhängig von jeder Codierung.

Schritt 3 — Die Tabelle

R	C/R	$P_e \geq$
0,531	1,000	0,000
0,60	0,885	0,115
0,80	0,664	0,336
1,00	0,531	0,469

Schritt 4 — Die Probe an der letzten Zeile

Bei $R = 1$ wird uncodiert gesendet, und jedes Bit kippt mit 0,1. Die Fehlerrate *je Bit* beträgt also 0,1.
Scheinbarer Widerspruch: Die Schranke sagt 0,469.
Auflösung: P_e ist die Wahrscheinlichkeit, dass die *gesamte Nachricht* falsch ist. Bei n Bit ohne Codierung:

$$P_e = 1 - (0{,}9)^n \;\longrightarrow\; 1$$

Das ist verträglich mit der Schranke 0,469. ✓

> *Die Verwechslung von Blockfehlerrate und Bitfehlerrate ist einer der häufigsten Fehler beim Umgang mit diesen Sätzen.* ***Satz 5.1 handelt von Blöcken.*** *Für die Bitfehlerrate gilt eine schwächere, aber ebenfalls scharfe Schranke, die mit der Verzerrungstheorie aus Kapitel 8 zusammenhängt.*

Schritt 5 — Die Deutung

> *Oberhalb der Kapazität bricht die Übertragung nicht allmählich ein, sondern stürzt ab. Das erklärt eine vertraute Erfahrung: Funkverbindungen und Datenleitungen arbeiten entweder sauber oder gar nicht — eine Zwischenzone gibt es kaum.* ***Die Schärfe des Übergangs bei $R = C$ ist im Alltag beobachtbar.***

Ein nicht konstruktiver Beweis

Shannons Beweis der Erreichbarkeit war der erste bedeutende Einsatz der **probabilistischen Methode** in der Nachrichtentechnik: Man beweist die Existenz eines Objekts, indem man zeigt, dass ein zufällig gewähltes die gewünschte Eigenschaft mit positiver Wahrscheinlichkeit hat.

> ***Paul Erdős*** *machte dieselbe Methode etwa gleichzeitig in der Kombinatorik populär. Sie hat eine unangenehme Eigenschaft: Sie beweist, dass etwas existiert, und lässt einen völlig ratlos, wie es aussieht. Für die Nachrichtentechnik bedeutete das ein halbes Jahrhundert Suche.*

Der lange Weg

Jahr	Code	Abstand zu C
1950	Hamming	groß
1960	Reed-Solomon	erheblich
1962	LDPC (Gallager)	klein — unbemerkt
1993	Turbo-Codes	0,5 dB
1996	LDPC wiederentdeckt	0,04 dB
2008	Polar-Codes	beweisbar erreichend

Gallagers Arbeit

Robert Gallager beschrieb 1962 in seiner Dissertation Codes, die der Kapazität sehr nahe kommen. Sie wurden vergessen.

> *Der Grund war schlicht: Die nötige Rechenleistung existierte nicht. Erst dreißig Jahre später, nach der Aufsehen erregenden Vorstellung der Turbo-Codes 1993, suchte man erneut — und fand Gallagers Arbeit wieder.* ***Ein Verfahren kann seiner Zeit so weit voraus sein, dass es unbemerkt bleibt*** *— dasselbe Muster wie bei Kantorowitsch in Band 19.*

Die Turbo-Codes

Claude Berrou und **Alain Glavieux** stellten sie 1993 vor. Die berichteten Ergebnisse lagen so nahe an der Kapazität, dass Fachleute zunächst einen Rechenfehler vermuteten.

> *Die Ergebnisse wurden bestätigt. Bemerkenswert ist, dass die Erfinder keine Informationstheoretiker waren — sie hatten die Konstruktion aus praktischen Erwägungen gefunden, und die Theorie ihres Funktionierens folgte erst Jahre später nach.*

Nach dem Theorem

Endliche Blocklängen	Wie nahe kommt man bei gegebenem n? Seit 2010 gibt es scharfe Näherungen.
Polar-Codes	Die erste Familie mit beweisbarer Erreichung der Kapazität und effizienter Decodierung.
Kurze Blöcke	Für Anwendungen mit Echtzeitanforderung sind Blocklängen unter hundert nötig — ein eigenes Forschungsfeld.

Zur ersten Zeile

Die Näherung lautet

$$R \;\approx\; C - \sqrt{\frac{V}{n}}\, Q^{-1}(\varepsilon)$$

mit der **Kanaldispersion** V und der inversen Normalverteilung Q^{-1}.

> *Der Abstand zur Kapazität schrumpft also wie $1/\sqrt{n}$ — deutlich langsamer, als die einfache Schranke aus Aufgabe 5.2 nahelegt. Bemerkenswert ist, dass hier eine Normalverteilung auftritt: Die Aussage ist im Kern ein zentraler Grenzwertsatz für die Informationsdichte, und V ist deren Varianz.*

Zu den Polar-Codes

Erdal Arıkan stellte sie 2008 vor. Sie beruhen auf einem überraschenden Gedanken: Man verwandelt n gleiche Kanäle in n *ungleiche* — teils fast perfekte, teils fast wertlose — und benutzt nur die guten.

> *Der Anteil der guten strebt gegen C. Das Verfahren ist der erste vollständige Beweis mit einem konkreten Code — sechzig Jahre nach Shannon. Polar-Codes sind seit 2016 Bestandteil des Mobilfunkstandards der fünften Generation.*

Was Sie jetzt können

Satz 5.1	scharfer Übergang bei $R = C$
Satz 5.3	typische Menge: winzig, trägt alles
Kugelpackung	2^{nC} Codewörter passen
Zufallscodierung	Fehler $\lesssim 2^{-n(C-R)}$
Sätze 5.4, 5.5	Fano und Datenverarbeitung

> *Im nächsten Kapitel bauen wir Codes, die man auch benutzen kann — und sehen, wie weit der Weg vom Existenzbeweis zur Technik war.*

Kapitel 6

Fehlerkorrigierende Codes

6.1 Der Hamming-Abstand

Definition 6.1

Der **Hamming-Abstand** zweier gleich langer Folgen ist die Zahl der Stellen, an denen sie sich unterscheiden:

$$d(x, y) = \bigl|\{\, i \;:\; x_i \neq y_i \,\}\bigr|.$$

Der **Minimalabstand** eines Codes ist der kleinste Abstand zweier verschiedener Codewörter.

Satz 6.2 — was der Minimalabstand leistet

Ein Code mit Minimalabstand d kann

$d-1$ Fehler	**erkennen**
$\left\lfloor \frac{d-1}{2} \right\rfloor$ Fehler	**korrigieren**

Beweis der Erkennung

Werden höchstens $d-1$ Stellen verfälscht, so hat das Empfangene von jedem Codewort außer dem gesendeten einen Abstand von mindestens 1 — es kann also kein anderes Codewort sein.
Genauer: Läge das Empfangene auf einem anderen Codewort, so hätten die beiden Codewörter einen Abstand von höchstens $d-1$ — Widerspruch zur Definition von d. ✓

Beweis der Korrektur

Sei $t = \lfloor \frac{d-1}{2} \rfloor$ und y das Empfangene mit höchstens t Fehlern, also $d(x, y) \le t$.
Für jedes andere Codewort x' gilt nach der Dreiecksungleichung

$$d(x', y) \;\ge\; d(x, x') - d(x, y) \;\ge\; d - t.$$

Wegen $t \le \frac{d-1}{2}$ ist $d - t \ge d - \frac{d-1}{2} = \frac{d+1}{2} > t$.

Das gesendete Codewort ist das einzige im Abstand höchstens t. Die Entscheidung für das nächstgelegene ist daher richtig. ■

Erkennen ist billiger als Korrigieren — man braucht nur halb so viel Abstand. Deshalb arbeiten viele Systeme mit Erkennung und Nachforderung statt mit Korrektur; das ist der Auslöschungskanal aus Kapitel 4, dessen Kapazität erheblich höher liegt.

6.2 Lineare Codes

Definition 6.3

Ein $[n, k]$-**Linearcode** ist ein k-dimensionaler Untervektorraum von $\{0,1\}^n$ — also die Menge aller Linearkombinationen von k Basisvektoren, mit Rechnung modulo 2.

Zwei Matrizen

Generatormatrix	G mit k Zeilen: $\boldsymbol{c} = \boldsymbol{u}\,G$ codiert die Nachricht $\boldsymbol{u}$.
Prüfmatrix	H mit $n-k$ Zeilen: $\boldsymbol{c}$ ist Codewort genau dann, wenn $H\boldsymbol{c}^\top = \boldsymbol{0}$.

Das Syndrom

Für das Empfangene $\boldsymbol{y} = \boldsymbol{c} + \boldsymbol{e}$ mit dem Fehlermuster $\boldsymbol{e}$:

$$H\boldsymbol{y}^\top = H\boldsymbol{c}^\top + H\boldsymbol{e}^\top = \boldsymbol{0} + H\boldsymbol{e}^\top = H\boldsymbol{e}^\top$$

Das Syndrom hängt nur vom Fehler ab, nicht vom gesendeten Wort. Das ist der Grund, warum lineare Codes praktisch handhabbar sind.

> *Statt mit allen 2^k Codewörtern zu vergleichen — wie es der Beweis in Kapitel 5 verlangte —, rechnet man ein Syndrom der Länge $n-k$ aus und schlägt es in einer Tabelle nach. Bei $n = 7$, $k = 4$ hat diese Tabelle acht Einträge statt sechzehn Vergleichen; bei $n = 1000$, $k = 500$ sind es 2^{500} gegenüber 2^{500} — der Gewinn liegt bei kurzen Prüfteilen.*

Satz 6.4 — der Minimalabstand

Bei einem Linearcode ist d das kleinste Gewicht eines Codeworts ungleich null. *Grund:* $d(\boldsymbol{c}, \boldsymbol{c}') = d(\boldsymbol{c} - \boldsymbol{c}', \boldsymbol{0})$, und Differenzen von Codewörtern sind wieder Codewörter.

> *Das erspart, alle $\binom{2^k}{2}$ Paare zu prüfen — man betrachtet nur $2^k - 1$ Wörter. Bei $k = 4$ sind das 15 statt 120.*

6.3 Der Hamming-Code

Die Konstruktion

Für den $[7, 4]$-Code besteht die Prüfmatrix aus allen Spalten ungleich null der Länge 3 — also den Binärdarstellungen von 1 bis 7:

$$H = \begin{pmatrix} 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \end{pmatrix}$$

Warum das funktioniert

Tritt genau ein Fehler an der Stelle j auf, so ist $\boldsymbol{e}$ der j-te Einheitsvektor und

$$H\boldsymbol{e}^\top = j\text{-te Spalte von } H = \text{Binärdarstellung von } j.$$

Das Syndrom *ist* die Nummer der fehlerhaften Stelle. Man liest sie unmittelbar ab.

Der Minimalabstand

Alle Spalten sind verschieden und ungleich null. Daher:

Gewicht 1	Syndrom ist eine Spalte, also $\neq \mathbf{0}$ — kein Codewort.
Gewicht 2	Syndrom ist die Summe zweier verschiedener Spalten, also $\neq \mathbf{0}$.
Gewicht 3	Kann null werden — etwa Spalten 1, 2 und 3.

$$d = 3 \quad \Longrightarrow \quad t = 1 \text{ Fehler korrigierbar}$$

Die Kenngrößen

Länge n	7
Nachricht k	4
Abstand d	3
Rate R	0,571

Ein perfekter Code

Die Kugelpackungsschranke lautet

$$2^k \cdot \sum_{i=0}^{t} \binom{n}{i} \;\leq\; 2^n.$$

Für den Hamming-Code:

$$2^4 \cdot (1+7) = 16 \cdot 8 = 128 = 2^7 \quad \checkmark$$

Gleichheit — die Kugeln füllen den Raum lückenlos aus. Solche Codes heißen **perfekt**.

Wie selten das ist

Code	t	$k + \operatorname{ld} V$	
$[7, 4]$	1	7,000	perfekt
$[15, 11]$	1	15,000	perfekt
$[23, 12]$	3	23,000	perfekt
$[15, 7]$	2	13,919	Lücke 1,08

Zur dritten Zeile: $1 + 23 + 253 + 1771 = 2048 = 2^{11}$, und $2^{12} \cdot 2^{11} = 2^{23}$.

Das ist der Golay-Code. Über dem Binäralphabet gibt es — außer den Wiederholungscodes ungerader Länge — nur die Hamming-Codes und diesen einen Golay-Code als perfekte Codes. Das ist ein tiefliegendes Ergebnis der Codierungstheorie, und der Golay-Code hat bemerkenswerte Verbindungen zu endlichen Gruppen und zur Kugelpackung im 24-dimensionalen Raum.

6.4 Was Codes leisten

Der Hamming-Code gegen die uncodierte Übertragung

Wir vergleichen die Wahrscheinlichkeit, dass ein Nachrichtenblock von vier Bit falsch ankommt.

f	uncodiert	Hamming	Faktor
0,001	0,00399	0,00002	200
0,010	0,03940	0,00203	19
0,050	0,18549	0,04438	4,2
0,100	0,34390	0,14969	2,3

Uncodiert: $1 - (1 - f)^4$.
Hamming: $1 - (1 - f)^7 - 7f(1 - f)^6$ — zwei oder mehr Fehler sind nicht korrigierbar.

Der Gewinn ist bei kleinen Fehlerraten groß und schrumpft rasch. Bei $f = 0{,}1$ bleibt nur der Faktor zwei — und man zahlt dafür 43 Prozent Rate.

Das ist die Grenze aller Codes, die nur einen Fehler korrigieren: Sobald zwei Fehler wahrscheinlich werden, versagen sie. Bei $n = 7$ und $f = 0{,}1$ sind im Mittel 0,7 Bit falsch — der Code arbeitet bereits außerhalb seines Bereichs.

Der Abstand zur Kapazität

f	C	Hamming	Ausnutzung
0,01	0,9192	0,5714	62 %
0,05	0,7136	0,5714	80 %
0,10	0,5310	0,5714	108 %

Zur letzten Zeile

Die Rate übersteigt die Kapazität — und genau deshalb bleibt die Fehlerrate bei 15 Prozent stehen.

> **Kapitel 5 verbietet nicht, mit einer Rate über C zu senden. Es verbietet, dabei fehlerfrei zu werden.**
>
> *Der Hamming-Code ist also bei $f = 0{,}1$ prinzipiell chancenlos. Bei $f = 0{,}01$ liegt er mit 62 Prozent Ausnutzung im brauchbaren Bereich — und das war 1950 ein großer Fortschritt.* ***Die Lücke zu den restlichen 38 Prozent zu schließen, hat fünfzig Jahre gedauert.***

6.5 Drei Schranken

Was möglich ist und was nicht

Schranke	Aussage	Art
Singleton	$d \le n - k + 1$	obere
Kugelpackung	$2^k \sum_{i \le t} \binom{n}{i} \le 2^n$	obere
Gilbert-Varshamov	existiert Code mit $2^k \ge \frac{2^n}{\sum_{i<d} \binom{n}{i}}$	untere

Beweis der Singleton-Schranke

Streicht man von jedem Codewort die letzten $d-1$ Stellen, so bleiben die Wörter paarweise verschieden — sie unterschieden sich ja an mindestens d Stellen.
Es gibt also 2^k verschiedene Wörter der Länge $n-d+1$:

$$2^k \;\le\; 2^{\,n-d+1} \quad\Longrightarrow\quad k \le n - d + 1$$

■

> *Codes, die hier Gleichheit erreichen, heißen* ***MDS*** *— maximal trennend. Über dem Binäralphabet sind sie selten; über größeren Alphabeten gibt es sie in Fülle, und das ist der Grund, warum die wichtigsten praktischen Codes nicht mit Bits, sondern mit Bytes rechnen.*

Zur Gilbert-Varshamov-Schranke

Sie ist eine *Existenz*aussage und wird durch ein gieriges Verfahren bewiesen: Man wählt Codewörter nacheinander und streicht jeweils die Kugel vom Radius $d - 1$ um das gewählte.

> *Bemerkenswert ist, dass diese Schranke über sechzig Jahre lang für Binärcodes nicht verbessert werden konnte. Erst 1982 fanden Tsfasman, Vlăduţ und Zink über algebraische Kurven bessere Codes — allerdings nur über hinreichend großen Alphabeten. Für das Binäralphabet ist Gilbert-Varshamov bis heute unübertroffen.*

6.6 Reed-Solomon und Bündelfehler

Codes über Bytes

Reed-Solomon-Codes arbeiten mit Symbolen aus einem Alphabet der Größe q — üblich $q = 256$, also Bytes.

Der Gedanke	Eine Nachricht aus k Symbolen wird als Polynom vom Grad $k-1$ aufgefasst und an n Stellen ausgewertet.
Die Eigenschaft	Je k Auswertungen legen das Polynom fest — man darf also $n-k$ Symbole verlieren.

$$d = n - k + 1$$

Reed-Solomon-Codes sind MDS — sie erreichen die Singleton-Schranke mit Gleichheit.

Der Grund ist der Fundamentalsatz über Polynome aus Band 1: Zwei verschiedene Polynome vom Grad höchstens $k-1$ stimmen an höchstens $k-1$ Stellen überein. Der Code ist also nichts anderes als die Aussage, dass k Punkte ein Polynom vom Grad $k-1$ eindeutig bestimmen — dasselbe Prinzip wie bei der Interpolation.

Warum Bytes

Ein einzelner Kratzer auf einer CD verfälscht viele aufeinanderfolgende Bit — aber nur wenige Bytes.

Anwendung	Code	korrigiert
Raumfahrt	$[255, 223]$	16 Bytes
QR-Code	verschiedene	bis 30 %
Compact Disc	zwei verschachtelt	$\approx$ 2,5 mm Kratzer

Der $[255, 223]$-Code hat die Rate 0,875 und korrigiert 16 von 255 Symbolen — das sind bis zu 128 aufeinanderfolgende Bit. Er war Teil des Standards für die Voyager-Sonden und ist bis heute in Gebrauch. ***Gegen gebündelte Fehler ist ein Symbolcode einem Bitcode weit überlegen****, weil ein Bündel nur wenige Symbole trifft.*

Wie die Kapazität schließlich erreicht wurde

LDPC	Prüfmatrix mit sehr wenigen Einsen je Zeile. Die Decodierung tauscht Nachrichten zwischen Bits und Prüfgleichungen aus, bis sich alles fügt.
Turbo	Zwei einfache Codes, durch eine Verschachtelung verbunden; die Decodierer geben einander Wahrscheinlichkeiten weiter.
Polar	Verwandelt gleiche Kanäle in ungleiche und benutzt nur die guten.

Allen dreien gemeinsam ist, dass sie nicht das nächstgelegene Codewort suchen. Sie berechnen für jedes Bit eine Wahrscheinlichkeit und verbessern sie schrittweise.

Das ist der Bruch mit der klassischen Codierungstheorie, die sich um Minimalabstände drehte. ***Codes, die der Kapazität nahekommen, haben oft einen schlechten Minimalabstand*** *— sie verlassen sich nicht darauf, jeden Fehler zu korrigieren, sondern nur die typischen. Genau das hatte Shannons Beweis in Kapitel 5 getan.*

6.7 Der Bruchfall

Was Codes nicht leisten

Zu viele Fehler	Über t hinaus entscheidet der Decodierer *falsch* — und zwar überzeugt. Er meldet keinen Fehler.
Falsches Kanalmodell	Ein für unabhängige Fehler ausgelegter Code versagt bei Bündeln.
Keine Sicherheit	Fehlerkorrektur schützt gegen Zufall, nicht gegen Absicht. Ein Angreifer kann gezielt Codewörter ineinander überführen.

Zur ersten Zeile

Beim Hamming-Code mit zwei Fehlern zeigt das Syndrom auf eine dritte Stelle — der Decodierer kippt sie und erzeugt drei Fehler statt zwei.

Ein perfekter Code hat keine Reserve, um Überlastung zu bemerken. Jedes Empfangswort liegt in genau einer Kugel.

Deshalb fügt man in der Praxis oft ein zusätzliches Prüfbit hinzu — der erweiterte $[8,4]$-Code mit $d = 4$ korrigiert einen Fehler und erkennt zwei. Er ist nicht mehr perfekt, und das ist der Vorteil: Die Lücken zwischen den Kugeln sind der Ort, an dem man Überlastung bemerkt.

Zur dritten Zeile

Das ist der Übergang zu Teil IV. Eine Prüfsumme, die zufällige Fehler erkennt, ist gegen gezielte Veränderung wertlos — man rechnet sie einfach neu aus. Für Schutz gegen Absicht braucht man Hashfunktionen mit anderen Eigenschaften, und die behandelt Kapitel 11.

6.8 Übungsaufgaben

Aufgabe 6.1 — Mit dem Hamming-Code rechnen

Mit der Prüfmatrix aus Abschnitt 6.3: Decodieren Sie $\boldsymbol{y} = (1,0,1,1,0,1,0)$.

Lösung

Schritt 1 — Das Syndrom berechnen

$$H = \begin{pmatrix} 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \end{pmatrix}, \qquad \boldsymbol{y} = (1,0,1,1,0,1,0)$$

Erste Zeile: Stellen $4,5,6,7$ tragen bei:

$$y_4 + y_5 + y_6 + y_7 = 1 + 0 + 1 + 0 = 2 \equiv 0 \pmod 2$$

Zweite Zeile: Stellen $2,3,6,7$:

$$0 + 1 + 1 + 0 = 2 \equiv 0$$

Dritte Zeile: Stellen $1,3,5,7$:

$$1 + 1 + 0 + 0 = 2 \equiv 0$$

$$\boldsymbol{s} = (0,0,0)$$

Das Syndrom ist null — $\boldsymbol{y}$ ist ein Codewort. Kein erkennbarer Fehler.

Schritt 2 — Ein Fehler wird eingebaut

Wir kippen Stelle 5: $\boldsymbol{y}' = (1,0,1,1,1,1,0)$.
Erste Zeile: $1 + 1 + 1 + 0 = 3 \equiv 1$
Zweite Zeile: $0 + 1 + 1 + 0 = 2 \equiv 0$
Dritte Zeile: $1 + 1 + 1 + 0 = 3 \equiv 1$

$$\boldsymbol{s} = (1,0,1)$$

Schritt 3 — Das Syndrom lesen

$(1,0,1)$ als Binärzahl gelesen ist $4 + 0 + 1 = 5$.

Der Fehler sitzt an Stelle 5 — genau dort, wo wir ihn eingebaut haben. ✓

Schritt 4 — Zwei Fehler

Wir kippen zusätzlich Stelle 2: $\boldsymbol{y}'' = (1,1,1,1,1,1,0)$.
Erste Zeile: $1+1+1+0 = 1$ (unverändert, Stelle 2 kommt nicht vor)
Zweite Zeile: $1+1+1+0 = 3 \equiv 1$
Dritte Zeile: $1+1+1+0 = 1$ (unverändert)

$$\boldsymbol{s} = (1,1,1) \longrightarrow \text{Stelle } 7$$

Der Decodierer kippt Stelle 7 — und erzeugt damit drei Fehler statt zwei.

Probe: $5 \oplus 2 = 7$ in der Bitverknüpfung: $101 \oplus 010 = 111$. ✓

> *Das Syndrom zweier Fehler ist die Summe der beiden Spalten — und die ist wieder eine Spalte, weil die Spalten alle Binärzahlen von 1 bis 7 durchlaufen.* ***Der Decodierer kann Überlastung nicht bemerken****, und das ist der Preis der Perfektheit.*

Schritt 5 — Das erweiterte Verfahren

Fügt man ein achtes Bit hinzu, das die Gesamtparität sichert, so gilt:

Syndrom	Parität	Schluss
$\mathbf{0}$	richtig	kein Fehler
$\neq \mathbf{0}$	falsch	ein Fehler, korrigierbar
$\neq \mathbf{0}$	richtig	zwei Fehler
$\mathbf{0}$	falsch	Fehler im Paritätsbit

> *Die dritte Zeile ist der Gewinn: Zwei Fehler verändern die Gesamtparität nicht, erzeugen aber ein Syndrom. Der $[8,4]$-Code korrigiert also einen Fehler und erkennt zwei — dieselbe Kombination, die in Arbeitsspeichern eingesetzt wird.*

Aufgabe 6.2 — Schranken prüfen

Welche der folgenden Codes können existieren?

(a)	$[10,6,4]$ binär
(b)	$[10,6,5]$ binär
(c)	$[15,11,3]$ binär
(d)	$[15,9,7]$ binär

Lösung

(a) $[10,6,4]$
Singleton: $d \leq 10-6+1 = 5$. Erfüllt. ✓

Kugelpackung mit $t = \lfloor 3/2 \rfloor = 1$:

$$2^6 \cdot (1 + 10) = 64 \cdot 11 = 704 \;\leq\; 1024 = 2^{10} \quad \checkmark$$

Möglich.

(b) $[10, 6, 5]$
Singleton: $d \leq 5$. Gerade noch erfüllt — der Code wäre MDS.
Kugelpackung mit $t = 2$:

$$2^6 \cdot (1 + 10 + 45) = 64 \cdot 56 = 3584 \;>\; 1024$$

Unmöglich.

> *Bemerkenswert: Die Singleton-Schranke ist erfüllt, die Kugelpackungsschranke nicht. Über einem Alphabet mit mindestens elf Symbolen gäbe es diesen MDS-Code sehr wohl — über dem Binäralphabet nicht.* ***Binäre MDS-Codes sind auf triviale Fälle beschränkt****, und das ist der Grund für Reed-Solomon über Bytes.*

(c) $[15, 11, 3]$
Singleton: $d \leq 5$. ✓
Kugelpackung mit $t = 1$:

$$2^{11} \cdot (1 + 15) = 2048 \cdot 16 = 32768 = 2^{15} \quad \checkmark$$

Möglich, und zwar mit Gleichheit — das ist der perfekte Hamming-Code der Länge 15.

(d) $[15, 9, 7]$
Singleton: $d \leq 15 - 9 + 1 = 7$. Gerade erfüllt.
Kugelpackung mit $t = 3$:

$$2^9 \cdot (1 + 15 + 105 + 455) = 512 \cdot 576 = 294\,912 \;>\; 32\,768$$

Unmöglich — um den Faktor neun.

Die Übersicht

	Singleton	Kugelpackung	Urteil
(a)	✓	✓	möglich
(b)	✓	nein	unmöglich
(c)	✓	✓(gleich)	perfekt
(d)	✓	nein	unmöglich

> *Die Kugelpackungsschranke ist bei Binärcodes fast immer die schärfere. Beide sind allerdings nur notwendig: Ein Code, der beide erfüllt, muss nicht existieren. Die Frage, welche Tripel $[n, k, d]$ tatsächlich vorkommen, ist für kleine n tabelliert und im Allgemeinen offen.*

Aufgabe 6.3 — Verschachtelung gegen Bündelfehler

Ein Kanal erzeugt Fehlerbündel von bis zu 4 aufeinanderfolgenden Bit. Zeigen Sie, wie sich ein Code mit $t = 1$ dennoch verwenden lässt.

Lösung

Schritt 1 — Das Problem

Ein Bündel von vier Fehlern trifft ein Codewort der Länge 7 mit hoher Wahrscheinlichkeit mehrfach — der Code versagt.

Schritt 2 — Die Verschachtelung

Man sendet vier Codewörter nicht nacheinander, sondern spaltenweise verschränkt:

Ohne	$c_1^{(1)} \dots c_7^{(1)}\ c_1^{(2)} \dots c_7^{(2)}\ \dots$
Mit	$c_1^{(1)} c_1^{(2)} c_1^{(3)} c_1^{(4)}\ c_2^{(1)} c_2^{(2)} \dots$

Schritt 3 — Die Wirkung

Ein Bündel von vier aufeinanderfolgenden gesendeten Bit trifft genau vier *verschiedene* Codewörter — jedes an einer einzigen Stelle.

> **Jedes Codewort erhält höchstens einen Fehler und ist korrigierbar.**

Schritt 4 — Die allgemeine Regel

Bei Verschachtelungstiefe m und einem Code, der t Fehler korrigiert, sind Bündel bis zur Länge

$$m \cdot t$$

korrigierbar.

m	t	**Bündel**	**Verzögerung**
4	1	4	28 Bit
16	1	16	112 Bit
8	2	16	120 Bit

Schritt 5 — Der Preis

> **Die Rate bleibt unverändert.** Bezahlt wird mit Verzögerung und Speicherbedarf: Vor dem Senden müssen m Codewörter vorliegen.
>
> *Das ist bemerkenswert: Die Verschachtelung verbessert die Fehlerleistung, ohne Redundanz zu kosten. Der Gewinn wird mit Zeit bezahlt statt mit Rate — und das ist genau der Zielkonflikt aus dem Bruchfall von Kapitel 5.*

Schritt 6 — In der Praxis

Die Compact Disc verwendet zwei verschachtelte Reed-Solomon-Codes.

Der erste korrigiert vereinzelte Fehler; erkannte, aber nicht korrigierbare Symbole werden als Auslöschungen an den zweiten weitergereicht — der sie wegen der höheren Kapazität des Auslöschungskanals aus Kapitel 4 doppelt so wirksam behandeln kann. Die Verschachtelung streckt ein Codewort über etwa drei Millimeter Spurlänge. ***Ein Kratzer von zweieinhalb Millimetern wird vollständig korrigiert*** *— deshalb überstehen zerkratzte CDs das Abspielen.*

Ein Wochenende mit Lochkarten

Richard Hamming (1915–1998) arbeitete Ende der 1940er Jahre an den Bell-Laboratorien mit einem Relaisrechner, der am Wochenende ohne Bedienung lief.

Der Rechner besaß eine Fehlererkennung: Fand er einen Fehler, so brach er ab und ging zum nächsten Auftrag. Zweimal hintereinander — an zwei Wochenenden — fand Hamming am Montag seine Rechnung abgebrochen vor. Er soll gedacht haben: Wenn die Maschine den Fehler finden kann, warum kann sie ihn nicht gleich beheben?

Die Arbeit

Hamming entwickelte seine Codes 1947. Die Veröffentlichung verzögerte sich bis 1950, weil die Bell-Laboratorien ein Patent anmelden wollten.

Shannon hatte die Konstruktion inzwischen in seiner Arbeit von 1948 als Beispiel erwähnt — mit Hinweis auf Hamming. Dass ein grundlegendes Ergebnis drei Jahre lang unveröffentlicht blieb, weil eine Patentabteilung prüfte, ist einer der aufschlussreicheren Nebenzüge dieser Geschichte.

Golay

Marcel Golay veröffentlichte 1949 — vor Hamming — eine halbseitige Notiz, die sowohl die Hamming-Codes als auch den nach ihm benannten perfekten Code enthält.

Die Notiz umfasst keine Beweise und ist extrem knapp gehalten. Sie gilt als eine der informationsdichtesten Veröffentlichungen der Mathematikgeschichte: eine halbe Seite, zwei Codefamilien, ein Sonderfall von bleibender Bedeutung.

Reed und Solomon

Irving Reed und **Gustave Solomon** veröffentlichten ihren Code 1960 auf fünf Seiten.

Ein praktisches Decodierverfahren fehlte; es kam 1968 von ***Elwyn Berlekamp*** *und* ***James Massey****. Erst damit wurde der Code brauchbar — und ist heute vermutlich der meistverwendete Code überhaupt: in jedem QR-Code, jeder CD, jeder DVD, jedem Speichersystem mit Ausfallsicherung.*

Codes heute

Im Einsatz	LDPC in Mobilfunk und Satellitenübertragung, Polar-Codes für Steuerkanäle, Reed-Solomon für Speicher.
Verteilte Speicher	Codes, bei denen ein ausgefallener Knoten wiederhergestellt werden kann, ohne alle übrigen zu lesen.
Quantencodes	Fehlerkorrektur für Quantenzustände — die Grundlage jedes brauchbaren Quantenrechners.

Zur zweiten Zeile

Bei einem Reed-Solomon-Code muss man zur Wiederherstellung eines Symbols k andere lesen.

> *In einem Rechenzentrum mit Hunderten von Speicherknoten ist das erhebliche Netzlast.* ***Lokal wiederherstellbare Codes*** *opfern etwas Rate, um diese Zahl klein zu halten — ein Zielkonflikt, den die klassische Theorie gar nicht kannte, weil sie nur Rate gegen Fehlerleistung abwog.*

Zur dritten Zeile

Quantenzustände lassen sich nicht kopieren und nicht ohne Störung messen — beides Grundlagen klassischer Fehlerkorrektur.

> *Dass Quantenfehlerkorrektur dennoch möglich ist, zeigte* ***Peter Shor*** *1995. Der Kunstgriff besteht darin, nur das Syndrom zu messen und den Zustand selbst unangetastet zu lassen — genau die Größe, die nach Abschnitt 6.2 keine Auskunft über die Nachricht gibt.* ***Die Eigenschaft, die lineare Codes praktisch macht, ist dieselbe, die sie auf Quantensysteme übertragbar macht.***

Was Sie jetzt können

Satz 6.2	$d-1$ erkennen, $\lfloor \frac{d-1}{2} \rfloor$ korrigieren
Syndrom	hängt nur vom Fehler ab
Hamming-Code	Syndrom ist die Fehlerstelle
Drei Schranken	Singleton, Kugelpackung, Gilbert-Varshamov
Verschachtelung	Bündel zerlegen, ohne Rate zu kosten

Damit endet Teil II. Bisher war der Zufall ein Gegner. Ab Kapitel 7 fragen wir, was Zufall überhaupt ist — und finden einen Begriff, der ohne Wahrscheinlichkeiten auskommt.

Teil III

Zufall und Komplexität

Kapitel 7

Kolmogorow-Komplexität

7.1 Die offene Frage

Was Aufgabe 3.3 übrig gelassen hat

Dort wurde gezeigt: Die allermeisten Binärfolgen lassen sich nicht komprimieren — aber die tatsächlich vorkommenden sehr wohl.

Die Frage lautet: Was zeichnet die komprimierbaren Folgen aus?

Zwei Folgen der Länge 48

A	01010101 01010101 01010101
	01010101 01010101 01010101
B	01101010 00001001 11100110
	01100111 11110011 10111100

A **ist offensichtlich einfach.** B sieht zufällig aus — 27 Einsen unter 48 Stellen, keine erkennbare Regel.

B sind die ersten 48 Nachkommastellen von $\sqrt{2}-1$ im Binärsystem. Die Folge lässt sich also durch ein sehr kurzes Programm erzeugen — und niemand sieht ihr das an. ***Die Frage nach der Komprimierbarkeit ist keine Frage der Statistik, sondern der Beschreibbarkeit.***

Warum die Entropie hier nicht hilft

Die Entropie ist eine Eigenschaft einer *Quelle*, nicht einer einzelnen Folge. Für eine feste Folge ist sie gar nicht definiert.

Man kann zwar die Häufigkeiten der Symbole in B zählen und daraus eine Zahl bilden — aber die sagt nichts darüber, ob eine Regel dahintersteckt. Gesucht ist ein Begriff, der eine einzelne Folge bewertet und dabei ohne Wahrscheinlichkeiten auskommt.

7.2 Die Definition

Definition 7.1 — Kolmogorow-Komplexität

Sei U eine feste universelle Rechenmaschine. Die **Komplexität** einer Zeichenfolge x ist

$$K_U(x) = \min\{\, |p| \;:\; U(p) = x \,\}$$

— die Länge des kürzesten Programms, das x ausgibt und anhält.

Was das bedeutet

Eine Folge	Die Komplexität gehört zu einem einzelnen Objekt, nicht zu einer Verteilung.
Keine Wahrscheinlichkeiten	Der Begriff kommt ohne sie aus.
Absolut	Er misst, wie viel Beschreibung das Objekt wirklich braucht.

Die beiden Extreme

Klein	$K(\underbrace{0101\ldots01}_{n}) \approx \operatorname{ld} n + c$ — man muss nur n mitteilen.
Groß	$K(x) \approx \lvert x\rvert$ — die Folge ist ihre eigene kürzeste Beschreibung.

Die obere Schranke

Für jede Folge gilt

$$K(x) \;\le\; |x| + c,$$

denn das Programm "gib die folgenden Bits aus: x" hat diese Länge.

> *Die Konstante c ist die Länge der Anweisung "gib aus" in der gewählten Programmiersprache. Sie hängt von der Sprache ab — und genau darin liegt die Schwierigkeit, die der nächste Satz behebt.*

Satz 7.2 — der Invarianzsatz

Für je zwei universelle Maschinen U und V gibt es eine Konstante c mit

$$\bigl|K_U(x) - K_V(x)\bigr| \;\le\; c \qquad \text{für alle } x.$$

Beweis
Da U universell ist, gibt es ein Programm π fester Länge, das V auf U nachbildet: Für jede Eingabe p gilt

$$U(\pi\, p) = V(p).$$

Ist p das kürzeste Programm für x auf V, so ist πp ein Programm für x auf U:

$$K_U(x) \;\leq\; |\pi| + K_V(x)$$

Dieselbe Überlegung in die andere Richtung liefert

$$K_V(x) \;\leq\; |\pi'| + K_U(x)$$

Mit $c = \max\{|\pi|, |\pi'|\}$ folgt die Behauptung. ■

Die Wahl der Programmiersprache ändert die Komplexität nur um eine Konstante. Sie ist damit für lange Folgen bedeutungslos.

Das ist der Satz, der den Begriff überhaupt erst zu einem mathematischen macht. Ohne ihn wäre K eine willkürliche Größe, die von der zufälligen Wahl einer Sprache abhinge. ***Der Preis ist, dass alle Aussagen nur "bis auf eine Konstante" gelten*** *— und diese Konstante kann für ein konkretes kurzes Objekt größer sein als das Objekt selbst.*

Die übliche Schreibweise
Man schreibt $K(x)$ ohne Index und meint: bis auf eine additive Konstante.

7.3 Die meisten Folgen sind zufällig

Satz 7.3 — das Abzählargument

Der Anteil der Folgen der Länge n mit

$$K(x) \;<\; n - k$$

ist kleiner als 2^{-k}.

Beweis
Es gibt höchstens

$$\sum_{j=0}^{n-k-1} 2^j = 2^{n-k} - 1$$

Programme der Länge kleiner als $n - k$.
Jedes davon erzeugt höchstens eine Folge. Also gibt es höchstens $2^{n-k} - 1$ Folgen mit $K(x) < n - k$.
Der Anteil an allen 2^n Folgen beträgt

$$\frac{2^{n-k} - 1}{2^n} \;<\; 2^{-k}.$$

■

k	**Anteil**
1	$< 50\,\%$
5	$< 3{,}13\,\%$
10	$< 0{,}098\,\%$
20	$< 10^{-6}$
50	$< 10^{-15}$

Weniger als ein Promille aller Folgen lässt sich um zehn Bit verkürzen.

Das ist genau die Tabelle aus Aufgabe 3.3 — nur mit einer anderen Begründung. Dort war es ein Abzählargument über Codes, hier über Programme. ***Beide Male ist die Ursache dieselbe: Es gibt nicht genug kurze Beschreibungen.***

Definition 7.4 — algorithmisch zufällig

Eine Folge heißt **inkomprimierbar**, wenn

$$K(x) \;\geq\; |x|.$$

Ein Zufallsbegriff ohne Wahrscheinlichkeiten

Eine Folge ist zufällig, wenn es keine kürzere Beschreibung von ihr gibt als sie selbst.

Warum das eine gute Definition ist

Einzelne Folgen	Die klassische Wahrscheinlichkeitsrechnung kann nicht sagen, dass *diese* Folge zufällig ist — jede einzelne hat dieselbe Wahrscheinlichkeit 2^{-n}.
Alle Tests bestanden	Eine inkomprimierbare Folge besteht jeden statistischen Test: Bestünde sie einen nicht, so könnte man daraus eine Verkürzung bauen.

Die zweite Zeile ist der eigentliche Gehalt. Hat eine Folge etwa deutlich mehr Nullen als Einsen, so lässt sie sich mit einem Huffman-Code aus Kapitel 3 verkürzen — also ist sie nicht inkomprimierbar. ***Inkomprimierbarkeit fasst alle denkbaren Regelmäßigkeiten in einer einzigen Bedingung zusammen.***

Ein Beispiel für die Umkehrung

Enthält eine Folge der Länge n nur einen Anteil $p \neq \frac{1}{2}$ an Einsen, so gilt

$$K(x) \;\lesssim\; n\,h(p) + O(\operatorname{ld} n).$$

Bei $p = 0{,}1$: $K \lesssim 0{,}469\,n$ — die Folge ist um mehr als die Hälfte verkürzbar.

7.4 Die Komplexität ist nicht berechenbar

Satz 7.5

Es gibt kein Verfahren, das zu jeder Folge x den Wert $K(x)$ bestimmt.

Beweis — durch Widerspruch

Angenommen, ein solches Verfahren existiert. Dann können wir folgendes Programm schreiben:

1	Lies eine Zahl m.
2	Durchlaufe alle Zeichenfolgen der Reihe nach.
3	Berechne für jede ihre Komplexität.
4	Gib die erste aus mit $K(x) \geq m$.

Schritt 1 — das Programm hält an

Nach Satz 7.3 gibt es Folgen beliebig großer Komplexität, also wird eine gefunden.

Schritt 2 — die Länge des Programms

Der Text der Schritte 2 bis 4 hat eine feste Länge c. Die Zahl m braucht etwa $\operatorname{ld} m$ Bit:

$$\text{Programmlänge} \;\approx\; c + \operatorname{ld} m$$

Schritt 3 — der Widerspruch

Das Programm gibt eine Folge x_0 mit $K(x_0) \geq m$ aus. Also ist

$$K(x_0) \;\leq\; c + \operatorname{ld} m.$$

Zusammen:

$$m \;\leq\; K(x_0) \;\leq\; c + \operatorname{ld} m$$

Für hinreichend großes m ist $c + \operatorname{ld} m < m$ — denn der Logarithmus wächst langsamer als jede lineare Funktion. Widerspruch. ■

Bei $c = 1000$ etwa genügt $m = 1024$: Dann ist $c + \operatorname{ld} m = 1010 < 1024$. ***Das Programm beschreibt in tausendzehn Bit eine Folge, die angeblich mehr als tausendvierundzwanzig Bit zu ihrer Beschreibung braucht.***

Die Verwandtschaft

Das Argument ist eine Formalisierung des Berryschen Paradoxons: "Die kleinste natürliche Zahl, die sich nicht mit weniger als zwölf Wörtern beschreiben lässt" — ein Satz aus elf Wörtern.

Was daraus folgt

Kein Optimum	Es gibt kein bestmögliches Kompressionsverfahren, das man tatsächlich ausführen könnte.
Kein Nachweis	Man kann von einer Folge im Allgemeinen nicht beweisen, dass sie zufällig ist.
Nur Schranken	$K(x)$ lässt sich von oben abschätzen — jedes Kompressionsverfahren liefert eine obere Schranke — aber nie von unten.

Die dritte Zeile ist die praktisch wichtigste. ***Wenn ein Verfahren eine Datei nicht verkleinert, beweist das nichts*** *— vielleicht hätte ein anderes es gekonnt. Umgekehrt: Gelingt eine Verkürzung, so ist K nachweislich klein.*

Und ein bemerkenswerter Nebeneffekt

Man kann für keine konkrete lange Folge *beweisen*, dass ihre Komplexität groß ist — obwohl fast alle Folgen diese Eigenschaft haben.

Genauer: In jedem widerspruchsfreien Beweissystem gibt es eine Schranke L, so dass sich für keine Folge die Aussage $K(x) > L$ beweisen lässt. L hängt dabei nur von der Länge der Axiome ab. Das ist eine Fassung des Unvollständigkeitssatzes von Gödel — und sie stammt von Chaitin. ***Die Mathematik kann fast keinem konkreten Objekt nachweisen, was fast alle Objekte erfüllen.***

7.5 Der Zusammenhang zur Entropie

Satz 7.6

Erzeugt eine Quelle mit der Entropie H unabhängige Symbole, so gilt

$$\frac{1}{n}\,\mathbb{E}\big[K(X_1,\ldots,X_n)\big] \;\longrightarrow\; H.$$

Die Begründung in zwei Richtungen

$\leq$	Man beschreibt die Folge durch ihren Huffman-Code plus das Decodierprogramm — nach Satz 3.3 etwa $nH + O(\mathrm{ld}\, n)$ Bit.
$\geq$	Nach Satz 7.3 lassen sich nicht alle Folgen kürzer beschreiben; der Erwartungswert bleibt daher oberhalb.

Im Mittel stimmen algorithmische Komplexität und Entropie überein. Im Einzelfall können sie beliebig weit auseinanderliegen.

Die Folge B vom Kapitelanfang ist das Beispiel: Als Ausgabe einer fairen Münze wäre sie typisch und hätte Entropie 48 Bit. Tatsächlich hat sie eine Komplexität von wenigen Dutzend Bit, weil sie $\sqrt{2}$ ist. ***Der Erwartungswert verdeckt genau die Fälle, um die es geht.***

7.6 Der Bruchfall

Vier Vorbehalte

Die Konstante	Alle Aussagen gelten bis auf eine additive Konstante. Für kurze Objekte ist der Begriff daher praktisch bedeutungslos.
Nicht berechenbar	Satz 7.5. Der Begriff ist ein Werkzeug des Beweisens, nicht des Rechnens.
Keine Zeit	K misst die Länge des Programms, nicht seine Laufzeit. Ein Programm von zehn Bit darf 10^{100} Jahre rechnen.
Kein Sinn	Wie die Entropie misst K keine Bedeutung. Eine zufällige Folge hat maximale Komplexität und minimalen Gehalt.

Zur dritten Zeile

Das ist ein ernster Einwand: Eine Beschreibung, die niemand ausführen kann, ist keine brauchbare Beschreibung.

Deshalb gibt es Varianten mit Zeitschranke — etwa die Frage nach dem kürzesten Programm, das innerhalb von t Schritten anhält. Diese Größen sind berechenbar, verlieren aber den Invarianzsatz in seiner einfachen Form. ***Man bezahlt die Berechenbarkeit mit der Eindeutigkeit.***

Zur vierten Zeile

Eine sinnvolle Nachricht liegt zwischen den Extremen: Reine Wiederholung hat niedrige Komplexität und sagt nichts; reiner Zufall hat maximale Komplexität und sagt ebenfalls nichts. Es gibt Versuche, diesen Zwischenbereich zu erfassen — die ***logische Tiefe*** *misst, wie lange das kürzeste Programm rechnen muss.* ***Ein tiefes Objekt ist eines, das kurz beschreibbar und dennoch aufwendig zu erzeugen ist*** *— etwa die ersten Milliarde Stellen von π.*

7.7 Übungsaufgaben

Aufgabe 7.1 — Komplexität abschätzen

Schätzen Sie die Komplexität der folgenden Folgen der Länge n nach oben ab.

(a)	n Nullen
(b)	Die ersten n Binärstellen von π
(c)	Eine Folge mit genau $n/4$ Einsen an zufälligen Stellen
(d)	Die Folge der ersten n Primzahlen in Binärdarstellung
(e)	Eine Folge aus n Münzwürfen

Lösung

(a) n Nullen

Das Programm lautet: "gib n Nullen aus". Die Zahl n braucht $\operatorname{ld} n$ Bit.

$$K \;\leq\; \operatorname{ld} n + c$$

Bei $n = 10^6$: etwa $20 + c$ Bit.

(b) Binärstellen von π

Ein Programm zur Berechnung von π hat feste Länge; man muss nur n mitteilen.

$$K \;\leq\; \operatorname{ld} n + c$$

> *Dieselbe Schranke wie bei (a) — obwohl die Folge völlig anders aussieht.* ***Die Komplexität misst nicht, wie kompliziert etwas wirkt, sondern wie kurz es beschreibbar ist.***

(c) Genau $n/4$ Einsen an zufälligen Stellen

Man muss angeben, *welche* der $\binom{n}{n/4}$ möglichen Anordnungen vorliegt:

$$K \;\lesssim\; \operatorname{ld} \binom{n}{n/4} + O(\operatorname{ld} n) \;\approx\; n\,h(0{,}25) = 0{,}811\,n$$

> *Die Folge ist also um etwa 19 Prozent verkürzbar — genau die Redundanz aus Kapitel 2. Die Kenntnis der Häufigkeit allein bringt nicht mehr; alles Weitere müsste aus zusätzlicher Struktur kommen.*

(d) Die ersten n Primzahlen

Ein Programm, das Primzahlen erzeugt, hat feste Länge.

$$K \;\leq\; \operatorname{ld} n + c$$

> *Die Folge der Primzahlen ist also algorithmisch sehr einfach — obwohl ihre Verteilung zu den tiefsten Fragen der Mathematik gehört.* ***Algorithmische Einfachheit und mathematische Tiefe sind zwei verschiedene Dinge.***

(e) n Münzwürfe
Nach Satz 7.3 gilt für den überwiegenden Teil der Folgen

$$K \geq n - k \quad \text{mit Wahrscheinlichkeit} > 1 - 2^{-k}.$$

Etwa: Mit Wahrscheinlichkeit über 99,9 Prozent ist $K \geq n - 10$.

Die Übersicht

	Schranke	**bei** $n = 10^6$
(a)	$\operatorname{ld} n + c$	$\approx 20 + c$
(b)	$\operatorname{ld} n + c$	$\approx 20 + c$
(c)	$0{,}811\, n$	$\approx 811\,000$
(d)	$\operatorname{ld} n + c$	$\approx 20 + c$
(e)	$\approx n$	$\approx 10^6$

Drei der fünf Folgen haben eine Komplexität von etwa zwanzig Bit — bei einer Million Stellen. ***Nur die Münzwürfe sind wirklich unkomprimierbar****, und genau sie sind die einzigen, bei denen man es nicht beweisen kann.*

Aufgabe 7.2 — Das Abzählargument nachrechnen

Wie viele Folgen der Länge 30 lassen sich um mindestens 10 Bit verkürzen? Und wie viele um mindestens die Hälfte?

Lösung

Schritt 1 — Um mindestens 10 Bit
Gesucht sind Folgen mit $K(x) < 20$.
Die Zahl der Programme kürzer als 20 Bit:

$$\sum_{j=0}^{19} 2^j = 2^{20} - 1 = 1\,048\,575$$

Schritt 2 — Der Anteil

$$\frac{1\,048\,575}{2^{30}} = \frac{1\,048\,575}{1\,073\,741\,824} = 9{,}77 \cdot 10^{-4}$$

Weniger als ein Promille.

Schritt 3 — Um mindestens die Hälfte
Gesucht: $K(x) < 15$. Die Zahl der Programme:

$$2^{15} - 1 = 32\,767$$

$$\frac{32\,767}{2^{30}} = 3{,}05 \cdot 10^{-5}$$

Schritt 4 — Die absolute Zahl
Höchstens 32 767 von über einer Milliarde Folgen lassen sich auf die Hälfte verkürzen.

Ersparnis	Anzahl	Anteil
≥ 5 Bit	$\leq 3{,}4 \cdot 10^7$	3,1 %
≥ 10 Bit	$\leq 1{,}0 \cdot 10^6$	0,098 %
≥ 15 Bit	$\leq 3{,}3 \cdot 10^4$	0,0031 %
≥ 20 Bit	≤ 1023	10^{-6}

Schritt 5 — Die Deutung

> *Die Schranke ist außerdem sehr großzügig: Sie unterstellt, dass jedes kurze Programm eine andere Folge der Länge 30 ausgibt. Tatsächlich erzeugen viele Programme dieselbe Ausgabe, viele andere gar keine oder eine Folge anderer Länge — oder sie halten nie an.* ***Die wahren Zahlen sind noch weit kleiner.***

Schritt 6 — Der Bezug zur Praxis
Eine Datei von 30 Bit ist bedeutungslos klein. Bei $n = 10^7$ — etwa einem Megabyte — gilt dieselbe Rechnung:

> **Höchstens ein Millionstel aller Dateien dieser Größe lässt sich um zwanzig Bit verkürzen.**
>
> *Dass Kompressionsprogramme dennoch regelmäßig Faktoren von zwei bis zehn erreichen, liegt allein daran, dass tatsächliche Dateien aus einer verschwindend kleinen, hochstrukturierten Teilmenge stammen. Es ist genau der Befund aus Aufgabe 3.3, nun mit einem Begriff versehen.*

Aufgabe 7.3 — Eine Variante des Beweises

Zeigen Sie: Es gibt kein Programm, das zu jeder Folge das *kürzeste* Programm ausgibt, das sie erzeugt.

Lösung

Schritt 1 — Die Annahme
Sei M ein Programm, das zu jedem x das kürzeste Programm p_x mit $U(p_x) = x$ ausgibt.

Schritt 2 — Daraus folgt Berechenbarkeit von K
Man führt M aus und misst die Länge der Ausgabe:

$$K(x) = |M(x)|$$

Damit wäre K berechenbar — Widerspruch zu Satz 7.5. ■

Schritt 3 — Die umgekehrte Frage
Gibt es ein Programm, das *prüft*, ob ein gegebenes p das kürzeste Programm für $U(p)$ ist?

Nein. Ein solches Programm erlaubte ebenfalls die Berechnung von K: Man durchläuft alle Programme aufsteigender Länge und prüft jedes.

Schritt 4 — Was man dennoch tun kann

Man kann K von oben *annähern*:

1	Lasse alle Programme bis zur Länge L jeweils t Schritte laufen.
2	Notiere für jedes ausgegebene x die kürzeste gefundene Länge.
3	Vergrößere t und beginne von vorn.

Die notierten Werte fallen monoton und streben gegen $K(x)$ — aber man erfährt nie, wann man angekommen ist.

Schritt 5 — Der Begriff dafür

Man nennt eine solche Funktion **von oben halbberechenbar**.

Man erfährt	Jede obere Schranke, die stimmt, wird irgendwann gefunden.
Man erfährt nicht	Ob die gefundene Schranke bereits der wahre Wert ist.

Diese Asymmetrie ist typisch für unentscheidbare Probleme: Positive Befunde lassen sich bestätigen, negative nicht. Bei der Frage nach dem Anhalten eines Programms ist es dasselbe — man erfährt, dass es anhält, wenn es anhält, und nie, dass es nicht anhält.

Schritt 6 — Und die praktische Entsprechung

Genau so arbeiten Kompressionsprogramme: Jedes liefert eine obere Schranke für K. Ein besseres Programm liefert eine bessere Schranke. ***Die Geschichte der Datenkompression ist die Geschichte immer besserer oberer Schranken für eine Größe, die niemand ausrechnen kann.***

Dreimal dieselbe Idee

Der Begriff wurde zwischen 1960 und 1965 dreimal unabhängig gefunden.

Solomonoff, 1960

Ray Solomonoff (1926–2009) suchte nach einer mathematischen Fassung des induktiven Schließens: Wie sollte man aus Beobachtungen auf Regeln schließen?

Seine Antwort: Man gewichtet jede mögliche Erklärung mit $2^{-\text{Programmlänge}}$. Das ist eine formale Fassung von Ockhams Rasiermesser — kürzere Erklärungen sind wahrscheinlicher. Solomonoffs Arbeit erschien als technischer Bericht und blieb lange unbeachtet.

Kolmogorow, 1965

Andrei Kolmogorow (1903–1987) — derselbe, der 1933 die Wahrscheinlichkeitstheorie axiomatisiert hatte — suchte einen Zufallsbegriff für einzelne Objekte.

> *Das ist bemerkenswert: Der Mann, der die Wahrscheinlichkeitsrechnung auf ein festes Fundament gestellt hatte, war mit ihr unzufrieden. Sie kann nicht sagen, dass diese Folge zufällig ist — nur etwas über Verteilungen. Kolmogorow suchte dreißig Jahre später den fehlenden Begriff und fand ihn in der Berechenbarkeitstheorie.*

Chaitin, 1965

Gregory Chaitin fand den Begriff als Student, im Alter von etwa achtzehn Jahren, unabhängig von beiden.

> *Von ihm stammt die Verbindung zur Unvollständigkeit und die Zahl Ω — die Wahrscheinlichkeit, dass ein zufällig gewähltes Programm anhält. Ω ist eine wohldefinierte reelle Zahl, deren Binärstellen algorithmisch zufällig sind: Um n Stellen von Ω zu kennen, braucht man n Bit an Axiomen.* ***Eine einzelne Zahl, die alles Wissen über das Anhalten von Programmen verdichtet enthält*** *— und deshalb unerreichbar ist.*

Die Namensgebung

Im Westen setzte sich "Kolmogorow-Komplexität" durch, obwohl Solomonoff früher war.

> *Kolmogorow selbst wies stets auf Solomonoffs Priorität hin. Es ist wieder Stiglers Gesetz aus Band 17 — diesmal mit dem Zusatz, dass der Namensgeber selbst dagegen anschrieb.*

Wo der Begriff wirkt

Beweistechnik	Die **Inkomprimierbarkeitsmethode**: Man nimmt ein zufälliges Objekt und leitet aus seiner Nichtbeschreibbarkeit untere Schranken her.
Modellwahl	Das Prinzip der kürzesten Beschreibung — Kapitel 8.
Ähnlichkeitsmaße	Der **Normalisierte Kompressionsabstand** vergleicht Objekte über ihre gemeinsame Komprimierbarkeit.

Zur ersten Zeile

Will man zeigen, dass ein Verfahren mindestens $f(n)$ Schritte braucht, so betrachtet man eine inkomprimierbare Eingabe.

Wäre das Verfahren schneller, so ließe sich aus seinem Ablauf eine kurze Beschreibung der Eingabe gewinnen — im Widerspruch zur Inkomprimierbarkeit. ***Die Methode ersetzt aufwendige Abzählargumente durch ein einziges Objekt****, und sie hat in der Komplexitätstheorie zahlreiche Schranken geliefert, die anders schwer zu erhalten waren.*

Zur dritten Zeile

Man schätzt die Ähnlichkeit zweier Objekte durch

$$\frac{Z(xy) - \min\{Z(x), Z(y)\}}{\max\{Z(x), Z(y)\}}$$

mit Z als Länge nach Kompression.

Der Gedanke: Sind x und y ähnlich, so hilft die Kenntnis des einen beim Komprimieren des anderen. Das Verfahren braucht keinerlei Vorwissen über den Gegenstand — es wurde erfolgreich auf Sprachverwandtschaft, Musikstile und Erbgutsequenzen angewandt. ***Ein Ähnlichkeitsmaß, das nichts über den Gegenstand voraussetzt****, ist genau das, was ein universeller Begriff verspricht.*

Was Sie jetzt können

Definition 7.1	kürzestes Programm
Satz 7.2	Invarianz bis auf eine Konstante
Satz 7.3	fast alle Folgen sind inkomprimierbar
Satz 7.5	K ist nicht berechenbar
Satz 7.6	im Mittel gleich der Entropie

Im nächsten Kapitel wird aus dem Gedanken der kürzesten Beschreibung ein statistisches Verfahren — und die relative Entropie aus Kapitel 4 erweist sich als der Begriff, der Information und Schätzen verbindet.

Kapitel 8

Information in der Statistik

8.1 Was die relative Entropie misst

Der Leitfall

Ein neuer Schnelltest soll geprüft werden. Behauptet wird eine Trefferquote von 0,6; der Verdacht ist, dass er nicht besser rät als eine Münze.

	Behauptung p	**Verdacht** q
Trefferquote	0,60	0,50

Die Frage: Wie viele Prüfungen braucht man, um sich zu entscheiden?

> *Band 17 beantwortet sie über Fehlerraten und Testgüte. Dieses Kapitel gibt eine zweite Antwort — über die Information, die jede einzelne Beobachtung beiträgt. Beide führen auf dieselbe Größenordnung, und die informationstheoretische Rechnung ist kürzer.*

Satz 8.1 — die relative Entropie ist die erwartete Evidenz

Gilt tatsächlich p, so beträgt die erwartete Log-Likelihood-Differenz je Beobachtung

$$\mathbb{E}_p\left[\operatorname{ld}\frac{p(X)}{q(X)}\right] = D(p\,\|\,q).$$

Was das bedeutet

Nach n unabhängigen Beobachtungen ist der Logarithmus des Likelihood-Verhältnisses näherungsweise

$$\operatorname{ld}\frac{\Pr[\text{Daten}\mid p]}{\Pr[\text{Daten}\mid q]} \;\approx\; n\cdot D(p\,\|\,q).$$

Jede Beobachtung trägt im Mittel $D(p\|q)$ Bit an Evidenz bei. Die Evidenz wächst linear mit dem Stichprobenumfang.

Für den Leitfall

$$\begin{aligned} D(0{,}6 \,\|\, 0{,}5) &= 0{,}6 \operatorname{ld} \frac{0{,}6}{0{,}5} + 0{,}4 \operatorname{ld} \frac{0{,}4}{0{,}5} \\ &= 0{,}6 \cdot 0{,}2630 + 0{,}4 \cdot (-0{,}3219) \\ &= 0{,}1578 - 0{,}1288 = \mathbf{0{,}0290}\ \text{Bit} \end{aligned}$$

Jede einzelne Prüfung liefert nur 0,029 **Bit.** Für ein Beweisniveau von 1000:1 — also 10 Bit — braucht man etwa 344 Prüfungen.

Die Zahl passt zu dem, was Band 17 über Fallzahlen sagt: Für einen Unterschied von zehn Prozentpunkten bei Anteilen um 0,5 liegt der nötige Umfang in der Größenordnung von einigen hundert. ***Die informationstheoretische Rechnung liefert das in drei Zeilen*** *und ohne Verteilungsannahmen über Teststatistiken.*

Die Abhängigkeit vom Unterschied

p	$D(p \,\|\, 0{,}5)$	n **für** 10 **Bit**
0,51	0,00029	34 655
0,55	0,00723	1384
0,60	0,02905	344
0,90	0,53100	19

Der nötige Umfang wächst wie das Quadrat des Kehrwerts des Unterschieds. Halber Unterschied bedeutet vierfacher Umfang.

Probe: Von $p = 0{,}6$ auf $p = 0{,}55$ halbiert sich der Abstand zu 0,5; der Umfang steigt von 344 auf 1384 — Faktor 4,02. ✓

Das ist dieselbe Wurzel-n-Regel wie in Band 17 — hier fällt sie als Nebenprodukt ab. Abschnitt 8.3 erklärt, woher sie kommt: D wächst für kleine Unterschiede quadratisch.

Die Asymmetrie

$$D(p \,\|\, q) \;\neq\; D(q \,\|\, p)$$

	Wert	
$D(0{,}6 \,\|\, 0{,}5)$	0,0290	
$D(0{,}5 \,\|\, 0{,}6)$	0,0294	fast gleich
$D(0{,}9 \,\|\, 0{,}5)$	0,5310	
$D(0{,}5 \,\|\, 0{,}9)$	0,7370	39 % mehr

Bei kleinen Unterschieden ist die relative Entropie nahezu symmetrisch, bei großen nicht.

Die Asymmetrie hat eine klare Bedeutung: $D(p\|q)$ misst, wie leicht man q widerlegt, wenn p gilt. Eine seltene Beobachtung unter q — etwa ein Misserfolg, wenn q ihn mit 0,1 erwartet — liefert sehr viel Evidenz. ***Die relative Entropie ist kein Abstand****; sie erfüllt weder die Symmetrie noch die Dreiecksungleichung und heißt deshalb Divergenz.*

8.2 Fisher-Information

Satz 8.2 — die lokale Näherung

Für kleine ε gilt

$$D(p_{\theta+\varepsilon} \,\|\, p_\theta) \;\approx\; \frac{\varepsilon^2}{2\ln 2}\, \mathcal{I}(\theta)$$

mit der **Fisher-Information**

$$\mathcal{I}(\theta) = \mathbb{E}\left[\left(\frac{\partial}{\partial\theta}\ln f_\theta(X)\right)^2\right].$$

Die Fisher-Information ist die Krümmung der relativen Entropie am Minimum.

Die Probe für die Bernoulli-Verteilung

$$\mathcal{I}(p) = \frac{1}{p(1-p)}$$

Bei $p = 0{,}5$ ist $\mathcal{I} = 4$:

ε	exakt	Näherung	Verh.
0,10	0,029049	0,028854	1,0068
0,05	0,007226	0,007213	1,0017
0,01	0,000289	0,000289	1,0001

Zur Näherung bei $\varepsilon = 0{,}1$: $\frac{0{,}01\cdot 4}{2\cdot 0{,}6931} = \frac{0{,}04}{1{,}3863} = 0{,}028854$. ✓

Die Folgerung: Cramér-Rao

Für jeden erwartungstreuen Schätzer aus n Beobachtungen gilt

$$\operatorname{Var}(\hat\theta) \;\geq\; \frac{1}{n\,\mathcal{I}(\theta)}.$$

p	$\mathcal{I}(p)$	**Schranke**
0,10	11,11	$0{,}090/n$
0,25	5,33	$0{,}188/n$
0,50	4,00	$0{,}250/n$
0,90	11,11	$0{,}090/n$

Die Information ist am Rand am größten, in der Mitte am kleinsten. Ein Anteil nahe 0 oder 1 lässt sich genauer schätzen als einer nahe $\frac{1}{2}$.

Die Schranke $p(1-p)/n$ ist genau die Varianz des relativen Häufigkeitsschätzers aus Band 17 — der damit die Schranke mit Gleichheit erreicht und in diesem Sinn optimal ist. ***Die Informationstheorie liefert hier nicht nur eine Grenze, sondern den Nachweis, dass ein vertrautes Verfahren sie erreicht.***

8.3 Modellwahl als Kompression

Der Gedanke

Nach Satz 3.3 kostet eine Beobachtung mit der Wahrscheinlichkeit p genau $-\operatorname{ld} p$ Bit, wenn man sie optimal codiert.

Die negative Log-Likelihood *ist* eine Codelänge.

Das Prinzip der kürzesten Beschreibung

Man wählt das Modell, das die Gesamtbeschreibung am kürzesten macht:

$$L_{\text{ges}} = \underbrace{L(\text{Modell})}_{\text{Parameter}} + \underbrace{L(\text{Daten} \mid \text{Modell})}_{-\operatorname{ld} \Pr[\text{Daten}|\hat{\theta}]}$$

Damit ist die Modellwahl ein Kompressionsproblem. ***Ein Modell ist gut, wenn es hilft, die Daten kurz aufzuschreiben*** *— und zwar einschließlich seiner eigenen Beschreibung. Das ist die praktisch ausführbare Fassung des Gedankens aus Kapitel 7.*

Die Kosten eines Parameters

Ein reellwertiger Parameter, aus n Beobachtungen geschätzt, braucht etwa

$$\tfrac{1}{2} \operatorname{ld} n \text{ Bit.}$$

Grund: Die Schätzgenauigkeit ist nach Cramér-Rao von der Ordnung $1/\sqrt{n}$; feiner anzugeben lohnt nicht.

n	$\frac{1}{2}\operatorname{ld} n$
100	3,32 Bit
1000	4,98 Bit
10^6	9,97 Bit

Ein durchgerechnetes Beispiel

Ist eine Münze fair? Wir vergleichen zwei Modelle.

Modell	**Parameter**	**Codelänge**
fair	keiner	n Bit
verzerrt	$\hat{p} = k/n$	$n\,h(\hat{p}) + \frac{1}{2}\operatorname{ld} n$

Die Auswertung

n	$\hat{p}$	**fair**	**verzerrt**	**Wahl**
100	0,55	100,00	102,60	fair
100	0,60	100,00	100,42	fair
100	0,65	100,00	96,73	verzerrt
1000	0,55	1000,00	997,76	verzerrt
1000	0,60	1000,00	975,93	verzerrt
10^4	0,52	10 000	9995,10	verzerrt

Zur zweiten Zeile: $100 \cdot h(0{,}6) = 100 \cdot 0{,}9710 = 97{,}10$; dazu $\frac{1}{2}\operatorname{ld} 100 = 3{,}32$; Summe $100{,}42 > 100$.

Bei 60 **Kopf unter** 100 **Würfen wird die Münze für fair gehalten; bei** 600 **unter** 1000 **nicht.** Dieselbe relative Abweichung, verschiedenes Urteil.

Das ist richtig so und entspricht dem, was Band 17 über Signifikanz sagt — nur ohne willkürliche Schwelle. ***Die Kosten des zusätzlichen Parameters wachsen mit*** $\frac{1}{2}\operatorname{ld} n$***, der Gewinn mit*** $n \cdot D(\hat{p}\,\|\,0{,}5)$*.* *Der Gewinn wächst schneller, also entscheidet bei genügend Daten jeder echte Unterschied.*

Die Umschlagbedingung

Das verzerrte Modell gewinnt, wenn

$$n\bigl(1 - h(\hat{p})\bigr) \;>\; \tfrac{1}{2}\operatorname{ld} n.$$

Wegen $1 - h(\hat{p}) \approx \frac{2}{\ln 2}(\hat{p} - 0{,}5)^2 \cdot \ldots$ — genauer nach Satz 8.2:

$$1 - h(\hat{p}) \;\approx\; \frac{4\,(\hat{p} - 0{,}5)^2}{2\ln 2} = 2{,}885\,(\hat{p} - 0{,}5)^2$$

Für $\hat{p} = 0{,}6$: $2{,}885 \cdot 0{,}01 = 0{,}02885$ gegen exakt $1 - 0{,}9710 = 0{,}0290$. ✓

$$n \cdot 2{,}885\,(\hat{p} - 0{,}5)^2 \;>\; \tfrac{1}{2}\operatorname{ld} n$$

Bei $\hat{p} = 0{,}6$: $0{,}02885\,n > 0{,}5 \operatorname{ld} n$. Bei $n = 100$: 2,885 gegen 3,32 — knapp nicht. Bei $n = 120$: 3,46 gegen 3,45 — gerade. ✓

Der Zusammenhang mit AIC

Ein verwandtes Kriterium lautet

$$\mathrm{AIC} = -2 \ln \hat{L} + 2k$$

mit k als Zahl der Parameter.

	Strafe je Parameter	**Ziel**
AIC	$1/\ln 2 = 1{,}44$ Bit	beste Vorhersage
MDL, BIC	$\frac{1}{2}\operatorname{ld} n$ Bit	richtiges Modell

AIC bestraft jeden Parameter mit einem festen Betrag, MDL mit einem wachsenden. Bei großen Datenmengen wählt AIC daher größere Modelle.

*Das ist kein Fehler eines der beiden, sondern ein Unterschied im Ziel. **Akaike** leitete sein Kriterium 1973 aus der erwarteten relativen Entropie zwischen Wahrheit und geschätztem Modell her — es zielt auf gute Vorhersage. MDL zielt darauf, das zutreffende Modell zu finden. **Wer das falsche Kriterium wählt, bekommt eine richtige Antwort auf eine andere Frage.***

8.4 Der Bruchfall

Vier Vorbehalte

Die Modellmenge	Alle Kriterien wählen *unter den betrachteten* Modellen. Ist keines richtig, so wählen sie das am wenigsten falsche.
Die Codierung	Die Kosten eines Parameters hängen davon ab, wie man ihn codiert. $\frac{1}{2}\operatorname{ld} n$ ist eine Näherung.
Unabhängigkeit	Satz 8.1 setzt unabhängige Beobachtungen voraus. Bei Abhängigkeit ist die tatsächliche Evidenz kleiner.
Asymptotik	Die Rechtfertigung von AIC und BIC ist asymptotisch. Bei kleinen Stichproben sind beide unzuverlässig.

Zur dritten Zeile

Werden hundert Messungen an zehn Patienten erhoben, so liegen nicht hundert unabhängige Beobachtungen vor.

> *Die Evidenz ist dann erheblich kleiner als $n \cdot D$, und alle Rechnungen dieses Kapitels überschätzen sie.* ***Das ist derselbe Fehler, den Band 17 als Pseudoreplikation behandelt*** *— hier erscheint er als eine zu großzügig gezählte Bitmenge.*

Zur ersten Zeile

> *Das ist die ernsteste Einschränkung und gilt für jedes Auswahlkriterium. Ein Kriterium, das unter zehn falschen Modellen das beste wählt, sagt nichts darüber, ob eines davon brauchbar ist.* ***Modellwahl ersetzt keine Modellprüfung.***

8.5 Übungsaufgaben

Aufgabe 8.1 — Relative Entropie und Asymmetrie

Berechnen Sie $D(p\|q)$ und $D(q\|p)$ für die Verteilungen

$$p = (0{,}5;\ 0{,}3;\ 0{,}2), \qquad q = (0{,}4;\ 0{,}4;\ 0{,}2).$$

Lösung

Schritt 1 — $D(p\|q)$

p_i	q_i	$\mathrm{ld}(p_i/q_i)$	$p_i \,\mathrm{ld}(p_i/q_i)$
0,5	0,4	0,3219	0,16096
0,3	0,4	−0,4150	−0,12451
0,2	0,2	0	0
			0,03645

Schritt 2 — $D(q\|p)$

q_i	p_i	$\mathrm{ld}(q_i/p_i)$	$q_i \,\mathrm{ld}(q_i/p_i)$
0,4	0,5	−0,3219	−0,12877
0,4	0,3	0,4150	0,16601
0,2	0,2	0	0
			0,03724

Schritt 3 — Der Vergleich

$$D(p\|q) = 0{,}0365, \qquad D(q\|p) = 0{,}0372$$

Beide sind positiv und verschieden — wie Satz 4.4 und die Asymmetrie verlangen.

Schritt 4 — Der Stichprobenumfang

Für 10 Bit Evidenz:

$$n \approx \frac{10}{0{,}0365} = 274$$

Schritt 5 — Ein Grenzfall

Hätte q eine Null an einer Stelle, an der p positiv ist:

$$q = (0{,}5;\ 0{,}5;\ 0), \qquad p = (0{,}5;\ 0{,}3;\ 0{,}2)$$

$$D(p\|q) = \cdots + 0{,}2 \,\mathrm{ld}\,\frac{0{,}2}{0} = \infty$$

Eine einzige Beobachtung, die unter q unmöglich ist, widerlegt q vollständig.

Umgekehrt ist $D(q\|p)$ endlich — man kann p durch keine einzelne Beobachtung ausschließen. ***Die Asymmetrie ist hier vollständig:*** *unendlich gegen endlich. Das ist der Grund, warum man in der Praxis nie ein Modell verwendet, das einer möglichen Beobachtung die Wahrscheinlichkeit null zuweist.*

Aufgabe 8.2 — Fallzahl bestimmen

Ein Medikament soll die Ansprechrate von 30 auf 40 Prozent heben. Wie viele Patien-

ten braucht man je Gruppe für ein Beweisniveau von 100:1?

Lösung

Schritt 1 — Das Beweisniveau in Bit

$$\operatorname{ld} 100 = 6{,}644 \text{ Bit}$$

Schritt 2 — Die relative Entropie

$$\begin{aligned} D(0{,}4 \,\|\, 0{,}3) &= 0{,}4 \operatorname{ld} \frac{0{,}4}{0{,}3} + 0{,}6 \operatorname{ld} \frac{0{,}6}{0{,}7} \\ &= 0{,}4 \cdot 0{,}4150 + 0{,}6 \cdot (-0{,}2224) \\ &= 0{,}16601 - 0{,}13343 = \mathbf{0{,}03258} \text{ Bit} \end{aligned}$$

Schritt 3 — Der Umfang

$$n \approx \frac{6{,}644}{0{,}03258} = 204$$

Etwa 204 Patienten in der Behandlungsgruppe.

Schritt 4 — Warum das nicht die ganze Antwort ist

Die Rechnung unterstellt, dass die Vergleichsgruppe die Rate 0,3 *sicher* hat. Tatsächlich wird auch sie geschätzt.

> *Bei zwei gleich großen Gruppen verdoppelt sich die Varianz der Differenz — man braucht etwa den doppelten Umfang je Gruppe. Die übliche Fallzahlrechnung aus Band 17 liefert für diesen Fall bei 80 Prozent Güte und fünf Prozent Niveau rund 370 je Gruppe.* ***Die Größenordnung stimmt; die informationstheoretische Rechnung ist eine untere Abschätzung.***

Schritt 5 — Die Abhängigkeit vom Unterschied

von 0,30 **auf**	D	n für 6,64 Bit
0,35	0,00834	796
0,40	0,03258	204
0,50	0,12577	53
0,60	0,27706	24

> *Die Vervierfachung beim Halbieren des Unterschieds ist wieder sichtbar: 204 → 796 ist der Faktor 3,9.* ***Wer einen halb so großen Effekt nachweisen will, braucht die vierfache Fallzahl*** *— und das ist der eigentliche Grund, warum kleine Effekte so schwer zu belegen sind.*

Aufgabe 8.3 — Modellwahl

Ein Würfel wird 120-mal geworfen. Die Sechs kommt 30-mal. Ist er gezinkt?

Lösung

Schritt 1 — Die Modelle

Modell	Parameter	Annahme
M_0	keiner	$p_6 = \frac{1}{6}$
M_1	einer	p_6 frei, Rest gleich

Schritt 2 — Die Codelänge unter M_0

Jeder Wurf ist entweder eine Sechs ($p = \frac{1}{6}$) oder nicht ($p = \frac{5}{6}$):

$$L_0 = 120 \cdot h\left(\tfrac{1}{6}\right) = 120 \cdot 0{,}6500 = 78{,}00 \text{ Bit}$$

Zur Entropie: $h\left(\frac{1}{6}\right) = \frac{1}{6}\operatorname{ld} 6 + \frac{5}{6}\operatorname{ld}\frac{6}{5} = 0{,}4308 + 0{,}2192 = 0{,}6500.$

> *Wir betrachten nur die Frage "Sechs oder nicht"; die Verteilung auf die übrigen fünf Augenzahlen ist in beiden Modellen gleich und kürzt sich heraus.*

Schritt 3 — Die Codelänge unter M_1

$$\hat{p} = \frac{30}{120} = 0{,}25$$

$$L_1 = 120 \cdot h(0{,}25) + \tfrac{1}{2}\operatorname{ld} 120 = 120 \cdot 0{,}8113 + 0{,}5 \cdot 6{,}907$$

$$= 97{,}36 + 3{,}45 = 100{,}81 \text{ Bit}$$

Schritt 4 — Der Vergleich

$$L_0 = 78{,}00 \;<\; L_1 = 100{,}81$$

M_0 gewinnt deutlich — der Würfel gilt als fair?

Schritt 5 — Der Fehler

Hier liegt eine Falle. Die Codelänge unter M_1 wurde mit der *tatsächlichen* Häufigkeit 0,25 gebildet — aber M_0 mit der *angenommenen* Rate $\frac{1}{6}$, obwohl die Daten 0,25 zeigen. *Richtig ist:* Unter M_0 kostet jeder Wurf $-\operatorname{ld} p$ Bit mit dem *Modellwert*:

$$L_0 = -30\operatorname{ld}\tfrac{1}{6} - 90\operatorname{ld}\tfrac{5}{6} = 30 \cdot 2{,}5850 + 90 \cdot 0{,}2630$$

$$= 77{,}55 + 23{,}67 = 101{,}22 \text{ Bit}$$

Schritt 6 — Der richtige Vergleich

	Bit	
M_0 (fair)	101,22	
M_1 (gezinkt)	**100,81**	kürzer
Unterschied	0,41	knapp

M_1 **gewinnt — aber nur um** 0,41 **Bit, also mit einem Evidenzverhältnis von** $2^{0,41} = 1{,}33$ **zu eins.** Das ist kein belastbarer Befund.

Schritt 7 — Die Probe über die relative Entropie

Der Gewinn ohne Parameterstrafe:

$$120 \cdot D(0{,}25 \,\|\, \tfrac{1}{6}) = 120 \cdot 0{,}03224 = 3{,}87 \text{ Bit}$$

Abzüglich der Strafe 3,45 bleiben 0,42 — bis auf Rundung der Unterschied aus Schritt 6. ✓

> *Die Lehre aus Schritt 5 ist allgemein:* ***Die Codelänge unter einem Modell wird stets mit dessen eigenen Wahrscheinlichkeiten gebildet****, nicht mit den beobachteten. Nur beim Modell mit freiem Parameter fallen beide zusammen — und genau dafür bezahlt man die Strafe* $\frac{1}{2} \operatorname{ld} n$.

Schritt 8 — Wie viele Würfe man bräuchte

Für 10 Bit Netto-Evidenz:

$$n \cdot 0{,}03224 - \tfrac{1}{2} \operatorname{ld} n \;\geq\; 10$$

Bei $n = 400$*:* $12{,}90 - 4{,}32 = 8{,}57$ — noch nicht.
Bei $n = 450$*:* $14{,}51 - 4{,}41 = 10{,}10$ — erreicht.

> *Etwa* 450 *Würfe. Die* 120 *des Beispiels reichten bei weitem nicht — obwohl die beobachtete Rate* 0,25 *die erwartete* 0,167 *um die Hälfte übersteigt.* ***Ein auffälliger Anteil ist noch kein Befund.***

Von der Entzifferung zur Modellwahl

Solomon Kullback (1907–1994) und **Richard Leibler** (1914–2003) arbeiteten beide für den amerikanischen Nachrichtendienst.

> *Kullback hatte während des Zweiten Weltkriegs an der Entzifferung japanischer Chiffren mitgewirkt und wurde später Chefkryptanalytiker der NSA. Die Frage, die zur relativen Entropie führte, war praktisch: Wie viele abgefangene Nachrichten braucht man, um zwischen zwei Hypothesen über ein Chiffriersystem zu entscheiden?*

Die Arbeit von 1951

Sie erschien in den *Annals of Mathematical Statistics* unter dem Titel “On Information and Sufficiency”.

Der Titel nennt den zweiten Beitrag: Kullback und Leibler zeigten, dass eine Statistik genau dann erschöpfend ist — also die ganze Information über den Parameter enthält — wenn sie die relative Entropie unverändert lässt. Damit erhielt ein Begriff aus Band 17 eine informationstheoretische Kennzeichnung.

Fisher, früher

Ronald Fisher hatte die nach ihm benannte Information bereits 1922 eingeführt — zwanzig Jahre vor Shannon und ohne jeden Bezug zur Nachrichtentechnik.

*Dass beide Größen zusammenhängen — die Fisher-Information ist die Krümmung der relativen Entropie — wurde erst nachträglich bemerkt. **Zwei Fächer hatten unabhängig voneinander dieselbe Größe gefunden**, das eine zur Beurteilung von Schätzern, das andere zur Beurteilung von Kanälen.*

Akaike, 1973

Hirotugu Akaike (1927–2009) leitete sein Kriterium aus der erwarteten relativen Entropie zwischen der wahren Verteilung und dem geschätzten Modell her.

Er berichtete, die Idee sei ihm 1971 in einem Zug gekommen. Sein Beitrag bestand darin, den Schätzfehler der Parameter mitzubilanzieren — und dabei kommt der Zuschlag von einem Parameter je Parameter heraus, unabhängig vom Stichprobenumfang.

Rissanen, 1978

Jorma Rissanen formulierte das Prinzip der kürzesten Beschreibung als eigenständigen Zugang zur Statistik — ohne die Annahme, dass es überhaupt ein *wahres* Modell gibt.

*Das ist der philosophisch bemerkenswerteste Punkt: **MDL fragt nicht, welches Modell wahr ist, sondern welches die Daten am kürzesten beschreibt.** Damit ist der Bogen zu Kapitel 7 geschlossen — und zu Solomonoffs Zugang von 1960, der dasselbe mit der nicht berechenbaren Größe K tat.*

Information und Lernen

Schranken für das Verallgemeinern	Wie viel ein Lernverfahren über seine Trainingsdaten *behält*, begrenzt seinen Übertragungsfehler.
Variationsverfahren	Die relative Entropie als Zielfunktion beim Anpassen von Näherungsverteilungen.
Informationsengpass	Man sucht eine Darstellung, die möglichst wenig über die Eingabe und möglichst viel über die Zielgröße enthält.

Zur ersten Zeile

Ist $I(\text{Trainingsdaten}; \text{gelerntes Modell})$ klein, so ist die Lücke zwischen Trainings- und Testfehler klein.

> *Das ist eine bemerkenswerte Umkehrung: Ein Verfahren verallgemeinert gut, wenn es sich möglichst wenig merkt. Die Schranke hat dieselbe Gestalt wie die Überanpassungsargumente aus Band 17 — nur in Bit gemessen.* ***Auswendiglernen ist informationstheoretisch teuer, und genau das bestraft die Schranke.***

Zur dritten Zeile

Man maximiert $I(T;Y) - \beta\, I(T;X)$ über Darstellungen T der Eingabe X.

> *Der Gedanke ist alt — es ist die Suche nach einer erschöpfenden Statistik — und in dieser Form seit 1999 formuliert. Die Behauptung, tiefe Netze arbeiteten nach diesem Prinzip, wurde ab 2017 lebhaft diskutiert und ist umstritten; die Messung von Transinformation in hochdimensionalen stetigen Räumen ist selbst ein ungelöstes Problem.*

Was Sie jetzt können

Satz 8.1	D ist die Evidenz je Beobachtung
Satz 8.2	Fisher ist die Krümmung von D
Cramér-Rao	Var $\geq 1/(n\mathcal{I})$
MDL	Modell plus Daten, in Bit
Der Bruchfall	Modellmenge, Abhängigkeit, Asymptotik

Damit endet Teil III. Bisher wollten wir Information erhalten. Ab Kapitel 9 wollen wir sie verbergen — und die Entropie wird zum Maß dafür, was ein Mitleser nicht erfährt.

Teil IV

Geheimhaltung

Kapitel 9

Perfekte Sicherheit

9.1 Der Leitfall

Patientendaten übertragen

Das Klinikum sendet Befunde an eine Praxis. Die Leitung ist abhörbar.



Die Bestandteile

Größe	Symbol	wer kennt sie
Klartext	M	Sender, Empfänger
Schlüssel	K	Sender, Empfänger
Geheimtext	C	alle

Die Frage: Was heißt es, dass der Mitleser nichts erfährt — und ist das erreichbar?

Die Antwort auf beide Teile gibt Shannons Arbeit von 1949, und sie benutzt genau die Größen aus Teil II. "Nichts erfahren" heißt: Die Transinformation zwischen Klartext und Geheimtext ist null.

Die Regel von Kerckhoffs

Das Verfahren gilt als bekannt. Geheim ist allein der Schlüssel.

Auguste Kerckhoffs *formulierte diesen Grundsatz 1883. Er ist keine Vorsichtsmaßnahme, sondern eine Aussage über die Wirklichkeit: Verfahren werden bekannt — durch Verrat, durch Nachbau, durch Veröffentlichung.* ***Ein Verfahren, dessen Sicherheit auf seiner Geheimhaltung beruht, ist genau einmal sicher.*** *Ein Schlüssel lässt sich dagegen austauschen.*

9.2 Warum klassische Verfahren brechen

Die einfache Ersetzung

Jedem Buchstaben wird fest ein anderer zugeordnet. Der Schlüsselraum umfasst

$$26! \approx 4{,}03 \cdot 10^{26}$$

Möglichkeiten — also

$$H(K) = \mathrm{ld}(26!) = 88{,}4 \text{ Bit}.$$

Das ist mehr als ein 80-Bit-Schlüssel — und das Verfahren ist mit Papier und Bleistift zu brechen.

Warum

Die Ersetzung verändert die Buchstaben, nicht ihre Häufigkeiten. Im Geheimtext steht an der Stelle des E ein anderes Zeichen — aber es ist genauso häufig.

*Die Größe des Schlüsselraums ist also kein Maß für Sicherheit. **Entscheidend ist, ob der Geheimtext Struktur des Klartextes durchlässt** — und genau das misst die Transinformation. Abschnitt 9.5 gibt an, wie viele Zeichen genügen, um den Schlüssel festzulegen.*

9.3 Perfekte Sicherheit

Definition 9.1 — Shannon, 1949

Ein Verfahren heißt **perfekt sicher**, wenn

$$I(M;C) = 0,$$

gleichbedeutend mit

$$\Pr[M = m \mid C = c] = \Pr[M = m] \qquad \text{für alle } m, c.$$

Was das bedeutet

Der Geheimtext verändert die Einschätzung des Mitlesers über den Klartext nicht im Geringsten. Er ist genau so klug wie vorher.

*Das ist eine sehr starke Forderung — und die einzige Sicherheitsdefinition dieses Bandes, die ohne jede Annahme über die Rechenkraft des Gegners auskommt. **Sie gilt auch gegen einen Gegner mit unbegrenzter Rechenzeit**, denn es gibt schlicht nichts zu berechnen.*

Was sie nicht fordert

Der Mitleser darf durchaus etwas über den Klartext wissen — etwa dass es ein Befund ist. Er darf nur durch den Geheimtext nichts *hinzulernen*.

Satz 9.2 — der Einmalschlüssel ist perfekt sicher

Sei M eine Bitfolge der Länge n und K eine gleichverteilte, unabhängige Bitfolge derselben Länge. Dann ist

$$C = M \oplus K$$

perfekt sicher.

Beweis

Für festes m und beliebiges c:

$$\Pr[C = c \mid M = m] = \Pr[K = c \oplus m] = 2^{-n}$$

— denn K ist gleichverteilt, und zu jedem Paar (c, m) gehört genau ein Schlüssel. Diese Wahrscheinlichkeit hängt *nicht* von m ab. Also sind C und M unabhängig, und nach Satz 4.5 ist $I(M;C) = 0$. ■

Ein Zahlenbeispiel

Klartext M	`01001000`
Schlüssel K	`11010110`
Geheimtext C	`10011110`

Entschlüsseln: $C \oplus K =$ `01001000` $= M$ ✓

Warum der Mitleser nichts erfährt

Zu *jedem* denkbaren Klartext gibt es einen Schlüssel, der genau diesen Geheimtext erzeugt hätte:

Klartext	**nötiger Schlüssel**
`01001000`	`11010110`
`01000001`	`11011111`
`11111111`	`01100001`

Alle drei sind gleich wahrscheinlich. Der Geheimtext schließt keinen Klartext aus.

9.4 Shannons Schranke

Satz 9.3 — der Schlüssel muss so groß sein wie die Nachricht

Ist ein Verfahren perfekt sicher, so gilt

$$H(K) \;\geq\; H(M).$$

Beweis — Schritt 1: die Voraussetzung
Perfekte Sicherheit bedeutet $I(M;C) = 0$, also nach Definition 4.1

$$H(M \mid C) = H(M).$$

Schritt 2 — der Empfänger kann entschlüsseln
Aus C und K ergibt sich M eindeutig:

$$H(M \mid C, K) = 0.$$

Schritt 3 — die Abschätzung

$$\begin{aligned} H(M \mid C) &\le H(M, K \mid C) && \text{(mehr Größen, mehr Ungewissheit)} \\ &= H(K \mid C) + H(M \mid K, C) && \text{(Kettenregel)} \\ &= H(K \mid C) + 0 && \text{(Schritt 2)} \\ &\le H(K) && \text{(Satz 2.6)} \end{aligned}$$

Schritt 4 — zusammensetzen

$$H(M) = H(M \mid C) \;\le\; H(K)$$

■

Perfekte Sicherheit verlangt einen Schlüssel, der mindestens so viel Ungewissheit trägt wie die Nachricht.

Der Beweis benutzt nur die Kettenregel und Satz 2.6 — also Werkzeuge aus Kapitel 2. ***Die mathematische Kryptographie beginnt mit einem Satz, dessen Beweis vier Zeilen Informationstheorie ist.*** *Und der Satz ist ein Unmöglichkeitsergebnis: Er sagt nicht, wie man sicher verschlüsselt, sondern was es kostet.*

Warum der Einmalschlüssel kaum benutzt wird

Schlüssellänge	Wer ein Gigabyte übertragen will, muss vorher ein Gigabyte Schlüssel sicher austauschen.
Das Henne-Ei-Problem	Wenn man einen sicheren Kanal für den Schlüssel hat, könnte man darüber gleich die Nachricht senden.
Einmalig	Der Name ist Programm. Wird ein Schlüssel zweimal verwendet, bricht alles zusammen.
Echter Zufall	Der Schlüssel muss gleichverteilt sein. Ein Pseudozufallsgenerator zerstört die Perfektheit.

Zur dritten Zeile
Werden M_1 und M_2 mit demselben K verschlüsselt, so gilt

$$C_1 \oplus C_2 = M_1 \oplus M_2.$$

Der Schlüssel fällt heraus. Übrig bleibt die Summe zweier Klartexte — und die ist mit Sprachstatistik zu trennen.

Genau das geschah tatsächlich: Das Venona-Projekt der amerikanischen Dienste konnte zwischen 1943 und 1980 sowjetische Funksprüche entziffern, weil während des Krieges Schlüsselblöcke doppelt gedruckt und verteilt worden waren. ***Ein beweisbar unbrechbares Verfahren wurde durch einen Verfahrensfehler gebrochen*** *— und das ist die Regel, nicht die Ausnahme.*

9.5 Die Unizitätsdistanz

Wenn der Schlüssel zu kurz ist

Ist $H(K) < H(M)$, so ist das Verfahren nicht perfekt sicher — aber wie unsicher?

Der Gedanke

Jedes Zeichen des Klartextes trägt Redundanz. Natürliche Sprache hat eine Entropierate von etwa 1,5 Bit je Zeichen bei einem Alphabet von 26 Zeichen:

$$D = \operatorname{ld} 26 - 1{,}5 = 4{,}70 - 1{,}5 = 3{,}2 \text{ Bit je Zeichen}$$

Jedes Zeichen Geheimtext liefert dem Angreifer etwa D Bit an Auskunft über den Schlüssel. Nach $H(K)/D$ Zeichen ist der Schlüssel festgelegt.

Definition 9.4 — Unizitätsdistanz

$$U = \frac{H(K)}{D}$$

— die Länge des Geheimtextes, ab der im Mittel nur noch ein Schlüssel zu einem sinnvollen Klartext führt.

Die Werte

Verfahren	$H(K)$	U in Zeichen
Cäsar	4,70	1,5
Vigenère, $t = 5$	23,50	7,3
Substitution	88,38	**27,6**
128-Bit-Schlüssel	128	40
256-Bit-Schlüssel	256	80
Einmalschlüssel	$= H(M)$	∞

Bei der einfachen Ersetzung genügen rund achtundzwanzig Buchstaben, um den Schlüssel eindeutig festzulegen.

Das erklärt die Erfahrung jedes Rätsellösers: Kurze Kryptogramme sind mehrdeutig, ab etwa dreißig Zeichen gibt es nur noch eine sinnvolle Lesart. ***Die Zahl folgt aus der Redundanz der Sprache, nicht aus einem Verfahren.***

Der entscheidende Vorbehalt

Die Unizitätsdistanz sagt, ab wann der Schlüssel *bestimmt* ist — nicht, wie man ihn findet.

Bei einem 128-Bit-Schlüssel ist nach vierzig Zeichen eindeutig festgelegt, welcher es ist. Ihn zu finden erfordert das Durchprobieren von 2^{128} Möglichkeiten — und genau darauf beruht die gesamte moderne Kryptographie. ***Sie tauscht informationstheoretische Sicherheit gegen rechnerische*** *und lebt davon, dass die Umsetzung der einen in die andere unpraktikabel ist.*

Und die Folgerung für die Praxis

Komprimiert man den Klartext vor der Verschlüsselung, so sinkt D — im Idealfall auf null.

Bei einem perfekt komprimierten Klartext wäre $U = \infty$ auch bei kurzem Schlüssel: Es gäbe keinen Anhaltspunkt, welcher Entschlüsselungsversuch sinnvoll ist. ***Kompression vor Verschlüsselung ist daher kein Luxus, sondern eine Sicherheitsmaßnahme*** *— und der einzige Punkt, an dem sich Teil I und Teil IV unmittelbar berühren.*

9.6 Der Bruchfall

Was perfekte Sicherheit nicht leistet

Keine Echtheit	Der Empfänger weiß nicht, ob die Nachricht vom richtigen Absender stammt.
Keine Unversehrtheit	Der Geheimtext lässt sich gezielt verändern.
Keine Verkehrsdaten	Dass gesendet wurde, wann und wie lang, bleibt sichtbar.

Zur zweiten Zeile — die Formbarkeit

Kippt ein Angreifer im Geheimtext das letzte Bit, so kippt es auch im Klartext:

$$(C \oplus \delta) \oplus K = M \oplus \delta$$

Ein Angreifer, der den Klartext nicht kennt, kann ihn dennoch gezielt verändern.

Bei einer Dosierungsangabe wäre das folgenschwer: Aus "5 mg" lässt sich ohne Kenntnis des Klartextes ein anderer Wert machen, wenn man weiß, an welcher Stelle die Zahl steht. ***Perfekte Geheimhaltung und Unversehrtheit sind völlig verschiedene Eigenschaften****, und Kapitel 11 behandelt die zweite.*

Zur dritten Zeile

Dass eine Praxis um drei Uhr nachts eine verschlüsselte Nachricht an die Onkologie sendet, sagt bereits etwas — unabhängig vom Inhalt. Die Verkehrsdatenanalyse ist in der Praxis oft ergiebiger als der Angriff auf die Verschlüsselung, und sie wird von keiner Sicherheitsdefinition dieses Bandes erfasst.

9.7 Übungsaufgaben

Aufgabe 9.1 — Der Einmalschlüssel

Gegeben sei der Geheimtext `11010011` eines 8-Bit-Einmalschlüssels.

(a)	Welcher Schlüssel liefert den Klartext `01000001`?
(b)	Welcher liefert `01011010`?
(c)	Was folgt daraus für den Mitleser?
(d)	Der Angreifer kippt Bit 3 und 8. Was empfängt der Empfänger?

Lösung

(a)

$$K = C \oplus M = \texttt{11010011} \oplus \texttt{01000001} = \texttt{10010010}$$

Probe: $\texttt{10010010} \oplus \texttt{01000001} = \texttt{11010011}$ ✓

(b)

$$K = \texttt{11010011} \oplus \texttt{01011010} = \texttt{10001001}$$

(c)
Beide Schlüssel sind gleich wahrscheinlich — jeder der 256 möglichen Schlüssel liefert genau einen der 256 möglichen Klartexte.

> **Der Mitleser kann keinen Klartext ausschließen und keinen bevorzugen.** Das ist Satz 9.2 in einem Einzelfall.

(d) Die Formbarkeit
Die Maske lautet $\delta = \texttt{00100001}$ (Bit 3 und 8, von links gezählt).

$$C' = \texttt{11010011} \oplus \texttt{00100001} = \texttt{11110010}$$

Der Empfänger entschlüsselt mit dem richtigen K:

$$M' = C' \oplus K = (C \oplus \delta) \oplus K = M \oplus \delta$$

Bei $M = \texttt{01000001}$:

$$M' = \texttt{01000001} \oplus \texttt{00100001} = \texttt{01100000}$$

> **Der Empfänger erhält eine veränderte Nachricht und bemerkt nichts.**

Schritt 5 — Die Deutung

> *Der Angreifer musste M nicht kennen, um M gezielt zu verändern. Er hat vollständige Kontrolle über die Differenz.* ***Wer eine Zahl an bekannter Stelle vermutet, kann sie gezielt verfälschen*** *— und beim Einmalschlüssel ist diese Verfälschung nicht erkennbar. Die Abhilfe ist ein Beglaubigungscode, Kapitel 11.*

Aufgabe 9.2 — Shannons Schranke anwenden

Ein Klinikum will täglich 500 Befunde von je 2 Kilobyte perfekt sicher übertragen. Wie viel Schlüsselmaterial ist nötig, und was bedeutet das?

Lösung

Schritt 1 — Das Nachrichtenvolumen

$$500 \cdot 2\,\text{kB} = 1000\,\text{kB} \approx 10^6\ \text{Byte} = 8 \cdot 10^6\ \text{Bit}$$

Schritt 2 — Die Schranke
Nach Satz 9.3 muss $H(K) \geq H(M)$ gelten. Bei unkomprimierten Befunden ist $H(M)$ deutlich kleiner als die Bitzahl — Text ist redundant.

Mit einer Entropierate von 1,5 *Bit je Zeichen und* 10^6 *Zeichen:*

$$H(M) \approx 1{,}5 \cdot 10^6 \text{ Bit}$$

Schritt 3 — Die praktische Folgerung

	je Tag	**je Jahr**
Unkomprimiert	1 MB	365 MB
Komprimiert	188 kB	69 MB

Selbst nach Kompression müssten jährlich rund 69 **Megabyte Schlüsselmaterial sicher ausgetauscht werden.**

Schritt 4 — Warum das den Ansatz erledigt

Der Schlüssel muss über einen sicheren Kanal übertragen werden — persönlich, per Kurier, auf einem versiegelten Datenträger.

Hätte man einen solchen Kanal für 69 Megabyte, so könnte man darüber gleich die Befunde senden. ***Der Einmalschlüssel verschiebt das Problem, statt es zu lösen*** *— er verwandelt "sicher übertragen" in "vorher sicher übertragen".*

Schritt 5 — Wo er dennoch eingesetzt wird

Kleine Mengen	Diplomatische Kurzmitteilungen, bei denen wenige hundert Bit genügen.
Vorratshaltung	Der Schlüssel wird zu einem Zeitpunkt ausgetauscht, zu dem ein sicherer Kanal vorhanden ist, und später verbraucht.
Langfristigkeit	Nachrichten, die auch in fünfzig Jahren geheim bleiben müssen — wo keine rechnerische Annahme trägt.

Die dritte Zeile ist heute wieder aktuell: Wer davon ausgeht, dass ein Quantenrechner die Verfahren aus Teil V bricht, muss annehmen, dass heute aufgezeichneter Verkehr später entschlüsselt wird. ***Gegen diese Sorge hilft nur informationstheoretische Sicherheit*** *— Kapitel 15 kommt darauf zurück.*

Aufgabe 9.3 — Unizitätsdistanz

Bestimmen Sie die Unizitätsdistanz für ein Vigenère-Verfahren mit der Schlüssellänge t und geben Sie an, ab welchem t ein Text von 200 Zeichen mehrdeutig bleibt.

Lösung

Schritt 1 — Die Schlüsselentropie
Der Schlüssel besteht aus t gleichverteilten Buchstaben:

$$H(K) = t \cdot \mathrm{ld}\, 26 = 4{,}70\, t \text{ Bit}$$

Schritt 2 — Die Unizitätsdistanz

$$U = \frac{4{,}70\, t}{3{,}2} = 1{,}47\, t$$

t	$H(K)$	U
1	4,70	1,5
5	23,50	7,3
20	94,00	29,4
100	470,0	146,9
136	639,2	**199,8**

Schritt 3 — Die Antwort

$$1{,}47\, t > 200 \quad \Longrightarrow \quad t > 136$$

Erst ab einer Schlüssellänge von 137 Zeichen bleibt ein Text von 200 Zeichen mehrdeutig.

Schritt 4 — Die Deutung
Der Schlüssel muss also mehr als zwei Drittel der Textlänge haben.

Das ist Satz 9.3 in abgeschwächter Form: Perfekte Sicherheit verlangt $H(K) \geq H(M)$, also $4{,}70\, t \geq 1{,}5 \cdot 200 = 300$, mithin $t \geq 64$. Die Unizitätsdistanz verlangt mehr, weil sie nicht Perfektheit fordert, sondern nur Mehrdeutigkeit bei der Suche — und dafür muss die Redundanz über die gesamte Alphabetgröße gemessen werden.

Schritt 5 — Warum Vigenère trotzdem fiel
Bei $t = 20$ und einem Text von 2000 Zeichen liegt $U = 29$ weit unter der Textlänge — der Schlüssel ist eindeutig bestimmt.

Und er ist auch findbar: Kennt man t, so zerfällt der Text in t Teiltexte, von denen jeder nur mit einem Cäsar-Verfahren verschlüsselt ist — und dafür genügt die Häufigkeitsanalyse. Die Periode t wiederum verrät sich durch Wiederholungen im Geheimtext. ***Die Unizitätsdistanz sagt, dass es geht; das Kasiski-Verfahren sagt, wie.***

Schritt 6 — Der Grenzfall
Bei $t \geq$ Textlänge und einem zufälligen Schlüssel wird Vigenère zum Einmalschlüssel.

Genau so wurde er historisch verwendet — als "laufender Schlüssel" mit einem Buchtext als Quelle. Das ist nicht perfekt sicher, weil der Buchtext selbst redundant ist: Man sucht Schlüssel, die zugleich sinnvollen Klartext und sinnvollen Schlüsseltext liefern.

Ein Patent und ein Beweis

Gilbert Vernam (1890–1960) meldete 1919 für die amerikanische Telefongesellschaft ein Verfahren an, das Fernschreibzeichen mit einem Lochstreifen verknüpfte.

> *Vernams ursprüngliches Verfahren benutzte einen sich wiederholenden Streifen — also einen Vigenère mit langer Periode.* ***Joseph Mauborgne*** *vom amerikanischen Fernmeldewesen erkannte, dass die Wiederholung die Schwäche ist, und schlug einen Streifen zufälliger Zeichen vor, der nur einmal benutzt wird.* ***Die entscheidende Idee war nicht die Verknüpfung, sondern die Einmaligkeit.***

Der Beweis

Claude Shannon bewies 1949 in *Communication Theory of Secrecy Systems*, dass das Verfahren perfekt sicher ist — und dass kein Verfahren mit kürzerem Schlüssel es sein kann.

> *Die Arbeit entstand bereits 1945 als vertraulicher Bericht und wurde erst nach der Freigabe veröffentlicht. Sie enthält neben Satz 9.3 die Unizitätsdistanz und die Begriffe Verwirrung und Verwischung, die den Entwurf von Blockchiffren bis heute leiten — Kapitel 10.*

Vorläufer

Frank Miller, ein amerikanischer Bankier, beschrieb 1882 in einem Codebuch für Telegramme ein Verfahren mit Einmalschlüsseln — siebenunddreißig Jahre vor Vernam.

> *Die Arbeit wurde erst 2011 wiederentdeckt und ausgewertet. Sie enthält bereits die Forderung nach Zufälligkeit und Einmaligkeit. Ob Vernam davon wusste, ist unbekannt.*

Venona

Zwischen 1943 und 1980 entzifferten amerikanische Dienste rund dreitausend sowjetische Funksprüche.

> *Die Ursache war ein Herstellungsfehler: Unter dem Druck des Krieges wurden Schlüsselblöcke doppelt gedruckt und an verschiedene Stellen verteilt.* ***Von Millionen Funksprüchen waren nur wenige Prozent betroffen — und das genügte.*** *Das Projekt enttarnte unter anderem die Spionage im Manhattan-Projekt. Es ist der lehrreichste Fall der Kryptographiegeschichte: Nicht die Mathematik versagte, sondern die Papierverwaltung.*

Informationstheoretische Sicherheit heute

Quanten-schlüsseltausch	Zwei Parteien erzeugen gemeinsames Schlüsselmaterial; Abhören ist physikalisch nachweisbar.
Geheimnisteilung	Ein Geheimnis wird so auf n Teile verteilt, dass je k genügen und $k-1$ nichts verraten.
Abhörkanäle	Ist der Kanal zum Angreifer schlechter als der zum Empfänger, lässt sich ohne Schlüssel geheim übertragen.

Zur zweiten Zeile

Adi Shamir gab 1979 ein Verfahren an, das auf der Polynominterpolation aus Kapitel 6 beruht.

> *Man wählt ein Polynom vom Grad $k-1$, dessen konstantes Glied das Geheimnis ist, und verteilt n Auswertungen. Je k Punkte bestimmen das Polynom; $k-1$ Punkte lassen jeden Wert an der Stelle null gleich möglich.* ***Das ist beweisbare Sicherheit im Sinn von Definition 9.1*** *— und dasselbe mathematische Prinzip wie beim Reed-Solomon-Code, nur in umgekehrter Absicht.*

Zur dritten Zeile

Aaron Wyner zeigte 1975: Ist der Kanal zum Abhörer schlechter, so gibt es eine positive **Geheimhaltungskapazität**.

> *Sie beträgt beim gedächtnislosen Kanal gerade die Differenz der Kapazitäten. Das ist bemerkenswert:* ***Man kann ohne vorher ausgetauschten Schlüssel geheim übertragen****, sofern der Gegner physikalisch benachteiligt ist. Praktisch ist die Voraussetzung schwer zu sichern — man müsste wissen, wie gut der Empfang des Abhörers ist.*

Was Sie jetzt können

Kerckhoffs	nur der Schlüssel ist geheim
Definition 9.1	$I(M;C) = 0$
Satz 9.2	Einmalschlüssel ist perfekt
Satz 9.3	$H(K) \geq H(M)$ — vier Zeilen
Definition 9.4	Unizitätsdistanz $H(K)/D$

Satz 9.3 macht perfekte Sicherheit praktisch unbrauchbar. Das nächste Kapitel gibt sie auf — und ersetzt sie durch eine Annahme, die niemand beweisen kann.

Kapitel 10

Blockchiffren

10.1 Der Übergang

Was Satz 9.3 erzwingt

Perfekte Sicherheit verlangt einen Schlüssel, der so lang ist wie die Nachricht. Das ist praktisch unbrauchbar.

Also gibt man sie auf — und ersetzt sie durch eine schwächere Forderung.

Informations-theoretisch	Der Geheimtext enthält *keine* Information über den Klartext. Gilt gegen jeden Gegner.
Rechnerisch	Der Geheimtext enthält Information, aber kein Verfahren mit vertretbarem Aufwand kann sie gewinnen.

Der Unterschied ist grundsätzlich. Bei rechnerischer Sicherheit gibt es die Information — ein Gegner mit unbegrenzter Rechenzeit findet den Schlüssel stets, einfach durch Durchprobieren. ***Die Sicherheit beruht allein darauf, dass niemand diese Rechenzeit hat.***

Die Zahlen

Schlüssel	**Möglich-keiten**	**bei 10^{18} je Sekunde**
56 Bit	$7{,}2 \cdot 10^{16}$	0,07 Sekunden
112 Bit	$5{,}2 \cdot 10^{33}$	$1{,}7 \cdot 10^{8}$ Jahre
128 Bit	$3{,}4 \cdot 10^{38}$	$1{,}1 \cdot 10^{13}$ Jahre
256 Bit	$1{,}2 \cdot 10^{77}$	$3{,}7 \cdot 10^{51}$ Jahre

Das Weltalter beträgt $1{,}4 \cdot 10^{10}$ Jahre. Bei 128 Bit liegt die Suchdauer tausendmal darüber — und die unterstellte Rate von einer Trillion Schlüsseln je Sekunde ist bereits großzügig. ***Zwischen 56 und 128 Bit liegen keine zweieinhalb Größenordnungen, sondern zwanzig.***

10.2 Verwirrung und Verwischung

Shannons zwei Entwurfsgrundsätze

Verwirrung	Der Zusammenhang zwischen Schlüssel und Geheimtext soll so verwickelt sein, dass er sich nicht durch einfache Gleichungen beschreiben lässt.
Verwischung	Jedes Bit des Klartextes soll jedes Bit des Geheimtextes beeinflussen — die Struktur des Klartextes wird über den ganzen Block verteilt.

Beide stammen aus Shannons Arbeit von 1949 und sind bis heute die Leitlinien jedes Chiffrenentwurfs. ***Die Verwischung ist die Antwort auf die Häufigkeitsanalyse aus Kapitel 9****: Wenn ein einzelnes Klartextzeichen den ganzen Block verändert, gibt es keine Zeichenhäufigkeiten mehr, die man zählen könnte.*

Das Lawinenkriterium

Ändert man ein Bit der Eingabe, so soll sich im Mittel die Hälfte der Ausgabebits ändern.

Warum genau die Hälfte

Das ist das Verhalten einer zufälligen Abbildung. Jedes Ausgabebit kippt unabhängig mit Wahrscheinlichkeit $\frac{1}{2}$.

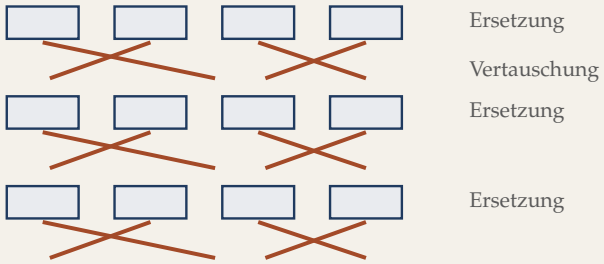
	Wert	
Blocklänge	128	
Erwartete Änderung	64	
Standardabweichung	5,66	$\sqrt{128/4}$
$\Pr[54 \ldots 74]$	0,937	

Ändern sich deutlich weniger oder deutlich mehr als 64 Bit, so verhält sich die Chiffre nicht wie eine zufällige Abbildung — und das ist angreifbar. ***Das Prüfkriterium lautet nicht "möglichst viel Änderung", sondern "genau so viel wie bei Zufall".*** *Eine Chiffre, die alle Bits kippt, wäre ebenso auffällig wie eine, die keines kippt.*

Der Aufbau in Runden

Verwirrung und Verwischung erreicht man durch Wiederholung einfacher Bausteine.

Baustein	Wirkung	Umfang
Ersetzung	Verwirrung	wenige Bits
Vertauschung	Verwischung	ganzer Block
Schlüsseladdition	bindet den Schlüssel	ganzer Block



mehrere Runden

*Nach wenigen Runden ist jedes Ausgabebit von jedem Eingabebit abhängig — das nennt man **vollständige Verwischung**. Die tatsächliche Rundenzahl liegt deutlich darüber: Der Advanced Encryption Standard erreicht vollständige Verwischung nach zwei Runden und benutzt zehn bis vierzehn. **Die überzähligen Runden sind der Sicherheitsabstand**, und der ist es, der ein Verfahren jahrzehntelang trägt.*

10.3 Betriebsarten

Eine Blockchiffre allein genügt nicht

Sie verschlüsselt einen Block fester Länge — etwa 128 Bit. Nachrichten sind länger.

Art	Vorschrift	Eigenschaft
ECB	$C_i = E_K(M_i)$	unbrauchbar
CBC	$C_i = E_K(M_i \oplus C_{i-1})$	braucht Startwert
CTR	$C_i = M_i \oplus E_K(N \Vert i)$	Stromchiffre

Warum ECB unbrauchbar ist

Gleiche Klartextblöcke ergeben gleiche Geheimtextblöcke.

Die Folge

Der Geheimtext verrät, welche Blöcke übereinstimmen — also die gesamte Wiederholungsstruktur der Nachricht.

Bei einem Bild bleiben die Umrisse sichtbar: Flächen gleicher Farbe werden zu Flächen gleicher Geheimtextblöcke. Das bekannteste Anschauungsbeispiel — ein verschlüsseltes Pinguinbild, dessen Umriss erkennbar bleibt — ist seit Jahren in jedem Lehrbuch.

In der Sprache von Kapitel 4

$I(M;C) > 0$**, und zwar erheblich.** ECB verletzt die Grundforderung, ohne dass man irgendetwas brechen müsste.

Bei Befunddaten

Eine Datenbank mit einem Eintrag je Patient, blockweise verschlüsselt: Alle Patienten mit derselben Diagnose haben denselben Geheimtextblock. Man kennt die Diagnose nicht — aber man kann die Patienten gruppieren und die Gruppengrößen mit der bekannten Häufigkeitsverteilung aus Kapitel 1 abgleichen. ***Damit ist die häufigste Gruppe zugeordnet, und die zweithäufigste auch.*** *Es ist die Häufigkeitsanalyse aus Kapitel 9, auf Blöcke übertragen.*

Die Abhilfe: Zufall hinzufügen

CBC	Ein zufälliger Startwert wird dem ersten Block zugemischt; jeder weitere Block erhält den vorangegangenen Geheimtext.
CTR	Ein Zähler wird verschlüsselt und liefert einen Schlüsselstrom; die Blockchiffre wird nie auf den Klartext angewandt.

In beiden Fällen liefern gleiche Klartextblöcke verschiedene Geheimtextblöcke. Dieselbe Nachricht zweimal verschlüsselt ergibt zwei völlig verschiedene Geheimtexte.

Der Vergleich

	ECB	CBC	CTR
Parallel	ja	nein	ja
Wahlfreier Zugriff	ja	teilweise	ja
Auffüllen nötig	ja	ja	nein
Sicher	nein	ja	ja

CTR verwandelt die Blockchiffre in eine Stromchiffre — und damit in etwas, das dem Einmalschlüssel aus Kapitel 9 formal gleicht. ***Der Unterschied ist, dass der Schlüsselstrom nicht zufällig, sondern nur nicht unterscheidbar von zufällig ist.*** *Damit erbt CTR alle Eigenschaften des Einmalschlüssels — einschließlich der unangenehmen.*

10.4 Der Bruchfall

Der Zählerwert darf sich nie wiederholen

Wird bei CTR derselbe Zählerwert zweimal mit demselben Schlüssel verwendet, so entsteht derselbe Schlüsselstrom:

$$C_1 \oplus C_2 = M_1 \oplus M_2$$

Das ist exakt der Venona-Fehler aus Kapitel 9 — nur dass er hier nicht durch doppelt gedrucktes Papier entsteht, sondern durch einen Programmfehler.

Häufige Ursachen: ein Zähler, der nach einem Neustart wieder bei null beginnt; ein zufällig gewählter Startwert, der zu kurz ist; ein auf mehrere Geräte kopierter Schlüssel ohne abgestimmte Zählerbereiche. ***Die Mathematik ist einwandfrei; die Umsetzung ist die Schwachstelle*** *— und das ist die durchgehende Erfahrung dieses Fachs.*

Die Geburtstagsschranke

Bei einer Blocklänge von n Bit treten nach etwa $2^{n/2}$ Blöcken Wiederholungen auf — rein aus Zufall.

Chiffre	n	Blöcke	Datenmenge
3DES	64	2^{32}	**34 GB**
AES	128	2^{64}	295 Exabyte

Bei 64 Bit Blocklänge genügen 34 Gigabyte, um eine Kollision wahrscheinlich zu machen.

Bei CBC verrät eine Kollision $C_i = C_j$ unmittelbar $M_i \oplus M_j$. Genau darauf beruht ein 2016 veröffentlichter Angriff auf Verbindungen, die noch 3DES verwendeten. ***Das Verfahren war nicht gebrochen — die Blocklänge war zu kurz.*** *Bei einer Dauerverbindung sind 34 Gigabyte binnen Stunden erreicht.*

Die Lehre

Schlüssellänge und Blocklänge sind verschiedene Größen. 3DES hat 112 Bit Schlüssel und ist dennoch begrenzt — durch die 64 Bit Blocklänge.

Und drei weitere Fallen

Keine Echtheit	Auch CBC und CTR sind formbar. Verschlüsselung allein schützt nicht vor gezielter Veränderung.
Seitenkanäle	Laufzeit, Stromverbrauch und Zwischenspeicherverhalten können den Schlüssel verraten, obwohl die Mathematik stimmt.
Auffüllen	Die Art, wie unvollständige Blöcke ergänzt werden, hat wiederholt zu Angriffen geführt.

Die zweite Zeile ist die unangenehmste, weil sie außerhalb des mathematischen Modells liegt. Ein Verfahren, dessen Rechenzeit vom Schlüssel abhängt, verrät ihn — und die frühen Umsetzungen des Advanced Encryption Standard taten genau das, weil die Ersetzungstabelle im Zwischenspeicher schlüsselabhängig durchlaufen wurde. ***Das Modell dieses Kapitels kennt nur Eingabe und Ausgabe; die Wirklichkeit hat mehr Kanäle.***

10.5 Übungsaufgaben

Aufgabe 10.1 — Der Lawineneffekt

Eine Chiffre mit 64 Bit Blocklänge wird geprüft: Bei Änderung eines Eingabebits ändern sich 18 Ausgabebits. Ist das auffällig?

Lösung

Schritt 1 — Die Erwartung

Bei einer zufälligen Abbildung kippt jedes Bit unabhängig mit $\frac{1}{2}$:

$$\mathbb{E} = 64 \cdot 0{,}5 = 32, \qquad \sigma = \sqrt{64 \cdot 0{,}25} = 4$$

Schritt 2 — Der Abstand

$$\frac{18 - 32}{4} = -3{,}5 \text{ Standardabweichungen}$$

Schritt 3 — Die Wahrscheinlichkeit

Nach der Normalverteilungsnäherung (Band 12):

$$\Pr[X \leq 18] \approx \Pr[Z \leq -3{,}5] = 2{,}3 \cdot 10^{-4}$$

Ein solches Ergebnis tritt bei einer guten Chiffre etwa einmal unter viertausend Versuchen auf — das ist auffällig.

Schritt 4 — Die Einschränkung

Prüft man alle 64 Eingabebits, so hat man 64 Versuche. Die Wahrscheinlichkeit, dass *mindestens einer* so weit abweicht:

$$1 - (1 - 2{,}3 \cdot 10^{-4})^{64} = 1{,}5\,\%$$

Das ist das Problem des mehrfachen Testens aus Band 17. ***Ein einzelner auffälliger Wert unter vielen Prüfungen ist noch kein Befund*** *— man müsste ihn an weiteren Eingaben bestätigen.*

Schritt 5 — Wann es ein Befund wäre

Träte die Abweichung bei *allen* Eingabebits auf, so wäre das systematisch:

$$(2{,}3 \cdot 10^{-4})^{64} \approx 10^{-234}$$

Dann läge kein Zufall vor, sondern eine Struktur — und Strukturen sind der Ansatzpunkt jedes Angriffs. ***Die Prüfung des Lawinenkriteriums ist ein statistischer Test wie jeder andere****, mit denselben Fallstricken.*

Aufgabe 10.2 — Betriebsarten

Eine Befunddatenbank enthält 50 000 Einträge mit je einem Diagnosecode. Die Häufigkeiten sind die aus Kapitel 1. Welche Auskunft gibt ein ECB-verschlüsselter Auszug?

Lösung

Schritt 1 — Was sichtbar wird

Jeder Diagnosecode ergibt stets denselben Geheimtextblock. Der Angreifer sieht acht verschiedene Blöcke mit ihren Häufigkeiten.

Schritt 2 — Die erwarteten Anzahlen

Gruppe	Anteil	erwartet	σ
A, *B*	0,2500	12 500	97
C, *D*	0,1250	6250	74
E–*H*	0,0625	3125	54

Zur Standardabweichung: $\sqrt{50\,000 \cdot 0{,}25 \cdot 0{,}75} = 96{,}8$.

Schritt 3 — Die Zuordnung

Die drei Häufigkeitsstufen sind durch je etwa sechzig Standardabweichungen getrennt.

Die Zuordnung der Stufen ist praktisch sicher. Innerhalb einer Stufe — etwa zwischen *A* und *B* — gibt die Häufigkeit nichts her.

Schritt 4 — Was der Angreifer erfährt

Auskunft	erhalten?	
Stufe je Eintrag	ja	drei Klassen
Genaue Gruppe	teilweise	bei C/D zweideutig
Gleichheit zweier Einträge	ja	vollständig

Schritt 5 — Der Informationsgehalt

Der Angreifer erfährt die Stufe. Die verbleibende Ungewissheit:

Stufe	Anteil	Restentropie
$\{A, B\}$	0,50	1 Bit
$\{C, D\}$	0,25	1 Bit
$\{E, \ldots, H\}$	0,25	2 Bit

$$H(M \mid C) = 0{,}5 \cdot 1 + 0{,}25 \cdot 1 + 0{,}25 \cdot 2 = 1{,}25 \text{ Bit}$$

$$I(M;C) = H(M) - H(M \mid C) = 2{,}75 - 1{,}25 = \mathbf{1{,}50} \text{ Bit}$$

Mehr als die Hälfte der Information ist durchgesickert — ohne dass die Chiffre gebrochen wurde.

Schritt 6 — Die Abhilfe

Bei CBC oder CTR mit wechselndem Startwert ist $I(M;C) = 0$ im Rahmen der rechnerischen Ununterscheidbarkeit.

> *Für eine durchsuchbare Datenbank ist das allerdings unbequem: Man kann dann nicht mehr nach dem Geheimtext suchen. Verfahren, die beides leisten — Suchbarkeit und Geheimhaltung —, geben notwendig etwas preis; die Frage ist nur, wie viel.* ***Das Spannungsfeld zwischen Nutzbarkeit und Geheimhaltung lässt sich verschieben, nicht auflösen.***

Aufgabe 10.3 — Zwei Schlüssel sind nicht doppelt so gut

Zeigen Sie, dass eine zweifache Anwendung einer Chiffre mit k-Bit-Schlüssel nicht die Sicherheit von $2k$ Bit erreicht.

Lösung

Schritt 1 — Das Verfahren

$$C = E_{K_2}\big(E_{K_1}(M)\big)$$

Der Gesamtschlüssel hat $2k$ Bit, der Raum umfasst 2^{2k} Möglichkeiten.

Schritt 2 — Der Angriff

Der Angreifer kennt ein Paar (M, C). Er nutzt

$$E_{K_1}(M) = D_{K_2}(C).$$

1	Berechne $E_K(M)$ für alle 2^k Schlüssel und speichere die Ergebnisse.
2	Berechne $D_K(C)$ für alle 2^k Schlüssel.
3	Suche Übereinstimmungen. Jede liefert einen Kandidaten (K_1, K_2).

Schritt 3 — Der Aufwand

$$2^k + 2^k = 2^{k+1} \text{ Verschlüsselungen}$$

statt 2^{2k}.

k	**erhofft**	**tatsächlich**	**Speicher**
56	2^{112}	2^{57}	2^{56} Einträge
128	2^{256}	2^{129}	2^{128}

Die zweifache Anwendung bringt genau ein Bit zusätzliche Sicherheit — nicht k.

Schritt 4 — Der Vorbehalt

Der Angriff braucht 2^k Speicherplätze. Bei $k = 56$ sind das $7{,}2 \cdot 10^{16}$ Einträge zu je 8 Byte — rund 576 Petabyte.

Das ist nicht praktikabel, aber es ist der Punkt: ***Ein Verfahren, dessen Sicherheit allein am Speicherbedarf eines Angriffs hängt, ist nicht solide entworfen.*** *Es gibt zudem Varianten, die Speicher gegen Rechenzeit tauschen und dabei deutlich unter 2^{2k} bleiben.*

Schritt 5 — Die Folgerung

Deshalb wurde dreifache statt zweifacher Anwendung genormt:

$$C = E_{K_3}\big(D_{K_2}(E_{K_1}(M))\big)$$

	Schlüssel	**Sicherheit**
einfach	56	2^{56}
zweifach	112	2^{57}
dreifach	168	$\approx 2^{112}$

Auch die dreifache Anwendung erreicht nicht 2^{168}, sondern nur etwa 2^{112} — derselbe Angriff wirkt eine Stufe höher. ***Die mittlere Entschlüsselung statt Verschlüsselung ist kein Sicherheitsmerkmal****, sondern erlaubt es, mit $K_1 = K_2 = K_3$ die einfache Chiffre nachzubilden und so ältere Geräte weiterzuverwenden.*

Zwei Normen und ein Wettbewerb

Horst Feistel (1915–1990), aus Deutschland in die Vereinigten Staaten emigriert, entwickelte bei IBM in den 1970er Jahren die Struktur, die seinen Namen trägt.

> *Ihr Kunstgriff: Man teilt den Block in zwei Hälften und verändert in jeder Runde nur eine davon. Dadurch ist die Umkehrung stets möglich — unabhängig davon, wie kompliziert die verwendete Funktion ist. Man kann also eine beliebig verwickelte Funktion einbauen, ohne sich um ihre Umkehrbarkeit zu sorgen.*

Der Data Encryption Standard

1977 als Norm verabschiedet, mit 56 Bit Schlüssel.

> *IBM hatte ursprünglich 64 Bit vorgeschlagen; die Kürzung auf 56 geschah auf Betreiben der NSA und war von Anfang an umstritten. 1998 baute die Electronic Frontier Foundation für rund 250 000 Dollar eine Maschine, die einen Schlüssel in gut zwei Tagen fand — und beendete damit die Debatte.*

Die andere Seite

Zugleich hatte die NSA die Ersetzungstabellen verändert. Das erregte Verdacht.

> *1990 fanden **Eli Biham** und **Adi Shamir** die **differentielle Kryptanalyse**. Es zeigte sich, dass die veränderten Tabellen gerade dagegen gehärtet waren — IBM und die NSA hatten das Verfahren also fünfzehn Jahre vor seiner öffentlichen Entdeckung gekannt und stillschweigend abgewehrt. **Der Verdacht war berechtigt und die Änderung war eine Verbesserung** — beides zugleich.*

Der Wettbewerb

1997 schrieb das amerikanische Normungsinstitut einen offenen Wettbewerb aus. Fünfzehn Vorschläge wurden eingereicht, öffentlich analysiert und über drei Jahre auf zwei Konferenzen diskutiert.

> *2000 gewann Rijndael der Belgier **Joan Daemen** und **Vincent Rijmen**. Das Verfahren verzichtet auf die Feistel-Struktur und beruht auf Rechnung in einem endlichen Körper — Band 6, Teil V. **Der offene Wettbewerb gilt heute als Vorbild**: Er hat mehr Vertrauen geschaffen als jede Behördenentscheidung es gekonnt hätte, und dasselbe Verfahren wurde später für Hashfunktionen wiederholt.*

Wo Blockchiffren heute stehen

Stand	Der Advanced Encryption Standard ist seit über zwanzig Jahren ungebrochen; die besten bekannten Angriffe sparen wenige Bit.
Verbundene Betriebsarten	Verschlüsselung und Beglaubigung in einem Durchgang — heute der Normalfall.
Leichtgewichtig	Chiffren für Geräte mit wenigen Kilobyte Speicher.

Zur ersten Zeile

Der beste bekannte Angriff auf die Vollrundenfassung mit 128 Bit senkt den Aufwand von 2^{128} auf etwa 2^{126}.

> *Das ist praktisch bedeutungslos — 2^{126} ist so unerreichbar wie 2^{128}. Bemerkenswert ist etwas anderes:* ***In über zwanzig Jahren intensiver öffentlicher Analyse wurde nichts Wesentliches gefunden.*** *Für ein Verfahren ohne Sicherheitsbeweis ist das die einzige verfügbare Evidenz — und sie ist schwächer, als man sich wünschte.*

Zur zweiten Zeile

Nach dem Bruchfall dieses Kapitels ist Verschlüsselung ohne Beglaubigung gefährlich.

> *Die Erfahrung hat gezeigt, dass Entwickler beides nur selten richtig kombinieren — die Reihenfolge ist entscheidend, und die falsche hat wiederholt zu Angriffen geführt.* ***Die Lösung bestand darin, die Wahl abzuschaffen****: Moderne Betriebsarten leisten beides und lassen sich gar nicht erst falsch zusammensetzen. Kapitel 11 behandelt die Beglaubigung.*

Was Sie jetzt können

Rechnerisch	Information ist da, aber unerreichbar
Zwei Grundsätze	Verwirrung und Verwischung
Lawine	genau die Hälfte, nicht mehr
Betriebsarten	ECB verrät die Struktur
Zwei Schranken	Schlüssellänge und Blocklänge

Im nächsten Kapitel geht es um die Eigenschaft, die alle bisherigen Verfahren nicht hatten: nachzuweisen, dass eine Nachricht unverändert und vom richtigen Absender ist.

Kapitel 11

Hashfunktionen und Unversehrtheit

11.1 Die fehlende Eigenschaft

Was Kapitel 9 und 10 offen gelassen haben

Beide Bruchfälle nannten dieselbe Lücke:

Kapitel 9	Der Einmalschlüssel ist perfekt geheim und vollständig formbar.
Kapitel 10	Auch CBC und CTR schützen nicht vor gezielter Veränderung.

Geheimhaltung und Unversehrtheit sind verschiedene Eigenschaften. Keine folgt aus der anderen.

Der Leitfall

Ein Arztbrief wird übertragen. Drei Fragen sind zu trennen:

Frage	Eigenschaft	Mittel
Liest jemand mit?	Geheimhaltung	Kapitel 10
Ist er unverändert?	Unversehrtheit	dieses Kapitel
Ist er echt?	Herkunft	dieses Kapitel

In der Praxis ist die zweite Frage oft die wichtigere. Ein mitgelesener Befund ist ein Datenschutzvorfall; ein verfälschter Befund ist ein Behandlungsfehler. ***Verschlüsselung ohne Beglaubigung löst die falsche Hälfte des Problems.***

11.2 Drei Anforderungen

Definition 11.1

Eine **Hashfunktion** bildet Eingaben beliebiger Länge auf Werte fester Länge n ab. Sie heißt **kryptographisch**, wenn drei Aufgaben schwer sind:

Aufgabe	Gegeben — gesucht	Aufwand
Urbild	y — ein x mit $H(x) = y$	2^n
Zweites Urbild	x — ein $x' \neq x$ mit gleichem Wert	2^n
Kollision	nichts — irgendein Paar	$\mathbf{2^{n/2}}$

Warum die dritte Aufgabe leichter ist

Bei den ersten beiden ist ein Ziel vorgegeben; bei der dritten darf der Angreifer sich beides aussuchen.

Diese Freiheit ist erheblich mehr wert, als man vermutet — sie halbiert den Exponenten. Der Grund ist das Geburtstagsproblem, und dessen Rechnung ist der Kern dieses Abschnitts.

Satz 11.2 — die Geburtstagsschranke

Zieht man k Werte gleichverteilt aus N Möglichkeiten, so gilt

$$\Pr[\text{keine Kollision}] = \prod_{i=0}^{k-1}\left(1 - \frac{i}{N}\right) \;\approx\; e^{-k^2/(2N)}.$$

Die Wahrscheinlichkeit einer Kollision erreicht $\frac{1}{2}$ bei

$$k \;\approx\; 1{,}177\,\sqrt{N}.$$

Beweis der Näherung

Für kleine x gilt $1 - x \approx e^{-x}$, also

$$\prod_{i=0}^{k-1}\left(1 - \frac{i}{N}\right) \;\approx\; \exp\left(-\sum_{i=0}^{k-1}\frac{i}{N}\right) = \exp\left(-\frac{k(k-1)}{2N}\right) \;\approx\; e^{-k^2/(2N)}.$$

Auflösen

$$e^{-k^2/(2N)} = \tfrac{1}{2} \quad\Longrightarrow\quad \frac{k^2}{2N} = \ln 2 \quad\Longrightarrow\quad k = \sqrt{2\ln 2}\cdot\sqrt{N} = 1{,}177\sqrt{N}$$

■

Die Probe am klassischen Beispiel

$N = 365$ Tage:

$$1{,}177 \cdot \sqrt{365} = 1{,}177 \cdot 19{,}105 = 22{,}5$$

k	**exakt**	
10	0,1169	
20	0,4114	
22	0,4757	
23	**0,5073**	Umschlag
50	0,9704	

Dreiundzwanzig Personen genügen für eine Chance über fünfzig Prozent. Die Näherung sagt 22,5.

Die Folgerung für Hashfunktionen

Mit $N = 2^n$:

$$k \approx 1{,}177 \cdot 2^{n/2}$$

Funktion	n	**Urbild**	**Kollision**
MD5	128	$3{,}4 \cdot 10^{38}$	$1{,}8 \cdot 10^{19}$
SHA-1	160	$1{,}5 \cdot 10^{48}$	$1{,}2 \cdot 10^{24}$
SHA-256	256	$1{,}2 \cdot 10^{77}$	$3{,}4 \cdot 10^{38}$

Wer Kollisionsresistenz von 128 Bit will, braucht einen Hashwert von 256 Bit. Das ist der Grund für die heute üblichen Längen.

Was tatsächlich geschah

	erwartet	**tatsächlich**	**Jahr**
MD5	2^{64}	$\approx 2^{18}$	2004
SHA-1	2^{80}	$\approx 2^{63}$	2017

Bei MD5 ist eine Kollision heute in Sekunden zu berechnen. Nicht die Geburtstagsschranke wurde erreicht — die Funktion selbst hat Struktur.

Der Unterschied zwischen 2^{64} und 2^{18} beträgt vierzehn Größenordnungen. ***Die Geburtstagsschranke ist eine obere Grenze für die Sicherheit, keine untere*** *— sie sagt, dass es nicht besser geht als $2^{n/2}$, nicht dass es so gut ist.*

Die praktische Folge

Mit einer MD5-Kollision lassen sich zwei Dokumente bauen, die denselben Hashwert haben — etwa ein harmloses und ein schädliches Programm, oder zwei Zertifikate mit verschiedenen Inhaltsangaben.

2008 wurde auf diesem Weg ein gefälschtes Zertifikat für eine Zertifizierungsstelle erzeugt. 2012 nutzte die Schadsoftware Flame eine bis dahin unbekannte MD5-Kollision, um sich als legitimes Aktualisierungspaket auszugeben. ***Zwischen dem ersten Nachweis der Schwäche und dem tatsächlichen Angriff lagen acht Jahre*** *— und in dieser Zeit war MD5 weiterhin verbreitet im Einsatz.*

11.3 Beglaubigung

Ein Hashwert allein genügt nicht

Wird eine Nachricht zusammen mit ihrem Hashwert übertragen, so kann ein Angreifer beides ersetzen.

Man braucht eine Größe, die nur berechnen kann, wer den Schlüssel kennt.

Der Beglaubigungscode

$$t = \mathrm{MAC}_K(M)$$

Der Empfänger rechnet nach und vergleicht.

Leistet	Unversehrtheit und Herkunft — die Nachricht stammt von jemandem mit dem Schlüssel.
Leistet nicht	Nichtabstreitbarkeit. Beide Seiten kennen den Schlüssel, also könnte jede die Nachricht erzeugt haben.

Die zweite Zeile ist wesentlich: Ein Beglaubigungscode taugt nicht als Beweis vor Dritten. Für einen Arztbrief, der später als Beleg dienen soll, braucht man eine Signatur — und dafür braucht man zwei verschiedene Schlüssel. Das ist Teil V.

Die naheliegende Konstruktion ist falsch

Der Versuch $t = H(K\|M)$ scheitert bei allen Hashfunktionen, die blockweise fortschreiten.

Die Längenerweiterung

Solche Funktionen verarbeiten die Nachricht Block für Block und führen dabei einen Zwischenzustand mit. Der ausgegebene Hashwert *ist* dieser Zustand.

Wer $H(K\|M)$ kennt, kann daraus $H(K\|M\|\text{Auffüllung}\|M')$ berechnen — ohne K zu kennen.

Man setzt den Zustand auf den bekannten Hashwert und rechnet weiter. Der Angreifer kann also an eine beglaubigte Nachricht etwas anhängen und den passenden Beglaubigungscode mitliefern. ***Das ist kein Angriff auf die Hashfunktion, sondern auf ihre Verwendung*** *— die Funktion tut genau das, wofür sie gebaut wurde.*

Die Abhilfe

$$\mathrm{HMAC}_K(M) = H\big((K \oplus \mathrm{opad}) \,\|\, H((K \oplus \mathrm{ipad}) \,\|\, M)\big)$$

Die zweifache Anwendung mit zwei verschiedenen Schlüsselableitungen beseitigt das Problem: Der äußere Aufruf verdeckt den inneren Zustand. Die Konstruktion ist beweisbar sicher, sofern die zugrundeliegende Kompressionsfunktion es ist — einer der wenigen Fälle in diesem Band, in dem ein Sicherheitsbeweis vorliegt, wenn auch relativ zu einer Annahme.

Und die neuere Bauweise

Hashfunktionen nach dem Schwammprinzip geben nur einen Teil ihres Zustands aus.

Bei ihnen tritt die Längenerweiterung nicht auf, und $H(K\|M)$ ist eine zulässige Konstruktion. ***Eine Bauweise kann einen ganzen Fehlertyp unmöglich machen*** *— das ist wirksamer, als vor ihm zu warnen.*

11.4 Zwei Anwendungen

Passwörter

Man speichert nicht das Passwort, sondern seinen Hashwert.

Warum das allein nicht genügt

Zu schnell	Eine gute Hashfunktion ist schnell — und damit auch das Durchprobieren.
Gleiche Werte	Zwei Benutzer mit gleichem Passwort haben denselben Eintrag.
Vorberechnung	Man kann Tabellen häufiger Passwörter im Voraus anlegen.

Die Zahlen

Acht Zeichen aus 94 möglichen ergeben

$$94^8 = 6{,}1 \cdot 10^{15} = 2^{52{,}4} \text{ Möglichkeiten.}$$

Rate	Dauer	
10^{10} je Sekunde	7 Tage	schnelle Funktion
10^{4} je Sekunde	**19 000 Jahre**	absichtlich langsam

Eine absichtlich verlangsamte Funktion verwandelt sieben Tage in neunzehntausend Jahre.

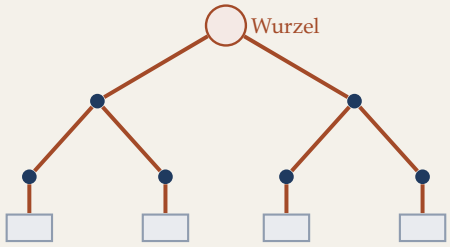
Das Salz

Man hängt jedem Passwort einen zufälligen Wert an und speichert ihn im Klartext mit.

Damit haben gleiche Passwörter verschiedene Einträge, und vorberechnete Tabellen sind wertlos — man müsste für jeden Salzwert eine eigene anlegen. Bei 128 Bit Salz sind das $3{,}4 \cdot 10^{38}$ Tabellen. ***Das Salz muss nicht geheim sein; es muss nur verschieden sein.***

Hashbäume

Um die Unversehrtheit einer großen Datenmenge nachzuweisen, ordnet man die Hashwerte baumförmig an.



Datenblöcke

Was das leistet

Um zu belegen, dass ein bestimmter Block zum Ganzen gehört, genügen die Hashwerte entlang des Weges zur Wurzel.

Blöcke	Nachweis
1000	10 Hashwerte
10^{6}	20 Hashwerte
10^{9}	30 Hashwerte

Bei einer Milliarde Blöcken genügen dreißig Hashwerte — knapp ein Kilobyte. ***Die Nachweislänge wächst logarithmisch****, und darauf beruhen Versionsverwaltungen, verteilte Dateisysteme und die Blockketten der Kryptowährungen.*

11.5 Der Bruchfall

Was Hashfunktionen nicht leisten

Keine Geheimhaltung	Bei kleinem Wertebereich lässt sich das Urbild durch Ausprobieren finden. Ein Hashwert einer Patientennummer schützt sie nicht.
Keine Beweise	Kein praktisch verwendetes Verfahren hat einen Sicherheitsbeweis. Man vertraut auf gescheiterte Angriffsversuche.
Vergleich in gleicher Zeit	Ein Vergleich, der beim ersten Unterschied abbricht, verrät über die Laufzeit, wie viele Stellen stimmten.

Zur ersten Zeile

Eine Patientennummer aus acht Ziffern hat 10^8 mögliche Werte.

Das sind in Sekundenbruchteilen durchprobiert. Der Hashwert ist dann kein Schutz, sondern eine umkehrbare Abbildung.

Dieser Fehler ist verbreitet: Man hält für anonymisiert, was nur gehasht ist. ***Eine Hashfunktion verbirgt nur, was genug Entropie hat*** *— und die Entropie einer Patientennummer beträgt knapp 27 Bit. Wer anonymisieren will, braucht einen geheimen Schlüssel im Spiel, also einen Beglaubigungscode statt einer Hashfunktion.*

Zur dritten Zeile

Vergleicht man den erwarteten mit dem empfangenen Beglaubigungscode Byte für Byte und bricht beim ersten Unterschied ab, so dauert der Vergleich umso länger, je mehr Anfangsbytes stimmen. Ein Angreifer kann den Code dadurch Byte für Byte erraten — statt 2^{128} *Versuchen braucht er* $16 \cdot 256$. ***Ein korrektes Verfahren, falsch verglichen, ist kein Verfahren.***

11.6 Übungsaufgaben

Aufgabe 11.1 — Die Geburtstagsschranke anwenden

Ein System vergibt zufällige Kennungen von 64 Bit.

(a)	Nach wie vielen Kennungen ist eine Doppelvergabe wahrscheinlicher als nicht?
(b)	Wie groß ist die Wahrscheinlichkeit bei einer Milliarde Kennungen?
(c)	Wie lang müssten die Kennungen sein, damit bei 10^{12} Vergaben die Wahrscheinlichkeit unter 10^{-9} bleibt?

Lösung

(a)

$$k \approx 1{,}177 \cdot 2^{32} = 1{,}177 \cdot 4{,}29 \cdot 10^{9} = 5{,}06 \cdot 10^{9}$$

Rund fünf Milliarden.

(b)

$$\Pr \approx 1 - e^{-k^2/(2N)} = 1 - \exp\left(-\frac{(10^9)^2}{2 \cdot 1{,}845 \cdot 10^{19}}\right)$$
$$= 1 - \exp(-0{,}0271) = 0{,}0267$$

Etwa 2,7 Prozent — bei einer Milliarde Kennungen aus 64 Bit.

Das ist mehr, als die meisten erwarten. Eine Milliarde ist gegenüber $1{,}8 \cdot 10^{19}$ verschwindend — und doch liegt die Kollisionswahrscheinlichkeit im Prozentbereich. Die Quadrierung im Exponenten ist der Grund.

(c)

Für kleine Wahrscheinlichkeiten gilt

$$\Pr \approx \frac{k^2}{2N} \quad \Longrightarrow \quad N \geq \frac{k^2}{2\Pr}$$

$$N \geq \frac{(10^{12})^2}{2 \cdot 10^{-9}} = \frac{10^{24}}{2 \cdot 10^{-9}} = 5 \cdot 10^{32}$$

$$n \geq \operatorname{ld}(5 \cdot 10^{32}) = 108{,}6$$

Mindestens 109 Bit — in der Praxis wählt man 128.

Die Merkregel

Für eine Kollisionswahrscheinlichkeit unter 2^{-t} bei 2^m Vergaben braucht man etwa $2m + t$ Bit. Hier: $2 \cdot 40 + 30 = 110$. ***✓Die Faustregel „doppelt so viele Bit wie Vergaben, plus Sicherheitsabstand" deckt alle Fälle ab.***

Aufgabe 11.2 — Die Längenerweiterung

Ein System beglaubigt Befehle mit $t = H(K\|M)$. Der Angreifer kennt

$$M = \texttt{"loesche=nein"}, \qquad t = H(K\|M).$$

Was kann er erreichen, ohne K zu kennen?

Lösung

Schritt 1 — Was der Angreifer weiß

Größe	bekannt?	
M	ja	abgehört
t	ja	abgehört
K	nein	
$\|K\|$	meist ja	Systemangabe

Schritt 2 — Der Angriff

Die Hashfunktion verarbeitet Blöcke und führt einen Zustand mit; t ist der Endzustand.

1	Setze den internen Zustand auf t.
2	Verarbeite den Anhang $M' = \texttt{"\&loesche=ja"}$.
3	Gib den neuen Zustand als t' aus.

Schritt 3 — Das Ergebnis

$$t' = H\big(K\|M\|\text{Auffüllung}\|M'\big)$$

Der Angreifer hat einen gültigen Beglaubigungscode für eine Nachricht erzeugt, die er sich ausgesucht hat.

Schritt 4 — Was der Empfänger sieht

Nachricht	`loesche=nein`, Füllbytes, `&loesche=ja`
Code	gültig

Ob die Füllbytes stören, hängt vom Empfänger ab. Viele Auswerteverfahren überlesen unbekannte Zeichen oder werten bei doppelten Angaben die letzte aus — und dann steht dort `ja`*. **Die Schwäche der Hashfunktion und die Nachlässigkeit des Auswerters wirken zusammen**, und beide für sich wären harmloser.*

Schritt 5 — Drei Abhilfen

HMAC	Zweifache Anwendung; der äußere Aufruf verdeckt den inneren Zustand.
Schwamm-Funktion	Gibt nur einen Teil des Zustands aus; die Fortsetzung ist unmöglich.
Schlüssel hinten	$H(M\|\|K)$ vermeidet die Längenerweiterung — ist aber gegen Kollisionen in H anfällig.

Die dritte Zeile zeigt, warum man solche Konstruktionen nicht selbst entwerfen sollte: Jede naheliegende Variante hat eine eigene Schwäche. ***HMAC ist nicht deshalb Standard, weil es elegant wäre, sondern weil es bewiesen ist*** *— und weil die Alternativen einzeln geprüft und verworfen wurden.*

Aufgabe 11.3 — Passwörter

Eine Klinik speichert 5000 Passwortwerte. Vergleichen Sie drei Verfahren gegen einen Angreifer, der die Datei erbeutet hat und 10^{10} Hashwerte je Sekunde berechnen kann.

Lösung

Schritt 1 — Die Annahmen

Passwörter aus acht Zeichen von 94 möglichen:

$$94^8 = 6{,}1 \cdot 10^{15}$$

Schritt 2 — Schnelle Hashfunktion ohne Salz

Der Angreifer berechnet einmal alle Hashwerte und vergleicht mit *allen* 5000 Einträgen zugleich.

$$\frac{6{,}1 \cdot 10^{15}}{10^{10}} = 6{,}1 \cdot 10^5 \text{ Sekunden} = 7{,}1 \text{ Tage}$$

Sieben Tage für *alle* fünftausend Passwörter. Der Aufwand hängt nicht von ihrer Zahl ab.

Schritt 3 — Schnelle Hashfunktion mit Salz

Jeder Eintrag hat ein eigenes Salz; der Angreifer muss jedes Passwort einzeln angreifen.

$$5000 \cdot 7{,}1 \text{ Tage} = 35\,500 \text{ Tage} = 97 \text{ Jahre}$$

Das Salz verwandelt einen Angriff auf alle in fünftausend Einzelangriffe.

Auf ein bestimmtes Passwort dauert es weiterhin sieben Tage. Das Salz schützt also die Menge, nicht den Einzelnen — und genau deshalb braucht es zusätzlich die dritte Maßnahme.

Schritt 4 — Langsame Funktion mit Salz

Bei 10^4 Berechnungen je Sekunde:

$$\frac{6{,}1 \cdot 10^{15}}{10^4} = 6{,}1 \cdot 10^{11} \text{ Sekunden} = 19\,400 \text{ Jahre}$$

Neunzehntausend Jahre für ein einziges Passwort.

Schritt 5 — Die Übersicht

Verfahren	**alle** 5000	**ein einzelnes**
schnell, ohne Salz	7 Tage	7 Tage
schnell, mit Salz	97 Jahre	7 Tage
langsam, mit Salz	—	**19 400 Jahre**

Schritt 6 — Der entscheidende Vorbehalt

Die Rechnung unterstellt, dass die Passwörter gleichverteilt aus 94^8 gewählt sind.

Tatsächlich haben von Menschen gewählte Passwörter eine Entropie von etwa 20 **bis** 30 **Bit — nicht** 52**.**

Bei 25 *Bit sind es* $3{,}4 \cdot 10^7$ *Möglichkeiten; selbst bei* 10^4 *Versuchen je Sekunde ist das in einer Stunde durchprobiert.* ***Die Entropie des Passworts ist die eigentliche Schranke*** *— alle Maßnahmen dieses Abschnitts vergrößern nur den Aufwand je Versuch, nicht die Zahl der Möglichkeiten. Das ist genau die Aussage von Satz 9.3 in anderer Gestalt: Ohne genug Entropie hilft kein Verfahren.*

Zwei Funktionen, zwei Jahrzehnte

Ronald Rivest entwarf 1991 die Funktion MD5 als Nachfolgerin von MD4, gegen die bereits Angriffe bekannt waren.

MD5 wurde binnen weniger Jahre allgegenwärtig — in Zertifikaten, Signaturen, Dateiprüfsummen, Passwortspeichern. 1996 fand ***Hans Dobbertin*** *eine Kollision der inneren Kompressionsfunktion und riet öffentlich von weiterer Verwendung ab. Es geschah wenig.*

Der Bruch

2004 stellte **Wang Xiaoyun** auf einer Konferenz vollständige Kollisionen vor — berechnet in etwa einer Stunde.

Die Arbeit kam überraschend und traf zugleich MD4, MD5, RIPEMD und HAVAL. Wangs Verfahren beruhte auf einer sorgfältigen Analyse der Differenzenfortpflanzung, die im Westen so nicht verfolgt worden war. ***Heute dauert eine MD5-Kollision Sekundenbruchteile****, und die Funktion gilt seit zwanzig Jahren als gebrochen — wird aber weiterhin in Altsystemen angetroffen.*

SHA-1

1995 als Norm verabschiedet, mit 160 Bit. Ab 2005 zeigten Wang und andere theoretische Angriffe unter 2^{80}.

2017 gelang einer Arbeitsgruppe bei Google die erste vollständige Kollision — zwei PDF-Dateien mit gleichem Hashwert und verschiedenem Inhalt. Der Aufwand betrug etwa 2^{63} Rechenschritte, umgerechnet einige zehntausend Jahre auf einem einzelnen Rechenkern. ***Zwischen der ersten Warnung und dem praktischen Nachweis lagen zwölf Jahre*** *— und dazwischen die zähe Umstellung ganzer Infrastrukturen.*

Der Wettbewerb

2007 schrieb das amerikanische Normungsinstitut einen offenen Wettbewerb aus — nach dem Vorbild aus Kapitel 10.

2012 gewann Keccak von ***Guido Bertoni***, ***Joan Daemen*** *— demselben wie bei Rijndael —,* ***Michaël Peeters*** *und* ***Gilles Van Assche****. Die Schwammbauweise unterscheidet sich grundlegend von der bisherigen und macht die Längenerweiterung strukturell unmöglich.* ***Der Wettbewerb wurde begonnen, bevor SHA-2 gebrochen war*** *— und das ist die eigentliche Lehre: Man baut den Nachfolger, solange noch Zeit ist.*

Hashfunktionen heute

Stand	SHA-2 und SHA-3 gelten als sicher; die besten Angriffe erreichen nur stark verkürzte Rundenzahlen.
Passwortfunktionen	Verfahren, die absichtlich viel Speicher brauchen — gegen Spezialhardware.
Nachweisbarkeit	Hashbäume als Grundlage für Belege, die sich nicht nachträglich ändern lassen.

Zur zweiten Zeile

Spezialhardware kann Hashwerte millionenfach schneller berechnen als Standardrechner — aber Speicher lässt sich nicht ebenso vervielfachen.

Deshalb sind moderne Passwortfunktionen so gebaut, dass sie einige hundert Megabyte Arbeitsspeicher benötigen. Das verteuert Spezialhardware erheblich und gleicht den Vorteil des Angreifers aus. ***Man verlagert den Wettbewerb von einer Größe, bei der der Angreifer im Vorteil ist, auf eine, bei der er es nicht ist*** *— eine Denkweise, die auch außerhalb der Kryptographie nützlich wäre.*

Und die Quantenfrage

Grovers Verfahren halbiert den Exponenten bei der Urbildsuche: aus 2^n wird $2^{n/2}$.

Für Kollisionen ist der Gewinn geringer und nach heutigem Stand praktisch bedeutungslos. ***Hashfunktionen sind die am wenigsten bedrohte Bausteinfamilie****: Eine Verdopplung der Ausgabelänge genügt als Vorsorge. Für die Verfahren aus Teil V sieht das völlig anders aus — Kapitel 15.*

Was Sie jetzt können

Definition 11.1	drei Anforderungen, zwei Aufwände
Satz 11.2	$k \approx 1{,}177\sqrt{N}$
Längenerweiterung	warum $H(K\|M)$ falsch ist
Salz und Langsamkeit	sieben Tage gegen 19 000 Jahre
Hashbäume	Nachweis in $\operatorname{ld} n$ Werten

Damit endet Teil IV. Alle bisherigen Verfahren setzen einen gemeinsamen Schlüssel voraus. Ab Kapitel 12 fragen wir, wie zwei Fremde einen solchen vereinbaren können — über eine abgehörte Leitung.

Teil V

Öffentliche Schlüssel

Kapitel 12

Schlüsseltausch über offene Leitung

12.1 Das Problem

Was alle bisherigen Verfahren voraussetzen

Kapitel 9	Sender und Empfänger teilen einen Einmalschlüssel.
Kapitel 10	Sie teilen einen Blockchiffrenschlüssel.
Kapitel 11	Sie teilen einen Beglaubigungsschlüssel.

Woher kommt dieser gemeinsame Schlüssel?

Das Ausmaß des Problems

Bei n Teilnehmern, die paarweise vertraulich kommunizieren wollen, braucht man

$$\binom{n}{2} = \frac{n(n-1)}{2} \text{ Schlüssel.}$$

Teilnehmer	Schlüssel	
10	45	Praxisnetz
1000	499 500	Klinikverbund
10^6	$5 \cdot 10^{11}$	aussichtslos

Und jeder einzelne müsste persönlich oder per Kurier übergeben werden. ***Bis 1976 galt das als grundsätzliche Grenze der Kryptographie*** *— man könne ohne vorherigen sicheren Kanal keinen Schlüssel vereinbaren. Der Gedanke, dass es anders geht, kam erst spät und wirkte zunächst unglaubwürdig.*

12.2 Rechnen mit Resten

Das Nötige in Kürze

Für eine Primzahl p rechnet man mit den Resten $1, 2, \ldots, p-1$ bei Division durch p.

Multiplikation	$a \cdot b \bmod p$ bleibt im Bereich.
Umkehrbarkeit	Zu jedem $a \neq 0$ gibt es genau ein a^{-1} mit $a\,a^{-1} \equiv 1$.
Kleiner Satz von Fermat	$a^{p-1} \equiv 1$ für alle $a \neq 0$.

Die Primitivwurzel

Ein Element g heißt **Primitivwurzel**, wenn seine Potenzen alle Reste durchlaufen:

$$\{g^1, g^2, \ldots, g^{p-1}\} = \{1, 2, \ldots, p-1\}$$

Beispiel: $p = 23$, $g = 5$.

k	1	2	3	4	5	6	7
5^k	5	2	10	4	20	**8**	17
k	8	9	10	11	$\cdots$	21	22
5^k	16	11	9	22	$\cdots$	14	1

Alle 22 Werte sind verschieden — 5 ist eine Primitivwurzel modulo 23.

> *Dass es solche Elemente gibt, ist ein Satz der Zahlentheorie: Die multiplikative Gruppe modulo einer Primzahl ist zyklisch. Der Beweis steht in Band 8, Teil III.* ***Für dieses Kapitel genügt die Tatsache****, und sie lässt sich an jedem Beispiel nachprüfen.*

Potenzieren ist schnell

Die Berechnung von $g^a \bmod p$ erfordert nicht a Multiplikationen, sondern nur etwa $2 \operatorname{ld} a$.

Quadrieren und Multiplizieren

Man liest den Exponenten binär von links und rechnet fortlaufend:

Bit 0	quadrieren
Bit 1	quadrieren, dann mit g multiplizieren

Beispiel: $5^{15} \bmod 23$ mit $15 = 1111_2$:

Bit	Rechnung	Ergebnis
1	$1^2 \cdot 5$	5
1	$5^2 \cdot 5 = 125$	10
1	$10^2 \cdot 5 = 500$	17
1	$17^2 \cdot 5 = 1445$	**19**

Probe: $125 = 5 \cdot 23 + 10$ ✓; $500 = 21 \cdot 23 + 17$ ✓; $1445 = 62 \cdot 23 + 19$ ✓

Vier Schritte statt fünfzehn. Bei einem Exponenten von 2048 Bit sind es rund 3000 statt 10^{616}.

Genau auf diesem Gefälle beruht das ganze Kapitel: ***Potenzieren ist leicht, der umgekehrte Weg vermutlich schwer.*** *Eine Funktion mit dieser Eigenschaft nennt man eine Einwegfunktion.*

12.3 Das Verfahren

Diffie-Hellman-Schlüsseltausch

Öffentlich bekannt sind p und eine Primitivwurzel g.

Schritt	Alice	Bob
1	wählt a geheim	wählt b geheim
2	sendet $A = g^a$	sendet $B = g^b$
3	rechnet B^a	rechnet A^b

Warum beide dasselbe erhalten

$$B^a = (g^b)^a = g^{ab} = (g^a)^b = A^b$$

Das Potenzgesetz ist der ganze Trick. Die Reihenfolge der Exponenten spielt keine Rolle.

Ein vollständiges Beispiel

$p = 23$, $g = 5$, $a = 6$, $b = 15$.

	Alice	Bob
geheim	$a = 6$	$b = 15$
gesendet	$A = 5^6 = 8$	$B = 5^{15} = 19$
gerechnet	$19^6 = \mathbf{2}$	$8^{15} = \mathbf{2}$

Probe: $g^{ab} = 5^{90} \bmod 23$. Wegen $5^{22} \equiv 1$ und $90 = 4 \cdot 22 + 2$ ist $5^{90} \equiv 5^2 = 25 \equiv 2$. ✓

Was der Mitleser sieht

$$p = 23, \quad g = 5, \quad A = 8, \quad B = 19$$

Er kennt g^a und g^b und will g^{ab}. Dafür müsste er a oder b bestimmen.

Definition 12.1 — das diskrete Logarithmusproblem

Gegeben p, g und y, bestimme x mit

$$g^x \equiv y \pmod{p}.$$

Der Stand

Für große Primzahlen ist kein Verfahren bekannt, das dieses Problem in vertretbarer Zeit löst. Bewiesen ist die Schwierigkeit nicht.

Es ist dieselbe Lage wie bei P *gegen* NP *in Band 19: Man weiß nicht, ob es schwer ist, sondern nur, dass seit fünfzig Jahren niemand einen schnellen Weg gefunden hat.* ***Die dritte Warnung aus dem Vorwort steht hier zum ersten Mal in voller Schärfe.***

Ein feiner Unterschied

Streng genommen muss der Angreifer nicht den Logarithmus bestimmen — er braucht nur g^{ab}.

Logarithmus-problem	Aus g^a bestimme a.
Diffie-Hellman-Problem	Aus g^a und g^b bestimme g^{ab}.

Das zweite ist höchstens so schwer wie das erste — wer Logarithmen ziehen kann, löst auch das zweite. Ob es genauso schwer ist, ist offen. Für die meisten Gruppen vermutet man es; bewiesen ist es nur unter Zusatzannahmen. ***Die Sicherheit des Verfahrens beruht auf einer Annahme, die schwächer ist als die naheliegende*** *— und das wird oft übersehen.*

12.4 Wie schwer ist es wirklich

Drei Angriffsverfahren

Verfahren	Aufwand	Speicher
Durchprobieren	p	$O(1)$
Riesen- und Zwergenschritte	$\sqrt{p}$	$\sqrt{p}$
Pollards Rho	$\sqrt{p}$	$O(1)$
Indexrechnung	unter-exponentiell	groß

Riesen- und Zwergenschritte

Man schreibt $x = i\,m + j$ mit $m = \lceil \sqrt{p-1} \rceil$ und $0 \le j < m$:

$$g^x = y \quad \Longleftrightarrow \quad g^j = y \cdot (g^{-m})^i$$

1	Tabelliere g^j für $j = 0, \ldots, m-1$ (die Zwergenschritte).
2	Berechne $y \cdot (g^{-m})^i$ für $i = 0, 1, \ldots$ (die Riesenschritte).
3	Bei einem Treffer ist $x = i\,m + j$.

Beispiel: $p = 23$, $g = 5$, $y = 8$. Mit $m = 5$:

j	0	1	2	3
5^j	1	**5**	2	10

Riesenschritt $i = 1$: $8 \cdot (5^{-5}) \bmod 23 = 5$ — Treffer bei $j = 1$.

$$x = 1 \cdot 5 + 1 = 6 \quad \checkmark$$

Statt 22 Versuchen genügen $5 + 2 = 7$. Bei $p \approx 2^{2048}$ wären es 2^{1024} — immer noch aussichtslos. ***Die Wurzel halbiert den Exponenten, und das genügt bei großen Zahlen nicht.***

Die Indexrechnung ändert alles

Für Restklassen modulo einer Primzahl gibt es ein Verfahren, dessen Aufwand langsamer wächst als jede Potenz — aber schneller als jedes Polynom.

$$L_p\left[\tfrac{1}{3},\, 1{,}923\right] = \exp\left(1{,}923\,(\ln p)^{1/3}(\ln \ln p)^{2/3}\right)$$

Größe von p	Aufwand	
2^{512}	$2^{63{,}9}$	gebrochen
2^{1024}	$2^{86{,}8}$	grenzwertig
2^{2048}	$2^{116{,}9}$	sicher
2^{3072}	$2^{138{,}7}$	sicher

Ein Schlüssel von 1024 Bit bietet nur etwa 87 Bit Sicherheit — nicht 512, wie die Wurzelschranke nahelegte.

*Das ist der Grund für die scheinbar übertriebenen Schlüssellängen: Man braucht 3072 Bit, um die Sicherheit eines 128-Bit-Blockchiffrenschlüssels zu erreichen. **Die Zahlen der beiden Welten sind nicht vergleichbar**, und das führt regelmäßig zu Fehleinschätzungen.*

Warum elliptische Kurven kürzer sind

Die Indexrechnung beruht auf der Zerlegung in Primfaktoren — ein Begriff, den es in der Gruppe einer elliptischen Kurve nicht gibt.

Sicherheit	DH/RSA	elliptisch	Faktor
80 Bit	1024	160	6,4
112 Bit	2048	224	9,1
128 Bit	3072	256	12,0
256 Bit	15 360	512	**30,0**

*Bei elliptischen Kurven ist die Wurzelschranke tatsächlich das Beste, was man kennt — also $2^{n/2}$ bei n Bit. **Der Vorteil wächst mit der geforderten Sicherheit**, und bei hohen Anforderungen ist er dreißigfach. Kapitel 14 behandelt diese Gruppen.*

12.5 Der Bruchfall

Der Mann in der Mitte

Das Verfahren sichert Vertraulichkeit — nicht Herkunft.



Der Ablauf

1	Mallory fängt $A = g^a$ ab und sendet Bob stattdessen g^m.
2	Ebenso in die Gegenrichtung.
3	Alice teilt nun einen Schlüssel mit Mallory, Bob einen anderen.
4	Mallory entschlüsselt, liest, verschlüsselt neu und leitet weiter.

Beide glauben, miteinander zu sprechen, und bemerken nichts.

Der Angriff braucht keinerlei Rechenkraft — er umgeht die Mathematik vollständig. ***Der Schlüsseltausch löst genau eine Hälfte des Problems****, und die andere Hälfte erfordert, dass Alice weiß, welcher öffentliche Wert zu Bob gehört. Kapitel 14 behandelt Signaturen, Kapitel 15 die Frage, wie man einen öffentlichen Schlüssel überhaupt jemandem zuordnet.*

Und drei weitere Fallen

Kleine Untergruppen	Ist $p - 1$ in kleine Faktoren zerlegbar, so lässt sich das Problem in Teilprobleme zerlegen. Man wählt $p = 2q + 1$ mit q prim.
Feste Parameter	Wird dieselbe Primzahl von Millionen Systemen genutzt, so lohnt sich eine einmalige Vorberechnung.
Schwache Exponenten	Ein vorhersehbarer Zufallsgenerator macht a ratbar — die Mathematik ist dann gleichgültig.

Zur zweiten Zeile

Die Indexrechnung zerfällt in eine teure Vorberechnung, die nur von p abhängt, und eine billige Endphase je Logarithmus.

Eine 2015 veröffentlichte Untersuchung zeigte, dass eine einzige 1024-Bit-Primzahl von einem erheblichen Teil aller damaligen Verbindungen verwendet wurde. ***Wer die Vorberechnung einmal leistet, bricht danach jede einzelne Verbindung binnen Minuten.*** *Der Aufwand lag in der Größenordnung dessen, was ein Staat aufbringen kann — und die Verfasser hielten es für wahrscheinlich, dass es geschehen war.*

12.6 Übungsaufgaben

Aufgabe 12.1 — Ein Schlüsseltausch von Hand

Mit $p = 23$ und $g = 5$ wählt Alice $a = 4$ und Bob $b = 3$. Führen Sie den Tausch durch und prüfen Sie das Ergebnis.

Lösung

Schritt 1 — Alices Wert

$$A = 5^4 = 625$$
$$625 = 27 \cdot 23 + 4 \quad \Longrightarrow \quad A = 4$$

Schritt 2 — Bobs Wert

$$B = 5^3 = 125 = 5 \cdot 23 + 10 \quad \Longrightarrow \quad B = 10$$

Schritt 3 — Alice rechnet

$$B^a = 10^4 = 10\,000$$

Schrittweise: $10^2 = 100 = 4 \cdot 23 + 8$, also 8. Dann $8^2 = 64 = 2 \cdot 23 + 18$, also **18**.

Schritt 4 — Bob rechnet

$$A^b = 4^3 = 64 = 2 \cdot 23 + 18 \quad \Longrightarrow \quad \mathbf{18}$$

Beide erhalten 18. ✓

Schritt 5 — Die Probe

$$g^{ab} = 5^{12} \bmod 23$$

Aus der Tabelle in Abschnitt 12.2: $5^{12} = 18$. ✓

Schritt 6 — Was der Mitleser tun müsste

Er kennt 5, 23, 4 und 10. Um a zu finden, probiert er:

k	1	2	3	4
5^k	5	2	10	**4**

Nach vier Versuchen hat er $a = 4$.

> *Bei $p = 23$ ist das Verfahren wertlos — es gibt nur 22 Möglichkeiten.* ***Die Sicherheit entsteht ausschließlich aus der Größe****, und praktisch verwendet man Primzahlen mit 2048 oder mehr Bit. Das Beispiel zeigt die Rechnung, nicht die Sicherheit.*

Aufgabe 12.2 — Riesen- und Zwergenschritte

Bestimmen Sie mit dem Verfahren aus Abschnitt 12.4 den Logarithmus von $y = 17$ zur Basis $g = 5$ modulo 23.

Lösung

Schritt 1 — Die Schrittweite

$$m = \left\lceil \sqrt{22} \right\rceil = \lceil 4{,}69 \rceil = 5$$

Schritt 2 — Die Zwergenschritte

j	0	1	2	3	4
5^j	1	5	2	10	4

Schritt 3 — Der Riesenschritt

$$5^5 = 20, \qquad (5^5)^{-1} = 20^{-1} \bmod 23$$

Inverses bestimmen: $20 \cdot 15 = 300 = 13 \cdot 23 + 1$, also $20^{-1} = 15$.

Schritt 4 — Die Suche

i	**Wert**	**Rechnung**	**Treffer**
0	17	—	nein
1	$17 \cdot 15 = 255$	$255 - 11 \cdot 23 = 2$	$j = 2$

Schritt 5 — Das Ergebnis

$$x = i\,m + j = 1 \cdot 5 + 2 = \mathbf{7}$$

Probe: $5^7 = 5^5 \cdot 5^2 = 20 \cdot 2 = 40 = 23 + 17$, also 17. ✓

Schritt 6 — Der Aufwand

Verfahren	**Schritte**	**Speicher**
Durchprobieren	bis 22	keiner
Riesen/Zwerge	$5 + 2 = 7$	5 Einträge

Bei $p \approx 2^{2048}$ bräuchte das Verfahren 2^{1024} Speicherplätze — also mehr, als es Atome im Weltall gibt. ***Es ist ein Zeit-Speicher-Tausch, und der Speicher ist die härtere Grenze.*** *Pollards Rho-Verfahren erreicht denselben Zeitaufwand mit konstantem Speicher und ist deshalb das praktisch verwendete.*

Aufgabe 12.3 — Schlüssellängen

Ein Klinikverbund plant eine Infrastruktur, die dreißig Jahre halten soll. Welche Schlüssellängen sind zu wählen?

Lösung

Schritt 1 — Das Sicherheitsniveau festlegen

Für dreißig Jahre wählt man mindestens 128 Bit Sicherheit.

Schritt 2 — Die Längen ablesen

Baustein	Länge	
Blockchiffre	128 Bit	Kapitel 10
Hashfunktion	256 Bit	Kapitel 11
Diffie-Hellman	3072 Bit	dieses Kapitel
Elliptische Kurve	256 Bit	Kapitel 14

Schritt 3 — Warum die dritte Zeile so absticht

Die Indexrechnung senkt die Sicherheit von 3072 Bit Schlüssellänge auf etwa 139 Bit Sicherheit.

$$\frac{3072}{128} = 24$$

Man braucht vierundzwanzigmal so viele Bit wie bei einer Blockchiffre.

Schritt 4 — Die Folgen für die Praxis

	DH 3072	**elliptisch** 256
Nachricht	384 Byte	32 Byte
Rechenzeit	hoch	gering
Batteriebedarf	hoch	gering

Für ein Blutzuckermessgerät mit Knopfzelle ist das der entscheidende Unterschied. ***Elliptische Kurven haben sich nicht durchgesetzt, weil sie schöner wären, sondern weil sie in den Speicher passen.***

Schritt 5 — Der Vorbehalt, der alles verändert

Alle Zahlen setzen voraus, dass kein Quantenrechner verfügbar ist.

Baustein	klassisch	mit Quantenrechner
Blockchiffre	128 Bit	64 Bit
Hashfunktion	128 Bit	≈ 85 Bit
Diffie-Hellman	139 Bit	gebrochen
Elliptische Kurve	128 Bit	gebrochen

Die letzten beiden Zeilen sind kategorisch: Shors Verfahren löst das Logarithmusproblem in polynomialer Zeit — längere Schlüssel helfen nicht. ***Für eine Infrastruktur mit dreißig Jahren Lebensdauer ist das die wichtigste Zeile der Tabelle****, und Kapitel 15 behandelt, was an ihre Stelle tritt.*

Zwei Entdeckungen, elf Jahre Abstand

Whitfield Diffie und **Martin Hellman** veröffentlichten 1976 die Arbeit *New Directions in Cryptography*. Sie beginnt mit dem Satz, man stehe an der Schwelle einer Revolution.

Die Arbeit enthält den Schlüsseltausch, den Begriff der Einwegfunktion und — als Idee ohne Umsetzung — das Konzept der digitalen Signatur. ***Ralph Merkle*** *hatte unabhängig ein verwandtes Verfahren entwickelt; Hellman schlug später vor, das Verfahren nach allen dreien zu benennen.*

Die frühere Entdeckung

Malcolm Williamson vom britischen Nachrichtendienst GCHQ fand dasselbe Verfahren 1974 — zwei Jahre früher.

Zuvor hatte ***James Ellis*** *dort 1970 die Grundidee formuliert und* ***Clifford Cocks*** *1973 ein Verfahren gefunden, das dem RSA aus Kapitel 13 entspricht. Alle drei Arbeiten blieben geheim und wurden erst 1997 freigegeben.* ***Ellis starb einen Monat vor der Freigabe****, ohne öffentliche Anerkennung erlebt zu haben.*

Warum die Geheimhaltung folgenlos blieb

Die Briten hielten ihre Entdeckung für eine Kuriosität ohne praktischen Wert — die nötige Rechenleistung schien unerreichbar.

Diffie und Hellman veröffentlichten, und ihre Arbeit löste ein Jahrzehnt intensiver Forschung aus. ***Dieselbe Entdeckung, geheim gehalten, blieb wirkungslos; veröffentlicht, veränderte sie die Welt.*** *Es ist eines der klarsten Beispiele dafür, dass wissenschaftlicher Fortschritt an der Verbreitung hängt und nicht am Fund.*

Der Widerstand

Die amerikanische NSA versuchte in den 1970er Jahren, die Veröffentlichung kryptographischer Forschung zu unterbinden.

Hellman erhielt Hinweise, dass Vorträge über sein Verfahren gegen Ausfuhrbestimmungen für Rüstungsgüter verstoßen könnten. Er ließ die Vorträge von Studenten halten, für die keine Genehmigung nötig war — da sie keine Ausländer unterrichteten, sondern lernten. Die Auseinandersetzung dauerte bis in die 1990er Jahre.

Schlüsseltausch heute

Vorwärts-geheimhaltung	Für jede Verbindung neue Exponenten; ein später erbeuteter Langzeitschlüssel entschlüsselt nichts rückwirkend.
Hybride Verfahren	Klassischer und quantensicherer Tausch kombiniert — sicher, solange einer von beiden hält.
Passwortbasiert	Schlüsseltausch mit einem kurzen gemeinsamen Wort, ohne dass Rateangriffe möglich werden.

Zur ersten Zeile

Verwendet man für jede Sitzung frische Exponenten und löscht sie danach, so nützt ein später kompromittierter Langzeitschlüssel nichts.

> *Das ist wirksam gegen das Aufzeichnen auf Vorrat — die Praxis, Verkehr heute zu speichern und später zu entschlüsseln.* ***Vorwärtsgeheimhaltung ist seit etwa 2013 der Normalfall*** *und einer der wenigen Fälle, in denen sich eine Sicherheitsverbesserung rasch flächendeckend durchgesetzt hat.*

Zur zweiten Zeile

Man führt beide Verfahren aus und leitet den Sitzungsschlüssel aus beiden Ergebnissen ab.

> *Die Begründung ist vorsichtig: Die klassischen Verfahren sind seit fünfzig Jahren geprüft, die quantensicheren erst seit wenigen Jahren. Eine Kombination hält, solange eines von beiden hält.* ***Das ist dieselbe Überlegung wie bei der Kombinationstherapie in Band 18, Kapitel 14*** *— und dieselbe Voraussetzung: Die Verfahren müssen unabhängig sein.*

Was Sie jetzt können

Primitivwurzel	erzeugt alle Reste
Quadrieren	Potenzieren in $2 \operatorname{ld} a$ Schritten
Der Tausch	g^{ab} aus g^a und g^b
Definition 12.1	das Logarithmusproblem
Indexrechnung	3072 Bit für 128 Bit Sicherheit

Im nächsten Kapitel lösen wir ein zweites Problem: nicht einen Schlüssel zu vereinbaren, sondern eine Nachricht an jemanden zu richten, mit dem man nie gesprochen hat.

Kapitel 13

RSA

13.1 Die andere Aufgabe

Was Kapitel 12 nicht leistet

Der Schlüsseltausch verlangt, dass beide Seiten gleichzeitig anwesend sind und miteinander sprechen.

Nicht möglich	Einem Empfänger eine Nachricht senden, der gerade nicht erreichbar ist.
Nicht möglich	Eine Nachricht so unterschreiben, dass jeder die Echtheit prüfen kann.

Gesucht ist ein Schlüsselpaar: einer zum Verschließen, ein anderer zum Öffnen. Der erste darf öffentlich sein.

Der Leitfall

Eine Praxis sendet einen Arztbrief an das Klinikum. Sie hat noch nie mit ihm gesprochen, kennt aber dessen öffentlichen Schlüssel.

> *Diffie und Hellman hatten die Idee 1976 formuliert, ohne ein Verfahren angeben zu können.* ***Ein Jahr später fanden drei Mathematiker am MIT eines*** *— und es beruht auf einer Frage, die zweitausend Jahre alt ist: wie schwer es ist, eine Zahl in ihre Primfaktoren zu zerlegen.*

13.2 Der Satz von Euler

Die Eulersche Funktion

Für eine natürliche Zahl n ist $\varphi(n)$ die Anzahl der zu n teilerfremden Zahlen zwischen 1 und n.

n	$\varphi(n)$	
p prim	$p-1$	alle außer 0
$p \cdot q$	$(p-1)(q-1)$	für $p \neq q$ prim
$143 = 11 \cdot 13$	$10 \cdot 12 = 120$	

Warum $(p-1)(q-1)$

Von den $n = pq$ Zahlen sind genau die Vielfachen von p und die von q nicht teilerfremd:

$$n - q - p + 1 = pq - p - q + 1 = (p-1)(q-1)$$

Die Eins wird addiert, weil die Null in beiden Listen steht. ✓

Satz 13.1 — der Satz von Euler

Ist $\gcd(a, n) = 1$, so gilt

$$a^{\varphi(n)} \equiv 1 \pmod{n}.$$

Der Beweis in Kürze

Die zu n teilerfremden Reste bilden eine Gruppe mit $\varphi(n)$ Elementen. Multipliziert man alle mit a, so entsteht dieselbe Menge in anderer Reihenfolge — denn a ist umkehrbar.
Das Produkt aller Elemente ist damit einerseits P, andererseits $a^{\varphi(n)}P$. Kürzen liefert die Behauptung. ■

> *Der kleine Satz von Fermat aus Kapitel 12 ist der Sonderfall $n = p$. Der vollständige Beweis steht in Band 6, Teil II — er ist der Satz von Lagrange über Gruppenordnungen, auf diese Gruppe angewandt.*

13.3 Das Verfahren

Die Schlüsselerzeugung

1	Wähle zwei große Primzahlen p und q und setze $n = pq$.
2	Berechne $\varphi(n) = (p-1)(q-1)$.
3	Wähle e teilerfremd zu $\varphi(n)$.
4	Bestimme d mit $e\,d \equiv 1 \pmod{\varphi(n)}$.

	Inhalt	Status
Öffentlicher Schlüssel	(n, e)	veröffentlicht
Geheimer Schlüssel	d	geheim
Zu vernichten	$p, q, \varphi(n)$	geheim

Die Operationen

$$c = m^e \bmod n, \qquad m = c^d \bmod n$$

Satz 13.2 — warum es funktioniert

Für alle m mit $\gcd(m, n) = 1$ gilt

$$\left(m^e\right)^d \equiv m \pmod{n}.$$

Beweis

Aus $e\,d \equiv 1 \pmod{\varphi(n)}$ folgt

$$e\,d = 1 + k\,\varphi(n) \quad \text{für ein } k \in \mathbb{N}.$$

Damit:

$$\begin{aligned} m^{ed} &= m^{1+k\varphi(n)} \\ &= m \cdot \left(m^{\varphi(n)}\right)^k \\ &\equiv m \cdot 1^k && \text{(Satz 13.1)} \\ &= m \end{aligned}$$

■

*Der Beweis ist vier Zeilen lang und benutzt nur den Satz von Euler. **Die Aussage gilt tatsächlich für alle** m, auch für die nicht teilerfremden — das erfordert eine zusätzliche Betrachtung über den chinesischen Restsatz. Bei großen Primzahlen ist der Fall ohnehin verschwindend selten: Ein m mit $\gcd(m, n) > 1$ zu finden hieße, n zu faktorisieren.*

Ein vollständiges Beispiel

Größe	Wert	Rechnung
p, q	11, 13	gewählt
n	143	$11 \cdot 13$
$\varphi(n)$	120	$10 \cdot 12$
e	7	teilerfremd zu 120
d	**103**	$7 \cdot 103 = 721$

Probe für d: $721 = 6 \cdot 120 + 1$ ✓

Verschlüsseln von $m = 9$

$$c = 9^7 \bmod 143$$

Quadrieren und Multiplizieren, $7 = 111_2$:

Bit	Rechnung	Ergebnis
1	$1^2 \cdot 9$	9
1	$9^2 \cdot 9 = 729$	14
1	$14^2 \cdot 9 = 1764$	**48**

Proben: $729 = 5 \cdot 143 + 14$ ✓; $1764 = 12 \cdot 143 + 48$ ✓

Entschlüsseln

$$48^{103} \bmod 143 = 9 \quad ✓$$

Diese Rechnung ist von Hand mühsam — zehn Quadrierungen. Der Empfänger kennt allerdings p und q und kann über den chinesischen Restsatz modulo 11 und modulo 13 getrennt rechnen; das ist etwa viermal schneller. ***Der geheime Schlüssel enthält mehr als nur*** *d, und praktische Umsetzungen speichern p, q und Hilfsgrößen mit.*

13.4 Wie sicher ist es

Wovon die Sicherheit abhängt

Faktorisierung	Kennt man p und q, so kennt man $\varphi(n)$ und damit d.
$\varphi(n)$ **bestimmen**	Gleichwertig zur Faktorisierung: Aus n und $\varphi(n)$ folgen p und q über eine quadratische Gleichung.
d **bestimmen**	Ebenfalls gleichwertig — daraus lässt sich n faktorisieren.
RSA-Problem	Aus c die e-te Wurzel ziehen. Höchstens so schwer wie Faktorisieren.

Die letzte Zeile hat denselben Vorbehalt wie beim Diffie-Hellman-Problem in Kapitel 12: Ob das Wurzelziehen genauso schwer ist wie das Faktorisieren, ist offen. ***Man weiß nur, dass es nicht schwerer ist.***

Der Stand der Faktorisierung

Zahl	Bits	Jahr	Aufwand
RSA-768	768	2009	$\approx$ 2000 Kernjahre
RSA-250	829	2020	$\approx$ 2700 Kernjahre
2048 Bit	2048	—	unerreicht

n	Aufwand	
2^{768}	$2^{76,5}$	gebrochen
2^{1024}	$2^{86,8}$	grenzwertig
2^{2048}	$2^{116,9}$	sicher
2^{3072}	$2^{138,7}$	sicher

Es sind dieselben Zahlen wie beim diskreten Logarithmus — das Zahlkörpersieb löst beide Probleme mit demselben Aufwandsgesetz. ***Die Schlüssellängenempfehlungen für RSA und Diffie-Hellman stimmen deshalb überein****, und ein Fortschritt bei einem Problem betrifft meist auch das andere.*

13.5 Der Bruchfall

Das reine Verfahren ist unsicher

Die Vorschrift $c = m^e$ — ohne weitere Maßnahmen — hat mehrere schwere Mängel.

Bestimmt	Dieselbe Nachricht ergibt stets denselben Geheimtext. Bei wenigen möglichen Nachrichten rät man sie durch Ausprobieren.
Formbar	$c_1 \cdot c_2$ entschlüsselt zu $m_1 \cdot m_2$.
Kleine Werte	Ist $m^e < n$, so entfällt die Modulrechnung — man zieht einfach die e-te Wurzel.

Zur ersten Zeile

Ein Arztbrief mit dem Feld "Befund: positiv" oder "negativ" hat zwei mögliche Werte. Der Angreifer verschlüsselt beide selbst — er kennt ja den öffentlichen Schlüssel — und vergleicht.

> **Ein Verfahren mit öffentlichem Schlüssel, das deterministisch ist, kann nicht sicher sein.** Der Angreifer kann jede Vermutung selbst prüfen.

Zur zweiten Zeile, nachgerechnet

Mit $n = 143$, $e = 7$:

m	c	
5	47	
7	6	
35	**139**	$47 \cdot 6 = 282 \equiv 139$

Probe: $282 = 143 + 139$ ✓, und $35^7 \bmod 143 = 139$ ✓

> *Der Angreifer kann also aus dem Geheimtext einer Zahl den Geheimtext ihres Vielfachen erzeugen — ohne den Klartext zu kennen. Das ist dieselbe Formbarkeit wie beim Einmalschlüssel in Kapitel 9, nur multiplikativ statt additiv.*

Die Abhilfe

Man füllt die Nachricht vor dem Potenzieren mit Zufall auf, nach einem genau festgelegten Verfahren.

> *Damit ist die Verschlüsselung nicht mehr bestimmt — dieselbe Nachricht ergibt jedes Mal einen anderen Geheimtext — und die Struktur des Auffüllens zerstört die Formbarkeit.* ***Die Auffüllung ist kein technisches Beiwerk, sondern der Teil, der das Verfahren sicher macht.*** *Frühere Auffüllverfahren waren angreifbar, und der bekannteste dieser Angriffe nutzte aus, dass der Empfänger fehlerhafte Auffüllungen meldete.*

Und vier Umsetzungsfallen

Gemeinsame Faktoren	Werden Primzahlen mit schlechtem Zufall erzeugt, so teilen sich verschiedene Schlüssel einen Faktor — und beide fallen.
Zu nahe Primzahlen	Liegen p und q dicht beieinander, so findet man sie durch Suche um $\sqrt{n}$.
Laufzeit	Die Entschlüsselungsdauer hängt von d ab und verrät es.
Fehlerangriff	Ein einziger Rechenfehler bei der Rechnung über den chinesischen Restsatz verrät p.

Zur ersten Zeile

Eine Untersuchung von 2012 prüfte Millionen öffentlicher Schlüssel aus dem Internet und berechnete paarweise größte gemeinsame Teiler.

> *Bei einigen Zehntausend Schlüsseln wurde man fündig — meist von eingebetteten Geräten, die ihre Schlüssel kurz nach dem Einschalten erzeugten, bevor genug Zufall gesammelt war.* ***Der größte gemeinsame Teiler ist in Millisekunden berechnet****, während die Faktorisierung einer einzelnen Zahl aussichtslos ist. Zwei schlechte Schlüssel brechen einander.*

Zur vierten Zeile

Rechnet der Empfänger getrennt modulo p und modulo q und tritt bei einer der beiden Teilrechnungen ein Fehler auf, so gilt für die fehlerhafte Signatur s':

$$\gcd\left(s'^{\,e} - m,\ n\right) = q$$

> *Ein einziger gekippter Bitwert — durch Spannungsschwankung, Hitze oder gezielte Einstrahlung — gibt den Schlüssel preis. Deshalb prüfen sichere Umsetzungen jede Signatur nach dem Erzeugen.* ***Ein mathematisch einwandfreies Verfahren kann durch einen Hardwarefehler vollständig fallen*** *— und das ist ein Angriffsweg, den kein Sicherheitsbeweis erfasst.*

13.6 Übungsaufgaben

Aufgabe 13.1 — RSA durchrechnen

Mit $p = 5$, $q = 11$ und $e = 3$: Bestimmen Sie d und verschlüsseln Sie $m = 8$.

Lösung

Schritt 1 — Die Kenngrößen

$$n = 55, \qquad \varphi(n) = 4 \cdot 10 = 40$$

Teilerfremdheit prüfen: $\gcd(3, 40) = 1$ ✓

Schritt 2 — d bestimmen

Gesucht ist d mit $3d \equiv 1 \pmod{40}$.
Durchprobieren der Vielfachen: $3 \cdot 27 = 81 = 2 \cdot 40 + 1$ ✓

$$d = 27$$

Schritt 3 — Verschlüsseln

$$c = 8^3 = 512$$
$$512 = 9 \cdot 55 + 17 \quad \Longrightarrow \quad c = \mathbf{17}$$

Schritt 4 — Entschlüsseln

$$17^{27} \bmod 55$$

Schrittweise: $17^2 = 289 = 5 \cdot 55 + 14$, also 14.

$$17^4 = 14^2 = 196 = 3 \cdot 55 + 31 \;\to\; 31$$

$$17^8 = 31^2 = 961 = 17 \cdot 55 + 26 \;\to\; 26$$
$$17^{16} = 26^2 = 676 = 12 \cdot 55 + 16 \;\to\; 16$$

Mit $27 = 16 + 8 + 2 + 1$:

$$17^{27} = 16 \cdot 26 \cdot 14 \cdot 17$$
$$16 \cdot 26 = 416 = 7 \cdot 55 + 31 \;\to\; 31$$
$$31 \cdot 14 = 434 = 7 \cdot 55 + 49 \;\to\; 49$$
$$49 \cdot 17 = 833 = 15 \cdot 55 + 8 \;\to\; \mathbf{8} \quad ✓$$

Schritt 5 — Die Probe über Satz 13.2

$$e\,d = 81 = 2 \cdot 40 + 1$$
$$m^{81} = m \cdot (m^{40})^2 \equiv m \cdot 1 = m$$

> *Zur Anwendbarkeit von Satz 13.1:* $\gcd(8, 55) = 1$ ✓. *Bei $m = 5$ oder $m = 11$ wäre der Satz nicht unmittelbar anwendbar — die Aussage gilt dort trotzdem, wie die erweiterte Betrachtung zeigt.*

Schritt 6 — Warum dieses Beispiel unsicher ist

Mit $n = 55$ gibt es 55 mögliche Nachrichten. Der Angreifer verschlüsselt alle und vergleicht.

> *Und er kann $55 = 5 \cdot 11$ im Kopf faktorisieren.* ***Das Beispiel zeigt die Rechnung; die Sicherheit kommt allein aus der Größe*** *— praktisch verwendet man Primzahlen mit über tausend Bit.*

Aufgabe 13.2 — Die Formbarkeit ausnutzen

Ein Angreifer kennt den öffentlichen Schlüssel (n, e) und einen Geheimtext c, dessen Klartext m er erfahren will. Er darf den Empfänger *einen* anderen Geheimtext entschlüsseln lassen — aber nicht c selbst.

Lösung

Schritt 1 — Der Ansatz

Der Angreifer wählt ein r und bildet

$$c' = c \cdot r^e \bmod n.$$

Schritt 2 — Was der Empfänger zurückgibt

$$(c')^d = (c \cdot r^e)^d = c^d \cdot r^{ed} \equiv m \cdot r \pmod{n}$$

Schritt 3 — Das Ergebnis

Der Angreifer erhält $m \cdot r$ und dividiert:

$$m = (m \cdot r) \cdot r^{-1} \bmod n$$

> **Er kennt den Klartext — und c' sah für den Empfänger völlig unverdächtig aus.**

Schritt 4 — Ein Zahlenbeispiel

$n = 55$, $e = 3$, $c = 17$ (also $m = 8$). Der Angreifer wählt $r = 2$:

$$c' = 17 \cdot 2^3 = 17 \cdot 8 = 136 = 2 \cdot 55 + 26 \;\rightarrow\; 26$$

Der Empfänger entschlüsselt: $26^{27} \bmod 55 = 16$.

$$m = 16 \cdot 2^{-1} \bmod 55$$

Inverses von 2: $2 \cdot 28 = 56 \equiv 1$, also $2^{-1} = 28$.

$$16 \cdot 28 = 448 = 8 \cdot 55 + 8 \;\rightarrow\; \mathbf{8} \quad \checkmark$$

Schritt 5 — Die Deutung

> *Dieser Angriff setzt voraus, dass der Empfänger überhaupt bereit ist, fremde Geheimtexte zu entschlüsseln. Das klingt weltfremd und ist es nicht: Ein Server, der auf fehlerhafte Nachrichten mit einer Fehlermeldung antwortet, gibt bereits genug preis.* ***Jede Antwort auf einen gewählten Geheimtext ist eine Entschlüsselung*** *— und sei sie nur ein Ja oder Nein.*

Schritt 6 — Die Abhilfe

Eine ordentliche Auffüllung macht c' mit überwältigender Wahrscheinlichkeit ungültig.

> *Das Produkt $m \cdot r$ hat keine gültige Auffüllstruktur, und der Empfänger lehnt ab. Damit ist der Angriff abgewehrt — vorausgesetzt, die Ablehnung verrät nicht, warum abgelehnt wurde, und die Antwortzeit ist in allen Fällen gleich.* ***Die Abwehr liegt außerhalb der Mathematik****, und genau dort versagte sie historisch mehrfach.*

Aufgabe 13.3 — Signaturen

Erklären Sie, wie sich RSA zum Unterschreiben verwenden lässt, und warum man nicht die Nachricht selbst signiert.

Lösung

Schritt 1 — Die Vertauschung

Beim Verschlüsseln wendet man e an und der Empfänger d. Beim Signieren ist es umgekehrt:

$$s = m^d \bmod n \qquad \text{(nur der Inhaber kann das)}$$

$$s^e \stackrel{?}{=} m \qquad \text{(jeder kann das prüfen)}$$

Das funktioniert, weil e und d symmetrisch zueinander stehen: $m^{ed} = m^{de}$.

Schritt 2 — Was das leistet

Herkunft	Nur wer d kennt, kann s erzeugen.
Unversehrtheit	Jede Änderung an m macht die Prüfung ungültig.
Nicht-abstreitbarkeit	Anders als beim Beglaubigungscode aus Kapitel 11 kann der Empfänger die Signatur nicht selbst erzeugt haben.

Schritt 3 — Warum man nicht m selbst signiert

Erstens: Länge. Die Nachricht muss kleiner als n sein. Ein Arztbrief ist es nicht.
Zweitens: Fälschbarkeit. Der Angreifer wählt ein beliebiges s und berechnet $m = s^e$.

Er hat eine gültige Signatur — für eine Nachricht, die er sich nicht aussuchen konnte.

Drittens: Formbarkeit. Aus zwei Signaturen s_1, s_2 ergibt sich

$$s_1 \cdot s_2 = (m_1 m_2)^d$$

— eine gültige Signatur für $m_1 m_2$, ohne Kenntnis von d.

Schritt 4 — Die Abhilfe

Man signiert den Hashwert:

$$s = H(m)^d \bmod n$$

Länge	Der Hashwert ist kurz genug.
Fälschbarkeit	Der Angreifer müsste zu s^e ein passendes Urbild finden — das ist Definition 11.1.
Formbarkeit	$H(m_1) \cdot H(m_2)$ ist kein Hashwert einer sinnvollen Nachricht.

Schritt 5 — Die Folge für die Hashfunktion

Findet jemand eine Kollision $H(m_1) = H(m_2)$, so überträgt sich jede Signatur von m_1 auf m_2.

*Deshalb war der Bruch von MD5 in Kapitel 11 folgenschwer: Man konnte zwei Zertifikate mit gleichem Hashwert und verschiedenem Inhalt bauen, eines harmlos signieren lassen und die Signatur auf das andere übertragen. **Die Sicherheit der Signatur ist durch die schwächste der beiden Komponenten begrenzt** — und das war nicht RSA.*

Schritt 6 — Auch hier braucht es Auffüllung

Die naheliegende Form $H(m)^d$ ohne weitere Struktur ist ebenfalls angreifbar.

Der Hashwert ist kurz, n ist lang — der Rest wird aufgefüllt, und die Art des Auffüllens war wiederholt Angriffspunkt. Ein bekannter Fall von 2006 nutzte aus, dass manche Prüfroutinen Zusatzbytes hinter dem Hashwert ignorierten; bei $e = 3$ ließen sich damit Signaturen ohne Kenntnis von d fälschen.

Ein Wochenende im April

Ron Rivest, **Adi Shamir** und **Leonard Adleman** arbeiteten 1977 am MIT an der Frage, ob Diffie und Hellmans Idee eines Verfahrens mit öffentlichem Schlüssel überhaupt umsetzbar sei.

Die Arbeitsteilung war ungewöhnlich: Rivest und Shamir schlugen Verfahren vor, Adleman brach sie. Nach eigener Erinnerung etwa zweiundvierzigmal. Der dreiundvierzigste Vorschlag hielt stand.

Die Nacht der Entdeckung

Rivest kam die Idee in der Nacht zum 3. April 1977, nach einem Abend mit Wein bei einem Pessachfest. Er schrieb die Arbeit noch in derselben Nacht.

Adleman wollte zunächst nicht als Autor genannt werden — er habe nur Vorschläge widerlegt. Rivest bestand darauf. Die Reihenfolge der Namen ergab sich alphabetisch rückwärts, und so heißt das Verfahren RSA statt ARS.

Die Vorwegnahme

Clifford Cocks hatte dasselbe Verfahren 1973 beim britischen GCHQ gefunden — in einer halben Stunde, wie er berichtete.

*Er hielt es für rechnerisch unpraktikabel und schrieb es auf vier Seiten nieder, die bis 1997 geheim blieben. **Cocks hatte zudem keine Signaturen betrachtet** — ihm ging es allein um Verschlüsselung. Der Gedanke, dass dasselbe Verfahren rückwärts eine Unterschrift liefert, fehlt in seiner Arbeit.*

Die Zahlen der Preisaufgabe

1977 veröffentlichte Rivest in einer Zeitschriftenkolumne eine mit 129 Stellen verschlüsselte Nachricht und setzte hundert Dollar aus. Er schätzte den nötigen Aufwand auf $4 \cdot 10^{16}$ Jahre.

*Die Zahl wurde 1994 faktorisiert — von sechshundert Freiwilligen über das Internet, in acht Monaten. Der Klartext lautete "the magic words are squeamish ossifrage". **Rivests Schätzung lag um vierzehn Größenordnungen daneben**, weil er die Entwicklung der Faktorisierungsverfahren nicht vorhersehen konnte. Das ist die deutlichste Warnung vor Sicherheitsprognosen, die dieses Fach kennt.*

RSA heute

Rückgang	Neue Anwendungen wählen überwiegend elliptische Kurven — kürzere Schlüssel, schnellere Signaturen.
Bestand	In Zertifikaten und Altsystemen weiterhin allgegenwärtig.
Quanten	Shors Verfahren faktorisiert in polynomialer Zeit; längere Schlüssel helfen nicht.

Zur ersten Zeile

Bei gleicher Sicherheit ist eine elliptische Signatur etwa zwölfmal kürzer und ihre Erzeugung deutlich schneller.

RSA hat allerdings einen Vorteil, der oft übersehen wird: Die Prüfung ist mit kleinem e sehr schnell — schneller als bei elliptischen Kurven. Wo eine Signatur einmal erzeugt und millionenfach geprüft wird, kann das den Ausschlag geben.

Zur dritten Zeile

Shor veröffentlichte sein Verfahren 1994. Der Aufwand ist polynomial in der Bitlänge.

*Nach heutigen Schätzungen bräuchte man für einen 2048-Bit-Schlüssel einige Millionen fehlerkorrigierte Quantenbits — gegenwärtig sind es einige hundert bis wenige tausend physikalische. **Der Abstand ist groß und schrumpft**, und niemand kann zuverlässig sagen, wie schnell. Kapitel 15 behandelt, was an die Stelle tritt.*

Was Sie jetzt können

Satz 13.1	Euler: $a^{\varphi(n)} \equiv 1$
Satz 13.2	$m^{ed} = m$ in vier Zeilen
Die Sicherheit	höchstens so hart wie Faktorisieren
Der Bruchfall	bestimmt, formbar, kleine Werte
Signaturen	den Hashwert signieren, nie die Nachricht

Im nächsten Kapitel ersetzen wir die Restklassen durch eine Gruppe, in der dieselben Verfahren mit einem Zwölftel der Bits auskommen.

Kapitel 14

Elliptische Kurven und Signaturen

14.1 Warum eine andere Gruppe

Was die Kapitel 12 und 13 gemeinsam haben

Beide Verfahren benutzen die Multiplikation modulo einer Zahl — und beide leiden unter derselben Schwäche.

Die Ursache	Die Indexrechnung und das Zahlkörpersieb beruhen darauf, dass sich Zahlen in Primfaktoren zerlegen lassen.
Die Folge	Der Aufwand wächst nur unterexponentiell — 3072 Bit für 128 Bit Sicherheit.

Gesucht ist eine Gruppe, in der es keine Primfaktorzerlegung gibt — und in der die Wurzelschranke das Beste bleibt.

Die Verfahren aus Kapitel 12 brauchen nämlich gar keine Zahlen. Sie brauchen nur eine Menge mit einer Verknüpfung, in der sich leicht potenzieren und schwer logarithmieren lässt. ***Der Schlüsseltausch ist eine Aussage über Gruppen, nicht über Zahlen*** *— und das eröffnet die Wahl.*

14.2 Die Kurve

Definition 14.1

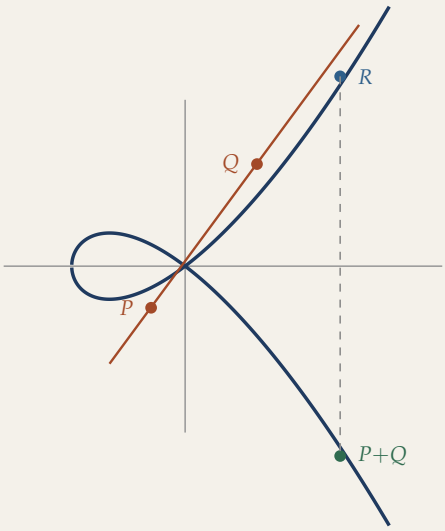
Eine **elliptische Kurve** über einem Körper ist die Menge der Punkte (x, y) mit

$$y^2 = x^3 + a\,x + b$$

zuzüglich eines **Fernpunkts** $\mathcal{O}$, wobei $4a^3 + 27b^2 \neq 0$.

Die Verknüpfung

Man legt eine Gerade durch zwei Punkte. Sie schneidet die Kurve in einem dritten. Dessen Spiegelung an der x-Achse ist die Summe.



Warum die Spiegelung

Ohne sie wäre die Verknüpfung nicht assoziativ. Mit ihr gilt: Drei Punkte auf einer Geraden addieren sich zu $\mathcal{O}$.

> *Dass die so erklärte Verknüpfung tatsächlich eine Gruppe liefert, ist ein Satz — und die Assoziativität ist der unangenehme Teil des Beweises. Elementar geführt ist er eine lange Rechnung; mit den Mitteln der algebraischen Geometrie ist er kurz.* ***Wir nehmen die Gruppeneigenschaft hier als gegeben*** *und prüfen sie an Beispielen nach.*

Die Formeln

Für $P = (x_1, y_1)$ und $Q = (x_2, y_2)$ mit $P \neq -Q$:

$$\lambda = \begin{cases} \dfrac{y_2 - y_1}{x_2 - x_1} & \text{für } P \neq Q \\[2ex] \dfrac{3x_1^2 + a}{2y_1} & \text{für } P = Q \end{cases}$$

$$x_3 = \lambda^2 - x_1 - x_2, \qquad y_3 = \lambda\,(x_1 - x_3) - y_1$$

> *Die zweite Zeile für λ ist die Ableitung der Kurve — die Tangente. Sie ergibt sich durch implizites Differenzieren: $2y\,y' = 3x^2 + a$.* ***Verdoppeln heißt, die Tangente zu legen****, und das ist die geometrische Entsprechung des Quadrierens aus Kapitel 12.*

14.3 Über endlichen Körpern

Dasselbe modulo einer Primzahl

Die Formeln gelten unverändert, wenn man modulo p rechnet. Die Division wird zur Multiplikation mit dem Inversen.

Ein vollständiges Beispiel

$$E:\ y^2 = x^3 + 2x + 2 \quad \text{über} \quad \mathbb{F}_{17}$$

Ist $G = (5,1)$ ein Punkt?

$$5^3 + 2\cdot 5 + 2 = 125 + 10 + 2 = 137 = 8\cdot 17 + 1 \ \to\ 1$$

$$y^2 = 1 \quad \checkmark$$

Verdoppeln

$$\lambda = \frac{3\cdot 25 + 2}{2\cdot 1} = \frac{77}{2}$$

Modulo 17: $77 = 4\cdot 17 + 9 \to 9$; $2^{-1} = 9$ wegen $2\cdot 9 = 18 \equiv 1$.

$$\lambda = 9\cdot 9 = 81 = 4\cdot 17 + 13 \ \to\ 13$$

$$x_3 = 13^2 - 5 - 5 = 169 - 10 = 159 = 9\cdot 17 + 6 \ \to\ \mathbf{6}$$

$$y_3 = 13\,(5-6) - 1 = -14 \equiv \mathbf{3} \pmod{17}$$

$$2G = (6,3)$$

Probe: $6^3 + 12 + 2 = 230 = 13\cdot 17 + 9 \to 9$, und $3^2 = 9$ ✓

Die ganze Gruppe

k	kG	k	kG	k	kG
1	$(5,1)$	8	$(13,7)$	15	$(3,16)$
2	$(6,3)$	9	$(7,6)$	16	$(10,11)$
3	$(10,6)$	10	$(7,11)$	17	$(6,14)$
4	$(3,1)$	11	$(13,10)$	18	$(5,16)$
5	$(9,16)$	12	$(0,11)$	19	$\mathcal{O}$
6	$(16,13)$	13	$(16,4)$		
7	$(0,6)$	14	$(9,1)$		

Die Gruppe hat 19 Elemente, und G erzeugt sie alle. G ist also ein erzeugendes Element wie die Primitivwurzel in Kapitel 12.

Bemerkenswert ist die Symmetrie: $18G = (5,16)$ und $G = (5,1)$ — und $1 + 16 = 17 \equiv 0$. Die Punkte kG und $(19-k)G$ sind Spiegelbilder an der x-Achse, also entgegengesetzt. ***Die Tabelle liest sich von beiden Enden.***

Das Logarithmusproblem hier

Gegeben G und $Q = kG$, bestimme k.

	Restklassen	elliptisch
Durchprobieren	n	n
Pollards Rho	$\sqrt{n}$	$\sqrt{n}$
Indexrechnung	$L_n[1/3]$	nicht bekannt

Die dritte Zeile ist der ganze Vorteil. Bei elliptischen Kurven ist die Wurzelschranke nach heutigem Wissen das Beste — also $2^{n/2}$ bei n Bit.

Die Folge für die Schlüssellängen

Sicherheit	RSA/DH	elliptisch	Faktor
112 Bit	2048	224	9,1
128 Bit	3072	256	12,0
192 Bit	7680	384	20,0
256 Bit	15 360	512	30,0

Der Grund für das Fehlen der Indexrechnung ist begrifflich: Sie sucht Elemente, die sich in kleine Faktoren zerlegen lassen. Auf einer elliptischen Kurve gibt es keinen Begriff von "klein" — die Punkte tragen keine Größenordnung. ***Ein Verfahren scheitert nicht an einer Schwierigkeit, sondern daran, dass sein zentraler Begriff fehlt.***

14.4 Signaturen

Das Verfahren

Öffentlich: die Kurve, G und die Ordnung n. Der Unterzeichner hat d geheim und $Q = dG$ öffentlich.

Signieren	Wähle k zufällig; setze $R = kG$ und $r = x_R \bmod n$. $s = k^{-1}\big(H(m) + r\,d\big) \bmod n$ Die Signatur ist (r, s).
Prüfen	$u_1 = H(m)\,s^{-1}$, $u_2 = r\,s^{-1}$ Prüfe $x\big(u_1 G + u_2 Q\big) \equiv r$

Warum die Prüfung aufgeht

$$\begin{aligned} u_1 G + u_2 Q &= H(m)s^{-1}G + rs^{-1}dG \\ &= s^{-1}\big(H(m) + rd\big)\,G \\ &= s^{-1} \cdot s\,k\,G && \text{(Definition von } s\text{)} \\ &= k\,G = R \end{aligned}$$

Also stimmt die x-Koordinate mit r überein. ✓

Der Prüfer rechnet R aus, ohne k zu kennen — er setzt es aus zwei bekannten Punkten zusammen. ***Das ist der Kunstgriff des Verfahrens****, und er funktioniert, weil die Gruppenoperation kommutiert.*

Der Zufallswert darf sich nie wiederholen

Werden zwei Nachrichten mit demselben k signiert, so gilt

$$s_1 = k^{-1}(h_1 + rd), \qquad s_2 = k^{-1}(h_2 + rd)$$

Die Auflösung

$$s_1 - s_2 = k^{-1}(h_1 - h_2) \quad \Longrightarrow \quad k = \frac{h_1 - h_2}{s_1 - s_2}$$

Und daraus:

$$d = \frac{s_1 k - h_1}{r}$$

Zwei Signaturen mit demselben Zufallswert geben den geheimen Schlüssel vollständig preis.

Man beachte, dass r in beiden Fällen gleich ist — das verrät die Wiederholung sogar öffentlich. ***Der Angreifer braucht nur zwei Signaturen mit gleichem r zu suchen****, und dann zwei Divisionen. Das ist derselbe Fehler wie beim Einmalschlüssel in Kapitel 9 und beim Zähler in Kapitel 10 — zum dritten Mal in diesem Band, in neuer Gestalt.*

Was tatsächlich geschah

2010 wurde der Signaturschlüssel einer verbreiteten Spielkonsole veröffentlicht. Der Hersteller hatte einen festen Wert statt eines zufälligen verwendet.

Es war kein Fehler in der Mathematik, kein zu kurzer Schlüssel und keine Schwäche der Kurve — eine Zeile Programmcode. Die Folge war, dass beliebige Software als vom Hersteller signiert ausgegeben werden konnte. ***Der geheime Schlüssel ließ sich aus zwei öffentlich verfügbaren Signaturen berechnen.***

Die Abhilfe

Man leitet k aus dem geheimen Schlüssel und der Nachricht ab, statt es zu würfeln:

$$k = \mathrm{HMAC}_d(H(m))$$

Damit ist k für jede Nachricht verschieden und für den Angreifer unvorhersehbar — und das Verfahren kommt ohne Zufallsgenerator aus. ***Man ersetzt eine Anforderung an die Umgebung durch eine Rechnung****, und das ist fast immer der sicherere Weg.*

14.5 Der Bruchfall

Die Kurve muss stimmen

Schwache Kurven	Bei bestimmten Kurven lässt sich das Problem auf ein leichteres zurückführen und in polynomialer Zeit lösen.
Kleine Ordnung	Hat die Gruppe kleine Faktoren, so zerfällt das Problem in Teilprobleme.
Punkte prüfen	Liegt ein empfangener Punkt gar nicht auf der Kurve, so kann die Rechnung den Schlüssel verraten.

Zur dritten Zeile

Die Additionsformeln benutzen den Parameter b nicht.

Ein Angreifer kann daher einen Punkt einer *anderen* Kurve senden, deren Gruppe kleine Ordnung hat — und aus der Antwort den Schlüssel modulo dieser Ordnung erschließen.

Nach genügend vielen solchen Anfragen setzt man den Schlüssel über den chinesischen Restsatz zusammen. Die Abhilfe ist eine Zeile: ***Jeden empfangenen Punkt darauf prüfen, ob er die Kurvengleichung erfüllt.*** *Dass diese Zeile fehlte, hat wiederholt zu Angriffen geführt.*

Und die Vertrauensfrage

Die gebräuchlichen Kurven wurden von Normungsgremien festgelegt, teils mit Parametern unklarer Herkunft.

Nach den Enthüllungen von 2013 über einen manipulierten Zufallsgenerator wuchs das Misstrauen. Die Antwort waren Kurven mit ***nachvollziehbar zufälligen*** *Parametern — jede Konstante wird aus einer öffentlichen Rechenvorschrift abgeleitet, so dass kein Spielraum für eine versteckte Hintertür bleibt.* ***Man ersetzt Vertrauen durch Nachprüfbarkeit****, und das ist dieselbe Denkweise wie beim offenen Wettbewerb aus Kapitel 10.*

14.6 Übungsaufgaben

Aufgabe 14.1 — Punkte addieren

Auf $E : y^2 = x^3 + 2x + 2$ über $\mathbb{F}_{17}$ mit $P = (5, 1)$ und $Q = (6, 3)$: Bestimmen Sie $P + Q$.

Lösung

Schritt 1 — Die Steigung

$$\lambda = \frac{3 - 1}{6 - 5} = \frac{2}{1} = 2$$

Schritt 2 — Die neue x-Koordinate

$$x_3 = \lambda^2 - x_1 - x_2 = 4 - 5 - 6 = -7 \equiv 10 \pmod{17}$$

Schritt 3 — Die neue y-Koordinate

$$y_3 = \lambda\,(x_1 - x_3) - y_1 = 2\,(5 - 10) - 1 = -11 \equiv 6 \pmod{17}$$

$$P + Q = (10,\ 6)$$

Schritt 4 — Die Probe

Liegt der Punkt auf der Kurve?

$$10^3 + 2 \cdot 10 + 2 = 1000 + 22 = 1022$$

$$1022 = 60 \cdot 17 + 2 \ \rightarrow\ 2$$

$$6^2 = 36 = 2 \cdot 17 + 2 \ \rightarrow\ 2 \quad \checkmark$$

Schritt 5 — Die zweite Probe

Nach der Tabelle in Abschnitt 14.3 ist $P = G$, $Q = 2G$ und $3G = (10, 6)$.

$$G + 2G = 3G \quad \checkmark$$

Schritt 6 — Ein Sonderfall

Was ist $P + (5, 16)$?
Wegen $1 + 16 = 17 \equiv 0$ sind die beiden Punkte entgegengesetzt:

$$(5, 1) + (5, 16) = \mathcal{O}$$

> *Die Formel versagt hier — der Nenner $x_2 - x_1$ wäre null.* ***Das ist kein Mangel, sondern der Fernpunkt****: Die Gerade durch zwei senkrecht übereinanderliegende Punkte ist senkrecht und schneidet die Kurve kein drittes Mal im Endlichen. Jede Umsetzung muss diesen Fall gesondert behandeln, und das ist eine bekannte Fehlerquelle.*

Aufgabe 14.2 — Schlüsseltausch auf der Kurve

Alice wählt $a = 3$, Bob $b = 10$. Führen Sie den Tausch mit derselben Kurve durch.

Lösung

Schritt 1 — Die öffentlichen Punkte

Aus der Tabelle:

$$A = 3G = (10, 6), \qquad B = 10G = (7, 11)$$

Schritt 2 — Alice rechnet

$$10 \cdot A = 10 \cdot (3G) = 30\,G$$

Wegen $\mathcal{O} = 19G$ gilt $30G = 11G$:

$$30 = 19 + 11 \quad \Longrightarrow \quad 30G = 11G = (13, 10)$$

Schritt 3 — Bob rechnet

$$3 \cdot B = 3 \cdot (10G) = 30\,G = (13, 10) \quad \checkmark$$

Beide erhalten $(13, 10)$**.** Der gemeinsame Schlüssel wird üblicherweise aus der x-Koordinate abgeleitet.

Schritt 4 — Was der Mitleser sieht

Er kennt die Kurve, G, $A = (10, 6)$ und $B = (7, 11)$.
Um a zu finden, müsste er die Tabelle durchgehen — bei 19 Punkten in Sekunden.

Praktisch verwendete Kurven haben Gruppenordnungen um 2^{256}. ***Auch hier gilt: Das Beispiel zeigt die Rechnung, nicht die Sicherheit.***

Schritt 5 — Der Vergleich mit Kapitel 12

	Kapitel 12	**hier**
Menge	Reste mod p	Kurvenpunkte
Verknüpfung	Multiplikation	Punktaddition
Potenzieren	g^a	aG
Schwer	Logarithmus	Logarithmus

Die Verfahren sind identisch; nur die Gruppe ist ausgetauscht. ***Das ist der Ertrag der abstrakten Formulierung****: Wer Diffie-Hellman für Gruppen versteht, versteht es für jede Gruppe — und kann die beste wählen.*

Aufgabe 14.3 — Den Schlüssel aus zwei Signaturen

Ein Unterzeichner hat mit demselben k zwei Nachrichten signiert. Bekannt sind n, r,

s_1, s_2, h_1, h_2. Bestimmen Sie den geheimen Schlüssel.

Lösung

Schritt 1 — Die beiden Gleichungen

$$s_1 = k^{-1}(h_1 + r\,d), \qquad s_2 = k^{-1}(h_2 + r\,d)$$

Schritt 2 — Subtrahieren

$$s_1 - s_2 = k^{-1}\big[(h_1 + rd) - (h_2 + rd)\big] = k^{-1}(h_1 - h_2)$$

Der Term mit d fällt heraus.

Schritt 3 — k bestimmen

$$k = \frac{h_1 - h_2}{s_1 - s_2} \bmod n$$

Schritt 4 — d bestimmen
Aus $s_1 k = h_1 + rd$:

$$d = \frac{s_1 k - h_1}{r} \bmod n$$

Schritt 5 — Ein Zahlenbeispiel
Mit $n = 19$, $r = 13$, $h_1 = 5$, $h_2 = 9$, $s_1 = 7$, $s_2 = 3$:

$$k = \frac{5 - 9}{7 - 3} = \frac{-4}{4} = -1 \equiv 18 \pmod{19}$$

$$d = \frac{7 \cdot 18 - 5}{13} = \frac{126 - 5}{13} = \frac{121}{13} \bmod 19$$

Zähler: $121 = 6 \cdot 19 + 7 \to 7$.
Inverses von 13: $13 \cdot 3 = 39 = 2 \cdot 19 + 1$, also $13^{-1} = 3$.

$$d = 7 \cdot 3 = 21 \equiv \mathbf{2} \pmod{19}$$

Schritt 6 — Die Probe

$$s_1 = k^{-1}(h_1 + rd) = 18^{-1}\,(5 + 13 \cdot 2) = 18^{-1} \cdot 31$$

$31 \equiv 12$; $18 \equiv -1$, *also* $18^{-1} = 18$.

$$s_1 = 18 \cdot 12 = 216 = 11 \cdot 19 + 7 \;\to\; \mathbf{7} \quad \checkmark$$

Schritt 7 — Der Aufwand

Zwei Subtraktionen, zwei Divisionen. Der Angreifer braucht keine Rechenkraft, nur zwei Signaturen mit gleichem r.

Und r steht offen in der Signatur — er muss also nur nach Wiederholungen suchen. Bei einem festen k ist r in allen Signaturen gleich, und der Angriff gelingt beim ersten Paar. ***Ein Verfahren, dessen Sicherheit an einem einzigen Zufallswert hängt, bricht vollständig, wenn dieser Wert versagt*** *— und das unterscheidet die Signatur von der Verschlüsselung, wo eine Wiederholung nur die betroffenen Nachrichten gefährdet.*

Schritt 8 — Sogar Teilinformation genügt

Kennt der Angreifer auch nur wenige Bit von k — etwa weil der Zufallsgenerator leicht verzerrt ist — so lässt sich d aus vielen Signaturen mit Gitterverfahren gewinnen.

Einige hundert Signaturen mit je vier bekannten Bit genügen. Das ist praktisch bedeutsam, weil Seitenkanäle aus Kapitel 10 genau solche Teilinformation liefern. ***Ein fast perfekter Zufallsgenerator ist hier nicht fast sicher, sondern unsicher.***

Zwei Vorschläge im selben Jahr

Neal Koblitz an der Universität Washington und **Victor Miller** bei IBM schlugen 1985 unabhängig voneinander vor, elliptische Kurven für die Kryptographie zu verwenden.

Beide kannten die Kurven aus der Zahlentheorie, wo sie seit dem 19. Jahrhundert untersucht werden — unter anderem im Zusammenhang mit der Fermatschen Vermutung, deren Beweis 1995 wesentlich auf ihnen beruht. ***Ein Gegenstand reiner Grundlagenforschung wurde zur Grundlage der digitalen Sicherheit****, und zwar ohne dass jemand es geplant hätte.*

Die lange Anlaufzeit

Die Verfahren brauchten fünfzehn Jahre bis zur breiten Anwendung.

Gründe waren Patentfragen, die höhere Komplexität der Umsetzung und ein grundsätzliches Misstrauen: Die zugrundeliegende Mathematik galt als schwerer überprüfbar. Erst als die Schlüssellängen für RSA unbequem wurden — insbesondere bei Mobilgeräten — setzte sich der Wechsel durch.

Die Kurve mit dem Zweifel

2013 wurde bekannt, dass ein genormter Zufallsgenerator auf elliptischen Kurven vermutlich eine Hintertür enthielt.

Der Verdacht bestand seit 2007 — zwei Forscher hatten gezeigt, dass die Kenntnis eines bestimmten Zusammenhangs zwischen zwei Konstanten die Vorhersage aller Ausgaben erlaubt. Die Konstanten waren ohne Begründung festgelegt worden. ***Der Generator wurde 2014 zurückgezogen****; die Kurven selbst waren nie betroffen, aber das Vertrauen war beschädigt.*

Die Antwort

Daniel Bernstein und andere entwarfen ab 2005 Kurven, deren Parameter sich vollständig aus nachvollziehbaren Regeln ergeben.

Jede Konstante wird begründet — etwa als kleinste Zahl mit einer bestimmten Eigenschaft. Zusätzlich wurden die Formeln so gewählt, dass Sonderfälle wie in Aufgabe 14.1 nicht auftreten und die Rechnung stets gleich lange dauert. ***Der Entwurf schließt die Fehler aus, statt vor ihnen zu warnen*** *— und das ist die eigentliche Lehre der letzten beiden Kapitel.*

Elliptische Kurven heute

Verbreitung	Bei neuen Anwendungen der Regelfall; in Mobilfunk, Messengern und Kartenzahlung.
Paarungen	Besondere Kurven erlauben eine Verknüpfung zweier Punkte zu einem Körperelement — Grundlage für Verfahren, die anders nicht möglich wären.
Isogenien	Abbildungen zwischen Kurven; galten als quantensicherer Kandidat.

Zur zweiten Zeile

Eine Paarung ist eine Abbildung mit

$$e(aP, bQ) = e(P, Q)^{ab}.$$

Damit lassen sich Dinge bauen, die sonst unerreichbar sind: Schlüsseltausch zu dritt in einer Runde, Verschlüsselung an eine Kennung statt an einen Schlüssel, und kurze Beweise für umfangreiche Behauptungen. ***Die Paarung war zunächst als Angriffswerkzeug entdeckt worden*** *— sie führt das Problem auf eines in einem Körper zurück und schwächt bestimmte Kurven. Erst später erkannte man sie als Baustein.*

Zur dritten Zeile

Ein auf Isogenien beruhendes Verfahren galt lange als aussichtsreicher Kandidat für die Zeit nach dem Quantenrechner.

2022 wurde es gebrochen — klassisch, auf einem einzelnen Rechner, binnen Stunden. Der Angriff beruhte auf einem Satz von 1997, den niemand in diesem Zusammenhang gesehen hatte. ***Ein Verfahren, das fünf Jahre lang geprüft worden war, fiel an einem Nachmittag****, und das ist die beste Mahnung zur Vorsicht bei neuen Annahmen. Kapitel 15 behandelt die verbliebenen Kandidaten.*

Was Sie jetzt können

Definition 14.1	Kurve, Fernpunkt, Gruppengesetz
Die Formeln	Sehne und Tangente, modular gerechnet
Der Vorteil	keine Indexrechnung, Faktor 12
Signaturen	der Prüfer setzt R zusammen
Der Bruchfall	k zweimal heißt Schlüssel verloren

Damit endet Teil V. Alle Verfahren dieses Teils — Diffie-Hellman, RSA, elliptische Kurven — fallen durch dasselbe Quantenverfahren. Das letzte Kapitel fragt, was danach kommt.

Teil VI

Aktueller Stand

Kapitel 15

Was Information leistet

15.1 Die Bedrohung

Zwei Quantenverfahren, zwei Wirkungen

	Shor, 1994	**Grover, 1996**
Leistet	Faktorisieren und diskrete Logarithmen in polynomialer Zeit	Durchsuchen in $\sqrt{N}$ statt N
Betrifft	Teil V vollständig	Teil IV teilweise
Abhilfe	keine	Länge verdoppeln

Die Bilanz je Baustein

Baustein	**klassisch**	**mit Quantenrechner**
AES-128	128	64 Bit
AES-256	256	128 Bit
SHA-256	128	$\approx$ 85 Bit
SHA-512	256	$\approx$ 170 Bit
RSA-3072	138	gebrochen
Elliptisch-256	128	gebrochen

Die ersten vier Zeilen sind ein Umstellungsaufwand. Die letzten beiden sind ein Bruch.

*Der Unterschied ist grundsätzlich: Grover halbiert den Exponenten — man verdoppelt die Schlüssellänge und ist wieder da, wo man war. Shor macht das Problem polynomial — **längere Schlüssel helfen nicht**, weil der Aufwand nur polynomial mitwächst.*

Warum die Umstellung heute nötig ist

Wer heute aufgezeichneten Verkehr speichert, kann ihn entschlüsseln, sobald ein Quantenrechner verfügbar ist.

Die Rechnung

Größe	Jahre	
Geheimhaltungs-dauer	30	Patientendaten
Umstellungsdauer	10	Infrastruktur
Summe	**40**	

Ist ein Quantenrechner in weniger als vierzig Jahren verfügbar, so ist heute verschlüsselter Verkehr betroffen. ***Niemand kann den Zeitpunkt zuverlässig nennen*** *— und genau deshalb ist die Umstellung keine Frage der Vorhersage, sondern der Vorsicht. Für Patientendaten mit lebenslanger Schutzdauer verschärft sich die Rechnung erheblich.*

Der Stand der Technik

Gegenwärtig arbeiten Quantenrechner mit einigen hundert bis wenigen tausend physikalischen Quantenbits.

Für einen 2048-Bit-Schlüssel bräuchte man nach heutigen Schätzungen einige Millionen fehlerkorrigierte Quantenbits — und ein fehlerkorrigiertes erfordert tausend oder mehr physikalische. Der Abstand beträgt also mehrere Größenordnungen. ***Er schrumpft, und die Schrumpfungsrate ist unbekannt.***

15.2 Was an die Stelle tritt

Vier Familien

Familie	beruht auf	Stand
Gitter	kürzeste Vektoren in hochdimensionalen Gittern	genormt
Codes	Decodieren zufälliger linearer Codes	genormt
Hashwerte	nur Kapitel 11	genormt, langsam
Mehrere Variablen	Gleichungssysteme über endlichen Körpern	teils gebrochen

Die zweite Zeile ist bemerkenswert

Das Decodierproblem zufälliger linearer Codes ist genau das Problem aus Kapitel 6 — nur ohne die Struktur, die Codes brauchbar macht.

> ***Robert McEliece*** *schlug 1978 ein darauf beruhendes Verfahren vor, zwei Jahre nach Diffie und Hellman.* ***Es ist seit fast fünfzig Jahren ungebrochen*** *— länger als jedes andere Verfahren mit öffentlichem Schlüssel. Durchgesetzt hat es sich nie, weil der öffentliche Schlüssel etwa ein Megabyte umfasst.*

Die dritte Zeile

Signaturen lassen sich allein aus Hashfunktionen bauen — ohne jede zahlentheoretische Annahme.

> *Das ist die konservativste Wahl: Sie setzt nur voraus, dass die Hashfunktion hält, und nach Kapitel 11 ist das die am wenigsten bedrohte Annahme. Der Preis sind lange Signaturen und teils begrenzte Nutzungszahlen.* ***Für Aufgaben wie das Signieren von Aktualisierungen, die selten und langfristig erfolgen, ist das die richtige Abwägung.***

Die Annahmen sind jung

Annahme	geprüft seit	
Faktorisierung	≈ 2300 Jahren	Euklid
Diskreter Logarithmus	50 Jahren	
Gitterprobleme	≈ 30 Jahren	
Isogenien	15 Jahren	gebrochen 2022

Die neuen Verfahren beruhen auf Problemen, die erheblich weniger lange geprüft sind als die alten.

Der Fall von 2022 ist die Mahnung: Ein Verfahren, das fünf Jahre im Normungsverfahren geprüft worden war, fiel binnen Stunden auf einem gewöhnlichen Rechner — durch einen Satz von 1997. ***Die Prüfdauer ist die einzige verfügbare Evidenz, und sie ist bei den neuen Verfahren kurz.***

Die Antwort der Praxis

Man kombiniert: klassischer und neuer Schlüsseltausch zugleich, der Sitzungsschlüssel aus beiden abgeleitet.

Das hält, solange eines von beiden hält — gegen einen Quantenrechner das neue, gegen einen Fehler im neuen das alte. ***Es ist die Kombinationstherapie aus Band 18, Kapitel 14****, mit derselben Voraussetzung: Die Verfahren müssen unabhängig sein.*

15.3 Vier Muster

Muster 1 — eine Ungleichung, immer wieder

2	$H \leq \operatorname{ld} n$ — das Maximum bei Gleichverteilung.
3	$L \geq H$ — keine Codierung unterbietet die Entropie.
4	$D(p\|\|q) \geq 0$ — und $I(X;Y) \geq 0$ als Sonderfall.
8	Die Fisher-Information als Krümmung von D.

Viermal derselbe Beweis: Jensen auf den Logarithmus, mit einer geschickt gewählten Konstante in der Summe.

Alle sind Sonderfälle von $D(p\|\|q) \geq 0$. ***Die relative Entropie ist das eine Werkzeug, auf dem die gesamte Informationstheorie ruht*** *— und sie taucht in Kapitel 8 als statistischer Begriff wieder auf, ohne dass sie sich verändert hätte.*

Muster 2 — das Typische trägt alles

3	Man codiert nur die typischen Folgen und lässt den Rest scheitern.
5	2^{nH} von 2^n Folgen tragen die ganze Wahrscheinlichkeit.
6	Gute Codes korrigieren nur die typischen Fehler, nicht alle.
7	Fast alle Folgen sind inkomprimierbar — und kommen nie vor.

Die Informationstheorie handelt nicht vom Möglichen, sondern vom Wahrscheinlichen.

Darin liegt ihr Unterschied zur Kombinatorik und zur Codierungstheorie klassischer Prägung. Shannons Beweis in Kapitel 5 verzichtet auf die Garantie für alle Fälle und gewinnt dadurch die Kapazität. ***Wer alles korrigieren will, erreicht weniger als wer das Typische korrigiert*** *— das ist eine der überraschendsten Einsichten dieses Bandes.*

Muster 3 — derselbe Fehler, dreimal

9	Einmalschlüssel zweimal benutzt: $C_1 \oplus C_2 = M_1 \oplus M_2$.
10	Zählerwert zweimal benutzt: derselbe Schlüsselstrom.
14	Zufallswert zweimal benutzt: der geheime Schlüssel fällt.

Dreimal dieselbe Ursache, dreimal ein anderes Verfahren, dreimal ein vollständiger Bruch.

Bei Venona war es doppelt gedrucktes Papier, bei den Betriebsarten ein Neustart, bei der Spielkonsole eine Zeile Programmcode. ***Die Mathematik war in allen drei Fällen einwandfrei.*** *Das ist der durchgehende Befund von Teil IV und V: Verfahren fallen nicht durch Kryptanalyse, sondern durch Umsetzung.*

Muster 4 — Schranken sind einseitig

1	Die Wägeschranke schließt aus; sie garantiert nicht.
6	Die Kugelpackungsschranke verbietet Codes; sie liefert keine.
7	K lässt sich von oben abschätzen, nie von unten.
11	Die Geburtstagsschranke ist eine obere Grenze für die Sicherheit.

Fast alle Schranken dieses Bandes sagen, was nicht geht. Dass etwas geht, ist stets ein eigener Satz — und oft der schwierigere.

Shannons Kanalcodierungstheorem ist das klarste Beispiel: Die Umkehrung folgt aus zwei Ungleichungen, die Erreichbarkeit brauchte einen nicht konstruktiven Beweis und sechzig Jahre bis zur Umsetzung. ***Bei MD5 lag zwischen Schranke und Wirklichkeit der Faktor*** 10^{14} *— in die ungünstige Richtung.*

15.4 Was nicht die Mathematik ist

Die Bilanz der drei Warnungen

Erste	Information ist nicht Bedeutung. Bestätigt in Kapitel 1 und 7: Eine zufällige Folge hat maximale Information und minimalen Gehalt.
Zweite	Sätze gelten für Grenzwerte. Bestätigt in Kapitel 5: Die Kapazität ist erreichbar — bei Blocklängen in den Tausenden.
Dritte	Sicherheit ist nicht beweisbar. Bestätigt in jedem Kapitel von Teil IV und V.

Zur dritten Warnung

Mit einer einzigen Ausnahme — dem Einmalschlüssel — beruht jedes Verfahren dieses Bandes auf einer unbewiesenen Annahme.

Und die Ausnahme ist praktisch unbrauchbar, wie Satz 9.3 beweist. ***Die Sicherheit der digitalen Welt ruht auf der Vermutung, dass bestimmte Rechenprobleme schwer sind*** *— und ein Beweis dafür würde zugleich* $\mathsf{P} \neq \mathsf{NP}$ *zeigen, also eines der Millenniumsprobleme lösen.*

Und die eigentliche Schwachstelle

Selten	Ein Verfahren wird durch Kryptanalyse gebrochen.
Häufig	Ein korrektes Verfahren wird falsch verwendet.
Sehr häufig	Der Angriff umgeht die Mathematik vollständig — Seitenkanäle, Verkehrsdaten, Schlüsselverwaltung, Menschen.

Der Mann in der Mitte aus Kapitel 12 braucht keinerlei Rechenkraft. Der Fehlerangriff aus Kapitel 13 braucht einen Spannungsstoß. Der Zeitangriff aus Kapitel 11 braucht eine Stoppuhr. ***Die Mathematik ist der am besten gesicherte Teil des System*** *— und deshalb greift niemand sie an.*

15.5 Sechs Sätze, die bleiben

Die Bilanz

1	Der Informationsgehalt hängt allein von der Wahrscheinlichkeit ab — drei schwache Forderungen legen ihn fest.
2	Die Entropie ist die Grenze der Kompression, und sie ist erreichbar.
3	Über einen gestörten Kanal lässt sich bis zur Kapazität beliebig zuverlässig übertragen. Darüber gar nicht.
4	Fast alle Folgen sind unkomprimierbar, und man kann es keiner einzelnen nachweisen.
5	Perfekte Geheimhaltung verlangt einen Schlüssel so lang wie die Nachricht.
6	Alles andere beruht auf einer Annahme.

Ein Schlusswort

Dieser Band begann mit der Behauptung, eine Nachricht habe ein Gewicht, das sich in Bit angeben lässt — und dass dieses Gewicht nicht davon abhängt, was sie bedeutet.
Fünfzehn Kapitel später lässt sich sagen, was aus dieser Beschränkung geworden ist. Sie hat eine Theorie ermöglicht, die für jede Art von Nachricht gleichermaßen gilt: für Diagnoseschlüssel und Funksignale, für Erbgutsequenzen und Passwörter. Und sie hat Sätze hervorgebracht, die man ohne sie nicht einmal hätte formulieren können — über Grenzen, die niemand unterbietet, und über Verfahren, die sie erreichen.
Der Preis war von Anfang an klar und ist es geblieben. Der Begriff sagt nichts darüber, ob eine Nachricht wahr ist, ob sie nützt oder ob sie verstanden wird. Er misst allein, wie sehr sie Ungewissheit auflöst — und das ist eine Frage an den Empfänger, nicht an die Nachricht.

In der zweiten Hälfte kehrt sich das Vorzeichen um, und der Begriff bleibt derselbe. Geheimhaltung heißt, dass der Geheimtext die Ungewissheit des Mitlesers nicht auflöst — Definition 9.1 ist Kapitel 4 mit umgekehrtem Wunsch. ***Dieselbe Größe misst, was ankommen soll, und was nicht ankommen darf.***

Damit steht dieser Band neben den drei vorangegangenen. Die Statistik sagt, was die Daten hergeben. Die Biomathematik sagt, woran es liegt. Die Optimierung sagt, was es kostet. Und die Informationstheorie sagt, was überhaupt übertragbar ist — ***und sie sagt es in einer Einheit, die man nachrechnen kann.***

Teil VII

Anhang

Kapitel A

Formelsammlung und Übersicht

A.1 Information messen

Grundgrößen

$I(p) = \operatorname{ld} \frac{1}{p}$	Informationsgehalt (1.2)
stetig, fallend, additiv	Satz 1.1
$H(X) = -\sum p_i \operatorname{ld} p_i$	Entropie (2.1)
$0 \leq H \leq \operatorname{ld} n$	Satz 2.2
$h(p) = -p \operatorname{ld} p - (1-p) \operatorname{ld}(1-p)$	binär (2.3)
$h(0{,}11) = 0{,}5$	Steilheit am Rand
$H(X,Y) = H(X) + H(Y \mid X)$	Kettenregel (2.5)
$H(Y \mid X) \leq H(Y)$	Satz 2.6, im Mittel
$H_\infty = \lim H(X_1..X_n)/n$	Entropierate

Quellencodierung

$\sum 2^{-l_i} \leq 1$	Kraft (Satz 3.1)
$L = \sum p_i l_i \geq H$	Satz 3.2
Gleichheit $\iff l_i = -\operatorname{ld} p_i$	dyadisch
$H \leq L < H+1$	Satz 3.3
$l_i = \lceil -\operatorname{ld} p_i \rceil$	Shannon-Code
kleinste zwei zusammenfassen	Huffman (3.4)
$H \leq L_n/n < H + 1/n$	Blöcke

A.2 Der Kanal

Transinformation und Kapazität

$I(X;Y) = H(X) - H(X \mid Y)$	Definition 4.1
$= H(X) + H(Y) - H(X,Y)$	symmetrisch
$D(p\|q) = \sum p_i \operatorname{ld} \frac{p_i}{q_i} \geq 0$	Satz 4.4
$I = D\big(p(x,y)\|p(x)p(y)\big)$	Satz 4.5
$C = \max_{p(x)} I(X;Y)$	Definition 4.6
$C = 1 - h(f)$	BSC (Satz 4.7)
$C = 1 - e$	Auslöschung
$C = \frac{1}{2} \operatorname{ld}(1 + S/N)$	Gauß-Kanal

Codierung

$R < C$ möglich, $R > C$ nicht	Satz 5.1
$\|A_\varepsilon\| \approx 2^{nH}$	typische Menge (5.3)
$2^{n(1-h(f))} = 2^{nC}$ Kugeln	Kugelpackung
$P_e \lesssim 2^{-n(C-R)}$	Zufallscodierung
$H(X \mid Y) \leq$ $h(P_e) + P_e \operatorname{ld}(\|\mathcal{X}\| - 1)$	Fano (5.4)
$I(X;Z) \leq I(X;Y)$	Datenverarbeitung (5.5)
$d-1$ erkennen, $\lfloor \frac{d-1}{2} \rfloor$ korrigieren	Satz 6.2
$H\boldsymbol{y}^\top = H\boldsymbol{e}^\top$	Syndrom
$2^k \sum_{i \leq t} \binom{n}{i} \leq 2^n$	Kugelpackung
$d \leq n - k + 1$	Singleton
$m \cdot t$	Verschachtelung

A.3 Zufall und Statistik

Komplexität

$K(x) = \min\{\lvert p\rvert : U(p) = x\}$	Definition 7.1
$\lvert K_U - K_V\rvert \le c$	Invarianz (7.2)
Anteil mit $K < n-k$: $< 2^{-k}$	Satz 7.3
$K(x) \ge \lvert x\rvert$	inkomprimierbar (7.4)
K nicht berechenbar	Satz 7.5
$\mathbb{E}[K]/n \to H$	Satz 7.6

Statistik

$\mathbb{E}_p[\mathrm{ld}(p/q)] = D(p\Vert q)$	Evidenz je Beobachtung
$n \approx \mathrm{Bit}/D(p\Vert q)$	Stichprobenumfang
$D(p_{\theta+\varepsilon}\Vert p_\theta) \approx \frac{\varepsilon^2}{2\ln 2}\mathcal{I}(\theta)$	Satz 8.2
$\mathcal{I}(p) = \dfrac{1}{p(1-p)}$	Bernoulli
$\mathrm{Var} \ge 1/(n\mathcal{I})$	Cramér-Rao
$L(\text{Modell}) + L(\text{Daten} \mid \text{Modell})$	MDL
$\frac{1}{2}\,\mathrm{ld}\, n$	Kosten je Parameter
$-2\ln\hat{L} + 2k$	AIC

A.4 Kryptographie

Geheimhaltung

$I(M;C) = 0$	perfekt sicher (9.1)
$C = M \oplus K$	Einmalschlüssel (9.2)
$H(K) \geq H(M)$	Satz 9.3
$U = H(K)/D$	Unizitätsdistanz (9.4)
$D = \mathrm{ld}\,\lvert\mathcal{A}\rvert - H_\infty$	Redundanz
$C_1 \oplus C_2 = M_1 \oplus M_2$	Wiederverwendung
Verwirrung, Verwischung	Shannon 1949
halbe Bits kippen	Lawinenkriterium
$C_i = E(M_i)$	ECB, unbrauchbar
$C_i = E(M_i \oplus C_{i-1})$	CBC
$C_i = M_i \oplus E(N \Vert i)$	CTR
$2^{n/2}$ Blöcke	Geburtstagsschranke

Hashwerte und öffentliche Schlüssel

Urbild, zweites Urbild: 2^n	Definition 11.1
Kollision: $2^{n/2}$	
$k \approx 1{,}177\sqrt{N}$	Satz 11.2
$H(K\|M)$ falsch	Längenerweiterung
$H((K \oplus o)\|H((K \oplus i)\|M))$	HMAC
ld n Werte	Hashbaum
$A = g^a, B = g^b, g^{ab}$	Diffie-Hellman
$g^x \equiv y$	Logarithmusproblem (12.1)
$L_p[1/3, 1{,}923]$	Indexrechnung
$\varphi(pq) = (p-1)(q-1)$	
$a^{\varphi(n)} \equiv 1$	Euler (13.1)
$ed \equiv 1 \bmod \varphi(n)$	RSA
$m^{ed} = m$	Satz 13.2
$y^2 = x^3 + ax + b$	elliptisch (14.1)
$\lambda = \frac{3x_1^2+a}{2y_1}$	Verdoppeln
$x_3 = \lambda^2 - x_1 - x_2$	
$s = k^{-1}(H(m) + rd)$	Signatur
$k = \frac{h_1-h_2}{s_1-s_2}$	bei Wiederholung

A.5 Die Landkarte des Bandes

Welcher Satz wo — und worauf er beruht

Ergebnis	Kap.	Beruht auf
$I(p) = -C \ln p$	1	Cauchys Funktionalgleichung
$H \leq \operatorname{ld} n$	2	Jensen
Kettenregel	2	Logarithmengesetz
Kraft	3	Blätter abzählen
$L \geq H$	3	Jensen + Kraft
$H \leq L < H + 1$	3	Aufrunden
Huffman optimal	3	Vertauschen, Induktion
$D(p\|\|q) \geq 0$	4	Jensen
$I \geq 0$	4	Sonderfall von D
$C = 1 - h(f)$	4	$H(Y \mid X)$ konstant
Typische Menge	5	Gesetz großer Zahlen
Kapazität erreichbar	5	Zufallscodierung
Umkehrung	5	Fano + Datenverarbeitung
Ganzzahlige Ecken	6	Dreiecksungleichung
Ganzzahligkeit	6	Cramer (Band 19)
Invarianz	7	Nachbildung
K unberechenbar	7	Berry-Paradoxon
D als Evidenz	8	Erwartungswert
Fisher	8	zweite Ableitung von D
Einmalschlüssel	9	gleichverteiltes K
$H(K) \geq H(M)$	9	Kettenregel + Satz 2.6
Geburtstag	11	$1 - x \approx e^{-x}$
g^{ab} beidseitig	12	Potenzgesetz
$m^{ed} = m$	13	Euler
Signatur prüfbar	14	Kommutativität

Was in diesem Band *nicht* bewiesen wurde

Ergebnis	Kap.	Wo es steht
Jensensche Ungleichung	2	Band 19, Kap. 7
Gesetz großer Zahlen	5	Band 12, Teil IV
Erreichbarkeit, vollständig	5	Cover[5], Kap. 7
Kraft für eindeutige Codes	3	Cover[5], Kap. 5
Umkehrung von Satz 6.4	6	Lin[16]
Gruppengesetz assoziativ	14	Hankerson[11]
$\mathbb{Z}_p^*$ ist zyklisch	12	Band 8, Teil III
Satz von Euler	13	Band 6, Teil II
Shors Verfahren	15	Nielsen[19]

Neun Auslassungen, jede im Text benannt, mit Begründung und Fundstelle — die einzige zulässige Form, die Regel dieses Werkes zu brechen.

A.6 Zeittafel

Von Fermat bis zur Post-Quanten-Normung

Jahr	Person	Ereignis
1640	Fermat	kleiner Satz
1763	Bayes	bedingte Wahrscheinlichkeit
1836	Morse	Häufigkeit und Codelänge
1877	Boltzmann	$S = k \ln W$
1883	Kerckhoffs	nur der Schlüssel ist geheim
1902	Gibbs	$-k \sum p \ln p$
1906	Jensen	Ungleichung
1919	Vernam	Einmalschlüssel patentiert
1924	Nyquist	Symbolrate
1928	Hartley	$n \log s$
1929	Szilárd	Dämon und Information
1943	—	Venona beginnt
1948	**Shannon**	**Informationstheorie**
1949	Shannon	perfekte Sicherheit
1950	Hamming	fehlerkorrigierende Codes
1951	Kullback, Leibler	relative Entropie
1952	Huffman	optimaler Präfixcode
1960	Solomonoff	algorithmische Wahrscheinlichkeit
1960	Reed, Solomon	Codes über Bytes
1961	Landauer	Löschen kostet Energie
1962	Gallager	LDPC — vergessen
1965	Kolmogorow, Chaitin	Komplexität
1973	Cocks (GCHQ)	RSA, geheim
1973	Akaike	Informationskriterium
1974	Williamson (GCHQ)	Schlüsseltausch, geheim
1976	**Diffie, Hellman**	**öffentliche Schlüssel**
1977	Rivest, Shamir, Adleman	RSA
1977	—	DES als Norm
1978	Rissanen	kürzeste Beschreibung
1978	McEliece	Codes als Grundlage
1985	Koblitz, Miller	elliptische Kurven
1993	Berrou, Glavieux	Turbo-Codes
1994	Shor	Quantenfaktorisierung
1994	—	RSA-129 gebrochen
1995	Shor	Quantenfehlerkorrektur
2001	Daemen, Rijmen	AES
2004	Wang	MD5 gebrochen
2008	Arıkan	Polar-Codes
2012	Bertoni u. a.	SHA-3

A.7 Glossar

Begriffe von A bis Z

Begriff	Bedeutung
Beglaubigungscode	Prüfwert mit Schlüssel (11)
Bit	Einheit und Binärstelle (1.2)
Blocklänge	Zahl der Symbole je Codewort (5)
Differentielle Entropie	stetiger Fall, kann negativ sein (2)
Entropie	mittlerer Informationsgehalt (2.1)
Entropierate	Grenzwert je Symbol (3)
Fernpunkt	neutrales Element der Kurve (14.1)
Fisher-Information	Krümmung von D (8.2)
Geburtstagsschranke	$1{,}177\sqrt{N}$ (11.2)
Hashfunktion	feste Ausgabelänge (11.1)
Indexrechnung	unterexponentiell für Restklassen (12)
Inkomprimierbar	$K(x) \geq \lvert x\rvert$ (7.4)
Kanalkapazität	$\max I(X;Y)$ (4.6)
Kerckhoffs	nur der Schlüssel ist geheim (9)
Kollisionsresistenz	kein Paar gleicher Werte (11.1)
Kraftsche Ungleichung	$\sum 2^{-l_i} \leq 1$ (3.1)
Längenerweiterung	Fortsetzen aus dem Hashwert (11)
Lawinenkriterium	halbe Bits kippen (10)
Perfekt sicher	$I(M;C) = 0$ (9.1)
Präfixfrei	kein Wort Anfang eines anderen (3)
Primitivwurzel	erzeugt alle Reste (12)
Relative Entropie	$D(p\Vert q)$ (4.3)
Salz	öffentlicher Zufallszusatz (11)
Seitenkanal	Laufzeit, Strom, Speicher (10)
Syndrom	$H\boldsymbol{y}^{\top}$, hängt nur am Fehler (6)
Transinformation	$I(X;Y)$ (4.1)
Typische Menge	2^{nH} Folgen (5.2)
Unizitätsdistanz	$H(K)/D$ (9.4)
Verschachtelung	Bündel auf Codewörter verteilen (6)

Verwirrung	Schlüssel-Geheimtext verwickelt (10)
Verwischung	jedes Bit wirkt auf jedes (10)
Vorwärts-geheimhaltung	Sitzungsschlüssel, dann gelöscht (12)
Zertifikat	prüfbarer Beleg (Band 19, Kap. 12)

Kapitel B

Kommentierte Quellen

Achtundzwanzig Werke, eingeordnet: Zu jedem steht, wofür man es aufschlägt und was es leistet, das andere nicht leisten.

[1] Anderson, R.: *Security Engineering*. 3. Aufl., Wiley 2020.

Das Buch über alles, was in diesem Band nicht steht. *Anderson behandelt Sicherheit als Systemfrage: Menschen, Anreize, Organisationen, Seitenkanäle, Fehlbedienung. Über tausend Seiten mit unzähligen Fallbeispielen, frei verfügbar. Wer nach Kapitel 15 wissen will, warum Systeme tatsächlich fallen, liest hier weiter.*

[2] Arıkan, E.: *Channel Polarization*. IEEE Transactions on Information Theory 55, 2009.

Die Arbeit mit den Polar-Codes — der erste explizite Code, der die Kapazität beweisbar erreicht, sechzig Jahre nach Shannon. Der Gedanke, gleiche Kanäle in ungleiche zu verwandeln, ist elementar und überraschend zugleich.

[3] Beutelspacher, A.: *Kryptologie*. 10. Aufl., Springer Spektrum 2015.

Auf Deutsch und für den Einstieg geeignet. *Beutelspacher erklärt die klassischen Verfahren und die Grundideen der modernen Kryptographie mit ungewöhnlich wenig Vorkenntnis. Wo dieser Band zu schnell war, ist das der sanftere Weg.*

[4] Boneh, D., Shoup, V.: *A Graduate Course in Applied Cryptography*. Frei verfügbar, laufend aktualisiert.

Die gründlichste zeitgemäße Darstellung mit Sicherheitsbeweisen. Behandelt genau die Fragen, die dieser Band nur streifen konnte: Was heißt es präzise, dass ein Verfahren sicher ist, und wie führt man den Beweis relativ zu einer Annahme?

[5] Cover, T., Thomas, J.: *Elements of Information Theory*. 2. Aufl., Wiley 2006.

Für die Teile I bis III die maßgebliche Quelle. *Enthält alle Beweise, die hier ausgelassen wurden — insbesondere die vollständige Erreichbarkeit in Kapitel 7 und die Kraftsche Ungleichung für eindeutig lesbare Codes. Sauber geschrieben und mit reichlich Übungen.*

[6] Csiszár, I., Körner, J.: *Information Theory: Coding Theorems for Discrete Memoryless Systems*. 2. Aufl., Cambridge 2011.

Die theoretisch anspruchsvollste Darstellung. Entwickelt die Methode der Typen, mit der sich die Sätze aus Kapitel 5 mit exakten Fehlerexponenten statt nur asymptotisch beweisen lassen. Für Leser, die Kapitel 5 unbefriedigend ungenau fanden.

[7] Diffie, W., Hellman, M.: *New Directions in Cryptography*. IEEE Transactions on Information Theory 22, 1976.

Die Arbeit, die alles veränderte. Enthält den Schlüsseltausch, den Begriff der Einwegfunktion und — als Idee

ohne Umsetzung — die digitale Signatur. Lesenswert auch, weil die Verfasser die Tragweite selbst benennen.

[8] Ferguson, N., Schneier, B., Kohno, T.: *Cryptography Engineering*. Wiley 2010.

Das Buch über die Umsetzung. *Warum HMAC so aussieht, wie es aussieht; welche Betriebsart wann; wie man Zufall gewinnt; wie man Schlüssel verwaltet. Der Kapitel 15 zugrundeliegende Befund — Verfahren fallen durch Umsetzung — ist hier über dreihundert Seiten ausgeführt.*

[9] Gallager, R.: *Information Theory and Reliable Communication*. Wiley 1968.

Das klassische Lehrbuch des Fachs, von einem seiner wichtigsten Vertreter. Enthält die Zufallscodierungsschranke mit exakten Exponenten und ist bis heute die beste Quelle für die Frage, wie schnell die Fehlerrate tatsächlich fällt.

[10] Goldreich, O.: *Foundations of Cryptography*. Band I und II, Cambridge 2001/2004.

Die begriffliche Grundlegung: Was ist eine Einwegfunktion, ein Pseudozufallsgenerator, ein Beweis ohne Wissenspreisgabe — und wie hängt alles zusammen. Nicht für die Praxis, sondern für die Frage, worauf sie beruht.

[11] Hankerson, D., Menezes, A., Vanstone, S.: *Guide to Elliptic Curve Cryptography*. Springer 2004.

Die Vertiefung zu Kapitel 14 — einschließlich des Beweises, dass das Gruppengesetz assoziativ ist, und aller Umsetzungsfragen von der Punktdarstellung bis zur Abwehr von Seitenkanälen.

[12] Huffman, D.: *A Method for the Construction of Minimum-Redundancy Codes*. Proceedings of the IRE 40, 1952.

Vier Seiten, die seit siebzig Jahren in Gebrauch sind. Der Optimalitätsbeweis ist kürzer als jede Nacherzählung und benutzt nichts als ein Vertauschungsargument.

[13] Katz, J., Lindell, Y.: *Introduction to Modern Cryptography*. 3. Aufl., Chapman & Hall 2020.

Für die Teile IV und V das Standardlehrbuch. *Es unterscheidet sich von älteren Darstellungen dadurch, dass jedes Verfahren mit einer präzisen Sicherheitsdefinition und einem Beweis relativ zu einer benannten Annahme daherkommt — genau die Sorgfalt, die Kapitel 13 als fehlend beklagte.*

[14] Kolmogorow, A.: *Three approaches to the quantitative definition of information*. Problems of Information Transmission 1, 1965.

Sieben Seiten, in denen der Begründer der Wahrscheinlichkeitstheorie einen Zufallsbegriff sucht, den seine eigene Theorie nicht liefern kann. Methodisch bemerkenswert und gut lesbar.

[15] Li, M., Vitányi, P.: *An Introduction to Kolmogorov Complexity and Its Applications*. 4. Aufl., Springer 2019.

Das umfassende Werk zu Kapitel 7. Enthält die Inkomprimierbarkeitsmethode mit zahlreichen Anwendungen, Chaitins Unvollständigkeitsergebnisse und den Zusammenhang zur Lerntheorie. Über achthundert Seiten und die einzige vollständige Darstellung.

[16] Lin, S., Costello, D.: *Error Control Coding*. 2. Aufl., Pearson 2004.

Das Standardwerk zu Kapitel 6. Behandelt lineare Codes, zyklische Codes, Reed-Solomon mit Decodierverfahren, Faltungscodes und LDPC — mit allen Rechnungen, die hier nur angedeutet werden konnten.

[17] MacKay, D.: *Information Theory, Inference, and Learning Algorithms*. Cambridge 2003.

Das Buch, das die Brücke schlägt *— zwischen Informationstheorie, Statistik und maschinellem Lernen, also zwischen den Teilen I bis III dieses Bandes und Band 17. Ungewöhnlich lebendig geschrieben, voller Beispiele und frei verfügbar. MacKay hat auch die LDPC-Codes wiederentdeckt.*

[18] Menezes, A., van Oorschot, P., Vanstone, S.: *Handbook of Applied Cryptography*. CRC Press 1996.

Das Nachschlagewerk. Kein Lehrbuch, sondern eine systematische Sammlung von Verfahren, Angriffen und Zahlenwerten, frei verfügbar. Wer wissen will, welche Varianten es gibt und was gegen sie bekannt ist, beginnt hier.

[19] Nielsen, M., Chuang, I.: *Quantum Computation and Quantum Information*. Cambridge 2010.

Das Standardwerk zum Quantenrechnen. Enthält Shors und Grovers Verfahren vollständig sowie die Quantenfehlerkorrektur — und einen eigenen Teil über Quanteninformationstheorie, in dem die Größen aus Teil I ihre quantenmechanische Entsprechung finden.

[20] Paar, C., Pelzl, J.: *Kryptografie verständlich*. Springer Vieweg 2016.

Auf Deutsch, für Ingenieure geschrieben. *Behandelt AES, RSA, elliptische Kurven und Hashfunktionen mit durchgerechneten Beispielen und Blick auf die Umsetzung in Hardware. Die passende Ergänzung zu den Kapiteln 10 bis 14.*

[21] Richardson, T., Urbanke, R.: *Modern Coding Theory*. Cambridge 2008.

Die Theorie der Codes, die der Kapazität nahekommen — LDPC, Nachrichtenaustausch bei der Decodierung, Dichteentwicklung. Erklärt, warum Codes mit schlechtem Minimalabstand besser sein können, und das ist der Bruch mit Kapitel 6.

[22] Rissanen, J.: *Modeling by shortest data description*. Automatica 14, 1978.

Die Begründung des Prinzips der kürzesten Beschreibung. Bemerkenswert ist der Verzicht auf die Annahme, dass es ein wahres Modell gibt — eine Position, die in der Statistik bis heute die Minderheit ist.

[23] Rivest, R., Shamir, A., Adleman, L.: *A Method for Obtaining Digital Signatures and Public-Key Cryptosystems*. Communications of the ACM 21, 1978.

Sieben Seiten, die die digitale Welt tragen. Enthält das Verfahren, den Korrektheitsbeweis und die Preisaufgabe, deren Sicherheitsschätzung um vierzehn Größenordnungen danebenlag.

[24] Shannon, C.: *A Mathematical Theory of Communication*. Bell System Technical Journal 27, 1948.

Die Arbeit, die alles enthält. *Entropie, Quellencodierung, Kapazität, Codierungstheorem, stetige Kanäle — gut fünfzig Seiten, frei verfügbar und erstaunlich gut lesbar. Wer nur eine Originalarbeit dieses Bandes liest, liest diese.*

[25] Shannon, C.: *Communication Theory of Secrecy Systems*. Bell System Technical Journal 28, 1949.

Die Begründung der mathematischen Kryptographie. Enthält Satz 9.3, die Unizitätsdistanz sowie die Begriffe Verwirrung und Verwischung, die den Entwurf von Blockchiffren bis heute leiten.

[26] Shor, P.: *Polynomial-Time Algorithms for Prime Factorization and Discrete Logarithms on a Quantum Computer*. SIAM Journal on Computing 26, 1997.

Die Arbeit, die Teil V ein Ablaufdatum gab. Der Kern ist die Quanten-Fouriertransformation zur Periodenbestimmung; der Rest ist klassische Zahlentheorie. Bemerkenswert zugänglich für ein Ergebnis dieser Tragweite.

[27] Werner, M.: *Information und Codierung*. 3. Aufl., Springer Vieweg 2008.

Auf Deutsch, knapp und anwendungsnah. *Deckt die Teile I und II ab, mit Schwerpunkt auf den Verfahren der Nachrichtentechnik. Für Leser, die eine deutschsprachige Zweitdarstellung suchen.*

[28] Willems, W.: *Codierungstheorie und Kryptographie*. Birkhäuser 2008.

Auf Deutsch und mathematisch streng. *Verbindet beide Hälften dieses Bandes in einem Band und entwickelt die algebraischen Grundlagen — endliche Körper, Gruppen, elliptische Kurven — von Grund auf. Die passende Vertiefung zu den Kapiteln 6 und 12 bis 14.*

Wenn Sie nur drei Bücher kaufen

[5]	**Cover, Thomas**	**Für die Theorie**
[13]	**Katz, Lindell**	Für die Kryptographie
[17]	**MacKay**	**Für den Zusammenhang**

Cover und Thomas enthalten die Teile I bis III mit allen Beweisen. Katz und Lindell behandeln Teil IV und V mit der begrifflichen Strenge, die dieses Fach erst seit wenigen Jahrzehnten hat. MacKay steht nicht zufällig an dritter Stelle: Er ist der einzige, der Informationstheorie, Statistik und Lernverfahren als eine Sache behandelt — und er ist frei verfügbar.

Vier frei verfügbare Ergänzungen: [24] Shannons Arbeit von 1948, die man gelesen haben sollte; [1] Anderson für alles, was über die Mathematik hinausgeht; [18] als Nachschlagewerk und [4] für Sicherheitsbeweise. Auf Deutsch: [3] Beutelspacher als Einstieg, [20] Paar und Pelzl für die Praxis, [28] Willems für die Algebra.

Information ist die
Auflösung von Ungewissheit.
Geheimhaltung ist
ihre Verweigerung.

— die beiden Hälften
dieses Bandes.