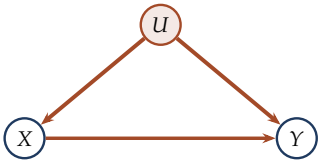
Mathematik von Grund auf — Band 23

Woran es liegt

Kausale Schlüsse



was man sieht, ist beides zugleich

Von Simpsons Paradoxon bis zur Zielstudienemulation

Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Stand der Forschung: August 2026

Mathematik von Grund auf — Band 23
Woran es liegt · Kausale Schlüsse

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Simulationen, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/mathematik-von-grund-auf`
Dauerhaft archiviert bei Zenodo: `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Mathematik von Grund auf, Band 23: Woran es liegt*. Fassung 1.0.1.
`https://doi.org/10.5281/zenodo.23698547`

Satz: LaTeX mit Palatino. Fassung 1.0.1, Oktober 2026. 158 Seiten.

Inhaltsverzeichnis

Vorwort **1**

I Das Problem **5**

1 Zusammenhang und Ursache **7**

1.1 Der Leitfall . . . 7
1.2 Drei Gründe für einen Zusammenhang . . . 8
1.3 Zwei Verteilungen . . . 9
1.4 Warum keine Statistik allein genügt . . . 10
1.5 Der Bruchfall . . . 11
1.6 Übungsaufgaben . . . 12

2 Was gewesen wäre **17**

2.1 Der Leitfall, einzeln betrachtet . . . 17
2.2 Vom Einzelnen zur Gruppe . . . 18
2.3 Vier Annahmen . . . 19
2.4 Der Bruchfall . . . 20
2.5 Übungsaufgaben . . . 21

3 Das Los **27**

3.1 Die Annahme herstellen . . . 27
3.2 Was das Los nicht kann . . . 28
3.3 Wie groß muss die Studie sein? . . . 29
3.4 Der Bruchfall . . . 29
3.5 Übungsaufgaben . . . 31

II Graphen und Regeln **37**

4 Annahmen aufschreiben **39**

4.1 Der Leitfall als Bild . . . 39
4.2 Drei Bausteine . . . 40

4.3 Am Leitfall geprüft . . . 42
4.4 Der Bruchfall . . . 42
4.5 Übungsaufgaben . . . 43

5 Was man herausrechnen darf **49**
5.1 Die Frage . . . 49
5.2 Vier Rollen . . . 49
5.3 Was in jedem Fall geschieht . . . 50
5.4 Der Fehler der zweiten Tabelle . . . 52
5.5 Der Bruchfall . . . 52
5.6 Übungsaufgaben . . . 53

6 Der Hintertürtest **59**
6.1 Die Regel . . . 59
6.2 Wenn kein Hinterweg zu sperren ist . . . 61
6.3 Der Bruchfall . . . 61
6.4 Übungsaufgaben . . . 62

III Anpassen **67**

7 Eine Zahl statt zwanzig **69**
7.1 Warum Schichten nicht reichen . . . 69
7.2 Vier Wege, sie zu benutzen . . . 70
7.3 Der Bruchfall . . . 71
7.4 Übungsaufgaben . . . 72

8 Gewichten und doppelte Absicherung **77**
8.1 Eine Pseudobevölkerung bauen . . . 77
8.2 Zwei Modelle, eine Chance . . . 78
8.3 Der Bruchfall . . . 79
8.4 Übungsaufgaben . . . 80

IV Wenn Anpassen nicht reicht **85**

9 Instrumente **87**
9.1 Der Gedanke . . . 87
9.2 Wessen Effekt wird geschätzt? . . . 88

9.3 Der Bruchfall 89
9.4 Übungsaufgaben 89

10 Natürliche Versuche **95**
10.1 Der Sprung an der Schwelle 95
10.2 Vorher und nachher, hier und dort 96
10.3 Der Bruchfall 97
10.4 Übungsaufgaben 97

11 Die Studie nachbilden **103**
11.1 Der Leitfall, aufgelöst 103
11.2 Unsterbliche Zeit 104
11.3 Der Leitfall gerechnet 104
11.4 Der Bruchfall 105
11.5 Übungsaufgaben 106

V Über die Zeit, im Einzelfall **111**

12 Behandeln über die Zeit **113**
12.1 Das Problem 113
12.2 Die g-Formel 114
12.3 Der Bruchfall 116
12.4 Übungsaufgaben 116

13 Auf welchem Weg **121**
13.1 Die Frage 121
13.2 Was der lineare Fall verbirgt 122
13.3 Der Bruchfall 122
13.4 Übungsaufgaben 123

14 Für wen es wirkt **127**
14.1 Der Durchschnitt verbirgt 127
14.2 Wie man es schätzt 128
14.3 Der Bruchfall 128
14.4 Übungsaufgaben 129

VI Aktueller Stand **135**

15 Woran es liegt **137**

15.1 Die Tabelle aus Kapitel 1, ein letztes Mal 137

15.2 Vier Muster 137

15.3 Was offen ist 139

15.4 Sechs Sätze, die bleiben 139

VII Anhang **141**

A Formelsammlung und Übersicht **143**

A.1 Begriffe und Formeln 143

A.2 Die Landkarte 144

A.3 Was nicht bewiesen wurde 145

A.4 Zeittafel 146

A.5 Glossar 148

B Kommentierte Quellen **149**

Vorwort

Die Frage, die Band 22 offenließ

Das letzte Kapitel von Band 22 endete mit einer Feststellung: Ein Verfahren, das gut vorhersagt, hat nicht verstanden, warum. Die Merkmale, die es benutzt, beschreiben die Daten — nicht die Krankheit.

Dieser Band behandelt die andere Frage: Was geschieht, wenn man eingreift?

Sie ist die eigentliche Frage der Medizin. ***Kein Arzt will wissen, welche Patienten sterben werden — er will wissen, was er tun soll****, damit sie es nicht tun. Das ist keine Frage nach Zusammenhängen, sondern nach Wirkungen, und bis vor wenigen Jahrzehnten galt sie als außerhalb der Statistik liegend.*

Wo der Band steht

Band 17	Statistik schätzt Größen einer Verteilung und prüft Hypothesen darüber.
Band 22	Das Lernen sagt vorher, was bei einem neuen Fall zu erwarten ist.
Band 21	Die Spieltheorie fragt, was geschieht, wenn andere auf eine Änderung reagieren.
Hier	Die Frage lautet: Was wäre geschehen, wenn man anders gehandelt hätte?

Die letzte Zeile enthält eine Größe, die niemand beobachten kann. *Ein Patient wurde früh behandelt oder spät, nicht beides. Was mit ihm im anderen Fall geschehen wäre, ist keine fehlende Messung, sondern eine, die es nicht geben kann. Dass sich über solche Größen dennoch rechnen lässt — unter angebbaren Annahmen —, ist der Inhalt dieses Bandes.*

Drei Ergebnisse, die man nicht erwartet

1	Dieselbe Tabelle von Zahlen ist mit *entgegengesetzten* Wirkungen vereinbar. Keine noch so große Datenmenge kann zwischen ihnen entscheiden — nur Annahmen können es. *(Kapitel 1)*
2	Für manche Merkmale ist es ein Fehler, sie herauszurechnen. Wer nach allem anpasst, was er gemessen hat, erzeugt Verzerrungen, die vorher nicht da waren. *(Kapitel 5)*
3	Aus reinen Beobachtungsdaten lässt sich unter prüfbaren Bedingungen dasselbe berechnen wie aus einer randomisierten Studie — und die Bedingungen sind erstaunlich oft erfüllt. *(Kapitel 6 und 11)*

Das zweite Ergebnis widerspricht der verbreiteten Übung, in ein Modell möglichst viele Störgrößen aufzunehmen. ***Es gibt Merkmale, deren Berücksichtigung schadet*** *— und man erkennt sie nicht an den Daten, sondern nur an einer Überlegung darüber, wie die Daten entstanden sind.*

Die sechs Teile

Teil	Thema	Kapitel
I	Das Problem	1–3
II	Graphen und Regeln	4–6
III	Anpassen	7–8
IV	Wenn Anpassen nicht reicht	9–11
V	Über die Zeit, im Einzelfall	12–14
VI	Stand	15

Der Leitfall

Am Klinikum Neustadt zeigen die Behandlungsdaten: *Patienten, die früh Antibiotika erhielten, starben häufiger.*

Die Leitlinien verlangen eine möglichst frühe Gabe, und die Evidenz dafür ist gut. ***Die eigenen Daten des Hauses scheinen das Gegenteil zu zeigen*** *— und die Auflösung dieses Widerspruchs führt durch den ganzen Band. Sie beginnt in Kapitel 1 mit einer Tabelle und endet in Kapitel 11 mit einem Verfahren, das aus Routinedaten eine Studie nachbildet.*

Drei Warnungen

Erste	Jede kausale Aussage beruht auf Annahmen, die sich aus den Daten nicht prüfen lassen. Das Verfahren macht sie nicht überflüssig — es macht sie sichtbar.
Zweite	Ein Durchschnittseffekt sagt nichts über den einzelnen Patienten. Er kann positiv sein, während er bei der Hälfte schadet.
Dritte	Was in einer Bevölkerung wirkt, muss in einer anderen nicht wirken — und was unter Studienbedingungen wirkt, nicht im Alltag.

Die erste Warnung ist die wichtigste und wird oft für einen Einwand gehalten. ***Sie ist das Gegenteil****: Die Stärke der Verfahren dieses Bandes liegt darin, dass sie die Annahmen benennen, statt sie zu verstecken. Wer eine Regression rechnet und von "Einfluss" spricht, hat dieselben Annahmen gemacht — nur ohne sie aufzuschreiben.*

Was dieser Band voraussetzt

Werkzeug	Band	gebraucht in
Bedingte Wahrscheinlichkeit	4	durchgehend
Schätzen, Konfidenz	17	Kapitel 3, 7, 8
Regression	17, 22	Kapitel 7, 9, 14
Graphen, Wege	16	Kapitel 4–6
Lernverfahren	22	Kapitel 8, 14

Teil I und II kommen mit Band 0 und den Grundzügen der Wahrscheinlichkeitsrechnung aus. *Die Graphen aus Band 16 werden gebraucht, aber nur in ihren einfachsten Eigenschaften — gerichtete Kanten, Wege, Kreisfreiheit. Wo ein Satz aus einem Vorgängerband benutzt wird, steht die Fundstelle dabei.*

Teil I

Das Problem

Kapitel 1

Zusammenhang und Ursache

1.1 Der Leitfall

Eine Tabelle, die das Gegenteil zeigt

Am Klinikum Neustadt wurden 1200 Sepsispatienten ausgewertet. Die Hälfte erhielt das Antibiotikum innerhalb einer Stunde (“früh”), die andere Hälfte später.

Gabe	Patienten	gestorben	Anteil
früh	600	210	35,0 %
spät	600	125	20,8 %

Die frühe Gabe scheint die Sterblichkeit um vierzehn Prozentpunkte zu erhöhen.

*Das widerspricht allem, was die Leitlinien sagen. **Ein Statistiker könnte die Zahlen prüfen, und sie wären richtig** — der Unterschied ist groß, die Stichprobe ausreichend, das Vertrauensintervall schließt die Null weit aus. Trotzdem ist der Schluss falsch, und dieses Kapitel zeigt, woran das liegt.*

Dieselben Patienten, nach Schweregrad getrennt

	früh		spät	
	n	tot	*n*	tot
schwer krank	500	200	100	50
		40 %		50 %
leicht krank	100	10	500	75
		10 %		15 %

In jeder der beiden Gruppen senkt die frühe Gabe die Sterblichkeit — von 50 auf 40 und von 15 auf 10 Prozent.

Warum sich das Vorzeichen umkehrt

Wer bekommt früh?	Die Schwerkranken — 500 von 600. Bei ihnen ist die Diagnose offensichtlich, und man handelt sofort.
Wer stirbt?	Ebenfalls die Schwerkranken.

Der Schweregrad wirkt auf beides: auf die Behandlung und auf den Ausgang. ***Die Gruppe "früh" besteht überwiegend aus Schwerkranken, die Gruppe "spät" überwiegend aus Leichtkranken*** *— man vergleicht nicht zwei Behandlungen, sondern zwei Patientengruppen. In der Medizin heißt das* ***Indikationsverzerrung****, und sie ist die häufigste Fehlerquelle bei der Auswertung von Behandlungsdaten.*

Die richtige Rechnung

Man fragt: Was wäre geschehen, wenn *alle* 1200 früh behandelt worden wären? Und wenn alle spät?

Standardisierung

Der Anteil Schwerkranker ist $600/1200 = \frac{1}{2}$.

$$\Pr[\text{Tod} \mid \text{do}(\text{früh})] = \tfrac{1}{2} \cdot 0{,}40 + \tfrac{1}{2} \cdot 0{,}10 = 0{,}250$$

$$\Pr[\text{Tod} \mid \text{do}(\text{spät})] = \tfrac{1}{2} \cdot 0{,}50 + \tfrac{1}{2} \cdot 0{,}15 = 0{,}325$$

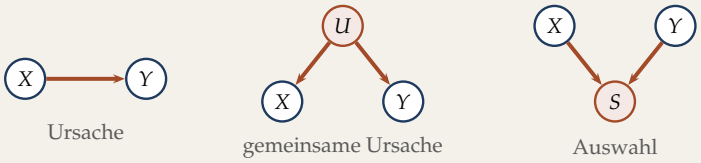
Rechnung	Effekt
naiver Vergleich	$+14{,}2$ Punkte
standardisiert	$\mathbf{-7{,}5}$ **Punkte**

Die frühe Gabe rettet siebeneinhalb von hundert Patienten — statt vierzehn zu töten.

Der Schweregrad wird dabei nicht weggelassen, sondern gleichgesetzt*: Man rechnet beide Behandlungen für dieselbe Mischung aus Schwer- und Leichtkranken durch. Kapitel 6 wird zeigen, unter welcher Bedingung diese Rechnung erlaubt ist — und Kapitel 5, dass es Größen gibt, bei denen man sie gerade nicht anwenden darf.*

1.2 Drei Gründe für einen Zusammenhang

Wenn X und Y zusammenhängen



Ursache	X wirkt auf Y. Nur hier hilft ein Eingriff.
Gemeinsame Ursache	Eine dritte Größe wirkt auf beide. Man nennt sie **Störgröße**. Das ist der Leitfall.
Auswahl	Beide wirken auf etwas Drittes, und man betrachtet nur Fälle mit bestimmtem Wert davon. Man nennt das einen **Kollider**.

Alle drei erzeugen denselben Zusammenhang in den Daten. Nur der erste rechtfertigt ein Handeln.

Die dritte Zeile ist die unbekannteste und in der klinischen Forschung die tückischste. ***Wer nur stationäre Patienten untersucht, hat bereits nach einem Kollider ausgewählt*** *— eine Aufnahme wird durch jedes ernste Leiden begünstigt. Aufgabe 1.2 rechnet vor, wie stark der Zusammenhang wird, den diese Auswahl allein erzeugt.*

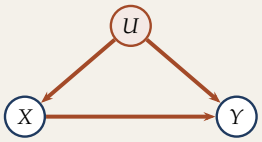
1.3 Zwei Verteilungen

Definition 1.1 — sehen und tun

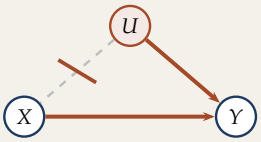
$\Pr[Y \mid X = x]$	**Sehen:** Wie sieht Y aus *unter denen*, bei denen X den Wert x hat?
$\Pr[Y \mid \mathrm{do}(X = x)]$	**Tun:** Wie sähe Y aus, wenn man bei *allen* den Wert x herstellte?

Der Unterschied

Sehen	ändert nichts an der Welt. Die Auswahl der Patienten mit $X = x$ ist nicht zufällig.
Tun	ändert die Welt: Alle Pfeile, die auf X zeigen, werden durchtrennt. X hängt dann von nichts mehr ab.



beobachtet



nach $\mathrm{do}(X = x)$

Der Eingriff schneidet die Pfeile ab, die in X hineinlaufen — und nur diese.

Im Leitfall heißt das: Der Pfeil "Schweregrad → frühe Gabe" verschwindet, der Pfeil "Schweregrad → Tod" bleibt. ***Genau das tut eine randomisierte Studie****: Das Los ersetzt die ärztliche Entscheidung und trennt die Behandlung von allem, was sie sonst beeinflusst. Kapitel 3 behandelt das ausführlich.*

1.4 Warum keine Statistik allein genügt

Satz 1.2 — Beobachtungsäquivalenz

Es gibt zwei verschiedene Ursachenstrukturen, die *genau dieselbe* gemeinsame Verteilung von X und Y erzeugen — und in denen der Effekt eines Eingriffs verschieden ist.

Die Zahlen

	$Y = 1$	$Y = 0$
$X = 1$	0,40	0,10
$X = 0$	0,10	0,40

$$\Pr[Y = 1 \mid X = 1] = 0{,}80, \qquad \Pr[Y = 1 \mid X = 0] = 0{,}20$$

Modell A — X wirkt auf Y

X ist ein Münzwurf; danach ist $Y = 1$ mit Wahrscheinlichkeit 0,8 falls $X = 1$, sonst mit 0,2.

$$\Pr[Y = 1 \mid \mathrm{do}(X = 1)] = 0{,}80, \qquad \Pr[Y = 1 \mid \mathrm{do}(X = 0)] = 0{,}20$$
$$\text{Effekt} = +0{,}60$$

Modell B — eine gemeinsame Ursache, X wirkt nicht

U ist ein Münzwurf. Bei $U = 1$ ist $X = 1$ mit Wahrscheinlichkeit $a = 0{,}8873$ und unabhängig davon $Y = 1$ mit derselben Wahrscheinlichkeit; bei $U = 0$ jeweils $1 - a$.
Probe:

$$\Pr[X = 1, Y = 1] = \tfrac{1}{2}a^2 + \tfrac{1}{2}(1-a)^2 = \tfrac{1}{2}(0{,}7873) + \tfrac{1}{2}(0{,}0127) = 0{,}40 \quad \checkmark$$

$$\Pr[Y = 1 \mid \mathrm{do}(X = 1)] = \Pr[Y = 1 \mid \mathrm{do}(X = 0)] = 0{,}50$$
$$\text{Effekt} = 0$$

Dieselben Zahlen, ein Effekt von $+0{,}60$ oder von null. Kein Test an diesen Daten kann entscheiden, welcher gilt.

***Das ist das erste der drei überraschenden Ergebnisse des Vorworts**, und es ist kein Grenzfall, sondern die Regel: Zu praktisch jeder beobachteten Verteilung gibt es mehrere Ursachenstrukturen. Auch beliebig viele weitere Patienten ändern daran nichts — sie bestimmen die Verteilung genauer, und die Verteilung ist es ja gerade, die nicht entscheidet.*

Was daraus folgt

Nicht:	"Kausale Schlüsse sind unmöglich."
Sondern:	Sie brauchen Annahmen, die nicht aus den Daten stammen — aus Fachwissen, aus dem Ablauf in der Zeit, aus dem Versuchsaufbau.

***Das ist genau dieselbe Lage wie in Band 22, Satz 1.5**: Ohne Annahme kein Lernen, ohne Annahme kein kausaler Schluss. Der Unterschied liegt darin, dass die Annahmen hier viel gezielter eingreifen — und dass die Verfahren dieses Bandes sie aufschreiben statt verschweigen.*

1.5 Der Bruchfall

Was die Standardisierung voraussetzt

Die Rechnung in Abschnitt 1.1 war richtig — unter einer Bedingung, die in den Zahlen nicht steht.

Alles gemessen	Der Schweregrad darf nicht die einzige Störgröße sein, die es gibt — er muss die einzige sein, die es gibt.
Zwei Stufen	"Schwer" und "leicht" sind eine grobe Einteilung. Innerhalb der Schwerkranken kann derselbe Zusammenhang erneut auftreten.
Überlappung	In jeder Gruppe müssen beide Behandlungen vorkommen. Bei 100 Prozent früh in einer Gruppe gibt es nichts zu vergleichen.

*Die erste Zeile ist unprüfbar. **Man kann nie ausschließen, dass eine weitere, nicht gemessene Größe beides beeinflusst** — etwa die Erfahrung des diensthabenden Arztes oder die Tageszeit. Kapitel 6 gibt der Annahme einen Namen und eine grafische Fassung; Kapitel 9 und 10 zeigen Wege, die ohne sie auskommen.*

Und die zweite Zeile in Zahlen

Teilt man "schwer" nochmals in zwei Stufen, so kann sich das Vorzeichen abermals umkehren — Simpsons Paradoxon kann sich auf jeder Ebene wiederholen. ***Feinere Einteilung hilft nur, wenn genug Patienten je Stufe bleiben****, sonst tauscht man Verzerrung gegen Varianz, genau wie in Band 22, Kapitel 2. Kapitel 7 behandelt diesen Zielkonflikt.*

1.6 Übungsaufgaben

Aufgabe 1.1 — Simpson erzeugen

Zeigen Sie, wie man aus zwei Untergruppen, in denen die Behandlung jeweils *schadet*, eine Gesamttabelle erzeugt, in der sie zu nützen scheint.

Lösung

Schritt 1 — Das Rezept

Man braucht zwei Bedingungen:

1	Die Untergruppen unterscheiden sich stark im Ausgang.
2	Die Behandlung ist in der *günstigeren* Untergruppe überrepräsentiert.

Schritt 2 — Zahlen

	behandelt		**nicht**	
	n	**tot**	n	**tot**
leicht	900	90	100	5
		10 %		5 %
schwer	100	60	900	450
		60 %		50 %
gesamt	1000	150	1000	455
		15 %		**45,5** %

In beiden Gruppen schadet die Behandlung um zehn Punkte. Insgesamt scheint sie um dreißig Punkte zu nützen.

Schritt 3 — Die standardisierte Rechnung

Jede Gruppe umfasst 1000 von 2000 Patienten, also je die Hälfte:

$$\Pr[\text{Tod} \mid \text{do}(\text{behandelt})] = \tfrac{1}{2}\cdot 0{,}10 + \tfrac{1}{2}\cdot 0{,}60 = 0{,}350$$

$$\Pr[\text{Tod} \mid \text{do}(\text{nicht})] = \tfrac{1}{2}\cdot 0{,}05 + \tfrac{1}{2}\cdot 0{,}50 = 0{,}275$$

$$\text{Effekt} = +0{,}075$$

Die Behandlung schadet um siebeneinhalb Punkte — obwohl die Gesamttabelle einen Nutzen von dreißig Punkten zeigt. Der naive Vergleich liegt um 37,5 Punkte daneben und im Vorzeichen falsch.

Schritt 4 — Die Warnung

*Man beachte, dass die standardisierte Rechnung hier eine Entscheidung enthält: Man mittelt über die Hälfte-Hälfte-Mischung der beiden Gruppen. **Bei anderer Mischung ergäbe sich eine andere Zahl** — bei lauter Leichtkranken +5 Punkte, bei lauter Schwerkranken +10. Ein Durchschnittseffekt gilt immer für eine bestimmte Bevölkerung; welche das ist, muss man dazusagen. Das ist die dritte Warnung des Vorworts.*

Aufgabe 1.2 — Zusammenhang aus reiner Auswahl

Zwei Leiden A und B treten in der Bevölkerung mit je zehn Prozent auf und sind *voneinander unabhängig*. Jedes erhöht die Wahrscheinlichkeit einer Krankenhausaufnahme.

Zustand	Aufnahme
weder A noch B	2 %
nur eines	30 %
beide	60 %

Wie hängen A und B unter den Aufgenommenen zusammen?

Lösung

Schritt 1 — Die gemeinsamen Wahrscheinlichkeiten

Zustand	Anteil	Aufn.	beides
kein Leiden	0,81	0,02	0,0162
nur A	0,09	0,30	0,0270
nur B	0,09	0,30	0,0270
A und B	0,01	0,60	0,0060
Summe	1,00		**0,0762**

Schritt 2 — Unter den Aufgenommenen

$$\Pr[B \mid A,\ \text{aufgenommen}] = \frac{0{,}0060}{0{,}0270 + 0{,}0060} = \frac{0{,}0060}{0{,}0330} = 0{,}182$$

$$\Pr[B \mid \text{nicht } A,\ \text{aufgenommen}] = \frac{0{,}0270}{0{,}0162 + 0{,}0270} = \frac{0{,}0270}{0{,}0432} = 0{,}625$$

Unter den Aufgenommenen haben Patienten mit A deutlich *seltener* auch B — 18 gegen 63 Prozent.

Schritt 3 — Das Chancenverhältnis

$$\frac{0{,}182/0{,}818}{0{,}625/0{,}375} = \frac{0{,}222}{1{,}667} = 0{,}133$$

Ein Chancenverhältnis von 0,13 — in einer Bevölkerung, in der die beiden Leiden nichts miteinander zu tun haben.

Schritt 4 — Die Deutung

*Wer aufgenommen ist und kein A hat, muss einen anderen Grund haben — meist B. **Das Wissen um die Aufnahme macht die beiden Leiden gegenseitig erklärend**, und deshalb schließt das eine das andere aus. Der Effekt heißt nach **Joseph Berkson**, der ihn 1946 an Krankenhausdaten beschrieb.*

Schritt 5 — Die praktische Folge

***Jede Studie an stationären Patienten hat nach einem Kollider ausgewählt.** Findet sie einen Zusammenhang zwischen zwei Erkrankungen, so kann er ganz oder teilweise aus der Auswahl stammen — und zwar mit umgekehrtem Vorzeichen gegenüber der Wirklichkeit. Dasselbe gilt für Studien an Freiwilligen, an Versicherten oder an Patienten mit vollständiger Dokumentation.*

Aufgabe 1.3 — Sehen und tun rechnen

Prüfen Sie in Modell B aus Satz 1.2 nach, dass $\Pr[Y = 1 \mid X = 1] = 0{,}80$ ist, aber $\Pr[Y = 1 \mid \mathrm{do}(X = 1)] = 0{,}50$.

Lösung

Schritt 1 — Das Modell

U	$\Pr[U]$	$\Pr[X = 1 \mid U]$	$\Pr[Y = 1 \mid U]$
1	0,5	0,8873	0,8873
0	0,5	0,1127	0,1127

X und Y sind bei gegebenem U unabhängig — kein Pfeil von X nach Y.

Schritt 2 — Sehen

$$\Pr[X = 1, Y = 1] = 0{,}5 \cdot 0{,}8873^2 + 0{,}5 \cdot 0{,}1127^2 = 0{,}3937 + 0{,}0063 = 0{,}400$$

$$\Pr[X = 1] = 0{,}5 \cdot 0{,}8873 + 0{,}5 \cdot 0{,}1127 = 0{,}500$$

$$\Pr[Y = 1 \mid X = 1] = \frac{0{,}400}{0{,}500} = 0{,}800 \quad \checkmark$$

Schritt 3 — Tun
Der Eingriff setzt X auf 1 und durchtrennt den Pfeil von U nach X. An der Verteilung von Y ändert das nichts, denn Y hängt nur von U ab:

$$\Pr[Y = 1 \mid \mathrm{do}(X = 1)] = \Pr[Y = 1] = 0{,}5 \cdot 0{,}8873 + 0{,}5 \cdot 0{,}1127 = 0{,}500 \quad \checkmark$$

Schritt 4 — Der Vergleich

	$X = 1$	$X = 0$
sehen	0,800	0,200
tun	0,500	0,500

***Das Sehen zeigt einen Unterschied von** 0,6**, das Tun keinen.** Der beobachtete Zusammenhang ist vollständig durch U erklärt: Wer $X = 1$ hat, hatte wahrscheinlich $U = 1$, und wer $U = 1$ hatte, hat wahrscheinlich $Y = 1$. Man sieht an X etwas über U — aber man ändert durch X nichts an U.*

Schritt 5 — Die Merkregel

Beobachten heißt: erfahren, welche Welt vorliegt. Eingreifen heißt: eine neue Welt herstellen.

Ein Paradoxon mit drei Namen

Edward Simpson beschrieb 1951 die Umkehr, die dieses Kapitel eröffnet — allerdings hatten **Karl Pearson** 1899 und **Udny Yule** 1903 dasselbe Phänomen bereits behandelt.

*Simpson selbst nannte es kein Paradoxon; er hielt fest, dass die Frage, welche Tabelle die richtige sei, nicht statistisch zu entscheiden ist, sondern vom Sachzusammenhang abhängt. **Damit hatte er die Lehre dieses Bandes bereits 1951 formuliert** — und sie wurde ein halbes Jahrhundert lang überlesen.*

Ein berühmter Fall
1973 schien die Universität Berkeley Frauen bei der Zulassung zu benachteiligen: 44 Prozent der Männer wurden angenommen, aber nur 35 Prozent der Frauen.

*Nach Fachbereichen getrennt kehrte sich das Bild in den meisten Fächern um. Frauen hatten sich häufiger für Fächer mit niedrigen Annahmequoten beworben. **Ob das die Benachteiligung widerlegt oder nur verschiebt, ist eine kausale Frage** — womöglich war die Fächerwahl selbst eine Folge früherer Benachteiligung. Die Zahlen allein entscheiden es nicht.*

Und der Widerstand

__Ronald Fisher__ bestritt bis zu seinem Tod 1962, dass der Zusammenhang zwischen Rauchen und Lungenkrebs ursächlich sei; er hielt eine gemeinsame genetische Ursache für möglich. __Sein Einwand war logisch korrekt__ — Satz 1.2 gibt ihm recht — und in der Sache falsch. Die Antwort kam nicht aus der Statistik, sondern aus Dosis-Wirkungs-Beziehungen, Tierversuchen und der Beobachtung, dass Aufhören das Risiko senkt.

Kausalität heute

Routinedaten	Aus Krankenakten Behandlungseffekte schätzen — Kapitel 11.
Ursachen entdecken	Aus Daten die Struktur selbst gewinnen, nicht nur Effekte schätzen.
Lernen und Kausalität	Verfahren, die auch bei veränderter Verteilung gelten.

Zur dritten Zeile

Band 22 endete mit der offenen Frage, wann ein an einer Klinik gelerntes Verfahren an einer anderen gilt. __Eine der wenigen belastbaren Antworten lautet: dann, wenn es kausale Zusammenhänge gelernt hat__ — denn diese bleiben unter Eingriffen und Verteilungsverschiebungen stabil, Korrelationen nicht. Das Sepsis-Warnsystem von 2021 scheiterte an einer Verschiebung; ein Modell, das nur auf ursächlichen Größen beruht, wäre robuster gewesen, hätte aber vermutlich schlechter vorhergesagt.

Was Sie jetzt können

Simpson	das Vorzeichen kann sich umkehren
Drei Gründe	Ursache, gemeinsame Ursache, Auswahl
Definition 1.1	sehen gegen tun
Satz 1.2	dieselben Daten, verschiedene Effekte
Standardisierung	über die Störgröße mitteln

Dieses Kapitel hat den Effekt an einem Beispiel ausgerechnet, ohne ihn zu definieren. Das nächste holt das nach — mit einer Größe, die für jeden einzelnen Patienten unbeobachtbar ist und für eine Gruppe trotzdem schätzbar.

Kapitel 2

Was gewesen wäre

2.1 Der Leitfall, einzeln betrachtet

Ein Patient

Herr K., 68 Jahre, Sepsis, schwer krank. Er erhielt das Antibiotikum nach vierzig Minuten und überlebte.

Hat die frühe Gabe ihm geholfen?

Die Frage ist klar gestellt und dennoch nicht zu beantworten. ***Um sie zu beantworten, müsste man wissen, was mit ihm geschehen wäre, hätte man länger gewartet*** *— und das kann niemand wissen, weil es diesen Patienten nur einmal gibt. Dieses Kapitel gibt der unbeobachtbaren Größe einen Namen, zeigt, warum sie für den Einzelnen unerreichbar bleibt, und unter welchen Bedingungen sie für eine Gruppe dennoch schätzbar ist.*

Definition 2.1 — potentielle Ergebnisse

Für jeden Patienten i und jede Behandlung x sei

$$Y_i(x)$$

das Ergebnis, das eintreten *würde*, wenn er die Behandlung x erhielte.
Bei zwei Behandlungen hat jeder Patient zwei solche Größen, $Y_i(1)$ und $Y_i(0)$, und der **individuelle Effekt** ist

$$\tau_i = Y_i(1) - Y_i(0).$$

Was daran neu ist

Bisher	Eine Zufallsgröße Y nimmt Werte an, und man fragt nach ihrer Verteilung, auch bedingt auf anderes.
Jetzt	Jeder Patient trägt *zwei* Werte in sich — einen für jede mögliche Behandlung. Beobachtbar ist immer nur einer.

Die Verbindung zum Beobachteten

$$Y_i = Y_i(X_i)$$

— das beobachtete Ergebnis ist dasjenige potentielle Ergebnis, das zur tatsächlich gegebenen Behandlung gehört. Diese Annahme heißt **Konsistenz**.

> *Sie klingt selbstverständlich und ist es nicht.* ***Sie verlangt, dass "die Behandlung" eindeutig bestimmt ist****: Wenn "früh" bei dem einen vierzig Minuten und bei dem anderen fünfzig heißt, so gibt es nicht ein $Y_i(1)$, sondern viele. Der Bruchfall kommt darauf zurück.*

Satz 2.2 — das grundlegende Problem

Der individuelle Effekt τ_i ist für keinen einzigen Patienten beobachtbar.

Begründung

Man beobachtet $Y_i(1)$ oder $Y_i(0)$, nie beides — der Patient wurde entweder früh behandelt oder nicht.

Patient	X_i	$Y_i(1)$	$Y_i(0)$
Herr K.	1	überlebt	?
Frau L.	0	?	gestorben

Die Hälfte der Tabelle fehlt — und zwar unvermeidlich, nicht aus Nachlässigkeit.

> ***Paul Holland*** *nannte das 1986 das "grundlegende Problem der kausalen Inferenz".* ***Es ist kein Messproblem, sondern ein begriffliches****: Die fehlende Größe existiert nicht als Tatsache über die Welt, sondern nur als Aussage darüber, was gewesen wäre. Man kann sie nicht nachmessen, auch nicht mit beliebigem Aufwand.*

2.2 Vom Einzelnen zur Gruppe

Definition 2.3 — Durchschnittseffekte

$\tau = \mathbb{E}[Y(1) - Y(0)]$	**Durchschnittseffekt** über alle.
$\tau_{\text{beh}} = \mathbb{E}[Y(1) - Y(0) \mid X = 1]$	**Effekt bei den Behandelten**.

Warum zwei Größen

τ	Was geschähe, wenn man *alle* behandelte? Die Frage einer Leitlinie.
τ_{beh}	Was hat die Behandlung denen gebracht, die sie erhalten haben? Die Frage einer Nachbetrachtung.

Beide fallen auseinander, sobald die Behandelten sich von den übrigen unterscheiden — also fast immer. ***Im Leitfall sind die Behandelten überwiegend schwer krank****; dort kann die Wirkung größer oder kleiner sein als bei den Leichtkranken. Aufgabe 2.1 rechnet beide aus und findet* $-0{,}25$ *gegen* $-0{,}375$*.*

2.3 Vier Annahmen

Was man braucht, um zu rechnen

Konsistenz	$Y_i = Y_i(X_i)$ — die Behandlung ist eindeutig bestimmt.
Keine Wechselwirkung	Die Behandlung des einen wirkt nicht auf das Ergebnis des anderen.
Positivität	In jeder Gruppe kommen beide Behandlungen vor: $0 < \Pr[X = 1 \mid Z] < 1$.
Bedingte Unabhängigkeit	$\big(Y(1), Y(0)\big) \perp X \mid Z$ — bei gleichem Z ist die Behandlung so gut wie ausgelost.

Nur die dritte Annahme lässt sich an den Daten prüfen.

Die erste ist eine Frage der Begriffsbildung, die zweite eine des Sachverhalts, die vierte eine des Fachwissens — und gerade die vierte trägt die ganze Last. ***Sie besagt, dass es außer*** Z ***keine gemeinsame Ursache von Behandlung und Ergebnis gibt****, und das ist genau die unprüfbare Annahme aus dem Bruchfall von Kapitel 1. Kapitel 6 gibt ihr eine grafische Gestalt, an der man sie wenigstens diskutieren kann.*

Satz 2.4 — die Anpassungsformel

Unter Konsistenz, Positivität und bedingter Unabhängigkeit gilt

$$\mathbb{E}\big[Y(x)\big] = \sum_{z} \mathbb{E}\big[Y \mid X = x,\ Z = z\big] \cdot \Pr[Z = z].$$

Beweis
Erstens — nach Z zerlegen (Satz von der totalen Erwartung, Band 4, Kapitel 9):

$$\mathbb{E}[Y(x)] = \sum_z \mathbb{E}[Y(x) \mid Z = z] \Pr[Z = z]$$

Zweitens — die Behandlung hinzunehmen: Nach der bedingten Unabhängigkeit ändert die Bedingung auf $X = x$ bei gegebenem $Z = z$ nichts an der Verteilung von $Y(x)$:

$$\mathbb{E}[Y(x) \mid Z = z] = \mathbb{E}[Y(x) \mid X = x,\ Z = z]$$

Damit dieser Ausdruck überhaupt definiert ist, braucht man die Positivität.
Drittens — Konsistenz: Unter denen mit $X = x$ ist $Y(x)$ das beobachtete Y:

$$\mathbb{E}[Y(x) \mid X = x,\ Z = z] = \mathbb{E}[Y \mid X = x,\ Z = z]$$

Einsetzen liefert die Behauptung. ■

Jede der drei Annahmen wird in genau einem Schritt gebraucht — und ohne sie bricht der Beweis an dieser Stelle ab.

***Das ist die Standardisierung aus Kapitel 1**, nun mit Begründung. Sie war dort eine plausible Rechnung; hier ist sie ein Satz mit angebbaren Voraussetzungen. Der Unterschied zwischen beidem ist der Gegenstand dieses Bandes.*

2.4 Der Bruchfall

Wechselwirkung: der Fall, in dem alles zusammenbricht

Die zweite Annahme — die Behandlung des einen wirke nicht auf das Ergebnis des anderen — ist bei ansteckenden Krankheiten falsch.

> *Wird ein Patient geimpft, so sinkt auch das Risiko seiner Nachbarn.* ***Dann gibt es nicht zwei potentielle Ergebnisse je Person, sondern eines für jede denkbare Belegung der ganzen Bevölkerung*** *— bei n Personen also 2^n. Definition 2.1 ist dann gar nicht anwendbar.*

Was man stattdessen tut

Gruppen bilden	Man randomisiert ganze Dörfer oder Stationen statt einzelner Personen.
Effekte trennen	Direkter Effekt der eigenen Impfung, indirekter Effekt der Impfung anderer.

> ***Der indirekte Effekt ist die Herdenwirkung aus Band 18, Kapitel 7.*** *Dort wurde sie als Eigenschaft des SIR-Modells hergeleitet; hier erscheint sie als Grund, warum ein ganzes Begriffsgebäude nicht greift. Bei Antibiotika kommt eine zweite Wechselwirkung hinzu: Die Resistenzlage einer Station hängt davon ab, wie andere Patienten behandelt wurden — Band 21, Kapitel 10.*

Konsistenz: was heißt "früh"?

Unscharf	"Innerhalb einer Stunde" umfasst fünf Minuten und neunundfünfzig.
Mit Begleitumständen	Wer früh behandelt wird, bekommt oft auch früher Flüssigkeit und mehr Aufmerksamkeit.

> *Der geschätzte Effekt gilt dann für das Bündel, nicht für das Antibiotikum allein.* ***Die Regel lautet: Man muss den Eingriff so genau beschreiben können, dass zwei Ärzte ihn gleich ausführen würden.*** *Bei Medikamenten gelingt das meist, bei Begriffen wie "Adipositas" oder "Stress" nicht — und deshalb sind kausale Aussagen über solche Größen schwer zu fassen.*

2.5 Übungsaufgaben

Aufgabe 2.1 — Die vollständige Tabelle

Für acht Patienten seien ausnahmsweise *beide* potentiellen Ergebnisse bekannt (1 bedeutet gestorben):

Nr.	Schwere	$Y(0)$	$Y(1)$	X	Y beob.
1	schwer	1	1	1	1
2	schwer	1	0	1	0
3	schwer	1	1	1	1
4	schwer	1	0	0	1
5	leicht	0	0	1	0
6	leicht	1	0	0	1
7	leicht	0	0	0	0
8	leicht	0	0	0	0

Berechnen Sie τ, τ_{beh}, den naiven Vergleich und die Anpassungsformel.

Lösung

Schritt 1 — Die individuellen Effekte

1	2	3	4	5	6	7	8
0	-1	0	-1	0	-1	0	0

Bei drei von acht Patienten rettet die Behandlung das Leben, bei fünf ändert sie nichts. Sie schadet niemandem.

Schritt 2 — Die Durchschnittseffekte

$$\tau = \frac{-3}{8} = -0{,}375$$

Behandelt sind 1, 2, 3, 5*:*

$$\tau_{\text{beh}} = \frac{0-1+0+0}{4} = -0{,}250$$

Unbehandelt sind 4, 6, 7, 8*:*

$$\tau_{\text{unbeh}} = \frac{-1-1+0+0}{4} = -0{,}500$$

Die Behandlung hätte bei den Unbehandelten doppelt so viel genützt wie bei den Behandelten. *Wer nur τ_{beh} berichtet, unterschätzt, was eine allgemeine Leitlinie brächte.*

Schritt 3 — Der naive Vergleich

$$\bar{Y}_{X=1} = \frac{1+0+1+0}{4} = 0{,}50, \qquad \bar{Y}_{X=0} = \frac{1+1+0+0}{4} = 0{,}50$$

$$\text{Unterschied} = 0$$

Der naive Vergleich zeigt gar keinen Effekt — der wahre ist $-0{,}375$.

Schritt 4 — Die Anpassungsformel

Gruppe	behandelt	unbehandelt	Anteil
schwer	$2/3 = 0{,}667$	$1/1 = 1{,}000$	0,5
leicht	$0/1 = 0{,}000$	$1/3 = 0{,}333$	0,5

$$\hat{\tau} = 0{,}5\,(0{,}667 - 1{,}000) + 0{,}5\,(0{,}000 - 0{,}333) = -0{,}167 - 0{,}167 = -0{,}333$$

Die Anpassung liefert $-0{,}333$ ***gegen einen wahren Wert von*** $-0{,}375$ *— der Rest ist Zufall der kleinen Stichprobe, nicht Verzerrung: In jeder Gruppe stehen nur ein bis drei Patienten. Bei* 1200 *Patienten wie in Kapitel 1 verschwindet dieser Unterschied.*

Aufgabe 2.2 — Die Annahme prüfen

Zeigen Sie an derselben Tabelle, dass die bedingte Unabhängigkeit hier tatsächlich gilt, und was geschähe, wenn sie verletzt wäre.

Lösung

Schritt 1 — Was zu prüfen ist

Innerhalb jeder Schweregruppe müssten Behandelte und Unbehandelte dieselben potentiellen Ergebnisse haben.

Gruppe	$\bar{Y}(0)$ behandelt	$\bar{Y}(0)$ unbehandelt
schwer	1,000	1,000
leicht	0,000	0,333

In der schweren Gruppe stimmen sie überein, in der leichten nicht ganz — 0,000 gegen 0,333.

Schritt 2 — Ist das eine Verletzung?

Nicht notwendig. Die leichte Gruppe umfasst vier Patienten, davon einen behandelten. ***Ein Unterschied von einem Drittel bei so wenigen Fällen ist mit Zufall vereinbar.*** *Die Annahme ist eine Aussage über die Verteilung, nicht über die Stichprobe — und genau deshalb lässt sie sich an der Stichprobe nicht widerlegen.*

Schritt 3 — Eine echte Verletzung

Man tausche die Behandlung der Patienten 5 und 6: Nun ist Patient 6 behandelt (er hätte ohne Behandlung $Y(0) = 1$) und Patient 5 nicht.

Gruppe	behandelt	unbehandelt	Anteil
schwer	0,667	1,000	0,5
leicht	$0/1 = 0{,}000$	$0/3 = 0{,}000$	0,5

$$\hat{\tau} = 0{,}5\,(-0{,}333) + 0{,}5\,(0{,}000) = -0{,}167$$

Derselbe wahre Effekt von $-0{,}375$, nun auf $-0{,}167$ geschätzt — weil innerhalb der leichten Gruppe gerade der Kränkere behandelt wurde.

Schritt 4 — Die Lehre

Die Anpassung an Z hilft nur, wenn Z alles enthält, wonach ausgewählt wurde. *Hier hat der Arzt innerhalb der leichten Gruppe nach etwas ausgewählt, das nicht in Z steht — vielleicht dem Aussehen des Patienten. Kein Rechenverfahren kann das bemerken; nur die Frage, woraufhin der Arzt entschieden hat.*

Aufgabe 2.3 — Positivität

In einer Klinik erhalten alle Schwerkranken das Antibiotikum früh. Was folgt daraus, und was geschieht bei 98 statt 100 Prozent?

Lösung

Schritt 1 — Bei hundert Prozent

In der Anpassungsformel steht für die schwere Gruppe der Ausdruck

$$\mathbb{E}[Y \mid X = 0,\ Z = \text{schwer}]$$

— ein Mittelwert über eine leere Menge.

Der Durchschnittseffekt ist nicht schätzbar. Nicht ungenau, sondern gar nicht.

Schritt 2 — Was trotzdem geht

Andere Zielgruppe	Der Effekt bei den Leichtkranken bleibt schätzbar.
Modellannahme	Man unterstellt, der Effekt sei in beiden Gruppen gleich, und überträgt. Das ist eine Annahme, keine Schätzung.

Schritt 3 — Bei achtundneunzig Prozent

Von 600 Schwerkranken sind 12 unbehandelt. Der Mittelwert über diese 12 hat die Streuung

$$\frac{\sigma}{\sqrt{12}} = \frac{0{,}5}{3{,}46} = 0{,}144$$

bei einem Anteil nahe 0,5.

Ein Vertrauensintervall von etwa ± 28 Prozentpunkten — für eine Gruppe, die die Hälfte des Gewichts trägt.

Schritt 4 — Die Verfahren aus Kapitel 8

Gewichtet man Patienten mit dem Kehrwert ihrer Behandlungswahrscheinlichkeit — Kapitel 8 —, so erhält jeder der zwölf das Gewicht $1/0{,}02 = 50$. ***Zwölf Patienten bestimmen dann die Hälfte des Ergebnisses****, und ein einzelner Todesfall verschiebt es um mehrere Prozentpunkte.*

Anteil behandelt	Gewicht
50 %	2
90 %	10
98 %	50

Die Positivität ist keine Ja-Nein-Eigenschaft, sondern eine Frage des Grades. *Je näher man ihrer Grenze kommt, desto mehr hängt das Ergebnis an wenigen Patienten — ein Übergang von Verzerrung zu Varianz, wie in Band 22, Kapitel 2. Die übliche Abhilfe ist, die Zielgruppe zu beschränken und den Effekt nur dort zu berichten, wo beide Behandlungen tatsächlich vorkommen.*

Eine Notation aus der Landwirtschaft

Jerzy Neyman führte die potentiellen Ergebnisse 1923 in seiner Doktorarbeit ein — für Feldversuche mit Kartoffelsorten.

Er schrieb den Ertrag jeder Parzelle für jede mögliche Sorte an und behandelte die Zuteilung als Ziehung ohne Zurücklegen. ***Die Arbeit erschien auf Polnisch und blieb sechzig Jahre unbeachtet****; erst 1990 wurde sie ins Englische übersetzt.*

Rubin

Donald Rubin griff die Notation 1974 auf und übertrug sie auf Beobachtungsdaten.

Sein Beitrag war die Einsicht, dass man dieselbe Sprache benutzen kann, wenn nicht das Los, sondern ein Arzt entscheidet — sofern man angeben kann, woraufhin er entschieden hat. ***Das Gebäude heißt heute nach Neyman und Rubin****, und die vier Annahmen dieses Kapitels stammen im Wesentlichen aus seinen Arbeiten der 1970er und 1980er Jahre.*

Holland

Paul Holland *fasste 1986 den Stand in einem Aufsatz zusammen, der den Satz enthält, „keine Ursache ohne Manipulation“.* ***Danach wären Aussagen wie „sie wurde wegen ihres Geschlechts nicht befördert“ keine kausalen Aussagen****, weil man das Geschlecht nicht zuteilen kann. Der Satz ist seither heftig umstritten; die heutige Mehrheitsmeinung hält ihn für zu eng, verlangt aber, dass man genau angibt, welcher Eingriff gemeint ist.*

Effekte heute

Schranken	Was sich über den Effekt sagen lässt, wenn die Annahmen *nicht* gelten.
Empfindlichkeit	Wie stark eine unbeobachtete Störgröße wirken müsste, um das Ergebnis umzukehren.
Wechselwirkung	Effekte in Netzwerken, wo die Nachbarn mitwirken.

Zur zweiten Zeile

Statt die bedingte Unabhängigkeit zu behaupten, fragt man: Wie stark müsste eine unbeobachtete Größe mit Behandlung und Ergebnis zusammenhängen, damit der geschätzte Effekt verschwindet? ***Für den Zusammenhang zwischen Rauchen und Lungenkrebs hätte eine solche Größe das Risiko verneunfachen müssen*** *— ein Argument, das* ***Jerome Cornfield*** *1959 gegen Fisher vorbrachte und das heute in verfeinerter Form Standard ist.*

Was Sie jetzt können

Definition 2.1	zwei Werte je Patient, einer sichtbar
Satz 2.2	der individuelle Effekt bleibt unbekannt
Definition 2.3	τ und τ_{beh} fallen auseinander
Vier Annahmen	nur die Positivität ist prüfbar
Satz 2.4	Anpassungsformel, dreimal begründet

Die schwierigste Annahme war die bedingte Unabhängigkeit. Das nächste Kapitel zeigt den einen Fall, in dem sie nicht behauptet, sondern hergestellt wird — durch das Los.

Kapitel 3

Das Los

3.1 Die Annahme herstellen

Der Unterschied zu Kapitel 2

Die bedingte Unabhängigkeit war dort eine Behauptung über die Welt — unprüfbar, begründet allenfalls durch Fachwissen.

> **Wird die Behandlung ausgelost, so ist sie keine Behauptung mehr, sondern eine Tatsache über das Vorgehen.**
>
> *Das Los weiß nichts über den Patienten. Es kann sich also weder nach dem Schweregrad richten noch nach dem Alter, nach Vorerkrankungen, nach dem Aussehen — **auch nicht nach Größen, die niemand gemessen hat und an die niemand gedacht hat.** Darin liegt die ganze Leistung der Randomisierung, und keine noch so sorgfältige Anpassung an gemessene Größen kann sie ersetzen.*

Satz 3.1 — warum das Los genügt

Wird X unabhängig von allem Übrigen ausgelost, so gilt

$$\big(Y(1),\, Y(0)\big) \;\perp\; X$$

und damit

$$\mathbb{E}[Y \mid X = 1] - \mathbb{E}[Y \mid X = 0] = \tau.$$

Beweis

Erstens: Die potentiellen Ergebnisse $Y_i(1)$ und $Y_i(0)$ sind Eigenschaften des Patienten, die vor der Zuteilung feststehen. Das Los wird unabhängig davon gezogen, also sind X und das Paar unabhängig.
Zweitens: Wegen dieser Unabhängigkeit

$$\mathbb{E}[Y(1) \mid X = 1] = \mathbb{E}[Y(1)], \qquad \mathbb{E}[Y(0) \mid X = 0] = \mathbb{E}[Y(0)].$$

Drittens — Konsistenz: Unter $X = 1$ ist das beobachtete Y gleich $Y(1)$, unter $X = 0$ gleich $Y(0)$:

$$\mathbb{E}[Y \mid X = 1] = \mathbb{E}[Y(1)], \qquad \mathbb{E}[Y \mid X = 0] = \mathbb{E}[Y(0)]$$

Subtrahieren:

$$\mathbb{E}[Y \mid X = 1] - \mathbb{E}[Y \mid X = 0] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \tau$$

■

Der naive Vergleich, der in Kapitel 1 das Vorzeichen verfehlte, ist nach einer Randomisierung genau richtig.

Man beachte, was hier nicht gebraucht wird: keine Angabe darüber, welche Störgrößen es gibt, keine Anpassung, kein Modell. ***Die Randomisierung ersetzt die unprüfbare Annahme durch eine Handlung*** *— und das ist der Grund, warum die randomisierte Studie als Goldstandard gilt.*

3.2 Was das Los nicht kann

Ungleichgewicht bleibt möglich

Das Los erzeugt keine gleichen Gruppen — es erzeugt Gruppen, deren Unterschiede zufällig sind.

Im Mittel	gleich — über viele Wiederholungen der Studie.
In dieser Studie	womöglich deutlich verschieden, gerade bei kleinen Fallzahlen.

Bei 30 Patienten je Arm und einem Schwerkrankenanteil von 30 Prozent beträgt die Streuung der Differenz beider Anteile rund 12 Prozentpunkte — ein Unterschied von 20 Punkten ist keine Seltenheit. ***Satz 3.1 gilt trotzdem****: Die Schätzung ist unverzerrt, nur streut sie. Der Unterschied zwischen Verzerrung und Varianz ist hier so wichtig wie in Band 22, Kapitel 2.*

Zwei Gegenmittel

Schichten	Man lost getrennt innerhalb der Schwer- und der Leichtkranken. Das Ungleichgewicht in dieser Größe wird ausgeschlossen.
Anpassen	Man rechnet die Schichtzugehörigkeit nachträglich heraus — nicht gegen Verzerrung, sondern gegen Streuung.

In der randomisierten Studie dient die Anpassung einem ganz anderen Zweck als in Kapitel 1. *Dort behob sie eine Verzerrung, hier verringert sie eine Streuung: Wenn man weiß, dass der Schweregrad stark wirkt, so erklärt er einen Teil der Schwankung, und der Rest lässt sich genauer schätzen. Welche Größen man dafür heranzieht, muss vor der Auswertung festgelegt werden — sonst entsteht das Problem des multiplen Testens aus Band 17, Kapitel 13.*

3.3 Wie groß muss die Studie sein?

Die Fallzahl

Aus Band 17, Kapitel 6: Für zwei Anteile p_0 und p_1 braucht man je Gruppe

$$n = \frac{\left(z_{1-\alpha/2} + z_{1-\beta}\right)^2 \left[p_0(1-p_0) + p_1(1-p_1)\right]}{(p_0 - p_1)^2}.$$

Der Leitfall

Nach Kapitel 1: $p_0 = 0{,}325$ ohne frühe Gabe, $p_1 = 0{,}250$ mit. Zweiseitig $\alpha = 0{,}05$, Trennschärfe 80 Prozent.

$$n = \frac{(1{,}960 + 0{,}842)^2 \cdot (0{,}2194 + 0{,}1875)}{0{,}075^2} = \frac{7{,}849 \cdot 0{,}4069}{0{,}005625} = 568$$

gesuchter Effekt	je Gruppe	gesamt
10 Punkte	310	620
7,5 Punkte	568	1136
5 Punkte	1315	2630

Halbiert man den gesuchten Effekt, so vervierfacht sich die Fallzahl.

Die 1200 Patienten des Klinikums hätten also für eine Studie ausgereicht — wenn man sie ausgelost hätte. ***Dieselbe Datenmenge, die als Beobachtung das Vorzeichen verfehlte, hätte als Versuch die richtige Antwort geliefert.*** *Der Unterschied liegt nicht in der Zahl, sondern darin, wer die Behandlung bestimmt hat.*

3.4 Der Bruchfall

Wenn nicht alle tun, was ausgelost wurde

Wird die frühe Gabe ausgelost, so heißt das nicht, dass sie auch erfolgt. Bei manchen Patienten verzögert sich die Diagnose, bei anderen fehlt der Zugang.

Ein Zahlenbeispiel

Je 1000 Patienten, 30 Prozent schwer krank. Im Arm "früh" erhalten 200 der 300 Schwerkranken das Antibiotikum dennoch spät.

Auswertung	Effekt	
wahrer Effekt	−6,5 Punkte	
nach Zuteilung	−4,5 Punkte	zu klein
nach Behandlung	−11,8 Punkte	zu groß

Die eine Auswertung unterschätzt den Effekt, die andere überschätzt ihn fast um das Doppelte.

Warum

Nach Zuteilung	Ein Teil des Arms wurde gar nicht früh behandelt. Der Effekt wird verdünnt — aber die Auswertung bleibt unverzerrt für die Frage: "Was bringt die Anordnung?"
Nach Behandlung	Man vergleicht wieder zwei selbst gewählte Gruppen: Die tatsächlich früh Behandelten sind die Leichtkranken. Die Randomisierung ist aufgehoben.

Die Auswertung nach Zuteilung heißt Behandlungsabsicht und ist der Standard klinischer Studien. *Sie beantwortet nicht die Frage nach der Wirkung des Medikaments, sondern die nach der Wirkung der Anordnung — und das ist für eine Leitlinie oft die richtigere Frage. Die Auswertung nach tatsächlicher Behandlung sieht genauer aus und ist es nicht; Kapitel 9 zeigt, wie man aus derselben Studie dennoch den Behandlungseffekt gewinnt.*

Und vier weitere Grenzen

Übertragbarkeit	Studienteilnehmer sind jünger, gesünder und besser überwacht als die Patienten im Alltag.
Ethik	Auslosen ist nur zulässig, wenn ernsthaft offen ist, was besser wirkt. Bei einer Leitlinienempfehlung ist das nicht mehr der Fall.
Zeit und Kosten	Eine Studie über seltene Ausgänge dauert Jahre.
Unmöglichkeit	Rauchen, Armut, Geburtsgewicht lassen sich nicht zuteilen.

Die zweite Zeile ist ein Zirkel, der die Medizin durchzieht: ***Sobald eine Behandlung als überlegen gilt, darf man sie nicht mehr prüfen*** *— auch wenn die Überlegenheit auf schwacher Evidenz beruht. Bei der frühen Antibiotikagabe ist genau das eingetreten. Deshalb behandeln die Teile III und IV dieses Bandes Verfahren, die aus Beobachtungsdaten arbeiten: nicht weil sie besser wären, sondern weil es oft keine Alternative gibt.*

3.5 Übungsaufgaben

Aufgabe 3.1 — Dieselben Patienten, ausgelost

Man nehme die 1200 Patienten aus Kapitel 1 mit denselben Risiken — schwer: 40 gegen 50 Prozent, leicht: 10 gegen 15 — und lose die Behandlung aus. Welche Tabelle ergibt sich, und was zeigt der naive Vergleich?

Lösung

Schritt 1 — Die Aufteilung

Bei Auslosung erhält in jeder Gruppe die Hälfte die frühe Gabe:

	früh		**spät**	
	n	**tot**	*n*	**tot**
schwer	300	120	300	150
leicht	300	30	300	45
Summe	600	**150**	600	**195**

Schritt 2 — Der naive Vergleich

$$\frac{150}{600} - \frac{195}{600} = 0{,}250 - 0{,}325 = -0{,}075$$

Genau der kausale Effekt aus Kapitel 1 — ohne jede Anpassung.

Schritt 3 — Woran es liegt

Anteil schwer	**früh**	**spät**
Beobachtung (Kap. 1)	83,3 %	16,7 %
Randomisierung	50,0 %	50,0 %

Die Risiken je Gruppe sind in beiden Fällen dieselben — nur die Mischung ist verschieden. *In Kapitel 1 verglich man 83 Prozent Schwerkranke mit 17 Prozent; hier 50 mit 50. Die Anpassungsformel stellt diese Gleichheit rechnerisch her, das Los tatsächlich.*

Schritt 4 — Eine Probe

Die Anpassungsformel auf die randomisierte Tabelle angewandt:

$$0{,}5\,(0{,}40 - 0{,}50) + 0{,}5\,(0{,}10 - 0{,}15) = -0{,}050 - 0{,}025 = -0{,}075 \quad \checkmark$$

Sie liefert dasselbe wie der naive Vergleich. ***Nach einer Randomisierung schadet die Anpassung nicht, sie ändert nur nichts am Erwartungswert*** *— wohl aber an der Streuung, wie Abschnitt 3.2 sagt.*

Aufgabe 3.2 — Die Fallzahl

Wie viele Patienten braucht man, um eine Senkung der Sterblichkeit von 32,5 auf 25,0 Prozent nachzuweisen? Und wie ändert sich das bei 90 Prozent Trennschärfe?

Lösung

Schritt 1 — Die Bestandteile

Größe	Wert	
$z_{0{,}975}$	1,960	$\alpha = 0{,}05$
$z_{0{,}80}$	0,842	Trennschärfe 80 %
$p_0(1-p_0)$	0,2194	
$p_1(1-p_1)$	0,1875	
$(p_0-p_1)^2$	0,005625	

Schritt 2 — Einsetzen

$$n = \frac{(2{,}802)^2 \cdot 0{,}4069}{0{,}005625} = \frac{7{,}849 \cdot 0{,}4069}{0{,}005625} = \frac{3{,}194}{0{,}005625} = 567{,}7$$
$$\Longrightarrow \; n = 568 \text{ je Gruppe}, \quad 1136 \text{ insgesamt}$$

Schritt 3 — Mit neunzig Prozent Trennschärfe

$z_{0{,}90} = 1{,}282$:

$$n = \frac{(1{,}960 + 1{,}282)^2 \cdot 0{,}4069}{0{,}005625} = \frac{10{,}51 \cdot 0{,}4069}{0{,}005625} = 760$$

Trennschärfe	je Gruppe	Zuwachs
80 %	568	—
90 %	760	+34 %

Schritt 4 — Und mit Ausfällen

Rechnet man mit 20 Prozent Abbrechern, so braucht man

$$\frac{568}{0{,}8} = 710 \text{ je Gruppe.}$$

> ***Diese Aufstockung deckt nur den Verlust an Fällen, nicht die Verdünnung des Effekts*** *durch Patienten, die die zugeteilte Behandlung nicht erhalten. Nach dem Bruchfall beträgt der beobachtbare Effekt dann nur noch $-4{,}5$ statt $-6{,}5$ Punkte — und für einen kleineren Effekt braucht man nach Schritt 2 quadratisch mehr Patienten. Wer beides übersieht, plant eine Studie, die ihr Ziel nicht erreichen kann.*

Aufgabe 3.3 — Zuteilung oder Behandlung

Rechnen Sie den Bruchfall nach: je 1000 Patienten, 30 Prozent schwer krank, im Arm "früh" erhalten 200 der 300 Schwerkranken dennoch spät.

Lösung

Schritt 1 — Arm "früh"

Gruppe	n	Risiko	tot
schwer, früh	100	0,40	40
schwer, spät	200	0,50	100
leicht, früh	700	0,10	70
Summe	1000		**210**

Schritt 2 — Arm "spät"

$$300 \cdot 0{,}50 + 700 \cdot 0{,}15 = 150 + 105 = 255$$

Schritt 3 — Nach Zuteilung

$$\frac{210}{1000} - \frac{255}{1000} = -0{,}045$$

Schritt 4 — Der wahre Effekt

$$\big(0{,}3 \cdot 0{,}40 + 0{,}7 \cdot 0{,}10\big) - \big(0{,}3 \cdot 0{,}50 + 0{,}7 \cdot 0{,}15\big) = 0{,}190 - 0{,}255 = -0{,}065$$

Schritt 5 — Woher die Verdünnung kommt

Gruppe	n	Effekt	Beitrag
schwer, früh	100	$-0{,}10$	-10
schwer, spät	200	0	0
leicht, früh	700	$-0{,}05$	-35
	1000		$\mathbf{-45}$

$$-\frac{45}{1000} = -0{,}045 \quad \checkmark$$

Die 200 **Wechsler tragen nichts bei — sie wurden behandelt wie der Vergleichsarm.**

Schritt 6 — Nach tatsächlicher Behandlung

Die 800 tatsächlich früh Behandelten:

$$\frac{40+70}{800} = \frac{110}{800} = 0{,}1375$$

$$0{,}1375 - 0{,}255 = -0{,}1175$$

Fast das Doppelte des wahren Effekts. *Die 800 bestehen zu 87,5 Prozent aus Leichtkranken, der Vergleichsarm nur zu 70 — man vergleicht wieder zwei verschiedene Bevölkerungen.* ***Die Randomisierung ist durch die Auswahl nach dem Los wieder verlorengegangen****, und zwar durch eine Auswahl, die nach der Zuteilung stattfand. Merkregel: Man darf nach nichts auswählen, was dem Los zeitlich folgt.*

Vom Teeversuch zur Streptomycinstudie

Ronald Fisher beschrieb 1935 in *The Design of Experiments* die Randomisierung als Grundlage jedes Versuchs — eingeleitet durch das Beispiel einer Dame, die behauptete, am Geschmack zu erkennen, ob der Tee vor oder nach der Milch eingegossen wurde.

Fishers Punkt war, dass die Reihenfolge der Tassen ausgelost werden muss — sonst ließe sich jedes Ergebnis auf eine Regelmäßigkeit im Aufbau schieben. ***Er entwickelte die Idee in der Agrarforschung****, wo Bodenunterschiede die Ernteversuche verfälschten, und übertrug sie nie selbst auf die Medizin.*

Die erste moderne Studie

Austin Bradford Hill leitete 1946 die Streptomycinstudie des britischen Medical Research Council zur Behandlung der Lungentuberkulose.

Die Zuteilung erfolgte durch versiegelte Umschläge nach einer Zufallsliste, die der behandelnde Arzt nicht kannte. ***Hill begründete die Randomisierung damals weniger statistisch als praktisch****: Sie schütze den Arzt vor dem Vorwurf, die Auswahl beeinflusst zu haben. Der Umstand, dass Streptomycin knapp war und nicht alle Kranken behandelt werden konnten, machte den Versuch überhaupt erst vertretbar.*

Und der Streit um die Absicht

Die Auswertung nach Behandlungsabsicht setzte sich erst in den 1980er Jahren durch. ***Sie erschien vielen Ärzten widersinnig****: Warum soll man Patienten, die das Medikament nie erhielten, der Medikamentengruppe zurechnen? Die Antwort steht im Bruchfall — und der Streit flammt bei jeder Studie neu auf, in der viele Teilnehmer wechseln.*

Versuche heute

Angepasste Aufbauten	Studien, die Zuteilungswahrscheinlichkeiten während des Verlaufs ändern.
Pragmatische Studien	Randomisierung im Klinikalltag statt unter Studienbedingungen.
Gruppenversuche	Ganze Stationen werden ausgelost — gegen die Wechselwirkung aus Kapitel 2.

Zur zweiten Zeile

Eine pragmatische Studie lost innerhalb der gewöhnlichen Versorgung, ohne Ausschlusskriterien und ohne zusätzliche Überwachung. ***Sie beantwortet die Frage, die die Klinik wirklich hat*** *— wirkt es bei meinen Patienten? — und erkauft das mit unschärferer Behandlung und mehr Wechslern. Die Übertragbarkeit steigt, die Konsistenz aus Kapitel 2 leidet.*

Was Sie jetzt können

Satz 3.1	das Los macht den naiven Vergleich richtig
Auch Unbekanntes	keine Anpassung leistet das
Anpassen	gegen Streuung, nicht gegen Verzerrung
Fallzahl	halber Effekt, vierfache Zahl
Der Bruchfall	Zuteilung ehrlich, Behandlung verzerrt

Damit endet Teil I. Wo ausgelost werden kann, ist die Sache entschieden. Teil II wendet sich dem Fall zu, in dem das nicht geht — und braucht dafür eine Sprache, in der sich Annahmen über Ursachen aufschreiben lassen: Graphen.

Teil II

Graphen und Regeln

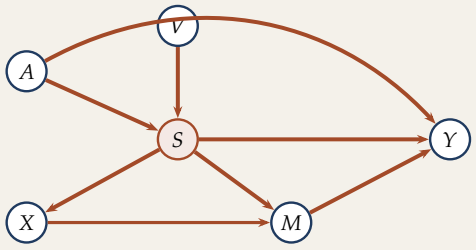
Kapitel 4

Annahmen aufschreiben

4.1 Der Leitfall als Bild

Was man über Neustadt weiß

	Größe	hängt ab von
A	Alter über 70	—
V	Vorerkrankungen	—
S	Schweregrad	A, V
X	frühe Antibiotikagabe	S
M	Organversagen	S, X
Y	Tod	A, S, M



Jeder Pfeil ist eine Annahme. Jeder *fehlende* Pfeil ist auch eine — und die schwerer wiegende.

*Dass kein Pfeil von A nach X führt, besagt: **Das Alter beeinflusst die Entscheidung über den Zeitpunkt nur über den Schweregrad** — bei gleich schwer Kranken behandelt man Alte nicht anders als Junge. Das ist eine inhaltliche Behauptung, die man bestreiten kann und die man prüfen sollte. Ein Graph macht solche Behauptungen sichtbar; eine Regressionsgleichung versteckt sie.*

Definition 4.1 — kausaler Graph

Ein **kausaler Graph** ist ein gerichteter, kreisfreier Graph (Band 16, Kapitel 2), dessen Knoten die Größen sind. Ein Pfeil $U \to W$ bedeutet: U ist eine *unmittelbare* Ursache

von W.
Dazu gehört ein **strukturelles Gleichungsmodell**: Jede Größe wird durch ihre Elternknoten und eine eigene Zufallsgröße bestimmt,

$$W = f_W\big(\text{Eltern}(W),\ \varepsilon_W\big),$$

wobei die ε voneinander unabhängig sind.

Satz 4.2 — die Faktorisierung

Erfüllt eine Verteilung ein solches Modell, so gilt

$$\Pr[v_1, \ldots, v_k] = \prod_{i=1}^{k} \Pr\big[v_i \mid \text{Eltern}(v_i)\big].$$

Was das erspart

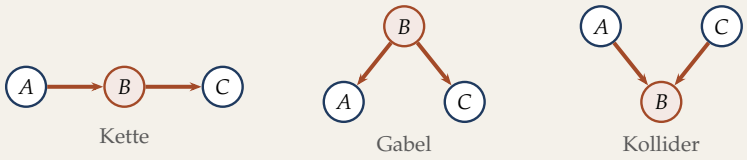
Größen	volle Tabelle	Leitfall-Graph
6	63	**20**
10	1023	
20	1 048 575	

Zur rechten Spalte: $2^0 + 2^0 + 2^2 + 2^1 + 2^2 + 2^3 = 1 + 1 + 4 + 2 + 4 + 8 = 20$.

> ***Die Ersparnis ist nicht der Zweck, sondern ein Nebengewinn.*** *Der Zweck ist, dass man die Annahmen einzeln hinschreiben und einzeln bestreiten kann. Aber die Ersparnis erklärt, warum sich solche Modelle auch dort durchgesetzt haben, wo es gar nicht um Ursachen geht — in Band 22 etwa als Grundlage wahrscheinlichkeitstheoretischer Lernverfahren.*

4.2 Drei Bausteine

Jeder Weg besteht aus diesen drei



Baustein	ohne Bedingung	gegeben B
Kette	A, C abhängig	unabhängig
Gabel	A, C abhängig	unabhängig
Kollider	unabhängig	abhängig

Beim Kollider ist alles umgekehrt: Er sperrt von selbst und öffnet, sobald man auf ihn bedingt.

Die dritte Zeile ist die Berkson-Verzerrung aus Aufgabe 1.2, nun als Baustein. ***Und sie gilt auch, wenn man auf einen Nachkommen des Kolliders bedingt*** *— wer nach einem Merkmal auswählt, das vom Kollider abhängt, öffnet den Weg ebenfalls, wenn auch schwächer.*

Definition 4.3 — d-Trennung

Ein Weg zwischen zwei Knoten heißt **gesperrt** durch eine Menge Z, wenn er einen Knoten enthält, der

1	eine Kette oder Gabel bildet und in Z liegt, oder
2	ein Kollider ist und weder selbst noch einer seiner Nachkommen in Z liegt.

Zwei Knoten heißen **d-getrennt** durch Z, wenn *jeder* Weg zwischen ihnen gesperrt ist.

Satz 4.4 — was d-Trennung bedeutet

Sind U und W durch Z d-getrennt, so sind sie in jeder Verteilung, die zum Graphen passt, bedingt unabhängig gegeben Z.

Der Beweis führt über die Faktorisierung aus Satz 4.2 und eine Induktion über die Wege; wir verzichten auf ihn — die erste Auslassung dieses Bandes; die Fundstelle ist Pearl[18], Kapitel 1. ***Die Umkehrung gilt fast immer****: Sind zwei Knoten nicht d-getrennt, so sind sie für fast alle zum Graphen passenden Verteilungen abhängig — Ausnahmen entstehen nur bei exakt sich aufhebenden Wirkungen.*

Ein Bild wird damit zu einer Rechenvorschrift: Man liest Unabhängigkeiten ab, statt sie zu prüfen.

4.3 Am Leitfall geprüft

Vier Fragen, abgelesen und nachgerechnet

400 000 erzeugte Patienten nach dem Modell aus Abschnitt 4.1:

Frage	Korrelation	abgelesen
X und A roh	$+0{,}188$	abhängig über S
X und A gegeben S	$-0{,}002$	d-getrennt
A und V roh	$-0{,}001$	unabhängig
A und V gegeben S	$\mathbf{-0{,}107}$	Kollider geöffnet

Zur zweiten Zeile

Es gibt zwei Wege von X nach A:

$X \leftarrow S \leftarrow A$	Kette über S — durch S gesperrt.
$X \leftarrow S \rightarrow M \rightarrow Y \leftarrow A$	Kollider Y — von selbst gesperrt.

Beide gesperrt, also d-getrennt — und die Korrelation fällt von 0,188 auf $-0{,}002$. ✓

Zur vierten Zeile

A und V haben keine gemeinsame Ursache und keinen Pfeil zueinander — sie sind unabhängig, und die Rechnung bestätigt es.

> **Bedingt man auf den Schweregrad, so wird aus Unabhängigkeit eine Korrelation von $-0{,}107$.**
>
> *S ist ein Kollider von A und V. **Unter den Schwerkranken erklärt das hohe Alter den Schweregrad — also braucht es die Vorerkrankungen nicht mehr**, und umgekehrt. Wer den Schweregrad "herausrechnet", erzeugt damit einen Zusammenhang zwischen Alter und Vorerkrankungen, den es in der Bevölkerung nicht gibt. Kapitel 5 zeigt, wann das schadet.*

4.4 Der Bruchfall

Der Graph ist nicht in den Daten

Gleiche Muster	Mehrere Graphen erzeugen genau dieselben Unabhängigkeiten. Die Daten können zwischen ihnen nicht entscheiden.
Verborgene Größen	Was nicht gemessen ist, fehlt im Graphen — und verändert alle Schlüsse.
Kreise	Rückkopplungen — Fieber erhöht Herzfrequenz erhöht Fieber — sind in einem kreisfreien Graphen nicht darstellbar.

Zur ersten Zeile

Graph	$X \perp Y$?	$X \perp Y \mid S$?
$X \to S \to Y$	nein	ja
$X \leftarrow S \leftarrow Y$	nein	ja
$X \leftarrow S \to Y$	nein	ja
$X \to S \leftarrow Y$	ja	nein

Die ersten drei sind an den Daten nicht zu unterscheiden — der vierte schon.

Das ist Satz 1.2 in grafischer Gestalt. *Die Daten legen das Gerüst fest — welche Knoten verbunden sind — und die Kollider; die übrigen Pfeilrichtungen nicht. Man nennt die Menge der ununterscheidbaren Graphen eine* ***Markow-Äquivalenzklasse****. Immerhin sind Kollider erkennbar, und das ist mehr, als Kapitel 1 vermuten ließ; Abschnitt 4.5 des Forschungskastens nutzt es aus.*

Zur zweiten Zeile

Nimmt man im Leitfall eine unbeobachtete Größe an — etwa die Erfahrung des diensthabenden Arztes, die sowohl den Zeitpunkt als auch die weitere Behandlung beeinflusst —, so entsteht ein zusätzlicher Weg von X nach Y, den keine Anpassung an S sperrt. ***Man zeichnet solche Größen als gestrichelte Doppelpfeile ein****, und Kapitel 6 sagt, wann sie schaden und wann nicht.*

4.5 Übungsaufgaben

Aufgabe 4.1 — Wege sperren

Im Graphen des Leitfalls: Welche der folgenden Aussagen gelten?

(a)	$V \perp Y \mid S$
(b)	$X \perp Y \mid S$
(c)	$X \perp A \mid S, M$

Lösung

(a) — Wege von V nach Y

Weg	**gegeben S**
$V \to S \to Y$	Kette, gesperrt
$V \to S \to M \to Y$	Kette, gesperrt
$V \to S \to X \to M \to Y$	Kette, gesperrt
$V \to S \leftarrow A \to Y$	S ist Kollider, geöffnet

(a) gilt nicht. Der letzte Weg wird durch das Bedingen auf S gerade geöffnet.

Inhaltlich: Unter Schwerkranken sind die ohne Vorerkrankungen eher die Alten — und Alter erhöht die Sterblichkeit unmittelbar. So entsteht ein Zusammenhang zwischen V und Y.

(b) — Wege von X nach Y

Weg	**gegeben S**
$X \to M \to Y$	offen — das ist die Wirkung
$X \leftarrow S \to Y$	gesperrt
$X \leftarrow S \to M \to Y$	gesperrt

(b) gilt nicht — und soll es auch nicht. Der offene Weg ist der ursächliche; genau ihn will man messen.

Die Rechnung ergab $-0{,}021$ — klein, aber von null verschieden: die Schutzwirkung der frühen Gabe.

(c) — mit M im Bedingungssatz

Weg	**gegeben S und M**
$X \leftarrow S \leftarrow A$	gesperrt durch S
$X \to M \leftarrow S \to \dots$	—
$X \to M \to Y \leftarrow A$	M in Z: offen; Y Kollider: gesperrt

(c) gilt. Alle Wege bleiben gesperrt.

*Hier ist das Bedingen auf M unschädlich für diese Frage — **aber es wäre schädlich für die Schätzung des Effekts von X auf Y**, weil es den ursächlichen Weg $X \to M \to Y$ durchschneidet. Dieselbe Größe kann für die eine Frage harmlos und für die andere verheerend sein. Kapitel 5 macht daraus eine Systematik.*

Aufgabe 4.2 — Wie viele Zahlen

Wie viele Wahrscheinlichkeiten braucht man für die gemeinsame Verteilung von zehn binären Größen — ohne Graph, und mit einem Graphen, in dem jede Größe höchstens drei Eltern hat?

Lösung

Schritt 1 — Ohne Graph

$$2^{10} - 1 = 1023$$

Schritt 2 — Mit Graph

Je Größe braucht man eine Wahrscheinlichkeit für jede Belegung der Eltern:

$$\sum_{i=1}^{10} 2^{|\text{Eltern}(i)|} \;\leq\; 10 \cdot 2^3 = 80$$

Größen	**ohne Graph**	**höchstens** 3 **Eltern**
10	1023	≤ 80
20	$\approx 10^6$	≤ 160
50	$\approx 10^{15}$	≤ 400

Schritt 3 — Die Bedeutung

> *Die volle Tabelle wächst exponentiell, das Modell linear.* ***Bei fünfzig Größen bräuchte man mehr Patienten, als es Menschen gibt*** *— mit Graph genügen einige tausend. Das ist derselbe Gewinn wie in Band 22, Kapitel 10: Eine Annahme über die Struktur macht aus einer unmöglichen Aufgabe eine lösbare.*

Schritt 4 — Der Preis

> *Man bezahlt mit der Richtigkeit der Struktur.* ***Fehlt ein Pfeil, den es gibt, so ist das Modell falsch — und zwar ohne dass ein Rechenverfahren das bemerkte.*** *Zu viele Pfeile schaden dagegen nur der Genauigkeit, nicht der Gültigkeit. Im Zweifel zeichnet man den Pfeil ein.*

Aufgabe 4.3 — Was die Daten verraten

Man beobachte an drei Größen: X und Y sind abhängig, X und S sind abhängig, S und Y sind abhängig — aber $X \perp Y \mid S$. Welche Graphen kommen in Frage?

Lösung

Schritt 1 — Das Gerüst

Alle drei Paare hängen zusammen, aber X und Y werden durch S getrennt. Also gibt

es keinen Pfeil zwischen X und Y:

$$X - S - Y$$

Schritt 2 — Die möglichen Richtungen

Graph	Art	$X \perp Y \mid S$?
$X \to S \to Y$	Kette	ja
$X \leftarrow S \leftarrow Y$	Kette	ja
$X \leftarrow S \to Y$	Gabel	ja
$X \to S \leftarrow Y$	Kollider	nein

Drei Graphen bleiben übrig. Der Kollider ist ausgeschlossen.

Schritt 3 — Was das praktisch heißt

Kette	X wirkt auf Y — über S. Eingriff in X hilft.
Gabel	S verursacht beides. Eingriff in X hilft nicht.

Die Daten entscheiden nicht, ob ein Eingriff hilft *— genau wie in Satz 1.2. Was sie entscheiden, ist eine Teilfrage: Sie schließen den Kollider aus. Und manchmal genügt Wissen über die Zeit: Liegt X zeitlich vor S, so sind die letzten beiden Zeilen ausgeschlossen, und es bleibt die Kette.*

Schritt 4 — Im Leitfall

Dort ist die Richtung klar: Der Schweregrad besteht bei Aufnahme, die Gabe erfolgt danach. ***Die Zeitordnung ist die wichtigste Quelle kausalen Wissens*** *— und der Grund, warum man bei jeder Größe festhalten sollte, wann sie erhoben wurde. Das war bereits die Lehre aus Band 22, Kapitel 3, wo ein Merkmal aus der Zukunft das Modell verdarb.*

Von den Pfadkoeffizienten zu den Graphen

Sewall Wright (1889–1988) führte 1918 die Pfadanalyse ein — für die Vererbung der Fellzeichnung bei Meerschweinchen.

Er zeichnete gerichtete Diagramme und gab Regeln an, wie sich Korrelationen aus den Pfadkoeffizienten zusammensetzen. ***Die Statistik seiner Zeit lehnte das ab****: Wrights Lehrer* ***Karl Pearson*** *und später* ***Ronald Fisher*** *hielten Kausalaussagen aus Beobachtungsdaten für unwissenschaftlich. Wrights Verfahren überlebte in der Genetik und in der Soziologie, nicht in der Statistik.*

Pearl

Judea Pearl entwickelte in den 1980er Jahren Bayessche Netze für die künstliche Intelligenz — zunächst ohne kausale Deutung, als Werkzeug zum effizienten Rechnen mit Wahrscheinlichkeiten.

*Die d-Trennung stammt aus dieser Arbeit. **Erst um 1990 zog er die Folgerung, dass dieselben Graphen Ursachen darstellen können**, wenn man die Pfeile ernst nimmt und den Eingriff als Durchtrennen deutet. Sein Buch Causality von 2000 machte daraus ein geschlossenes Gebäude; 2011 erhielt er den Turing-Preis.*

Zwei Schulen

*Die Sprache der potentiellen Ergebnisse aus Kapitel 2 und die der Graphen entstanden getrennt und standen sich lange feindlich gegenüber. **Sie sind nachweislich gleichwertig** — jede Aussage der einen lässt sich in die andere übersetzen —, und heute benutzt man beide nebeneinander: Graphen, um die Annahmen zu finden, potentielle Ergebnisse, um die Schätzer aufzuschreiben. Dieser Band verfährt ebenso.*

Graphen heute

Struktur lernen	Aus Daten die Äquivalenzklasse bestimmen — nicht mehr, aber auch nicht weniger.
Mit Eingriffen	Wenige gezielte Versuche genügen, um die Richtungen festzulegen.
Große Graphen	Genregulation mit Tausenden von Knoten.

Zur zweiten Zeile

*Kann man einzelne Größen gezielt verändern — in der Zellbiologie etwa durch Ausschalten eines Gens —, so lassen sich Richtungen bestimmen, die aus Beobachtung allein nicht folgen. **Die Zahl der nötigen Eingriffe wächst dabei nur logarithmisch mit der Knotenzahl**, wenn man sie geschickt wählt. Das ist eines der wenigen Ergebnisse, bei denen Theorie und Laborpraxis sich unmittelbar treffen.*

Was Sie jetzt können

Definition 4.1	Pfeile sind Annahmen, fehlende auch
Satz 4.2	Faktorisierung über die Eltern
Drei Bausteine	Kette, Gabel, Kollider
Definition 4.3	d-Trennung: alle Wege gesperrt
Satz 4.4	d-getrennt heißt bedingt unabhängig

Man kann nun Annahmen aufschreiben und Unabhängigkeiten ablesen. Das nächste Kapitel beantwortet die praktische Frage, die daraus folgt: Welche Größen soll man herausrechnen — und welche auf keinen Fall?

Kapitel 5

Was man herausrechnen darf

5.1 Die Frage

Sechs Größen, welche ins Modell?

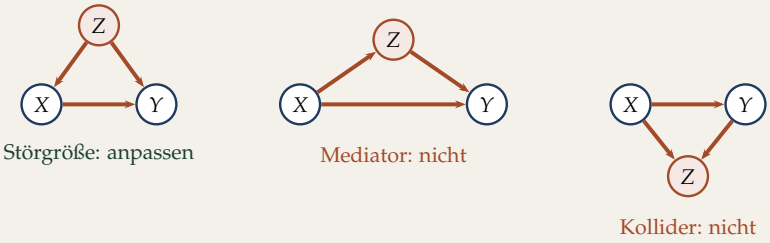
Im Leitfall stehen Alter, Vorerkrankungen, Schweregrad, Organversagen und die Behandlung zur Verfügung. Die übliche Antwort lautet: möglichst alle — je mehr man berücksichtigt, desto besser.

Diese Antwort ist falsch, und zwar nicht nur ungenau, sondern im Vorzeichen.

Dieses Kapitel unterscheidet vier Rollen, die eine Größe im Graphen spielen kann. ***Bei zweien muss man anpassen, bei zweien darf man es auf keinen Fall*** *— und welche Rolle vorliegt, steht nicht in den Daten, sondern im Graphen aus Kapitel 4.*

5.2 Vier Rollen

Die Übersicht



Rolle	Lage im Graphen	anpassen?
Störgröße	Ursache von X und von Y	ja — muss
Mediator	liegt auf dem Weg $X \to Y$	nein
Kollider	Folge von X und von Y	nein
Instrument	Ursache nur von X	nein

Nur die erste Zeile rechtfertigt die Anpassung. Die übrigen drei schaden — jede auf eigene Weise.

5.3 Was in jedem Fall geschieht

Alle vier durchgerechnet

Jeweils 200 000 erzeugte Patienten, lineare Modelle, geschätzt durch kleinste Quadrate.

Erstens — der Mediator

X wirkt *nur* über M auf Y; wahrer Gesamteffekt $0{,}8 \cdot 0{,}9 = 0{,}72$. Eine Störgröße U ist beobachtet.

Modell	Schätzung	
$Y \sim X$	1,217	verzerrt durch U
$Y \sim X + U$	**0,720**	richtig
$Y \sim X + M + U$	**0,004**	Effekt verschwunden

Wer den Mediator anpasst, misst den Effekt bei festgehaltenem Organversagen *— und der ist null, weil die Behandlung nur über das Organversagen wirkt. Das Ergebnis ist rechnerisch richtig und beantwortet die falsche Frage. Kapitel 13 behandelt die Fälle, in denen man genau das absichtlich tut.*

Zweitens — der Kollider

A und B sind unabhängig; beide verursachen S.

Modell	Koeffizient	
$A \sim B$	0,002	unabhängig
$A \sim B + S$	**−0,390**	erfunden

Aus nichts wird ein deutlicher negativer Zusammenhang. ***Das ist die Berkson-Verzerrung aus Aufgabe 1.2 — nur nicht durch Auswahl, sondern durch Anpassung erzeugt.*** *Für die Verzerrung ist es gleichgültig, ob man nur Aufgenommene betrachtet oder die Aufnahme als Kovariable ins Modell nimmt.*

Drittens — das Instrument

Z wirkt nur auf X; eine *unbeobachtete* Störgröße U bleibt im Modell fehlen.

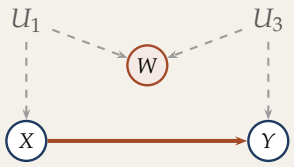
Modell	Schätzung	Verzerrung
$Y \sim X$	1,186	+0,186
$Y \sim X + Z$	1,403	**+0,403**

Die Anpassung an das Instrument verdoppelt die Verzerrung.

Der Grund: Z erklärt einen Teil der Schwankung von X, der nicht von U stammt. Was von X übrig bleibt, ist stärker von U durchsetzt — und damit wiegt die verbliebene Verzerrung schwerer. ***Man nennt das Verstärkungsverzerrung****, und sie ist besonders tückisch, weil das Modell mit Z genauer aussieht: Es erklärt mehr Streuung und hat engere Vertrauensintervalle.*

Viertens — eine Größe, die gar nichts damit zu tun hat

W ist weder Ursache von X noch von Y. Sie ist Kollider zweier unbeobachteter Größen: U_1 wirkt auf X und auf W, U_3 wirkt auf W und auf Y.



Modell	Schätzung	**wahr:** 1,000
$Y \sim X$	**0,999**	unverzerrt
$Y \sim X + W$	**0,863**	verzerrt

Ohne Anpassung richtig, mit Anpassung falsch — und W liegt zeitlich vor der Behandlung.

Man nennt das nach der Form des Graphen die ***M-Verzerrung****.* ***Sie widerlegt die verbreitete Regel, man dürfe gefahrlos alles anpassen, was vor der Behandlung erhoben wurde.*** *Ohne Graph ist W von einer echten Störgröße nicht zu unterscheiden: Beide hängen mit X und mit Y zusammen.*

5.4 Der Fehler der zweiten Tabelle

Koeffizienten sind nicht alle gleich zu lesen

Eine übliche Veröffentlichung zeigt in der zweiten Tabelle ein Modell mit allen Kovariablen und deutet jeden Koeffizienten als Wirkung.

Die Behandlung	Ihr Koeffizient ist kausal deutbar — wenn der Satz aus Kapitel 6 erfüllt ist.
Die Kovariablen	Ihre Koeffizienten sind es in aller Regel nicht.

Die Anpassungsmenge wurde gewählt, um die Wege um die Behandlung zu sperren — nicht die um das Alter. ***Für das Alter kann dieselbe Menge zu wenig enthalten (eine Störgröße fehlt) oder zu viel (ein Mediator ist dabei).*** *Im Leitfall ist der Schweregrad ein Mediator zwischen Alter und Tod: Der Alterskoeffizient misst dann nur den direkten Anteil und unterschätzt die Gesamtwirkung des Alters.*

Ein Modell, ein deutbarer Koeffizient. Wer mehrere Wirkungen wissen will, braucht mehrere Modelle mit jeweils eigener Anpassungsmenge.

5.5 Der Bruchfall

Wenn die Störgröße ungenau gemessen ist

Passt man an eine fehlerhaft gemessene Störgröße an, so bleibt ein Teil der Verzerrung bestehen.

Restverzerrung	Der Schweregrad in zwei Stufen ist ein grobes Abbild einer stetigen Größe. Was innerhalb der Stufen schwankt, bleibt unkorrigiert.
Stellvertreter	Ein gemessener Wert ersetzt oft eine nicht messbare Größe — etwa die Laborwerte den “Zustand”. Die Anpassung ist dann unvollständig.

Eine Anpassung an einen Stellvertreter beseitigt die Verzerrung nur teilweise*, und wie viel übrig bleibt, hängt davon ab, wie gut der Stellvertreter ist. In der Praxis ist das die häufigste Ursache dafür, dass Beobachtungsstudien und randomisierte Studien auseinanderfallen. Kapitel 11 behandelt Verfahren, die diesen Rest abschätzen.*

Und eine Ausnahme von der Regel

Nicht jede Anpassung an einen Nicht-Störfaktor schadet. ***Eine Größe, die nur auf*** *Y* ***wirkt und nicht auf*** *X,* ***darf man anpassen*** *— sie verzerrt nicht und verringert sogar die Streuung, genau wie in der randomisierten Studie aus Kapitel 3. Die vier Rollen sind also nicht vollständig; die allgemeine Regel liefert erst der Hintertürtest des nächsten Kapitels.*

5.6 Übungsaufgaben

Aufgabe 5.1 — Den Mediator erkennen

Im Leitfall soll der Effekt der frühen Gabe auf den Tod geschätzt werden. Welche der fünf übrigen Größen gehören ins Modell?

Lösung

Schritt 1 — Die Rollen bestimmen

Größe	Rolle	anpassen?
S Schweregrad	Ursache von X und Y	ja
A Alter	Ursache von S und Y	darf
V Vorerkrankungen	Ursache nur von S	nein
M Organversagen	Mediator	nein

Schritt 2 — Die drei Begründungen

S: Er liegt auf dem Weg $X \leftarrow S \rightarrow Y$. Ohne Anpassung bleibt dieser offen — das war Kapitel 1.
A: Das Alter wirkt auf Y unmittelbar und auf X nur über S. Passt man ohnehin an S an, so ist A nicht nötig — aber unschädlich und streuungsmindernd.
V: Die Vorerkrankungen wirken nur über S. Sie sind ein *Instrument* für X — und nach Abschnitt 5.3 kann ihre Anpassung eine verbliebene Verzerrung verstärken.
M: Mediator. Seine Anpassung setzt den Effekt auf null.

Schritt 3 — Die Antwort

> **Es genügt $\{S\}$, und $\{S, A\}$ ist ebenso richtig. V und M gehören nicht hinein.**

Schritt 4 — Was ein Rechner nicht sieht

> *Nimmt man alle fünf Größen ins Modell — wie es viele Auswertungsprogramme vorschlagen —, so ist das Ergebnis falsch, und zwar dreifach:* ***Der Mediator tilgt den Effekt, das Instrument verstärkt die Restverzerrung, und die Alterskoeffizienten verleiten zum Fehler der zweiten Tabelle.*** *Nichts davon zeigt sich in den Gütemaßen: Das volle Modell erklärt mehr Streuung als das richtige.*

Aufgabe 5.2 — Den Kollider in Zahlen

Alter und Vorerkrankungen sind in der Bevölkerung unabhängig. Beide erhöhen den Schweregrad. Nach Kapitel 4 beträgt ihre Korrelation unter Festhalten des Schweregrads $-0{,}107$. Was folgt daraus für eine Studie an Schwerkranken?

Lösung

Schritt 1 — Die Lage

Eine Studie, die nur Schwerkranke einschließt, hat auf S bedingt — nicht durch Rechnung, sondern durch die Einschlusskriterien.

Schritt 2 — Die Folge

Bevölkerung	$r = -0{,}001$
nur Schwerkranke	$r = -0{,}107$

In der Studie erscheinen Vorerkrankungen als *schützend* gegen hohes Alter — ein Zusammenhang, den es nicht gibt.

Schritt 3 — Wann das den Effekt verfälscht

Für den Effekt der Behandlung ist die Einschränkung auf Schwerkranke hier unschädlich — sie entspricht einer Anpassung an S, und S ist die Störgröße. ***Gefährlich wird es, wenn man aus derselben Studie einen Zusammenhang zwischen Alter und Vorerkrankungen berichtet****, oder wenn die Einschlussgröße ein Kollider von Behandlung und Ausgang ist.*

Schritt 4 — Ein Beispiel für den gefährlichen Fall

Man werte nur Patienten aus, die mindestens drei Tage überlebt haben — eine übliche Bereinigung, weil frühe Todesfälle die Auswertung stören. ***Das Überleben der ersten drei Tage ist eine Folge sowohl der Behandlung als auch des Zustands.*** *Es ist ein Kollider, und die Einschränkung darauf verzerrt den Effekt. Dieselbe Falle steckt hinter der Auswertung nach tatsächlicher Behandlung aus Kapitel 3.*

Aufgabe 5.3 — Die Verstärkung nachrechnen

Warum verstärkt die Anpassung an ein Instrument die Verzerrung? Rechnen Sie es an den Zahlen aus Abschnitt 5.3 nach.

Lösung

Schritt 1 — Das Modell

$$X = 1{,}2\,Z + 0{,}5\,U + \varepsilon_X, \qquad Y = 1{,}0\,X + 1{,}0\,U + \varepsilon_Y$$

mit Z, U, ε unabhängig und standardnormal. U ist unbeobachtet.

Schritt 2 — Ohne Anpassung

Die Verzerrung der Regression von Y auf X beträgt

$$\text{Verzerrung} = 1{,}0 \cdot \frac{\operatorname{Cov}(X,U)}{\operatorname{Var}(X)} = \frac{0{,}5}{1{,}2^2 + 0{,}5^2 + 1} = \frac{0{,}5}{2{,}69} = 0{,}186$$

Die Simulation ergab 0,186. ✓

Schritt 3 — Mit Anpassung an Z

Bei festgehaltenem Z schwankt X nur noch durch U und ε_X:

$$\mathrm{Var}(X \mid Z) = 0{,}5^2 + 1 = 1{,}25$$

$$\text{Verzerrung} = \frac{0{,}5}{1{,}25} = 0{,}400$$

Die Simulation ergab 0,403. ✓

Schritt 4 — Der Mechanismus

	ohne Z	**mit** Z
Streuung von X	2,69	1,25
davon aus U	0,25	0,25
Anteil	9,3 %	**20,0** %

Der Zähler bleibt, der Nenner schrumpft. Was von der Behandlung übrig bleibt, ist stärker von der Störgröße durchsetzt.

Schritt 5 — Die Warnung

Je stärker das Instrument, desto schlimmer die Verstärkung. *Bei Z-Gewicht 2 statt 1,2 bliebe* $\mathrm{Var}(X \mid Z)$ *unverändert bei 1,25, aber ohne Anpassung wäre die Verzerrung nur* $0{,}5/5{,}25 = 0{,}095$ *— der Faktor stiege auf über vier. Und da niemand U beobachtet, ist die Verzerrung weder vorher noch nachher sichtbar. Kapitel 9 zeigt, wie man dasselbe Z richtig benutzt: nicht als Kovariable, sondern als Instrument.*

Eine Regel, die sich als falsch erwies

Bis in die 1990er Jahre galt in der Epidemiologie eine einfache Auswahlregel: Man passe an jede Größe an, die sowohl mit der Behandlung als auch mit dem Ausgang zusammenhängt — und die zeitlich vor der Behandlung liegt.

Die Regel ist plausibel und in den allermeisten Fällen richtig. ***Die M-Verzerrung aus Abschnitt 5.3 widerlegt sie*** *— dort erfüllt W beide Bedingungen und darf dennoch nicht angepasst werden. Das Beispiel geht auf Arbeiten von* ***Judea Pearl*** *zurück;* ***Sander Greenland*** *und Mitarbeiter trugen es 1999 in die Epidemiologie.*

Wie oft es vorkommt

Über die praktische Bedeutung wird gestritten. Die M-Verzerrung ist meist klein, wenn die beteiligten Wirkungen mäßig sind — in der Simulation 14 Prozent. ***Die Verstärkungsverzerrung dagegen ist oft groß****, und sie tritt auf, sobald man Größen anpasst, die stark die Behandlung und kaum den Ausgang beeinflussen. Beides spricht dafür, die Anpassungsmenge aus einem Graphen abzuleiten statt aus einer Faustregel.*

Der Fehler der zweiten Tabelle

__Daniel Westreich__ und __Sander Greenland__ gaben ihm 2013 diesen Namen — nach der Stelle, an der die vollständige Koeffiziententabelle in Veröffentlichungen meist steht. __Sie fanden ihn in der Mehrzahl der von ihnen durchgesehenen Arbeiten.__ Seither verlangen manche Zeitschriften, Kovariablenkoeffizienten gar nicht mehr abzudrucken.

Anpassen heute

Automatische Auswahl	Programme, die aus einem Graphen die zulässigen Mengen berechnen.
Auswahl aus Daten	Verfahren, die Störgrößen aus vielen Kandidaten wählen — mit den Lecks aus Band 22.
Negative Kontrollen	Größen, bei denen kein Effekt zu erwarten ist, als Prüfstein.

Zur dritten Zeile

Man wählt einen Ausgang, auf den die Behandlung sicher nicht wirken kann — etwa einen Unfalltod — und schätzt den Effekt darauf. __Findet man einen, so ist die Anpassung unvollständig__, und man kann die Größe der verbliebenen Verzerrung abschätzen. Das Verfahren ist eines der wenigen, mit denen sich die unprüfbare Annahme aus Kapitel 2 wenigstens indirekt prüfen lässt.

Was Sie jetzt können

Störgröße	anpassen — sperrt den Hinterweg
Mediator	nicht — tilgt den Effekt
Kollider	nicht — erfindet Zusammenhang
Instrument	nicht — verstärkt die Restverzerrung
Zweite Tabelle	ein Modell, ein deutbarer Koeffizient

Vier Rollen sind vier Fälle, keine Regel. Das nächste Kapitel gibt die Regel — ein Kriterium, das für jeden Graphen entscheidet, welche Mengen zulässig sind, und das die vier Fälle als Sonderfälle enthält.

Kapitel 6

Der Hintertürtest

6.1 Die Regel

Was Kapitel 5 offenließ

Vier Rollen sind vier Fälle. Gesucht ist ein Kriterium, das für *jeden* Graphen entscheidet, welche Anpassungsmengen zulässig sind.

Zwei Arten von Wegen

Vorderwege	Beginnen mit einem Pfeil *aus* X heraus. Sie tragen die Wirkung — sie müssen offen bleiben.
Hinterwege	Beginnen mit einem Pfeil *in* X hinein. Sie tragen die Verzerrung — sie müssen gesperrt werden.

Definition 6.1 — Hintertürkriterium

Eine Menge Z erfüllt das **Hintertürkriterium** für (X, Y), wenn

1	Z enthält keinen Nachkommen von X, und
2	Z sperrt jeden Hinterweg von X nach Y.

Satz 6.2 — die Hintertürformel

Erfüllt Z das Kriterium, so gilt

$$\Pr\big[Y \mid \mathrm{do}(X = x)\big] = \sum_{z} \Pr[Y \mid X = x,\ Z = z]\,\Pr[Z = z].$$

Warum die beiden Bedingungen genau das Richtige leisten

Bedingung 1	schließt Mediatoren aus (sie sind Nachkommen) — die Vorderwege bleiben offen. Sie schließt auch Kollider aus, die *nach* X liegen.
Bedingung 2	schließt Störgrößen ein — die Hinterwege werden gesperrt — und verbietet zugleich, durch Bedingen auf einen Kollider neue Wege zu öffnen.

Die rechte Seite enthält nur beobachtbare Größen. Damit ist der Effekt aus Beobachtungsdaten berechenbar — wenn der Graph stimmt.

Der Beweis benutzt die Faktorisierung aus Satz 4.2 und die Deutung des Eingriffs als Durchtrennen der Pfeile in X hinein; er ist eine Zeilenrechnung über Summen und findet sich bei Pearl[18], Kapitel 3 — die zweite Auslassung dieses Bandes. ***Man erkennt in der Formel die Anpassungsformel aus Satz 2.4 wieder****: Was dort aus den vier Annahmen folgte, folgt hier aus dem Bild.*

Der Leitfall geprüft

Hinterwege von X nach Y:

Weg	**durch** $\{S\}$	**durch** $\{S, A\}$
$X \leftarrow S \rightarrow Y$	gesperrt	gesperrt
$X \leftarrow S \rightarrow M \rightarrow Y$	gesperrt	gesperrt
$X \leftarrow S \leftarrow A \rightarrow Y$	gesperrt	gesperrt
$X \leftarrow S \leftarrow V \rightarrow \ldots$	—	—

Menge	**Bedingung 1**	**Bedingung 2**
$\{S\}$	ja	ja
$\{S, A\}$	ja	ja
$\{S, M\}$	nein	—
$\{A, V\}$	ja	ja
$\varnothing$	ja	nein

Auch $\{A, V\}$ ***genügt****, obwohl der Schweregrad selbst fehlt: Alter und Vorerkrankungen sind seine einzigen Ursachen, und wer beide festhält, sperrt jeden Weg, der über S zurückläuft. Es gibt also mehrere zulässige Mengen, und man wählt die, die man am besten gemessen hat. Das ist ein praktischer Vorzug des Kriteriums gegenüber einer starren Regel.*

6.2 Wenn kein Hinterweg zu sperren ist

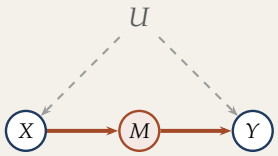
Satz 6.3 — die Vordertürformel

Gibt es eine unbeobachtete Störgröße, aber einen Mediator M, der

1	jeden Vorderweg von X nach Y abfängt,
2	keinen unbeobachteten Hinterweg zu X hat, und
3	dessen Hinterwege zu Y durch X gesperrt sind,

so ist der Effekt dennoch berechenbar:

$$\Pr[Y \mid \mathrm{do}(x)] = \sum_m \Pr[m \mid x] \sum_{x'} \Pr[Y \mid m, x'] \Pr[x'].$$



Der Effekt wird in zwei Stücke zerlegt: die Wirkung von X auf M — unverzerrt, weil U nicht auf M wirkt — und die von M auf Y, für die X die Störgröße sperrt.

***Das ist der erstaunlichste Satz dieses Bandes**: Man schätzt einen Effekt trotz unbeobachteter Störgröße, ohne Randomisierung und ohne Instrument. Er wird allerdings selten angewandt, weil Bedingung 1 sehr stark ist — es darf keinen anderen Wirkweg geben. Bei Rauchen und Lungenkrebs wurde er für den Teerniederschlag in der Lunge vorgeschlagen; ob das zutrifft, ist umstritten.*

6.3 Der Bruchfall

Was das Kriterium nicht leistet

Der Graph	Das Kriterium prüft einen Graphen. Ob der Graph stimmt, prüft es nicht.
Keine Menge	Manchmal gibt es gar keine zulässige Menge — dann ist der Effekt aus diesen Daten *nicht* bestimmbar, und kein Verfahren ändert das.
Messfehler	Eine schlecht gemessene Größe sperrt nur teilweise; Kapitel 5, Bruchfall.

> *Die zweite Zeile ist ein Gewinn, kein Mangel.* ***Ein Verfahren, das jedem Datensatz eine Zahl entlockt, verschweigt den Fall der Unbestimmbarkeit*** *— eine Regression liefert immer einen Koeffizienten. Das Kriterium sagt hingegen, wann man schweigen muss, und weist damit auf die Verfahren der Kapitel 9 bis 11.*

6.4 Übungsaufgaben

Aufgabe 6.1 — Mengen prüfen

Prüfen Sie im Leitfallgraphen die Mengen $\{M\}$, $\{A\}$ und $\{S, V\}$.

Lösung

$\{M\}$
M ist Nachkomme von X — Bedingung 1 verletzt.
Und zusätzlich: M ist Kollider von X und S; das Bedingen öffnet den Weg $X \to M \leftarrow S \to Y$. Doppelt unzulässig.

$\{A\}$
Bedingung 1 erfüllt. Aber der Weg $X \leftarrow S \to Y$ bleibt offen — S ist weder in Z noch ein Kollider.

Unzulässig: die Hauptstörgröße bleibt unberücksichtigt.

$\{S, V\}$
Bedingung 1 erfüllt. Alle Hinterwege laufen über S und sind gesperrt.

Zulässig — aber unklug.

> *V wirkt nur über S auf X; nach Kapitel 5 ist es ein Instrument.* ***Solange der Graph stimmt, schadet seine Aufnahme nicht*** *— die Verstärkungsverzerrung entsteht erst, wenn eine unbeobachtete Störgröße übrig ist. Da man das nie ausschließen kann, lässt man Instrumente vorsichtshalber weg. Das Kriterium erlaubt mehr, als die Klugheit rät.*

Aufgabe 6.2 — Wenn keine Menge genügt

Der diensthabende Arzt sei unbeobachtet; seine Erfahrung beeinflusst sowohl den Zeitpunkt als auch die weitere Versorgung. Zeichnen Sie das ein und prüfen Sie.

Lösung

Schritt 1 — Der Graph
Ein gestrichelter Doppelpfeil zwischen X und Y: eine unbeobachtete gemeinsame Ursache.

Schritt 2 — Die Prüfung

Der Hinterweg $X \leftarrow U \rightarrow Y$ enthält keinen beobachteten Knoten. Keine Menge kann ihn sperren.

Es gibt keine zulässige Menge. Der Effekt ist aus diesen Daten nicht bestimmbar.

Schritt 3 — Was bleibt

Messen	Die Erfahrung des Arztes erheben — dann wird sie zur Störgröße und ist anpassbar.
Instrument	Eine Größe suchen, die nur den Zeitpunkt beeinflusst — Kapitel 9.
Schranken	Angeben, wie groß der Effekt höchstens und mindestens sein kann.
Empfindlichkeit	Ausrechnen, wie stark U wirken müsste, um das Ergebnis umzukehren.

Die vierte Zeile ist in der Praxis die häufigste Antwort. *Sie verwandelt eine unbeantwortbare Frage in eine beantwortbare: Statt "wie groß ist der Effekt" fragt man "wie unplausibel müsste die Welt sein, damit es keinen gibt". Für Rauchen und Lungenkrebs lautete die Antwort: neunfach erhöhtes Risiko einer verborgenen Größe — Kapitel 2, Forschungskasten.*

Aufgabe 6.3 — Die Vordertür rechnen

X, M, Y binär, U unbeobachtet. Gegeben:

$$\Pr[M = 1 \mid X = 1] = 0{,}80, \quad \Pr[M = 1 \mid X = 0] = 0{,}30$$

$$\Pr[Y = 1 \mid M = 1] \text{ gemittelt über } X: 0{,}20, \qquad \text{für } M = 0: 0{,}50$$

Berechnen Sie den Effekt.

Lösung

Schritt 1 — Die zweite Stufe

Die innere Summe in Satz 6.3 ist der über X gemittelte Ausgang bei gegebenem M:

$$\sum_{x'} \Pr[Y = 1 \mid m, x'] \Pr[x'] = \begin{cases} 0{,}20 & m = 1 \\ 0{,}50 & m = 0 \end{cases}$$

Schritt 2 — Die erste Stufe

$$\Pr[Y = 1 \mid \mathrm{do}(X = 1)] = 0{,}80 \cdot 0{,}20 + 0{,}20 \cdot 0{,}50 = 0{,}16 + 0{,}10 = 0{,}26$$
$$\Pr[Y = 1 \mid \mathrm{do}(X = 0)] = 0{,}30 \cdot 0{,}20 + 0{,}70 \cdot 0{,}50 = 0{,}06 + 0{,}35 = 0{,}41$$

$$\text{Effekt} = 0{,}26 - 0{,}41 = \mathbf{-0{,}15}$$

Schritt 3 — Die Deutung

Wirkung auf M	$+0{,}50$
Wirkung von M **auf** Y	$-0{,}30$
Produkt	$\mathbf{-0{,}15}$

Bei binären Größen zerfällt die Formel in ein Produkt zweier Differenzen. ***Beide Stücke sind unverzerrt schätzbar — das erste, weil*** U ***nicht auf*** M ***wirkt; das zweite, weil*** X ***dort die Störgröße sperrt.*** *Der Effekt ist damit bestimmt, obwohl der direkte Vergleich von* X *und* Y *hoffnungslos verzerrt wäre.*

Ein Kriterium und ein Kalkül

Judea Pearl veröffentlichte das Hintertürkriterium 1993 und die Vordertürformel 1995.

Beide sind Sonderfälle eines Regelwerks aus drei Umformungsregeln, des ***do-Kalküls****.* ***Ilya Shpitser und Pearl zeigten 2006, dass dieses Kalkül vollständig ist****: Lässt sich ein Effekt überhaupt aus Beobachtungsdaten bestimmen, so führen die drei Regeln zum Ziel — und wenn nicht, so beweist das Scheitern die Unbestimmbarkeit. Ein Rechner kann das heute in Sekunden entscheiden.*

Und der Widerstand

Die Epidemiologie übernahm die Graphen zügig; die Ökonometrie tat sich schwerer und arbeitet bis heute überwiegend mit den Verfahren der Kapitel 9 und 10. ***Der Streit war teils sachlich, teils sprachlich****: Dieselben Annahmen heißen in beiden Fächern anders, und beide Seiten hielten die jeweils andere für ungenau.*

Bestimmbarkeit heute

Rechner	Programme, die zulässige Mengen und Formeln automatisch bestimmen.
Übertragung	Effekte aus einer Bevölkerung auf eine andere übertragen — mit eigenem Kriterium.
Teilweise Bestimmbarkeit	Schranken statt Punktschätzungen.

Zur zweiten Zeile

Ein Effekt aus Studie A gilt in Klinik B, wenn sich die Unterschiede zwischen beiden als Knoten in einen gemeinsamen Graphen eintragen lassen und ein entsprechendes Kriterium erfüllt ist. ***Damit wird die Übertragbarkeit aus Band 22, Kapitel 3 zu einer prüfbaren Bedingung*** *statt einer Hoffnung — sofern man weiß, worin sich die Bevölkerungen unterscheiden.*

Was Sie jetzt können

Vorder-, Hinterweg	Wirkung gegen Verzerrung
Definition 6.1	kein Nachkomme, alle Hinterwege gesperrt
Satz 6.2	Hintertürformel = Anpassungsformel
Satz 6.3	Vordertür: Effekt trotz verborgener Störgröße
Unbestimmbar	auch eine Antwort

Damit endet Teil II. Man weiß nun, wonach anzupassen ist. Teil III behandelt, wie — denn bei zwanzig Störgrößen versagt das Stratifizieren, und an seine Stelle tritt eine einzige Zahl je Patient.

Teil III

Anpassen

Kapitel 7

Eine Zahl statt zwanzig

7.1 Warum Schichten nicht reichen

Die Anpassungsformel in der Praxis

Satz 6.2 verlangt, über alle Werte von Z zu summieren. Bei zwei Stufen ist das leicht.

Störgrößen	Schichten	je Schicht
1 binär	2	600
5 binär	32	38
10 binär	1024	1
3 stetig	∞	0

Bei 1200 Patienten.

Ab etwa fünf Störgrößen ist keine Schicht mehr besetzt — der Fluch der Dimension aus Band 22, Kapitel 10.

Definition 7.1 — Behandlungsneigung

Die **Behandlungsneigung** eines Patienten ist die Wahrscheinlichkeit, mit der er die Behandlung erhält:

$$e(z) = \Pr[X = 1 \mid Z = z].$$

Satz 7.2 — Rosenbaum und Rubin, 1983

Genügt Z dem Hintertürkriterium, so genügt auch die einzelne Zahl $e(Z)$:

$$\big(Y(1), Y(0)\big) \perp X \mid Z \quad \Longrightarrow \quad \big(Y(1), Y(0)\big) \perp X \mid e(Z).$$

Beweis

Erstens: Bei gegebenem $e(Z)$ ist $\Pr[X = 1 \mid e(Z)] = e(Z)$, denn

$$\Pr[X = 1 \mid e(Z)] = \mathbb{E}\big[\Pr[X = 1 \mid Z] \,\big|\, e(Z)\big] = \mathbb{E}[e(Z) \mid e(Z)] = e(Z).$$

Zweitens: Für die potentiellen Ergebnisse gilt ebenso

$$\Pr\big[X = 1 \mid Y(1), Y(0),\, e(Z)\big] = \mathbb{E}\big[\Pr[X = 1 \mid Y(1), Y(0), Z] \,\big|\, Y(1), Y(0), e(Z)\big].$$

Nach Voraussetzung ist der innere Ausdruck gleich $e(Z)$, unabhängig von den potentiellen Ergebnissen.
Drittens: Beide Ausdrücke sind gleich $e(Z)$ — also hängt die Behandlungswahrscheinlichkeit bei gegebenem $e(Z)$ nicht von den potentiellen Ergebnissen ab. ■

Zwanzig Störgrößen lassen sich auf eine einzige Zahl zusammenziehen — ohne etwas zu verlieren.

Das ist der wichtigste praktische Satz dieses Bandes. ***Er verwandelt ein hochdimensionales Problem in ein eindimensionales****, und die Zahl $e(Z)$ hat eine klare Bedeutung: Zwei Patienten mit gleicher Behandlungsneigung sind, was die Zuteilung angeht, austauschbar — als hätte man bei ihnen dieselbe Münze geworfen.*

7.2 Vier Wege, sie zu benutzen

Die Verfahren

Schichten	Fünf Gruppen gleicher Größe nach e; in jeder vergleichen, dann mitteln.
Paaren	Zu jedem Behandelten den Unbehandelten mit nächstliegendem e suchen.
Gewichten	Jeden Patienten mit $1/e$ bzw. $1/(1-e)$ gewichten — Kapitel 8.
Als Kovariable	e ins Regressionsmodell aufnehmen. Am schwächsten, weil es eine Modellform unterstellt.

Der Leitfall gerechnet

20 000 Patienten, zwei stetige Störgrößen, wahres Modell bekannt.

Schicht	$\bar{e}$	n_{beh}	n_{unbeh}	Differenz
1	0,12	499	3501	−0,039
2	0,27	1112	2888	−0,081
3	0,42	1732	2268	−0,122
4	0,59	2385	1615	−0,138
5	0,80	3156	844	−0,124

Verfahren	Schätzung
naiv	+0,049
fünf Schichten	−0,101
Gewichten	**−0,123**
wahrer Effekt	**−0,122**

Der naive Vergleich hat das falsche Vorzeichen. Fünf Schichten beseitigen den größten Teil der Verzerrung, ein Sechstel bleibt.

***Der Rest ist Restverzerrung innerhalb der Schichten**: In Schicht 1 reicht die Neigung von 0,02 bis 0,20, und innerhalb dieser Spanne sind Behandelte noch immer kränker. Zehn oder zwanzig Schichten verringern den Rest, dünnen aber die Besetzung aus — derselbe Zielkonflikt wie in Band 22, Kapitel 2. Das Gewichten umgeht ihn, indem es gar nicht erst einteilt.*

7.3 Der Bruchfall

Die Neigung ist geschätzt

Modellfehler	$e(Z)$ kennt niemand; man schätzt es, meist durch logistische Regression. Ist das Modell falsch, bleibt Verzerrung.
Kein Ersatz	Die Neigung fasst nur zusammen, was in Z steht. Fehlt eine Störgröße, hilft sie nicht.
Gute Balance täuscht	Dass Behandelte und Unbehandelte nach dem Paaren ähnlich aussehen, beweist nichts über unbeobachtete Größen.

*Die dritte Zeile erklärt einen verbreiteten Irrtum. **Eine Tabelle, die nach dem Paaren gleiche Mittelwerte in allen gemessenen Größen zeigt, sieht aus wie eine randomisierte Studie und ist keine.** Die Randomisierung gleicht auch das Ungemessene aus, die Neigung nur das Gemessene — Kapitel 3, Satz 3.1.*

Und ein Fehler beim Aufbau des Modells

*In das Neigungsmodell gehören Größen, die den Ausgang beeinflussen — nicht solche, die nur die Behandlung beeinflussen. **Letztere sind Instrumente und verstärken nach Kapitel 5 die Restverzerrung.** Wer das Neigungsmodell nach Güte der Vorhersage von X auswählt, wählt also genau falsch: Ein Modell, das die Behandlung perfekt vorhersagt, macht jede Schätzung unmöglich — es verletzt die Positivität.*

7.4 Übungsaufgaben

Aufgabe 7.1 — Schichten von Hand

Aus den fünf Schichten der Tabelle: Berechnen Sie den geschichteten Schätzer und den Effekt bei den Behandelten.

Lösung

Schritt 1 — Der Durchschnittseffekt

Jede Schicht enthält 4000 von 20 000 Patienten, also je 20 Prozent:

$$\hat{\tau} = 0{,}2\,(-0{,}039 - 0{,}081 - 0{,}122 - 0{,}138 - 0{,}124) = 0{,}2 \cdot (-0{,}504) = -0{,}101$$

Schritt 2 — Der Effekt bei den Behandelten

Nun gewichtet man mit dem Anteil der *Behandelten* je Schicht:

Schicht	n_{beh}	Anteil	Beitrag
1	499	0,056	−0,0022
2	1112	0,125	−0,0101
3	1732	0,195	−0,0238
4	2385	0,268	−0,0370
5	3156	0,355	−0,0441
	8884	1,000	**−0,117**

−0,117 gegen −0,101: Die Behandelten profitieren stärker, weil sie in den oberen Schichten überwiegen.

Schritt 3 — Die Lehre

> ***Dieselben Schichtdifferenzen, zwei verschiedene Zahlen — je nachdem, über welche Bevölkerung man mittelt.*** *Das ist Definition 2.3 in der Rechnung: Der Durchschnittseffekt und der Effekt bei den Behandelten unterscheiden sich, sobald die Wirkung zwischen den Schichten schwankt. Welche Zahl man braucht, hängt von der Frage ab — Leitlinie oder Nachbetrachtung.*

Aufgabe 7.2 — Wie fein soll man schichten?

Bei 1200 Patienten und einem Behandeltenanteil von 50 Prozent: Wie viele Schichten sind sinnvoll?

Lösung

Schritt 1 — Die Besetzung

Schichten	je Schicht	je Gruppe
5	240	120
10	120	60
20	60	30
50	24	12

Schritt 2 — Die verbleibende Verzerrung

Eine Faustregel besagt, dass fünf Schichten etwa 90 Prozent der Verzerrung einer stetigen Störgröße beseitigen, zehn Schichten etwa 95.
Im Leitfall: $-0{,}101$ gegenüber $-0{,}122$ sind 83 Prozent — etwas weniger, weil die Neigung stark streut.

Schritt 3 — Die Streuung

Bei 30 Patienten je Gruppe und Schicht beträgt die Streuung einer Differenz zweier Anteile nahe 0,3 rund

$$\sqrt{\frac{2 \cdot 0{,}21}{30}} = 0{,}118.$$

Über 20 Schichten gemittelt: $0{,}118/\sqrt{20} = 0{,}026$.

> ***Die Streuung des Gesamtschätzers wächst durch feinere Schichtung kaum*** *— solange jede Schicht beide Gruppen enthält. Bricht das zusammen, so fällt die Schicht ganz aus, und die Schätzung wird verzerrt und ungenau. Die Grenze liegt also nicht bei der Streuung, sondern bei der Positivität: Man schichtet so fein, wie es die Besetzung zulässt.*

Aufgabe 7.3 — Was Balance beweist

Nach dem Paaren stimmen Alter, Vorerkrankungen und Laborwerte in beiden Gruppen überein. Welche Schlüsse sind zulässig?

Lösung

Schritt 1 — Was gezeigt ist

Gezeigt	Das Neigungsmodell hat die gemessenen Größen ausgeglichen. Es ist also brauchbar angepasst.
Nicht gezeigt	Dass es keine weiteren Störgrößen gibt.

Schritt 2 — Warum das kein Zirkel ist

> *Die Balance prüft das Modell, nicht die Annahme.* ***Sie ist eine notwendige, keine hinreichende Bedingung****: Wer sie nicht erreicht, hat sicher ein Problem; wer sie erreicht, hat eines der beiden möglichen Probleme ausgeschlossen.*

Schritt 3 — Die einzige echte Prüfung

Negative Kontrolle	Ein Ausgang, auf den die Behandlung nicht wirken kann. Findet man dort einen Effekt, fehlt eine Störgröße.
Empfindlichkeit	Wie stark müsste eine verborgene Größe wirken?
Vergleich	Gibt es zu derselben Frage eine randomisierte Studie?

***Der dritte Punkt ist die strengste Prüfung und in großem Maßstab durchgeführt worden**: Man bildete mit Beobachtungsdaten Studien nach, deren randomisiertes Ergebnis bekannt war. Bei sorgfältiger Emulation — Kapitel 11 — stimmten die Ergebnisse überwiegend überein; bei nachlässiger wichen sie erheblich ab, und zwar in beide Richtungen.*

Ein Aufsatz von acht Seiten

Paul Rosenbaum und **Donald Rubin** veröffentlichten 1983 in *Biometrika* den Aufsatz, der Satz 7.2 enthält.

*Er gehört zu den meistzitierten Arbeiten der Statistik überhaupt. **Der Gedanke, eine ganze Menge von Störgrößen durch eine einzige Zahl zu ersetzen, war neu und überraschend** — und der Beweis passt, wie oben, auf eine halbe Seite.*

Ein früher Einsatz

*Rubin wurde in den 1990er Jahren als Gutachter in einem Verfahren gegen Tabakkonzerne herangezogen und benutzte Neigungsverfahren, um die Krankheitskosten des Rauchens zu schätzen. **Die Methode wurde dadurch weit über die Statistik hinaus bekannt** — und zugleich zum Gegenstand der Kritik, weil beide Seiten mit denselben Daten verschiedene Zahlen erzeugten.*

Neigung heute

Maschinell geschätzt	Die Neigung mit Verfahren aus Band 22 statt logistischer Regression.
Balance als Ziel	Gewichte direkt so bestimmen, dass die Mittelwerte übereinstimmen.
Hochdimensional	Hunderte von Störgrößen aus Abrechnungsdaten.

Zur ersten Zeile

Ein flexibles Lernverfahren schätzt $e(Z)$ genauer — und schafft ein neues Problem: ***Seine Fehler sind nicht mehr klein genug, damit die einfachen Schätzer gültig bleiben.*** *Man braucht dann die doppelt robusten Verfahren des nächsten Kapitels, die genau für diesen Fall gebaut sind.*

Was Sie jetzt können

Definition 7.1	Behandlungsneigung $e(z)$
Satz 7.2	eine Zahl ersetzt alle Störgrößen
Vier Wege	Schichten, Paaren, Gewichten, Kovariable
Restverzerrung	innerhalb der Schichten
Balance	prüft das Modell, nicht die Annahme

Das Schichten verschenkt Information, das Gewichten nicht. Das nächste Kapitel führt es aus — und zeigt ein Verfahren, das selbst dann noch richtig rechnet, wenn eines von zwei Modellen falsch ist.

Kapitel 8

Gewichten und doppelte Absicherung

8.1 Eine Pseudobevölkerung bauen

Der Gedanke

Ein Schwerkranker, der die Behandlung mit Wahrscheinlichkeit 0,9 erhält, steht für viele seinesgleichen, die sie ebenfalls erhielten — und für wenige, die sie nicht erhielten. Jeder unbehandelte Schwerkranke vertritt also besonders viele.

Definition 8.1 — Gewichtung nach der Kehrwahrscheinlichkeit

$$w_i = \frac{1}{e(z_i)} \text{ falls } X_i = 1, \qquad w_i = \frac{1}{1 - e(z_i)} \text{ falls } X_i = 0$$

Satz 8.2 — der gewichtete Mittelwert schätzt den Eingriff

$$\mathbb{E}\left[\frac{XY}{e(Z)}\right] = \mathbb{E}\big[Y(1)\big]$$

Beweis

Erstens — nach Z bedingen:

$$\mathbb{E}\left[\frac{XY}{e(Z)} \,\middle|\, Z\right] = \frac{1}{e(Z)}\,\mathbb{E}[X\,Y(1) \mid Z]$$

— unter $X = 1$ ist $Y = Y(1)$ (Konsistenz), unter $X = 0$ verschwindet der Term.
Zweitens — bedingte Unabhängigkeit:

$$\mathbb{E}[X\,Y(1) \mid Z] = \mathbb{E}[X \mid Z] \cdot \mathbb{E}[Y(1) \mid Z] = e(Z) \cdot \mathbb{E}[Y(1) \mid Z]$$

Drittens — kürzen und mitteln:

$$\mathbb{E}\left[\frac{XY}{e(Z)}\right] = \mathbb{E}\big[\mathbb{E}[Y(1) \mid Z]\big] = \mathbb{E}[Y(1)]$$

■

Die Gewichte bauen eine gedachte Bevölkerung, in der jeder mit gleicher Wahrscheinlichkeit behandelt wird — eine nachträglich erzeugte Randomisierung.

Der Vorzug gegenüber dem Schichten: Es wird nicht eingeteilt, also entsteht keine Restverzerrung innerhalb von Schichten. *Im Leitfall lieferte das Gewichten $-0{,}123$ gegen einen wahren Wert von $-0{,}122$, das Schichten nur $-0{,}101$.*

Der Preis: extreme Gewichte

Im Leitfall betrug das größte Gewicht 112 — ein einziger Patient zählte so viel wie hundertzwölf.

Neigung	Gewicht	
0,50	2	unauffällig
0,10	10	
0,02	50	bedenklich
0,009	112	ein Patient allein

Das Gewichten verlagert das Positivitätsproblem aus Kapitel 2 in die Varianz. *Wo das Schichten eine Schicht leer lässt und sichtbar scheitert, liefert das Gewichten eine Zahl — die aber an wenigen Patienten hängt. Übliche Abhilfen sind das Stutzen extremer Gewichte, das Beschränken auf den Bereich gemeinsamer Neigung und stabilisierte Gewichte, bei denen man mit dem Randanteil multipliziert.*

8.2 Zwei Modelle, eine Chance

Satz 8.3 — doppelte Absicherung

Der Schätzer

$$\hat{\mu}_1 = \frac{1}{n}\sum_i \left[\frac{X_i\,(Y_i - \hat{m}_1(z_i))}{\hat{e}(z_i)} + \hat{m}_1(z_i)\right]$$

schätzt $\mathbb{E}[Y(1)]$ richtig, wenn *mindestens eines* der beiden Modelle — das Neigungsmodell $\hat{e}$ oder das Ausgangsmodell $\hat{m}_1$ — stimmt.

Der Gedanke

Stimmt $\hat{m}_1$	Der zweite Summand ist schon richtig; der erste hat Erwartungswert null, weil $\mathbb{E}[Y - m_1 \mid X{=}1, Z] = 0$.
Stimmt $\hat{e}$	Der Ausdruck ist Satz 8.2 mit einer Korrektur, deren Erwartungswert sich weghebt — was $\hat{m}_1$ zu viel oder zu wenig sagt, wird gewichtet zurückgenommen.

Am Leitfall geprüft

Lage	Schätzung	
beide Modelle richtig	−0,115	gut
Ausgangsmodell falsch	−0,117	gut
Neigungsmodell falsch	−0,116	gut
beide falsch	**+0,049**	naiv
wahr	−0,122	

Ein falsches Modell schadet nicht — zwei falsche schon.

"Falsch" bedeutete hier: nur eine Konstante statt des richtigen Modells. ***Der Schätzer fängt beide Male den vollen Fehler ab*** *und landet innerhalb eines halben Prozentpunkts. Sind beide falsch, fällt er auf den naiven Vergleich zurück — samt Vorzeichenfehler.*

Warum das heute wichtig ist

Schätzt man beide Modelle mit Lernverfahren aus Band 22, so sind sie beide ungenau statt falsch — und die Ungenauigkeit fällt langsamer als $1/\sqrt{n}$. ***Beim doppelt abgesicherten Schätzer multiplizieren sich die beiden Fehler****, statt sich zu addieren: Ist jeder von der Ordnung* $n^{-1/4}$*, so ist ihr Produkt von der Ordnung* $n^{-1/2}$ *— und der Schätzer wird wieder normalverteilt mit der üblichen Rate. Das ist der Grund, warum kausale Schätzung und maschinelles Lernen sich erst durch diesen Satz vertragen.*

Zwei Fehler, die sich multiplizieren, sind besser als einer, der allein steht.

8.3 Der Bruchfall

Drei Fallen

Beide falsch	Die doppelte Absicherung sichert nicht gegen fehlende Störgrößen — beide Modelle benutzen dasselbe Z.
Überanpassung	Werden beide Modelle auf denselben Daten geschätzt wie der Effekt, entsteht ein Leck wie in Band 22, Kapitel 3. Abhilfe: Kreuzanpassung, also Schätzung auf der einen und Auswertung auf der anderen Hälfte.
Instabilität	Kleine $\hat{e}$ machen den Korrekturterm riesig, auch wenn das Ausgangsmodell gut ist.

Die erste Zeile ist die wichtigste und wird am häufigsten übersehen. ***Doppelte Absicherung heißt: doppelt abgesichert gegen Modellfehler, gar nicht abgesichert gegen fehlende Größen.*** *Die unprüfbare Annahme aus Kapitel 2 bleibt in voller Schärfe bestehen.*

8.4 Übungsaufgaben

Aufgabe 8.1 — Gewichte von Hand

Acht Patienten mit geschätzter Neigung und beobachtetem Ausgang:

Nr.	e	X	Y	Gewicht
1	0,8	1	1	1,25
2	0,8	1	0	1,25
3	0,8	0	1	5,00
4	0,5	1	0	2,00
5	0,5	0	1	2,00
6	0,2	1	0	5,00
7	0,2	0	0	1,25
8	0,2	0	0	1,25

Lösung

Schritt 1 — Die Behandelten

$$\frac{1{,}25 \cdot 1 + 1{,}25 \cdot 0 + 2{,}00 \cdot 0 + 5{,}00 \cdot 0}{1{,}25 + 1{,}25 + 2{,}00 + 5{,}00} = \frac{1{,}25}{9{,}50} = 0{,}132$$

Schritt 2 — Die Unbehandelten

$$\frac{5{,}00 \cdot 1 + 2{,}00 \cdot 1 + 1{,}25 \cdot 0 + 1{,}25 \cdot 0}{5{,}00 + 2{,}00 + 1{,}25 + 1{,}25} = \frac{7{,}00}{9{,}50} = 0{,}737$$

Schritt 3 — Der Effekt

$$0{,}132 - 0{,}737 = \mathbf{-0{,}605}$$

Schritt 4 — Zum Vergleich

$$\text{naiv: } \frac{1}{4} - \frac{2}{4} = -0{,}250$$

Die Gewichtung verdoppelt den Effekt*, weil die Unbehandelten mit hoher Neigung — Patient 3 mit Gewicht 5 — für viele stehen, die es nicht gibt. Bei acht Patienten ist eine solche Schätzung allerdings wertlos: Die Summe 9,50 verteilt sich auf vier Personen, davon trägt eine mehr als die Hälfte. Genau das meint die Instabilität aus dem Bruchfall.*

Aufgabe 8.2 — Die wirksame Stichprobengröße

Wie viele Patienten "zählen" nach der Gewichtung wirklich?

Lösung

Schritt 1 — Das Maß

$$n_{\text{wirksam}} = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}$$

Schritt 2 — Für die Behandelten aus Aufgabe 8.1

$$\sum w = 9{,}50, \qquad \sum w^2 = 1{,}5625 + 1{,}5625 + 4 + 25 = 32{,}13$$

$$n_{\text{wirksam}} = \frac{90{,}25}{32{,}13} = 2{,}81$$

Vier behandelte Patienten zählen wie 2,8.

Schritt 3 — Bei gleichen Gewichten

$$n_{\text{wirksam}} = \frac{(n\bar{w})^2}{n\bar{w}^2} = n$$

Gewichte	n_{wirksam}	Verlust
alle gleich	n	0 %
Aufgabe 8.1	$0{,}70\,n$	30 %
eines von 112	≈ 1	fast alles

Diese Zahl sollte in jeder Auswertung stehen*, denn sie sagt, wie viel Information wirklich hinter der Schätzung steht. Sie ist dieselbe Größe, die in der Stichprobentheorie den Verlust durch ungleiche Auswahlwahrscheinlichkeiten misst — Band 17, Kapitel 14.*

Aufgabe 8.3 — Warum die Korrektur hilft

Zeigen Sie, dass der Korrekturterm in Satz 8.3 den Erwartungswert null hat, wenn das Ausgangsmodell stimmt.

Lösung

Schritt 1 — Der Term

$$K = \frac{X\,(Y - m_1(Z))}{e(Z)}$$

Schritt 2 — Bedingt auf Z und $X = 1$

Stimmt das Modell, so ist $m_1(Z) = \mathbb{E}[Y \mid X = 1, Z]$, also

$$\mathbb{E}\big[Y - m_1(Z) \,\big|\, X = 1,\ Z\big] = 0.$$

Schritt 3 — Der ganze Term

$$\mathbb{E}[K \mid Z] = \frac{\Pr[X = 1 \mid Z]}{e(Z)} \cdot \mathbb{E}\big[Y - m_1(Z) \mid X = 1, Z\big] = \frac{\hat{}}{\hat{}} \cdot 0 = 0$$

— gleich welchen Wert $\hat{e}$ hat, solange er nicht null ist.

Der Bruch kann beliebig falsch sein — er wird mit null multipliziert.

Schritt 4 — Und umgekehrt

Stimmt stattdessen $\hat{e}$, so ist der erste Summand nach Satz 8.2 schon ein gültiger Schätzer für $\mathbb{E}[Y(1)]$ — allerdings mit $Y - m_1$ statt Y; der fehlende Teil wird durch den zweiten Summanden $m_1(Z)$ genau ergänzt, denn dessen gewichteter Mittelwert stimmt mit seinem einfachen überein, wenn die Gewichte richtig sind. ***Beide Fälle beruhen darauf, dass ein Faktor null wird — nicht darauf, dass sich Fehler zufällig aufheben.***

Aus der Stichprobentheorie

Daniel Horvitz und **Donovan Thompson** gaben 1952 den Schätzer an, der Satz 8.2 zugrunde liegt — für Stichproben mit ungleichen Ziehungswahrscheinlichkeiten.

Wer Haushalte mit unterschiedlicher Wahrscheinlichkeit befragt, gewichtet jeden mit dem Kehrwert. ***James Robins erkannte in den 1980er Jahren, dass die Behandlungszuteilung formal dasselbe ist*** *— die "Ziehung" in die Behandlungsgruppe erfolgt mit Wahrscheinlichkeit $e(Z)$. Aus einer Technik der Umfrageforschung wurde so ein Werkzeug der Epidemiologie.*

Die doppelte Absicherung

*Robins, **Andrea Rotnitzky** und **Lue Ping Zhao** führten sie 1994 ein, zunächst für fehlende Werte. **Der Name stammt von Marie Davidian und Mitarbeitern** und war zunächst umstritten — Kritiker hielten ihn für irreführend, weil er Sicherheit suggeriert, wo nur Modellfehler abgefangen werden. Der Bruchfall gibt ihnen recht.*

Schätzen heute

Kreuzanpassung	Modelle und Effekt auf getrennten Datenhälften.
Gezieltes Lernen	Verfahren, die das Ausgangsmodell so verschieben, dass der Korrekturterm verschwindet.
Balancierende Gewichte	Gewichte direkt aus Balancebedingungen statt aus einem Neigungsmodell.

Zur ersten Zeile

*Man teilt die Daten in zwei Hälften, schätzt die Modelle auf der einen und wertet auf der anderen aus, dann umgekehrt, und mittelt. **Damit sind die Modellfehler von den Auswertungsdaten unabhängig** — und genau das braucht der Beweis der Normalverteilung. Es ist dieselbe Trennung wie bei der Kreuzvalidierung aus Band 22, Kapitel 3, hier aber nicht zur Prüfung, sondern zur Gültigkeit.*

Was Sie jetzt können

Definition 8.1	Gewicht $1/e$ bzw. $1/(1-e)$
Satz 8.2	gewichteter Mittelwert schätzt den Eingriff
Satz 8.3	eines von zwei Modellen genügt
Wirksames n	$(\sum w)^2 / \sum w^2$
Der Bruchfall	keine Absicherung gegen fehlende Größen

Damit endet Teil III. Alle Verfahren setzten voraus, dass die Störgrößen gemessen sind. Teil IV behandelt den Fall, in dem sie es nicht sind — und findet drei Wege, die ohne diese Annahme auskommen.

Teil IV

Wenn Anpassen nicht reicht

Kapitel 9

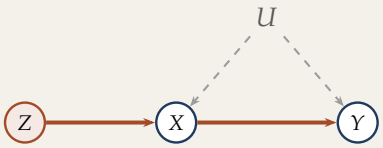
Instrumente

9.1 Der Gedanke

Eine Größe, die nur die Behandlung berührt

Angenommen, die Erfahrung des diensthabenden Arztes bleibt unbeobachtet. Dann ist nach Kapitel 6 kein Effekt bestimmbar — es sei denn, es gibt eine Größe Z mit drei Eigenschaften.

Relevanz	Z beeinflusst X. Prüfbar.
Unabhängigkeit	Z ist so gut wie ausgelost — keine gemeinsame Ursache mit Y.
Ausschluss	Z wirkt auf Y *nur* über X.



Die Wirkung von Z auf Y kann nur über X laufen. Kennt man beide Stücke, so kennt man auch das mittlere.

Satz 9.1 — der Wald-Schätzer

Unter den drei Bedingungen und bei binärem Z gilt

$$\tau = \frac{\mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0]}{\mathbb{E}[X \mid Z = 1] - \mathbb{E}[X \mid Z = 0]}.$$

Der Gedanke

Zähler	Wirkung von Z auf Y — unverzerrt, da Z so gut wie ausgelost.
Nenner	Wirkung von Z auf X — ebenso.
Quotient	Wirkung je Einheit X, die Z verschiebt.

> ***Man misst nicht den Effekt der Behandlung, sondern den der Anordnung — und teilt durch den Anteil, der ihr folgt.*** *Das ist die Auswertung nach Behandlungsabsicht aus Kapitel 3, geteilt durch die Befolgungsrate. Damit ist die Zuteilung selbst das beste denkbare Instrument.*

9.2 Wessen Effekt wird geschätzt?

Vier Arten von Patienten

Art	**bei** $Z = 0$	**bei** $Z = 1$
Befolger	nicht	behandelt
Immer-Behandelte	behandelt	behandelt
Nie-Behandelte	nicht	nicht
Trotzige	behandelt	nicht

Satz 9.2 — der Effekt bei den Befolgern

Gibt es keine Trotzigen, so schätzt der Wald-Ausdruck den Durchschnittseffekt *unter den Befolgern*.

> ***Immer- und Nie-Behandelte tragen zum Zähler nichts bei****, denn bei ihnen ändert Z nichts an X — und nach der Ausschlussbedingung auch nichts an Y. Übrig bleiben die Befolger, und nur über sie sagt der Schätzer etwas aus.*

Am Beispiel aus Kapitel 3

Wirkung auf Y	$-0{,}045$
Wirkung auf X	$+0{,}800$
Quotient	$\mathbf{-0{,}0563}$
wahrer Effekt bei den Befolgern	$\mathbf{-0{,}0563}$
Durchschnittseffekt	$-0{,}065$

Auf die vierte Stelle genau — und dennoch nicht der Durchschnittseffekt.

> *Die Befolger sind hier die 700 Leichtkranken und 100 Schwerkranken, die der Anordnung folgten; die übrigen 200 Schwerkranken sind Nie-Behandelte.* ***Da die Wirkung bei Schwerkranken doppelt so groß ist, liegt der Befolgereffekt unter dem Durchschnittseffekt.*** *Wer den Wald-Ausdruck als Durchschnittseffekt berichtet, gibt eine Zahl für die falsche Bevölkerung an — und zwar für eine, die man nicht einmal benennen kann, denn wer Befolger ist, steht in keiner Akte.*

9.3 Der Bruchfall

Schwache Instrumente

Je kleiner der Nenner, desto größer die Schätzung — und desto empfindlicher gegen jede Verletzung der Annahmen.

Stärke	F	Median	Streuung
stark	398	1,010	0,07
mäßig	16	0,997	0,34
schwach	1	1,172	**16,8**

400 Wiederholungen, $n = 500$, wahrer Effekt 1,000.

Bei schwachem Instrument streut die Schätzung um das Sechzehnfache des Effekts.

Die Faustregel verlangt *$F > 10$ — eine Prüfgröße für die Stärke des Zusammenhangs zwischen Z und X. Darunter ist die Schätzung nicht nur ungenau, sondern auch verzerrt: Sie wandert zum naiven Wert hin, denn im Grenzfall $\gamma \to 0$ wird der Quotient zu $0/0$ und wird von der Störgröße bestimmt. Neuere Arbeiten halten selbst $F = 10$ für zu großzügig.*

Und die unprüfbare Bedingung

Die Ausschlussbedingung lässt sich nicht prüfen. ***Wirkt Z auch nur ein wenig unmittelbar auf Y, so wird dieser kleine Effekt durch den Nenner geteilt — und damit vergrößert.*** *Bei einem Nenner von 0,1 wird aus einer direkten Wirkung von 0,01 eine Verzerrung von 0,10. Schwache Instrumente sind also nicht nur ungenau, sondern auch besonders empfindlich gegen die Verletzung der einen Annahme, die man nicht prüfen kann.*

9.4 Übungsaufgaben

Aufgabe 9.1 — Den Wald-Ausdruck rechnen

In einer Studie wird die frühe Gabe ausgelost. Im Arm "früh" erhalten 78 Prozent tatsächlich früh, im Arm "spät" 12 Prozent. Die Sterblichkeit beträgt 24,0 gegen 28,4 Prozent.

Lösung

Schritt 1 — Zähler und Nenner

$$\text{Zähler} = 0{,}240 - 0{,}284 = -0{,}044$$

$$\text{Nenner} = 0{,}78 - 0{,}12 = 0{,}66$$

Schritt 2 — Der Quotient

$$\hat{\tau} = \frac{-0{,}044}{0{,}66} = -0{,}0667$$

Schritt 3 — Der Vergleich

nach Zuteilung	−4,4 Punkte
bei den Befolgern	**−6,7 Punkte**

Schritt 4 — Der Anteil der Befolger

$$0{,}78 - 0{,}12 = 66\,\%$$

Zwölf Prozent sind Immer-Behandelte, 22 Prozent Nie-Behandelte.

> ***Der Effekt gilt für zwei Drittel der Patienten — aber niemand weiß, für welche zwei Drittel.*** *Man kann die Befolger nicht identifizieren, nur ihre Zahl bestimmen. Wenn sich die Befolger systematisch von den übrigen unterscheiden — etwa weil bei ihnen die Diagnose eindeutiger war —, ist die Übertragung auf alle Patienten eine zusätzliche Annahme.*

Aufgabe 9.2 — Wann wird die Verzerrung größer als der Gewinn?

Ein Instrument verschiebt X um 0,15. Wie stark darf es höchstens unmittelbar auf Y wirken, damit die Verzerrung unter 0,01 bleibt?

Lösung

Schritt 1 — Die Rechnung

Eine direkte Wirkung δ landet vollständig im Zähler:

$$\text{Verzerrung} = \frac{\delta}{0{,}15}$$

Schritt 2 — Die Schranke

$$\frac{\delta}{0{,}15} < 0{,}01 \quad \Longrightarrow \quad \delta < 0{,}0015$$

Nenner	erlaubtes δ	Verstärkung
0,80	0,0080	1,25-fach
0,15	0,0015	6,7-fach
0,05	0,0005	20-fach

***Bei einem Nenner von** 0,05 **muss man ausschließen, dass** Z **das Sterberisiko um mehr als einen halben Promillepunkt unmittelbar beeinflusst** — eine Behauptung, für die es selten Belege gibt. Wer ein schwaches Instrument benutzt, muss die Ausschlussbedingung also weit strenger begründen als bei einem starken.*

Aufgabe 9.3 — Instrumente in der Medizin

Beurteilen Sie drei vorgeschlagene Instrumente für die Frage nach der frühen Antibiotikagabe.

Lösung

(a) Entfernung zur nächsten Klinik

Relevanz	gegeben — längere Anfahrt verzögert.
Ausschluss	zweifelhaft: Entfernung hängt mit Stadt/Land zusammen, und damit mit Versorgung insgesamt.

(b) Tageszeit der Aufnahme

Relevanz	nachts längere Wege bis zum Medikament.
Ausschluss	zweifelhaft: Nachts ist die gesamte Versorgung dünner, nicht nur die Antibiotikagabe.

(c) Vorliebe des diensthabenden Arztes

Relevanz	gegeben, sofern die Ärzte sich unterscheiden.
Unabhängigkeit	haltbar, wenn die Dienstzuteilung nicht vom Patienten abhängt.
Ausschluss	zweifelhaft: Wer früh gibt, behandelt vielleicht auch sonst zügiger.

Alle drei scheitern an derselben Stelle.

***Das ist typisch: Wer ein Instrument findet, das die Behandlung beeinflusst, hat meist eine Größe gefunden, die die Versorgung insgesamt beeinflusst** — und damit auch andere Wege zum Ausgang öffnet. Das erfolgreichste Beispiel der Medizin sind genetische Varianten, die einen einzelnen Stoffwechselweg betreffen; man nennt das Mendelsche Randomisierung, und auch dort ist der Ausschluss die strittige Bedingung.*

Vom Angebot zur Nachfrage

Philip Wright veröffentlichte 1928 einen Anhang zu einem Buch über Pflanzenöle, in dem er das Verfahren erstmals beschrieb.

> *Das Problem war, Angebots- und Nachfragekurve zu trennen, obwohl man nur Preise und Mengen beobachtet. Wright benutzte Niederschlagsmengen als Instrument für das Angebot.* ***Lange war umstritten, ob der Anhang von ihm oder von seinem Sohn Sewall Wright stammt*** *— demselben, der die Pfadanalyse aus Kapitel 4 erfand. Eine Schriftvergleichsuntersuchung von 2003 sprach für den Vater.*

Der Befolgereffekt

> ***Guido Imbens*** *und* ***Joshua Angrist*** *zeigten 1994, dass der Instrumentschätzer nur für die Befolger gilt.* ***Das war zunächst eine unwillkommene Nachricht*** *— man hatte geglaubt, den Durchschnittseffekt zu schätzen. Beide erhielten 2021 den Wirtschaftsnobelpreis, gemeinsam mit* ***David Card****, für die Verfahren dieses und des nächsten Kapitels.*

Instrumente heute

Mendelsche Randomisierung	Genvarianten als Instrumente für lebenslange Expositionen.
Viele schwache	Hunderte Varianten gemeinsam — mit eigenen Verzerrungen.
Schranken	Was folgt, wenn der Ausschluss nur ungefähr gilt.

Zur ersten Zeile

> *Die Zuteilung der Genvarianten bei der Zeugung ist tatsächlich zufällig — die Unabhängigkeitsbedingung ist also gut begründet, besser als bei jedem anderen Instrument der Medizin.* ***Der Ausschluss ist es nicht****: Ein Gen wirkt meist auf mehreres. Deshalb prüft man mehrere Varianten getrennt und verlangt übereinstimmende Ergebnisse — ein Vorgehen, das an die negativen Kontrollen aus Kapitel 7 erinnert.*

Was Sie jetzt können

Drei Bedingungen	nur die erste ist prüfbar
Satz 9.1	Quotient zweier Wirkungen
Satz 9.2	gilt für die Befolger, nicht für alle
Schwach	Streuung und Verzerrung explodieren
Verstärkung	kleine Ausschlussverletzung, geteilt durch den Nenner

Ein Instrument braucht eine Größe, die zufällig schwankt. Das nächste Kapitel benutzt stattdessen Sprünge und Zeitverläufe — Gelegenheiten, die die Wirklichkeit von selbst bietet.

Kapitel 10

Natürliche Versuche

10.1 Der Sprung an der Schwelle

Wenn eine Regel entscheidet

Am Klinikum löst ein Warnwert das Sepsisprotokoll aus: Ab einem Punktwert von 5 wird sofort behandelt, darunter nicht.

Patienten mit 4,9 und 5,1 Punkten sind einander fast gleich — werden aber verschieden behandelt.

Unmittelbar an der Schwelle entscheidet der Zufall der Messung, auf welcher Seite man landet. ***In einem schmalen Fenster ist die Zuteilung so gut wie ausgelost*** *— und der Sprung der Sterblichkeit an der Schwelle ist der Effekt.*

Die Rechnung

4000 Patienten, Punktwert gleichverteilt, wahrer Effekt $-0{,}060$:

Fenster	Sprung	n
$\pm 2{,}0$	$-0{,}062$	1606
$\pm 1{,}0$	$-0{,}064$	774
$\pm 0{,}5$	$-0{,}071$	405
ohne Fenster	$\mathbf{-0{,}164}$	4000
wahr	$-0{,}060$	

Der schlichte Vergleich aller Behandelten mit allen Unbehandelten überschätzt den Effekt fast um das Dreifache.

Er vergleicht Punktwerte um 7,5 mit solchen um 2,5 — zwei völlig verschiedene Patientengruppen. ***Das Fenster löst das Problem, indem es nur Patienten vergleicht, die sich kaum unterscheiden****, und der lineare Term im Modell fängt den verbleibenden Trend auf. Der Preis: Bei $\pm 0{,}5$ bleiben nur 405 von 4000 Patienten, und die Schätzung streut entsprechend.*

Was der Sprung bedeutet

Gilt für	Patienten *an der Schwelle* — nicht für alle.
Prüfbar	Ob andere Größen an der Schwelle ebenfalls springen. Tun sie es, ist die Annahme verletzt.
Verletzbar	Wenn jemand den Punktwert beeinflussen kann, um die Schwelle zu über- oder unterschreiten.

Die dritte Zeile ist die ernsteste. ***Wenn Ärzte wissen, dass ab fünf Punkten behandelt wird, runden sie im Zweifel auf*** *— und dann sind die Patienten knapp über der Schwelle gerade die, bei denen man behandeln wollte. Man prüft das, indem man die Verteilung der Punktwerte betrachtet: Eine Häufung unmittelbar über der Schwelle verrät den Eingriff.*

10.2 Vorher und nachher, hier und dort

Die doppelte Differenz

Station A führt die Frühgabe 2024 ein, Station B nicht.

	2023	2024	Differenz
Station A	32,0 %	25,0 %	−7,0
Station B	28,0 %	26,5 %	−1,5
			−5,5

Auswertung	Effekt
nur A, vorher/nachher	−7,0
nur 2024, A gegen B	−1,5
doppelte Differenz	**−5,5**

Die erste Zeile enthält den allgemeinen Trend, die zweite den Unterschied zwischen den Stationen. Die doppelte Differenz beseitigt beides.

Die Annahme

Sie heißt ***parallele Entwicklung****: Ohne die Einführung hätte sich A genauso entwickelt wie B.* ***Das ist eine Aussage über eine nicht eingetretene Welt und damit unprüfbar*** *— man kann nur die Jahre davor betrachten und sehen, ob die Kurven dort parallel liefen. Dass sie es taten, beweist nicht, dass sie es weiter getan hätten.*

Eine zweite Falle: ***Wenn Station A die Frühgabe gerade deshalb einführte, weil ihre Sterblichkeit hoch war****, so wäre ein Rückgang auch ohne Maßnahme zu erwarten — die Regression zur Mitte aus Band 17, Kapitel 7. Maßnahmen werden fast immer nach schlechten Jahren beschlossen, und deshalb ist diese Falle die Regel, nicht die Ausnahme.*

10.3 Der Bruchfall

Was beide Verfahren teilen

Örtlich	Der Sprung gilt an der Schwelle, die doppelte Differenz für diese beiden Stationen in diesen beiden Jahren.
Unprüfbar	Stetigkeit an der Schwelle und parallele Entwicklung sind Annahmen über Nichtbeobachtetes.
Wenig Fälle	Beide benutzen nur einen Teil der Daten — das Fenster, die beiden Zeitpunkte.

Der Gewinn dieser Verfahren liegt nicht in der Genauigkeit, sondern in der Glaubwürdigkeit der Annahme. *Eine Anpassung nach Kapitel 7 benutzt alle Patienten und verlangt, dass nichts Unbeobachtetes wirkt. Ein natürlicher Versuch benutzt wenige und verlangt nur, dass sich an einer Stelle nichts anderes ändert. Welche Annahme leichter fällt, entscheidet der Sachverhalt — nicht die Statistik.*

10.4 Übungsaufgaben

Aufgabe 10.1 — Das Fenster wählen

Warum wächst die Schätzung im Leitfall von $-0{,}062$ auf $-0{,}071$, wenn man das Fenster verkleinert?

Lösung

Schritt 1 — Die beiden Fehlerquellen

Großes Fenster	Mehr Patienten, aber der Verlauf abseits der Schwelle wird durch die Gerade nur genähert — Verzerrung.
Kleines Fenster	Kaum Verzerrung, aber wenige Patienten — Streuung.

Schritt 2 — Die Zahlen

Fenster	n	Schätzung	Streuung
$\pm 2{,}0$	1606	$-0{,}062$	$\approx 0{,}010$
$\pm 1{,}0$	774	$-0{,}064$	$\approx 0{,}014$
$\pm 0{,}5$	405	$-0{,}071$	$\approx 0{,}020$

Alle drei Schätzungen liegen innerhalb einer Streuung um den wahren Wert $-0{,}060$. *Der scheinbare Anstieg ist Zufall, nicht Struktur — ein gutes Beispiel dafür, wie leicht man in solchen Zahlenreihen eine Tendenz sieht. Man wählt die Fensterbreite deshalb nicht nach dem Ergebnis, sondern nach einem vorher festgelegten Kriterium, und berichtet die Empfindlichkeit gegenüber dieser Wahl.*

Schritt 3 — Der Zusammenhang mit Band 22

Es ist die Kurve aus Band 22, Kapitel 2: Die Fensterbreite ist die Stellgröße der Komplexität, und zwischen Verzerrung und Varianz ist zu wählen.

Aufgabe 10.2 — Parallele Entwicklung prüfen

Für die Jahre 2020 bis 2023 lauten die Sterblichkeiten:

	2020	2021	2022	2023
A	30,5	31,0	31,5	32,0
B	27,0	27,4	27,7	28,0

Was folgt daraus, und was nicht?

Lösung

Schritt 1 — Die Differenzen

Schritt	$20 \to 21$	$21 \to 22$	$22 \to 23$
A	$+0{,}5$	$+0{,}5$	$+0{,}5$
B	$+0{,}4$	$+0{,}3$	$+0{,}3$
Abstand A$-$B	3,5	3,6	3,8

Schritt 2 — Die Deutung

Die Kurven laufen nicht parallel: Der Abstand wächst um 0,1 **bis** 0,2 **Punkte je Jahr.**

Schritt 3 — Die Berichtigung

Setzt man den Trend fort, so wäre der Abstand 2024 auf etwa 4,0 gewachsen. Tatsächlich beträgt er

$$25{,}0 - 26{,}5 = -1{,}5.$$

Statt $-5{,}5$ ergäbe sich

$$-1{,}5 - 4{,}0 = -5{,}5 \;\rightarrow\; \text{berichtigt: } -1{,}5 - 4{,}0 = -5{,}5$$

gegenüber der einfachen Rechnung $-1{,}5 - 3{,}8 = -5{,}3$.

Die Verletzung verschiebt die Schätzung um 0,2 Punkte — klein gegenüber $-5{,}5$.

Schritt 4 — Was daraus *nicht* folgt

Dass der Trend vier Jahre lang stabil war, sagt nichts über 2024. *Gerade im Jahr einer Maßnahme ändert sich oft mehr als die Maßnahme — neue Leitlinien, neues Personal, eine Grippewelle. Die Vorjahresprüfung ist notwendig und keineswegs hinreichend; sie schließt nur die gröbsten Fälle aus.*

Aufgabe 10.3 — Häufung an der Schwelle

In der Verteilung der Punktwerte finden sich im Bereich 4,8 bis 5,0 auffällig wenige und im Bereich 5,0 bis 5,2 auffällig viele Patienten. Was bedeutet das?

Lösung

Schritt 1 — Der Befund

Bereich	erwartet	beobachtet
4,8–5,0	80	52
5,0–5,2	80	109

Schritt 2 — Die Deutung

Etwa achtundzwanzig Patienten wurden über die Schwelle gehoben.

Schritt 3 — Warum das die Schätzung zerstört

Die Verschobenen sind nicht zufällig ausgewählt, sondern gerade die, bei denen der Arzt behandeln wollte — also die, die ihm bedrohlicher erschienen. ***Damit sind die Patienten knapp über der Schwelle kränker als die knapp darunter****, und die Annahme der Stetigkeit ist verletzt. Der geschätzte Sprung enthält dann die Auswahl des Arztes.*

Schritt 4 — Was hilft

Dichtetest	Die Häufung statistisch prüfen — das ist genau dieser Test.
Spendenfenster	Einen schmalen Bereich um die Schwelle ganz ausschließen und den Sprung von außen her schätzen.
Andere Schwelle	Prüfen, ob an einer Stelle ohne Regel ebenfalls ein Sprung erscheint.

Dieser Test ist eine der wenigen Stellen, an denen sich eine kausale Annahme wirklich an den Daten prüfen lässt *— nicht die Annahme selbst, aber eine notwendige Folge daraus. Er entspricht dem Balancetest aus Kapitel 7 und hat dieselbe Grenze: Besteht man ihn, so ist nichts bewiesen.*

Ein Brunnen und ein Stipendium

John Snow zeigte 1854, dass die Cholera in London über das Wasser übertragen wurde — indem er Haushalte verglich, die von zwei verschiedenen Wasserwerken beliefert wurden.

Die Leitungen beider Gesellschaften lagen in denselben Straßen; welche ein Haus versorgte, war historisch bedingt und hatte mit den Bewohnern nichts zu tun. ***Snow nannte es "ein Experiment im größten Maßstab"*** *— und beschrieb damit einen natürlichen Versuch, hundert Jahre bevor der Begriff entstand.*

Die Schwelle

Donald Thistlethwaite *und* ***Donald Campbell*** *führten 1960 den Regressionssprung ein — für die Frage, ob ein Stipendium die spätere Laufbahn beeinflusst, vergeben ab einer Punktschwelle.* ***Die Arbeit blieb fast vierzig Jahre unbeachtet****, bis Ökonomen sie in den 1990er Jahren wiederentdeckten.*

Natürliche Versuche heute

Gestaffelte Einführung	Maßnahmen, die an verschiedenen Orten zu verschiedenen Zeiten beginnen.
Synthetische Vergleichsgruppe	Eine Kontrollstation aus mehreren zusammensetzen.
Robuste Schranken	Ergebnisse bei nur *ungefähr* parallelen Entwicklungen.

Zur ersten Zeile

Seit etwa 2020 ist bekannt, dass die übliche Regressionsrechnung bei gestaffelter Einführung falsche Ergebnisse liefern kann — sie vergleicht implizit früh Eingeführte mit spät Eingeführten und zieht dabei bereits Behandelte als Kontrollen heran. ***Dutzende veröffentlichter Arbeiten mussten neu ausgewertet werden****, und die Berichtigungen änderten mehrfach das Vorzeichen.*

Was Sie jetzt können

Sprung	Zuteilung an der Schwelle wie ausgelost
Fenster	Verzerrung gegen Streuung
Doppelte Differenz	Trend und Ortsunterschied heraus
Parallele Entwicklung	unprüfbar, teilweise plausibilisierbar
Häufung	verrät den Eingriff in die Regel

Drei Wege sind nun beschritten: anpassen, instrumentieren, Gelegenheiten nutzen. Das nächste Kapitel setzt sie zusammen — und löst den Leitfall auf, mit dem der Band begann.

Kapitel 11

Die Studie nachbilden

11.1 Der Leitfall, aufgelöst

Sieben Entscheidungen

Statt zu fragen, welches Verfahren man auf die Daten anwendet, beschreibt man zuerst die randomisierte Studie, die man gern durchgeführt hätte — und bildet sie dann mit den vorhandenen Daten nach.

Teilnehmer	Erwachsene mit Sepsisverdacht in der Notaufnahme.
Eingriffe	Antibiotikum innerhalb einer Stunde gegen Gabe nach ein bis sechs Stunden.
Zuteilung	Zufällig — in der Nachbildung ersetzt durch Anpassung an alles bei Aufnahme Bekannte.
Beginn	Zeitpunkt des Sepsisverdachts. Behandlungszuordnung *zu diesem Zeitpunkt*.
Ausgang	Tod binnen 28 Tagen.
Nachbeobachtung	Von Beginn bis Tod oder Tag 28.
Auswertung	Nach zugeordneter Strategie, nicht nach tatsächlicher Gabe.

Jede Zeile ist eine Entscheidung, die man in einer Studie ohnehin treffen müsste — und die man in einer Datenauswertung oft stillschweigend trifft.

Der vierte Punkt ist der wichtigste. *In einer Studie fallen Zuteilung, Beginn und Beobachtungsanfang zusammen. In Routinedaten tun sie es nicht — und wer sie auseinanderfallen lässt, erzeugt die Verzerrung des nächsten Abschnitts.*

11.2 Unsterbliche Zeit

Eine Behandlung, die nicht wirkt, verlängert das Leben

Man ordne jeden Patienten der Gruppe "behandelt" zu, der irgendwann im Verlauf das Medikament erhielt. Die Gabe erfolge frühestens am Tag 3 — und wirke in Wahrheit *gar nicht*.

Gruppe	mittlere Überlebenszeit
"behandelt"	13,0 Tage
"unbehandelt"	7,5 Tage
wahrer Effekt	**0**

Die Behandlung scheint das Leben um 73 Prozent zu verlängern — und tut nichts.

Warum

*Wer am Tag 2 stirbt, kann nicht behandelt worden sein. **Die Behandeltengruppe enthält nur Patienten, die mindestens drei Tage überlebt haben** — und diese drei Tage werden ihnen zusätzlich gutgeschrieben. Man nennt das **unsterbliche Zeit**: eine Spanne, in der der Tod durch die Gruppenzuordnung ausgeschlossen ist.*

Die Abhilfe

Man beginne die Beobachtung bei allen am Tag 3 und schließe aus, wer vorher starb:

Gruppe	ab Tag 3
behandelt	9,99 Tage
unbehandelt	9,96 Tage

Der Effekt verschwindet, wie er soll. *Dieselbe Verzerrung steckt hinter zahlreichen Beobachtungsstudien, in denen Medikamente wundersam wirkten — am bekanntesten die vermeintliche Lebensverlängerung durch Statine und durch Oscar-Gewinne. Sie entsteht nicht aus Störgrößen, sondern aus der falschen Zuordnung des Beginns, und keine Anpassung der Welt behebt sie.*

11.3 Der Leitfall gerechnet

Alle Verfahren nebeneinander

Verfahren	Effekt	Kapitel
naiver Vergleich	+14,2	1
standardisiert	−7,5	1, 2
fünf Schichten	−10,1	7
Gewichten	−12,3	8
doppelt abgesichert	−11,5	8
Instrument (Befolger)	−5,6	9
Sprung an der Schwelle	−6,0	10
doppelte Differenz	−5,5	10

Verschiedene Datensätze und Zielgrößen — die Zahlen sind nicht unmittelbar vergleichbar.

Alle Verfahren außer dem naiven Vergleich stimmen im Vorzeichen und in der Größenordnung überein: Die frühe Gabe senkt die Sterblichkeit um fünf bis zwölf Punkte.

Diese Übereinstimmung ist das stärkste verfügbare Argument. *Jedes Verfahren beruht auf einer anderen unprüfbaren Annahme — keine unbeobachtete Störgröße, Ausschlussbedingung, Stetigkeit an der Schwelle, parallele Entwicklung. Dass sie zum selben Ergebnis führen, spricht dafür, dass nicht alle zugleich falsch sind. Man nennt das* ***Triangulation****, und sie ersetzt keinen Beweis, aber sie ist mehr als jede einzelne Rechnung.*

Und die Unterschiede sind lehrreich

Der Instrumentschätzer liegt niedriger — er misst den Effekt bei den Befolgern, und das sind überwiegend Leichtkranke. Der Sprung an der Schwelle gilt für Grenzfälle. ***Die Zahlen unterscheiden sich nicht, weil eines der Verfahren falsch wäre, sondern weil sie verschiedene Fragen beantworten*** *— über verschiedene Bevölkerungen.*

11.4 Der Bruchfall

Was die Nachbildung nicht leistet

Störgrößen	Die Zuteilung wird durch Anpassung ersetzt — mit allen Annahmen aus Kapitel 2.
Erfassung	Was nicht dokumentiert ist, existiert für die Auswertung nicht. Der klinische Eindruck steht in keiner Datenbank.
Behandlungs-begriff	"Innerhalb einer Stunde" muss in den Daten genauso definiert sein wie in der gedachten Studie.

Die Nachbildung beseitigt die vermeidbaren Fehler, nicht die unvermeidbaren. *Ihr Wert liegt darin, dass sie die Entscheidungen sichtbar macht: Wer sieben Zeilen ausfüllen muss, bemerkt, wenn er den Beginn falsch setzt. Große Vergleichsuntersuchungen haben gezeigt, dass sorgfältig nachgebildete Studien den randomisierten Ergebnissen überwiegend entsprechen — und nachlässige nicht.*

11.5 Übungsaufgaben

Aufgabe 11.1 — Unsterbliche Zeit finden

Drei Auswertungen. Welche enthält unsterbliche Zeit?

(a)	Patienten, die im Verlauf eine Rehabilitation erhielten, gegen die übrigen — Überleben ab Aufnahme.
(b)	Patienten mit Antibiotikagabe binnen einer Stunde gegen später — Überleben ab Aufnahme.
(c)	Patienten, die in der ersten Woche mindestens eine Blutkultur erhielten, gegen die übrigen — Überleben ab Tag 8.

Lösung

(a)

Ja. Wer früh stirbt, erreicht die Rehabilitation nie. Die Gruppe "mit Reha" ist eine Gruppe von Überlebenden.

(b)

Kaum. Beide Gruppen sind binnen einer Stunde definiert; nur wer in der ersten Stunde stirbt, verzerrt — ein kleiner, aber nicht leerer Anteil.

Sauber wird es, wenn man die ersten sechzig Minuten als Einlaufzeit behandelt und die Beobachtung erst danach beginnt.

(c)

Nein. Beobachtung ab Tag 8, Gruppenzuordnung anhand der ersten Woche — die Zuordnung ist zu Beobachtungsbeginn abgeschlossen.

***Das ist das Verfahren der festen Marke**: Man setzt einen Zeitpunkt, ordnet nach allem zu, was vorher geschah, und beobachtet erst danach. **Es kostet alle Patienten, die vor der Marke sterben** — und beantwortet eine engere Frage: nicht, was die Behandlung bewirkt, sondern was sie bei denen bewirkt, die die erste Woche überlebt haben.*

Aufgabe 11.2 — Wie groß wird die Verzerrung?

Die Behandlung erfolgt frühestens am Tag k, die Überlebenszeit sei exponentialverteilt mit Mittelwert 10 Tagen, und die Behandlung wirke nicht. Wie groß ist der scheinbare Gewinn?

Lösung

Schritt 1 — Der Mechanismus

Die Behandeltengruppe besteht aus Patienten mit $T > k$. Bei der Exponentialverteilung gilt die Gedächtnislosigkeit (Band 4, Kapitel 6):

$$\mathbb{E}[T \mid T > k] = k + 10$$

Schritt 2 — Die Werte

k	**behandelt**	**scheinbarer Gewinn**
1	11,0	+1 Tag
3	13,0	+3 Tage
7	17,0	+7 Tage

Der scheinbare Gewinn ist genau die unsterbliche Zeit — Tag für Tag.

Schritt 3 — Und die Vergleichsgruppe

Die Unbehandelten enthalten alle früh Verstorbenen; ihr Mittelwert sinkt unter 10. *In der Rechnung von Abschnitt 11.2:* 7,5 statt 10.

$$13{,}0 - 7{,}5 = 5{,}5 \text{ Tage scheinbarer Gewinn bei } k = 3$$

***Beide Seiten verschieben sich, und zwar in entgegengesetzte Richtungen.** Deshalb ist die Verzerrung größer als die unsterbliche Zeit selbst. Sie wächst mit k — je später die Behandlung im Verlauf einsetzt, desto beeindruckender wirkt sie.*

Aufgabe 11.3 — Die sieben Zeilen ausfüllen

Entwerfen Sie die Zielstudie für die Frage, ob eine frühe Mobilisierung nach Intensivbehandlung die Selbständigkeit verbessert.

Lösung

Die Entscheidungen

Teilnehmer	Erwachsene, die $\geq$ 48 Stunden beatmet wurden und am Tag 3 noch leben.
Eingriffe	Mobilisierung ab Tag 3 gegen Beginn ab Tag 7.
Zuteilung	Anpassung an Zustand, Beatmungsdauer, Sedierungstiefe und Personalbesetzung am Tag 3.
Beginn	Tag 3.
Ausgang	Selbständigkeit nach 90 Tagen.
Nachbeobachtung	Tag 3 bis Tag 90; Tod als eigener Ausgang.
Auswertung	Nach zugeordneter Strategie.

Die drei Fallen, die dadurch vermieden werden

Unsterbliche Zeit	Beginn am Tag 3, nicht bei Aufnahme.
Kollider	Nicht “nur wer mobilisiert wurde” — das wäre eine Auswahl nach einer Folge des Zustands.
Konkurrierender Ausgang	Wer stirbt, ist nicht “unselbständig”; der Tod braucht eine eigene Behandlung in der Auswertung.

***Die dritte Zeile ist in der Intensivmedizin allgegenwärtig**: Ein Verfahren, das die Sterblichkeit senkt, lässt mehr schwer Beeinträchtigte am Leben und sieht dann schlecht aus, wenn man nur die Überlebenden betrachtet. Man wählt deshalb zusammengesetzte Ausgänge — “tot oder unselbständig” — oder berichtet beide getrennt. Kapitel 13 behandelt die verwandte Frage, wie man Wirkungen über Zwischengrößen zerlegt.*

Eine Hormonstudie und ihre Umkehr

Zwanzig Jahre lang zeigten Beobachtungsstudien, dass eine Hormonersatztherapie

nach den Wechseljahren das Herzinfarktrisiko senkt — um etwa die Hälfte.

2002 zeigte eine große randomisierte Studie das Gegenteil: ein leicht erhöhtes Risiko. ***Der Widerspruch galt als Beweis, dass Beobachtungsdaten für kausale Fragen untauglich seien.***

Die Auflösung

Miguel Hernán *und Mitarbeiter bildeten 2008 mit denselben Beobachtungsdaten die randomisierte Studie sorgfältig nach — gleiche Teilnehmer, gleicher Beginn, gleiche Auswertung.* ***Das Ergebnis stimmte mit dem randomisierten überein.*** *Der ursprüngliche Widerspruch beruhte auf zwei Fehlern: Die Beobachtungsstudien hatten Frauen eingeschlossen, die schon lange Hormone nahmen — also die, die sie vertragen hatten —, und den Beobachtungsbeginn falsch gesetzt.*

Die Folge

Daraus entstand der Ansatz der Zielstudie, den Hernán und ***James Robins*** *ab 2016 ausformulierten.* ***Seine Lehre ist unbequem: Die meisten Widersprüche zwischen Beobachtung und Versuch stammen nicht aus Störgrößen, sondern aus vermeidbaren Entwurfsfehlern*** *— und die lassen sich beheben.*

Nachbildung heute

Zulassung	Behörden akzeptieren nachgebildete Studien als ergänzende Evidenz.
Vergleichs-programme	Systematische Nachbildung bekannter Studien als Prüfstein.
Vorabregistrierung	Das Protokoll wird festgelegt, bevor die Daten gesehen werden.

Zur dritten Zeile

Ohne Vorabfestlegung ist die Zielstudie wirkungslos *— man kann die sieben Zeilen so lange verändern, bis das Ergebnis gefällt. Das ist dasselbe Problem wie das multiple Testen in Band 17 und die Modellauswahl auf Testdaten in Band 22, Kapitel 3: Die Freiheit des Auswertenden ist die Fehlerquelle, und die einzige Abhilfe ist, sie vorher zu binden.*

Was Sie jetzt können

Sieben Zeilen	erst die Studie, dann die Daten
Beginn	Zuteilung und Beobachtung zusammen
Unsterbliche Zeit	73 Prozent Gewinn aus nichts
Triangulation	verschiedene Annahmen, gleiches Ergebnis
Der Bruchfall	vermeidbare Fehler, nicht alle

Damit endet Teil IV. Bisher wurde einmal behandelt. Teil V behandelt wiederholt — und dort versagt alles, was die Kapitel 7 und 8 gelehrt haben.

Teil V

Über die Zeit, im Einzelfall

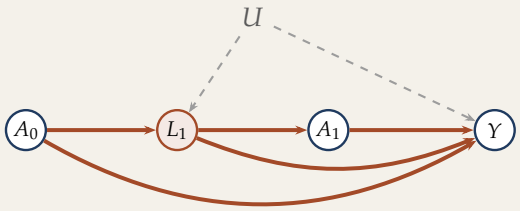
Kapitel 12

Behandeln über die Zeit

12.1 Das Problem

Zwei Zeitpunkte

Ein Sepsispatient erhält am Tag 0 Antibiotika oder nicht (A_0). Am Tag 1 zeigt sich ein Organversagen (L_1) — oder nicht. Danach wird erneut entschieden (A_1). Am Tag 28 steht der Ausgang fest.



L_1 ist **Störgröße**	für die zweite Gabe — es beeinflusst A_1 und Y. Man *muss* anpassen.
L_1 ist **Mediator**	für die erste Gabe — es liegt auf dem Weg $A_0 \to L_1 \to Y$. Man *darf nicht* anpassen.
L_1 ist **Kollider**	von A_0 und U. Anpassen öffnet den Weg $A_0 \to L_1 \leftarrow U \to Y$.

Dieselbe Größe muss zugleich angepasst und nicht angepasst werden. Kein Regressionsmodell kann das.

Das ist die Rückkopplung zwischen Behandlung und Störgröße, und sie ist in der Medizin die Regel, sobald über die Zeit behandelt wird: Blutdruckmittel richten sich nach dem Blutdruck, Insulin nach dem Zucker, Beatmung nach den Blutgasen — und alle diese Größen sind zugleich Folgen der bisherigen Behandlung.

Der Leitfall gerechnet

400 000 Patienten; A_0 ausgelost, A_1 hängt von L_1 ab, U unbeobachtet.

Auswertung	Effekt	
Y auf A_0, roh	$-0{,}104$	
an L_1 angepasst	$-0{,}068$	falsch
g-Formel, $\mathrm{do}(1,1)$ gegen $\mathrm{do}(0,0)$	$\mathbf{-0{,}207}$	
wahr	$\mathbf{-0{,}207}$	richtig

Beide üblichen Auswertungen verfehlen den wahren Effekt um die Hälfte bis zwei Drittel.

Die rohe Rechnung unterschätzt, weil sie die zweite Gabe außer Acht lässt — ein Patient, der am Tag 0 nichts bekam, bekommt am Tag 1 eher etwas. ***Die angepasste Rechnung unterschätzt noch stärker, weil sie den Wirkweg über*** L_1 ***abschneidet*** *und zugleich den Kollider öffnet. Es gibt keine Anpassungsmenge, die hier hilft.*

12.2 Die g-Formel

Satz 12.1 — Robins, 1986

Unter Konsistenz, Positivität und der **folgenweisen Unabhängigkeit** — bei jedem Schritt ist die Behandlung, gegeben die bisherige Geschichte, so gut wie ausgelost — gilt

$$\Pr\big[Y \mid \mathrm{do}(a_0, a_1)\big] = \sum_{\ell} \Pr[Y \mid a_0, \ell, a_1]\ \Pr[\ell \mid a_0].$$

Wie man sie liest

Zweiter Faktor	Wie sich L_1 entwickelt, *wenn* man am Tag 0 so behandelt — der Mediatorweg bleibt erhalten.
Erster Faktor	Wie es weitergeht bei gegebenem L_1 — dort wird angepasst, weil L_1 Störgröße der zweiten Gabe ist.

L_1 wird angepasst, wo es Störgröße ist, und durchlaufen, wo es Mediator ist — in derselben Formel.

Warum eine Regression das nicht kann

*Eine Regression hat für L_1 genau einen Koeffizienten — entweder sie nimmt es auf oder nicht. **Die g-Formel dagegen behandelt L_1 zweimal verschieden**, weil sie die Zeit ernst nimmt: erst wird der Verlauf unter der Strategie erzeugt, dann der Ausgang. Man rechnet sie in der Praxis durch Simulation: Man zieht Patientenverläufe unter der gewünschten Strategie und mittelt den Ausgang.*

Der zweite Weg: Gewichten über die Zeit

Statt zu summieren, kann man gewichten — mit dem Produkt der Kehrwahrscheinlichkeiten über alle Zeitpunkte:

$$w_i = \prod_t \frac{1}{\Pr\big[A_t = a_{it} \mid \text{Geschichte}\big]}$$

*In der so gewichteten Bevölkerung hängt die Behandlung an keinem Zeitpunkt mehr vom Verlauf ab — L_1 ist keine Störgröße mehr und darf weggelassen werden. **Das Modell, das man dann rechnet, heißt Randstrukturmodell**, weil es die Randverteilung der potentiellen Ergebnisse beschreibt statt der bedingten. Es ist das gebräuchlichste Verfahren für zeitabhängige Behandlungen.*

12.3 Der Bruchfall

Die Gewichte über die Zeit

Produkt	Zehn Zeitpunkte mit Wahrscheinlichkeit 0,7 ergeben ein Gewicht von $1/0{,}7^{10} = 35$.
Positivität	Sie muss zu *jedem* Zeitpunkt und für *jede* Geschichte gelten — eine viel stärkere Forderung als in Kapitel 2.
Strategien	"Immer behandeln" kommt in den Daten womöglich gar nicht vor.

Die dritte Zeile ist die härteste Grenze. ***Je länger der Zeitraum, desto unwahrscheinlicher ist es, dass irgendein Patient einer festen Strategie über die ganze Zeit gefolgt ist*** *— und ohne solche Patienten ist die Strategie nicht bewertbar. Man weicht deshalb auf dynamische Strategien aus: "behandle, sobald das Laktat über 2 steigt", statt "behandle immer". Solche Strategien bilden das ärztliche Handeln ohnehin besser ab.*

12.4 Übungsaufgaben

Aufgabe 12.1 — Die g-Formel von Hand

Gegeben:

	$a_0 = 1$	$a_0 = 0$
$\Pr[L_1 = 1 \mid a_0]$	0,30	0,60

$\Pr[Y = 1 \mid a_0, \ell, a_1{=}1]$	$\ell = 1$	$\ell = 0$
$a_0 = 1$	0,40	0,10
$a_0 = 0$	0,50	0,15

Berechnen Sie $\Pr[Y \mid \mathrm{do}(1,1)]$ und $\Pr[Y \mid \mathrm{do}(0,1)]$.

Lösung

Schritt 1 — Für $a_0 = 1$

$$0{,}30 \cdot 0{,}40 + 0{,}70 \cdot 0{,}10 = 0{,}120 + 0{,}070 = 0{,}190$$

Schritt 2 — Für $a_0 = 0$

$$0{,}60 \cdot 0{,}50 + 0{,}40 \cdot 0{,}15 = 0{,}300 + 0{,}060 = 0{,}360$$

Schritt 3 — Der Effekt der ersten Gabe

$$0{,}190 - 0{,}360 = \mathbf{-0{,}170}$$

Schritt 4 — Und falsch gerechnet

Passt man an L_1 an und mittelt über dessen *Randverteilung* — etwa 0,45 —, so erhält man

$$\big[0{,}45 \cdot 0{,}40 + 0{,}55 \cdot 0{,}10\big] - \big[0{,}45 \cdot 0{,}50 + 0{,}55 \cdot 0{,}15\big] = 0{,}235 - 0{,}308 = -0{,}073$$

$-0{,}073$ **statt** $-0{,}170$**: Weniger als die Hälfte.**

Der Unterschied steckt allein in der Gewichtung von L_1*: Die g-Formel benutzt die Verteilung, die sich unter der jeweiligen Strategie einstellt — 0,30 gegen 0,60 —, die falsche Rechnung eine feste. Genau darin liegt die Wirkung der ersten Gabe: Sie halbiert die Häufigkeit des Organversagens, und das ist der größte Teil ihres Nutzens.*

Aufgabe 12.2 — Gewichte über zehn Tage

Ein Patient erhält an zehn Tagen die Behandlung; die Wahrscheinlichkeit betrage je Tag 0,7, bei zweien nur 0,3. Welches Gewicht trägt er?

Lösung

Schritt 1 — Das Produkt

$$w = \frac{1}{0{,}7^{8} \cdot 0{,}3^{2}} = \frac{1}{0{,}0576 \cdot 0{,}09} = \frac{1}{0{,}00518} = 193$$

Schritt 2 — Zum Vergleich

Verlauf	Gewicht
zehnmal 0,7	35
achtmal 0,7, zweimal 0,3	**193**
zehnmal 0,5	1024

Schritt 3 — Stabilisierte Gewichte

Man multipliziert mit der Wahrscheinlichkeit derselben Folge *ohne* Bedingung auf den Verlauf:

$$w^{\text{stab}} = \prod_{t} \frac{\Pr[A_t = a_t \mid \text{bisherige Behandlung}]}{\Pr[A_t = a_t \mid \text{Geschichte}]}$$

Zähler und Nenner sind ähnlich groß, das Gewicht bleibt nahe bei eins — im Beispiel etwa 2 *statt* 193*.* ***Der Erwartungswert bleibt derselbe, die Streuung sinkt erheblich.*** *Das ist dasselbe Prinzip wie bei der Anpassung in der randomisierten Studie aus Kapitel 3: Man ändert nichts an der Unverzerrtheit und viel an der Genauigkeit.*

Aufgabe 12.3 — Welche Strategie ist bewertbar?

Über zehn Tage sei die Behandlungswahrscheinlichkeit je Tag 0,7. Wie viele von 10 000 Patienten haben der Strategie "immer behandeln" vollständig entsprochen?

Lösung

Schritt 1 — Die Rechnung

$$10\,000 \cdot 0{,}7^{10} = 10\,000 \cdot 0{,}0282 = 282$$

Schritt 2 — Und "nie behandeln"

$$10\,000 \cdot 0{,}3^{10} = 10\,000 \cdot 0{,}0000059 = \mathbf{0{,}06}$$

Kein einziger Patient. Die Strategie "nie behandeln" ist aus diesen Daten nicht bewertbar.

Schritt 3 — Was stattdessen geht

Kürzerer Zeitraum	Drei statt zehn Tage: $0{,}3^3 = 2{,}7\,\%$, also 270 Patienten.
Dynamische Strategie	"Behandle nur, wenn das Laktat über 2 liegt" — solche Verläufe kommen häufig vor.
Modellieren	Den Ausgang als Funktion der Behandlungsdauer modellieren, statt Strategien einzeln zu vergleichen.

*Die dritte Zeile tauscht **Positivität gegen Modellannahme** — man behauptet einen glatten Zusammenhang und kann dann auch Bereiche bewerten, in denen keine Daten liegen. Das ist ehrlich, solange man es sagt. Die zweite Zeile ist der bessere Weg: Sie stellt die Frage so, dass sie beantwortbar ist, und trifft zugleich besser, was Ärzte wirklich tun.*

Eine Arbeit über Arsen

James Robins veröffentlichte 1986 einen Aufsatz von 115 Seiten über die Wirkung von Arsen auf Arbeiter einer Kupferhütte.

*Das Problem: Wer krank wurde, verließ die belastete Abteilung — die Belastung hing vom Gesundheitszustand ab, der wiederum von der bisherigen Belastung. **Robins entwickelte dafür die g-Formel**, und der Aufsatz gilt als einer der schwersten der Epidemiologie. Er wurde jahrelang kaum gelesen; erst die Behandlung der HIV-Infektion in den 1990er Jahren, bei der dasselbe Problem auftrat, machte das Verfahren bekannt.*

Der gesunde Arbeiter

Die Epidemiologie kannte das Problem als "Effekt des gesunden Arbeiters": Beschäftigte sind gesünder als die Allgemeinbevölkerung, weil Kranke ausscheiden. ***Man hatte es als Auswahlproblem gedeutet und mit Anpassung zu beheben versucht*** *— und genau diese Anpassung machte es schlimmer, wie Abschnitt 12.1 zeigt.*

Über die Zeit heute

Dynamische Strategien	Regeln der Form "behandle, wenn", statt fester Folgen.
Intensivmedizin	Beatmung, Flüssigkeit, Katecholamine — alles rückgekoppelt.
Bestärkendes Lernen	Strategien aus Daten lernen statt sie zu vergleichen.

Zur dritten Zeile

Verfahren des bestärkenden Lernens suchen die beste Strategie, statt gegebene zu bewerten — und stoßen dabei auf dieselbe Positivitätsgrenze, nur schärfer: ***Die gefundene Strategie weicht gerade dort vom ärztlichen Handeln ab, wo es keine Daten gibt.*** *Eine vielbeachtete Arbeit von 2018 schlug für die Sepsisbehandlung Strategien vor, die Intensivmediziner für gefährlich hielten; die Nachprüfung zeigte, dass die Verfahren genau die datenarmen Bereiche bevorzugten.*

Was Sie jetzt können

Rückkopplung	Störgröße und Mediator zugleich
Satz 12.1	g-Formel: erst Verlauf, dann Ausgang
Gewichten	Produkt über die Zeitpunkte
Positivität	zu jedem Zeitpunkt, für jede Geschichte
Dynamisch	die beantwortbare Frage stellen

Die g-Formel durchläuft den Mediator, statt ihn zu sperren. Das nächste Kapitel fragt, wie viel Wirkung durch ihn läuft — und stößt auf eine Annahme, die über zwei Welten zugleich spricht.

Kapitel 13

Auf welchem Weg

13.1 Die Frage

Wirkt die frühe Gabe über das Organversagen?

Der Gesamteffekt ist bekannt. Nun fragt man: Wie viel davon läuft über die Verhinderung des Organversagens, und wie viel auf anderem Wege — über die Bakterienlast, über die Verweildauer, über anderes?

Gesamteffekt	Wirkung von X auf Y auf allen Wegen.
Indirekter Effekt	Der Teil, der über M läuft.
Direkter Effekt	Der Rest.

Die Frage ist nicht müßig. ***Läuft die Wirkung ganz über*** *M,* ***so genügt es,*** *M* ***zu behandeln*** *— und man braucht die frühe Gabe nur, soweit sie M verhindert. Läuft sie daran vorbei, so hilft die Behandlung von M nicht. Das ist der Unterschied zwischen einer Ursachenkette und einem Bündel paralleler Wirkungen.*

Der lineare Fall

Bei linearen Modellen ohne Wechselwirkung zerfällt der Effekt in ein Produkt und eine Summe:

$$\text{gesamt} = \underbrace{c'}_{\text{direkt}} + \underbrace{a \cdot b}_{\text{indirekt}}$$

mit a: Wirkung von X auf M; b: Wirkung von M auf Y bei festem X; c': Wirkung von X auf Y bei festem M.

Gerechnet

300 000 Patienten, $a = 0{,}6$, $b = 0{,}5$, $c' = 0{,}4$:

Größe	Schätzung	erwartet
gesamt	0,697	0,700
direkt	0,400	0,400
indirekt	0,300	0,300
Summe	0,700	✓

Anteil über den Mediator: $\frac{0{,}300}{0{,}697} = 43\,\%$

13.2 Was der lineare Fall verbirgt

Kontrolliert und natürlich

Sobald die Wirkung von M davon abhängt, ob behandelt wurde, zerfällt der einfache Zusammenhang.

Kontrolliert direkt	Effekt von X, wenn man M bei allen auf denselben Wert *zwingt*. Hängt davon ab, welchen.
Natürlich direkt	Effekt von X, wenn M den Wert behält, den es *ohne* Behandlung angenommen hätte.
Natürlich indirekt	Effekt der Verschiebung von M — bei festgehaltener Behandlung.

Nur die natürlichen Effekte summieren sich zum Gesamteffekt.

Die Annahme, die dahintersteckt

Die natürlich direkte Wirkung vergleicht den Ausgang bei Behandlung, aber mit dem Organversagen, das ohne Behandlung eingetreten wäre. ***Das ist eine Größe aus zwei verschiedenen Welten zugleich*** *— behandelt in der einen Hinsicht, unbehandelt in der anderen. Sie ist in keinem Versuch herstellbar, auch nicht mit beliebigem Aufwand: Man kann einen Patienten nicht behandeln und ihm zugleich den Verlauf des Unbehandelten geben.*

Die zugehörige Annahme heißt Kreuzwelt-Unabhängigkeit*, und sie ist grundsätzlich unprüfbar — nicht bloß in der Praxis schwer zu prüfen, sondern aus logischen Gründen: Keine Beobachtung und kein Versuch können sie widerlegen. Das unterscheidet sie von allen anderen Annahmen dieses Bandes.*

13.3 Der Bruchfall

Drei Gründe für Vorsicht

Störgrößen des Mediators	Für die Zerlegung braucht man nicht nur X unverzerrt, sondern auch $M \to Y$ — also eine zweite, oft unbeachtete Anpassungsmenge.
Folgen der Behandlung	Ist eine Störgröße von $M \to Y$ selbst eine Folge von X, so sind die natürlichen Effekte nicht bestimmbar — dieselbe Lage wie in Kapitel 12.
Messfehler	Ein ungenau gemessener Mediator verschiebt Anteile vom indirekten zum direkten Effekt.

Die dritte Zeile erklärt einen verbreiteten Befund: ***Wer einen groben Mediator misst, findet einen großen "direkten" Effekt*** *— und deutet ihn als eigenständigen Wirkweg, obwohl er nur den nicht erfassten Teil des indirekten Weges enthält. In der psychiatrischen Forschung, wo Mediatoren oft Fragebogenwerte sind, ist das die Regel.*

13.4 Übungsaufgaben

Aufgabe 13.1 — Die Zerlegung rechnen

$a = 0{,}6$, $b = 0{,}5$, $c' = 0{,}4$. Berechnen Sie die drei Effekte und den vermittelten Anteil. Was ändert sich, wenn b auf 0,9 steigt?

Lösung

Schritt 1 — Die Ausgangslage

$$\text{indirekt} = 0{,}6 \cdot 0{,}5 = 0{,}30, \qquad \text{gesamt} = 0{,}4 + 0{,}3 = 0{,}70$$

$$\text{Anteil} = 0{,}30 / 0{,}70 = 43\,\%$$

Schritt 2 — Mit $b = 0{,}9$

$$\text{indirekt} = 0{,}54, \qquad \text{gesamt} = 0{,}94, \qquad \text{Anteil} = 57\,\%$$

Schritt 3 — Die Tabelle

b	indirekt	gesamt	Anteil
0,1	0,06	0,46	13 %
0,5	0,30	0,70	43 %
0,9	0,54	0,94	57 %

Der vermittelte Anteil hängt vom Nenner ab und ist deshalb schlecht zu vergleichen. *Zwei Studien mit demselben indirekten Effekt berichten verschiedene Anteile, wenn ihre Gesamteffekte sich unterscheiden — etwa weil die Bevölkerungen verschieden sind. Man berichtet daher besser die absoluten Effekte.*

Aufgabe 13.2 — Wenn der Mediator ungenau gemessen ist

Der wahre Mediator werde nur mit einer Korrelation von 0,7 erfasst. Wie verschiebt sich die Zerlegung?

Lösung

Schritt 1 — Der Mechanismus

Bei klassischem Messfehler wird der Koeffizient b um den Faktor der Zuverlässigkeit gedämpft:

$$b_{\text{gemessen}} \approx 0{,}7^2 \cdot b = 0{,}49\, b$$

Schritt 2 — Die Folge

	wahr	gemessen
indirekt	0,30	0,15
direkt	0,40	0,55
gesamt	0,70	0,70
Anteil	43 %	**21** %

Der Gesamteffekt bleibt richtig; die Aufteilung verschiebt sich um die Hälfte.

Was der Mediator nicht erfasst, erscheint als direkter Effekt *— der direkte Effekt ist eine Restgröße und erbt jeden Fehler. Deshalb ist der Satz "die Wirkung läuft nur teilweise über M" fast nie belastbar, solange die Messgenauigkeit von M nicht bekannt ist.*

Aufgabe 13.3 — Zwei Welten zugleich

Warum lässt sich der natürlich direkte Effekt nicht durch einen Versuch bestimmen?

Lösung

Schritt 1 — Was er verlangt

$$\mathbb{E}\big[Y\big(1,\, M(0)\big)\big] - \mathbb{E}\big[Y\big(0,\, M(0)\big)\big]$$

— der erste Ausdruck beschreibt einen Patienten, der behandelt wird, dessen Organversagen aber dem Verlauf ohne Behandlung folgt.

Schritt 2 — Warum das kein Versuch leisten kann

M **zwingen**	ergibt den *kontrollierten* Effekt — dabei wird M auf einen festen Wert gesetzt, nicht auf den individuellen Wert ohne Behandlung.
$M(0)$ **beobachten**	geht nur bei Unbehandelten — dann kann man nicht zugleich behandeln.

Die Größe bezieht sich auf keinen möglichen Versuch. Sie ist eine Erfindung des Formalismus — aber eine nützliche.

Schritt 3 — Wozu sie dann gut ist

Sie beantwortet die Frage nach dem Mechanismus, nicht nach einer Handlung. *Wer wissen will, ob eine Behandlung wirkt, braucht sie nicht. Wer verstehen will, warum, braucht etwas in dieser Art — und muss dafür eine Annahme hinnehmen, die niemand prüfen kann. Der kontrollierte direkte Effekt ist dagegen prüfbar und beantwortet eine andere, oft ebenso brauchbare Frage: Was bringt die Behandlung, wenn man M ohnehin behandelt?*

Von der Psychologie zur Mathematik

Reuben Baron und **David Kenny** veröffentlichten 1986 ein Verfahren zur Mediationsanalyse, das aus drei Regressionen bestand.

Der Aufsatz erschien in einer psychologischen Zeitschrift und wurde zu einem der meistzitierten Texte der Sozialwissenschaften überhaupt — über hunderttausend Nennungen. ***Sein Verfahren ist unter Wechselwirkungen falsch*** *und setzt stillschweigend voraus, dass für den Mediator dieselben Störgrößen genügen wie für die Behandlung.*

Die Berichtigung

Judea Pearl *und* ***Jacques Robins*** *klärten in den 1990er Jahren, welche Größen überhaupt gemeint sind, und führten die natürlichen Effekte ein.* ***Tyler VanderWeele machte daraus ab 2009 ein Lehrgebäude für die Epidemiologie.*** *Die alte Dreiregressionsmethode wird dennoch weiter benutzt — ein Beispiel dafür, wie lange ein bequemes Verfahren überlebt, nachdem seine Grenzen bekannt sind.*

Mechanismen heute

Trennbare Effekte	Wirkungen so zerlegen, dass jeder Teil einem möglichen Eingriff entspricht.
Mehrere Mediatoren	Wege, die sich gegenseitig beeinflussen.
Empfindlichkeit	Wie stark die Kreuzwelt-Annahme verletzt sein dürfte.

Zur ersten Zeile

Statt eine Behandlung nachträglich in Wege zu zerlegen, denkt man sie sich in Bestandteile zerlegt, die getrennt gegeben werden könnten — etwa ein Antibiotikum, das die Bakterien tötet, und eines, das zusätzlich entzündungshemmend wirkt. ***Jeder Teileffekt entspricht dann einem denkbaren Versuch****, und die Kreuzwelt-Annahme entfällt. Der Preis ist, dass man die Zerlegung inhaltlich begründen muss — was die Frage vom Formalismus zurück in die Pharmakologie verlagert.*

Was Sie jetzt können

Linear	gesamt $= c' + ab$
Kontrolliert	M auf einen Wert zwingen
Natürlich	M auf seinen Wert ohne Behandlung
Kreuzwelt	grundsätzlich unprüfbar
Messfehler	verschiebt indirekt nach direkt

Bisher ging es um Durchschnitte über alle. Das nächste Kapitel fragt nach dem einzelnen Patienten — und findet, dass die Antwort für jeden anders ausfällt.

Kapitel 14

Für wen es wirkt

14.1 Der Durchschnitt verbirgt

Ein Effekt, vier Zahlen

300 000 Patienten, Behandlung ausgelost. Der Effekt hängt vom Alter ab: bei den Jüngsten $-0{,}20$, bei den Ältesten 0.

Alter	geschätzt	wahr
40–55	$-0{,}171$	$-0{,}170$
55–70	$-0{,}107$	$-0{,}110$
70–85	$-0{,}053$	$-0{,}050$
85–90	$-0{,}029$	$-0{,}010$
alle	$-0{,}100$	$-0{,}100$

Der Durchschnittseffekt von zehn Punkten gilt für niemanden: Die Jungen gewinnen doppelt so viel, die Alten nichts.

Das ist die zweite Warnung des Vorworts in Zahlen. *Ein Durchschnittseffekt ist ein Mittelwert über eine Bevölkerung — und wie jeder Mittelwert sagt er nichts über die Streuung. Er kann sogar positiv sein, während die Behandlung der Hälfte schadet; das sieht man ihm nicht an.*

Was man schätzen will

$$\tau(z) = \mathbb{E}\big[Y(1) - Y(0) \;\big|\; Z = z\big]$$

— der Effekt bei Patienten mit den Merkmalen z.

Nicht	der Effekt *dieses* Patienten — der bleibt nach Satz 2.2 unbekannt.
Sondern	der Durchschnitt über alle, die ihm in den gemessenen Merkmalen gleichen.

***Je mehr Merkmale, desto näher kommt man dem Einzelnen — und desto größer wird die Streuung**, denn in jeder Zelle bleiben weniger Patienten. Es ist der Zielkonflikt aus Band 22, Kapitel 2, nun auf eine Differenz angewandt: Man schätzt nicht einen Ausgang, sondern den Unterschied zweier Ausgänge, und Differenzen sind erheblich unschärfer als ihre Bestandteile.*

14.2 Wie man es schätzt

Drei Wege

Untergruppen	Vorher festgelegte Gruppen getrennt auswerten. Ehrlich, aber grob und schnell erschöpft.
Wechselwirkung	Ein Term $X \cdot Z$ im Modell. Unterstellt eine Form.
Kausale Wälder	Bäume, die nicht nach dem Ausgang, sondern nach dem *Unterschied* der Ausgänge teilen — Band 22, Kapitel 9.

*Ein kausaler Wald sucht die Aufteilung, bei der sich die geschätzten Effekte der beiden Gruppen am stärksten unterscheiden. **Der entscheidende Kunstgriff heißt Ehrlichkeit**: Eine Hälfte der Daten bestimmt, wo geteilt wird, die andere schätzt in den entstandenen Blättern. Ohne diese Trennung findet der Wald Unterschiede, die er selbst erzeugt hat — das Leck aus Band 22, Kapitel 3, in kausaler Gestalt.*

14.3 Der Bruchfall

Untergruppen, die keine sind

Multiples Testen	Zwanzig Untergruppen ergeben bei reinem Zufall eine “bedeutsame”.
Skalenabhängig	Ein Effekt kann auf der Differenzskala schwanken und auf der Verhältnisskala konstant sein — und umgekehrt.
Streuung	Der Effekt in einer Untergruppe wird aus einer Differenz zweier Differenzen geschätzt — vierfache Fallzahl für gleiche Genauigkeit.

Zur zweiten Zeile

Senkt eine Behandlung das Risiko überall um 20 Prozent relativ, so beträgt die absolute Senkung bei einem Grundrisiko von 40 Prozent acht Punkte, bei zehn Prozent nur zwei. ***Auf der Verhältnisskala gibt es dann keine Heterogenität, auf der Differenzskala erhebliche*** *— und beide Beschreibungen sind richtig. Für die Behandlungsentscheidung zählt die absolute, denn sie sagt, wie viele Patienten man behandeln muss.*

Daraus folgt: Die wichtigste Quelle von Heterogenität ist das Grundrisiko*, nicht eine besondere Empfindlichkeit. Wer wissen will, wem eine Behandlung am meisten nützt, schätzt zuerst das Risiko ohne Behandlung — das ist eine Vorhersageaufgabe im Sinne von Band 22 — und wendet darauf den relativen Effekt an. Dieses zweistufige Vorgehen ist robuster als die unmittelbare Schätzung von $\tau(z)$.*

14.4 Übungsaufgaben

Aufgabe 14.1 — Wie viele Patienten je Untergruppe?

Der Gesamteffekt beträgt $-0{,}10$ bei einem Grundrisiko von 0,30. Wie viele Patienten braucht man, um einen Unterschied von 0,10 zwischen zwei Untergruppen nachzuweisen?

Lösung

Schritt 1 — Der Haupteffekt

Nach Kapitel 3:

$$n = \frac{(1{,}96 + 0{,}84)^2 \left[0{,}30 \cdot 0{,}70 + 0{,}20 \cdot 0{,}80\right]}{0{,}10^2} = \frac{7{,}85 \cdot 0{,}37}{0{,}01} = 291 \text{ je Gruppe}$$

Schritt 2 — Der Unterschied zweier Effekte

Er ist eine Differenz zweier Differenzen; seine Varianz ist die Summe von vier Varianzen statt zweier:

$$n = 4 \cdot 291 = 1164 \text{ je Gruppe}$$

Frage	je Gruppe	gesamt
Wirkt es?	291	582
Wirkt es verschieden?	1164	**4656**

Achtmal so viele Patienten für die Frage nach dem Unterschied.

> ***Deshalb sind Untergruppenbefunde aus Studien, die für den Haupteffekt geplant wurden, fast immer unzuverlässig*** *— sie haben für diese Frage eine Trennschärfe von vielleicht zwanzig Prozent. Ein "kein Effekt in dieser Untergruppe" heißt dann meist nur: zu wenige Patienten.*

Aufgabe 14.2 — Behandeln oder nicht?

Mit dem Effektverlauf aus Abschnitt 14.1: Welche Politik ist die beste, wenn die Behandlung Nebenwirkungen im Wert von 0,03 Punkten hat?

Lösung

Schritt 1 — Die Schwelle

Behandeln lohnt, solange $\tau(\text{Alter}) < -0{,}03$:

$$-0{,}20 + 0{,}004\,(\text{Alter} - 40) < -0{,}03 \quad \Longrightarrow \quad \text{Alter} < 82{,}5$$

Schritt 2 — Der Gewinn der drei Politiken

Politik	Nutzen	
niemanden	0	
alle	$-0{,}100 + 0{,}030 = -0{,}070$	
unter 82,5	$\mathbf{-0{,}072}$	beste

Zur letzten Zeile: 85 Prozent der Patienten sind jünger als 82,5; ihr mittlerer Effekt beträgt $-0{,}115$, abzüglich 0,03 ergibt $0{,}85 \cdot (-0{,}085) = -0{,}072$; bei den Älteren geht nichts verloren, weil sie unbehandelt bleiben.

Schritt 3 — Die Einordnung

> ***Der Gewinn durch gezieltes Behandeln ist hier klein*** *— zwei Tausendstel gegenüber "alle behandeln". Das ist typisch: Solange der Effekt überall dasselbe Vorzeichen hat, bringt die Auswahl wenig. Lohnend wird sie erst, wenn die Behandlung bei einem Teil der Patienten schadet — und dann hängt alles daran, ob man diesen Teil zuverlässig erkennt.*

Schritt 4 — Und die Unsicherheit

> *Die geschätzte Schwelle von 82,5 Jahren hat selbst ein Vertrauensintervall, und zwar ein breites — in Aufgabe 14.1 wurde sichtbar, wie teuer die Schätzung von Unterschieden ist.* ***Eine Politik, die an einer ungenau geschätzten Schwelle hängt, kann schlechter sein als gar keine Auswahl.*** *Man vergleicht deshalb Politiken nicht am geschätzten Optimum, sondern an ihrem Nutzen unter Unsicherheit.*

Aufgabe 14.3 — Skala und Heterogenität

Eine Behandlung senkt das Risiko überall um 25 Prozent relativ. Ist der Effekt heterogen?

Lösung

Schritt 1 — Die absoluten Effekte

Grundrisiko	mit	Differenz	Zahl nötig
0,40	0,30	$-0{,}10$	10
0,20	0,15	$-0{,}05$	20
0,05	0,0375	$-0{,}0125$	80

"Zahl nötig" ist die Zahl der Behandelten je verhindertem Ereignis.

Schritt 2 — Die Antwort

> **Auf der Verhältnisskala nein, auf der Differenzskala ja — achtfach.**

Schritt 3 — Was für die Praxis zählt

Die letzte Spalte entscheidet über den Einsatz: ***Bei einem Grundrisiko von fünf Prozent muss man achtzig Patienten behandeln, um ein Ereignis zu verhindern*** *— bei vierzig Prozent nur zehn. Ist die Behandlung teuer oder belastend, so lohnt sie im einen Fall und im anderen nicht, obwohl sie "gleich gut wirkt".*

Schritt 4 — Die Folgerung für Leitlinien

Eine Leitlinie sollte den relativen Effekt aus Studien mit dem individuellen Grundrisiko aus einem Vorhersagemodell verbinden *— statt Untergruppen nach Alter oder Geschlecht zu bilden. Damit treffen sich Band 22 und dieser Band an der Stelle, auf die es klinisch ankommt: Die Vorhersage sagt, wie gefährdet jemand ist; der kausale Schluss sagt, was die Behandlung daran ändert.*

Die Untergruppe der Zwillinge

In einer großen Herzstudie der 1980er Jahre wurde die Wirkung von Aspirin nach Sternzeichen ausgewertet.

Bei Zwillingen und Waagen zeigte sich kein Nutzen, in allen anderen Zeichen ein deutlicher. ***Die Verfasser druckten das Ergebnis ausdrücklich ab, um zu zeigen, wie wenig Untergruppenanalysen wert sind.*** *Der Scherz wird seither in jeder Methodenvorlesung erzählt — und die Praxis der Untergruppenauswertung hat er nicht beendet.*

Und ein ernster Fall

Mehrfach wurden Medikamente aufgrund von Untergruppenbefunden gezielt eingesetzt und später widerlegt — oder umgekehrt Patientengruppen ausgeschlossen, denen das Mittel geholfen hätte. ***Die Zulassungsbehörden verlangen deshalb heute, Untergruppen vorab zu benennen*** *und den Wechselwirkungsterm zu prüfen, statt Gruppen getrennt auszuwerten.*

Einzelfall heute

Kausale Wälder	Heterogenität ohne vorgegebene Form, mit Vertrauensintervallen.
Politiklernen	Behandlungsregeln, die den Nutzen unter Nebenbedingungen maximieren.
Risikobasierte Auswertung	Studien nach vorhergesagtem Grundrisiko schichten.

Zur dritten Zeile

Man teilt die Studienteilnehmer nach ihrem vorhergesagten Risiko in Viertel und berichtet den absoluten Effekt je Viertel. ***Das ist eine einzige, vorab festgelegte Untergruppenbildung statt vieler*** *— und sie trifft die klinisch wichtigste Quelle von Heterogenität. Mehrere Fachgesellschaften empfehlen dieses Vorgehen inzwischen als Standard.*

Was Sie jetzt können

$\tau(z)$	Durchschnitt über Gleichartige, nicht der Einzelne
Drei Wege	Untergruppen, Wechselwirkung, kausale Wälder
Ehrlichkeit	teilen und schätzen getrennt
Achtfach	Fallzahl für Unterschiede
Skala	Heterogenität hängt an ihr

Damit endet Teil V. Das letzte Kapitel zieht Bilanz — und kehrt ein letztes Mal zur Tabelle aus Kapitel 1 zurück.

Teil VI

Aktueller Stand

Kapitel 15

Woran es liegt

15.1 Die Tabelle aus Kapitel 1, ein letztes Mal

Was inzwischen dazugehört

Am Anfang stand eine Tabelle, die zeigte, dass früh behandelte Patienten häufiger starben.

Kap.	Frage	Antwort
1	Was zeigt die Tabelle?	Nichts Kausales.
2	Was will man wissen?	$\mathbb{E}[Y(1) - Y(0)]$.
3	Wie käme man hin?	Auslosen.
4–6	Und ohne Los?	Hinterwege sperren.
7–8	Womit?	Neigung, Gewichte.
9–11	Wenn das nicht geht?	Instrument, Sprung, Nachbildung.
12–14	Über die Zeit, für wen?	g-Formel, $\tau(z)$.

Keine dieser Antworten steckt in den Daten. Sie alle bestehen darin, die richtige Annahme zu benennen und ihre Folgen auszurechnen.

15.2 Vier Muster

Muster 1 — die Daten entscheiden nicht

1	Satz 1.2: Dieselbe Tabelle, Effekt $+0{,}60$ oder null.
4	Drei Graphen sind ununterscheidbar; nur der Kollider verrät sich.
6	Manchmal gibt es gar keine zulässige Anpassungsmenge.
13	Die Kreuzwelt-Annahme ist grundsätzlich unprüfbar.

Das ist keine Schwäche des Faches, sondern sein wichtigster Beitrag. *Vor diesen Verfahren rechnete man Regressionen und sprach von "Einfluss"; die Annahmen blieben unausgesprochen und damit unbestreitbar. Wer heute einen Graphen zeichnet, legt sie offen — und jeder Fachkollege kann einen Pfeil bestreiten.*

Muster 2 — mehr anpassen ist nicht besser

5	Mediator: Effekt von 0,72 auf 0,004.
5	Kollider: aus null wird −0,39.
5	Instrument: Verzerrung verdoppelt.
12	Dieselbe Größe muss zugleich angepasst und durchlaufen werden.

In jedem dieser Fälle sieht das falsche Modell besser aus als das richtige *— es erklärt mehr Streuung, hat engere Intervalle und bestandene Gütemaße. Kein Auswahlverfahren aus Band 22 findet den Fehler, weil er nicht in den Daten steckt.*

Muster 3 — der Entwurf schlägt das Verfahren

3	Nach Behandlung statt nach Zuteilung: fast doppelter Effekt.
11	Unsterbliche Zeit: 73 Prozent Gewinn aus nichts.
11	Die Hormonstudien widersprachen sich wegen des Beginns, nicht wegen der Störgrößen.
14	Untergruppen brauchen die achtfache Fallzahl.

Die größten Fehler dieses Bandes sind Entwurfsfehler, keine Rechenfehler *— und sie sind vermeidbar. Das ist dieselbe Lehre wie in Band 22, Kapitel 3, wo die Prüfung wichtiger war als das Verfahren. Wer die sieben Zeilen der Zielstudie ausfüllt, bevor er rechnet, hat mehr gewonnen als durch jede Verfeinerung des Schätzers.*

Muster 4 — jede Zahl gilt für eine Bevölkerung

2	τ und τ_{beh}: $-0{,}375$ gegen $-0{,}250$.
9	Der Instrumentschätzer gilt für die Befolger — die niemand benennen kann.
10	Der Sprung gilt an der Schwelle.
14	Der Durchschnitt von $-0{,}10$ gilt für niemanden.

Ein kausaler Effekt ohne Angabe der Bevölkerung ist unvollständig *— so unvollständig wie ein Mittelwert ohne Angabe, worüber gemittelt wurde. Die Verfahren dieses Bandes unterscheiden sich weniger in ihrer Güte als in der Frage, die sie beantworten.*

15.3 Was offen ist

Vier Fragen

Übertragung	Wann gilt ein Effekt in einer anderen Klinik? Kapitel 6 gibt ein Kriterium — es verlangt zu wissen, worin sich die Häuser unterscheiden.
Struktur finden	Graphen aus Daten zu gewinnen, gelingt nur bis zur Äquivalenzklasse.
Entscheiden	Strategien lernen statt bewerten — und die Positivitätsgrenze.
Verbinden	Vorhersage und Ursache in einem Modell.

Die letzte Frage schließt den Bogen zu Band 22. ***Ein Modell, das nur ursächliche Größen benutzt, bleibt bei Verteilungsverschiebungen gültig und sagt schlechter vorher; eines, das alles benutzt, sagt besser vorher und bricht bei Verschiebungen zusammen.*** *Das Sepsis-Warnsystem von 2021 war vom zweiten Typ. Ob es einen brauchbaren Mittelweg gibt, ist offen.*

15.4 Sechs Sätze, die bleiben

Die Bilanz

1	Zusammenhang entsteht aus Wirkung, gemeinsamer Ursache oder Auswahl — und die Daten sagen nicht, woraus.
2	Der individuelle Effekt ist unbeobachtbar; der durchschnittliche ist unter angebbaren Annahmen schätzbar.
3	Das Los stellt her, was sonst behauptet werden muss.
4	Eine Menge ist zulässig, wenn sie keinen Nachkommen enthält und jeden Hinterweg sperrt.
5	Alle Störgrößen lassen sich durch eine einzige Zahl ersetzen — die Behandlungsneigung.
6	Wird über die Zeit behandelt, ist dieselbe Größe Störgröße und Mediator zugleich; nur die g-Formel trennt beides.

Ein Schlusswort

Dieser Band begann mit einer Frage, die jeder Arzt täglich stellt: Was geschieht, wenn ich dies tue statt jenes?
Fünfzehn Kapitel später lässt sich sagen, was die Mathematik darauf antwortet. Sie antwortet nicht mit einer Zahl, sondern mit einer Buchführung: Welche Annahme brauche ich, damit diese Rechnung gilt? Welchen Weg muss ich sperren, welchen offen lassen? Für welche Patienten gilt das Ergebnis? Und woran würde ich merken, dass ich falsch liege?
Die Antworten sind unbequem. Fast jede wichtige Annahme ist unprüfbar. Fast jede Zahl gilt für eine andere Bevölkerung als die, für die man sie braucht. Und die größten Fehler entstehen nicht beim Rechnen, sondern beim Entwerfen — lange bevor der erste Schätzer gewählt ist.
Aber die Buchführung ist mehr, als es vorher gab. Wer die Annahmen aufschreibt, kann sie bestreiten lassen. Wer die Bevölkerung nennt, kann gefragt werden, ob sie die richtige ist. Das ist keine Gewissheit — es ist die Form, in der man über Ursachen streiten kann, ohne aneinander vorbeizureden.

Damit steht dieser Band am Ende der zweiten Werkhälfte. Die Statistik sagt, was die Daten hergeben. Die Optimierung sagt, was es kostet. Die Informationstheorie sagt, was übertragbar ist. Die Spieltheorie sagt, was übrig bleibt, wenn der andere mitdenkt. Das Lernen sagt, was auf den nächsten Fall zutrifft. ***Und die Kausalität sagt, was davon sich ändert, wenn man handelt.***

Teil VII

Anhang

Kapitel A

Formelsammlung und Übersicht

A.1 Begriffe und Formeln

Teil I und II

$Y_i(1),\ Y_i(0)$	potentielle Ergebnisse (2.1)
$Y_i = Y_i(X_i)$	Konsistenz
$\tau = \mathbb{E}[Y(1) - Y(0)]$	Durchschnittseffekt (2.3)
τ_{beh}	Effekt bei den Behandelten
$(Y(1), Y(0)) \perp X \mid Z$	bedingte Unabhängigkeit
$0 < \Pr[X{=}1 \mid Z] < 1$	Positivität
$\sum_z \mathbb{E}[Y \mid x, z] \Pr[z]$	Anpassungsformel (2.4)
$\Pr[Y \mid \text{do}(x)]$	Eingriffsverteilung (1.1)
$n = \frac{(z_{1-\alpha/2}+z_{1-\beta})^2[\cdot]}{(p_0-p_1)^2}$	Fallzahl (3)
$\prod_i \Pr[v_i \mid \text{Eltern}]$	Faktorisierung (4.2)
Kette, Gabel, Kollider	drei Bausteine (4)
d-Trennung	alle Wege gesperrt (4.3)
kein Nachkomme, Hinterwege zu	Hintertür (6.1)
$\sum_m \Pr[m \mid x] \sum_{x'} \Pr[Y \mid m, x'] \Pr[x']$	Vordertür (6.3)

Teil III bis V

$e(z) = \Pr[X{=}1 \mid z]$	Behandlungsneigung (7.1)
$\perp X \mid e(Z)$	Rosenbaum-Rubin (7.2)
$w = 1/e$ bzw. $1/(1-e)$	Gewichte (8.1)
$\mathbb{E}[XY/e(Z)] = \mathbb{E}[Y(1)]$	(8.2)
$\frac{X(Y-\hat{m}_1)}{\hat{e}} + \hat{m}_1$	doppelt abgesichert (8.3)
$(\sum w)^2 / \sum w^2$	wirksame Fallzahl
$\frac{\Delta\mathbb{E}[Y]}{\Delta\mathbb{E}[X]}$	Wald-Schätzer (9.1)
$F > 10$	Instrumentstärke
Sprung an der Schwelle	Regressionssprung (10)
$(\bar{y}_{A,1} - \bar{y}_{A,0}) - (\bar{y}_{B,1} - \bar{y}_{B,0})$	doppelte Differenz (10)
sieben Zeilen	Zielstudie (11)
$\sum_\ell \Pr[Y \mid a_0, \ell, a_1] \Pr[\ell \mid a_0]$	g-Formel (12.1)
$\prod_t 1/\Pr[A_t \mid \text{Geschichte}]$	Gewichte über die Zeit
$c' + ab$	Mediation, linear (13)
$\tau(z)$	bedingter Effekt (14)

A.2 Die Landkarte

Welcher Satz worauf beruht

Ergebnis	Kap.	beruht auf
Beobachtungs-äquivalenz	1	zwei Modelle, eine Tabelle
kein individueller Effekt	2	Begriffsbildung
Anpassungsformel	2	totale Erwartung
Randomisierung	3	Unabhängigkeit vor der Zuteilung
Faktorisierung	4	Modellaufbau
d-Trennung	4	Wege und Kollider
Hintertür	6	Durchtrennen der Pfeile
Vordertür	6	zwei Stücke, je unverzerrt
Neigung genügt	7	Turmregel
Gewichtung	8	Konsistenz und Kürzen
doppelte Absicherung	8	ein Faktor wird null
Wald-Schätzer	9	Ausschlussbedingung
Befolgereffekt	9	vier Patiententypen
g-Formel	12	Zeitordnung
Mediation	13	zwei Welten zugleich

A.3 Was nicht bewiesen wurde

Vier Auslassungen

Ergebnis	Kap.	Wo es steht
d-Trennungssatz	4	Pearl[18], Kap. 1
Hintertürformel	6	Pearl[18], Kap. 3
Vollständigkeit des do-Kalküls	6	Pearl u. a.[19]
Satz über natürliche Effekte	13	VanderWeele[26]

Alle übrigen Sätze des Bandes sind vollständig bewiesen *— darunter die Anpassungsformel, Satz 3.1 über die Randomisierung, Satz 7.2 über die Behandlungsneigung, Satz 8.2 über die Gewichtung und Satz 8.3 über die doppelte Absicherung.*

A.4 Zeittafel

Von Hume bis zur Zielstudie

Jahr	Person	Ereignis
1748	Hume	Ursache als beständige Verknüpfung
1843	Mill	Methoden der Übereinstimmung
1854	Snow	die Wasserwerke Londons
1899	Pearson	die Umkehr in Teiltabellen
1918	S. Wright	Pfadanalyse
1923	Neyman	potentielle Ergebnisse
1928	P. Wright	Instrumentvariablen
1935	Fisher	*The Design of Experiments*
1946	Berkson	Verzerrung durch Aufnahme
1948	Bradford Hill	Streptomycinstudie
1951	Simpson	das Paradoxon
1952	Horvitz, Thompson	Gewichtung nach Kehrwert
1959	Cornfield	Empfindlichkeits-argument
1960	Thistlethwaite	Regressionssprung
1965	Bradford Hill	neun Gesichtspunkte
1974	Rubin	potentielle Ergebnisse für Beobachtungen
1983	Rosenbaum, Rubin	Behandlungsneigung
1986	**Robins**	**g-Formel**
1986	Holland	"keine Ursache ohne Manipulation"
1986	Baron, Kenny	Mediation in drei Regressionen
1993	**Pearl**	**Hintertürkriterium**
1994	Imbens, Angrist	Befolgereffekt
1994	Robins u. a.	doppelte Absicherung
1995	Pearl	Vordertürformel
2000	Pearl	*Causality*
2002	WHI	Umkehr des Hormonbefundes
2006	Shpitser, Pearl	Vollständigkeit des do-Kalküls
2008	Hernán u. a.	Auflösung des Hormonwiderspruchs
2016	Hernán, Robins	Zielstudie
2018	Athey, Wager	kausale Wälder
2021	Card, Angrist, Imbens	Nobelpreis

A.5 Glossar

Begriffe von A bis Z

Begriff	Bedeutung
Behandlungsabsicht	Auswertung nach Zuteilung (3)
Behandlungsneigung	$\Pr[X{=}1 \mid Z]$ (7.1)
Befolger	wer der Zuteilung folgt (9)
d-Trennung	alle Wege gesperrt (4.3)
Doppelte Absicherung	eines von zwei Modellen genügt (8.3)
Doppelte Differenz	Trend und Ort heraus (10)
Gabel	gemeinsame Ursache (4)
g-Formel	Verlauf erzeugen, dann mitteln (12.1)
Hinterweg	Pfeil in X hinein (6)
Indikationsverzerrung	Kranke werden anders behandelt (1)
Instrument	Ursache nur von X (9)
Kollider	gemeinsame Folge (4)
Konsistenz	$Y = Y(X)$ (2)
Kontrafaktisch	was gewesen wäre (2.1)
Kreuzwelt	zwei Welten zugleich (13)
Mediator	auf dem Weg $X \to Y$ (5)
Positivität	beide Behandlungen kommen vor (2)
Randstrukturmodell	Modell der potentiellen Ergebnisse (12)
Regressionssprung	Schwelle als Zufall (10)
Störgröße	Ursache von X und Y (5)
Triangulation	verschiedene Annahmen, gleiches Ergebnis (11)
Unsterbliche Zeit	Spanne ohne Sterbemöglichkeit (11)
Vordertür	Effekt über den Mediator (6.3)
Zielstudie	erst die Studie, dann die Daten (11)

Kapitel B

Kommentierte Quellen

Achtundzwanzig Werke, eingeordnet: Zu jedem steht, wofür man es aufschlägt und was es leistet, das andere nicht leisten.

[1] Angrist, J., Pischke, J.-S.: *Mostly Harmless Econometrics*. Princeton 2009.

Die Verfahren der Kapitel 9 und 10 aus ökonometrischer Sicht — Instrumente, Sprünge, doppelte Differenzen. Salopp geschrieben, technisch genau, mit vielen Beispielen aus der Arbeitsmarktforschung. Ergänzt diesen Band dort, wo er am knappsten ist.

[2] Athey, S., Wager, S.: *Estimating Treatment Effects with Causal Forests*. Observational Studies 7, 2021.

Kausale Wälder aus Kapitel 14, von ihren Entwicklern erklärt. Zeigt, wie Bäume nach Effektunterschieden statt nach Ausgängen teilen und warum die Trennung von Teilen und Schätzen nötig ist.

[3] Baron, R., Kenny, D.: *The moderator–mediator variable distinction*. J. Personality Soc. Psych. 51, 1986.

*Der meistzitierte Aufsatz zur Mediation — und ein Lehrstück darüber, wie lange ein bequemes Verfahren überlebt. **Zu lesen, um zu verstehen, was in Kapitel 13 berichtigt wird**, nicht als Anleitung.*

[4] Bradford Hill, A.: *The Environment and Disease: Association or Causation?* Proc. R. Soc. Med. 58, 1965.

***Die neun Gesichtspunkte** zur Beurteilung, ob ein Zusammenhang ursächlich ist: Stärke, Beständigkeit, Dosis-Wirkung und sechs weitere. Hill nannte sie ausdrücklich keine Prüfliste. Sie werden bis heute als solche benutzt und haben die Rauchen-Krebs-Debatte entschieden.*

[5] Cinelli, C., Forney, A., Pearl, J.: *A Crash Course in Good and Bad Controls*. Sociol. Methods Res. 53, 2024.

*Kapitel 5 dieses Bandes in Aufsatzform: achtzehn Graphen, jeder mit der Antwort, ob man anpassen darf. **Zum Aushängen über dem Schreibtisch.** Enthält auch die M-Verzerrung und die Verstärkung durch Instrumente.*

[6] Cornfield, J. u. a.: *Smoking and lung cancer*. J. Natl. Cancer Inst. 22, 1959.

Die Antwort auf Fishers Einwand aus Kapitel 1, und zugleich die Geburt der Empfindlichkeitsanalyse: Eine verborgene Ursache hätte das Risiko verneunfachen müssen. Ein Muster dafür, wie man ohne Randomisierung überzeugend argumentiert.

[7] Cunningham, S.: *Causal Inference: The Mixtape*. Yale 2021.

Eine ungewöhnlich lesbare Einführung, mit Code und historischen Abschweifungen. Deckt die Kapitel 7 bis 10 vollständig ab. Frei verfügbar; gut für Leser, die selbst rechnen wollen.

[8] Elwert, F., Winship, C.: *Endogenous Selection Bias*. Annu. Rev. Sociol. 40, 2014.

Der Kollider, systematisch — als Auswahl, als Anpassung, als Studieneinschluss. Erklärt, warum dieselbe Verzerrung unter einem Dutzend Namen umläuft, und ist die beste Vertiefung zu Aufgabe 1.2 und 5.2.

[9] Greenland, S., Pearl, J., Robins, J.: *Causal Diagrams for Epidemiologic Research*. Epidemiology 10, 1999.

Der Aufsatz, der die Graphen in die Epidemiologie trug — zehn Seiten, ohne Beweise, mit Beispielen. ***Wer nur einen Text über kausale Graphen liest, lese diesen.*** *Enthält die M-Verzerrung, die die alte Anpassungsregel widerlegte.*

[10] Hernán, M., Robins, J.: *Causal Inference: What If*. Chapman & Hall 2020.

Das Standardwerk und die Hauptquelle dieses Bandes. *Teil I ohne Modelle, Teil II mit, Teil III über die Zeit — g-Formel, Gewichtung, Zielstudie. Von den Entwicklern der Verfahren, medizinisch orientiert, frei verfügbar.*

[11] Hernán, M. u. a.: *Observational studies analyzed like randomized experiments*. Epidemiology 19, 2008.

Die Auflösung des Hormonwiderspruchs aus Kapitel 11. Zeigt an einem Fall von großer Tragweite, dass die meisten Widersprüche zwischen Beobachtung und Versuch aus dem Entwurf stammen, nicht aus Störgrößen.

[12] Hernán, M., Robins, J.: *Using Big Data to Emulate a Target Trial*. Am. J. Epidemiol. 183, 2016.

Die sieben Zeilen aus Kapitel 11, ausgeführt. Kurz und unmittelbar anwendbar. ***Vor jeder Auswertung von Routinedaten zu lesen*** *— und auszufüllen.*

[13] Holland, P.: *Statistics and Causal Inference*. J. Am. Stat. Assoc. 81, 1986.

Der Aufsatz, der das grundlegende Problem benannte und die Diskussion um "keine Ursache ohne Manipulation" auslöste. Mit Erwiderungen, die den Streit gut abbilden. Philosophisch klar, mathematisch leicht.

[14] Imbens, G., Angrist, J.: *Identification and Estimation of Local Average Treatment Effects*. Econometrica 62, 1994.

Satz 9.2 in seiner Urform: Der Instrumentschätzer gilt für die Befolger. ***Eine unwillkommene Nachricht, die ein ganzes Fach zum Umdenken zwang*** *— und 2021 mit dem Nobelpreis bedacht wurde.*

[15] Imbens, G., Rubin, D.: *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge 2015.

Das große Werk zur Sprache der potentiellen Ergebnisse — Randomisierung, Neigung, Instrumente, mit vollständigen Herleitungen. Ohne Graphen; die Ergänzung zu [18] von der anderen Schule.

[16] Kuß, O., Blettner, M., Börgermann, J.: *Propensity Score — eine alternative Methode zur Analyse von Therapieeffekten*. Dtsch. Ärztebl. 113, 2016.

Auf Deutsch und kurz. *Die Behandlungsneigung aus Kapitel 7, für Ärzte erklärt, mit einem herzchirurgischen Beispiel. Frei verfügbar; gut als erste Lektüre oder zur Weitergabe an Kollegen.*

[17] Mill, J. S.: *A System of Logic*. London 1843.

Die Methoden der Übereinstimmung und des Unterschieds — der erste systematische Versuch, Ursachen aus

Beobachtung zu erschließen. Mills "Methode des Unterschieds" ist im Kern die randomisierte Studie, hundert Jahre zu früh gedacht.

[18] Pearl, J.: *Causality: Models, Reasoning, and Inference*. 2. Aufl., Cambridge 2009.

Das Werk, das die Graphen begründete. *Enthält d-Trennung, Hintertür, Vordertür, do-Kalkül mit Beweisen — die Fundstelle für alle Auslassungen der Kapitel 4 und 6. Anspruchsvoll und eigenwillig geschrieben.*

[19] Pearl, J., Glymour, M., Jewell, N.: *Causal Inference in Statistics: A Primer*. Wiley 2016.

Die zugängliche Fassung von [18]: knapp zweihundert Seiten, mit Aufgaben und Lösungen. ***Der beste Einstieg in die grafische Seite des Faches*** *— für Leser, die Kapitel 4 bis 6 vertiefen wollen.*

[20] Robins, J.: *A new approach to causal inference in mortality studies*. Math. Modelling 7, 1986.

Die Arbeit über die Kupferhütte, in der die g-Formel entstand. 115 *Seiten, schwer zugänglich — aber sie enthält alles, was Kapitel 12 behandelt, zwanzig Jahre vor seiner allgemeinen Anerkennung.*

[21] Rosenbaum, P., Rubin, D.: *The central role of the propensity score*. Biometrika 70, 1983.

Satz 7.2 im Original — acht Seiten, die die Praxis der Beobachtungsforschung verändert haben. Der Beweis ist so kurz wie der in Kapitel 7.

[22] Rubin, D.: *Estimating causal effects of treatments in randomized and nonrandomized studies*. J. Educ. Psychol. 66, 1974.

Die Übertragung der potentiellen Ergebnisse von Versuchen auf Beobachtungsdaten. Der Ausgangspunkt der gesamten Rubin-Schule; bemerkenswert klar geschrieben.

[23] Schomaker, M., Heumann, C.: *Kausalität in der Statistik*. Springer Spektrum 2023.

Auf Deutsch und mathematisch. *Behandelt Graphen, potentielle Ergebnisse und die Schätzverfahren in einem Band, mit Beispielen und R-Code. Die deutschsprachige Entsprechung zu [10] in kompakterer Form.*

[24] Shpitser, I., Pearl, J.: *Identification of joint interventional distributions*. AAAI 2006.

Der Vollständigkeitsbeweis des do-Kalküls: Lässt sich ein Effekt bestimmen, so führen die drei Regeln zum Ziel. Technisch; wichtig als Beleg dafür, dass "unbestimmbar" eine beweisbare Aussage ist.

[25] Suttorp, M. u. a.: *Graphical presentation of confounding in directed acyclic graphs*. Nephrol. Dial. Transplant. 30, 2015.

Kausale Graphen für klinisch tätige Ärzte, mit Beispielen aus der Nephrologie. Kurz, praktisch, ohne Formalismus — gut geeignet, um Kollegen den Unterschied zwischen Störgröße, Mediator und Kollider zu erklären.

[26] VanderWeele, T.: *Explanation in Causal Inference: Methods for Mediation and Interaction*. Oxford 2015.

Das Standardwerk zu Kapitel 13 — natürliche und kontrollierte Effekte, Wechselwirkungen, Empfindlichkeitsanalysen. Die Fundstelle für den Satz über natürliche Effekte, den dieser Band ausließ.

[27] VanderWeele, T., Ding, P.: *Sensitivity Analysis in Observational Research: Introducing the E-Value*. Ann. Intern. Med. 167, 2017.

Eine einzige Zahl, die angibt, wie stark eine unbeobachtete Störgröße wirken müsste, um den Befund zu erklären. ***Sie gehört in jede Beobachtungsstudie*** *und ist ohne Annahmen über die Form der Störung berechen-*

bar.

[28] Wong, A. u. a.: *External validation of a widely implemented proprietary sepsis prediction model*. JAMA Intern. Med. 181, 2021.

Die Nachprüfung aus Band 22, hier als Mahnung am anderen Ende: Ein Modell, das vorhersagt, ohne Ursachen zu kennen, bricht zusammen, sobald sich die Verteilung ändert. Der Übergang von jenem Band zu diesem in einer Arbeit.

Wenn Sie nur drei Werke lesen

[10]	**Hernán, Robins**	**Für alles**
[9]	**Greenland u. a.**	Für die Graphen
[12]	**Hernán, Robins**	**Vor der ersten Auswertung**

Hernán und Robins erklären die Verfahren; Greenland und Mitarbeiter liefern auf zehn Seiten, wofür Kapitel 4 bis 6 fünfzig brauchten. ***Und der dritte Text ist die Prüfliste, die die meisten Fehler verhindert, bevor sie entstehen.*** *Alle drei sind frei verfügbar.*

Nach Interessenlage: [19] Pearl u. a. zum Einstieg in die Graphen, [1] Angrist und Pischke für natürliche Versuche, [26] VanderWeele für Mechanismen, [27] für die Empfindlichkeit. Auf Deutsch: [23] Schomaker und Heumann für die Mathematik, [16] Kuß u. a. und [25] Suttorp u. a. für die klinische Praxis.

Die Daten sagen, was zusammen auftritt.
Der Graph sagt, was man annimmt.
Erst beides zusammen sagt,
was geschieht, wenn man handelt.