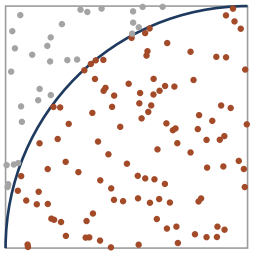
Mathematik von Grund auf — Band 27

Was der Rechner vom Zufall weiß

Numerische Simulation



$$\pi \approx 4 \cdot \frac{\textit{Treffer}}{\textit{Würfe}}$$

Von der Zufallszahl bis zur Fehlerkontrolle

Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Stand der Forschung: August 2026

Mathematik von Grund auf — Band 27
Was der Rechner vom Zufall weiß · Numerische Simulation

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Simulationen, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/mathematik-von-grund-auf`
Dauerhaft archiviert bei Zenodo: `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Mathematik von Grund auf, Band 27: Was der Rechner vom Zufall weiß*. Fassung 1.1.0. `https://doi.org/10.5281/zenodo.23698547`

Satz: LaTeX mit Palatino. Fassung 1.1.0, Oktober 2026. 170 Seiten.

Inhaltsverzeichnis

Vorwort **1**

I Der Zufall im Rechner **5**

1 Ein Experiment im Rechner **7**

1.1 Der Leitfall . . . 7
1.2 Die Streuung messen . . . 8
1.3 Warum man simuliert . . . 9
1.4 Der Bruchfall . . . 10
1.5 Übungsaufgaben . . . 10

2 Zufall aus einer Formel **15**

2.1 Der Widerspruch . . . 15
2.2 Das Gitter . . . 16
2.3 Aus gleichverteilt wird alles andere . . . 17
2.4 Der Bruchfall . . . 19
2.5 Übungsaufgaben . . . 19

3 Der Fluch der Dimension **25**

3.1 Ein Integral als Erwartungswert . . . 25
3.2 Die Rechnung in d Dimensionen . . . 25
3.3 Wo auch der Zufall versagt . . . 27
3.4 Der Bruchfall . . . 27
3.5 Übungsaufgaben . . . 28

II Genauer werden **33**

4 Den Fehler richtig messen **35**

4.1 Der naive Standardfehler . . . 35
4.2 Drei Verfahren . . . 35
4.3 Der Anfang . . . 37

4.4 Zwei Varianten vergleichen . . . 38
4.5 Der Bruchfall . . . 38
4.6 Übungsaufgaben . . . 39

5 Weniger Streuung ohne mehr Läufe 45
5.1 Das Prinzip . . . 45
5.2 Antithetische Variablen . . . 45
5.3 Kontrollvariablen . . . 46
5.4 Konditionierung . . . 47
5.5 Was zusammen wirkt . . . 48
5.6 Der Bruchfall . . . 49
5.7 Übungsaufgaben . . . 49

6 Dort ziehen, wo etwas passiert 55
6.1 Das Problem der seltenen Treffer . . . 55
6.2 Die Wichtigkeitsstichprobe . . . 56
6.3 Die Verschiebung . . . 56
6.4 Quasi-Monte-Carlo . . . 58
6.5 Der Bruchfall . . . 59
6.6 Übungsaufgaben . . . 60

III Ketten und Pfade 65

7 Ziehen, ohne ziehen zu können 67
7.1 Das Problem . . . 67
7.2 Der Metropolis-Algorithmus . . . 67
7.3 Die Schrittweite . . . 69
7.4 Der Gibbs-Sampler . . . 69
7.5 Was man mit der Kette tut . . . 70
7.6 Der Bruchfall . . . 71
7.7 Übungsaufgaben . . . 72

8 Ist die Kette angekommen? 77
8.1 Was man nicht sehen kann . . . 77
8.2 Mehrere Ketten . . . 77
8.3 Das wirksame n der Kette . . . 78
8.4 Der Anfang und das Ausdünnen . . . 79

8.5 Der Bruchfall 80
8.6 Übungsaufgaben 81

9 Fliegen statt kriechen, und Pfade rechnen 85
9.1 Der Zufallsweg in hundert Dimensionen 85
9.2 Hamilton-Monte-Carlo 85
9.3 Pfade stochastischer Differentialgleichungen 87
9.4 Mehrebenen-Monte-Carlo 88
9.5 Der Bruchfall 89
9.6 Übungsaufgaben 90

IV Systeme über die Zeit 95

10 Die Station als Programm 97
10.1 Zustand, Ereignis, Uhr 97
10.2 Die Ereignisliste 97
10.3 Zeitschritt statt Ereignis 99
10.4 Die Warteschlange 99
10.5 Der Bruchfall 100
10.6 Übungsaufgaben 101

11 Was hilft, und wie selten es schlimm wird 107
11.1 Ein Bett mehr 107
11.2 Wie selten wird die Schlange lang? 108
11.3 Der Bruchfall 110
11.4 Übungsaufgaben 111

12 Was jetzt gerade los ist 115
12.1 Die umgekehrte Frage 115
12.2 Der Teilchenfilter 115
12.3 Wozu die Neuziehung 117
12.4 Was der Filter noch kann 117
12.5 Der Bruchfall 118
12.6 Übungsaufgaben 119

V Die Praxis **123**

13 Dasselbe noch einmal **125**

13.1 Was Reproduzierbarkeit heißt . . . 125
13.2 Startwerte und Ströme . . . 126
13.3 Das Programm prüfen . . . 127
13.4 Der Bericht . . . 128
13.5 Der Bruchfall . . . 129
13.6 Übungsaufgaben . . . 129

14 Was man dem Ergebnis glauben darf **135**

14.1 Zwei Arten von Zufall . . . 135
14.2 Die Unsicherheit durch das Modell . . . 135
14.3 Woher die Unsicherheit kommt . . . 136
14.4 Die Entscheidung unter Unsicherheit . . . 137
14.5 Der Bruchfall . . . 138
14.6 Übungsaufgaben . . . 139

VI Aktueller Stand **143**

15 Was der Rechner vom Zufall weiß **145**

15.1 Der Leitfall, ein letztes Mal . . . 145
15.2 Vier Muster . . . 145
15.3 Was offen ist . . . 148
15.4 Sechs Sätze, die bleiben . . . 148

VII Anhang **151**

A Formelsammlung und Übersicht **153**

A.1 Begriffe und Formeln . . . 153
A.2 Die Landkarte . . . 155
A.3 Was nicht bewiesen wurde . . . 156
A.4 Zeittafel . . . 156
A.5 Glossar . . . 158

B Kommentierte Quellen **161**

Vorwort

Die Zahlen dieser Reihe

Fast jede Zahl der Bände 16 bis 26 stammt aus einer Simulation: Zwanzigtausend Irrfahrten, zweihunderttausend Versicherte, fünftausend Paare von Zeitreihen. Die Bände haben diese Zahlen benutzt, als wären sie berechnet. Dieser Band fragt, was sie wirklich sind.

Band 18	Epidemien, gezogen aus Zufallszahlen, die ein Rechner erzeugt hat.
Band 22	Lernkurven über hundert Wiederholungen — mit welchem Fehlerbalken?
Band 25	Brownsche Pfade mit 10^6 Schritten — wie nahe an der Theorie?
Band 26	Scheinregression in 77 Prozent der Fälle — plus oder minus wie viel?

Eine Simulation ist ein Experiment. Sie hat Fehler, Verzerrungen und Grenzen wie jedes andere — und sie verlangt dieselbe Sorgfalt.

Drei Ergebnisse, die man nicht erwartet

1	Ein Zufallsgenerator, der jahrzehntelang in Gebrauch war, erzeugt Punkte, die vollständig auf fünfzehn Ebenen liegen — und bestand alle gängigen Tests. *(Kapitel 2)*
2	In zwanzig Dimensionen hat ein Gitter mit einer Million Punkten nur zwei Punkte je Achse; Zufallspunkte stören sich daran nicht. *(Kapitel 3)*
3	Man kann eine Simulation hundertmal genauer machen, ohne sie hundertmal länger laufen zu lassen — indem man denselben Zufall zweimal benutzt. *(Kapitel 5)*

Das zweite Ergebnis ist der Grund, warum es diesen Band gibt. ***Oberhalb von vier oder fünf Dimensionen versagt jede systematische Rechnung****, und die Zufallsmethode wird vom Notbehelf zur einzigen Möglichkeit. Fast alle Fragen der zweiten Werkhälfte — Integrale über Patientenmerkmale, über Pfade, über Parameter — sind hochdimensional.*

Die sechs Teile

Teil	Thema	Kapitel
I	Der Zufall im Rechner	1–3
II	Genauer werden	4–6
III	Ketten und Pfade	7–9
IV	Systeme über die Zeit	10–12
V	Die Praxis	13–14
VI	Stand	15

Der Leitfall

Eine Intensivstation mit zwölf Betten. Patienten treffen zufällig ein, bleiben unterschiedlich lange, und wer kein Bett findet, muss verlegt werden. Wie oft geschieht das — und was ändert ein dreizehntes Bett?

Die Frage ist einfach genug, um sie im Sonderfall exakt zu lösen, und realistisch genug, um das sofort zu verlieren*: Sobald Dringlichkeit, Tageszeit oder die Abhängigkeit der Verweildauer von der Auslastung hinzukommen, gibt es keine Formel mehr. Dann bleibt die Simulation — und die Frage, wie weit man ihr trauen darf.*

Drei Warnungen

Erste	Eine Simulation ohne Fehlerbalken ist eine Anekdote. Jede Zahl braucht ihre Streuung.
Zweite	Der Fehler fällt mit $1/\sqrt{n}$. Zehnmal genauer heißt hundertmal länger — es sei denn, man ist klug.
Dritte	Was man simuliert, ist das Modell. Die Simulation prüft die Rechnung, nicht die Annahmen.

Die dritte Warnung verbindet diesen Band mit Band 23 und 26. ***Eine Simulation kann zeigen, dass ein Schätzer unter den eigenen Annahmen funktioniert*** *— so wurde es in Band 26 durchgehend getan. Ob die Annahmen gelten, kann sie nicht zeigen; dafür gibt es keine Rechnung.*

Was dieser Band voraussetzt

Werkzeug	Band	gebraucht in
Wahrscheinlichkeit	4	durchgehend
Numerik	5	Kapitel 10–12
Statistik	17	Kapitel 4, 13
Markow-Ketten	25	Kapitel 7–9
Differential-gleichungen	14	Kapitel 10–11

Alle Rechnungen dieses Bandes sind in wenigen Zeilen Python nachvollziehbar*; der Code steht im Anhang und im Quellenverzeichnis der Reihe. Das ist hier kein Zusatz, sondern der Gegenstand.*

Teil I

Der Zufall im Rechner

Kapitel 1

Ein Experiment im Rechner

1.1 Der Leitfall

Zwölf Betten

Eine Intensivstation: Patienten treffen im Mittel 2,4-mal am Tag ein, unabhängig voneinander. Die Verweildauer ist logarithmisch normalverteilt mit Median vier Tage und Streuung 0,6 auf der logarithmischen Skala — im Mittel also 4,79 Tage. Zwölf Betten.

Wie oft muss ein Patient abgewiesen werden, weil alle Betten belegt sind?

Die Formel

Das System ist eine Warteschlange ohne Warteraum — Band 25, Kapitel 5. Für sie gilt die Formel von Erlang, und bemerkenswerterweise hängt sie nur vom Mittel der Verweildauer ab, nicht von ihrer Form:

$$a = \lambda \cdot \bar{d} = 2{,}4 \cdot 4{,}79 = 11{,}49, \qquad \Pr[\text{Abweisung}] = \frac{a^c / c!}{\sum_{k=0}^{c} a^k / k!} = 0{,}1785$$

Fast jeder fünfte Patient findet kein Bett. *Das ist das exakte Ergebnis, und es wird gleich zum Maßstab: Eine Simulation, die diese Zahl nicht trifft, ist falsch. Danach verlassen wir den Sonderfall, in dem es eine Formel gibt.*

Dasselbe als Simulation

Man erzeuge Ankünfte, ziehe Verweildauern, führe Buch über die Betten, zähle Abweisungen:

Tage	Ankünfte	Abweisung	Fehler
100	238	0,160	0,019
1 000	2 387	0,174	0,005
10 000	23 956	0,172	0,006
100 000	240 287	0,180	0,001
exakt		**0,1785**	

Die Simulation nähert sich dem exakten Wert — langsam und unregelmäßig. Bei zehntausend Tagen ist sie schlechter als bei tausend.

***Das ist kein Fehler des Programms, sondern die Natur des Verfahrens**: Jede Zeile der Tabelle ist eine Zufallsgröße. Die dritte war zufällig weit weg, die zweite zufällig nahe. Wer nur eine Zeile sieht, kann das nicht wissen — und das ist die erste Lehre dieses Bandes: Eine simulierte Zahl ohne Angabe ihrer Streuung ist nicht zu gebrauchen.*

1.2 Die Streuung messen

Fünfzig Wiederholungen

Die Simulation über tausend Tage, fünfzigmal mit verschiedenen Startwerten:

Mittel der 50 Läufe	0,1797
Streuung der Einzelläufe	0,0128
Standardfehler des Mittels	**0,0018**
exakt	0,1785

Das Ergebnis lautet nicht $0{,}18$**, sondern** $0{,}180 \pm 0{,}002$**. Erst mit dem zweiten Teil ist es eine Aussage.**

***Ein einzelner Lauf von tausend Tagen streut um** $0{,}013$ — *das ist ein Zehntel des Werts selbst. Wer zwei Stationsvarianten mit je einem Lauf vergleicht und einen Unterschied von einem Prozentpunkt findet, hat nichts gefunden. Kapitel 4 zeigt, wie man solche Vergleiche richtig anstellt, und Kapitel 5, wie man die Streuung um das Zehnfache drückt, ohne länger zu rechnen.*

Definition 1.1 — Monte-Carlo-Schätzer

Sei $\theta = \mathbb{E}[g(X)]$ für eine Zufallsgröße X, die man erzeugen kann. Der **Monte-Carlo-Schätzer** ist

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^{n} g(X_i)$$

mit unabhängigen Kopien $X_1, \dots, X_n$.

Satz 1.2 — die Wurzelregel

Ist $\mathrm{Var}[g(X)] = \sigma^2 < \infty$, so gilt

$$\mathbb{E}[\hat{\theta}_n] = \theta, \qquad \mathrm{Var}[\hat{\theta}_n] = \frac{\sigma^2}{n}, \qquad \frac{\hat{\theta}_n - \theta}{\sigma/\sqrt{n}} \longrightarrow \mathcal{N}(0,1).$$

Beweis

Erwartungswert und Varianz folgen aus der Linearität und der Unabhängigkeit; die Grenzverteilung ist der zentrale Grenzwertsatz aus Band 4, Kapitel 13. ■

Der Fehler fällt mit $1/\sqrt{n}$ — unabhängig davon, was X ist, wie viele Dimensionen es hat, und wie glatt g ist.

Beides ist in diesem Satz enthalten — der Fluch und der Segen der Methode. *Der Fluch: Zehnmal genauer verlangt hundertmal mehr Läufe, immer. Der Segen: Es gibt keine Abhängigkeit von der Dimension. Die Trapezregel aus Band 5 ist in einer Dimension unschlagbar und in zwanzig unbrauchbar; Monte Carlo ist überall gleich mittelmäßig — und deshalb oberhalb von etwa fünf Dimensionen die einzige Methode, die überhaupt funktioniert. Kapitel 3 rechnet das vor.*

1.3 Warum man simuliert

Drei Gründe

Keine Formel	Sobald die Station Dringlichkeitsstufen hat, die Verweildauer von der Auslastung abhängt oder die Ankünfte tagsüber häufiger sind, gibt es keine Erlang-Formel mehr.
Verteilung statt Mittel	Die Formel gibt die mittlere Abweisungsrate. Die Simulation gibt auch, wie oft an einem Tag drei Patienten abgewiesen werden.
Prüfung	Ein Schätzer, ein Test, ein Verfahren — ob es tut, was es soll, prüft man an Daten, bei denen man die Wahrheit kennt. Band 26 hat das durchgehend getan.

Der dritte Grund ist für die Wissenschaft der wichtigste. *Eine Methode, die in der Simulation unter ihren eigenen Annahmen versagt, ist falsch — das ist ein Beweis. Eine Methode, die dort funktioniert, ist nicht bewiesen; sie hat nur eine Prüfung bestanden. Das ist der Unterschied zwischen Band B und diesem Band, und er wird in Kapitel 13 wieder aufgenommen.*

1.4 Der Bruchfall

Was die Simulation nicht weiß

Die Annahmen	Poisson-Ankünfte, logarithmisch normale Dauern, Unabhängigkeit — die Simulation nimmt sie als gegeben. Ob sie stimmen, sagt sie nicht.
Der Anfang	Die Station startet leer. Die ersten Tage sind untypisch, und bei hundert Tagen Laufzeit sind sie ein Zehntel der Daten.
Die seltenen Fälle	Will man wissen, wie oft an einem Tag fünf Patienten abgewiesen werden, braucht man Millionen Tage — oder Kapitel 6.

Zur zweiten Zeile

> *Die erste Zeile der Tabelle in Abschnitt 1.1 lag bei* 0,160 *— zu niedrig, und nicht nur durch Zufall: Eine leere Station weist in der ersten Woche niemanden ab.* ***Das ist die Einschwingphase, und sie ist dasselbe Problem wie die Mischzeit in Band 25, Kapitel 3.*** *Man verwirft die ersten Tage; wie viele, ist die Frage, die Kapitel 7 beantwortet.*

1.5 Übungsaufgaben

Aufgabe 1.1 — Die Formel nachrechnen

Berechnen Sie die Abweisungsrate für $a = 11{,}49$ und $c = 12$ mit der rekursiven Form $B_c = \dfrac{a\,B_{c-1}}{c + a\,B_{c-1}}$, $B_0 = 1$.

Lösung

Schritt 1 — Die Rekursion

c	B_c	c	B_c
0	1,000	7	0,470
1	0,920	8	0,403
2	0,841	9	0,340
3	0,763	10	0,281
4	0,687	11	0,227
5	0,612	12	**0,1785**
6	0,540	13	0,136

Schritt 2 — Das dreizehnte Bett

$$0{,}1785 - 0{,}136 = 0{,}042$$

Ein weiteres Bett senkt die Abweisung von 17,9 auf 13,6 Prozent — bei 876 Ankünften im Jahr sind das 37 Patienten weniger, die verlegt werden müssen.

Schritt 3 — Warum die Rekursion

Die geschlossene Formel verlangt 12! und a^{12} — Zahlen, die bei großen Stationen den Zahlenbereich sprengen. ***Die Rekursion vermeidet das und ist nebenbei numerisch stabil*** *— Band 5, Kapitel 2. Dass man diese Aufgabe exakt lösen kann, ist die Ausnahme; sie dient als Maßstab für alles, was folgt.*

Aufgabe 1.2 — Wie viele Läufe?

Die Abweisungsrate soll auf $\pm 0{,}002$ genau bestimmt werden (95 %-Intervall). Wie viele Simulationstage braucht man?

Lösung

Schritt 1 — Die Streuung je Ankunft

Jede Ankunft ist ein Bernoulli-Versuch mit $p \approx 0{,}18$:

$$\sigma = \sqrt{0{,}18 \cdot 0{,}82} = 0{,}384$$

Schritt 2 — Die Wurzelregel

$$1{,}96 \cdot \frac{0{,}384}{\sqrt{n}} \le 0{,}002 \quad \Longrightarrow \quad n \ge \left(\frac{1{,}96 \cdot 0{,}384}{0{,}002} \right)^2 = 141\,600 \text{ Ankünfte}$$

Schritt 3 — In Tagen

$$\frac{141\,600}{2{,}4} \approx 59\,000 \text{ Tage} \approx 160 \text{ Jahre}$$

Für drei Stellen Genauigkeit braucht man hundertsechzig simulierte Jahre — und die Rechnung unterschätzt noch, weil aufeinanderfolgende Ankünfte nicht unabhängig sind.

***Die Unabhängigkeit fehlt, weil die Station ein Gedächtnis hat**: Ist sie heute voll, ist sie es morgen wahrscheinlich auch. Die Abweisungen kommen in Häufungen, und die wirksame Zahl der Beobachtungen ist kleiner als n — Satz 10.4 aus Band 26. Die Tabelle aus Abschnitt 1.2 zeigt es: 0,0128 Streuung bei 2387 Ankünften entspricht einer wirksamen Zahl von nur etwa 900. Kapitel 4 behandelt die Abhilfe.*

Aufgabe 1.3 — Eine Frage ohne Formel

Formulieren Sie die Simulation so um, dass Notfälle Vorrang haben: Ein Notfall belegt das Bett eines Patienten, der am ehesten verlegt werden kann. Was ändert sich am Programm, und was lässt sich nun fragen?

Lösung

Schritt 1 — Was sich ändert

Ankunft	Jeder Patient erhält eine Dringlichkeit, etwa 30 Prozent Notfälle.
Belegung	Ist alles voll und kommt ein Notfall, wird der Patient mit der kürzesten Restdauer verlegt.
Buchführung	Zwei Zähler: abgewiesene Notfälle, vorzeitig Verlegte.

Schritt 2 — Was man nun fragen kann

1	Wie oft wird ein Notfall abgewiesen? (Nur, wenn alle Betten von Notfällen belegt sind.)
2	Wie viele Patienten werden vorzeitig verlegt, und wie lange vor ihrer Zeit?
3	Senkt ein dreizehntes Bett eher die Abweisungen oder die Verlegungen?

Für keine dieser Fragen gibt es eine Formel. Die Simulation braucht zehn Zeilen mehr.

Schritt 3 — Was gleich bleibt

Die Wurzelregel. *Auch die neue Simulation streut, und die Frage nach Fehlerbalken, Einschwingphase und Abhängigkeit stellt sich unverändert. Die Freiheit, jede Regel einbauen zu können, ist der Grund für die Beliebtheit der Methode — und die Statistik dahinter ist dieselbe wie beim einfachsten Fall. Das ist der Aufbau dieses Bandes: Teil I liefert den Zufall, Teil II die Genauigkeit, Teil III und IV die Modelle.*

Ein Kartenspiel und ein Name

Stanisław Ulam lag 1946 nach einer Krankheit im Bett und legte Patiencen. Er fragte sich, wie groß die Wahrscheinlichkeit ist, dass eine aufgeht — und fand, dass es leichter sei, hundert Spiele zu legen und zu zählen, als es auszurechnen.

*Er erzählte es **John von Neumann**, und beide erkannten, dass dasselbe für die Neutronendiffusion in Los Alamos galt. **Den Decknamen "Monte Carlo" schlug Nicholas Metropolis vor** — nach dem Spielkasino, in dem Ulams Onkel sein Geld verspielt hatte. Die erste Rechnung lief 1947 auf dem ENIAC; von Neumann schrieb das Programm auf Lochkarten.*

Und die Vorgeschichte

***Georges-Louis Leclerc de Buffon** hatte 1777 vorgeschlagen, π zu bestimmen, indem man Nadeln auf ein Dielenmuster wirft und zählt, wie viele eine Fuge kreuzen — das Titelbild dieses Bandes in anderer Gestalt. **William Gosset erzeugte 1908 seine t-Verteilung, indem er Körpermaße von Verbrechern auf Karten schrieb, mischte und zog**: die erste statistische Simulation, von Hand, mit dreitausend Karten.*

Erlang

*Die Formel aus Abschnitt 1.1 stammt von **Agner Krarup Erlang** aus dem Jahr 1917 — für Telefonleitungen, nicht für Betten. **Dass sie von der Form der Verweildauer unabhängig ist, bewies erst Boris Sevastyanov 1957**; Erlang hatte es vermutet. Für Krankenhäuser wurde sie ab den 1960er Jahren benutzt, und sie ist bis heute das einfachste Werkzeug der Bettenplanung.*

Simulation heute

Digitale Zwillinge	Ganze Krankenhäuser als Simulation, fortlaufend mit Daten abgeglichen.
Agentenmodelle	Jeder Patient, jeder Arzt ein eigenes Programm — Band 18 für Epidemien.
Reproduzier-barkeit	Simulationen, die ein anderer mit denselben Zahlen wiederholen kann.

Zur dritten Zeile

Ein großer Teil veröffentlichter Simulationsstudien lässt sich nicht wiederholen — weil der Startwert fehlt, die Version des Generators, die Zahl der verworfenen Einschwingtage. ***Seit 2020 verlangen die meisten Fachzeitschriften Code und Startwerte****; in der Medizin ist man noch nicht so weit. Dieser Band legt für jede Zahl beides offen, und Kapitel 13 macht daraus eine Regel.*

Was Sie jetzt können

Der Leitfall	zwölf Betten, 17,9 Prozent Abweisung
Definition 1.1	Mittelwert über Zufallsläufe
Satz 1.2	Fehler $\sigma / \sqrt{n}$, dimensionsfrei
Die Regel	jede Zahl mit Standardfehler
Der Bruchfall	Annahmen, Anfang, seltene Fälle

Alles beruht darauf, dass der Rechner Zufallszahlen liefert. Das nächste Kapitel zeigt, dass er das gar nicht kann — und was er stattdessen tut.

Kapitel 2

Zufall aus einer Formel

2.1 Der Widerspruch

Ein Rechner kann nicht würfeln

Jede Anweisung eines Rechners ist festgelegt; derselbe Zustand führt stets zum selben nächsten. Was er liefert, ist eine Folge, die nach einer Formel entsteht — und die nur so aussieht, als wäre sie zufällig.

> **Die Frage ist nicht, ob die Zahlen zufällig sind — sie sind es nicht —, sondern ob irgendein Test den Unterschied bemerkt.**
>
> *Das ist dieselbe Haltung wie bei der Kryptographie in Band 20: Dort hieß ein Schlüsselstrom sicher, wenn kein Angreifer ihn von Zufall unterscheiden kann. Hier heißt eine Folge brauchbar, wenn keine Simulation den Unterschied merkt. Beides sind Aussagen über den Beobachter, nicht über die Folge.*

Definition 2.1 — linearer Kongruenzgenerator

$$x_{n+1} = (a\,x_n + c) \bmod m, \qquad u_n = x_n / m$$

mit Multiplikator a, Inkrement c, Modul m und Startwert x_0.

Zwei Beispiele mit $m = 16$

$a = 5, c = 1$	0, 1, 6, 15, 12, 13, 2, 11, 8, 9, 14, 7, 4, 5, 10, 3, 0, … — alle sechzehn Werte, dann von vorn.
$a = 5, c = 0$	$1, 5, 9, 13, 1, 5, \ldots$ — Periode vier.

Satz 2.2 — die volle Periode

Ein Generator mit $c \neq 0$ hat genau dann die Periode m, wenn c und m teilerfremd sind, $a - 1$ durch jeden Primteiler von m teilbar ist, und $a - 1$ durch 4 teilbar ist, falls m es ist.

Probe am ersten Beispiel: $\mathrm{ggT}(1,16)=1$; $a-1=4$ *ist durch* 2 *und durch* 4 *teilbar.* ✓ *Der Beweis ist Zahlentheorie aus Band 1 und wird dort in Kapitel 9 geführt — wir übergehen ihn hier, die erste Auslassung dieses Bandes.*

Die Periode ist die erste Grenze: Nach m Zahlen wiederholt sich alles. Eine Simulation, die mehr braucht, benutzt dieselben Zahlen zweimal.

Generator	Periode	bei 10^6/s
Minimal Standard (1988)	$2^{31}-2$	36 Minuten
Mersenne-Twister (1998)	$2^{19937}-1$	10^{5990} Jahre
PCG64 (2014)	2^{128}	10^{25} Jahre

Der Minimal Standard war zwanzig Jahre lang die Empfehlung *— und seine Periode ist heute in einer halben Stunde erschöpft. Die Bände 16 bis 26 dieser Reihe benutzen PCG64, den Standard von NumPy seit 2019; seine 2^{128} Zahlen reichen für jede Simulation, die ein Rechner je ausführen wird.*

2.2 Das Gitter

Der Fehler von RANDU

IBM lieferte ab 1960 den Generator $x_{n+1} = 65539\,x_n \bmod 2^{31}$ aus. Er bestand die üblichen Tests — Mittelwert 0,503, Varianz 0,0832 gegen 0,0833, keine Autokorrelation.

Satz 2.3 — alle Tripel liegen auf fünfzehn Ebenen
Für RANDU gilt für je drei aufeinanderfolgende Zahlen

$$x_{n+2} - 6\,x_{n+1} + 9\,x_n \equiv 0 \pmod{2^{31}}.$$

Beweis
$65539 = 2^{16}+3$, also

$$x_{n+2} = (2^{16}+3)^2 x_n = (2^{32} + 6\cdot 2^{16} + 9)\,x_n \equiv (6\cdot 2^{16}+9)\,x_n \pmod{2^{31}}.$$

Andererseits $6\,x_{n+1} = 6(2^{16}+3)x_n = (6\cdot 2^{16}+18)\,x_n$. Die Differenz ist $-9x_n$. ■

Jedes Tripel (u_n, u_{n+1}, u_{n+2}) liegt auf einer von nur fünfzehn parallelen Ebenen im Einheitswürfel. Ein zufälliger Punkt im Würfel tut das nie.

Generator	$(9u_n - 6u_{n+1} + u_{n+2}) \bmod 1$
RANDU	nimmt **einen** Wert an (30 000 Tripel)
PCG64	29 540 verschiedene Werte

Das ist die Gitterstruktur, die jeder lineare Kongruenzgenerator hat *— RANDU nur in ihrer schlimmsten Form.* ***Marsaglia*** *zeigte 1968, dass die k-Tupel jedes solchen Generators auf höchstens $(k!\,m)^{1/k}$ Hyperebenen liegen; bei $m = 2^{31}$ und $k = 3$ sind das höchstens 2344, bei gutem Multiplikator fast so viele, bei RANDU fünfzehn. Eine Simulation, die Tripel braucht — jeder Punkt im Raum, jede Verweildauer mit zwei Parametern —, sieht bei RANDU ein Gitter statt einer Wolke.*

2.3 Aus gleichverteilt wird alles andere

Satz 2.4 — Inversion

Ist U gleichverteilt auf $(0, 1)$ und F eine Verteilungsfunktion mit Umkehrfunktion F^{-1}, so hat $X = F^{-1}(U)$ die Verteilung F.

Beweis

$$\Pr[X \le x] = \Pr[F^{-1}(U) \le x] = \Pr[U \le F(x)] = F(x).$$

■

Verteilung	$F^{-1}(u)$	geprüft
Exponential(λ)	$-\ln(1-u)/\lambda$	Mittel 0,4175 bei $1/\lambda = 0{,}4167$
Poisson(λ)	kleinstes k mit $F(k) \ge u$	Mittel 3,201, Varianz 3,209
Normal	keine geschlossene Form	—

Die Inversion ist das Verfahren der Wahl, wo sie geht*: Sie braucht genau eine Zufallszahl je Ziehung, erhält die Ordnung — größeres u, größeres x — und macht damit die Tricks aus Kapitel 5 möglich. Für die Normalverteilung geht sie nur näherungsweise, und das führt zu den beiden anderen Verfahren.*

Satz 2.5 — Box und Muller

Sind U_1, U_2 unabhängig gleichverteilt, so sind

$$Z_1 = \sqrt{-2\ln U_1}\,\cos(2\pi U_2), \qquad Z_2 = \sqrt{-2\ln U_1}\,\sin(2\pi U_2)$$

unabhängig standardnormalverteilt.

Beweis

Das Paar (Z_1, Z_2) hat in Polarkoordinaten den Radius $R = \sqrt{-2\ln U_1}$ und den Winkel $\Theta = 2\pi U_2$. Der Winkel ist gleichverteilt; für den Radius gilt $\Pr[R^2 \le r] = \Pr[-2\ln U_1 \le r] = 1 - e^{-r/2}$ — also ist R^2 exponentialverteilt mit Mittel 2. Genau das ist die Verteilung von $Z_1^2 + Z_2^2$ bei zwei unabhängigen Normalgrößen (χ^2 mit zwei Freiheitsgraden), und die Richtung ist unabhängig vom Radius. ■

Geprüft an 100 000 *Paaren: Mittel* −0,0007, *Streuung* 0,998, *Schiefe* 0,001.

Satz 2.6 — Verwerfung

Sei f die gewünschte Dichte und g eine Dichte, aus der man ziehen kann, mit $f(x) \le M\,g(x)$ für alle x. Man ziehe $X \sim g$ und U gleichverteilt; man nehme X an, falls $U \le f(X)/(Mg(X))$.

Beweis

$$\Pr[X \le x \mid \text{angenommen}] = \frac{\int_{-\infty}^{x} g(t)\,\frac{f(t)}{Mg(t)}\,\mathrm{d}t}{\int_{-\infty}^{\infty} g(t)\,\frac{f(t)}{Mg(t)}\,\mathrm{d}t} = \frac{\frac{1}{M}\int_{-\infty}^{x} f}{\frac{1}{M}} = F(x).$$

Die Annahmewahrscheinlichkeit ist $1/M$. ■

Zwei Beispiele

Ziel	M	soll	geprüft
Halbkreis aus Rechteck	$4/\pi$	0,785	0,787
Halbnormal aus Exponential	$\sqrt{2e/\pi}$	0,760	0,761

***Die Verwerfung ist das allgemeinste Verfahren und das verschwenderischste**: Ein Viertel der Ziehungen geht verloren, und bei schlecht gewählter Hülle weit mehr. Ihr Vorzug ist, dass sie nur die Dichte braucht — keine Verteilungsfunktion, keine Umkehrung. In Kapitel 7 wird sie zum Baustein des Metropolis-Verfahrens, das sogar ohne die Normierung der Dichte auskommt.*

2.4 Der Bruchfall

Was den Zufall verdirbt

Der Startwert	Zwei Läufe mit demselben Startwert sind identisch. Zwei Läufe mit den Startwerten 1 und 2 sind bei schlechten Generatoren fast identisch.
Die Uhr als Startwert	Zwei Prozesse, die in derselben Sekunde starten, erzeugen dieselben Zahlen — der häufigste Fehler bei parallelen Simulationen.
Die unteren Bits	Bei vielen alten Generatoren wechseln die letzten Bits streng abwechselnd. Wer $x \bmod 2$ als Münzwurf benutzt, erhält Kopf, Zahl, Kopf, Zahl.
Die Umwandlung	$u \cdot n$ abgerundet ist nicht gleichverteilt auf $\{0, \dots, n-1\}$, wenn n kein Teiler des Moduls ist. Der Fehler ist klein und systematisch.

***Die zweite Zeile hat in den 2010er Jahren mehrere veröffentlichte Studien entwertet**, deren Simulationen auf Rechenclustern liefen: Hundert Knoten, dieselbe Sekunde, hundertmal dieselben Zahlen — und ein Fehlerbalken, der zehnmal zu klein war. Moderne Generatoren bieten dafür Ströme: aus einem Startwert beliebig viele unabhängige Folgen. Kapitel 13 macht daraus eine Vorschrift.*

2.5 Übungsaufgaben

Aufgabe 2.1 — Einen Generator prüfen

Hunderttausend Zahlen eines Generators werden in hundert gleich breite Klassen sortiert. Die χ^2-Statistik beträgt 105,5, die Autokorrelation auf Abstand eins $+0{,}003$. Ist der Generator brauchbar?

Lösung

Schritt 1 — Gleichverteilung

Erwartungswert 99, 95-Prozent-Grenze 123 (Band 17, Kapitel 10). 105,5 ist unauffällig.

Schritt 2 — Unabhängigkeit

Standardfehler der Autokorrelation bei $n = 100\,000$: $1/\sqrt{n} = 0{,}003$. Der Wert 0,003 ist

eine Standardabweichung — unauffällig.

Schritt 3 — Das Urteil

Beide Tests bestanden — und RANDU hätte sie auch bestanden.

Ein Generator ist nie bewiesen, nur noch nicht widerlegt. *Die heute üblichen Prüfsammlungen — TestU01 mit über hundert Tests, darunter Tripel auf Ebenen, Geburtstagsabstände, Rangtests von Zufallsmatrizen — sind das Ergebnis von fünfzig Jahren gefundener Fehler. Für eigene Zwecke genügt die Regel: einen Generator aus dieser Sammlung benutzen, nie einen selbst gebauten.*

Aufgabe 2.2 — Inversion für eine Verweildauer

Erzeugen Sie aus $u = 0{,}37$ eine logarithmisch normalverteilte Verweildauer mit Median 4 und $\sigma = 0{,}6$.

Lösung

Schritt 1 — Die Normalgröße

$\Phi^{-1}(0{,}37) = -0{,}332$ (Tafel oder Näherung).

Schritt 2 — Die Umwandlung

$$d = 4 \cdot e^{0{,}6 \cdot (-0{,}332)} = 4 \cdot e^{-0{,}199} = 4 \cdot 0{,}820 = 3{,}28 \text{ Tage}$$

Schritt 3 — Die Probe

$\ln(3{,}28/4)/0{,}6 = -0{,}331$; $\Phi(-0{,}331) = 0{,}370$. ✓

Schritt 4 — Warum über die Normalgröße

Die Umkehrfunktion der logarithmischen Normalverteilung ist $\exp(\mu + \sigma\Phi^{-1}(u))$ — Inversion der Normalverteilung, dann Exponentialfunktion. ***Φ^{-1} hat keine geschlossene Form, aber sehr gute Näherungen*** *(Band 5, Kapitel 6), und jeder Rechner hat sie eingebaut. Für die Verweildauern im Leitfall ist das der schnellste Weg, und er erhält die Ordnung: Ein großes u ist ein langer Aufenthalt. Kapitel 5 wird genau das ausnutzen.*

Aufgabe 2.3 — Die Hülle wählen

Für die Halbnormalverteilung $f(x) = \sqrt{2/\pi}\, e^{-x^2/2}$, $x > 0$, soll die Exponentialverteilung $g(x) = \lambda e^{-\lambda x}$ als Hülle dienen. Welches λ ist das beste?

Lösung

Schritt 1 — Das Verhältnis

$$\frac{f(x)}{g(x)} = \frac{\sqrt{2/\pi}}{\lambda}\, e^{-x^2/2+\lambda x}$$

Der Exponent ist maximal bei $x = \lambda$, der Wert dort $e^{\lambda^2/2}$:

$$M(\lambda) = \frac{\sqrt{2/\pi}}{\lambda}\, e^{\lambda^2/2}$$

Schritt 2 — Minimieren

$$\frac{\mathrm{d}}{\mathrm{d}\lambda} \ln M = -\frac{1}{\lambda} + \lambda = 0 \quad \Longrightarrow \quad \lambda = 1$$

$$M(1) = \sqrt{2/\pi} \cdot e^{1/2} = \sqrt{2e/\pi} = 1{,}3155$$

Schritt 3 — Die Annahmequote

$$\frac{1}{M} = 0{,}760 \quad \text{— geprüft: } 0{,}761$$

λ	M	**Annahme**
0,5	1,81	55 %
1,0	**1,32**	**76** %
2,0	2,95	34 %

Die beste Hülle ist die, die der Zieldichte am engsten anliegt *— hier bei $\lambda = 1$, wo Hülle und Ziel sich bei $x = 1$ berühren. Das ist eine Optimierungsaufgabe aus Band 19 und das Muster für alle Verwerfungsverfahren: Je enger die Hülle, desto weniger Verschwendung. Für die Normalverteilung benutzt man heute den Ziggurat-Algorithmus, dessen Hülle aus 256 Rechtecken besteht und 99 Prozent annimmt.*

Ein Verfahren, das jeder benutzte, und sein Fehler

John von Neumann schlug 1946 die Mittquadratmethode vor — Zahl quadrieren, mittlere Ziffern nehmen — und wusste, dass sie schlecht war. Sein Satz dazu ist berühmt: **Wer arithmetische Verfahren zur Erzeugung von Zufallsziffern erwägt, befindet sich in einem Zustand der Sünde.**

Derrick Lehmer *gab 1949 den linearen Kongruenzgenerator an.* ***RANDU kam 1960 von IBM und war bis in die 1970er Jahre der meistbenutzte Generator der Welt*** *— im System/360, in Fortran-Bibliotheken, in Lehrbüchern.* ***George Marsaglia*** *veröffentlichte 1968 den Aufsatz Random Numbers Fall Mainly in the Planes, und Satz 2.3 wurde allgemein bekannt. Benutzt wurde RANDU trotzdem noch jahrelang;* ***Knuth*** *nannte ihn “wirklich entsetzlich”.*

Der Mersenne-Twister

__Makoto Matsumoto__ und __Takuji Nishimura__ veröffentlichten 1998 einen Generator mit der Periode $2^{19937} - 1$, gleichverteilt in 623 Dimensionen — das Gitterproblem war damit praktisch erledigt. __Er wurde der Standard in Python, R, Matlab und fast allen anderen Umgebungen__ und blieb es zwanzig Jahre, bis kleinere und schnellere Generatoren wie PCG ihn ablösten. Für die Kryptographie taugt keiner von beiden: Aus 624 Ausgaben lässt sich der Zustand des Twisters vollständig zurückrechnen.

Zufallszahlen heute

Zählergeneratoren	Zahl Nummer n direkt berechnen, ohne die $n-1$ davor — ideal für Parallelrechner.
Physikalischer Zufall	Rauschen in Halbleitern, Photonen am Strahlteiler — für Schlüssel, nicht für Simulationen.
Quasi-Zufall	Folgen, die absichtlich gleichmäßiger sind als Zufall — Kapitel 6.

Zur ersten Zeile

Generatoren wie Philox oder Threefry berechnen die n-te Zufallszahl als Funktion von n und einem Schlüssel — eine abgeschwächte Blockchiffre aus Band 20. __Damit kann jeder Prozessor eines Rechenverbunds seine eigenen Zahlen erzeugen, ohne mit den anderen zu sprechen__, und das Problem aus dem Bruchfall verschwindet. Dass die Kryptographie und die Simulation hier dieselben Werkzeuge benutzen, ist kein Zufall: Beide brauchen Folgen, die niemand von Zufall unterscheiden kann.

Was Sie jetzt können

Definition 2.1	Kongruenzgenerator, Periode
Satz 2.3	RANDU: fünfzehn Ebenen
Satz 2.4	Inversion: eine Zahl, eine Ziehung
Satz 2.5, 2.6	Box-Muller, Verwerfung
Der Bruchfall	Startwert, Uhr, untere Bits

Nun kann der Rechner aus jeder Verteilung ziehen. Das nächste Kapitel benutzt das für die Aufgabe, an der alle anderen Verfahren scheitern: Integrale in vielen Dimensionen.

Kapitel 3

Der Fluch der Dimension

3.1 Ein Integral als Erwartungswert

Die Umdeutung

Jedes Integral über einen beschränkten Bereich ist ein Erwartungswert:

$$\int_0^1 f(x)\,\mathrm{d}x = \mathbb{E}\big[f(U)\big], \qquad U \sim \text{gleichverteilt auf } (0,1).$$

Also lässt es sich mit Definition 1.1 schätzen: Zufallspunkte ziehen, f auswerten, mitteln.

In einer Dimension: kein guter Tausch

$\int_0^1 e^{-x^2}\mathrm{d}x = 0{,}746824$:

n	Trapezregel	Monte Carlo
10	$6 \cdot 10^{-4}$	$6 \cdot 10^{-2}$
100	$6 \cdot 10^{-6}$	$2 \cdot 10^{-2}$
1000	$6 \cdot 10^{-8}$	$7 \cdot 10^{-3}$

Die Trapezregel aus Band 5 gewinnt in einer Dimension um fünf Größenordnungen. *Ihr Fehler fällt mit n^{-2}, der von Monte Carlo mit $n^{-1/2}$. Wer ein eindimensionales Integral mit Zufallszahlen rechnet, hat das falsche Werkzeug. Die Frage ist, was in zehn Dimensionen geschieht.*

3.2 Die Rechnung in d Dimensionen

Satz 3.1 — der Fluch

Eine Produktregel mit k Stützstellen je Achse braucht in d Dimensionen $n = k^d$ Auswertungen. Ihr Fehler fällt wie $k^{-2} = n^{-2/d}$. Der Monte-Carlo-Fehler fällt wie $n^{-1/2}$ — für jedes d.

Beweis
Die Trapezregel hat in jeder Achse den Fehler $O(h^2)$ mit $h = 1/k$; der Produktfehler ist von derselben Ordnung (Band 5, Kapitel 7). Mit $k = n^{1/d}$ folgt $n^{-2/d}$. Der Monte-Carlo-Teil ist Satz 1.2. ■

Gleichstand bei $d = 4$. Darüber gewinnt der Zufall — und ab etwa $d = 10$ ist er die einzige Methode, die überhaupt noch ein Ergebnis liefert.

Geprüft: $\int_{[0,1]^d} e^{-|x|^2}\,\mathrm{d}x$ mit je 10^5 Auswertungen

d	exakt	Monte Carlo	Trapez	je Achse
1	0,74682	$0{,}7470 \pm 0{,}0006$	0,74682	100 000
3	0,41654	$0{,}4157 \pm 0{,}0006$	0,41649	46
6	0,17350	$0{,}1735 \pm 0{,}0004$	0,1711	7
10	0,05397	$\mathbf{0{,}0541 \pm 0{,}0002}$	**0,0438**	3

In zehn Dimensionen hat die Trapezregel drei Punkte je Achse und liegt um zwanzig Prozent daneben; Monte Carlo liegt um drei Promille daneben — und weiß es. *Die letzte Spalte ist die eigentliche Erklärung: Ein Gitter muss jede Achse abtasten, und die Zahl der Punkte wird auf d Achsen verteilt. Zufallspunkte tun das nicht; sie füllen den Raum, ohne ihn zu zerlegen.*

Wo die Dimensionen herkommen

Band 17	Bayessche A-posteriori-Erwartung: ein Integral über alle Parameter — bei zwanzig Parametern zwanzig Dimensionen.
Band 23	Die g-Formel: Integral über die Verteilung aller Störgrößen zu allen Zeitpunkten.
Band 24	Erwartungsnutzen über Patientenmerkmale, Testergebnisse, Verläufe.
Band 25	Erwartungswert eines Pfadfunktionals: ein Integral über 10^6 Zeitschritte — 10^6 Dimensionen.

Fast jede Erwartung der zweiten Werkhälfte ist ein hochdimensionales Integral. Es gab nie eine Alternative zur Simulation — der Band holt nur nach, warum.

3.3 Wo auch der Zufall versagt

Seltene Treffer

Das Volumen der Einheitskugel in d Dimensionen, geschätzt als Trefferanteil im Würfel $[-1,1]^d$ mit 200 000 Punkten:

d	exakt	geschätzt	Trefferquote	rel. Fehler
2	3,1416	3,1384	0,785	0,1 %
5	5,2638	5,2771	0,165	0,5 %
10	2,5502	2,3808	0,0023	4,5 %
20	0,0258	**0**	$2 \cdot 10^{-8}$	—

In zwanzig Dimensionen trifft keiner von zweihunderttausend Punkten die Kugel. Die Schätzung ist null, und der Standardfehler auch.

***Das ist der zweite Fluch, und er betrifft den Zufall selbst**: Der relative Fehler einer Trefferschätzung ist $\sqrt{(1-p)/(np)}$ — bei kleinem p braucht man $n \approx 1/p$ Punkte für einen einzigen Treffer. Die Kugel in zwanzig Dimensionen ist ein Hundertmillionstel des Würfels; die Simulation sucht einen Punkt in einem leeren Raum. Dasselbe geschieht bei jedem seltenen Ereignis — der Abweisung von fünf Patienten an einem Tag, dem Zusammenbruch eines Portfolios, der Fehldiagnose bei einer Prävalenz von einem Promille. Kapitel 6 zeigt den Ausweg: nicht gleichmäßig ziehen, sondern dort, wo etwas passiert.*

3.4 Der Bruchfall

Unendliche Varianz

Satz 1.2 verlangt $\operatorname{Var}[g(X)] < \infty$. Was, wenn nicht?

Das Beispiel	$\int_0^1 x^{-1/2}\,\mathrm{d}x = 2$: Der Integrand ist integrierbar, sein Quadrat x^{-1} nicht.
Was geschieht	Der Schätzer konvergiert — nach dem Gesetz der großen Zahlen —, aber langsamer als $n^{-1/2}$, und der geschätzte Standardfehler ist unbrauchbar: Er springt bei jedem seltenen, sehr kleinen x.
Die Abhilfe	Substitution $x = t^2$: $\int_0^1 2\,\mathrm{d}t = 2$ — Varianz null.

> ***Der Fall ist nicht exotisch.*** *Gewichtete Schätzer aus Band 23, Kapitel 8 — Gewichtung mit der inversen Behandlungsneigung — haben genau diese Form: Ein Patient mit Neigung* 0,001 *erhält das Gewicht* 1000*, und ein einziger solcher Patient bewegt das Ergebnis. Die Varianz ist formal endlich, aber riesig, und der Standardfehler aus der Stichprobe unterschätzt sie. Die Abhilfe dort heißt Gewichte stutzen; die Abhilfe hier heißt Substitution. Beides ist derselbe Gedanke: die Masse dorthin verschieben, wo der Schätzer sie verträgt.*

3.5 Übungsaufgaben

Aufgabe 3.1 — Den Gleichstand bestimmen

Bei welchem d ist die Produkt-Simpsonregel (Fehler $n^{-4/d}$) gleichauf mit Monte Carlo?

Lösung

Schritt 1 — Gleichsetzen

$$n^{-4/d} = n^{-1/2} \quad \Longleftrightarrow \quad \frac{4}{d} = \frac{1}{2} \quad \Longleftrightarrow \quad d = 8$$

Schritt 2 — Die Tabelle

Regel	Fehler	Gleichstand bei
Trapez	$n^{-2/d}$	$d = 4$
Simpson	$n^{-4/d}$	$d = 8$
Gauß, k Punkte	$n^{-2k/d}$	$d = 4k$

Schritt 3 — Der Haken

Die Fehlerordnungen der Produktregeln setzen glatte Integranden voraus. Ein Integrand mit Knick — $\max\{S - K, 0\}$ aus Band 25 — fällt auf $n^{-1/d}$ zurück, und der Gleichstand liegt bei $d = 2$.

> ***Monte Carlo braucht keine Glattheit*** *— nur endliche Varianz. Das ist neben der Dimensionsfreiheit sein zweiter Vorzug, und in der Praxis oft der wichtigere: Indikatorfunktionen (ist der Patient abgewiesen?), Maxima (ist die Option im Geld?), Schwellen (hat die Kette den Zustand erreicht?) sind alle unstetig. Für sie gibt es keine Regel mit hoher Ordnung, in keiner Dimension.*

Aufgabe 3.2 — Ein Integral aus Band 24

Der Erwartungsnutzen der Behandlung bei Frau B. sei ein Integral über die Verteilung

des Blutungsrisikos r (Beta-verteilt, Mittel 0,03) und der Schlaganfallwahrscheinlichkeit s (Beta, Mittel 0,02). Wie würde man es simulieren, und mit welchem Fehler?

Lösung

Schritt 1 — Der Schätzer

Ziehe n Paare (r_i, s_i), berechne je Paar den Nutzen $u_i = 1 - 0{,}30\, r_i - 0{,}60\, s_i$ (vereinfacht), mittle.

Schritt 2 — Die Streuung

Mit Streuungen 0,015 für r und 0,010 für s:

$$\sigma_u = \sqrt{0{,}30^2 \cdot 0{,}015^2 + 0{,}60^2 \cdot 0{,}010^2} = \sqrt{2{,}0 \cdot 10^{-5} + 3{,}6 \cdot 10^{-5}} = 0{,}0075$$

Schritt 3 — Die nötige Zahl

Der Gewinn durch Behandlung war 0,018; man will ihn auf $\pm 0{,}001$ genau:

$$n \geq \left(\frac{1{,}96 \cdot 0{,}0075}{0{,}001} \right)^2 \approx 216$$

Zweihundert Ziehungen genügen — weil der Integrand linear ist und der Zufall nur zwei Dimensionen hat.

Band 24 hat genau das getan und es „probabilistische Empfindlichkeitsanalyse" genannt. *Die Zahl wächst, sobald der Nutzen nichtlinear wird — etwa bei einem Markow-Modell über zwanzig Jahre, dessen Ergebnis ein Produkt aus hunderten Übergängen ist. Dann steigt σ_u, und n geht in die Tausende. Das ist der Normalfall der Gesundheitsökonomie, und er ist der Grund, warum Kapitel 5 die Varianz senkt, statt n zu erhöhen.*

Aufgabe 3.3 — Die Varianz reparieren

Zeigen Sie, dass $\int_0^1 x^{-1/2} \mathrm{d}x$ durch Monte Carlo mit unendlicher Varianz geschätzt wird, und reparieren Sie es.

Lösung

Schritt 1 — Die Varianz

$$\mathbb{E}\left[g(U)^2\right] = \int_0^1 x^{-1}\, \mathrm{d}x = \infty$$

Schritt 2 — Was man beobachtet

Mit $n = 10\,000$ Ziehungen: Mittel 1,98, geschätzter Standardfehler 0,03 — scheinbar brauchbar. Dann kommt eine Ziehung mit $u = 10^{-7}$ und $g = 3162$; das Mittel springt auf 2,30, der Standardfehler auf 0,32.

Der Standardfehler ist nicht zu groß, sondern unberechenbar: Er hängt davon ab, ob der seltene Ausreißer schon gezogen wurde.

Schritt 3 — Die Substitution

$x = t^2$, $\mathrm{d}x = 2t\,\mathrm{d}t$:

$$\int_0^1 x^{-1/2}\,\mathrm{d}x = \int_0^1 \frac{2t}{t}\,\mathrm{d}t = \int_0^1 2\,\mathrm{d}t$$

Der Integrand ist konstant; Monte Carlo liefert 2 mit Varianz null.

Schritt 4 — Die allgemeine Regel

> ***Man zieht nicht gleichverteilt, sondern aus einer Dichte, die der Singularität folgt*** *— hier aus $2t$, was dasselbe ist wie x mit Dichte $\frac{1}{2}x^{-1/2}$. Das ist die Wichtigkeitsgewichtung aus Kapitel 6 in ihrer einfachsten Form, und die Lehre aus dem Bruchfall: Wo der Integrand explodiert, muss die Ziehungsdichte mit explodieren. Bevor man eine Simulation startet, prüft man das zweite Moment — auf dem Papier, nicht im Rechner, denn der Rechner zeigt es erst, wenn es zu spät ist.*

Der Fluch bekommt einen Namen

Richard Bellman prägte 1957 den Ausdruck “Fluch der Dimension” — in demselben Buch, das die dynamische Programmierung aus Band 24 begründete.

> *Er meinte damit, dass eine Wertfunktion über zehn Zustandsgrößen mit je hundert Stützstellen 10^{20} Werte braucht.* ***Die Einsicht, dass Zufallspunkte dem Fluch entgehen, war älter****:* ***Metropolis*** *und* ***Ulam*** *schrieben 1949 im ersten veröffentlichten Aufsatz über die Monte-Carlo-Methode, der Vorzug liege gerade bei Integralen hoher Dimension — und nannten als Beispiel die Boltzmann-Gleichung in sechs.*

Und die Bayessche Statistik

> *Die Bayessche Statistik aus Band 17 war bis 1990 auf Modelle mit wenigen Parametern beschränkt — weil das Integral im Nenner nicht zu berechnen war.* ***Als Gelfand und Smith 1990 zeigten, dass Markow-Ketten das Integral umgehen****, änderte sich das Fach innerhalb von fünf Jahren. Kapitel 7 und 8 dieses Bandes behandeln das Verfahren; dass es nötig war, folgt aus Satz 3.1.*

Hochdimensionale Integration heute

Dünne Gitter	Produktregeln, bei denen man die meisten Punkte weglässt — bis etwa $d = 50$.
Quasi-Monte-Carlo	Punktfolgen mit Fehler n^{-1} statt $n^{-1/2}$ — Kapitel 6.
Effektive Dimension	Warum Integrale in 10^6 Dimensionen oft so leicht sind wie in zehn.

Zur dritten Zeile

Ein Pfadintegral über 10^6 Zeitschritte ist formal 10^6-dimensional — aber der Integrand hängt meist nur von wenigen Kombinationen ab: dem Endwert, dem Maximum, dem Mittel. ***Die effektive Dimension ist die Zahl der Richtungen, auf die es ankommt****, und sie liegt oft unter zehn. Das erklärt, warum die Simulationen aus Band 25 so gut funktionierten, und es ist der Grund, warum man den Fluch in der Praxis seltener spürt, als Satz 3.1 befürchten lässt.*

Was Sie jetzt können

Die Umdeutung	Integral = Erwartungswert
Satz 3.1	$n^{-2/d}$ gegen $n^{-1/2}$, Gleichstand $d = 4$
Seltene Treffer	relativer Fehler $\sqrt{1/(np)}$
Der Bruchfall	zweites Moment vorher prüfen
Glattheit	nicht nötig — nur Varianz

Damit endet Teil I. Der Zufall ist erzeugt, die Methode begründet, ihr Fehler bekannt. Teil II fragt, wie man diesen Fehler kleiner macht — erst durch richtiges Messen, dann durch Tricks, die den Zufall gegen sich selbst ausspielen.

Teil II

Genauer werden

Kapitel 4

Den Fehler richtig messen

4.1 Der naive Standardfehler

Eine Simulation, fünftausend Tage

12 096 Ankünfte, Abweisungsanteil 0,1784. Nach Band 17 wäre der Standardfehler

$$\frac{\sqrt{p(1-p)}}{\sqrt{n}} = \frac{0{,}383}{\sqrt{12\,096}} = 0{,}0035.$$

Er ist falsch — um fast das Doppelte. Die Ankünfte sind nicht unabhängig.

Die Autokorrelation der Abweisungen

Abstand	1	2	5	10
ρ_k	0,38	0,20	0,02	−0,00

Wird ein Patient abgewiesen, ist die Station voll — und beim nächsten ist sie es wahrscheinlich noch. *Die Abweisungen kommen in Häufungen. Das ist Satz 10.4 aus Band 26 in der Simulation: Die Varianz des Mittels ist um den Faktor $1 + 2\sum \rho_k$ größer als bei Unabhängigkeit.*

4.2 Drei Verfahren

Satz 4.1 — die Autokorrelationszeit

Für eine stationäre Folge mit Autokorrelationen ρ_k gilt

$$\operatorname{Var}[\bar{x}] \approx \frac{\sigma^2}{n}\,\tau, \qquad \tau = 1 + 2\sum_{k \geq 1} \rho_k .$$

τ heißt **integrierte Autokorrelationszeit**; n/τ ist die **wirksame Stichprobengröße**.

Beweis

Band 26, Satz 10.4. ■

Im Leitfall

$\tau \approx 2{,}5$, wirksames $n = 4\,800$, Standardfehler 0,0055.

> ***Die Schwierigkeit liegt in der Summe**: Sie läuft über alle Abstände, und die geschätzten ρ_k für große k sind reines Rauschen. Man bricht ab, sobald ρ_k unter null fällt oder bei $k \approx \sqrt{n}$ — beides Faustregeln. Die beiden folgenden Verfahren vermeiden die Schätzung von ρ_k ganz.*

Satz 4.2 — Blockmittel

Man teile die Folge in b Blöcke der Länge $m = n/b$ und bilde die Blockmittel $\bar{x}_1, \dots, \bar{x}_b$. Ist m groß gegen τ, so sind die Blockmittel nahezu unabhängig, und

$$\widehat{\mathrm{SE}} = \frac{s_{\mathrm{Block}}}{\sqrt{b}}$$

mit der Stichprobenstreuung s_{Block} der Blockmittel.

Der Gedanke

Zwei Blöcke, die weiter als τ auseinanderliegen, wissen nichts voneinander. Ihre Mittel sind damit unabhängige Beobachtungen, und Band 17 gilt wieder — nur mit b statt n. ■

Blöcke	Länge	Standardfehler
10	1 209	0,0071
50	241	0,0060
200	60	0,0057
naiv		0,0035

> ***Alle drei Blockungen liegen nahe beieinander und beim Doppelten des naiven Werts.** Zu wenige Blöcke machen die Streuungsschätzung selbst ungenau (zehn Werte); zu kurze Blöcke lassen Abhängigkeit über die Grenze (sechzig Ankünfte bei $\tau = 3$ ist noch gut). Zwischen zwanzig und hundert Blöcken ist die übliche Wahl, und der Vorzug des Verfahrens ist, dass es keine Annahme über die Form der Abhängigkeit braucht.*

Unabhängige Wiederholungen

Vierzig Läufe à tausend Tage, jeder mit eigenem Startwert:

$$\bar{p} = 0{,}1799, \qquad \mathrm{SE} = \frac{s}{\sqrt{40}} = 0{,}0020$$

Das sauberste Verfahren: Jeder Lauf ist eine Beobachtung, und Band 17 gilt ohne Einschränkung.

***Der Preis ist die Einschwingphase**: Jeder Lauf beginnt mit leerer Station, und vierzig Läufe haben vierzig Anfänge. Bei kurzen Läufen frisst das einen großen Teil der Daten — der nächste Abschnitt beziffert, wie viel. Die Blockmittel haben dieses Problem nur einmal.*

4.3 Der Anfang

Die Einschwingphase gemessen

1 500 Läufe, Abweisungsanteil nach Zeitfenster:

Tage	Anteil	Tage	Anteil
0–10	**0,101**	50–60	0,179
10–20	0,174	60–80	0,178
20–30	0,178	80–100	0,178
30–50	0,186	100–200	0,180

Die ersten zehn Tage liegen bei der Hälfte des Dauerwerts. Ab Tag zwanzig ist nichts mehr zu erkennen.

Die Regel

Messen	Den Verlauf über viele Läufe mitteln und ablesen, ab wann er flach ist — wie hier.
Faustregel	Mindestens das Fünffache der längsten Zeitskala im System verwerfen; hier $5 \cdot 4{,}8 = 24$ Tage.
Warm starten	Den Endzustand eines Laufs als Anfang des nächsten nehmen — dann gibt es nur eine Einschwingphase.

***Die Einschwingphase ist die Mischzeit der Markow-Kette aus Band 25, Kapitel 3** — und wie dort ist sie im Einzelfall schwer zu bestimmen, weil man nicht weiß, wie der Dauerzustand aussieht, bevor man ihn erreicht hat. Die Tabelle oben kostet 1 500 Läufe; in der Praxis genügen fünfzig, um die Größenordnung zu sehen. Was nicht genügt, ist Raten.*

4.4 Zwei Varianten vergleichen

Satz 4.3 — gemeinsame Zufallszahlen

Will man $\theta_A - \theta_B$ schätzen, so simuliere man beide Varianten mit denselben Zufallszahlen. Dann gilt

$$\operatorname{Var}[\hat\theta_A - \hat\theta_B] = \operatorname{Var}[\hat\theta_A] + \operatorname{Var}[\hat\theta_B] - 2\operatorname{Cov}[\hat\theta_A, \hat\theta_B],$$

und die Kovarianz ist positiv, wenn beide Varianten auf dieselben Zufallszahlen ähnlich reagieren.

Zwölf gegen dreizehn Betten, je 30 Läufe à 2 000 Tage

Zufallszahlen	Differenz	SE
unabhängig	0,0423	0,0020
gemeinsam	0,0423	**0,0003**
exakt (Erlang)	0,0422	

Dieselben Ankünfte, dieselben Verweildauern, nur ein Bett mehr: Der Fehler der Differenz fällt auf ein Siebtel — die Varianz auf ein Fünfundvierzigstel. Ohne eine einzige Rechnung mehr.

Das ist die wichtigste Regel dieses Kapitels und die am häufigsten verletzte. Wer zwei Stationsvarianten mit zwei verschiedenen Startwerten vergleicht, misst die Differenz plus den Unterschied zweier Zufallsfolgen. Mit gemeinsamen Zahlen misst er nur die Differenz. In der klinischen Forschung heißt derselbe Gedanke gepaarter Vergleich: Jeder Patient sein eigener Kontrollfall. Kapitel 5 treibt ihn weiter.

4.5 Der Bruchfall

Wenn der Fehler nicht normalverteilt ist

Seltene Ereignisse	Bei einem Anteil von 0,001 und zehn Treffern ist das Intervall $\pm 1{,}96$ SE falsch — es reicht unter null. Man braucht das Intervall aus Band 17, Kapitel 9, oder die Poisson-Verteilung.
Schwere Ränder	Ist die gemessene Größe eine Wartezeit oder ein Maximum, so bestimmen wenige extreme Läufe den Mittelwert; der zentrale Grenzwertsatz greift erst bei sehr großem n.
Quantile	Das 95-Prozent-Quantil der Wartezeit hat einen Standardfehler, der mit der Dichte am Quantil skaliert — und die ist dort klein.

Für alle drei Fälle ist der Bootstrap aus Band 17, Kapitel 12 die Rettung: *Man ziehe aus den Blockmitteln oder aus den unabhängigen Läufen mit Zurücklegen, berechne die Kennzahl, wiederhole. Das liefert ein Intervall ohne Normalverteilungsannahme — und kostet nur Rechenzeit, nicht Simulationszeit.*

4.6 Übungsaufgaben

Aufgabe 4.1 — Die Autokorrelationszeit berechnen

Aus den Werten $\rho_1 = 0{,}37$, $\rho_2 = 0{,}22$, $\rho_3 = 0{,}12$, $\rho_4 = 0{,}07$, $\rho_5 = 0{,}04$ und danach null: Wie groß ist τ, das wirksame n und der Standardfehler bei $n = 12\,018$ und $\sigma = 0{,}386$?

Lösung

Schritt 1 — τ

$$\tau = 1 + 2(0{,}37 + 0{,}22 + 0{,}12 + 0{,}07 + 0{,}04) = 1 + 2 \cdot 0{,}82 = 2{,}64$$

Schritt 2 — Wirksames n

$$\frac{12\,096}{2{,}64} = 4\,582$$

Schritt 3 — Standardfehler

$$\frac{0{,}383}{\sqrt{4\,582}} = 0{,}0057$$

Schritt 4 — Vergleich

Verfahren	SE
naiv	0,0035
Autokorrelationszeit	0,0057
Blockmittel (50)	0,0060

Die beiden richtigen Verfahren unterscheiden sich um ein Zehntel, vom falschen um fast das Doppelte. *Die Abweichung zwischen ihnen ist die Unsicherheit der Schätzung des Standardfehlers selbst — die bei fünfzig Blöcken etwa zehn Prozent beträgt. Mehr Genauigkeit im Fehlerbalken braucht niemand; die Genauigkeit in der Zahl selbst ist das Ziel.*

Aufgabe 4.2 — Wie lange einschwingen lassen?

Die mittlere Verweildauer sei nun 12 Tage statt 4,8, bei gleicher Auslastung. Wie ändert sich die Einschwingphase, und was folgt für die Planung der Läufe?

Lösung

Schritt 1 — Die Zeitskala

Die Station vergisst ihren Anfangszustand mit der Verweildauer. Faustregel: fünffache Dauer.

$$5 \cdot 12 = 60 \text{ Tage statt } 24$$

Schritt 2 — Die Folge für unabhängige Wiederholungen

Bei Läufen von 200 Tagen:

Verweildauer	verworfen	nutzbar
4,8 Tage	24	88 %
12 Tage	60	70 %

Schritt 3 — Und die Autokorrelation

Längere Verweildauern heißen längeres Gedächtnis: τ wächst, das wirksame n schrumpft — bei gleicher Lauflänge wird die Schätzung ungenauer.

Deshalb wählt man bei trägen Systemen wenige lange Läufe statt vieler kurzer: *Ein Lauf von 8 000 Tagen hat eine Einschwingphase, vierzig Läufe von 200 Tagen haben vierzig. Für die Streuung nimmt man dann Blockmittel. Die Regel ist dieselbe wie bei Markow-Ketten-Verfahren in Kapitel 8, wo sie noch mehr Gewicht hat.*

Aufgabe 4.3 — Gemeinsame Zufallszahlen richtig einsetzen

Ein Kollege simuliert zwölf und dreizehn Betten mit demselben Startwert, findet aber keine Varianzsenkung. Was ist vermutlich falsch?

Lösung

Schritt 1 — Die Bedingung

Gemeinsame Zufallszahlen wirken nur, wenn *dieselbe* Zufallszahl in beiden Varianten *dasselbe* bedeutet — die k-te Ankunftszeit, die k-te Verweildauer.

Schritt 2 — Der häufigste Fehler

Ein einziger Zahlenstrom für alles: Erst die Ankunft, dann — falls ein Bett frei ist — die Verweildauer. Bei dreizehn Betten wird öfter eine Verweildauer gezogen, und ab der ersten Abweichung ist die Zuordnung verschoben: Die Zahl, die bei zwölf Betten eine Ankunft war, ist bei dreizehn eine Verweildauer.

> **Die Zahlen sind gemeinsam, aber nicht synchron. Die Kovarianz verschwindet.**

Schritt 3 — Die Abhilfe

Getrennte Ströme	Ein Generator für Ankünfte, einer für Verweildauern, je mit eigenem Startwert.
Immer ziehen	Die Verweildauer jedes Patienten ziehen, auch wenn er abgewiesen wird — und verwerfen.
Inversion	Nur Verfahren mit fester Zahl von Zufallszahlen je Ziehung; Verwerfung bricht die Synchronität.

> ***Die dritte Zeile ist der Grund, warum Kapitel 2 die Inversion bevorzugt hat.*** *Box-Muller braucht zwei Zahlen je Paar, immer; die Verwerfung braucht mal eine, mal fünf. Wer Varianten vergleichen will, baut die Simulation von Anfang an so, dass jede Zufallszahl eine feste Rolle hat — das ist Entwurf, nicht Nachbesserung.*

Die Statistik der Simulation

Die ersten Simulationen der 1940er Jahre berichteten Zahlen ohne Fehler; die Frage, wie genau sie waren, galt als nachrangig.

> ***George Fishman*** *schrieb 1973 das erste Lehrbuch, das die Simulation als statistisches Experiment behandelte — Einschwingphase, Autokorrelation, Blockmittel.* ***Die Blockmethode selbst stammt von Conway aus dem Jahr 1963****, der Warteschlangen für die Fertigung simulierte und bemerkte, dass seine Vertrauensintervalle systematisch zu eng waren.*

Gemeinsame Zufallszahlen

Der Gedanke ist so alt wie die Methode: ***Kahn*** *und* ***Marshall*** *beschrieben ihn 1953 in einem Bericht der RAND Corporation.* ***Dass er in der Praxis so oft versäumt wird, liegt an der Bequemlichkeit****: Ein einziger Zahlenstrom ist einfacher zu programmieren als drei synchronisierte.* ***Law*** *und* ***Kelton****, deren Lehrbuch seit 1982 das Fach bestimmt, widmen dem Fehler aus Aufgabe 4.3 ein ganzes Kapitel.*

Fehlerkontrolle heute

Folgeverfahren	Simulieren, bis das Intervall eine vorgegebene Breite hat — mit den Martingalen aus Band 25.
Mehrere Ausgaben	Gemeinsame Intervalle für Abweisungsrate, Wartezeit und Auslastung zugleich.
Automatische Einschwingerkennung	Verfahren, die den Verwerfungspunkt aus den Daten bestimmen.

Zur ersten Zeile

Wer „simuliert, bis es signifikant ist", begeht den Fehler aus Band 17, Kapitel 12 — außer, das Abbruchkriterium ist ein Martingal. ***Die sequenziellen Verfahren aus Band 25, Kapitel 9 erlauben genau das****: eine Breite vorgeben, laufen lassen, abbrechen, wenn sie erreicht ist, und das Intervall bleibt gültig. Für Simulationen, bei denen jeder Lauf Stunden kostet, ist das der Unterschied zwischen machbar und nicht.*

Was Sie jetzt können

Satz 4.1	$\tau = 1 + 2\sum \rho_k$, wirksames n/τ
Satz 4.2	Blockmittel: keine Annahme über die Form
Einschwingen	messen, fünffache Zeitskala verwerfen
Satz 4.3	gemeinsame Zahlen für Differenzen
Der Bruchfall	Bootstrap, wenn nicht normal

Satz 4.3 hat gezeigt, dass man denselben Zufall zweimal benutzen kann, um Fehler zu senken. Das nächste Kapitel macht daraus ein Prinzip — und drückt die Varianz um Faktoren, die mehr Läufe nie erreichen würden.

Kapitel 5

Weniger Streuung ohne mehr Läufe

5.1 Das Prinzip

Zwei Wege zu mehr Genauigkeit

Nach Satz 1.2 ist der Fehler $\sigma/\sqrt{n}$. Es gibt genau zwei Stellschrauben:

n **erhöhen**	Viermal so viele Läufe für die halbe Breite. Teuer, aber ohne Nachdenken.
σ **senken**	Denselben Erwartungswert durch eine andere Zufallsgröße mit kleinerer Varianz schätzen. Billig, aber es braucht einen Einfall.

Dieses Kapitel ist die Sammlung der Einfälle. Jeder ersetzt Y durch ein Y' mit $\mathbb{E}[Y'] = \mathbb{E}[Y]$ und $\mathrm{Var}[Y'] < \mathrm{Var}[Y]$.

Eine Varianzsenkung um den Faktor 30 *entspricht dreißigmal so vielen Läufen — die Tabelle in Abschnitt 5.2 wird sie liefern, für eine Zeile mehr Programmtext. Die Verfahren heißen* ***Varianzreduktion****, und sie sind der Grund, warum erfahrene Simulierer mit tausend Läufen genauer sind als Anfänger mit einer Million.*

5.2 Antithetische Variablen

Satz 5.1 — antithetische Paare

Sei $Y = g(U)$ mit U gleichverteilt auf $[0,1]$ und g monoton. Dann hat

$$Y' = \frac{g(U) + g(1-U)}{2}$$

denselben Erwartungswert wie Y, und

$$\mathrm{Var}[Y'] = \frac{\mathrm{Var}[Y]}{2}\,(1+\rho), \qquad \rho = \mathrm{Corr}[g(U), g(1-U)] \le 0.$$

Beweis
$1-U$ ist ebenfalls gleichverteilt, also $\mathbb{E}[g(1-U)] = \mathbb{E}[g(U)]$. Die Varianz des Mittels zweier Größen mit gleicher Varianz σ^2 und Korrelation ρ ist $\sigma^2(1+\rho)/2$ (Band 17, Kapitel 5). Ist g monoton, so ist $g(1-U)$ groß, wenn $g(U)$ klein ist, und $\rho \le 0$ — das ist die Ungleichung von **Chebyshev** für gleichsinnig geordnete Funktionen, Band 15, Kapitel 4. ■

Der Vergleich bei gleichem Aufwand

Ein antithetisches Paar kostet zwei Auswertungen, also vergleicht man $n/2$ Paare mit n Einzelwerten:

$$\frac{\operatorname{Var}[\bar{Y}']}{\operatorname{Var}[\bar{Y}]} = 1 + \rho$$

Beispiel $\int_0^1 e^x\,dx$, $n = 10\,000$

Verfahren	SE	Varianzfaktor
naiv	0,0048	1
antithetisch	0,0009	**31**

Die Korrelation von e^U und e^{1-U} beträgt $-0{,}968$; $1+\rho = 0{,}032 \approx 1/31$.

> ***Das funktioniert, weil e^x nahezu linear ist:*** *Für eine exakt lineare Funktion wäre $\rho = -1$ und die Varianz null — das Paar träfe den Mittelwert immer genau. Je krummer g, desto schwächer die Wirkung; für $g(u) = (u-\tfrac12)^2$ ist $g(U) = g(1-U)$, $\rho = +1$, und das Verfahren verdoppelt die Varianz. Monotonie ist die Bedingung, nicht die Garantie.*

5.3 Kontrollvariablen

Satz 5.2 — Kontrollvariable

Sei C eine Zufallsgröße mit bekanntem Erwartungswert $\mathbb{E}[C] = c$, die in derselben Simulation anfällt. Dann hat für jedes β

$$Y' = Y - \beta\,(C - c)$$

den Erwartungswert $\mathbb{E}[Y]$, und die Varianz ist minimal für

$$\beta^* = \frac{\operatorname{Cov}[Y,C]}{\operatorname{Var}[C]}, \qquad \operatorname{Var}[Y'] = \operatorname{Var}[Y]\,(1-\rho_{YC}^2).$$

Beweis
$\mathbb{E}[C-c] = 0$ erledigt den Erwartungswert. Die Varianz $\operatorname{Var}[Y] - 2\beta\operatorname{Cov}[Y,C] + \beta^2\operatorname{Var}[C]$ ist eine Parabel in β mit Scheitel bei β^*; Einsetzen gibt den Rest. ■

Das ist die Regression aus Band 26: Y auf C regressieren, und den Teil von Y behalten, den C nicht erklärt.

Wo die Kontrollvariable herkommt

Die Eingabe selbst	U mit $\mathbb{E}[U] = \frac{1}{2}$; beim Integral $\int e^x$ ist $\rho = 0{,}992$, Varianzfaktor 56.
Eine Zählgröße	Die Zahl der Ankünfte, Erwartungswert λT.
Ein Mittelwert	Die mittlere gezogene Verweildauer, Erwartungswert 4,79.
Ein einfacheres Modell	Die Abweisungsrate desselben Laufs mit exponentieller statt lognormaler Verweildauer, Erlang-exakt.

Die Intensivstation, 200 Läufe à 1 000 Tage

Kontrolle	ρ	Streuung	Faktor
keine		0,0132	1
Zahl der Ankünfte	0,72	0,0092	2,1
mittlere Verweildauer	0,52	0,0112	1,4
beide		**0,0059**	**5,0**

Ein Lauf mit zufällig vielen Ankünften weist zufällig viele Patienten ab — das ist Rauschen, das man kennt, und was man kennt, kann man abziehen. *Beide Kontrollen zusammen halbieren den Fehler und ersetzen damit 800 weitere Läufe. Das β^* wird aus denselben Läufen geschätzt; das macht Y' um eine Größenordnung $1/n$ verzerrt, was bei 200 Läufen niemand merkt.*

5.4 Konditionierung

Satz 5.3 — bedingter Erwartungswert als Schätzer

Für jede Zufallsgröße Z gilt

$$\mathbb{E}\big[\mathbb{E}[Y \mid Z]\big] = \mathbb{E}[Y], \qquad \operatorname{Var}\big[\mathbb{E}[Y \mid Z]\big] \le \operatorname{Var}[Y].$$

Kann man $\mathbb{E}[Y \mid Z]$ ausrechnen, so simuliere man nur Z und mittle die Formel.

Beweis
Turmregel und Varianzzerlegung aus Band 25, Kapitel 2: $\mathrm{Var}[Y] = \mathrm{Var}[\mathbb{E}[Y|Z]] + \mathbb{E}[\mathrm{Var}[Y|Z]]$, und der zweite Summand ist nicht negativ. ■

Beispiel: $P(X+Y>4)$ für unabhängige $X, Y \sim \mathrm{Exp}(1)$
Statt beide zu ziehen und zu zählen, ziehe man nur X und mittle

$$P(Y > 4 - X \mid X) = e^{-(4-X)^+}.$$

Verfahren	Schätzung	SE	Faktor
zählen	0,0917	0,0027	1
konditionieren	0,0916	0,0016	2,9
exakt $5e^{-4}$	0,0916		

Der Zähler liefert nur Nullen und Einsen; der Konditionierer liefert für jedes X eine Wahrscheinlichkeit zwischen beiden. *Ein glatter Wert streut weniger als ein Indikator — das ist der ganze Trick. In der Intensivstation heißt das: Statt zu zählen, wen man abweist, notiere man bei jeder Ankunft, ob die Station voll ist. Es ist derselbe Schätzer. Aber wer die Belegung zu jedem Zeitpunkt kennt, kann die Abweisungswahrscheinlichkeit als Zeitanteil "Station voll" schätzen — das nutzt die Zeit zwischen den Ankünften mit, die der Zähler verschenkt.*

5.5 Was zusammen wirkt

Die vier Verfahren und ihre Bedingungen

Verfahren	braucht	versagt bei
gemeinsame Zahlen	Synchronität	Verwerfung, Verzweigung
antithetisch	Monotonie	symmetrischem g
Kontrollvariable	bekanntes $\mathbb{E}[C]$	$\rho \approx 0$
Konditionierung	Formel für $\mathbb{E}[Y\|Z]$	keiner — nur Rechenarbeit

Die Verfahren lassen sich kombinieren, aber nicht beliebig. *Antithetische Paare und gemeinsame Zahlen vertragen sich; Kontrollvariablen passen zu allem; Konditionierung ändert, was simuliert wird, und muss zuerst kommen. Was in diesem Kapitel fehlt, ist das stärkste Verfahren von allen, das Wichtigkeitsstichprobe heißt und Kapitel 6 ganz gehört — weil es auch das gefährlichste ist.*

5.6 Der Bruchfall

Wenn die Reduktion die Varianz erhöht

Antithetisch bei $g(u) = \lvert u - \frac{1}{2} \rvert$	$g(U) = g(1-U)$: Jedes Paar besteht aus zwei gleichen Werten, $\rho = 1$, Varianz verdoppelt bei gleichem Aufwand.
Kontrolle mit geschätztem c	Wer $\mathbb{E}[C]$ nicht kennt und es aus denselben Läufen schätzt, zieht $\beta(C - \bar{C}) = 0$ ab — es passiert nichts. Wer es aus einer kleinen Vorsimulation nimmt, addiert deren Fehler.
Falsches β	Jedes β mit $0 < \beta < 2\beta^*$ senkt die Varianz; jedes andere erhöht sie. Ein Vorzeichenfehler verdoppelt sie.

Kein Verfahren dieses Kapitels verfälscht den Erwartungswert *— das ist ihre Sicherheit: Im schlimmsten Fall wird die Schätzung ungenauer, nie falsch. Man prüfe die Wirkung immer, indem man die Streuung mit und ohne Verfahren misst. Eine Varianzreduktion, deren Faktor man nicht gemessen hat, ist eine Vermutung.*

5.7 Übungsaufgaben

Aufgabe 5.1 — Antithetisch bei einer Wartezeit

Die Verweildauer wird durch Inversion $L = F^{-1}(U)$ erzeugt. Warum erzeugt $F^{-1}(1 - U)$ ein antithetisches Gegenstück, und was passiert, wenn die Abweisungsrate als Funktion der Verweildauern nicht monoton ist?

Lösung

Schritt 1 — Monotonie der Inversion

F^{-1} ist monoton wachsend, also ist $F^{-1}(1 - U)$ klein, wenn $F^{-1}(U)$ groß ist: Dem Lauf mit langen Verweildauern steht ein Lauf mit kurzen gegenüber.

Schritt 2 — Die Abweisungsrate

Mehr Verweildauer heißt mehr Abweisungen, bei jeder einzelnen Verweildauer und damit in der Summe. Die Abbildung von den U auf die Abweisungsrate ist monoton in jedem Argument.

Also sind die beiden Läufe negativ korreliert, und Satz 5.1 gilt — mehrdimensional, mit derselben Begründung.

Schritt 3 — Wenn die Monotonie bricht

Nimmt man auch die Ankunftszeiten antithetisch, so ist die Wirkung unklar: Eine frühe Ankunft kann die Abweisungen erhöhen (Station voll) oder nicht (Station leer). Für Zwischenankunftszeiten gilt die Monotonie zwar auch — längere Abstände, weniger Abweisungen — aber die Korrelation ist schwach, weil die Abweisung von der Reihenfolge abhängt, nicht nur von den Werten.

> ***Deshalb wendet man das Verfahren auf die Zahlen an, deren Wirkung man versteht, und misst den Faktor.*** *Für die Verweildauern allein liegt er bei etwa 1,3; mit den Ankünften zusammen kaum höher. Die 31 vom Integral sind ein Sonderfall glatter Funktionen; bei ereignisgetriebenen Systemen sind Faktoren um 1,5 schon gut.*

Aufgabe 5.2 — Das optimale β nachrechnen

Für $Y = e^U$ und $C = U$: Berechnen Sie β^* und den Varianzfaktor exakt.

Lösung

Schritt 1 — Die Momente

$$\mathbb{E}[U] = \tfrac{1}{2}, \quad \mathrm{Var}[U] = \tfrac{1}{12}, \quad \mathbb{E}[e^U] = e - 1, \quad \mathbb{E}[e^{2U}] = \tfrac{e^2-1}{2}$$

$$\mathrm{Var}[e^U] = \tfrac{e^2-1}{2} - (e-1)^2 = 0{,}2420$$

Schritt 2 — Die Kovarianz

$$\mathbb{E}[Ue^U] = \int_0^1 ue^u \, du = [ue^u - e^u]_0^1 = 1$$

$$\mathrm{Cov}[e^U, U] = 1 - \tfrac{1}{2}(e-1) = 0{,}1409$$

Schritt 3 — β^* und ρ

$$\beta^* = \frac{0{,}1409}{1/12} = 1{,}691, \qquad \rho = \frac{0{,}1409}{\sqrt{0{,}2420 \cdot 1/12}} = 0{,}9918$$

Schritt 4 — Der Faktor

$$\frac{1}{1-\rho^2} = \frac{1}{1-0{,}9837} = 61$$

Die Simulation in Abschnitt 5.3 gab 56 — der Unterschied ist die Unsicherheit eines geschätzten Varianzverhältnisses aus 200 Wiederholungen.

> *$\beta^* = 1{,}69$* ***ist nahe an*** *$e - 1 = 1{,}72$****, der mittleren Steigung von*** *e^x — die Kontrollvariable zieht die lineare Näherung ab und lässt nur die Krümmung als Rauschen übrig. Das ist allgemein: Je besser eine lineare Funktion von C das Y trifft, desto größer der Faktor. Die Kontrollvariable ist die Taylor-Entwicklung ersten Grades, als Schätzer verkleidet.*

Aufgabe 5.3 — Alles zusammen

Für den Vergleich zwölf gegen dreizehn Betten standen drei Verfahren zur Wahl: gemeinsame Zufallszahlen (Faktor 45), Kontrolle durch beide Zählgrößen (Faktor 5,0), Konditionierung auf die Belegung. Wie würden Sie vorgehen, und welchen Faktor erwarten Sie?

Lösung

Schritt 1 — Die Reihenfolge

1	Konditionierung: Zeitanteil "voll" statt Zählung — ändert den Schätzer.
2	Gemeinsame Zufallszahlen mit getrennten Strömen für beide Varianten.
3	Kontrollvariablen auf die Differenz anwenden, nicht auf jede Variante einzeln.

Schritt 2 — Warum auf die Differenz

Die Zahl der Ankünfte ist in beiden Varianten dieselbe — gemeinsame Zahlen. Ihre Wirkung auf die Abweisungen ist in beiden fast gleich und kürzt sich in der Differenz weitgehend heraus. Was bleibt, ist der Teil, der gerade nicht gleich ist, und der korreliert schwächer mit C.

> **Die Faktoren multiplizieren sich nicht. Gemeinsame Zahlen und Kontrollvariablen entfernen zum Teil dasselbe Rauschen.**

Schritt 3 — Die Erwartung

Gemeinsame Zahlen 45; Kontrollen auf die Differenz vielleicht noch 1,5; Konditionierung 1,3. Zusammen etwa 60 bis 80 — gemessen, nicht gerechnet.

> ***Ein Faktor*** 60 ***bedeutet:*** 30 ***Läufe leisten, was sonst*** 1 800 ***leisten würden.*** *Bei einem Modell, das in Sekunden läuft, ist das Bequemlichkeit. Bei einem Modell, in dem ein Lauf eine Stunde dauert, weil es ein ganzes Krankenhaus mit Operationssälen, Notaufnahme und Normalstationen abbildet, ist es der Unterschied zwischen einer Antwort heute und einer nächste Woche.*

Die Erfinder der Varianzreduktion

Die Verfahren sind fast so alt wie die Methode, und sie stammen aus derselben Werkstatt.

> ***Herman Kahn****, später als Stratege des Kalten Krieges bekannt, schrieb 1949 bei RAND den ersten Bericht über Varianzreduktion bei Neutronentransport — Kontrollvariablen und gemeinsame Zahlen stehen schon darin.* ***Die antithetischen Variablen erfand Hammersley 1956 in Oxford****, zusammen mit* ***Morton****; ihr Buch mit* ***Handscomb*** *von 1964 ist die erste Monographie des Fachs und noch heute lesbar.*

Der Name

"Antithetisch" — gegensätzlich — wählte Hammersley, weil das zweite Element eines Paars dem ersten entgegenläuft. ***Die Idee, Konditionierung als Schätzer zu nutzen, heißt in der Literatur Rao-Blackwellisierung****, nach einem Satz aus Band 17 über die Verbesserung von Schätzern durch suffiziente Statistiken;* ***Casella*** *und* ***Robert*** *prägten die Anwendung auf Simulation 1996.*

Varianzreduktion heute

Mehrebenen-Monte-Carlo	Grobes Modell oft, feines Modell selten, Differenzen als Kontrolle — Kapitel 9.
Gelernte Kontrollen	Ein neuronales Netz als Kontrollvariable, trainiert auf dieselben Läufe.
Quasi-Monte-Carlo	Gar keine Zufallszahlen, sondern gleichmäßig gestreute Punkte — Kapitel 6.

Zur ersten Zeile

Das Mehrebenen-Verfahren von Giles aus dem Jahr 2008 ist die wichtigste Neuerung des Fachs seit Jahrzehnten*: Es nimmt Satz 5.2 und wendet ihn rekursiv an — das grobe Modell kontrolliert das feine, ein noch gröberes das grobe. Für stochastische Differentialgleichungen aus Band 25 senkt es die Kosten um Größenordnungen; Kapitel 9 rechnet es vor.*

Was Sie jetzt können

Satz 5.1	antithetisch: Faktor $1/(1+\rho)$ bei Monotonie
Satz 5.2	Kontrollvariable: Faktor $1/(1-\rho^2)$
Satz 5.3	Konditionierung: nie schlechter
Die Regel	Faktor immer messen
Der Bruchfall	Symmetrie, geschätztes c, falsches β

> *Alle Verfahren dieses Kapitels haben eines gemeinsam: Sie ziehen aus der richtigen Verteilung. Das nächste Kapitel zieht aus einer falschen — absichtlich — und gewinnt damit Faktoren von einer Million. Oder verliert alles.*

Kapitel 6

Dort ziehen, wo etwas passiert

6.1 Das Problem der seltenen Treffer

Wie oft kommt es ganz schlimm?

Aus 400 000 simulierten Tagen der Intensivstation:

Abweisungen am Tag	Anteil	etwa alle
≥ 1	0,235	4 Tage
≥ 3	0,050	20 Tage
≥ 5	0,0068	5 Monate
≥ 7	0,00057	5 Jahre

Für die letzte Zeile gab es 226 Treffer — noch genug. Für zehn Abweisungen am Tag gäbe es in 400 000 Tagen vielleicht einen. Für die Frage, ob so etwas einmal im Jahrhundert vorkommt, versagt das Zählen.

Das Gesetz der seltenen Treffer

Für einen Anteil p ist der relative Fehler $\sqrt{(1-p)/(np)}$. Zehn Prozent Genauigkeit brauchen $n \approx 100/p$ Läufe:

$$p = 10^{-3} : \; 10^{5}, \qquad p = 10^{-6} : \; 10^{8}, \qquad p = 10^{-9} : \; 10^{11}.$$

Das Jahrhundertereignis braucht hundert Jahrhunderte Simulation. *Für Reaktorsicherheit, Versicherungsrisiken, Bitfehler in Übertragungen und Nebenwirkungen bei einem von einer Million Patienten ist das die Normalsituation. Der Ausweg ist in Kapitel 3 schon angeklungen: nicht aus der richtigen Verteilung ziehen, sondern aus einer, die das seltene Ereignis häufig macht — und den Betrug nachträglich verrechnen.*

6.2 Die Wichtigkeitsstichprobe

Definition 6.1 — Wichtigkeitsgewicht

Sei $\theta = \mathbb{E}_f[h(X)] = \int h(x) f(x)\,dx$ gesucht, und sei g eine Dichte mit $g(x) > 0$ überall dort, wo $h(x)f(x) \neq 0$. Dann ist

$$\theta = \int h(x)\,\frac{f(x)}{g(x)}\,g(x)\,dx = \mathbb{E}_g\big[h(X)\,w(X)\big], \qquad w(x) = \frac{f(x)}{g(x)}.$$

Man ziehe $X_1, \dots, X_n$ aus g und schätze $\hat\theta = \frac{1}{n}\sum h(X_i)\,w(X_i)$. g heißt **Vorschlagsdichte**, w das **Wichtigkeitsgewicht**.

Satz 6.2 — Erwartungstreue und Varianz

$\hat\theta$ ist erwartungstreu, und

$$\operatorname{Var}_g[h\,w] = \int \frac{h(x)^2 f(x)^2}{g(x)}\,dx - \theta^2.$$

Die Varianz ist null für $g^*(x) = |h(x)|f(x)/\int |h|f$; für $h \geq 0$ ist das $g^* = hf/\theta$.

Beweis

Erwartungstreue ist die Umformung in Definition 6.1. Die Varianz ist $\mathbb{E}_g[(hw)^2] - \theta^2$ mit $(hw)^2 g = h^2 f^2 / g$. Einsetzen von g^* gibt $\int h^2 f^2 \theta/(hf) = \theta \int hf = \theta^2$, also Varianz null. ■

> **Die beste Vorschlagsdichte ist der Integrand selbst. Man kennt sie nicht — sie enthält θ — aber man weiß jetzt, wie sie aussehen soll: wie $h \cdot f$, groß, wo das Produkt groß ist.**
>
> ***Für ein seltenes Ereignis $h = \mathbf{1}_A$ heißt das: g soll auf A konzentriert sein und dort wie f aussehen.*** *Jede Ziehung außerhalb A ist verschenkt, jede Ziehung in A zählt mit dem Gewicht f/g, das klein ist, weil g dort groß ist — viele kleine Beiträge statt seltener großer. Das ist das Prinzip; der Rest ist die Wahl von g.*

6.3 Die Verschiebung

$P(Z > 4)$ für die Standardnormalverteilung

Exakt: $3{,}167 \cdot 10^{-5}$ — einer von 32 000. Naiv mit $n = 100\,000$: im Mittel drei Treffer, relativer Fehler 57 %.

Der Vorschlag
Man ziehe aus $N(\mu, 1)$ statt $N(0, 1)$. Das Gewicht ist

$$w(x) = \frac{\varphi(x)}{\varphi(x-\mu)} = \exp\Big(-\mu x + \frac{\mu^2}{2}\Big),$$

und der Schätzer $\frac{1}{n}\sum \mathbf{1}\{X_i > 4\}\, w(X_i)$.

Das Ergebnis, $n = 100\,000$, hundert Wiederholungen

μ	Schätzung	rel. Fehler	Varianzfaktor
0 (naiv)	$2{,}8 \cdot 10^{-5}$	57 %	1
2	$3{,}171 \cdot 10^{-5}$	2,4 %	550
4	$3{,}167 \cdot 10^{-5}$	**0,7 %**	**6 700**
6	$3{,}158 \cdot 10^{-5}$	1,9 %	900
8	$3{,}13 \cdot 10^{-5}$	30 %	3

Die Verschiebung auf die Schwelle gibt einen Faktor von fast siebentausend — mit 1 000 Ziehungen ist man so genau wie naiv mit sieben Millionen.

***Und die letzte Zeile ist die Warnung**: Zu weit verschoben, und die Hälfte der Ziehungen liegt weit jenseits der Schwelle mit winzigem Gewicht, während die wenigen nahe der Schwelle riesige Gewichte tragen. Die Varianz steigt wieder; bei $\mu = 8$ ist fast nichts gewonnen. **Die Faustregel heißt: g so wählen, dass der Modus von g dort liegt, wo hf seinen Modus hat** — bei einer Schwelle also auf der Schwelle. Die exakte Rechnung steht in Aufgabe 6.1.*

Die wirksame Stichprobengröße

Ein Maß für die Qualität der Gewichte:

$$n_{\text{eff}} = \frac{\big(\sum w_i\big)^2}{\sum w_i^2}.$$

Sind alle Gewichte gleich, ist $n_{\text{eff}} = n$; trägt ein Gewicht alles, ist $n_{\text{eff}} = 1$.

Vorschlag	n	n_{eff}
$N(4, 1)$, Gewichte auf A	100 000	18 000

Ein Fünftel — und das bei der besten Verschiebung. *Die andere Hälfte der Ziehungen liegt unter der Schwelle mit Gewicht null, und die darüber tragen ungleiche Gewichte. n_{eff} ist die erste Zahl, die man nach jeder Wichtigkeitsstichprobe ansieht: Fällt sie unter ein Prozent von n, so stimmt die Vorschlagsdichte nicht, und die Schätzung ist nicht zu trauen — auch wenn ihr Standardfehler klein aussieht. Warum er trügen kann, zeigt der Bruchfall.*

6.4 Quasi-Monte-Carlo

Gleichmäßiger als Zufall

Zufallspunkte in $[0,1]^d$ bilden Haufen und Lücken — das ist der Grund für den Fehler $n^{-1/2}$. Eine **Folge niedriger Diskrepanz** füllt den Würfel absichtlich gleichmäßig: Jedes achsenparallele Teilrechteck enthält fast genau den Anteil der Punkte, der seinem Volumen entspricht.

Satz 6.3 — Koksma–Hlawka
Für eine Punktmenge P mit Sterndiskrepanz $D_n^*(P)$ und eine Funktion h mit beschränkter Variation $V(h)$ im Sinne von Hardy und Krause gilt

$$\left|\frac{1}{n}\sum_{i=1}^{n} h(x_i) - \int h\right| \le V(h)\, D_n^*(P).$$

Für die Folgen von **Sobol** und **Halton** ist $D_n^* = O\big((\log n)^d / n\big)$.

Beweis
Band 20, Kapitel 11 (Auslassung 2 für den mehrdimensionalen Fall). Die eindimensionale Fassung ist partielle Integration: $\frac{1}{n}\sum h(x_i) - \int h = -\int_0^1 \big(F_n(t) - t\big)\, dh(t)$ mit der empirischen Verteilungsfunktion F_n, und $\sup|F_n - t|$ ist die Diskrepanz. ■

Das Integral $\int_{[0,1]^d} e^{x_1+\cdots+x_d}\,dx/(e-1)^d = 1$, Fehler bei $n = 16\,384$

d	Monte Carlo	Sobol	Faktor
2	$3{,}6 \cdot 10^{-3}$	$1{,}5 \cdot 10^{-7}$	24 000
5	$6{,}3 \cdot 10^{-3}$	$8{,}5 \cdot 10^{-6}$	740
10	$1{,}1 \cdot 10^{-2}$	$2{,}7 \cdot 10^{-4}$	38
20	$1{,}3 \cdot 10^{-2}$	$3{,}2 \cdot 10^{-3}$	4

In zwei Dimensionen ist Sobol um das Zwanzigtausendfache genauer. In zwanzig immer noch um das Vierfache — der Faktor $(\log n)^d$ frisst den Vorteil langsam, aber er frisst ihn.

***Satz 6.3 ist eine Schranke, keine Fehlerschätzung**: $V(h)$ ist selten berechenbar, und $(\log n)^{20}/n$ ist für jedes erreichbare n größer als $n^{-1/2}$ — die Tabelle zeigt trotzdem einen Gewinn, weil die Schranke grob ist. Um einen Fehler mit Standardabweichung zu bekommen, verwirft man die Determiniertheit halb: Man **verwürfelt** die Folge zufällig (**Owen**, 1995), wiederholt das zwanzigmal und mittelt. Die Tabelle ist so entstanden. Für glatte Integranden in mäßiger Dimension — Preise von Finanzprodukten, Erwartungswerte über wenige Parameter — ist Quasi-Monte-Carlo heute Standard; für die Intensivstation mit ihren Tausenden von Zufallszahlen je Lauf ist es wirkungslos.*

6.5 Der Bruchfall

Die Vorschlagsdichte mit zu dünnen Rändern

Gesucht $\mathbb{E}[X^2] = 1$ für $X \sim N(0,1)$; vorgeschlagen $g = N(0,\ 0{,}6^2)$ — schmaler als f.

n	**Schätzung**	n_{eff}	**größtes Gewicht**
10^3	0,79	346	3,2 %
10^4	1,31	605	2,9 %
10^5	1,04	7 970	0,6 %
10^6	0,98	115 000	0,1 %

Was geschieht

$$\frac{f(x)^2}{g(x)} \propto \exp\Big(-x^2 + \frac{x^2}{2\cdot 0{,}36}\Big) = \exp\left(0{,}39\,x^2\right) \to \infty$$

Die Varianz des Schätzers ist unendlich. Der Mittelwert konvergiert — nach dem Gesetz der großen Zahlen — aber ohne Rate, und jeder geschätzte Standardfehler ist eine Lüge: Zwischen $n = 10^3$ und 10^4 wird die Schätzung schlechter.

***Die Regel: Die Vorschlagsdichte muss schwerere Ränder haben als f, nie leichtere.** Eine Normalverteilung als Vorschlag für eine Normalverteilung braucht eine größere Streuung; sicherer ist eine t-Verteilung, deren Ränder jede Normalverteilung überholen. Das zweite Moment $\int h^2 f^2/g$ ist auf dem Papier zu prüfen, bevor der Rechner läuft — derselbe Rat wie beim Bruchfall in Kapitel 3, und aus demselben Grund: Der Rechner zeigt eine unendliche Varianz nicht an. Er zeigt gelegentlich einen Sprung, und zwischen den Sprüngen sieht alles gut aus.*

6.6 Übungsaufgaben

Aufgabe 6.1 — Die optimale Verschiebung

Für $P(Z > c)$ mit Vorschlag $N(\mu, 1)$: Zeigen Sie, dass das zweite Moment des Schätzers $e^{\mu^2}\, P(Z > c+\mu)$ ist, und bestimmen Sie das beste μ für $c = 4$.

Lösung

Schritt 1 — Das zweite Moment

$$\mathbb{E}_g\big[\mathbf{1}\{X > c\}\, w(X)^2\big] = \int_c^\infty \frac{\varphi(x)^2}{\varphi(x-\mu)}\, dx$$

Mit $\varphi(x)^2/\varphi(x-\mu) = \varphi(x)\, e^{-\mu x + \mu^2/2}$ und $\varphi(x)e^{-\mu x} = \varphi(x+\mu)\, e^{\mu^2/2}$:

$$= e^{\mu^2} \int_c^\infty \varphi(x+\mu)\, dx = e^{\mu^2}\, P(Z > c+\mu)$$

Schritt 2 — Die Werte für $c = 4$

μ	$e^{\mu^2} P(Z > 4+\mu)$	**Varianz**
0	$3{,}17 \cdot 10^{-5}$	$3{,}17 \cdot 10^{-5}$
2	$5{,}4 \cdot 10^{-8}$	$5{,}3 \cdot 10^{-8}$
4	$5{,}5 \cdot 10^{-9}$	$4{,}5 \cdot 10^{-9}$
6	$3{,}3 \cdot 10^{-8}$	$3{,}2 \cdot 10^{-8}$
8	$1{,}1 \cdot 10^{-5}$	$1{,}1 \cdot 10^{-5}$

Varianz = zweites Moment $-\theta^2$ mit $\theta^2 = 1{,}0 \cdot 10^{-9}$.

Schritt 3 — Das Optimum

Ableiten von $\mu^2 + \ln P(Z > 4+\mu)$ nach μ: $2\mu = \varphi(4+\mu)/P(Z > 4+\mu) \approx 4+\mu$ für große Argumente, also $\mu \approx 4$ — genauer $\mu^* = 4{,}1$.

> ***Der Varianzfaktor gegenüber naiv ist*** $3{,}17 \cdot 10^{-5}/4{,}5 \cdot 10^{-9} = 7\,000$ *— die Simulation gab 6 700. Die Rechnung zeigt auch, warum $\mu = 8$ scheitert: e^{64} ist 10^{28}, und $P(Z > 12)$ gleicht das knapp aus; die Gewichte werden astronomisch. Die Verschiebung auf die Schwelle ist der Spezialfall einer allgemeinen Regel, der* ***exponentiellen Neigung*** *aus Band 25, Kapitel 9: Man wählt $g(x) \propto e^{\lambda x} f(x)$ und λ so, dass $\mathbb{E}_g[X] = c$.*

Aufgabe 6.2 — Zehn Abweisungen an einem Tag

Wie würden Sie die Wahrscheinlichkeit von mindestens zehn Abweisungen an einem Tag auf der Intensivstation schätzen?

Lösung

Schritt 1 — Was das Ereignis treibt

Zehn Abweisungen brauchen eine volle Station und viele Ankünfte an einem Tag — bei $\lambda = 2{,}4$ sind zwölf oder mehr Ankünfte ein 10^{-5}-Ereignis der Poisson-Verteilung allein.

Schritt 2 — Der Vorschlag

Man erhöhe für den betrachteten Tag die Ankunftsrate auf $\lambda' = 12$ und verkürze nichts an den Verweildauern. Das Gewicht für einen Tag mit k Ankünften zu den Zeiten $t_1, \dots, t_k$ ist das Dichteverhältnis der beiden Poisson-Prozesse:

$$w = \left(\frac{\lambda}{\lambda'}\right)^{k} e^{(\lambda' - \lambda)\cdot 1} = 0{,}2^{k}\, e^{9{,}6}$$

Schritt 3 — Der Zustand davor

Die Station muss zu Tagesbeginn voll sein. Man simuliere das System normal, bis es im Dauerzustand ist, und starte die geneigten Tage aus Zuständen, die man dem laufenden System entnimmt — jeder Tag ein unabhängiger Versuch mit Gewicht w.

Das Ergebnis ist $\frac{1}{n}\sum \mathbf{1}\{R_i \geq 10\}\, w_i$ — mit einem n_{eff}, das man prüft, bevor man eine Zahl nennt.

***Die Wahl $\lambda' = 12$ ist die Neigung aus Aufgabe 6.1**: Die Rate so verschieben, dass das Ereignis typisch wird. Die Gewichte sind dann klein und ungleich — $0{,}0015$ für einen Tag mit zehn Ankünften, 10^{-10} für einen mit zwanzig — und ein Tag mit dreizehn Ankünften, von denen zehn abgewiesen werden, trägt hunderttausendmal so viel wie einer mit zwanzig. Zu schwach geneigt, und das Ereignis bleibt selten; zu stark, und die Gewichte verzetteln sich. Die Kunst liegt in der Mitte, und Kapitel 11 wird für seltene Ereignisse in Systemen über die Zeit ein Verfahren vorstellen, das die Neigung selbst findet.*

Aufgabe 6.3 — Wann Quasi-Monte-Carlo hilft

Für welche der folgenden Aufgaben lohnt eine Sobol-Folge: (a) $\int_{[0,1]^3}$ einer glatten Funktion, (b) die Abweisungsrate der Intensivstation über 1 000 Tage, (c) der Preis einer Option, der von 50 täglichen Kursen abhängt?

Lösung

Schritt 1 — (a)

Drei Dimensionen, glatt, beschränkte Variation: Faktor Tausende. Ja.

Schritt 2 — (b)

Ein Lauf braucht etwa 2 400 Ankunftszeiten und ebenso viele Verweildauern — Dimension 5 000, und die Abweisungsrate ist als Funktion dieser Zahlen unstetig mit unendlicher Variation. $(\log n)^{5000}$ ist kein Argument mehr. Nein — oder nur mit Verwürfelung, als harmloser Zufallsersatz ohne Gewinn.

Schritt 3 — (c)
Fünfzig Dimensionen, aber die **wirksame Dimension** ist klein: Der Preis hängt vor allem vom Endkurs ab, und der ist die Summe aller fünfzig Schritte. Erzeugt man den Pfad so, dass die erste Sobol-Koordinate den Endkurs bestimmt und die weiteren die Zwischenwerte (**Brownsche Brücke**, Band 25, Kapitel 6), so wirkt die Folge wie in zwei oder drei Dimensionen.

Ja — und das ist der Grund, warum Quasi-Monte-Carlo in der Finanzmathematik seit den 1990er Jahren Standard ist.

***Die Regel ist nicht die Dimension, sondern die wirksame Dimension**: Wie viele Koordinaten tragen den Großteil der Varianz? **Caflisch**, **Morokoff** und **Owen** haben 1997 gezeigt, dass eine Hypothekenbewertung in 360 Dimensionen eine wirksame Dimension von zwei hat. Die Intensivstation hat keine: Jede Ankunft zählt gleich viel. Für sie bleibt der Zufall — und die Verfahren der Kapitel 4 und 5.*

Vom Neutron zur Hypothek

Die Wichtigkeitsstichprobe ist das älteste Verfahren dieses Bandes, und sie entstand aus einer Not.

*Die Neutronen in Los Alamos, die durch eine Abschirmung dringen, sind ein seltenes Ereignis — eines von 10^{10}. **Kahn** und **Harris** beschrieben 1951, wie man die Neutronen künstlich in die Abschirmung hineinlenkt und mit Gewichten korrigiert. **Den Namen „importance sampling" prägte Kahn**; das Gewicht nannte er „particle weight", und die Teilchen trugen es wie einen Pass durch die Simulation.*

Quasi-Zufall

*Die Diskrepanz stammt aus der Zahlentheorie: **Hermann Weyl** 1916 über Gleichverteilung modulo eins. **Koksma** bewies die Ungleichung 1942 in einer Dimension, **Hlawka** 1961 allgemein, **Sobol** konstruierte seine Folge 1967 in Moskau. **Dass sie außerhalb der Zahlentheorie etwas taugt, bemerkte die Wall Street**: **Paskov** und **Traub** bewerteten 1995 eine Hypothekenanleihe in 360 Dimensionen mit Sobol-Punkten und waren hundertmal schneller als die Bank.*

Seltene Ereignisse heute

Adaptive Neigung	Die Vorschlagsdichte aus den Ziehungen lernen, in Runden — Kreuzentropie-Verfahren, Kapitel 11.
Aufspaltung	Statt zu gewichten, Pfade vervielfältigen, die sich dem Ereignis nähern — Kapitel 11.
Höhere Ordnung	Gitterregeln und Netze, deren Fehler für glatte h wie n^{-2} oder n^{-3} fällt.

Zur dritten Zeile

Die Theorie der Quasi-Monte-Carlo-Verfahren ist in den letzten zwanzig Jahren die aktivste Ecke des Fachs geworden: ***Dick*** *und* ***Pillichshammer*** *haben 2010 Punktmengen konstruiert, die für Funktionen mit k glatten Ableitungen einen Fehler n^{-k} erreichen — in beliebiger Dimension, solange die wirksame Dimension klein bleibt. Für die Unsicherheitsquantifizierung in Kapitel 14, wo ein Modell Hunderte unsichere Parameter hat, von denen wenige zählen, ist das der Werkzeugkasten.*

Was Sie jetzt können

Definition 6.1	$w = f/g$, aus g ziehen, mit w wichten
Satz 6.2	beste $g \propto \lvert h \rvert f$; Ränder schwerer als f
Die Verschiebung	Modus von g auf die Schwelle
n_{eff}	immer prüfen
Satz 6.3	Koksma–Hlawka; Sobol bei kleiner wirksamer Dimension

Teil II ist damit abgeschlossen: Fehler messen, Fehler senken, seltene Ereignisse erreichen. Alle Verfahren haben vorausgesetzt, dass man aus f oder aus einem g ziehen kann. Teil III beginnt mit der Frage, was man tut, wenn man es nicht kann — wenn f nur bis auf eine unbekannte Konstante bekannt ist, in tausend Dimensionen. Die Antwort ist die wichtigste Erfindung der Simulation seit ihrer Erfindung.

Teil III

Ketten und Pfade

Kapitel 7

Ziehen, ohne ziehen zu können

7.1 Das Problem

Die Verweildauer schätzen

Hundert beobachtete Aufenthalte, logarithmiert: Mittel $\bar{y} = 1{,}283$, Streuung $s = 0{,}528$. Gesucht ist, was man über μ und σ der logarithmischen Normalverteilung weiß — nach Band 21 die A-posteriori-Dichte

$$p(\mu, \sigma \mid y) \;\propto\; \sigma^{-(n+1)} \exp\!\Big(-\frac{\sum_i (y_i - \mu)^2}{2\sigma^2}\Big)$$

bei flacher A-priori-Verteilung für μ und $\ln \sigma$.

Die rechte Seite ist bekannt. Die Normierungskonstante nicht. Und aus einer Dichte, deren Konstante man nicht kennt, kann man mit Kapitel 2 nicht ziehen.

Das ist der Normalfall in der Bayes-Statistik und in der statistischen Physik: Ein Produkt aus Likelihood und A-priori-Dichte, über 2 oder 2 000 Parameter, dessen Integral niemand ausrechnen kann. Für diesen Fall — zwei Parameter, konjugierte Form — gibt es noch exakte Formeln, und genau deshalb eignet er sich zum Prüfen. Das Verfahren, das jetzt kommt, braucht die Formeln nicht; es braucht nur die rechte Seite, ausgewertet an beliebigen Punkten.

7.2 Der Metropolis-Algorithmus

Definition 7.1 — Metropolis–Hastings

Sei π eine Dichte, bekannt bis auf eine Konstante, und $q(x' \mid x)$ eine Vorschlagsdichte, aus der man ziehen kann. Ausgehend von x_0 wiederhole man:

1	Vorschlag $x' \sim q(\cdot \mid x_t)$ ziehen.
2	Annahmewahrscheinlichkeit berechnen: $\alpha = \min\left\{1, \dfrac{\pi(x')\,q(x_t \mid x')}{\pi(x_t)\,q(x' \mid x_t)}\right\}$
3	Mit Wahrscheinlichkeit α setze $x_{t+1} = x'$, sonst $x_{t+1} = x_t$.

Für symmetrisches q — etwa $x' = x_t + \text{Schritt} \cdot Z$ — kürzt sich q heraus: $\alpha = \min\{1, \pi(x')/\pi(x_t)\}$. Das ist der **Zufallsweg-Metropolis**.

Satz 7.2 — π ist die stationäre Verteilung

Die Kette aus Definition 7.1 erfüllt die detaillierte Bilanz

$$\pi(x)\,P(x \to x') = \pi(x')\,P(x' \to x)$$

und hat daher π als stationäre Verteilung. Ist sie zudem irreduzibel und aperiodisch, so gilt für jede integrierbare Funktion h

$$\frac{1}{T}\sum_{t=1}^{T} h(x_t) \longrightarrow \int h\,\pi \qquad \text{fast sicher.}$$

Beweis

Für $x \neq x'$ ist $P(x \to x') = q(x'|x)\,\alpha(x,x')$. Sei ohne Einschränkung $\pi(x')q(x|x') \leq \pi(x)q(x'|x)$; dann ist $\alpha(x,x') = \pi(x')q(x|x')/(\pi(x)q(x'|x))$ und $\alpha(x',x) = 1$. Also

$$\pi(x)\,q(x'|x)\,\alpha(x,x') = \pi(x')\,q(x|x') = \pi(x')\,q(x|x')\,\alpha(x',x).$$

Detaillierte Bilanz ergibt Stationarität durch Integration über x (Band 25, Satz 3.5). Die Konvergenz des Mittels ist der Ergodensatz für Markow-Ketten, Band 25, Satz 3.9. ■

Die Normierungskonstante kommt im Quotienten $\pi(x')/\pi(x)$ nicht vor. Das ist der ganze Trick — und er trägt das ganze Fach.

Was der Satz nicht sagt, ist, wie lange es dauert. *Die Kette konvergiert, aber die Werte $x_1, x_2, \ldots$ sind abhängig — jeder vom vorigen — und Kapitel 4 hat gezeigt, was das für den Fehler bedeutet. Die Autokorrelationszeit τ hängt von der Schrittweite ab, und die Tabelle im nächsten Abschnitt zeigt, wie empfindlich.*

7.3 Die Schrittweite

Zufallsweg-Metropolis für $(\mu, \ln\sigma)$, 20 000 Schritte

Schritt	Annahme	τ	wirksames n
0,01	91 %	108	170
0,05	61 %	10	1 800
0,10	36 %	**6,4**	**2 800**
0,20	15 %	11	1 600
1,00	0,8 %	184	100

A-posteriori-Streuung von μ in allen Zeilen 0,053; exakt $s/\sqrt{n}\cdot\sqrt{(n-1)/(n-3)} = 0{,}0533$.

Zu kleine Schritte: fast alles wird angenommen, aber die Kette kriecht. Zu große: fast alles wird abgelehnt, und die Kette steht. Dazwischen liegt ein Faktor dreißig im wirksamen n.

Die Regel

Schrittweite so wählen, dass etwa ein Viertel bis die Hälfte der Vorschläge angenommen wird — in einer Dimension nahe 45 %, in vielen nahe 23 %.

Die 23 % sind ein Satz, nicht eine Faustregel: Roberts, Gelman und Gilks bewiesen 1997, dass für Produktdichten in hoher Dimension die optimale Schrittweite wie $2{,}38/\sqrt{d}$ skaliert und genau diese Annahmerate ergibt. Die Streuung 0,053 in jeder Zeile zeigt, dass Satz 7.2 immer gilt — auch die kriechende Kette ist richtig, nur hat sie nach 20 000 Schritten erst 170 unabhängige Werte gesammelt. Richtig und brauchbar sind zwei Dinge.

7.4 Der Gibbs-Sampler

Definition 7.3 — Gibbs-Sampler

Sei $\pi(x_1,\dots,x_d)$ gegeben, und seien die bedingten Verteilungen $\pi(x_j \mid x_{-j})$ jeder Koordinate bei festgehaltenen übrigen ziehbar. Dann ziehe man reihum

$$x_1 \sim \pi(\cdot \mid x_2,\dots,x_d),\quad x_2 \sim \pi(\cdot \mid x_1,x_3,\dots,x_d),\quad \dots,\quad x_d \sim \pi(\cdot \mid x_1,\dots,x_{d-1}).$$

Jeder Teilschritt ist ein Metropolis-Hastings-Schritt mit Annahmewahrscheinlichkeit 1.

Der Gibbs-Sampler für (μ, σ)

Beide bedingten Verteilungen sind in Band 21 hergeleitet:

$$\mu \mid \sigma, y \sim N\Big(\bar{y},\ \frac{\sigma^2}{n}\Big), \qquad \sigma^2 \mid \mu, y \sim \frac{\sum_i (y_i - \mu)^2}{\chi^2_n}.$$

Ergebnis, 20 000 **Schritte**

	Mittel	**Streuung**	τ
μ	1,2825	0,0531	1,0
σ	0,532	0,038	1,0

Kein Schritt wird abgelehnt, keine Schrittweite ist zu wählen, und $\tau = 1$: Die Kette ist so gut wie unabhängige Ziehungen.

Warum $\alpha = 1$

Vorschlag $x_j' \sim \pi(x_j' \mid x_{-j})$, alles andere bleibt. Der Hastings-Quotient:

$$\frac{\pi(x_j', x_{-j})\ \pi(x_j \mid x_{-j})}{\pi(x_j, x_{-j})\ \pi(x_j' \mid x_{-j})} = \frac{\pi(x_j' \mid x_{-j})\,\pi(x_{-j})\ \pi(x_j \mid x_{-j})}{\pi(x_j \mid x_{-j})\,\pi(x_{-j})\ \pi(x_j' \mid x_{-j})} = 1$$

***Hier ist** $\tau = 1$, **weil** μ **und** σ **a posteriori fast unabhängig sind.** Sind zwei Koordinaten stark korreliert — $\rho = 0{,}99$ —, so kommt der Gibbs-Sampler nur in winzigen Treppenstufen den schmalen Grat entlang, und τ wächst wie $1/(1-\rho^2)$: auf 50. Dann hilft eine Drehung der Koordinaten, oder man zieht beide gemeinsam (**Block-Gibbs**). Der Gibbs-Sampler ist nicht besser als Metropolis; er ist Metropolis mit dem bestmöglichen Vorschlag je Koordinate — und der Preis ist, dass man die bedingten Verteilungen kennen muss.*

7.5 Was man mit der Kette tut

Abgeleitete Größen

Die mittlere Verweildauer ist $\exp(\mu + \sigma^2/2)$. Aus der Gibbs-Kette, Wert für Wert:

A-posteriori-Mittel	4,16 Tage
95-Prozent-Intervall	[3,74; 4,67]
$P(\text{Mittel} > 5)$	0,0012

Keine Deltamethode, keine Näherung: Man rechnet die Funktion für jeden Kettenwert aus und sieht ihre Verteilung.

***Das ist der Grund, warum die Bayes-Statistik mit diesen Verfahren praktisch wurde**: Nicht die Parameter interessieren, sondern Funktionen von ihnen — die Abweisungsrate bei dreizehn Betten unter Unsicherheit über die Verweildauer, Kapitel 14 — und für jede Funktion liefert dieselbe Kette die Antwort. Die* 0,0012 *beruhen auf* 24 *Kettenwerten über* 5*; mit Kapitel 6 ließe sich das schärfen, aber für die Entscheidung "sicher unter fünf" reicht es.*

7.6 Der Bruchfall

Die Kette, die nur die Hälfte sieht

Zieldichte $\frac{1}{2}N(-6,1) + \frac{1}{2}N(6,1)$, Zufallsweg-Metropolis, Schrittweite 1, vier Ketten à 5 000 Schritte, gestartet bei -6, -5, 5, 6.

Kette	Start	Mittel	Annahme
1	-6	$-5{,}98$	71 %
2	-5	$-6{,}02$	71 %
3	5	5,97	70 %
4	6	6,06	70 %

Jede Kette für sich sieht makellos aus: Annahmerate gut, $\tau = 8$, Standardfehler 0,015**. Jede Kette ist um** 6 **falsch. Das wahre Mittel ist** 0**.**

Warum

Der Weg von -6 nach 6 führt durch 0, wo die Dichte e^{-18} der Gipfelhöhe beträgt. Ein Schritt der Weite 1 schafft die zwölf Einheiten nicht, und zwölf Schritte hintereinander bergab werden mit Wahrscheinlichkeit $e^{-18} \approx 10^{-8}$ angenommen. Die Kette ist *theoretisch* irreduzibel und *praktisch* in einer Hälfte gefangen.

***Mit Schrittweite** 6 **wechseln die Ketten die Gipfel; Annahme** 24 %**, alle vier Mittel nahe** 0**.** *Aber woher wüsste man, dass es zwei Gipfel gibt, wenn man die Dichte nicht zeichnen kann, weil sie* 200 *Dimensionen hat? Eine einzelne Kette verrät es nie.* ***Vier Ketten von verschiedenen Startpunkten verraten es sofort** — und das ist der Grundgedanke des nächsten Kapitels.*

7.7 Übungsaufgaben

Aufgabe 7.1 — Ein Metropolis-Schritt von Hand

Zieldichte $\pi(x) \propto e^{-x^2/2}$. Die Kette steht bei $x_t = 1{,}0$; der Vorschlag ist $x' = 1{,}8$; die gezogene Gleichverteilte ist $u = 0{,}35$. Was ist x_{t+1}? Und bei $x' = 0{,}4$?

Lösung

Schritt 1 — Der Quotient für $x' = 1{,}8$

$$\frac{\pi(1{,}8)}{\pi(1{,}0)} = \exp\Big(-\frac{1{,}8^2 - 1{,}0^2}{2}\Big) = \exp(-1{,}12) = 0{,}326$$

Schritt 2 — Die Entscheidung

$u = 0{,}35 > 0{,}326$: abgelehnt. $x_{t+1} = 1{,}0$ — der alte Wert zählt noch einmal.

Schritt 3 — Für $x' = 0{,}4$

$$\frac{\pi(0{,}4)}{\pi(1{,}0)} = \exp\Big(-\frac{0{,}16 - 1}{2}\Big) = \exp(0{,}42) = 1{,}52 > 1$$

Angenommen ohne Ziehung: $x_{t+1} = 0{,}4$.

> ***Bergauf immer, bergab mit Wahrscheinlichkeit gleich dem Höhenverhältnis*** *— so bewegt sich die Kette: Sie strebt zum Gipfel, aber nicht blind, sondern so, dass sie die Zeit an jedem Ort proportional zu dessen Höhe verbringt. Das Nein in Schritt 2 ist kein verlorener Schritt: Die Wiederholung von 1,0 ist die Art, wie die Kette ausdrückt, dass 1,0 wahrscheinlicher ist als 1,8. Wer abgelehnte Schritte aus der Kette streicht, zerstört Satz 7.2.*

Aufgabe 7.2 — Die Ankunftsrate dazu

Nun seien auch die $k = 240$ Ankünfte in 100 Tagen beobachtet, und λ soll mitgeschätzt werden, A-priori flach. Erweitern Sie den Gibbs-Sampler.

Lösung

Schritt 1 — Die Likelihood für λ

Poisson: $p(k \mid \lambda) \propto \lambda^k e^{-100\lambda}$. Bei flacher A-priori-Verteilung ist das eine Gammadichte:

$$\lambda \mid k \sim \text{Gamma}(k+1,\ 100)$$

mit Mittel 2,41 und Streuung 0,155.

Schritt 2 — Die Unabhängigkeit

λ kommt in der Likelihood der Verweildauern nicht vor, (μ, σ) nicht in der der Ankünfte. Die bedingte Verteilung von λ hängt von (μ, σ) nicht ab.

Schritt 3 — Der erweiterte Sampler

1	$\mu \sim N(\bar{y}, \sigma^2/n)$
2	$\sigma^2 \sim \sum(y_i - \mu)^2/\chi^2_n$
3	$\lambda \sim \text{Gamma}(241, 100)$ — unabhängig von Schritt 1 und 2

Schritt 3 ist ein Gibbs-Schritt, der kein Gibbs-Schritt sein müsste *— man könnte λ auch getrennt ziehen. Aber im Sampler ist es kostenlos, und der Gewinn kommt in Kapitel 14: Mit jedem Tripel (λ, μ, σ) der Kette lässt sich die Station simulieren, und die Verteilung der Abweisungsraten über die Kette ist die Unsicherheit der Vorhersage, die aus der Unsicherheit der Parameter folgt. Die Ankunftsrate ist dabei der größere Beitrag: $\pm 6\,\%$ in λ gegen $\pm 2\,\%$ in der mittleren Verweildauer.*

Aufgabe 7.3 — Unabhängigkeitsvorschlag

Statt eines Zufallswegs schlage man x' unabhängig vom aktuellen Wert aus einer festen Dichte g vor. Was ist α, und wann ist das Verfahren gut?

Lösung

Schritt 1 — Der Hastings-Quotient

$q(x' \mid x) = g(x')$:

$$\alpha = \min\left\{1,\ \frac{\pi(x')\,g(x)}{\pi(x)\,g(x')}\right\} = \min\left\{1,\ \frac{w(x')}{w(x)}\right\}, \qquad w = \frac{\pi}{g}$$

Schritt 2 — Die Verbindung

w ist das Wichtigkeitsgewicht aus Kapitel 6. Der Vorschlag wird angenommen, wenn er ein höheres Gewicht hat als der Stand, sonst mit Wahrscheinlichkeit des Gewichtsverhältnisses.

Schritt 3 — Wann es gut ist

> **Wenn g nahe an π liegt: Dann sind alle Gewichte etwa gleich, fast alles wird angenommen, und die Werte sind nahezu unabhängig — $\tau \approx 1$.**

Hat g dünnere Ränder als π, so gibt es Punkte mit riesigem w, und die Kette bleibt dort hängen: Hat sie einmal x mit $w(x) = 10^6$ erreicht, lehnt sie fast jeden Vorschlag ab, und τ wird astronomisch — dieselbe Krankheit wie im Bruchfall von Kapitel 6.

> ***Der Unabhängigkeitsvorschlag ist damit das Gegenstück zur Wichtigkeitsstichprobe****: Dieselbe Dichte g, dieselbe Bedingung an die Ränder, aber statt Gewichten eine Kette. In der Praxis nimmt man g als Normal- oder t-Verteilung um das Maximum von π mit der Krümmung aus Band 21 — die Laplace-Näherung — und lässt Metropolis den Rest korrigieren. Für glatte, eingipflige π in mäßiger Dimension ist das oft das beste Verfahren überhaupt.*

Los Alamos 1953 und die zwanzig Jahre danach

Der Algorithmus erschien 1953 im Journal of Chemical Physics, unter fünf Namen: **Nicholas Metropolis**, **Arianna** und **Marshall Rosenbluth**, **Augusta** und **Edward Teller**.

> *Die Aufgabe war die Zustandsgleichung von Flüssigkeiten: zweihundert harte Scheiben in einer Schachtel, die Energie als Funktion aller Positionen, und der Boltzmann-Faktor $e^{-E/kT}$ als Dichte — mit unbekannter Zustandssumme.* ***Marshall Rosenbluth erfand das Verfahren, Arianna Rosenbluth programmierte es auf der MANIAC****; Metropolis stellte den Rechner und stand als Erster auf dem Papier.* ***Hastings*** *verallgemeinerte 1970 in Toronto auf unsymmetrische Vorschläge, und sein Aufsatz blieb zwanzig Jahre fast ungelesen.*

Die Wende

> ***Geman*** *und* ***Geman*** *formulierten 1984 den Gibbs-Sampler für die Bildrekonstruktion — benannt nach Gibbs, weil ihre Dichten Gibbs-Verteilungen der Physik waren.* ***Gelfand und Smith zeigten 1990, dass dasselbe Verfahren jede Bayes-Analyse rechenbar macht****, und innerhalb von fünf Jahren war die Bayes-Statistik von einer philosophischen Richtung zu einer Praxis geworden. Das Programm BUGS aus Cambridge, 1991, machte sie für Mediziner zugänglich, die keine Zeile Metropolis je geschrieben haben.*

Jenseits des Zufallswegs

Hamilton-Verfahren	Vorschläge entlang von Bahnen eines Teilchens im Potential $-\ln \pi$ — weite Schritte bei hoher Annahme; Kapitel 9.
Langevin	Zufallsweg plus ein Schritt bergauf entlang $\nabla \ln \pi$.
Parallele Temperierung	Mehrere Ketten bei verschiedenen “Temperaturen”, die Zustände tauschen — gegen den Bruchfall.

Zur dritten Zeile

> ***Die Kette bei hoher Temperatur sieht $\pi^{1/T}$, flach genug, um die Gipfel zu wechseln****; die bei $T = 1$ ist die gesuchte. Ab und zu tauschen benachbarte Ketten ihre Zustände, mit einem Metropolis-Quotienten, der die detaillierte Bilanz erhält. So gelangt die kalte Kette über die heiße von einem Gipfel zum anderen. Für Proteinfaltung und für Mischmodelle in der Statistik ist das Standard, und der Preis ist das Zehnfache an Rechenzeit — für Ketten, die sonst nie das Richtige fänden.*

Was Sie jetzt können

Definition 7.1	Vorschlag, Quotient, Annahme
Satz 7.2	detaillierte Bilanz $\Rightarrow \pi$ stationär
Schrittweite	Annahme 25–45 %, τ messen
Definition 7.3	Gibbs: bedingt ziehen, $\alpha = 1$
Der Bruchfall	zwei Gipfel, eine Kette

Satz 7.2 verspricht Konvergenz, der Bruchfall zeigt, dass man sie nicht sieht. Das nächste Kapitel ist der Frage gewidmet, woran man erkennt, ob eine Kette angekommen ist — und was man tun kann, wenn man es nicht erkennen kann.

Kapitel 8

Ist die Kette angekommen?

8.1 Was man nicht sehen kann

Das Dilemma

Satz 7.2 sagt: Die Kette konvergiert gegen π. Er sagt nicht, wann. Und der Bruchfall in Kapitel 7 hat gezeigt, dass eine Kette, die nicht angekommen ist, genauso aussieht wie eine, die es ist — Annahmerate, Autokorrelation, Standardfehler: alles unauffällig.

> **Konvergenz lässt sich aus einer Kette nicht beweisen. Nichtkonvergenz lässt sich oft nachweisen. Die Diagnostik dieses Kapitels sucht nach dem Nachweis — und wer ihn nicht findet, hat eine Vermutung, keine Gewissheit.**
>
> *Das ist dieselbe Logik wie beim statistischen Test in Band 17: Man kann die Nullhypothese "konvergiert" nicht bestätigen, nur verwerfen. Die Werkzeuge sind drei: mehrere Ketten vergleichen, die Autokorrelation messen, den Anfang verwerfen. Alle drei kosten Rechenzeit, die man lieber in längere Ketten steckte — und alle drei sind billiger als eine falsche Zahl in einem Gutachten.*

8.2 Mehrere Ketten

Definition 8.1 — Die Kennzahl $\hat{R}$

Für m Ketten der Länge n mit Kettenmitteln $\bar{x}_j$ und Kettenvarianzen s_j^2 sei

$$W = \frac{1}{m}\sum_{j} s_j^2, \qquad B = \frac{n}{m-1}\sum_{j}(\bar{x}_j - \bar{x})^2, \qquad \hat{V} = \frac{n-1}{n}\,W + \frac{1}{n}\,B.$$

Dann heißt

$$\hat{R} = \sqrt{\frac{\hat{V}}{W}}$$

der **Skalenreduktionsfaktor** von **Gelman** und **Rubin**.

Satz 8.2 — Was $\hat{R}$ misst

Sind alle Ketten im Dauerzustand, so schätzen W und $\hat{V}$ beide $\mathrm{Var}_\pi[x]$, und $\hat{R} \to 1$. Haben die Ketten — von verschiedenen Startpunkten — verschiedene Gegenden erreicht, so ist $B \gg W$ und $\hat{R} > 1$.

Beweis

W unterschätzt die Varianz, wenn jede Kette nur einen Teil der Verteilung gesehen hat; $\hat{V}$ ist die Varianz der zusammengelegten Werte und überschätzt sie, wenn die Startpunkte überstreut sind. Im Dauerzustand stimmen beide überein — $\hat{V}$ ist dann die übliche Varianzzerlegung in Band 17, Kapitel 10, Zwischen- plus Innerhalb-Varianz. ■

Die Ergebnisse aus Kapitel 7

Ketten	$\hat{R}$	Urteil
(μ, σ), Schritt 0,05, 4 Ketten	1,003	angekommen
(μ, σ), Schritt 0,2	1,001	angekommen
zwei Gipfel, Schritt 1	**6,9**	gefangen
zwei Gipfel, Schritt 6	1,006	angekommen

Die vier gefangenen Ketten, die einzeln makellos aussahen, ergeben zusammen $\hat{R} = 6{,}9$. Die Faustregel: $\hat{R} < 1{,}01$, sonst länger laufen oder anders vorschlagen.

***Die Bedingung ist das Wort „überstreut“**: Die Startpunkte müssen weiter auseinanderliegen, als die Verteilung breit ist — sonst starten alle Ketten im selben Gipfel, und $\hat{R}$ ist 1,00 bei Nichtkonvergenz. Woher man weiß, wie breit die Verteilung ist, bevor man sie kennt? Man nimmt das Maximum der Dichte und die Krümmung dort (Band 21), streut die Startpunkte auf das Mehrfache — und hofft. Das ist der Bruchfall dieses Kapitels, und er hat keine Lösung, nur eine Milderung: viele Ketten, weit gestreut.*

8.3 Das wirksame n der Kette

Satz 4.1 für Ketten

Die Werte einer Kette sind abhängig; Kapitel 4 gilt ohne Änderung:

$$n_{\mathrm{eff}} = \frac{m\,n}{\tau}, \qquad \mathrm{SE} = \frac{\sigma_\pi}{\sqrt{n_{\mathrm{eff}}}}.$$

Bei mehreren Ketten schätzt man τ aus den Autokorrelationen innerhalb jeder Kette und mittelt.

Für die Gibbs-Kette und die Metropolis-Kette, 20 000 **Werte**

Verfahren	τ	n_{eff}	SE von μ
Gibbs	1,0	20 000	0,0004
Metropolis 0,1	6,4	2 800	0,0010
Metropolis 0,01	108	170	0,0041

Die Planung

Für Standardfehler 0,001 bei $\sigma_\pi = 0{,}053$ und $\tau = 6{,}4$:

$$n = \left(\frac{0{,}053}{0{,}001}\right)^2 \cdot 6{,}4 = 18\,000 \text{ Schritte.}$$

Eine Kette mit $n_{eff} < 100$ ***ist nicht auswertbar*** *— nicht weil das Mittel schlecht wäre, sondern weil die Schätzung des Standardfehlers selbst dann unbrauchbar ist. Und die Quantile der Ränder, das 2,5- und das 97,5-Prozent-Quantil für ein Intervall, brauchen ein eigenes, kleineres* n_{eff}*: Ränder werden seltener besucht. Die neueren Programme berechnen beides getrennt.*

8.4 Der Anfang und das Ausdünnen

Zwei Regeln und eine Unsitte

Einschwingphase	Die erste Hälfte jeder Kette verwerfen, $\hat{R}$ mit der zweiten berechnen. Verschwenderisch, aber sicher: Ist $\hat{R}$ mit der ersten Hälfte anders als mit der zweiten, läuft die Kette noch.
Halbe Ketten	Jede Kette zusätzlich in zwei Hälften teilen und $\hat{R}$ über $2m$ Halbketten bilden — entdeckt Drift innerhalb einer Kette.
Ausdünnen	Nur jeden k-ten Wert behalten. *Senkt den Speicher, nie den Fehler*: Zehn Werte mit $\tau = 10$ enthalten mehr Information als einer.

Das Ausdünnen ist die am weitesten verbreitete Unsitte des Fachs: Es wirft Information weg, um eine Autokorrelation zu verstecken, die man mit Kapitel 4 einfach hätte berücksichtigen können.

Die Unsitte stammt aus einer Zeit, in der Speicher knapp war und die Standardfehler mit Band-17-Formeln berechnet wurden *— dann war Ausdünnen die einzige Art, zu unabhängigen Werten zu kommen. Heute ist beides anders. Ein Fall bleibt: Wenn die Auswertung je Kettenwert teuer ist — eine Stationssimulation je Parametertripel wie in Kapitel 14 —, dann dünnt man auf etwa n_{eff} Werte aus, weil mehr nichts bringt.*

8.5 Der Bruchfall

Vier Ketten, ein Gipfel

Zieldichte wie in Kapitel 7, zwei Gipfel bei ± 6. Vier Ketten, Schrittweite 1, gestartet bei 5, 5,5, 6, 6,5.

$$\hat{R} = 1{,}00, \qquad \tau = 8, \qquad \text{alle vier Mittel bei } 6{,}0.$$

Jede Diagnostik dieses Kapitels gibt grünes Licht. Das wahre Mittel ist 0. Es gibt kein Verfahren, das aus diesen Ketten den zweiten Gipfel erkennen könnte, weil keine von ihnen ihn je gesehen hat.

Was bleibt

Überstreuen	Startpunkte aus einer Verteilung, die viel breiter ist als die vermutete.
Temperieren	Die heiße Kette aus Kapitel 7 sieht beide Gipfel.
Verstehen	Hat das Modell Symmetrien — vertauschbare Komponenten in einem Mischmodell —, so weiß man, dass es $k!$ Gipfel gibt, und prüft, ob die Kette sie besucht.

Die Diagnostik ersetzt nicht das Nachdenken über die Dichte. *Wer weiß, dass seine Likelihood in σ zwei Lösungen haben kann, startet dort. Wer es nicht weiß, hat mit vier Ketten eine bessere Chance als mit einer, und mit vierzig eine bessere als mit vier. Aber eine Garantie gibt es nicht, und wer in einem Gutachten eine Markow-Ketten-Schätzung berichtet, schreibt dazu, wie viele Ketten, wie gestreut, welches $\hat{R}$ — damit der Leser weiß, wie viel er glauben darf.*

8.6 Übungsaufgaben

Aufgabe 8.1 — $\hat{R}$ von Hand

Vier Ketten à $n = 1\,000$ für μ: Mittel 1,279, 1,286, 1,278, 1,290; Varianzen 0,00281, 0,00279, 0,00285, 0,00276. Berechnen Sie $\hat{R}$.

Lösung

Schritt 1 — W

$$W = \frac{0{,}00281 + 0{,}00279 + 0{,}00285 + 0{,}00276}{4} = 0{,}002803$$

Schritt 2 — B

Gesamtmittel 1,28325; Stichprobenvarianz der vier Mittel $3{,}29 \cdot 10^{-5}$:

$$B = n \cdot 3{,}29 \cdot 10^{-5} = 0{,}0329$$

Schritt 3 — $\hat{V}$ und $\hat{R}$

$$\hat{V} = \frac{999}{1000} \cdot 0{,}002803 + \frac{0{,}0329}{1000} = 0{,}002833, \qquad \hat{R} = \sqrt{\frac{0{,}002833}{0{,}002803}} = 1{,}005$$

Angekommen — und zugleich sieht man, wie die Rechnung ausgehen muss: Vier Mittel aus je 1 000 abhängigen Werten mit Streuung 0,053 und $\tau \approx 10$ streuen mit $0{,}053\sqrt{10/1000} = 0{,}0053$; die Varianz $3{,}3 \cdot 10^{-5}$, Streuung 0,0057, ist genau das. Wäre sie 0,05 — die Ketten in verschiedenen Gegenden —, so wäre $B = 2{,}5$, $\hat{V} = 0{,}0053$ und $\hat{R} = 1{,}38$.

Aufgabe 8.2 — Wie viele Ketten, wie lang?

Ein Lauf von 10 000 Schritten dauert eine Minute. Sie haben vier Rechenkerne und zehn Minuten. $\tau = 20$, $\sigma_\pi = 2$. Welchen Standardfehler erreichen Sie, und wie verteilen Sie die Zeit?

Lösung

Schritt 1 — Das Budget

Vier Kerne, zehn Minuten: $4 \cdot 100\,000 = 400\,000$ Schritte.

Schritt 2 — Die Einschwingphase

Erste Hälfte verwerfen: 200 000 nutzbare Werte, $n_{\text{eff}} = 200\,000/20 = 10\,000$.

$$\text{SE} = \frac{2}{\sqrt{10\,000}} = 0{,}02$$

Schritt 3 — Die Verteilung

4 Ketten à 100 000	Ein Kern je Kette. $\hat{R}$ möglich, $n_{\text{eff}} = 10\,000$.
1 Kette à 400 000	Nicht parallelisierbar — dauert vierzig Minuten. Kein $\hat{R}$.
40 Ketten à 10 000	Zehn je Kern nacheinander. $n_{\text{eff}} = 10\,000$, aber vierzig Einschwingphasen und je Kette nur 250 wirksame Werte — zu wenig für die Ränder.

***Eine Kette je Kern, so lang wie die Zeit reicht, mindestens vier**: Das ist die Antwort in fast allen Fällen, und sie ist der Grund, warum die Programme standardmäßig vier Ketten laufen lassen. Mehr Ketten als Kerne kosten Einschwingphasen; weniger kosten die Diagnostik. Die eine lange Kette ist die Wahl von früher, als es einen Kern gab — und als man die Nichtkonvergenz entsprechend selten bemerkte.*

Aufgabe 8.3 — Ausdünnen oder nicht

Eine Kette von 100 000 Werten mit $\tau = 25$. Vergleichen Sie: alle Werte auswerten mit Satz 4.1; jeden 25-sten Wert behalten und als unabhängig behandeln.

Lösung

Schritt 1 — Alle Werte

$n_{\text{eff}} = 100\,000/25 = 4\,000$.

Schritt 2 — Ausgedünnt

4 000 Werte im Abstand 25. Ihre Autokorrelation ist ρ_{25} der Originalkette — bei $\tau = 25$ typisch noch 0,1 bis 0,2, nicht null. Behandelt man sie als unabhängig, ist $n_{\text{eff}} = 4\,000$ *überschätzt*; richtig gerechnet mit $\tau' = 1 + 2(0{,}15 + \ldots) \approx 1{,}4$ sind es 2 900.

Schritt 3 — Der Vergleich

Vorgehen	n_{eff}	**Standardfehler**
alle, Satz 4.1	4 000	richtig
ausgedünnt, naiv	2 900	als 4 000 berichtet: zu klein

***Das Ausdünnen verliert ein Viertel der Information und erzeugt obendrein einen zu kleinen Fehlerbalken**, weil die Restkorrelation ignoriert wird. Es gibt genau ein Argument dafür: Wenn die 100 000 Werte je 2 000 Parameter sind und nicht in den Speicher passen. Dann dünnt man aus — und rechnet den Standardfehler trotzdem mit Satz 4.1 aus den behaltenen Werten.*

Der Streit um die eine Kette

Anfang der 1990er Jahre, als die Bayes-Statistik rechenbar wurde, stritt das Fach, wie man Konvergenz prüft.

__Gelman__ und __Rubin__ schlugen 1992 mehrere überstreute Ketten vor und die Kennzahl $\hat{R}$. __Geyer__ hielt im selben Jahr dagegen: __eine lange Kette sei besser als viele kurze__, weil nur sie die Einschwingphase einmal bezahle — und die Schätzung von τ aus einer Kette sei die bessere Diagnostik. Beide hatten recht; die Kerne haben entschieden: Seit Rechner vier davon haben, laufen vier Ketten, und Geyers Autokorrelationsschätzer wird in jeder von ihnen benutzt.

Die Programme

BUGS 1991 ließ den Benutzer die Diagnostik selbst anstellen — und viele taten es nicht. __Stan, seit 2012, verweigert sich__: Es berechnet $\hat{R}$ und n_{eff} für jeden Parameter, warnt bei $\hat{R} > 1{,}01$ und bei $n_{\mathit{eff}} < 100$ je Kette, und gibt die Warnungen in roter Schrift aus. Dass seither weniger falsche Bayes-Analysen erscheinen, ist nicht bewiesen, aber plausibel.

Diagnostik heute

Rang-$\hat{R}$	$\hat{R}$ auf rangtransformierten Werten — robust gegen schwere Ränder und unendliche Varianz.
Kopplung	Zwei Ketten so koppeln, dass sie sich nach endlicher Zeit treffen; die Treffzeit schätzt die Mischzeit ohne Annahme.
Unverzerrte Schätzer	Aus gekoppelten Ketten einen Schätzer ohne Einschwingfehler bauen — Band 25, Kapitel 3.

Zur zweiten Zeile

__Jacob, O'Leary und Atchadé haben 2020 die Kopplung aus Band 25 zum Werkzeug gemacht__: Zwei Ketten laufen mit gemeinsamen Zufallszahlen — Satz 4.3 — und einem Vorschlag, der sie mit positiver Wahrscheinlichkeit auf denselben Punkt setzt. Haben sie sich getroffen, bleiben sie zusammen, und ab da ist der Einschwingfehler null. Die Verteilung der Treffzeit ist eine obere Schranke für die Mischzeit — die erste Diagnostik, die eine Garantie liefert statt eines Verdachts. Für den Bruchfall gilt auch sie nicht: Zwei Ketten im selben Gipfel treffen sich schnell.

Was Sie jetzt können

Definition 8.1	$\hat{R}$ aus W und B; unter 1,01
Satz 8.2	überstreute Startpunkte sind die Bedingung
$n_{\mathbf{eff}}$	mn/τ; unter 100 nicht auswertbar
Regeln	erste Hälfte verwerfen, nicht ausdünnen
Der Bruchfall	vier Ketten, ein Gipfel: unsichtbar

Zwei Kapitel lang war die Kette ein Zufallsweg mit Schritten der Weite 0,1 *in zwei Dimensionen. In zweitausend Dimensionen braucht derselbe Weg nach Satz 7.2 Schritte der Weite* 0,05 *und Millionen davon. Das nächste Kapitel lässt die Kette stattdessen fliegen — entlang der Bahnen der Mechanik — und rechnet danach die Pfade, aus denen Band 25 besteht.*

Kapitel 9

Fliegen statt kriechen, und Pfade rechnen

9.1 Der Zufallsweg in hundert Dimensionen

Das Problem

Zielverteilung: hundert unabhängige Normalverteilungen mit Streuungen von 0,1 bis 1,0. Zufallsweg-Metropolis, Schrittweite nach der $2{,}38/\sqrt{d}$-Regel, 80 000 Schritte nach der Einschwingphase:

Schritt	Annahme	τ für $\sigma = 0{,}1$	τ für $\sigma = 1$
0,024	71 %	94	4 800
0,048	45 %	41	2 700
0,071	26 %	34	**2 000**

Die Schrittweite muss zur schmalsten Richtung passen — und dann kriecht die Kette in der breitesten: 80 000 **Schritte,** 40 **wirksame Werte.**

Das ist der Fluch der Dimension für Markow-Ketten: Die Zahl der Schritte, um einmal die Verteilung zu durchqueren, wächst wie $d \cdot (\sigma_{\max}/\sigma_{\min})^2$. Mit zweitausend Parametern eines Modells aus Band 26 und einem Verhältnis von Hundert sind das 10^7 Schritte je wirksamem Wert. Der Zufallsweg ist am Ende. Was fehlt, ist eine Bewegung, die weit geht und trotzdem angenommen wird.

9.2 Hamilton-Monte-Carlo

Definition 9.1 — Hamilton-Dynamik für π

Man schreibe $\pi(x) \propto e^{-U(x)}$, U die **potentielle Energie**, und füge einen **Impuls** $p \in \mathbb{R}^d$ mit kinetischer Energie $\tfrac{1}{2}p^\top p$ hinzu. Die Gesamtenergie $H(x,p) = U(x) + \tfrac{1}{2}p^\top p$ definiert die Verteilung e^{-H}, deren x-Rand π ist. Ein Schritt:

1	Impuls ziehen: $p \sim N(0, I)$.
2	L Schritte der Weite ε entlang der Bewegungsgleichungen $\dot{x} = p$, $\dot{p} = -\nabla U(x)$ mit dem Sprungverfahren (unten).
3	Metropolis-Annahme mit $\alpha = \min\{1, e^{H(x,p) - H(x',p')}\}$.

Satz 9.2 — Warum das funktioniert

1. Die exakte Hamilton-Dynamik erhält H und das Volumen (Liouville); der Vorschlag wäre dann immer angenommen.
2. Das **Sprungverfahren** (*leapfrog*) $p \mathrel{-}= \frac{\varepsilon}{2}\nabla U(x)$, $x \mathrel{+}= \varepsilon p$, $p \mathrel{-}= \frac{\varepsilon}{2}\nabla U(x)$ ist volumenerhaltend und umkehrbar, erhält H aber nur bis auf $O(\varepsilon^2)$.
3. Die Metropolis-Korrektur in Schritt 3 macht aus dem Näherungsfehler eine exakte Kette mit stationärer Verteilung e^{-H}.

Beweis

(1) ist Mechanik, Band 24, Kapitel 2 (Auslassung 3). (2): Jeder der drei Teilschritte ist eine Scherung — eine Koordinate wird um eine Funktion der anderen verschoben — und Scherungen haben Determinante 1. Umkehrbar, weil $p \to -p$ den Weg rückwärts durchläuft. (3): Volumenerhaltung und Umkehrbarkeit machen den Vorschlag symmetrisch im Sinne von Definition 7.1, also ist der Hastings-Quotient $e^{-H(x',p')}/e^{-H(x,p)}$. ■

Dasselbe Ziel, 5 000 Schritte mit $L = 20$, $\varepsilon = 0{,}1$

Verfahren	Gradienten	Annahme	$\tau_{\max}$	wirksames n
Zufallsweg	80 000	26 %	2 000	40
Hamilton	100 000	85 %	**1,0**	**5 000**

Bei gleichem Rechenaufwand das Hundertfache an wirksamen Werten — und die Streuungen 0,099 und 0,999 stimmen in jeder Richtung.

***Der Impuls trägt die Kette über die Verteilung hinweg, statt sie zufällig hin und her zu schieben**: In $L = 20$ Schritten legt sie den Weg $L\varepsilon = 2$ zurück, zwei Standardabweichungen der breitesten Richtung, und kommt mit fast derselben Energie an. Der Zufallsweg braucht für dieselbe Strecke $(2/0{,}071)^2 = 800$ Schritte. Der Preis ist der Gradient ∇U — den man heute, Band 26, Kapitel 13, automatisch erhält. Die Abstimmung von ε und L ist heikel; das Programm Stan erledigt sie selbst (Forschungskasten).*

9.3 Pfade stochastischer Differentialgleichungen

Definition 9.3 — Das Euler–Maruyama-Verfahren

Für $dX = a(X)\,dt + b(X)\,dW$ aus Band 25, Kapitel 7, mit Schrittweite Δt:

$$X_{k+1} = X_k + a(X_k)\,\Delta t + b(X_k)\,\Delta W_k, \qquad \Delta W_k \sim N(0, \Delta t) \text{ unabhängig.}$$

Das **Milstein-Verfahren** fügt $\tfrac{1}{2} b(X_k) b'(X_k) \big(\Delta W_k^2 - \Delta t\big)$ hinzu.

Satz 9.4 — Starke und schwache Ordnung

Unter Lipschitz-Bedingungen an a und b gilt für den Pfadfehler

$$\sqrt{\mathbb{E}\big[(X_T^{\Delta t} - X_T)^2\big]} \le C\,\Delta t^{1/2} \ \text{(Euler)}, \qquad \le C\,\Delta t \ \text{(Milstein)}$$

und für den Fehler im Erwartungswert glatter Funktionen

$$\big|\mathbb{E}[h(X_T^{\Delta t})] - \mathbb{E}[h(X_T)]\big| \le C\,\Delta t \ \text{(beide)}.$$

Beweis

Band 25, Kapitel 8, Satz 8.6 für die starke Ordnung (Auslassung 4 für Milstein); die schwache Ordnung folgt aus der Kolmogorow-Rückwärtsgleichung und einer Taylor-Entwicklung in Δt. ■

Geometrische Brownsche Bewegung, $X_0 = 100$, $a = 0{,}05X$, $b = 0{,}2X$, $T = 1$, 20 000 Pfade

Schritte	stark Euler	stark Milstein	schwach Euler
4	1,53	0,290	0,033
16	0,75	0,074	0,0082
64	0,38	0,018	0,0021
256	0,19	0,0046	0,00051
1 024	0,094	0,0012	0,00013

Viermal so viele Schritte: Euler-Pfadfehler halbiert ($\Delta t^{1/2}$), Milstein geviertelt (Δt), Erwartungswertfehler geviertelt (Δt).

> **Wer einen Erwartungswert will, braucht Euler mit Δt. Wer den Pfad selbst will — eine Barriere, ein Maximum, einen Stopp —, braucht Milstein oder viel kleinere Schritte.**

> ***Der schwache Fehler ist hier exakt berechenbar:*** *$\mathbb{E}[X_T^{\Delta t}] = X_0(1+0{,}05\Delta t)^{1/\Delta t}$ gegen $X_0 e^{0{,}05}$ — die Zinseszinsformel aus Band 2, und ihre Abweichung vom stetigen Zins ist genau der Euler-Fehler. Die starke Ordnung $\frac{1}{2}$ hat denselben Grund wie die Wurzelregel: ΔW ist von der Größe $\sqrt{\Delta t}$, und der erste vernachlässigte Term $bb'(\Delta W^2 - \Delta t)$ ist von der Ordnung Δt je Schritt, über $1/\Delta t$ Schritte summiert mit zufälligem Vorzeichen: $\sqrt{\Delta t}$. Milstein nimmt genau diesen Term mit.*

9.4 Mehrebenen-Monte-Carlo

Satz 9.5 — Die Mehrebenen-Zerlegung

Sei P_ℓ die Auszahlung mit 2^ℓ Schritten. Dann gilt die Teleskopsumme

$$\mathbb{E}[P_L] = \mathbb{E}[P_0] + \sum_{\ell=1}^{L} \mathbb{E}[P_\ell - P_{\ell-1}],$$

und jeder Summand wird mit eigener Pfadzahl N_ℓ geschätzt — P_ℓ und $P_{\ell-1}$ aus *denselben* Brownschen Zuwächsen (Satz 4.3). Ist $\mathrm{Var}[P_\ell - P_{\ell-1}] = V_\ell$ und kostet ein Pfad $C_\ell = 2^\ell$, so minimiert

$$N_\ell \propto \sqrt{V_\ell / C_\ell}$$

die Kosten bei vorgegebener Gesamtvarianz.

Beweis

Die Teleskopsumme ist Algebra. Die Kosten $\sum N_\ell C_\ell$ bei Nebenbedingung $\sum V_\ell/N_\ell = \varepsilon^2/2$ minimiert man mit Lagrange (Band 12): $C_\ell = \lambda V_\ell / N_\ell^2$, also $N_\ell \propto \sqrt{V_\ell/C_\ell}$. ■

Kaufoption $\max(X_T - 100, 0)$, abgezinst; exakt $10{,}451$ (Black–Scholes)

ℓ	**Schritte**	$\mathrm{Var}[P_\ell]$	$\mathrm{Var}[P_\ell - P_{\ell-1}]$	N_ℓ für $\varepsilon = 0{,}02$
0	1	161		1 707 000
1	2	187	2,41	148 000
2	4	202	1,26	75 000
3	8	209	0,70	40 000
4	16	213	0,37	20 000
5	32	216	0,19	10 000
6	64	217	0,095	5 000

Kosten Mehrebenen	$3{,}6 \cdot 10^6$ Schritte
Kosten eine Ebene (64)	$69 \cdot 10^6$ Schritte

Faktor 19 — weil die Varianz der Differenzen mit jeder Ebene halbiert wird und die teuren feinen Pfade nur zu Tausenden statt zu Millionen gebraucht werden.

***Das ist Satz 5.2, rekursiv angewandt**: Die grobe Ebene ist die Kontrollvariable der feinen, und ihr Erwartungswert ist nicht bekannt, sondern wird selbst — billig — geschätzt. **Giles** hat 2008 gezeigt, dass die Gesamtkosten für Genauigkeit ε von ε^{-3} auf $\varepsilon^{-2}(\log \varepsilon)^2$ fallen, wenn V_ℓ wie $2^{-\ell}$ fällt — was bei Euler und Lipschitz-Auszahlung der Fall ist. Für $\varepsilon = 0{,}001$ wird aus dem Faktor 19 ein Faktor von mehreren Hundert.*

9.5 Der Bruchfall

Wenn das Sprungverfahren explodiert

Hamilton-Monte-Carlo mit ε größer als das Doppelte der kleinsten Streuung: Für $U = x^2/(2\sigma^2)$ ist das Sprungverfahren mit $\varepsilon > 2\sigma$ instabil — H wächst exponentiell mit jedem Schritt, die Energie läuft weg, der Vorschlag wird abgelehnt.

ε	Annahme	Zustand
0,10	85 %	gut
0,15	61 %	ΔH bis 5
0,19	43 %	grenzwertig; ΔH bis 20
0,21	0 %	ΔH bis 10^{12}: divergent

Der Übergang ist keine allmähliche Verschlechterung, sondern eine Klippe: Bei $\varepsilon = 2\sigma_{\min}$ kippt das Verfahren.

***Dieselbe Klippe hat Euler–Maruyama**: Für $dX = -\theta X\,dt + dW$ mit $\theta\Delta t > 2$ wächst $|X_k|$ geometrisch, obwohl der wahre Prozess zur Null zurückkehrt. Beides sind Stabilitätsgrenzen expliziter Verfahren, Band 11, Kapitel 9, und beides zeigt sich in der Praxis als "divergente Übergänge" (Stan) oder als Pfade mit 10^{300}. Die Abhilfe ist in beiden Fällen dieselbe: kleinerer Schritt in der steifen Richtung — oder eine Umskalierung der Koordinaten, die alle Streuungen auf eins bringt. Im Hamilton-Verfahren heißt das Massenmatrix, und Stan schätzt sie in der Einschwingphase.*

9.6 Übungsaufgaben

Aufgabe 9.1 — Ein Sprungschritt von Hand

$U(x) = x^2/2$, Start $x = 1$, $p = 0$, $\varepsilon = 0{,}5$, ein Schritt. Berechnen Sie (x', p') und ΔH.

Lösung

Schritt 1 — Halber Impulsschritt

$\nabla U(1) = 1$: $p = 0 - 0{,}25 \cdot 1 = -0{,}25$.

Schritt 2 — Ortsschritt

$x = 1 + 0{,}5 \cdot (-0{,}25) = 0{,}875$.

Schritt 3 — Halber Impulsschritt

$\nabla U(0{,}875) = 0{,}875$: $p = -0{,}25 - 0{,}25 \cdot 0{,}875 = -0{,}469$.

Schritt 4 — Die Energie

$$H_0 = \tfrac{1}{2} + 0 = 0{,}5, \qquad H_1 = \tfrac{1}{2} \cdot 0{,}875^2 + \tfrac{1}{2} \cdot 0{,}469^2 = 0{,}383 + 0{,}110 = 0{,}493$$

$\Delta H = -0{,}007$: Annahme sicher. Die exakte Bahn wäre $x(t) = \cos t$, $x(0{,}5) = 0{,}878$, $p(0{,}5) = -0{,}479$.

> ***Der Fehler in H ist $0{,}007$ bei einem Schritt von $0{,}5$ — und er wächst nicht mit der Zahl der Schritte**: Das Sprungverfahren ist symplektisch, Band 24, und seine Energie schwankt um den wahren Wert, statt wegzulaufen. Das unterscheidet es von Euler, dessen Energiefehler sich aufsummiert. Für Hamilton-Monte-Carlo ist das entscheidend: $L = 100$ Schritte sind so gut annehmbar wie einer.*

Aufgabe 9.2 — Wie viele Schritte für eine Barriere?

Gesucht ist die Wahrscheinlichkeit, dass der Prozess aus Abschnitt 9.3 im Jahr unter 80 fällt. Warum reicht die schwache Ordnung nicht, und was tut man?

Lösung

Schritt 1 — Das Problem

Die Barriere fragt nach dem Minimum des Pfads. Zwischen zwei Gitterpunkten kann der wahre Pfad unter 80 fallen und zurückkehren — das Gitter sieht es nicht. Der Fehler der Trefferwahrscheinlichkeit ist dann von der Ordnung $\sqrt{\Delta t}$, nicht Δt, auch bei glattem a und b.

Schritt 2 — Die Abhilfe

Brownsche Brücke	Zwischen X_k und X_{k+1} ist die Wahrscheinlichkeit, die Barriere B zu kreuzen, bekannt: $\exp\big(-2(X_k-B)(X_{k+1}-B)/(b^2\Delta t)\big)$. Man ziehe mit ihr, ob gekreuzt wurde.
Feineres Gitter	Δt um den Faktor 100 kleiner — hundertfache Kosten für den Faktor 10 im Fehler.

Die Brücke gibt die Ordnung Δt zurück, ohne einen Schritt mehr *— derselbe Gedanke wie die Konditionierung in Satz 5.3: Was man zwischen den Gitterpunkten weiß, rechnet man aus, statt es zu simulieren. Im Mehrebenen-Verfahren ist die Barriere der schwierige Fall, weil $P_\ell - P_{\ell-1}$ dann Sprünge hat und V_ℓ nur wie $2^{-\ell/2}$ fällt; Giles und Mitarbeiter haben dafür eigene Kopplungen entwickelt.*

Aufgabe 9.3 — Die Ebenenzahl wählen

Im Mehrebenen-Beispiel: Bis zu welcher Ebene L muss man gehen, damit der Verfahrensfehler unter $\varepsilon/\sqrt{2} = 0{,}014$ liegt?

Lösung

Schritt 1 — Der Verfahrensfehler

$\mathbb{E}[P_L] - \mathbb{E}[P]$ ist der schwache Fehler mit 2^L Schritten. Aus der Tabelle: Die mittleren Differenzen $\mathbb{E}[P_\ell - P_{\ell-1}]$ fallen von 0,165 über 0,049, 0,010 auf etwa 0,003 bei $\ell = 6$ — grob halbiert je Ebene.

Schritt 2 — Die Restsumme

Bei Halbierung ist der Restfehler nach Ebene L etwa gleich der letzten Differenz: $|\mathbb{E}[P_L - P_{L-1}]|$. Bei $\ell = 5$: 0,0013; bei $\ell = 6$: 0,0026 — beide unter 0,014, und der Unterschied zwischen ihnen ist Rauschen aus 20 000 Pfaden.

Schritt 3 — Die Wahl

$L = 4$ hätte gereicht (0,016 ist knapp drüber, $L = 5$ sicher). Mit $L = 5$ statt 6 sinken die Kosten um weitere 15 %.

> ***Das Verfahren von Giles tut genau das automatisch****: Es beginnt mit drei Ebenen, schätzt V_ℓ und $\mathbb{E}[P_\ell - P_{\ell-1}]$ aus wenigen Pfaden, fügt Ebenen hinzu, bis die letzte Differenz klein genug ist, und verteilt die Pfade nach Satz 9.5. Der Benutzer gibt ε vor und sonst nichts — und bekommt eine Schätzung mit statistischem Fehler $\varepsilon/\sqrt{2}$ und Verfahrensfehler $\varepsilon/\sqrt{2}$, zusammen ε. Das ist die Form, in der die Simulation stochastischer Differentialgleichungen heute in Banken läuft.*

Physiker, Statistiker, Banker

Die drei Verfahren dieses Kapitels kommen aus drei Welten.

Duane*, *Kennedy*, *Pendleton *und* ***Roweth*** *erfanden 1987 das Hamilton-Verfahren für die Gitter-Quantenchromodynamik — Felder mit Millionen Freiheitsgraden, für die der Zufallsweg hoffnungslos war; sie nannten es "Hybrid Monte Carlo".* ***Radford Neal brachte es 1993 in die Statistik****, für neuronale Netze, und sein Übersichtsartikel von 2011 ist bis heute die beste Einführung. Mit Stan, 2012, wurde es das Standardverfahren der angewandten Bayes-Statistik.*

Maruyama und Giles

Gisiro Maruyama *bewies 1955 in Fukuoka die Konvergenz des Euler-Verfahrens für stochastische Gleichungen;* ***Milstein*** *fand 1974 in Swerdlowsk die Korrektur erster Ordnung.* ***Michael Giles, Oxford, veröffentlichte das Mehrebenen-Verfahren 2008****, nach einer Vorarbeit von* ***Heinrich*** *2001 für parametrische Integrale. Innerhalb von zehn Jahren wurde es auf partielle Differentialgleichungen, Markow-Ketten und die Unsicherheitsquantifizierung übertragen — und ist heute die wichtigste Idee des Fachs nach der Wichtigkeitsstichprobe.*

Was die Programme heute tun

NUTS	Die Bahnlänge L selbst wählen: laufen, bis die Bahn umkehrt ("No-U-Turn", Hoffman und Gelman 2014).
Riemann-Hamilton	Die Massenmatrix ortsabhängig aus der Krümmung von U — für Verteilungen mit wechselnder Breite.
Mehrebenen-Ketten	Mehrebenen-Monte-Carlo für Markow-Ketten, mit gekoppelten Ketten auf groben und feinen Modellen.

Zur ersten Zeile

Die Wahl von *L* ***war das letzte Handwerk im Hamilton-Verfahren****: zu kurz, und die Kette kriecht; zu lang, und die Bahn kehrt zum Ausgangspunkt zurück — Rechenzeit für nichts. NUTS baut die Bahn in beide Zeitrichtungen aus, verdoppelt sie, bis sich Anfang und Ende aufeinander zubewegen, und zieht aus allen Punkten der Bahn mit einem Gewicht, das die detaillierte Bilanz erhält. Seit es NUTS gibt, hat der Benutzer nichts mehr einzustellen — und das ist der Grund, warum Mediziner heute hierarchische Modelle mit Tausenden Parametern rechnen, die 1995 Expertenarbeit waren.*

Was Sie jetzt können

Satz 9.2	Hamilton: Impuls, Sprungverfahren, Korrektur
Satz 9.4	Euler stark $\frac{1}{2}$, Milstein 1, schwach 1
Satz 9.5	Mehrebenen: $N_\ell \propto \sqrt{V_\ell / C_\ell}$
Der Bruchfall	$\varepsilon > 2\sigma_{\min}$: Klippe

Teil III hat gezeigt, wie man aus Verteilungen zieht, die man nicht kennt, und Pfade rechnet, die niemand aufschreiben kann. Teil IV kehrt zur Intensivstation zurück — als vollständiges Programm, mit Ereignisliste, Warteschlange und allem, was ein System über die Zeit braucht.

Teil IV

Systeme über die Zeit

Kapitel 10

Die Station als Programm

10.1 Zustand, Ereignis, Uhr

Was eine Simulation über die Zeit braucht

Die Intensivstation hat neun Kapitel lang Zahlen geliefert, ohne dass gesagt wurde, wie das Programm aussieht. Jetzt wird es gesagt, weil jedes System über die Zeit dieselben drei Dinge braucht:

Zustand	Alles, was man wissen muss, um die Zukunft zu simulieren: hier die Entlassungszeiten der belegten Betten.
Ereignisse	Die Zeitpunkte, an denen sich der Zustand ändert: Ankunft, Entlassung. Dazwischen passiert nichts.
Uhr	Die Simulationszeit springt von Ereignis zu Ereignis — nicht in festen Schritten.

Das ist die ereignisgesteuerte Simulation: Zwischen zwei Ereignissen wird nicht gerechnet, weil sich nichts ändert.

***Der Zustand muss markowsch sein**: Aus ihm allein — ohne die Vergangenheit — muss die Zukunft ziehbar sein (Band 25, Kapitel 3). Für exponentielle Verweildauern genügt die Zahl der belegten Betten; für lognormale, die ein Gedächtnis haben, braucht man die Entlassungszeit jedes Patienten. Das ist der Grund, warum Erlang mit einer Zahl rechnen konnte und die Simulation eine Liste führt.*

10.2 Die Ereignisliste

Definition 10.1 — Ereignisliste und Hauptschleife

Die **Ereignisliste** ist eine nach Zeit geordnete Menge von Paaren (Zeit, Art). Die Hauptschleife:

1	Frühestes Ereignis aus der Liste entnehmen; Uhr auf seine Zeit setzen.
2	Zustand gemäß der Ereignisart ändern; Zähler fortschreiben.
3	Folgeereignisse erzeugen und in die Liste einfügen.
4	Zurück zu 1, bis die Uhr das Ende erreicht.

Die Liste wird als **Halde** (Band B, Kapitel 7) geführt: Entnehmen und Einfügen in $O(\log n)$.

Die Intensivstation in zwei Ereignisarten

Ankunft	Nächste Ankunft erzeugen: Uhr $+\,\mathrm{Exp}(1/\lambda)$, einfügen. Verweildauer L ziehen. Ist ein Bett frei: Entlassung bei Uhr $+L$ einfügen, Bett belegen. Sonst: Abweisung zählen.
Entlassung	Bett freigeben.

Die Zähler

Ankünfte, Abweisungen	nach der Einschwingphase: Abweisungsanteil 0,1795
Belegungsintegral	$\int_0^T N(t)\,dt$, fortgeschrieben bei jedem Ereignis als (Zeit seit letztem Ereignis) $\times$ (belegte Betten): mittlere Belegung $L = 9{,}45$

Die Belegung ist ein Zeitmittel, kein Ereignismittel: Man wichtet jeden Zustand mit der Dauer, die er anhielt.

Die Probe — der Satz von Little

Band 25, Satz 11.3: mittlere Belegung = Rate der aufgenommenen $\times$ mittlere Verweildauer:

$$\lambda(1-p)\cdot \bar{L} = 2{,}4 \cdot 0{,}8205 \cdot 4{,}79 = 9{,}43 \qquad \text{gegen} \qquad 9{,}45 \text{ gemessen.}$$

Der Satz von Little ist die erste Probe jeder Simulation über die Zeit, weil er für jedes System gilt, das nichts verliert — ohne Annahme über Verteilungen. Stimmt er nicht, ist das Programm falsch: ein Bett, das nicht freigegeben wird, ein Patient, der doppelt gezählt wird, ein Belegungsintegral, das beim letzten Ereignis nicht abgeschlossen wurde. Die 0,02 Abweichung oben sind der Standardfehler von 20 000 Tagen.

10.3 Zeitschritt statt Ereignis

Die andere Bauart

Man kann die Uhr auch in festen Schritten Δt laufen lassen: in jedem Schritt die Restverweildauern um Δt vermindern, Patienten mit Rest ≤ 0 entlassen, Poisson$(\lambda \Delta t)$ Ankünfte erzeugen.

Abweisungsanteil, je 20 000 **Tage**

Bauart	Δt	**Anteil**
ereignisgesteuert	—	0,1795
Zeitschritt	1 Stunde	0,181
Zeitschritt	6 Stunden	0,179
Zeitschritt	1 Tag	**0,193**

Standardfehler je Zeile etwa 0,004; exakt 0,1785.

Mit Tagesschritten ist der Anteil um 0,014 **zu hoch — vier Standardfehler. Die Zeitschritt-Simulation ist nicht nur ungenauer, sie ist verzerrt.**

Der Grund: Jeder Patient bleibt bis zum Ende des Schritts, in dem seine Verweildauer abläuft *— im Mittel einen halben Schritt zu lang. Bei Tagesschritten sind das zwölf Stunden auf 4,8 Tage, zehn Prozent mehr Belegung, und die Abweisung wächst mit ihr. Mit Stundenschritten ist die Verzerrung unter dem Standardfehler, aber das Programm rechnet 24-mal so viele Schritte wie Ereignisse. Die Zeitschritt-Bauart hat ihren Platz, wo sich der Zustand stetig ändert — Band 25, Kapitel 7, und Kapitel 9 dieses Bandes — oder wo Tausende Teilchen gleichzeitig laufen. Für Systeme mit abzählbaren Ereignissen ist sie der falsche Weg.*

10.4 Die Warteschlange

Was wäre, wenn niemand abgewiesen würde?

Eine Variante: Patienten, für die kein Bett frei ist, warten — auf der Normalstation, im Aufwachraum — und bekommen das nächste freie Bett. Eine dritte Ereignisart ändert sich:

Ankunft	Bett frei: wie bisher. Sonst: Ankunftszeit in die Warteschlange.
Entlassung	Bett freigeben. Ist die Warteschlange nicht leer: ältesten Wartenden aufnehmen, Wartezeit notieren, seine Entlassung einfügen.

Ergebnis, zehn Läufe à 20 000 Tage

	Simulation	**Erlang C**
Anteil, der wartet	$0{,}83 \pm 0{,}01$	0,84
mittlere Wartezeit (alle)	$5{,}5 \pm 0{,}4$ Tage	7,9 Tage
95-Prozent-Quantil	$18 \pm 1{,}5$ Tage	
mittlere Schlangenlänge	13 ± 1	
längste Schlange	123	

Bei Auslastung $a/c = 0{,}96$ wartet fast jeder, im Mittel fast eine Woche, jeder Zwanzigste zweieinhalb. Die Abweisung von 18 % war nicht das Problem — sie war das Ventil.

***Erlang C — Band 25, Satz 11.6, für exponentielle Verweildauern — trifft den Anteil der Wartenden, aber nicht die Wartezeit**: Mit lognormaler Verweildauer, deren Variationskoeffizient 0,66 unter dem exponentiellen 1 liegt, ist die Wartezeit kürzer. Die Unempfindlichkeit, die Erlang B für das Verlustsystem hatte, gilt für das Wartesystem nicht; das ist seit **Kingman** 1961 bekannt, und die Simulation ist für Wartesysteme mit allgemeiner Verweildauer bis heute der einzige exakte Weg. Was die Tabelle noch zeigt: Die Standardfehler sind groß — ±0,4 Tage auf 5,5 bei zweihunderttausend Tagen —, weil ein System an der Kapazitätsgrenze ein langes Gedächtnis hat; Kapitel 4 lässt grüßen. Bei 96 Prozent Auslastung ist die Wartezeit nicht ein Ergebnis, sondern eine Katastrophe — und das nächste Kapitel rechnet, was ein Bett mehr daran ändert.*

10.5 Der Bruchfall

Gleichzeitige Ereignisse

Zwei Ereignisse zur selben Simulationszeit: eine Entlassung und eine Ankunft. Welches zuerst?

Entlassung zuerst	Das Bett ist frei, der Patient wird aufgenommen.
Ankunft zuerst	Die Station ist voll, der Patient wird abgewiesen — und eine Sekunde später ist ein Bett frei.

Bei stetigen Zeiten ist Gleichzeitigkeit ein Nullereignis. Bei Zeitschritten — Tabelle in Abschnitt 10.3 — ist sie der Normalfall. Dort ändert die Reihenfolge innerhalb des Schritts das Ergebnis nicht, weil sie nur jeden Aufenthalt um einen Schritt verschiebt; sie ändert es, sobald Ereignisse auf dasselbe Raster fallen, das auch die Entscheidung benutzt.

In Systemen mit festen Taktzeiten, Schichtwechseln, Visiten um acht Uhr — Entlassungen, die sich auf denselben Zeitpunkt häufen wie Aufnahmen — entscheidet die Reihenfolge, wer ein Bett bekommt.

Die Regel: Die Reihenfolge gleichzeitiger Ereignisse ist eine Modellentscheidung, keine Programmfrage *— und sie muss aufgeschrieben werden. In der Ereignisliste erzwingt man sie durch einen zweiten Schlüssel: (Zeit, Rang, Art), und der Rang legt fest, dass Entlassungen vor Ankünften kommen, oder umgekehrt, je nachdem, was auf der Station wirklich geschieht. Wer es dem Zufall der Halde überlässt, hat ein Programm, dessen Ergebnis von der Implementierung der Halde abhängt — und das ist der Fehler, den niemand findet, weil er in keinem Lauf auffällt.*

10.6 Übungsaufgaben

Aufgabe 10.1 — Drei Ereignisse von Hand

Zwei Betten, Uhr bei 0, Bett 1 belegt bis 1,5, Bett 2 frei. Ankünfte bei 0,4 und 1,2 mit Verweildauern 2,0 und 3,0; die dritte Ankunft bei 1,7. Führen Sie die Ereignisliste bis zur dritten Ankunft.

Lösung

Schritt 1 — Anfang

Liste: $\{(0{,}4, \mathrm{A}), (1{,}5, \mathrm{E}_1)\}$. Belegung: 1.

Schritt 2 — Uhr 0,4, Ankunft

Bett 2 frei: belegen, Entlassung bei 2,4. Nächste Ankunft 1,2. Liste: $\{(1{,}2, \mathrm{A}), (1{,}5, \mathrm{E}_1), (2{,}4, \mathrm{E}_2)\}$. Belegungsintegral $+\,0{,}4 \cdot 1 = 0{,}4$.

Schritt 3 — Uhr 1,2, Ankunft

Beide Betten belegt: Abweisung. Nächste Ankunft 1,7. Liste: $\{(1{,}5, \mathrm{E}_1), (1{,}7, \mathrm{A}), (2{,}4, \mathrm{E}_2)\}$. Integral $+\,0{,}8 \cdot 2 = 2{,}0$.

Schritt 4 — Uhr 1,5, Entlassung Bett 1
Bett 1 frei. Liste: $\{(1{,}7, \mathrm{A}), (2{,}4, \mathrm{E}_2)\}$. Integral $+\,0{,}3 \cdot 2 = 2{,}6$.

Schritt 5 — Uhr 1,7
Ankunft, Bett 1 frei. Integral $+\,0{,}2 \cdot 1 = 2{,}8$; mittlere Belegung bisher $2{,}8/1{,}7 = 1{,}65$.

> ***Der Patient von 1,2 wurde abgewiesen, obwohl 0,3 Zeiteinheiten später ein Bett frei wurde*** *— das ist die Abweisung, die in der Wartevariante zu einer Wartezeit von 0,3 würde. Und die Verweildauer 3,0 dieses Patienten wurde gezogen und verworfen; wer sie nicht zieht, bricht die Synchronität aus Aufgabe 4.3. Fünf Ereignisse von Hand genügen, um zu sehen, dass das Programm nur Buchhaltung ist — und dass jede Zeile Buchhaltung eine Stelle für einen Fehler ist.*

Aufgabe 10.2 — Die Probe mit Little in der Wartevariante

In der Wartevariante gilt Little zweimal. Formulieren Sie beide Gleichungen und prüfen Sie sie mit den Zahlen aus Abschnitt 10.4.

Lösung

Schritt 1 — Die Betten
Niemand wird abgewiesen, also Aufnahmerate $\lambda = 2{,}4$:

$$L_{\text{Betten}} = 2{,}4 \cdot 4{,}79 = 11{,}5 \text{ von } 12$$

Auslastung 0,958 — das ist a/c.

Schritt 2 — Die Schlange

$$L_{\text{Schlange}} = \lambda \cdot \bar{W} = 2{,}4 \cdot 5{,}5 = 13{,}2 \text{ Wartende im Mittel}$$

Schritt 3 — Die Prüfung
Die Simulation hat die mittlere Schlangenlänge als Zeitmittel gezählt: 13 ± 1. Die längste Schlange war 123.

> ***Dreizehn Patienten, die im Mittel auf ein Intensivbett warten, bei einer Station mit zwölf Betten*** *— das ist die Zahl, die ein Klinikleiter sehen muss, und sie folgt aus der Wartezeit durch eine Multiplikation. Little verbindet die Sicht des Patienten (wie lange warte ich) mit der Sicht der Station (wie viele warten), und beide Zahlen aus derselben Simulation müssen zueinander passen. Tun sie es nicht, zählt das Programm an einer Stelle falsch.*

Aufgabe 10.3 — Eine dritte Ereignisart

Die Station soll Vorrang kennen: Notfälle werden aufgenommen, auch wenn dafür der stabilste Patient vorzeitig auf die Normalstation verlegt wird. Was ändert sich am Zustand, an den Ereignissen, an den Zählern?

Lösung

Schritt 1 — Der Zustand

Je Bett nicht nur die Entlassungszeit, sondern auch die Patientenart und die bisherige Liegedauer — um den "stabilsten" zu finden, braucht man ein Kriterium, etwa die kürzeste Restdauer.

Schritt 2 — Die Ereignisse

Ankunft Notfall	Bett frei: aufnehmen. Sonst: Patient mit kürzester Restdauer verlegen (sein Entlassungsereignis aus der Liste entfernen!), Notfall aufnehmen.
Ankunft geplant	wie bisher.
Verlegung	Zähler für vorzeitige Verlegungen; verbleibende Restdauer notieren.

Schritt 3 — Die Zähler

Abweisungen geplanter Patienten; Verlegungen; Verteilung der verlorenen Restdauer — denn eine Verlegung mit zwei Tagen Rest ist etwas anderes als eine mit zwei Stunden.

> ***Das Entfernen eines Ereignisses aus der Liste ist der Punkt, an dem die Halde allein nicht mehr reicht**: Sie kann das Minimum entnehmen, aber kein beliebiges Element. Man markiert das Ereignis als ungültig und überspringt es beim Entnehmen — "faules Löschen", Band B — und zählt, wie viele Leichen in der Liste liegen. Die Modellfrage dahinter ist größer als die Programmfrage: Ist die vorzeitige Verlegung ein Schaden? Dann braucht die Simulation ein Maß dafür, und das Maß kommt nicht aus der Mathematik, sondern von denen, die auf der Station arbeiten.*

Von GPSS zu SimPy

Die ereignisgesteuerte Simulation ist älter als ihre Theorie.

> ***Geoffrey Gordon** bei IBM schrieb 1961 GPSS — General Purpose Simulation System —, in dem man Fertigungsstraßen und Telefonzentralen als Fluss von Transaktionen durch Blöcke beschrieb. **Im selben Jahr begannen Dahl und Nygaard in Oslo mit Simula**, einer Sprache für Simulationen, in der jeder Patient, jedes Bett ein Objekt mit eigenem Zustand war — die erste objektorientierte Sprache, Band B, Kapitel 12, entstanden aus dem Bedürfnis, Ereignislisten sauber zu führen.*

Die Theorie danach

__Little__ bewies seinen Satz 1961 am MIT, nachdem er jahrelang als Faustregel benutzt worden war. __Die Frage, wie man Simulationen über die Zeit statistisch auswertet, beantworteten erst Law und Kelton 1982__ — Kapitel 4 dieses Bandes. SimPy, 2002, brachte die Ereignisliste in Python: Prozesse, die auf Ereignisse warten, in zwanzig Zeilen für die ganze Intensivstation. Der Leser, der bis hier gekommen ist, kann sie schreiben.

Simulation im Krankenhaus heute

Ganze Häuser	Notaufnahme, OP, Intensiv, Normalstation gekoppelt — mit Tagesrhythmus und Wochenrhythmus der Ankünfte.
Digitale Zwillinge	Das Modell läuft neben dem Betrieb und wird mit Echtzeitdaten gespeist; Vorhersage der Belegung für die nächsten 48 Stunden.
Agentenbasiert	Patienten und Personal als Agenten mit Regeln — für Epidemien innerhalb des Hauses.

Zur ersten Zeile

__Der Tagesrhythmus ist die wichtigste Erweiterung des Leitfalls__: Ankünfte in der Notaufnahme sind um 18 Uhr dreimal so häufig wie um 4 Uhr, Entlassungen von Intensivstationen häufen sich vormittags nach der Visite. Beides macht λ und die Verweildauer zeitabhängig — ein inhomogener Poisson-Prozess, Band 25, Kapitel 5, den man durch Ausdünnung erzeugt — und beides erhöht die Abweisungsrate gegenüber dem konstanten Modell, weil Spitzen nicht durch Täler ausgeglichen werden. Studien aus britischen und niederländischen Häusern finden Unterschiede von 20 bis 40 Prozent in der Abweisungsrate; das konstante Modell ist die untere Schranke.

Was Sie jetzt können

Definition 10.1	Ereignisliste, Halde, Hauptschleife
Zähler	Zeitmittel für Zustände, Ereignismittel für Patienten
Little	erste Probe jedes Programms
Zeitschritt	verzerrt um einen halben Schritt
Der Bruchfall	gleichzeitige Ereignisse: Rang festlegen

Die Wartevariante hat eine Zahl geliefert, die niemand hinnehmen würde: eine Woche Wartezeit auf ein Intensivbett. Das nächste Kapitel fragt, was dagegen hilft — ein Bett, zwei Betten, kürzere Verweildauer — und wie man die seltenen Tage findet, an denen die Schlange auf hundert wächst.

Kapitel 11

Was hilft, und wie selten es schlimm wird

11.1 Ein Bett mehr

Vier Eingriffe, je zehn Läufe à 20 000 Tage

Variante	ρ	wartet	Wartezeit	95 %
12 Betten	0,958	0,83	5,5 Tage	18 Tage
13 Betten	0,884	0,56	1,36	5,7
14 Betten	0,821	0,38	0,56	2,9
12, Verweildauer −10 %	0,862	0,53	1,06	4,6
12, Verweildauer −20 %	0,766	0,29	0,30	1,8

Standardfehler der Wartezeit: 0,4 in der ersten Zeile, unter 0,05 in den übrigen.

Ein Bett mehr — acht Prozent Kapazität — senkt die Wartezeit um den Faktor vier. Zehn Prozent kürzere Verweildauer wirken fast gleich. Nichts daran ist linear.

Die Auslastung $\rho = \lambda \bar{L} / c$ ist die einzige Zahl, die zählt, und die Wartezeit explodiert, wenn sie gegen eins geht — der Nenner $1 - \rho$ in jeder Warteschlangenformel aus Band 25, Kapitel 11. Von 0,96 auf 0,88 ist der Nenner dreimal so groß. Das ist der Grund, warum Intensivstationen bei 85 Prozent Auslastung geplant werden sollten und bei 95 Prozent betrieben werden: Die Betriebswirtschaft sieht nur die leeren Betten, die Simulation sieht die Schlange.

Satz 11.1 — Die Näherung von Sakasegawa

Für ein Wartesystem mit c Bedienern, Poisson-Ankünften und Bedienzeiten mit Mittel

S und Variationskoeffizient c_s gilt näherungsweise

$$\bar{W} \approx \frac{\rho^{\sqrt{2(c+1)}-1}}{c\,(1-\rho)} \cdot \frac{1+c_s^2}{2} \cdot S.$$

Beweis

Keiner — es ist eine Interpolationsformel von 1977 zwischen dem exakten $M/M/c$-Ergebnis (Erlang C) und dem exakten $M/G/1$-Ergebnis (Pollaczek–Chintschin, Band 25, Satz 11.8), deren Fehler in Simulationsstudien unter zehn Prozent liegt. ■

Für die Tabelle, $c_s^2 = e^{0{,}36} - 1 = 0{,}433$

Variante	Formel	Simulation
12 Betten	5,7	$5{,}5 \pm 0{,}4$
13 Betten	1,35	1,36
14 Betten	0,57	0,56
−10 %	1,02	1,06
−20 %	0,33	0,30

Die Formel trifft auf zwei Stellen, und sie kostet nichts *— warum dann simulieren? Weil sie nur das Mittel liefert, nicht das 95-Prozent-Quantil, nicht die längste Schlange, nicht den Tagesrhythmus, nicht den Vorrang. Die Simulation liefert alles, und die Formel ist ihre Probe: Stimmen die Mittel überein, darf man den Quantilen trauen. Der Faktor* $(1+c_s^2)/2$ *ist der Grund, warum die log-normale Verweildauer kürzere Wartezeiten gibt als die exponentielle:* 0,72 *statt* 1.

11.2 Wie selten wird die Schlange lang?

Die Frage

Bei dreizehn Betten: Wie wahrscheinlich ist es, dass die Schlange — beginnend mit einem Wartenden — auf sechzig wächst, bevor sie sich geleert hat? In 200 000 Tagen war die längste Schlange 49. Naiv ist nichts zu sehen.

Für exponentielle Verweildauern ist es ein Spielerruin

Solange die Schlange nicht leer ist, sind alle Betten belegt; die Schlange wächst mit Rate $\lambda = 2{,}4$ und schrumpft mit Rate $13/4{,}79 = 2{,}71$. Die eingebettete Kette ist ein Zufallsweg mit $p = 0{,}469$, Band 25, Kapitel 1:

$$P(60 \text{ vor } 0 \mid 1) = \frac{1-r}{1-r^{60}}, \qquad r = \frac{1-p}{p} = 1{,}131 : \qquad 8{,}1 \cdot 10^{-5}.$$

***Für die lognormale Verweildauer gibt es diese Formel nicht** — die Schrumpfrate hängt davon ab, wie lange die dreizehn Patienten schon liegen. Die Formel ist, wie in Satz 11.1, die Probe für das Verfahren, das jetzt kommt; das Verfahren selbst braucht sie nicht.*

Definition 11.2 — Aufspaltung

Man wähle Schwellen $0 < \ell_1 < \ell_2 < \cdots < \ell_m = \ell$ und schätze

$$P(\text{erreicht } \ell) = \prod_{k=1}^{m} P(\text{erreicht } \ell_k \mid \text{erreicht } \ell_{k-1}).$$

Jeden Faktor schätzt man mit Pfaden, die im **Eintrittszustand** der vorigen Schwelle starten: Von N_0 Pfaden erreichen n_1 die Schwelle ℓ_1; jeder wird in R Kopien **aufgespalten**, die unabhängig weiterlaufen; von den Rn_1 erreichen n_2 die Schwelle ℓ_2, und so fort. Der Schätzer ist

$$\hat{P} = \frac{n_1}{N_0} \cdot \frac{n_2}{Rn_1} \cdot \frac{n_3}{Rn_2} \cdots = \frac{n_m}{N_0 R^{m-1}}.$$

Die Aufspaltung im Leitfall

Schwellen $10, 20, \ldots, 60$; $N_0 = 2\,000$, $R = 5$; zwanzig Wiederholungen:

Schwelle	Anteil, exakt	Anteil, 1. Lauf
10	0,054	0,050
20	0,226	0,234
30	0,274	0,291
40	0,287	0,293
50	0,290	0,303
60	0,291	0,288

Schätzung	$(8{,}2 \pm 0{,}2) \cdot 10^{-5}$
exakt	$8{,}1 \cdot 10^{-5}$
Pfade je Lauf	9 600
relativer Fehler je Lauf	12 %
naiv für 12 %	810 000 Pfade

Faktor 84 — und das Verfahren hat keine Dichte verändert, kein Gewicht berechnet, nichts geneigt. Es hat nur die Pfade vervielfacht, die auf dem Weg waren.

***Das ist der Vorzug gegenüber Kapitel 6**: Die Wichtigkeitsstichprobe braucht die Dichte des Pfads — für die lognormale Station ein Produkt über Tausende Ziehungen — und eine Neigung, die man finden muss. Die Aufspaltung braucht nur ein Programm, das man anhalten, kopieren und weiterlaufen lassen kann. Die Regel für die Schwellen: so, dass jeder Faktor etwa 0,2 bis 0,5 beträgt, und $R \approx 1/\text{Faktor}$, damit die Pfadzahl je Stufe ungefähr gleich bleibt. Die erste Stufe hier ist mit 0,05 zu grob — $\ell_1 = 5$ wäre besser gewesen.*

11.3 Der Bruchfall

Der Eintrittszustand, der keiner ist

Bei lognormaler Verweildauer ist der Zustand an der Schwelle nicht die Schlangenlänge, sondern die Schlangenlänge *und* die dreizehn Entlassungszeiten. Wer beim Aufspalten nur die Schlangenlänge kopiert und die Entlassungszeiten neu zieht, simuliert ein anderes System.

Richtig	Den vollständigen Zustand kopieren, einschließlich der Ereignisliste. Jede Kopie bekommt einen eigenen Zufallsstrom ab der Schwelle.
Falsch	Nur den Zähler kopieren. Pfade, die die Schwelle mit dreizehn frisch belegten Betten erreichen — die gefährlichen —, werden durch Pfade mit mittleren Restdauern ersetzt. Die Schätzung ist zu klein.
Auch falsch	Alle Kopien mit demselben Zufallsstrom weiterlaufen lassen. Sie sind dann identisch, und R Kopien sind eine.

Die Kopien müssen am selben Ort beginnen und verschiedene Wege gehen. Beides zugleich, oder das Verfahren ist wertlos.

***Der zweite Fehler ist subtil, weil er erst nach der Schwelle wirkt**: Die Pfade, die eine Schwelle überhaupt erreichen, sind nicht typisch — sie haben eine Häufung langer Verweildauern hinter sich, und die liegt noch in den Betten. Das Vergessen des Zustands ersetzt sie durch typische Pfade und unterschätzt die Fortsetzung um Faktoren. Die Gegenprobe ist die Markow-Variante mit exponentieller Verweildauer, bei der der Zustand nur die Zahl ist: Stimmt sie mit der Formel überein, ist das Verfahren richtig, und erst dann wechselt man zur lognormalen.*

11.4 Übungsaufgaben

Aufgabe 11.1 — Wie viele Betten für zwei Tage?

Welche Bettenzahl bringt das 95-Prozent-Quantil der Wartezeit unter zwei Tage?

Lösung

Schritt 1 — Das Mittel aus Satz 11.1

c	ρ	$\bar{W}$ Formel	95 % Simulation
14	0,821	0,57	2,9
15	0,766	0,28	
16	0,719	0,15	

Schritt 2 — Vom Mittel zum Quantil

Aus der Tabelle in 11.1 ist das Quantil durchweg etwa das Fünffache des Mittels: $18/5{,}5 = 3{,}3$, $5{,}7/1{,}36 = 4{,}2$, $2{,}9/0{,}56 = 5{,}2$, $1{,}8/0{,}30 = 6$ — das Verhältnis wächst, wenn weniger warten, weil die Nullen das Mittel drücken. Für $c = 15$ also etwa $5{,}5 \cdot 0{,}28 = 1{,}5$ Tage.

Schritt 3 — Die Antwort

15 Betten; 14 reichen nicht. Zur Sicherheit: ein Lauf mit 15 Betten, der das Quantil direkt misst.

> ***Das Verfahren ist typisch: Formel zum Eingrenzen, Simulation zum Entscheiden.*** *Die Formel sagt, dass 15 oder 16 in Frage kommen; ein einziger Simulationslauf je Variante klärt es. Der Fehler wäre, zehn Varianten zu simulieren, ohne vorher die Formel zu befragen — oder der Formel das Quantil zu glauben, das sie nicht kennt.*

Aufgabe 11.2 — Die Faktoren der Aufspaltung

Leiten Sie die exakten Anteile 0,054 und 0,291 aus der Tabelle in Abschnitt 11.2 her.

Lösung

Schritt 1 — Von 1 nach 10 vor 0

Spielerruin mit $r = 1{,}131$, Start 1, Ziel 10:

$$\frac{1 - r^{1}}{1 - r^{10}} = \frac{-0{,}131}{1 - 3{,}42} = 0{,}054$$

Schritt 2 — Von 50 **nach** 60 **vor** 0

$$\frac{1-r^{50}}{1-r^{60}} = \frac{1-471}{1-1\,613} = 0{,}291$$

Schritt 3 — Warum die Faktoren sich stabilisieren

Für große k ist $r^{\ell_k} \gg 1$, und der Quotient geht gegen $r^{-10} = 1{,}131^{-10} = 0{,}291$: die Wahrscheinlichkeit, zehn Stufen zu steigen, bevor man *je* auf null fällt. Ab Schwelle 30 ist die Null praktisch unerreichbar, und jede Stufe kostet denselben Faktor.

> ***Das ist die Signatur eines Systems mit Drift**: Die Wahrscheinlichkeit, Höhe ℓ zu erreichen, fällt wie $r^{-\ell}$ — exponentiell — und jede weitere Schwelle multipliziert mit derselben Zahl. Für die Planung der Aufspaltung heißt das: gleichmäßige Schwellen sind richtig, wenn die Drift konstant ist. Bei der lognormalen Station ist sie es nicht ganz, und man setzt die Schwellen nach einem Vorlauf dort, wo die Anteile gleich werden.*

Aufgabe 11.3 — Von der Wahrscheinlichkeit zur Häufigkeit

Wie oft im Jahr erreicht die Schlange bei dreizehn Betten die Sechzig?

Lösung

Schritt 1 — Die Zyklen

Jedes Mal, wenn die Schlange von null auf eins springt, beginnt ein Versuch. Bei dreizehn Betten warten 56 % der 2,4 Ankünfte je Tag; die Zahl der Zyklen je Tag ist die Rate, mit der die leere Schlange verlassen wird — grob die Ankunftsrate mal die Wahrscheinlichkeit, dass alle Betten belegt und niemand wartet: etwa $2{,}4 \cdot 0{,}15 = 0{,}36$ je Tag, 130 im Jahr.

Schritt 2 — Die Häufigkeit

$$130 \cdot 8{,}1 \cdot 10^{-5} = 0{,}011 \text{ je Jahr} \qquad \text{— einmal in hundert Jahren.}$$

Schritt 3 — Und bei zwölf Betten

$r = 1/\rho = 1{,}044$, $r^{60} = 13{,}1$, $P = 0{,}044/12{,}1 = 0{,}0036$; mit etwa 100 Zyklen im Jahr: 0,36 je Jahr — **alle drei Jahre**. Die Simulation über 200 000 Tage sah sie zweimal.

> ***Ein Bett verwandelt ein Ereignis alle drei Jahre in eines alle hundert**: Das ist die Zahl, die in einen Antrag auf Erweiterung gehört, und sie ist ohne Kapitel 6 oder 11 nicht zu haben, weil kein Krankenhaus hundert Jahre Daten hat. Die Zyklenzahl in Schritt 1 ist eine grobe Schätzung — sie wäre in der Simulation direkt zu zählen, und wer die Zahl verwendet, sollte das tun.*

Von Kahn bis RESTART

Die Aufspaltung ist die zweite Erfindung von **Kahn** und **Harris** 1951 — im selben

Aufsatz wie die Wichtigkeitsstichprobe.

Neutronen, die tief in die Abschirmung eindrangen, wurden in Kopien aufgespalten, und Neutronen, die zurückkehrten, mit "russischem Roulette" — Band 25 — getötet, um Rechenzeit zu sparen. ***Dass dasselbe für Warteschlangen und Netze funktioniert, zeigten Villén-Altamirano und Villén-Altamirano 1991 unter dem Namen RESTART*** *— für Verlustwahrscheinlichkeiten von 10^{-9} in Telefonvermittlungen, die man für die Zulassung nachweisen musste.*

Die Theorie

Glasserman, ***Heidelberger***, ***Shahabuddin*** *und* ***Zajic*** *bewiesen 1999, wann die Aufspaltung effizient ist: Die Faktoren müssen etwa gleich sein, und ihre Zahl muss wie $\log(1/P)$ wachsen.* ***Cérou und Guyader machten 2007 die Schwellen adaptiv*** *— das Verfahren setzt sie selbst so, dass jeder Faktor ein vorgegebener Anteil ist — und verbanden es mit den Teilchenfiltern aus Kapitel 12.*

Seltene Ereignisse in Systemen

Kreuzentropie	Die Neigung aus Kapitel 6 in Runden lernen: simulieren, die Pfade behalten, die am weitesten kamen, die Parameter an sie anpassen, wiederholen (**Rubinstein** 1999).
Subset-Simulation	Aufspaltung mit Markow-Ketten statt Kopien — für Versagenswahrscheinlichkeiten in der Bauingenieurkunst.
Große Abweichungen	Die Theorie aus Band 25, Kapitel 9 liefert die asymptotisch optimale Neigung in geschlossener Form.

Zur ersten Zeile

Die Kreuzentropie-Methode beantwortet die Frage, die Aufgabe 6.2 offenließ — welches λ'?: *Man simuliere mit λ, nehme die zehn Prozent der Tage mit den meisten Abweisungen und schätze aus ihnen die Ankunftsrate, die sie am besten erklärt — das ist λ' für die nächste Runde. Nach drei bis fünf Runden ist das Ereignis typisch, und die letzte Runde liefert mit den Gewichten aus Kapitel 6 die Schätzung. Der Name kommt daher, dass die Anpassung die Kreuzentropie zur optimalen Dichte g^* aus Satz 6.2 minimiert, Band 23. Für die Intensivstation ist das Verfahren einfacher als die Aufspaltung; für Systeme ohne natürliche Parameterfamilie ist die Aufspaltung einfacher. Beides zu kennen ist der Stand.*

Was Sie jetzt können

Die Auslastung	ρ gegen 1: Wartezeit explodiert
Satz 11.1	Sakasegawa als Probe für das Mittel
Definition 11.2	Aufspaltung: Schwellen, Kopien, Produkt
Die Regel	Faktoren 0,2–0,5, $R \approx 1/\text{Faktor}$
Der Bruchfall	den ganzen Zustand kopieren

Alle Simulationen bis hierher haben das System gekannt und seine Zukunft erzeugt. Das nächste Kapitel dreht die Richtung um: Das System ist nur durch verrauschte Messungen bekannt — die Belegung von gestern, die Zahlen von heute Morgen — und gesucht ist, was jetzt wirklich los ist.

Kapitel 12

Was jetzt gerade los ist

12.1 Die umgekehrte Frage

Die Ankunftsrate ist nicht konstant

Elf Kapitel lang war $\lambda = 2{,}4$. In Wirklichkeit schwankt die Rate — Grippewellen, Hitzeperioden, ein neues Zuweiserkrankenhaus —, und was die Station jeden Morgen sieht, ist nicht λ_t, sondern die Zahl der Ankünfte von gestern: 1, 3, 2, 5, 2.

> **Gesucht ist λ_t heute, aus allen Zählungen bis heute. Das ist die Umkehrung der Simulation: nicht aus dem Zustand die Beobachtung erzeugen, sondern aus den Beobachtungen auf den Zustand schließen.**

Das Modell — Band 25, Kapitel 12

$$\ln \lambda_t = \ln \lambda_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0,\, 0{,}05^2) \qquad\qquad Y_t \mid \lambda_t \sim \text{Poisson}(\lambda_t)$$

Ein verborgener Zustand mit eigener Dynamik, eine verrauschte Beobachtung je Tag.

> ***Das Filterproblem fragt nach*** $p(\lambda_t \mid Y_1, \ldots, Y_t)$ *— der Verteilung des heutigen Zustands gegeben alles Bisherige. Für lineare Modelle mit Normalverteilungen löst es der Kalman-Filter aus Band 25 in geschlossener Form. Für Poisson-Zählungen mit logarithmischem Zufallsweg gibt es keine Formel. Es gibt aber die Simulation, und dieses Kapitel baut aus ihr einen Filter — mit genau den Werkzeugen der Kapitel 6 und 11.*

12.2 Der Teilchenfilter

Definition 12.1 — Der Teilchenfilter (Bootstrap-Filter)

N **Teilchen** $x_t^{(1)}, \ldots, x_t^{(N)}$ stellen die Filterverteilung dar. Je Zeitschritt:

Vorhersage	Jedes Teilchen nach der Zustandsdynamik weiterziehen: $x_t^{(i)} = x_{t-1}^{(i)} + \varepsilon_t^{(i)}$.
Gewichtung	$w^{(i)} \propto p(Y_t \mid x_t^{(i)})$ — die Likelihood der heutigen Beobachtung.
Neuziehung	N Teilchen mit Zurücklegen nach den Gewichten ziehen; alle Gewichte auf $1/N$ setzen.

Die Filterverteilung wird durch die gewichteten Teilchen genähert: $\mathbb{E}[h(x_t) \mid Y_{1:t}] \approx \sum_i w^{(i)} h(x_t^{(i)})$.

Satz 12.2 — Warum das die Filterverteilung ist

Die Teilchen nach der Vorhersage sind Ziehungen aus $p(x_t \mid Y_{1:t-1})$; die Gewichtung ist die Wichtigkeitsstichprobe aus Kapitel 6 mit Vorschlag $p(x_t \mid Y_{1:t-1})$ und Ziel $p(x_t \mid Y_{1:t}) \propto p(Y_t \mid x_t)\, p(x_t \mid Y_{1:t-1})$ — der Satz von Bayes, Band 21. Die Neuziehung ersetzt gewichtete durch ungewichtete Teilchen mit derselben Verteilung.

Beweis

Induktion über t: Sind die Teilchen zur Zeit $t-1$ aus der Filterverteilung, so sind sie nach der Vorhersage aus der Vorhersageverteilung (Vorwärtsgleichung, Band 25), nach der Gewichtung nach Definition 6.1 eine gewichtete Darstellung der Filterverteilung, und nach der Neuziehung eine ungewichtete. Die Neuziehung fügt Varianz hinzu, keinen Fehler (Satz 5.3 rückwärts). ■

Der Teilchenfilter ist Wichtigkeitsstichprobe, Tag für Tag, mit der Simulation als Vorschlagsdichte.

Ergebnis, 200 **Tage,** 1 000 **Teilchen**

Schätzer für λ_t	**Wurzel des mittleren Fehlerquadrats**
die Zählung Y_t selbst	1,59
Sieben-Tage-Mittel	0,60
Kalman-Filter auf $\sqrt{Y_t}$	0,45
Teilchenfilter	**0,42**

Das 90-Prozent-Intervall des Filters, Breite im Mittel 1,5, enthielt den wahren Wert an 94 % der Tage.

***Der Fehler* 0,42 *bei einer Rate um* 2,5 *ist nicht die Schwäche des Filters, sondern die der Daten**: Drei Ankünfte am Tag verraten über λ nicht viel, und keine Methode kann aus ihnen mehr herausholen, als drin ist. Was der Filter gegenüber dem Mittelwert gewinnt, ist das Modell — er weiß, wie schnell sich λ ändern kann — und was er gegenüber dem Kalman-Filter gewinnt, ist die richtige Verteilung statt einer genäherten. Der eigentliche Gewinn ist das Intervall: "λ liegt heute mit 90 Prozent zwischen 2,0 und 3,5" ist eine Aussage, die ein gleitendes Mittel nicht machen kann.*

12.3 Wozu die Neuziehung

Die Degeneration

Ohne Neuziehung multiplizieren sich die Gewichte von Tag zu Tag. Wirksame Teilchenzahl n_{eff} aus Kapitel 6, $N = 1\,000$:

Tag	1	5	20	50	200
n_{eff}	712	389	196	39	**2**

Mit Neuziehung jeden Tag: n_{eff} im Mittel 929, nie unter 344. Der Fehler ohne Neuziehung: 0,52 statt 0,42 — und nach Tag 200 wäre es ein einziges Teilchen.

Ein Teilchen, das vor fünfzig Tagen einmal zu hoch lag, trägt diese Schuld für immer. Die Neuziehung vergibt sie: Sie vervielfacht die Teilchen, die heute passen, und lässt die anderen sterben.

***Das ist die Aufspaltung aus Kapitel 11, mit der Likelihood als Schwelle**: Gute Pfade werden kopiert, schlechte getötet, und die Gesamtzahl bleibt konstant. Die Verbindung ist kein Zufall — Teilchenfilter und Aufspaltung sind dieselbe Idee, und die Theorie von **Del Moral** behandelt beide als "Feynman-Kac-Teilchensysteme". Die Faustregel: neu ziehen, wenn $n_{\text{eff}} < N/2$; jeden Tag neu zu ziehen kostet etwas Genauigkeit durch das Ziehungsrauschen, ist aber harmlos. Und $N = 50$ reicht für dieses Problem — der Fehler 0,39 bei $N = 50$ ist nicht schlechter als 0,43 bei 5 000, weil die Daten die Grenze setzen.*

12.4 Was der Filter noch kann

Drei Fragen, dieselben Teilchen

Vorhersage	Die Teilchen k Tage weiterziehen, ohne zu gewichten: $p(\lambda_{t+k} \mid Y_{1:t})$. Und mit jedem Teilchen die Station simulieren — Kapitel 10 — für die Belegung der nächsten Woche.
Likelihood	Das Mittel der ungenormten Gewichte je Tag, multipliziert über die Tage, schätzt $p(Y_{1:T})$ — die Grundlage, um Modelle zu vergleichen oder $s = 0{,}05$ zu schätzen (Band 21).
Glättung	Rückwärts durch die Vorfahren der Teilchen: $p(\lambda_t \mid Y_{1:T})$ für vergangene Tage — genauer als der Filter, weil die Zukunft mitspricht.

***Die erste Zeile ist der Grund für dieses Kapitel im Buch**: Die Filterverteilung ist der Anfangszustand für die Simulation der nächsten Woche — nicht ein Schätzwert, sondern tausend gewichtete Möglichkeiten, aus denen jede ihre eigene Woche erzeugt. Die Belegung am Freitag kommt dann als Verteilung heraus, und sie enthält beides: die Unsicherheit über λ heute und den Zufall der Woche. Kapitel 14 nennt das Unsicherheitsquantifizierung; hier ist es nur die konsequente Anwendung von Band 21 auf ein System, das läuft.*

12.5 Der Bruchfall

Das falsche Modell filtert trotzdem

Dieselben Daten, derselbe Filter, aber die Dynamik falsch angenommen:

angenommenes s	**Fehler**	**Überdeckung** 90 %
0,01 (zu starr)	0,41	**66** %
0,05 (wahr)	0,42	94 %
0,20 (zu beweglich)	0,64	100 %

Der zu starre Filter hat denselben Fehler wie der richtige — und Intervalle, die den wahren Wert in einem Drittel der Tage verfehlen. Er ist sich sicher und hat unrecht.

> ***Ein Filter liefert immer eine Verteilung, auch für ein falsches Modell*** — *es gibt keinen Fehlerausgang "das Modell passt nicht". Die Prüfung muss von außen kommen: Sind die Beobachtungen, die der Filter für morgen vorhersagt, mit dem verträglich, was morgen eintritt? Das* ***Vorhersage-Residuum*** Y_t *gegen* $p(Y_t \mid Y_{1:t-1})$ *ist dafür der Maßstab, und bei* $s = 0{,}01$ *häufen sich die Überraschungen: Tage, an denen die Zählung außerhalb des vorhergesagten 95-Prozent-Bereichs liegt, zehn Prozent statt fünf. Wer einen Filter betreibt, betreibt diese Prüfung mit. Und beim Bruchfall mit zu starrem Modell hilft nicht mehr Teilchen, sondern das Modell: s aus der Likelihood schätzen, zweite Zeile im Kasten oben.*

12.6 Übungsaufgaben

Aufgabe 12.1 — Ein Filterschritt mit vier Teilchen

Vier Teilchen stehen nach der Vorhersage bei $\lambda = 1{,}5,\ 2{,}0,\ 3{,}0,\ 4{,}0$. Beobachtet werden $Y_t = 4$ Ankünfte. Berechnen Sie die Gewichte und das Filtermittel.

Lösung

Schritt 1 — Die Likelihood
$p(4 \mid \lambda) = \lambda^4 e^{-\lambda}/24$:

λ	$\lambda^4 e^{-\lambda}$	$\div 24$
1,5	1,13	0,035
2,0	2,17	0,068
3,0	4,03	0,126
4,0	4,69	0,146

Normiert (Summe 12,02): 0,094, 0,181, 0,336, 0,390.

Schritt 2 — Das Filtermittel

$$0{,}094 \cdot 1{,}5 + 0{,}181 \cdot 2{,}0 + 0{,}336 \cdot 3{,}0 + 0{,}390 \cdot 4{,}0 = 3{,}07$$

Vor der Beobachtung war das Mittel 2,625; vier Ankünfte haben es um 0,45 angehoben.

Schritt 3 — Die Neuziehung
$n_{\text{eff}} = 1/\sum w^2 = 1/0{,}306 = 3{,}3$ von 4; man zieht viermal mit Zurücklegen — etwa $\{2{,}0; 3{,}0; 4{,}0; 4{,}0\}$ — und setzt alle Gewichte auf $\frac{1}{4}$.

> ***Vier Teilchen sind kein Filter, aber sie zeigen die Mechanik****: Die Beobachtung verschiebt das Gewicht, nicht die Teilchen; erst die Vorhersage des nächsten Tags bewegt sie, und erst die Neuziehung räumt die unwahrscheinlichen weg. Das Teilchen bei* 1,5 *hat nach vier Ankünften noch 9 Prozent — weil vier Ankünfte bei* $\lambda = 1{,}5$ *unwahrscheinlich sind, aber nicht unmöglich. Mit* $Y_t = 8$ *fiele es auf* 0,4 *Prozent.*

Aufgabe 12.2 — Der Kalman-Filter als Sonderfall

Für $x_t = x_{t-1} + \varepsilon_t$, $Y_t = x_t + \eta_t$ mit $\varepsilon \sim N(0, q)$, $\eta \sim N(0, r)$: Zeigen Sie, dass die Filterverteilung normal bleibt und leiten Sie den Schritt her.

Lösung

Schritt 1 — Vorhersage

Ist $x_{t-1} \mid Y_{1:t-1} \sim N(m, P)$, so ist $x_t \mid Y_{1:t-1} \sim N(m, P + q)$ — Summe unabhängiger Normalverteilungen.

Schritt 2 — Gewichtung

Normal mal Normal ist normal (Band 21, Satz 4.2):

$$x_t \mid Y_{1:t} \sim N\big(m + K(Y_t - m),\ (1 - K)(P + q)\big), \qquad K = \frac{P + q}{P + q + r}.$$

Schritt 3 — Die Deutung

K ist der **Kalman-Gewinn**: Bei kleinem Messrauschen r ist $K \to 1$ und der Filter glaubt der Messung; bei kleinem q ist $K \to 0$ und er glaubt dem Modell.

> ***Der Teilchenfilter braucht keinen dieser Schritte, weil die Teilchen die Verteilung sind, welche Form sie auch hat*** *— der Preis ist das Rauschen von N Ziehungen gegen eine exakte Formel. Für die Zählungen oben wurde der Kalman-Filter auf $\sqrt{Y_t + 3/8}$ angewandt, dessen Varianz nach Band 17 annähernd $\frac{1}{4}$ ist, unabhängig von λ — ein alter Trick, der ein Poisson-Problem in ein normales verwandelt. Er kostete* 0,03 *an Genauigkeit. In zwei Dimensionen wäre das Verhältnis dasselbe; in zweihundert ist der Teilchenfilter am Ende, Forschungskasten, und der Kalman-Filter läuft noch.*

Aufgabe 12.3 — Die Belegung am Freitag

Es ist Montag; der Filter gibt für λ tausend Teilchen. Beschreiben Sie, wie Sie die Verteilung der Belegung am Freitag berechnen, und was darin steckt.

Lösung

Schritt 1 — Der Anfangszustand

Der Zustand der Station heute — belegte Betten mit Entlassungszeiten — ist bekannt; nur λ nicht.

Schritt 2 — Die Läufe

Für jedes Teilchen $\lambda^{(i)}$: den Zufallsweg für $\ln \lambda$ vier Tage weiterziehen, die Station mit diesen Raten vier Tage simulieren (Kapitel 10), die Belegung am Freitag notieren.

Schritt 3 — Das Ergebnis

Tausend Belegungen; ihr Histogramm ist die Vorhersageverteilung. Ihre Streuung setzt sich zusammen aus

Parameterunsicherheit	verschiedene $\lambda^{(i)}$ — die Breite des Filters
Dynamik	λ ändert sich bis Freitag
Zufall der Woche	Ankünfte und Verweildauern — auch bei bekanntem λ

***Die Varianzzerlegung aus Satz 5.3 trennt die drei Anteile**: Simuliert man je Teilchen zehn Wochen statt einer, so ist die Varianz innerhalb der Teilchen der Zufall der Woche, die zwischen den Teilchen die Unsicherheit über λ. Für die Station ist meist die Woche der größere Anteil — bei 2,4 Ankünften am Tag und vier Tagen Horizont dominiert der Poisson-Zufall. Das heißt auch: Ein besserer Filter würde die Vorhersage kaum schärfen. Der Wert des Filters liegt nicht in der Freitagsvorhersage, sondern darin, eine Änderung von λ Wochen früher zu bemerken als das Bauchgefühl der Stationsleitung.*

Vom Mond zum Teilchen

Der Kalman-Filter von 1960 brachte Apollo zum Mond — die Bahnbestimmung aus verrauschten Radarmessungen lief in Echtzeit auf dem Bordrechner.

*Für nichtlineare Probleme behalf man sich dreißig Jahre mit Linearisierung — dem "erweiterten" Kalman-Filter —, der bei starker Nichtlinearität versagt. **Gordon, Salmond und Smith veröffentlichten 1993 den Bootstrap-Filter** für die Zielverfolgung bei der britischen Marine; der Name Teilchenfilter stammt von **Del Moral** 1996, der die Verbindung zur Physik der Feynman-Kac-Formeln sah. Fast gleichzeitig und unabhängig fanden **Kitagawa** in Tokio und **Isard** und **Blake** in Oxford dasselbe Verfahren — für Zeitreihen und für das Verfolgen von Objekten in Videobildern.*

Warum erst 1993

*Die Wichtigkeitsstichprobe für Zeitreihen war seit den 1970er Jahren bekannt — und wegen der Degeneration aufgegeben worden. **Die Neuziehung war die Erfindung**, und sie war so einfach, dass sie jahrzehntelang niemand für nötig hielt. Seit es sie gibt, laufen Teilchenfilter in Flugzeugen, in Robotern, in Epidemiemodellen — und in der Rekonstruktion der Reproduktionszahl im Jahr 2020, die wöchentlich in den Nachrichten stand.*

Teilchenfilter heute

Hohe Dimension	Bei d Zustandskoordinaten braucht der Bootstrap-Filter $N \sim e^{cd}$ Teilchen — für die Wettervorhersage mit 10^9 Koordinaten unmöglich; Ensemble-Kalman-Filter als Kompromiss.
Teilchen-MCMC	Der Filter als Likelihood-Schätzer in einer Metropolis-Kette für die Parameter — Kapitel 7 und 12 verbunden (**Andrieu**, **Doucet**, **Holenstein** 2010).
Differenzierbare Filter	Neuziehung so, dass man durch den Filter ableiten und die Parameter per Gradient anpassen kann.

Zur zweiten Zeile

***Das Likelihood-Schätzer aus dem Kasten in 12.4 ist verrauscht — und trotzdem darf man ihn in einen Metropolis-Quotienten einsetzen**: Andrieu, Doucet und Holenstein bewiesen, dass die Kette dann die exakte A-posteriori-Verteilung der Parameter hat, solange der Schätzer erwartungstreu ist — was der Teilchenfilter nach Del Moral ist. Das heißt: s, die A-priori-Verteilung, die Form der Dynamik — alles lässt sich aus den Zählungen schätzen, ohne eine Formel für die Likelihood zu besitzen. "Pseudo-marginale" Verfahren heißen sie, und sie sind der Grund, warum Modelle mit verborgenen Zuständen heute Routine sind, die 2005 unlösbar waren.*

Was Sie jetzt können

Definition 12.1	Vorhersage, Gewichtung, Neuziehung
Satz 12.2	Wichtigkeitsstichprobe, Tag für Tag
Degeneration	n_{eff} fällt ohne Neuziehung auf 1
Der Bruchfall	falsches Modell: sicher und falsch

Teil IV hat die Station als Programm gebaut, verbessert, an ihre seltenen Grenzen geführt und aus Beobachtungen zurückgeschlossen. Teil V fragt, was nötig ist, damit ein anderer dasselbe Ergebnis bekommt — und was man einem Ergebnis glauben darf, das aus einem Modell kommt, dessen Parameter niemand genau kennt.

Teil V

Die Praxis

Kapitel 13

Dasselbe noch einmal

13.1 Was Reproduzierbarkeit heißt

Drei Stufen

Bitgenau	Derselbe Startwert, dasselbe Programm, dieselbe Zahl bis zur letzten Stelle: 0,186134772708 — heute und in zehn Jahren.
Statistisch	Ein anderer Startwert gibt eine andere Zahl, 0,1678, und beide liegen innerhalb ihrer Standardfehler beim selben Wert.
Sachlich	Ein anderes Programm, von jemand anderem nach der Beschreibung geschrieben, gibt dasselbe Ergebnis — oder deckt auf, dass die Beschreibung unvollständig war.

Die erste Stufe ist eine Programmfrage, die zweite eine Statistikfrage, die dritte die einzige, die zählt. Dieses Kapitel handelt von allen dreien.

Eine Simulation, die nicht reproduzierbar ist, ist eine Anekdote. *Die Zahl* 0,1861 *oben ist der Abweisungsanteil aus* 5 000 *Tagen mit Startwert* 42*; sie weicht vom exakten Wert* 0,1785 *um zwei Standardfehler ab, und ohne den Startwert könnte niemand prüfen, ob das Zufall oder ein Fehler ist. Mit dem Startwert kann jeder den Lauf wiederholen, den Fehler einkreisen und — das ist der eigentliche Zweck — den Lauf mit einem geänderten Programm wiederholen und sehen, ob sich nur das ändert, was sich ändern sollte.*

13.2 Startwerte und Ströme

Regeln für den Zufall im Programm

Startwert sichtbar	Nie die Uhr als Startwert ohne ihn zu protokollieren. Der Startwert gehört in die Ausgabe, neben das Ergebnis.
Ein Strom je Zweck	Ankünfte, Verweildauern, Entscheidungen: je ein eigener Generator — Aufgabe 4.3.
Abgeleitete Ströme	Die Ströme für parallele Läufe nicht mit $1, 2, 3, \ldots$ starten, sondern aus einem Hauptstartwert ableiten: *SeedSequence*, *jumped*, *spawn* — Kapitel 2.
Generator benennen	PCG64, Mersenne-Twister, Philox: Der Name und die Version gehören ins Protokoll, weil derselbe Startwert in verschiedenen Generatoren verschiedene Folgen gibt.

Warum nicht $1, 2, 3$

Bei einem linearen Kongruenzgenerator liegen die Folgen zu Startwerten 1 und 2 nicht weit auseinander: Beide durchlaufen denselben Zyklus, und der Abstand zwischen ihnen ist eine feste, unbekannte Zahl von Schritten. Bei vierzig parallelen Läufen mit je 10^6 Zahlen aus einem Zyklus von 2^{31} überlappen sich zwei von ihnen mit Wahrscheinlichkeit um $40^2 \cdot 10^6 / 2^{31} \approx 0{,}7$.

Überlappende Ströme sind gemeinsame Zufallszahlen, die man nicht wollte: Die Läufe sind korreliert, und der Standardfehler aus Kapitel 4 ist zu klein.

Moderne Generatoren haben Perioden von 2^{128} ***und mehr, und das Problem ist dort praktisch verschwunden*** *— aber nicht aus dem Lehrbuch, weil der Fehler mit alten Generatoren noch in laufenden Programmen steckt. Die saubere Lösung, die SeedSequence von NumPy seit 2019 bietet: Aus einem Hauptstartwert werden Kindstartwerte so abgeleitet, dass ihre Ströme nach allen bekannten Tests unabhängig sind, und jedes Kind kann wieder Kinder haben. Vierzig Läufe sind dann vierzig Kinder von* 2026*, und das Protokoll braucht nur die eine Zahl.*

13.3 Das Programm prüfen

Satz 13.1 — Die Prüfleiter

Ein Simulationsprogramm ist geprüft, wenn es diese Stufen bestanden hat, in dieser Reihenfolge:

1	**Erhaltung**	Was hineingeht, kommt heraus: Ankünfte = Aufnahmen + Abweisungen. Little.
2	**Grenzfälle**	$\lambda \to 0$: keine Abweisung. Betten $\to \infty$: keine Abweisung. Verweildauer 0: keine Abweisung. Ein Bett: Erlang mit $c = 1$ von Hand.
3	**Formel**	Ein Sonderfall mit exakter Lösung: exponentielle Verweildauer gegen Erlang B, mit Standardfehler.
4	**Unempfindlichkeit**	Lognormal gegen exponentiell bei gleichem Mittel: gleiches Ergebnis, Satz aus Band 25.
5	**Zweites Programm**	Ein anderer schreibt es nach der Beschreibung. Abweichungen sind Lücken in der Beschreibung.

Beweis

Keine Prüfung beweist Korrektheit; jede Stufe schließt eine Klasse von Fehlern aus. Stufe 1 findet Buchhaltungsfehler, 2 Vorzeichen- und Grenzfehler, 3 Fehler in der Logik, 4 Fehler in der Verteilung, 5 Fehler im Verständnis. ■

Zwei Fehler, die alle Stufen bis 2 bestehen

Programm	Anteil	Urteil
richtig	$0{,}1826 \pm 0{,}0018$	✓
“voll” bei 11 statt 12	$0{,}2308 \pm 0{,}0018$	Stufe 3
Entlassungen *nach* der Aufnahme geprüft	$0{,}2191 \pm 0{,}0016$	Stufe 3
exakt	0,1785	

Beide Fehler erhalten die Buchhaltung, bestehen alle Grenzfälle — und liegen um ein Viertel daneben. Erst die Formel entlarvt sie.

***Der zweite Fehler ist der lehrreiche**: Ein Patient kommt um 10 Uhr, ein Bett wird um 9 Uhr frei — aber das Programm prüft erst nach der Aufnahmeentscheidung, welche Entlassungen fällig waren. Das Bett ist frei, der Patient wird abgewiesen. Es ist die Reihenfolge-Frage aus dem Bruchfall in Kapitel 10, nicht bei gleichzeitigen Ereignissen, sondern bei allen; und sie ist in jedem Zeitschritt-Programm und in jeder Hauptschleife eine Zeile, die man leicht falsch setzt. Die Stufe 3 ist deshalb nicht Luxus: **Für jedes Modell gibt es einen Sonderfall mit Formel**, und wer ihn nicht findet, hat das Modell nicht verstanden.*

13.4 Der Bericht

Was in jeden Simulationsbericht gehört

Modell	Zustand, Ereignisse, Verteilungen mit Parametern, Reihenfolge gleichzeitiger Ereignisse, Anfangszustand.
Lauf	Generator, Hauptstartwert, Zahl und Länge der Läufe, Einschwingphase und wie sie bestimmt wurde.
Ergebnis	Jede Zahl mit Standardfehler und dem Verfahren dafür (Blockmittel, Wiederholungen, τ). Bei Ketten: $\hat{R}$, n_{eff}.
Prüfung	Welche Stufen der Leiter, mit Zahlen.
Code	Der Quelltext, mit Version. Nicht “auf Anfrage”.

Eine Zahl ohne Standardfehler ist keine Simulationsergebnis. Ein Ergebnis ohne Startwert ist nicht nachprüfbar. Ein Modell ohne die Reihenfolge-Regel ist nicht beschrieben.

***In der Medizin gibt es dafür eine Leitlinie**: ISPOR-SMDM 2012 für Modellierungsstudien, die von Fachzeitschriften verlangt wird — und die Zahl der Studien, die sie erfüllen, liegt nach Übersichtsarbeiten unter der Hälfte. Der häufigste Mangel ist der letzte Punkt: Der Code fehlt. Wer in diesem Band bis hierher gekommen ist, hat ihn — die Intensivstation ist in jeder Sprache hundert Zeilen, und die hundert Zeilen sind der Beweis, nicht die Tabelle.*

13.5 Der Bruchfall

Bitgenau und doch verschieden

Dasselbe Programm, derselbe Startwert, zwei Rechner — und die Zahl stimmt in der zwölften Stelle nicht.

Summenreihenfolge	Eine Million Zahlen vorwärts summiert: 500 159,25646369834; rückwärts: 500 159,2564636872. Gleitkomma-Addition ist nicht assoziativ, Band 11.
Parallele Summen	Vier Kerne summieren je ein Viertel; welcher Kern zuerst fertig ist, entscheidet die Reihenfolge — und die ist jedes Mal anders.
Bibliotheksversion	Eine neue Version des Generators oder der Normalverteilungs-Routine (Box–Muller gegen Ziggurat, Kapitel 2) gibt zum selben Startwert andere Zahlen.
Mathematische Bibliothek	exp und log sind auf verschiedenen Prozessoren in der letzten Stelle verschieden.

Die zwölfte Stelle ist harmlos — bis eine Verzweigung davon abhängt: "Ist das Bett vor oder nach der Ankunft frei?" Dann läuft die Simulation ab diesem Ereignis anders, und am Ende steht eine andere Zahl im Rahmen des Standardfehlers, aber nicht dieselbe.

Bitgenaue Reproduzierbarkeit über Rechner hinweg ist ein Ziel, das man anstreben und nicht immer erreichen kann. *Was man erreichen kann: auf einem Rechner mit festgehaltenen Versionen bitgenau, über Rechner hinweg statistisch — und das Protokoll sagt, welches von beiden gemeint ist. Die Verzweigung in der Mitte ist zugleich das Argument gegen das Rechnen mit Gleitkommazeiten in Ereignislisten: Wer die Zeiten in ganzen Sekunden führt, Band 11, hat keine zwölfte Stelle, von der etwas abhängt.*

13.6 Übungsaufgaben

Aufgabe 13.1 — Ist das noch Zufall?

Startwert 42 gab 0,1861, Startwert 43 gab 0,1678, je 5 000 Tage; exakt ist 0,1785. Standardfehler je Lauf etwa 0,006 (Kapitel 4). Liegt ein Fehler vor?

Lösung

Schritt 1 — Die Abweichungen

$+0{,}0076$ und $-0{,}0107$: 1,3 und 1,8 Standardfehler.

Schritt 2 — Die Spanne

Zwei Läufe mit Differenz 0,0183 bei Standardfehler der Differenz $0{,}006\sqrt{2} = 0{,}0085$: 2,2 Standardfehler — bei zwei Läufen nicht auffällig (5 Prozent wären 1,96).

Schritt 3 — Das Urteil

> **Kein Befund. Aber auch kein Freispruch: Zwei Läufe entscheiden nichts. Zehn Läufe mit Mittel $0{,}1826 \pm 0{,}0018$ — Abschnitt 13.3 — liegen 2,3 Standardfehler über dem exakten Wert, und das ist der Punkt, an dem man nachsieht.**
>
> ***Und man findet: die Einschwingphase.*** *Die zehn Läufe verwerfen 100 Tage und beginnen leer; die Belegung in den ersten Tagen danach ist noch nicht ganz im Dauerzustand — Kapitel 4 hat das Fenster 10 bis 50 Tage mit 0,174 bis 0,188 gezeigt. Bei 5 000 Tagen je Lauf wiegt das wenig, aber bei zehn Läufen à 5 000 und einem Standardfehler von 0,0018 sieht man es. Mit 20 000 Tagen je Lauf war es in Kapitel 10 verschwunden: 0,1795. Die Lehre ist nicht, dass die Simulation falsch war — sondern dass ein Standardfehler von 0,002 Verzerrungen von 0,004 sichtbar macht, die bei 0,006 unsichtbar waren. Je genauer die Statistik, desto strenger prüft sie das Programm.*

Aufgabe 13.2 — Der Stufe-3-Test als Hypothesentest

Mit exponentieller Verweildauer: zehn Läufe geben Mittel 0,1799, Standardfehler 0,0015; Erlang sagt 0,1785. Formulieren Sie den Test und sein Ergebnis — und was ein "Bestehen" bedeutet.

Lösung

Schritt 1 — Der Test

H_0: Erwartungswert der Simulation $= 0{,}1785$. Teststatistik $(0{,}1799 - 0{,}1785)/0{,}0015 = 0{,}93$. Zweiseitig: $p = 0{,}35$. Nicht verworfen.

Schritt 2 — Was nicht verworfen heißt

Die Prüfung kann Verzerrungen unter etwa $2 \cdot 0{,}0015 = 0{,}003$ nicht sehen. Ein Fehler, der 0,002 Verzerrung erzeugt, besteht den Test.

Schritt 3 — Die Konsequenz

Prüfen mit Macht	So viele Läufe, dass der Standardfehler ein Zehntel der Genauigkeit ist, die man später beansprucht.
Mehrere Sonderfälle	Ein Bett, zwölf Betten, λ klein, λ groß: Ein Fehler, der bei 12 Betten 0,002 ausmacht, macht bei einem Bett 0,05.

Der Stufe-3-Test ist ein Äquivalenztest, kein Signifikanztest *— Band 17, Kapitel 11: Man will zeigen, dass die Verzerrung kleiner als eine Schranke ist, nicht, dass sie nicht nachweisbar ist. Dafür braucht man ein Vertrauensintervall, das ganz innerhalb der Schranke liegt:* $[0{,}177;\ 0{,}183]$ *innerhalb von* $0{,}1785 \pm 0{,}005$ *— bestanden, mit der Schranke als Teil des Urteils. Die Schranke setzt der Zweck: Für den Vergleich zweier Varianten mit Differenz* $0{,}04$ *genügt* $0{,}005$*; für eine Zulassung mit Verlustwahrscheinlichkeit* 10^{-6} *nicht.*

Aufgabe 13.3 — Vierzig Läufe auf vier Kernen

Entwerfen Sie die Startwertvergabe und die Zusammenführung so, dass das Ergebnis bitgenau reproduzierbar ist, unabhängig davon, welcher Kern wann fertig wird.

Lösung

Schritt 1 — Die Startwerte

Hauptstartwert 2026; vierzig Kinder über *SeedSequence(2026).spawn(40)*. Lauf k bekommt Kind k — nicht "den nächsten freien Kern", sondern die feste Nummer.

Schritt 2 — Die Zuteilung

Kern j bearbeitet die Läufe $k \equiv j \pmod 4$, oder eine Warteschlange verteilt sie — egal, denn Lauf k hängt nur von Kind k ab.

Schritt 3 — Die Zusammenführung

Ergebnisse in ein Feld der Länge 40 an Position k schreiben; erst nach dem letzten Lauf summieren, in der Reihenfolge 0 bis 39. Nie "addiere, sobald fertig".

Jeder Lauf ist eine Funktion seiner Nummer. Die Reihenfolge der Ausführung ist dann gleichgültig, und die Summe ist die Summe in fester Reihenfolge.

Das ist das Muster für alles Parallele in der Simulation*: unabhängige Aufgaben, je mit eigenem Zufall, Ergebnisse nach Nummer abgelegt, Reduktion am Ende in fester Reihenfolge. Es ist zugleich das Muster, das Markow-Ketten nicht erlauben — jede Kette ist eine Folge, und nur die Ketten laufen parallel, nicht die Schritte. Deshalb sind vier Ketten auf vier Kernen der Normalfall und eine Kette auf vier Kernen die Ausnahme, Kapitel 8.*

Die Krise und die Antwort

Die Reproduzierbarkeitskrise, die um 2011 in der Psychologie und der Medizin ausbrach, erreichte die Simulation später — und traf sie härter, weil hier alles reproduzierbar sein könnte.

*Eine Untersuchung von 2019 fand, dass von Simulationsstudien in führenden Zeitschriften weniger als ein Fünftel den Code beilegten und weniger als die Hälfte den Generator nannten. **Die Antwort kam aus der Werkzeugseite**: Versionsverwaltung, Band B, seit 2005 mit git; Container, die eine ganze Rechnerumgebung einfrieren; und Zeitschriften, die ab 2015 den Code als Teil der Einreichung verlangten — zuerst in der Statistik, dann in der Ökonomie, zuletzt in der Medizin.*

SeedSequence

***Robert Kern** entwarf 2019 für NumPy die Ableitung unabhängiger Startwerte aus einem Hauptstartwert — nach einer Vorarbeit von **O'Neill**, der Erfinderin von PCG. **Davor war die übliche Praxis, Startwerte** 1, 2, 3 **zu vergeben**, und bei den Generatoren der 1990er Jahre waren die Folgen zu benachbarten Startwerten messbar korreliert. Dass dieses Problem heute gelöst ist, verdankt sich wenigen Personen, die es für wichtig hielten, als es niemand sonst tat.*

Reproduzierbarkeit heute

Reproduzierbare Summen	Verfahren, die Gleitkommasummen unabhängig von der Reihenfolge bitgenau machen — mit etwas Mehraufwand.
Gegenfaktische Zufallszahlen	Ströme so anlegen, dass jede Zufallszahl an ein Objekt gebunden ist (Patient *k*, Verweildauer), nicht an eine Position — Varianten bleiben synchron.
Ausführbare Artikel	Der Artikel ist das Programm: Jede Zahl im Text wird beim Erzeugen des Dokuments berechnet.

Zur zweiten Zeile

***Die gegenfaktischen Zufallszahlen lösen Aufgabe 4.3 endgültig**: Statt eines Stroms, aus dem man der Reihe nach zieht, hat jeder Patient einen eigenen Startwert, aus seiner Nummer abgeleitet, und seine Verweildauer ist eine Funktion dieses Startwerts. Dann hat Patient 137 in der Variante mit zwölf und mit dreizehn Betten dieselbe Verweildauer — ob er aufgenommen wird oder nicht, ob vor ihm jemand abgewiesen wurde oder nicht. Die Synchronität ist in die Struktur eingebaut, nicht in die Disziplin des Programmierers. Die Zählergeneratoren aus Kapitel 2 — Philox, Threefry — sind genau dafür gebaut: Der Zähler ist die Patientennummer.*

Was Sie jetzt können

Drei Stufen	bitgenau, statistisch, sachlich
Ströme	sichtbar, je Zweck, abgeleitet, benannt
Satz 13.1	Prüfleiter: Erhaltung, Grenzen, Formel, Unempfindlichkeit, zweites Programm
Bericht	Modell, Lauf, Fehler, Prüfung, Code
Der Bruchfall	Gleitkomma ist nicht assoziativ

Geprüft, reproduzierbar, berichtet — und doch bleibt die Frage, was das Ergebnis wert ist, wenn $\lambda = 2{,}4$ aus hundert Tagen geschätzt wurde und ebenso gut 2,2 oder 2,6 sein könnte. Das nächste Kapitel rechnet diese Unsicherheit durch die Station hindurch.

Kapitel 14

Was man dem Ergebnis glauben darf

14.1 Zwei Arten von Zufall

Die Abweisungsrate ist 0,1785 — für wen?

Für eine Station mit $\lambda = 2{,}4$ und mittlerer Verweildauer 4,79. Beides sind Schätzungen aus Daten: 240 Ankünfte in 100 Tagen, 100 Aufenthalte mit $\bar{y} = 1{,}386$, $s = 0{,}60$ auf der logarithmischen Skala.

Aleatorisch	Der Zufall der Ankünfte und Verweildauern — er bleibt, auch wenn man λ exakt kennt. Die Simulation erzeugt ihn.
Epistemisch	Die Unkenntnis von λ, μ, σ — sie schrumpft mit mehr Daten. Band 21 beschreibt sie als A-posteriori-Verteilung.

Die Abweisungsrate ist eine Funktion der Parameter. Sind die Parameter unsicher, ist sie es auch — und die Frage ist, wie sehr.

***Unsicherheitsquantifizierung heißt, die epistemische Unsicherheit durch das Modell hindurchzurechnen**: nicht eine Zahl, sondern eine Verteilung über Zahlen, und für jede Entscheidung die Wahrscheinlichkeit, dass sie richtig ist. Die Werkzeuge sind die der Kapitel 7 und 3 — A-posteriori-Ziehungen und Integration über sie —, und das Ergebnis ist das, was ein Gutachten eigentlich schuldet.*

14.2 Die Unsicherheit durch das Modell

Definition 14.1 — Die A-posteriori-Vorhersage einer Kennzahl

Sei θ der Parametervektor mit A-posteriori-Dichte $p(\theta \mid \text{Daten})$ und $g(\theta)$ die Kennzahl des Modells. Die Verteilung von g gegeben die Daten ist das Bild der A-posteriori-Verteilung unter g:

$$P(g \le z \mid \text{Daten}) = \int \mathbf{1}\{g(\theta) \le z\}\, p(\theta \mid \text{Daten})\, d\theta.$$

Man zieht $\theta^{(1)}, \dots, \theta^{(N)}$ aus der A-posteriori-Verteilung (Kapitel 7) und berechnet $g(\theta^{(i)})$ — durch Formel oder durch Simulation.

Der Leitfall, 20 000 A-posteriori-Ziehungen

$\lambda \sim \text{Gamma}(241, 100)$, (μ, σ) nach Kapitel 7; g = Erlang B mit $a = \lambda\, e^{\mu+\sigma^2/2}$ — die Formel ist hier exakt, die Simulation wäre es auch.

	Mittel	**Streuung**	**90 %-Intervall**	$P(g > 0{,}2)$
12 Betten	0,183	0,042	[0,117; 0,254]	0,33
13 Betten	0,141	0,038	[0,082; 0,208]	0,07
Differenz	0,042	0,0035	[0,035; 0,046]	

Die Abweisungsrate bei zwölf Betten liegt zwischen 0,12 und 0,25. Die Wirkung des dreizehnten Betts zwischen 0,035 und 0,046 — zehnmal schärfer, weil beide Varianten von denselben Parametern abhängen.

***Das ist Satz 4.3 auf der Parameterebene**: Dieselben $\theta^{(i)}$ für beide Varianten, und die Unsicherheit über λ, die beide Raten hebt oder senkt, kürzt sich in der Differenz. Für die Entscheidung "dreizehntes Bett" ist die epistemische Unsicherheit damit fast belanglos — $0{,}042 \pm 0{,}0035$ — während die Frage "wie hoch ist die Rate überhaupt" mit $\pm 0{,}04$ beantwortet wird. Hundert Tage Daten reichen für das Eine und nicht für das Andere. Mit 400 Tagen halbiert sich die Streuung auf 0,021 — die Wurzelregel aus Band 17, hier für die Parameter.*

14.3 Woher die Unsicherheit kommt

Definition 14.2 — Sobol-Indizes

Für $g(\theta_1, \dots, \theta_d)$ mit unabhängigen θ_j ist der **Haupteffekt** von θ_j

$$S_j = \frac{\text{Var}\left[\mathbb{E}[g \mid \theta_j]\right]}{\text{Var}[g]}$$

— der Anteil der Varianz von g, den θ_j allein erklärt. Die Summe der S_j ist höchstens 1; der Rest sind Wechselwirkungen.

Satz 14.3 — Die Varianzzerlegung

Für unabhängige Eingaben und quadratintegrierbares g gilt

$$\operatorname{Var}[g] = \sum_{j} V_j + \sum_{j<k} V_{jk} + \cdots + V_{1\ldots d}$$

mit $V_j = \operatorname{Var}[\mathbb{E}[g \mid \theta_j]]$ und den höheren Termen als Varianzen der Wechselwirkungen.

Beweis

Band 20, Kapitel 12 (Auslassung 5): Die Zerlegung von g in orthogonale Summanden $g_0 + \sum g_j(\theta_j) + \sum g_{jk}(\theta_j, \theta_k) + \cdots$ mit $\mathbb{E}[g_j] = 0$ und paarweise unkorrelierten Termen; die Varianz ist dann die Summe der Varianzen. ■

Für die Abweisungsrate bei zwölf Betten

Parameter	relative Streuung	S_j
λ	6,4 %	0,48
μ		0,43
σ		0,09
Summe		1,00

Ankunftsrate und Lageparameter der Verweildauer tragen je die Hälfte; die Streuung der Verweildauer fast nichts. Keine Wechselwirkungen — weil g nur von $a = \lambda e^{\mu+\sigma^2/2}$ abhängt und $\ln a$ eine Summe ist.

*Die Indizes sagen, wo mehr Daten lohnen: Jeder Tag liefert 2,4 Ankünfte für λ und 2,4 Verweildauern für μ — beide schrumpfen gleich schnell. Wäre S_σ groß, so bräuchte man extreme Aufenthalte, und die sind selten. Die S_j sind hier aus 20 000 Ziehungen durch Einteilung in fünfzig Klassen je Parameter geschätzt — bei einem g, das eine Simulation ist, braucht man dafür die Schätzer von **Saltelli** aus dem Forschungskasten, die mit $N(d+2)$ Läufen auskommen.*

14.4 Die Entscheidung unter Unsicherheit

Was die Klinikleitung wissen will

Nicht “die Rate ist 0,18”, sondern:

Frage	Antwort
Liegt die Rate über 20 %?	mit 33 % Wahrscheinlichkeit
Bringt das dreizehnte Bett sie unter 15 %?	mit 62 %
Senkt es die Rate um mehr als drei Punkte?	mit > 99 %
Wie viel Daten für $\pm 0{,}02$?	etwa 400 Tage

Die dritte Zeile ist eine Entscheidung; die erste ist keine. Unsicherheitsquantifizierung trennt die Fragen, die die Daten beantworten können, von denen, die sie nicht beantworten können — und sagt, was es kosten würde.

***Band 24 hat gezeigt, wie man aus solchen Wahrscheinlichkeiten und den Kosten eine Entscheidung macht**: Erwartungswert über die A-posteriori-Verteilung, Wert der Information für mehr Daten. Hier reicht die Tabelle: Das dreizehnte Bett wirkt mit Sicherheit und seine Wirkung ist auf drei Prozent genau bekannt; ob die Station "ein Problem hat", ist bei hundert Tagen Daten dagegen offen. Wer das Erste als Argument und das Zweite als Frage vorträgt, hat die Simulation richtig benutzt.*

14.5 Der Bruchfall

Die Unsicherheit, die nicht im Modell ist

Alle Intervalle oben setzen voraus: Poisson-Ankünfte mit konstantem λ, lognormale Verweildauern, unabhängig, zwölf gleichwertige Betten. Was nicht darin ist:

Tagesrhythmus	erhöht die Rate um 20 bis 40 % — Kapitel 10, Forschungskasten.
Abhängigkeit	Eine Grippewelle bringt mehr Patienten *und* längere Aufenthalte zugleich: λ und μ steigen gemeinsam, und die Varianz von a ist größer als unter Unabhängigkeit.
Verhaltensänderung	Bei voller Station entlassen Ärzte früher. Die Verweildauer hängt von der Belegung ab, und das Modell weiß es nicht.
Die Daten selbst	Hundert Tage aus dem Winter sind kein Jahr.

Das Intervall $[0{,}12;\ 0{,}25]$ ist die Unsicherheit innerhalb des Modells. Die Unsicherheit über das Modell ist nicht darin, und sie ist wahrscheinlich größer.

***Die dritte Zeile ist die gefährlichste, weil sie das Modell in die richtige Richtung verfälscht**: Die Station sieht in Wirklichkeit weniger Abweisungen, als das Modell vorhersagt — weil sie sich anpasst —, und ein Modell, das das nicht enthält, überschätzt den Nutzen des dreizehnten Betts: Mit mehr Betten wird weniger früh entlassen, die Verweildauer steigt, und ein Teil des Gewinns verschwindet. Die Abhilfe ist nicht mehr Statistik, sondern **Modellvergleich** — mehrere Modelle rechnen, mit und ohne Anpassung, mit und ohne Tagesrhythmus — und die Spanne der Ergebnisse als die ehrliche Unsicherheit berichten. Band 21 nennt das **Modellmittelung**; die Praxis nennt es Sensitivitätsanalyse; beides ist dasselbe Eingeständnis.*

14.6 Übungsaufgaben

Aufgabe 14.1 — Die Elastizität von Hand

Wie stark reagiert die Abweisungsrate auf ein Prozent mehr Last a? Leiten Sie es aus der Erlang-Rekursion ab und prüfen Sie die Streuung 0,042.

Lösung

Schritt 1 — Die Ableitung

Numerisch aus Kapitel 1: $B(11{,}50) - B(11{,}48) = 0{,}00079$, also $dB/da = 0{,}040$. Elastizität $\dfrac{a}{B}\dfrac{dB}{da} = \dfrac{11{,}49 \cdot 0{,}040}{0{,}1785} = 2{,}6$.

Schritt 2 — Die Unsicherheit von a

$\ln a = \ln \lambda + \mu + \sigma^2/2$, unabhängige Summanden:

$$\operatorname{Var}[\ln a] = 0{,}064^2 + 0{,}060^2 + \operatorname{Var}[\sigma^2/2] \approx 0{,}0041 + 0{,}0036 + 0{,}0007 = 0{,}0084$$

Relative Streuung von a: 0,092.

Schritt 3 — Die Deltamethode

Relative Streuung von B: $2{,}6 \cdot 0{,}092 = 0{,}24$; absolut $0{,}24 \cdot 0{,}1785 = 0{,}043$. Simuliert: 0,042.

***Die Deltamethode aus Band 17 trifft die Streuung — nicht aber das Intervall**: $[0{,}117;\ 0{,}254]$ ist nicht symmetrisch um 0,183, weil B in a konvex ist und a lognormal. Für die Streuung reicht die Formel, für $P(g > 0{,}2)$ braucht man die Ziehungen. Die Elastizität 2,6 ist aber die Zahl, die man sich merkt: Ein Prozent mehr Last, zweieinhalb Prozent mehr Abweisungen — bei 96 Prozent Auslastung. Bei 80 Prozent wäre sie 3,4, bei 60 Prozent 5: Je leerer die Station, desto empfindlicher die relative Rate, aber desto kleiner die absolute.*

Aufgabe 14.2 — Wenn g eine Simulation ist

Statt der Erlang-Formel steht eine Simulation mit $\pm 0{,}006$ Standardfehler je Lauf. Wie trennt man die Simulationsstreuung von der Parameterunsicherheit?

Lösung

Schritt 1 — Die Zerlegung
Für jedes $\theta^{(i)}$ ein Lauf mit Ergebnis $\hat{g}_i = g(\theta^{(i)}) + e_i$, e_i der Simulationsfehler. Dann

$$\operatorname{Var}[\hat{g}] = \operatorname{Var}[g(\theta)] + \mathbb{E}[\operatorname{Var}[e]] = \operatorname{Var}[g(\theta)] + 0{,}006^2.$$

Schritt 2 — Die Zahlen
$\operatorname{Var}[\hat{g}] = 0{,}042^2 + 0{,}006^2 = 0{,}001764 + 0{,}000036$: Die Simulationsstreuung macht zwei Prozent der Varianz aus. Man kann sie abziehen — oder ignorieren.

Schritt 3 — Die Planung

> **Je Parameterziehung ein kurzer Lauf, nicht je Ziehung ein langer: Die Parameterunsicherheit ist siebenmal größer als die Simulationsstreuung, also gehört die Rechenzeit in viele Ziehungen.**
>
> *Das ist die Varianzzerlegung aus Satz 5.3 und Aufgabe 12.3 noch einmal, und sie beantwortet die häufigste Planungsfrage der Unsicherheitsquantifizierung: 1 000 Parameterziehungen mit je 1 000 Tagen schlagen 10 Ziehungen mit je 100 000 Tagen, bei gleichem Aufwand, um den Faktor zehn in der Genauigkeit über die Parameter. Nur wenn die Simulation selbst grob ist — $\pm 0{,}04$ je Lauf — lohnt sich der Ausgleich, und dann hilft Kapitel 5.*

Aufgabe 14.3 — Der Wert von vierhundert Tagen

Mit 400 Tagen Daten wäre die Streuung 0,021 statt 0,042. Was ist diese Verbesserung wert, wenn die Entscheidung lautet: dreizehntes Bett ja oder nein?

Lösung

Schritt 1 — Hängt die Entscheidung davon ab?
Die Differenz $0{,}042 \pm 0{,}0035$ ist schon bei hundert Tagen so scharf, dass kein realistischer Datensatz sie unter 0,03 bringt. Die Entscheidung “Bett ja” ändert sich durch mehr Daten nicht.

Schritt 2 — Der Wert der Information
Nach Band 24: Der Wert zusätzlicher Daten ist der Erwartungswert der Verbesserung der Entscheidung. Ändert sich die Entscheidung nicht, ist er null.

Schritt 3 — Wofür die Daten dann sind

> **Für die andere Frage: Ob die Station “über 20 %” liegt — für Berichte, Verhandlungen mit Kostenträgern, den Vergleich mit anderen Häusern. Dort halbieren 400 Tage das Intervall.**

Die Unsicherheitsquantifizierung endet nicht beim Intervall, sondern bei der Frage, wofür das Intervall gebraucht wird. *Dieselben Daten sind für eine Entscheidung mehr als genug und für eine Kennzahl zu wenig. Wer beides vermischt, fordert entweder Daten, die niemand braucht, oder trifft Entscheidungen auf Zahlen, die niemand hat. Die Tabelle in Abschnitt 14.4 ist der Versuch, die Trennung auf einer Seite darzustellen — und sie ist das, was man einer Klinikleitung vorlegt, nicht die Formel.*

Von Sobol bis zur Leitlinie

Ilya Sobol — derselbe, dessen Folgen Kapitel 6 nutzt — veröffentlichte die Varianzzerlegung 1990 in Moskau, auf Russisch; die englische Fassung von 1993 machte sie bekannt.

Andrea Saltelli und seine Gruppe in Ispra machten daraus ab 2000 ein Verfahren*: Schätzer für die Indizes aus $N(d+2)$ Modellläufen, Software, ein Lehrbuch 2008, und die Forderung, dass jede Modellstudie für die Europäische Kommission eine Sensitivitätsanalyse enthalten müsse. Die Bezeichnung "Unsicherheitsquantifizierung" stammt aus den amerikanischen Waffenlaboren der 1990er Jahre, wo nach dem Teststopp 1992 Simulationen die Versuche ersetzten — und die Frage, wie weit man ihnen trauen dürfe, zur Überlebensfrage wurde.*

Aleatorisch und epistemisch

*Die Unterscheidung ist älter — **Hacking** datiert sie auf die Entstehung der Wahrscheinlichkeit im siebzehnten Jahrhundert, die von Anfang an beides war: Würfel und Zeugenaussagen. **In der Simulation wurde sie in den 1990er Jahren zur Arbeitsgrundlage**, weil nur die zweite Art durch Daten schrumpft und nur die erste durch mehr Läufe sichtbar wird. Wer beide in einem Intervall vermischt, kann keines von beiden verkleinern.*

Unsicherheitsquantifizierung heute

Ersatzmodelle	Die Simulation durch ein Gauß-Prozess-Modell (Band 23) ersetzen, das aus hundert Läufen gelernt wird — dann sind Sobol-Indizes und Intervalle in Sekunden berechnet.
Mehrebenen-UQ	Grobe und feine Modelle gekoppelt, Satz 9.5 für die Parameterintegration.
Modell-unsicherheit	Formale Verfahren für den Bruchfall: Bayes-Modellmittelung, Imprecise Probabilities, Robustheit gegen Modellfehler.

Zur ersten Zeile

***Das Ersatzmodell ist der Schlüssel, sobald ein Lauf Stunden dauert**: Ein Klimamodell, ein Herzmodell, ein ganzes Krankenhaus. Man wählt hundert Parameterpunkte nach einem Versuchsplan — Sobol-Punkte, Kapitel 6, oder ein lateinisches Hyperwürfel-Design —, rechnet das Modell dort, und der Gauß-Prozess interpoliert mit einem eigenen Unsicherheitsmaß. Über das Ersatzmodell integriert man dann wie über eine Formel. **Kennedy** und **O'Hagan** haben 2001 gezeigt, wie man dabei die Interpolationsunsicherheit mitträgt — und wie man den Modellfehler selbst als Gauß-Prozess schätzt, der erste formale Zugang zum Bruchfall.*

Was Sie jetzt können

Zwei Arten	aleatorisch bleibt, epistemisch schrumpft
Definition 14.1	A-posteriori-Ziehungen durch das Modell
Satz 14.3	Sobol: Varianz nach Eingaben zerlegen
Die Differenz	gemeinsame Parameter kürzen sich
Der Bruchfall	Modellunsicherheit ist nicht im Intervall

Vierzehn Kapitel haben aus einem Rechner, der nur rechnen kann, einen gemacht, der vom Zufall weiß: ihn erzeugt, bändigt, dorthin lenkt, wo es selten wird, aus ihm zurückschließt und sagt, wie weit er trägt. Das letzte Kapitel fragt, wo das Fach im Jahr 2026 steht — und wo es nicht steht.

Teil VI

Aktueller Stand

Kapitel 15

Was der Rechner vom Zufall weiß

15.1 Der Leitfall, ein letztes Mal

Was der Band aus einer Station gemacht hat

Am Anfang stand: Wie oft weist eine Intensivstation mit zwölf Betten ab?

Kap.	Frage	Antwort
1	Wie oft?	0,18 — mit Fehler $1/\sqrt{n}$.
2–3	Woher der Zufall, und wie viel?	Aus Rechenregeln; und mehr, als Gitter leisten.
4–6	Wie genau, und genauer?	Abhängig gemessen; Varianz gesenkt; seltene Fälle gelenkt.
7–9	Und wenn man nicht ziehen kann?	Eine Kette, die hinläuft — geprüft, geflogen.
10–12	Und das System selbst?	Ereignisse, Schlangen, seltene Tage, Filter.
13–14	Und was ist es wert?	Reproduzierbar, geprüft, mit Unsicherheit.

Der exakte Wert war stets $0{,}1785$**. Was sich geändert hat, ist, was man ihm beilegen kann: einen Fehler, eine Verteilung, eine Bedingung, einen Beweis, dass das Programm stimmt.**

15.2 Vier Muster

Muster 1 — der Fehler fällt wie $1/\sqrt{n}$**, und nur so**

1	Die Wurzelregel — unabhängig von der Dimension.
3	Das Gitter fällt wie $n^{-2/d}$; ab $d = 4$ gewinnt der Zufall.
4	Bei Abhängigkeit ist n durch τ zu teilen.
6	Quasi-Zufall fällt schneller — bis $(\log n)^d$ es einholt.

***Das ist der Grund, warum die Methode in jedem Fach steht, das in mehr als drei Dimensionen rechnet**: Sie ist nicht gut, sie ist nur als einzige nicht hoffnungslos. Und es ist der Grund, warum der Rest des Bandes nötig war: Ein Fehler, der nur mit der Wurzel fällt, muss mit allen Mitteln an seiner Konstante gesenkt werden.*

Muster 2 — derselbe Zufall zweimal

4	Gemeinsame Zufallszahlen für Differenzen: Varianz durch fünfundvierzig.
5	Antithetisch: $g(U)$ und $g(1-U)$; Kontrolle: $Y - \beta(C - c)$.
9	Mehrebenen: grob und fein mit denselben Zuwächsen.
14	Dieselben Parameterziehungen für beide Varianten.

***Die dritte Überraschung des Vorworts ist das Prinzip des Bandes geworden**: Zufall, den man nicht braucht, wird nicht neu gezogen, sondern wiederverwendet, und was sich zwischen zwei Varianten nicht ändert, kürzt sich heraus. Jedes Verfahren der Varianzreduktion ist eine Art, dasselbe zu sagen.*

Muster 3 — der Rechner zeigt seine Fehler nicht an

2	RANDU lieferte zwanzig Jahre lang Zahlen auf fünfzehn Ebenen.
3, 6	Unendliche Varianz sieht aus wie Konvergenz — mit Sprüngen.
7, 8	Die gefangene Kette ist makellos; $\hat{R}$ sieht es, eine Kette nie.
12	Der falsche Filter liefert ein Intervall, das zu schmal ist.
13	Zwei Programmfehler bestehen jede Buchhaltungsprüfung.

Deshalb ist jedes Kapitel mit einem Bruchfall geendet. *Die Simulation hat keinen Fehlerausgang: Sie liefert immer eine Zahl, und die Zahl sieht immer plausibel aus. Was sie richtig macht, ist nie im Lauf selbst zu sehen — sondern in einer Formel für den Sonderfall, einer zweiten Kette, einem Blick auf das zweite Moment, einem Standardfehler aus Blockmitteln. Die Disziplin des Fachs besteht aus diesen Blicken.*

Muster 4 — die Simulation und die Formel brauchen einander

1	Erlang B prüft die Simulation; die Simulation verlässt Erlang B.
7	Der konjugierte Fall prüft die Kette; die Kette geht, wo keine Konjugation ist.
11	Spielerruin prüft die Aufspaltung; die Aufspaltung geht zur lognormalen Station.
14	Die Deltamethode prüft die Streuung; die Ziehungen geben das Intervall.

Die Simulation hat die Formel nicht verdrängt, sie hat ihr eine neue Rolle gegeben*: Die Formel ist der Sonderfall, an dem das Programm geprüft wird, bevor es dorthin geht, wo keine Formel reicht. Wer nur simuliert, hat keine Probe; wer nur rechnet, bleibt im Sonderfall. Die sechsundzwanzig Bände vor diesem haben die Formeln geliefert; dieser hat gezeigt, wofür man sie braucht, wenn man sie nicht mehr braucht.*

15.3 Was offen ist

Vier Fragen

Konvergenz erkennen	Es gibt keinen Beweis, dass eine Kette angekommen ist — nur Nachweise, dass sie es nicht ist. Die Kopplung aus Kapitel 8 ist der erste Weg zu Garantien, und er trägt nicht weit.
Hohe Dimension	Teilchenfilter versagen ab etwa zehn Zustandskoordinaten, Quasi-Monte-Carlo ab einigen Dutzend wirksamen Dimensionen, Markow-Ketten bei mehreren Gipfeln. Für jedes gibt es Umwege; für keines eine Lösung.
Modellfehler	Alle Unsicherheit dieses Bandes ist Unsicherheit innerhalb eines Modells. Die Unsicherheit über das Modell hat kein Maß, nur Sensitivitätsanalysen.
Verzerrung gegen Varianz	Mehrebenen-Verfahren, Ersatzmodelle und gelernte Kontrollen tauschen Varianz gegen Verzerrung, und niemand weiß allgemein, wie viel.

Die dritte Frage ist die wichtigste und die am wenigsten mathematische: *Das Intervall* $[0{,}12;\ 0{,}25]$ *aus Kapitel 14 ist korrekt für eine Station, die es nicht gibt — eine ohne Tagesrhythmus, ohne Grippewellen, ohne Ärzte, die bei voller Station früher entlassen. Die ehrliche Antwort ist die Spanne über mehrere Modelle, und sie ist breiter. Dass die Simulation dieses Eingeständnis leichter macht als jede Formel — man ändert zehn Zeilen und rechnet noch einmal —, ist ihr eigentlicher Beitrag zur Redlichkeit.*

15.4 Sechs Sätze, die bleiben

Die Bilanz

Satz 1.2	Der Fehler ist $\sigma/\sqrt{n}$, in jeder Dimension.
Satz 2.3	Ein linearer Generator legt seine Punkte auf Ebenen.
Satz 4.1	Abhängige Werte: n durch $\tau = 1 + 2\sum \rho_k$.
Satz 6.2	Die beste Vorschlagsdichte ist $\lvert h \rvert f$; die Ränder müssen schwerer sein als f.
Satz 7.2	Detaillierte Bilanz macht π stationär — ohne Normierungskonstante.
Satz 9.5	Grob oft, fein selten: Kosten ε^{-2} statt ε^{-3}.

Dazu eine Regel ohne Nummer: Jede Zahl aus einer Simulation hat einen Standardfehler, einen Startwert und eine Probe — oder sie ist keine.

Ein Schlusswort

Band 25 hat gezeigt, wie der Zufall weitergeht; Band 26, wie Daten sich selbst bestimmen. Dieser Band hat beides in den Rechner geholt — und gefunden, dass der Rechner vom Zufall genau so viel weiß, wie man ihm beigebracht hat: eine Rechenregel, die wie Zufall aussieht; eine Wurzel, die langsam fällt; und die Gewissheit, dass er seine Fehler nicht anzeigt. Alles Weitere — der Standardfehler, der Startwert, die Probe am Sonderfall — ist nicht im Rechner. Es ist in dem, der ihn benutzt. ***Das war die Absicht dieses Bandes: nicht ein Rechner, der simuliert, sondern ein Leser, der weiß, was er dabei tut.***

Teil VII

Anhang

Kapitel A

Formelsammlung und Übersicht

A.1 Begriffe und Formeln

Teil I bis III

$\hat{\theta} = \frac{1}{n}\sum h(X_i)$	Monte-Carlo-Schätzer (1.1)
$\mathrm{SE} = \sigma/\sqrt{n}$	Wurzelregel (1.2)
$B_c = aB_{c-1}/(c + aB_{c-1})$	Erlang-Rekursion (1)
$x_{k+1} = (ax_k + c) \bmod m$	LCG (2.1)
$\leq (d!\,m)^{1/d}$ Ebenen	Marsaglia (2.3)
$X = F^{-1}(U)$	Inversion (2.4)
$\sqrt{-2\ln U_1}\cos 2\pi U_2$	Box–Muller (2.5)
$n^{-2/d}$ gegen $n^{-1/2}$	Fluch der Dimension (3.1)
$\tau = 1 + 2\sum \rho_k$, n/τ	Autokorrelationszeit (4.1)
$s_{\text{Block}}/\sqrt{b}$	Blockmittel (4.2)
$\mathrm{Var}[A - B] = \ldots - 2\,\mathrm{Cov}$	gemeinsame Zahlen (4.3)
$\frac{1}{2}(g(U) + g(1-U))$, Faktor $1 + \rho$	antithetisch (5.1)
$Y - \beta^*(C - c)$, $1 - \rho^2$	Kontrollvariable (5.2)
$\mathrm{Var}[\mathbb{E}[Y\|Z]] \leq \mathrm{Var}[Y]$	Konditionierung (5.3)
$w = f/g$, $g^* \propto \lvert h\rvert f$	Wichtigkeit (6.1), (6.2)
$e^{\mu^2} P(Z > c + \mu)$	zweites Moment, Verschiebung

$(\sum w)^2 / \sum w^2$	wirksames n
$\lvert\bar{h} - \int h\rvert \le V(h) D_n^*$	Koksma–Hlawka (6.3)
$\min\{1, \frac{\pi(x')q(x\lvert x')}{\pi(x)q(x'\lvert x)}\}$	Metropolis–Hastings (7.1)
$\pi(x)P(x \to x') = \pi(x')P(x' \to x)$	detaillierte Bilanz (7.2)
$2{,}38/\sqrt{d}$, 23 %	optimale Schrittweite
$\hat{R} = \sqrt{\hat{V}/W}$	Gelman–Rubin (8.1)
$H = U + \frac{1}{2}p^\top p$, Sprungverfahren	Hamilton (9.1), (9.2)
$\Delta t^{1/2}$, Δt, Δt	Euler, Milstein, schwach (9.4)
$N_\ell \propto \sqrt{V_\ell / C_\ell}$	Mehrebenen (9.5)

Teil IV und V

(Zeit, Rang, Art)	Ereignisliste (10.1)
$L = \lambda_{\text{eff}}\, \bar{W}$	Little (10)
$\frac{1}{2}\Delta t$ zu lang	Zeitschritt-Verzerrung (10)
$\rho^{\sqrt{2(c+1)}-1}/(c(1-\rho)) \cdot \frac{1+c_s^2}{2}\, S$	Sakasegawa (11.1)
$(1-r)/(1-r^\ell)$, $r = (1-p)/p$	Spielerruin (11)
$n_m/(N_0 R^{m-1})$	Aufspaltung (11.2)
Vorhersage, Gewichtung, Neuziehung	Teilchenfilter (12.1)
$K = (P+q)/(P+q+r)$	Kalman-Gewinn (12)
Erhaltung, Grenzen, Formel, Unempfindlichkeit, zweites Programm	Prüfleiter (13.1)
$\int \mathbf{1}\{g(\theta) \le z\}\, p(\theta\lvert \mathrm{D})\, d\theta$	A-posteriori-Vorhersage (14.1)
$S_j = \mathrm{Var}[\mathbb{E}[g\lvert\theta_j]] / \mathrm{Var}[g]$	Sobol-Index (14.2)
$(a/B)\, dB/da$	Elastizität (14)

A.2 Die Landkarte

Welcher Satz worauf beruht

Satz	beruht auf
1.2 Wurzelregel	Gesetz der großen Zahlen, zentraler Grenzwertsatz (Band 17)
2.3 Marsaglia	Gitter in $\mathbb{Z}^d$ (Band 1, 7)
2.4 Inversion	Verteilungsfunktion (Band 15)
2.6 Verwerfung	bedingte Wahrscheinlichkeit (Band 15)
3.1 Fluch	Fehler der Trapezregel (Band 11)
4.1 Autokorrelationszeit	Satz 10.4 (Band 26)
5.1 antithetisch	Chebyshev-Ungleichung für Funktionen (Band 15)
5.2 Kontrolle	Regression (Band 26)
5.3 Konditionierung	Turmregel, Varianzzerlegung (Band 25)
6.2 Wichtigkeit	Dichtewechsel (Band 15)
6.3 Koksma–Hlawka	partielle Integration; mehrdimensional Auslassung 2
7.2 Metropolis	Sätze 3.5 und 3.9 (Band 25)
8.2 $\hat{R}$	Varianzzerlegung (Band 17)
9.2 Hamilton	Liouville (Band 24, Auslassung 3); 7.2
9.4 Ordnung	Satz 8.6 (Band 25); Milstein Auslassung 4
9.5 Mehrebenen	Lagrange (Band 12); 5.2

Satz	beruht auf
11.1 Sakasegawa	Erlang C, Pollaczek–Chintschin (Band 25); Näherung
12.2 Teilchenfilter	6.1; Satz von Bayes (Band 21)
13.1 Prüfleiter	kein Satz — eine Praxis
14.3 Sobol	orthogonale Zerlegung (Band 20, Auslassung 5)

A.3 Was nicht bewiesen wurde

Fünf Auslassungen

Ergebnis	Kap.	Wo es steht
Volle Periode des LCG (Hull–Dobell)	2	Band 1, Kap. 9; Knuth[12]
Koksma–Hlawka, mehrdimensional	6	Band 20; Niederreiter[21]
Satz von Liouville	9	Band 24; Neal[20]
Starke Ordnung des Milstein-Verfahrens	9	Band 25; Kloeden–Platen[11]
Sobol-Zerlegung	14	Band 20; Saltelli[26]

Alle übrigen Sätze des Bandes sind vollständig bewiesen *— darunter die Wurzelregel, der Ebenensatz für RANDU, Inversion und Verwerfung, der Fluch der Dimension, die Varianzformeln der antithetischen und der Kontrollvariablen, die optimale Vorschlagsdichte, die detaillierte Bilanz des Metropolis-Algorithmus, die Annahme 1 des Gibbs-Samplers, die Volumenerhaltung des Sprungverfahrens, die Teleskopzerlegung mit optimaler Pfadverteilung und die Erwartungstreue des Teilchenfilters. Die Näherung von Sakasegawa ist eine Interpolationsformel ohne Beweis und wurde als solche gekennzeichnet.*

A.4 Zeittafel

Von Buffon bis zur Kopplung

1777	Buffon	die Nadel: π durch Zufall
1909	Erlang	Verlustformel für Telefonzentralen
1916	Weyl	Gleichverteilung modulo eins
1946	Ulam, von Neumann	Monte Carlo in Los Alamos
1949	Lehmer	linearer Kongruenzgenerator
1951	Kahn, Harris	Wichtigkeitsstichprobe und Aufspaltung
1953	Metropolis u. a.	der Algorithmus
1955	Maruyama	Euler für stochastische Gleichungen
1956	Hammersley, Morton	antithetische Variablen
1958	Box, Muller	normalverteilte Zahlen
1960	Kalman	der Filter
1961	Little; Gordon; Dahl, Nygaard	$L = \lambda W$; GPSS; Simula
1967	Sobol	Folgen niedriger Diskrepanz
1968	Marsaglia	"Random numbers fall mainly in the planes"
1970	Hastings	Verallgemeinerung auf unsymmetrische Vorschläge
1974	Milstein	Verfahren erster Ordnung

1984	Geman, Geman	Gibbs-Sampler
1987	Duane u. a.	Hybrid Monte Carlo
1990	Gelfand, Smith; Sobol	Bayes wird rechenbar; Varianzzerlegung
1992	Gelman, Rubin	$\hat{R}$
1993	Gordon, Salmond, Smith	Bootstrap-Filter
1995	Owen	verwürfelte Netze
1997	Roberts, Gelman, Gilks	0,234
1998	Matsumoto, Nishimura	Mersenne-Twister
2008	Giles	Mehrebenen-Monte-Carlo
2010	Andrieu, Doucet, Holenstein	Teilchen-MCMC
2011	Salmon u. a.	Zählergeneratoren (Philox)
2014	Hoffman, Gelman; O'Neill	NUTS; PCG
2020	Jacob, O'Leary, Atchadé	unverzerrte Ketten durch Kopplung

A.5 Glossar

Begriffe von A bis Z

Begriff	Bedeutung
Aleatorisch	Zufall, der bleibt (14)
Antithetisch	U und $1-U$ als Paar (5.1)
Aufspaltung	gute Pfade kopieren (11.2)
Autokorrelationszeit	$1+2\sum\rho_k$ (4.1)
Blockmittel	Standardfehler ohne ρ_k (4.2)
Box–Muller	zwei Gleichverteilte, zwei Normale (2.5)
Degeneration	alle Gewichte auf einem Teilchen (12)
Detaillierte Bilanz	Fluss hin = Fluss zurück (7.2)
Diskrepanz	wie ungleichmäßig eine Punktmenge ist (6.3)

Einschwingphase	Anfang verwerfen (4)
Epistemisch	Zufall, der schrumpft (14)
Ereignisliste	nach Zeit geordnete Halde (10.1)
Erlang B	Verlustformel, unempfindlich (1)
Fluch der Dimension	Gitter brauchen n^d (3.1)
Gemeinsame Zufallszahlen	gleicher Zufall für Varianten (4.3)
Gibbs-Sampler	bedingt ziehen, nie ablehnen (7.3)
Hamilton-Monte-Carlo	Impuls und Bahn statt Zufallsweg (9.1)
Inversion	$F^{-1}(U)$ (2.4)
Kontrollvariable	bekannten Erwartungswert abziehen (5.2)
Konditionierung	$\mathbb{E}[Y\|Z]$ statt Y (5.3)
LCG	$ax + c \bmod m$ (2.1)
Mehrebenen	Teleskopsumme über Gitter (9.5)
Metropolis–Hastings	vorschlagen, annehmen mit α (7.1)
Milstein	Euler plus $\frac{1}{2} b b' (\Delta W^2 - \Delta t)$ (9.3)
Neuziehung	Teilchen nach Gewicht vervielfachen (12.1)
$\hat{R}$	zwischen/innerhalb der Ketten (8.1)
RANDU	fünfzehn Ebenen (2.3)
Sobol-Folge	Punkte niedriger Diskrepanz (6)
Sobol-Index	Varianzanteil einer Eingabe (14.2)
Sprungverfahren	symplektischer Integrator (9.2)
Startwert	Anfang der Zahlenfolge (2, 13)
Teilchenfilter	Wichtigkeit Tag für Tag (12.1)
Verwerfung	Vorschlag unter die Dichte (2.6)
Wichtigkeitsstichprobe	aus g ziehen, mit f/g wichten (6.1)
Wirksames n	n/τ oder $(\sum w)^2 / \sum w^2$ (4, 6)
Wurzelregel	Fehler $\sigma/\sqrt{n}$ (1.2)
Zählergenerator	Zahl aus Zählerstand (2, 13)

Kapitel B

Kommentierte Quellen

Achtundzwanzig Werke, eingeordnet: Zu jedem steht, wofür man es aufschlägt und was es leistet, das andere nicht leisten.

[1] Andrieu, C., Doucet, A., Holenstein, R.: *Particle Markov Chain Monte Carlo Methods*. J. Roy. Statist. Soc. B 72, 2010.

Der Aufsatz, der Kapitel 7 und 12 verbindet: ein verrauschter Likelihood-Schätzer im Metropolis-Quotienten, und die Kette ist trotzdem exakt. ***Die Grundlage der pseudo-marginalen Verfahren****; schwer, aber die Einleitung ist für jeden lesbar.*

[2] Asmussen, S., Glynn, P.: *Stochastic Simulation: Algorithms and Analysis*. Springer 2007.

Das mathematisch strengste Lehrbuch des Fachs *— Varianzreduktion, seltene Ereignisse, Markow-Ketten, stochastische Differentialgleichungen, mit Beweisen. Die Fundstelle für alles aus den Teilen II bis IV, was hier nur mit Simulation belegt wurde. Für Leser, die Band 25 beherrschen.*

[3] Brooks, S., Gelman, A., Jones, G., Meng, X.-L. (Hg.): *Handbook of Markov Chain Monte Carlo*. Chapman & Hall 2011.

Das Nachschlagewerk zu Teil III: Geyers Einführung, Neals Kapitel über Hamilton-Monte-Carlo, Diagnostik, Anwendungen. ***Neals Beitrag ist die beste Darstellung von Kapitel 9*** *und frei verfügbar.*

[4] Del Moral, P.: *Feynman–Kac Formulae: Genealogical and Interacting Particle Systems*. Springer 2004.

Die Theorie, die Teilchenfilter und Aufspaltung als dasselbe Objekt behandelt. ***Nicht zum Lesen, zum Nachschlagen*** *— die Fundstelle für die Erwartungstreue in Satz 12.2.*

[5] Doucet, A., de Freitas, N., Gordon, N. (Hg.): *Sequential Monte Carlo Methods in Practice*. Springer 2001.

Die Sammlung, die den Teilchenfilter bekannt machte — Kapitel 12 mit allen Varianten und Anwendungen von der Navigation bis zur Ökonometrie. Der Beitrag von Doucet, Godsill und Andrieu ist die Einführung.

[6] Gelman, A., Carlin, J., Stern, H., Dunson, D., Vehtari, A., Rubin, D.: *Bayesian Data Analysis*. 3. Aufl., Chapman & Hall 2013.

Das Standardwerk der angewandten Bayes-Statistik, mit den Kapiteln 10 bis 12 zu Metropolis, Gibbs, Hamilton und Diagnostik. ***Die Quelle für $\hat{R}$, die Halbketten-Regel und die Warnung vor dem Ausdünnen*** *aus Kapitel 8.*

[7] Giles, M.: *Multilevel Monte Carlo Path Simulation*. Oper. Res. 56, 2008.

Satz 9.5 im Original, mit dem Kostenbeweis und den Beispielen aus der Finanzmathematik. ***Zwölf Seiten, die ein Fach verändert haben****; Giles' Übersicht in Acta Numerica 2015 führt weiter.*

[8] Glasserman, P.: *Monte Carlo Methods in Financial Engineering*. Springer 2004.

Die Simulation aus der Sicht der Finanzmathematik: Varianzreduktion, Quasi-Monte-Carlo mit Brownscher Brücke, Pfaddiskretisierung, seltene Ereignisse. ***Die beste Darstellung der Kapitel 5, 6 und 9 für Leser mit Band 25****; die Beispiele sind Optionen, die Methoden allgemein.*

[9] Hammersley, J., Handscomb, D.: *Monte Carlo Methods*. Methuen 1964.

Die erste Monographie — antithetische Variablen, Kontrollvariablen, Wichtigkeit, auf 180 *Seiten.* ***Noch heute lesbar und ein Dokument des Anfangs****: Vieles, was später wiederentdeckt wurde, steht hier.*

[10] Hedtstück, U.: *Simulation diskreter Prozesse*. Springer Vieweg 2013.

Auf Deutsch*: die ereignisgesteuerte Simulation von Grund auf — Ereignisliste, Zustand, Zufallszahlen, Warteschlangen, statistische Auswertung —, mit Beispielen aus Fertigung und Verkehr. Die deutschsprachige Entsprechung zu Kapitel 10 und 11; knapp und für Leser ohne Band 25 zugänglich.*

[11] Kloeden, P., Platen, E.: *Numerical Solution of Stochastic Differential Equations*. Springer 1992.

Das Standardwerk zu Kapitel 9.3: Euler–Maruyama, Milstein, starke und schwache Ordnung mit allen Beweisen, höhere Verfahren. Die Fundstelle für die vierte Auslassung.

[12] Knuth, D.: *The Art of Computer Programming, Bd. 2: Seminumerical Algorithms*. 3. Aufl., Addison-Wesley 1997.

Das Kapitel über Zufallszahlen ist die Quelle von Kapitel 2 — lineare Generatoren, der Satz von Hull und Dobell (erste Auslassung), der Spektraltest, statistische Prüfungen. ***Mit Knuths Geschichte des Generators, den er selbst falsch baute.***

[13] Kolonko, M.: *Stochastische Simulation*. Vieweg+Teubner 2008.

Auf Deutsch, mit Beweisen*: Zufallszahlen und ihre Prüfung, Erzeugung von Verteilungen, Varianzreduktion, Markow-Ketten-Verfahren, Auswertung abhängiger Ausgaben. Die Kapitel 2, 4, 5 und 7 dieses Bandes in strengerer Form; die Fundstelle für Leser, die die Beweise in deutscher Sprache lesen wollen.*

[14] Kroese, D., Taimre, T., Botev, Z.: *Handbook of Monte Carlo Methods*. Wiley 2011.

Ein Nachschlagewerk mit Programmcode für fast alles in diesem Band: Erzeugung von Verteilungen, Varianzreduktion, Markow-Ketten, seltene Ereignisse mit Kreuzentropie und Aufspaltung. ***Für Leser, die es umsetzen wollen.***

[15] L'Ecuyer, P.: *Random Number Generation*. In: Handbook of Computational Statistics, Springer 2012.

Die moderne Übersicht über Generatoren — kombinierte, Mersenne-Twister, Zählergeneratoren, Ströme und Teilströme für parallele Läufe. ***Die Quelle für die Regeln in Kapitel 13*** *zu abgeleiteten Strömen.*

[16] Law, A.: *Simulation Modeling and Analysis*. 5. Aufl., McGraw-Hill 2015.

Das Standardwerk der ereignisgesteuerten Simulation — Teil IV — und der Statistik der Ausgaben, Kapitel 4. ***Mit dem Kapitel über gemeinsame Zufallszahlen und ihre Synchronisation****, das Aufgabe 4.3 zugrunde liegt. Ingenieurnah, mit vielen Fallstudien.*

[17] Liu, J.: *Monte Carlo Strategies in Scientific Computing*. Springer 2001.

Wichtigkeitsstichprobe, Markow-Ketten und Teilchenfilter aus einer Hand, mit den Verbindungen, die dieser Band betont — der Unabhängigkeitsvorschlag als Gegenstück zur Wichtigkeit, der Filter als Wichtigkeit über die Zeit. ***Das Buch für Leser, die die Einheit des Fachs sehen wollen.***

[18] Metropolis, N., Rosenbluth, A., Rosenbluth, M., Teller, A., Teller, E.: *Equation of State Calculations by Fast Computing Machines*. J. Chem. Phys. 21, 1953.

Der Algorithmus im Original, auf sechs Seiten, mit den harten Scheiben in der Schachtel. ***Lesenswert für die Klarheit*** *— und für den Satz, dass das Verfahren "obviously" die richtige Verteilung liefert; der Beweis ist ein Absatz.*

[19] Müller-Gronbach, T., Novak, E., Ritter, K.: *Monte Carlo-Algorithmen*. Springer 2012.

Auf Deutsch, mathematisch streng*: Zufallszahlen, Integration, Fluch der Dimension, Varianzreduktion, Markow-Ketten, stochastische Differentialgleichungen; mit Beweisen und mit der Frage, was Zufall gegenüber deterministischen Verfahren prinzipiell leisten kann (Kapitel 3 und 6). Die deutschsprachige Fundstelle für die Sätze dieses Bandes und die natürliche Fortsetzung für Leser, die Band 20 kennen.*

[20] Neal, R.: *MCMC Using Hamiltonian Dynamics*. In: [3], 2011.

Die Einführung in Kapitel 9.2 — Sprungverfahren, Volumenerhaltung, Abstimmung von ε und L, die Klippe des Bruchfalls. Frei verfügbar. ***Wer eine Sache aus diesem Band weiterliest, sollte diese wählen.***

[21] Niederreiter, H.: *Random Number Generation and Quasi-Monte Carlo Methods*. SIAM 1992.

Die Theorie der Diskrepanz, der Satz von Koksma–Hlawka (zweite Auslassung), die Konstruktion der Folgen von Sobol und Halton. ***Zahlentheoretisch streng****; die Quelle für Kapitel 6.4.*

[22] Owen, A.: *Monte Carlo Theory, Methods and Examples*. Stanford, online, 2013 ff.

Das vollständigste moderne Lehrbuch, frei verfügbar, laufend erweitert*: Zufallszahlen, Varianzreduktion, Quasi-Monte-Carlo mit Verwürfelung, Markow-Ketten, seltene Ereignisse. Owens eigene Erfindungen — die verwürfelten Netze — stehen in Kapitel 17. Die Hauptquelle dieses Bandes neben [2] und [24].*

[23] Robert, C., Casella, G.: *Monte Carlo Statistical Methods*. 2. Aufl., Springer 2004.

Die Markow-Ketten-Verfahren aus Sicht der Statistik, mit Beweisen: Metropolis–Hastings, Gibbs, Konvergenz, Diagnostik, Rao-Blackwellisierung. ***Die Fundstelle für Satz 7.2 in voller Allgemeinheit*** *und für die Theorie hinter Kapitel 8.*

[24] Ross, S.: *Simulation*. 6. Aufl., Academic Press 2022.

Der Einstieg*: Zufallszahlen, Erzeugung von Verteilungen, ereignisgesteuerte Simulation, Varianzreduktion, Bootstrap — knapp, mit vielen Aufgaben, ohne mehr Voraussetzungen als Band 15. Die Kapitel 1, 2 und 10 dieses Bandes folgen seiner Anlage.*

[25] Rubinstein, R., Kroese, D.: *Simulation and the Monte Carlo Method*. 3. Aufl., Wiley 2017.

Der Klassiker von 1981 in dritter Auflage, mit der Kreuzentropie-Methode (Kapitel 11, Forschungskasten) aus der Feder ihres Erfinders. Breit, mit Aufgaben; die Kapitel zu seltenen Ereignissen sind der Grund, es zu besitzen.

[26] Saltelli, A., Ratto, M., Andres, T., Campolongo, F., Cariboni, J., Gatelli, D., Saisana, M., Tarantola, S.: *Global Sensitivity Analysis: The Primer*. Wiley 2008.

Sobol-Indizes, ihre Schätzung aus $N(d+2)$ Läufen, Versuchspläne — Kapitel 14 in Breite, mit der Zerlegung (fünfte Auslassung). ***Das Lehrbuch der Sensitivitätsanalyse****, aus der Werkstatt, die sie zur Pflicht gemacht hat.*

[27] Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., Bürkner, P.-C.: *Rank-Normalization, Folding, and Localization: An Improved $\hat{R}$*. Bayesian Anal. 16, 2021.

Die Weiterentwicklung von $\hat{R}$ aus dem Forschungskasten in Kapitel 8: robust gegen schwere Ränder, mit getrenntem wirksamem n für Ränder und Mitte. ***Was Stan heute berechnet, steht hier.***

[28] Waldmann, K.-H., Helm, W.: *Simulation stochastischer Systeme — Eine anwendungsorientierte Einführung*. Springer Gabler 2016.

Auf Deutsch*: Zufallszahlen, Erzeugung von Verteilungen, ereignisgesteuerte Simulation von Warteschlangen und Lagersystemen, statistische Auswertung mit Einschwingphase und Blockmitteln — die Kapitel 1, 2, 4 und 10 dieses Bandes. Mit Beispielen aus Produktion und Logistik, die sich eins zu eins auf die Station übertragen lassen.*